

专业学位硕士学位论文

基于云台摄像机的特定目标实时检测与跟踪算法研究

Research on Real-time Detection and Tracking of Specific Target
Based on PTZ Camera

作者姓名: 姚贝
工程领域: 控制工程
学号: 1120171268
指导教师: 胡英 副教授
学位类别: 工程硕士
培养单位: 船舶电气工程学院
答辩时间: 2020 年 6 月

大连海事大学

Dalian Maritime University

大连海事大学

研究生学位论文原创性声明

本人郑重声明：所呈交的学位论文，是本人在导师的指导下进行研究工作所取得的成果。尽我所知，除文中已经注明引用内容和致谢的地方外，本论文不包含任何其他个人或集体已经发表或撰写过的研究成果。对论文所涉及的研究工作做出贡献的其他个人和集体，均已在论文中以明确的方式标明或致谢。

若有不实之处，本人愿意承担相关法律责任。

作者签名： 姚贝 日期： 2020 年 6 月 14 日

摘 要

随着科技不断创新发展,人们生活水平不断提高,智能监控越来越被重视,在诸多领域中广泛应用。虽然云台式摄像机已经得到了广泛安装,但对目标的监控和跟踪还需人工操作来完成。为了解决这一问题,本文提出了基于云台摄像机的特定目标检测跟踪系统。利用跟踪算法获取目标的位置和大小,再结合云台控制系统转动和缩放,保证目标能始终位于监控画面中心,以达到最佳的连续跟踪效果。本文的主要研究内容如下:

首先,研究了适用于云台摄像机的三种常用跟踪算法,阐述了它们的优劣性,并通过实验进行了分析比较。

然后,重点研究了 TLD 目标跟踪算法,该算法对目标遮挡、目标短暂消失以及长时间跟踪的情况效果较好。对 TLD 算法从检测模块、跟踪模块和学习模块进行了分析和改进,通过将 fDSST 跟踪算法与 TLD 算法相融合和缩小 TLD 算法检测模块中滑动窗口范围,来提高该算法的跟踪性能。

最后,对云台摄像机自动跟踪系统进行了设计。在设计控制算法时,将其分成两个部分:转动预测部分、云台控制部分。利用该系统自动控制云台的转动和镜头变倍,对监控目标进行实时跟踪,使得监控目标始终以合适的尺寸显示在监控画面中心区域,从而提升监控效果。

为了检验本文整体系统的可行性,选用海康威视云台摄像机对本文系统进行了实验及分析。实验结果表明本文整体系统具有良好的实时性和稳定的跟踪效果。

关键词: 目标跟踪; 云台摄像机; TLD 跟踪算法; 云台控制; 智能监控

Research on Real-time Detection and Tracking of Specific Target Based on PTZ Camera

Abstract

With the continuous innovation and development of science and technology and the continuous improvement of people's living standards, intelligent monitoring has been paid more and more attention and is widely used in many fields. Although the PTZ cameras have been widely installed, the monitoring and tracking of targets still require manual operations. In order to solve this problem, this thesis presents the research on the detection and tracking algorithm of the specific target based on the PTZ camera. Use the tracking algorithm to obtain the position and size of the target, combined with the pan and tilt control system rotation and zoom to ensure that the target can always be located in the center of the monitoring screen to achieve the best continuous tracking effect. The main research contents are as follows:

First, the three commonly used algorithms for PTZ cameras are studied, the advantages and disadvantages of the three algorithms are described, and the analysis and comparison are made through experiments.

Then, we focus on the TLD target tracking algorithm, which has a good effect on target occlusion, target short-term disappearance and long-term tracking. The TLD algorithm is analyzed and improved from the detection module, tracking module and learning module. The tracking performance of the algorithm is improved by fusing the fDSST tracking algorithm with the TLD algorithm and narrowing the sliding window range in the TLD algorithm detection module.

Finally, the PTZ camera automatic tracking system is designed. When designing the control algorithm, it is divided into two parts: the rotation prediction part and the PTZ control part. The system can automatically control the rotation of the pan tilt and zoom of the lens to track the monitoring target in real time, so that the monitoring target is always displayed in the central area of the monitoring screen with appropriate size, so as to improve the monitoring effect.

In order to test the feasibility of the whole system in this thesis, the experiment and analysis of the system are carried out by using the Hikvision PTZ camera. The experimental results show that the whole system has good real-time performance and stable tracking effect.

Key Words: Target Tracking; PTZ Camera; TLD Tracking Algorithm; PTZ Control; Intelligent Monitoring

目录

摘 要.....	I
Abstract.....	II
1 绪论.....	1
1.1 研究背景及意义.....	1
1.2 国内外研究现状.....	2
1.2.1 监控技术简介.....	2
1.2.2 运动目标检测.....	2
1.2.3 运动目标跟踪.....	3
1.3 主要研究内容及章节安排.....	4
2 传统的运动目标跟踪算法研究.....	5
2.1 Mean Shift 算法.....	5
2.2 CamShift 算法.....	7
2.3 粒子滤波算法.....	8
2.4 实验结果及分析.....	9
2.5 本章小结.....	11
3 基于在线学习 TLD 跟踪算法的研究及优化.....	13
3.1 TLD 跟踪算法概述.....	13
3.2 TLD 跟踪算法的跟踪模块.....	14
3.2.1 金字塔 LK 光流法.....	14
3.2.2 前向后向误差检测.....	15
3.2.3 跟踪流程.....	16
3.3 TLD 跟踪算法的检测模块.....	17
3.3.1 方差分类器.....	18
3.3.2 集成分类器.....	18
3.3.3 最近邻分类器.....	19
3.4 TLD 跟踪算法的学习模块.....	20
3.4.1 P-N 学习流程.....	20
3.4.2 P-N 学习的稳定性分析.....	20
3.5 TLD 算法优缺点分析.....	22
3.6 特定目标选择方式.....	22
3.6.1 行人自动检测.....	22

3.6.2	越界判断.....	24
3.7	TLD 算法检测部分改进.....	25
3.8	TLD 算法跟踪部分改进.....	28
3.8.1	fDSST 算法.....	28
3.8.2	fDSST 算法和 TLD 算法融合.....	30
3.9	实验结果及分析.....	31
3.9.1	实验平台.....	31
3.9.2	评价跟踪算法性能的指标.....	31
3.9.3	实验数据集.....	32
3.9.4	实验结果分析.....	33
4	云台摄像机跟踪控制系统.....	37
4.1	系统设计.....	37
4.1.1	系统硬件.....	37
4.1.2	系统软件开发环境.....	38
4.1.3	系统结构.....	38
4.2	云台摄像机控制算法.....	39
4.2.1	云台转动预测.....	39
4.2.2	云台控制.....	41
4.3	本章小结.....	45
5	系统实验结果及分析.....	46
5.1	系统整体界面设计.....	46
5.2	特定目标选取实验测试.....	46
5.2.1	自动行人检测.....	46
5.2.2	越界判断.....	47
5.3	云台控制系统的实验结果及分析.....	48
	总结与展望.....	51
	参考文献.....	52
	致谢.....	55
	大连海事大学学位论文授权使用声明.....	56

图表目录

图目录

图 1.1	传统的视频监控.....	1
图 2.1	Mean Shift 算法示意图.....	6
图 2.2	CamShift 跟踪算法流程图.....	7
图 2.3	粒子滤波跟踪算法流程图.....	8
图 2.4	三种算法的实验结果.....	10
图 2.5	Camshift 跟踪算法实验结果.....	11
图 3.1	TLD 跟踪算法框架图.....	13
图 3.2	前向后向误差示意图.....	16
图 3.3	前向后向误差计算原理.....	16
图 3.4	跟踪模块的跟踪原理.....	17
图 3.5	检测器模块.....	17
图 3.6	决策树示意图.....	18
图 3.7	P-N 学习框架图.....	20
图 3.8	行人检测方法.....	23
图 3.9	HOG 特征提取基本流程.....	23
图 3.10	基于支持向量机的分类算法流程图.....	24
图 3.11	越界判断流程图.....	24
图 3.12	缩小扫描区域示意图.....	26
图 3.13	缩小后滑动窗口区域.....	26
图 3.14	动态调整检测窗口的流程图.....	27
图 3.15	fDSST 位置滤波器和尺度滤波器目标位置估计过程.....	29
图 3.16	fDSST 算法与 TLD 算法融合.....	30
图 3.17	Woman 数据集跟踪效果图.....	33
图 3.18	David 数据集跟踪效果图.....	34
图 3.19	skating2 数据集跟踪效果图.....	34
图 3.20	跟踪算法在 3 个数据集上跟踪精度.....	35
图 3.21	跟踪算法在 3 个数据集上跟踪重叠度.....	35
图 4.1	云台摄像机实物图.....	37
图 4.2	软件系统框图.....	38
图 4.3	云台的预测跟踪模型.....	39

图 4.4	云台控制系统模块结构图.....	41
图 4.5	图像平面的像素坐标示意图.....	42
图 4.6	转速对应级别.....	43
图 5.1	系统控制界面.....	46
图 5.2	行人检测结果.....	47
图 5.3	目标跟踪效果图.....	47
图 5.4	未变换之前的监测矩形.....	48
图 5.5	变换之后的监测矩形.....	48
图 5.6	界内.....	48
图 5.7	界外.....	48
图 5.8	云台跟踪中的目标中心点的坐标位置散点图.....	49
图 5.9	改进后 TLD 算法云台摄像机目标跟踪.....	50

表目录

表 3.1	对更改扫描区域前后的情况对比.....	27
表 3.2	数据集.....	32
表 3.3	跟踪算法在 3 个数据集上跟踪平均帧率.....	35
表 4.1	海康 DS-2DC4223IW-D 网络监控球机参数表.....	37

1 绪论

1.1 研究背景及意义

计算机视觉是计算机和多媒体技术飞速发展下的产物，是顺应时势而生的。所谓的计算机视觉^[1]其实就是以计算机和摄像机为硬件设备，模拟生物视觉的一种方法，其最主要的任务就是利用各种成像系统来取代生物视觉器官，采集视频信息，再利用计算机代替大脑，完成处理和分析的任务，从而获得对应场景中的有效信息。如实现运动目标识别、跟踪和测量等功能。通过研究实现计算机视觉，让计算机能够和人类一样通过视觉对世界进行观察和分析。

视觉跟踪技术是计算机视觉领域中一个十分热门的研究课题，具有很高的实践研究意义，许多行业已经应用了这一技术，例如：车辆导航、生物医学、智能监控^[2]、交通运输^[3]、机器人视觉^[4]和航空航天^[5]等方面。近年来，国家对公共安防、社会安全等方面的投入也在逐年增加，为构建“和谐社会，平安城市”的口号而努力^[6]，智能监控系统更是广泛应用于机场、商场、银行、街道等场所。传统的监控系统主要有两种工作形态，一种是实时监控，一种是存储监控。其中实时监控，是将监控摄像机监测的视频统一传输到监控墙上，安排专人值班观测，需要耗费大量的人力和物力才能实现监控的实时观察，从资源的角度来说是一种浪费，此外，其监控效率低、监控成本高且缺乏客观性^[7]；而存储监控，是将摄像机监测视频通过一个较大的硬盘存储，便于在出现问题时，通过本地视频的调取对相关情况进行了解，其主要缺点是存储设备的容量有限，导致最先存储的视频会被不断的更替。



图 1.1 传统的视频监控

Fig. 1.1 Traditional video surveillance

由于存在上述不足,智能监控系统越来越受国内外学者的关注,目前智能监控已成为视频监控技术的研究热点。与传统视频监控相比,智能监控系统避免了人为干预,使分析、判断和预测的结果更加准确可靠,提高了监控效率,节省了人力,节约了成本^[8]。对于运动目标容易超过单个摄像机监控区域的问题,一般有两种可行性解决方案,一种是利用多个摄像机监控画面来回切换,另一种是利用云台变倍摄像机。后一种方法往往要比前一种更可取,主要是因为跨摄像机跟踪易出现摄像机间的盲区和多摄像机的视野变化不一致。而使用云台变倍摄像机跟踪目标时,却可随跟踪目标灵活变动,实时跟踪。

综上所述,利用云台摄像机实现运动目标跟踪是智能监控系统的发展趋势,是对视频监控的全面提升,是超越传统视频监控系统^[9]的关键,所以本文将对基于云台摄像机特定目标检测跟踪算法进行研究。

1.2 国内外研究现状

1.2.1 监控技术简介

从模拟视频监控系统(Closed Circuit Television,CCTV)到基于“PC+多媒体卡”的数字视频监控系统(Digital Video Recorder,DVR),再到基于IP网络的智能视频监控系统(IPVS),经历了视频监控系统发展的三个阶段,监控技术的发展发生了巨大变化^[10]。

美国的专家学者对视频监控技术的研究从上个世纪末美国国防署(DARPA)部署和启动的VSAM(Video Surveillance and Monitoring)项目^[11]便开始了,还有AVS(Airborne Video Surveillance)项目^[12]和HID(Human Identification at a Distance)^[13]计划。此外,日本开展的CDVP项目对公共区域的图像监控进行了深入研究^[14]。在智能监控领域,IBM、微软等企业也投入了相当可观的实验经费^[15],进行了大量的研究。

在这一领域,许多高校也有了自己的研究成果,如北京航空航天大学开发的面向生物医学工程的微操作机器人^[16]和浙江大学开发的捕获人体动作的系统^[17]等研究。此外,国内一些安防行业领先企业也开始推出自己的智能监控产品,如:华为公司为土耳其TCDD高铁监控、长沙天网平安城市项目、摩尔多瓦交通监控项目等多个领域提供智能视频解决方案^[18];大华公司提供了高清电子警察智能监控给济宁梁山电子警察项目、江苏沭阳3.20项目等^[19]。

1.2.2 运动目标检测

本文的研究重点是适用于云台摄像机特定目标跟踪算法和控制算法,所谓的特定目标是指人为设定、入侵或越界等特有规定的目标。由于检测算法只在目标选择部分涉及,所以在这只做简单介绍。基于静态背景下的运动目标检测算法主要有背景差分法、帧间

差分法和光流法。

背景差分法：将当前每一帧图像与事先存储或实时获取的背景图像相减，设置合理的阈值以及判别，再将计算出与背景偏离超过一定阈值的区域作为运动区域^[20]。该算法不仅实现简单而且还可以得到相对完整的运动目标位置和轮廓等信息。而前景提取效果的好坏关键在于背景模型的更新和获取，背景获取算法通常要求在场景中存在运动目标的情况下来获取精确的背景图像，根据视频序列中每一帧图像的变化对背景图像进行有针对性的更新，可以使背景能够适应场景中的各种变化和干扰，例如光线的改变和移动的行人等。

帧间差分法：先计算图像序列相邻两帧或多帧的差分，而运动目标的轮廓通过阈值化等处理后才能确定^[21]。帧间差分法具有计算简单和不受光线影响的特点，因此，在实际应用中备受欢迎。目标的速度是影响提取和检测结果准确与否的关键因素，因此在使用该方法时，一定要确保速度保持在合适的区间，速度过快或过慢都不适合这一方法。

光流法：利用图像序列中像素在时域的变化及相邻帧间的相关性来找到上一帧和当前帧之间存在的对应关系，从而计算出相邻帧之间物体的运动信息的一种方法^[22]。这种方法在使用过程中，不易受物体被遮挡问题的影响，甚至对相机自身的运动也能适应。但其缺点是计算繁琐、抗噪性较弱，实际应用的效果并不理想。

1.2.3 运动目标跟踪

经科研人员的不懈努力，新的目标跟踪算法不断涌现。以驱动方式为依据，大体可以将跟踪算法的构建的思路分为自顶而下和自底而上两种。自顶而下的跟踪算法通常是在图像序列中进行匹配或者求取最大后验概率来寻找目标，但要依赖所构建的模型和先验知识，而自底而上的跟踪算法直接在图像序列中进行目标检测和跟踪，不依赖于先验知识^[23]。

在目标跟踪算法中，先要通过人工初始化或自动初始化的方式对目标进行初始化的处理，发展至今，国内外研究人员做了大量的实验研究，提出了很多优秀算法。在对目标跟踪过程进行建模时，选择确定的动态系统建模，并依据图片序列中已有的位置滤波估计得到未知的目标位置的预测算法，其中 Carpenter 等人提出的粒子滤波方法和 Kalman R.E.提出的卡尔曼滤波方法^[24-25]，在 19 世纪中后期最具代表性。目标跟踪也被科学家们看做模板匹配的过程，以模板创建、匹配的方法为依据，又可以分为生成式跟踪算法和判别式跟踪算法。生成式跟踪算法如：于 2008 年根据子空间学习的增量提出的学习跟踪算法，2012 年基于稀疏表示的协同模型跟踪算法和 2014 年提出的超像素跟踪算法^[26-28]。生成式跟踪算法最终的跟踪目标是匹配搜索得出的最相似目标，这一过程利用了学习建立的自适应性外观模型来实现，由于外观模型的复杂性和候选区域较大的

特点，在实际应用中并不实用。而以检测的在线学习方法为基础，提出的判别式跟踪算法，拥有非常优秀的特性，具有代表性的算法有：多示例学习跟踪算法^[29]、压缩感知算法^[30]、在线判别特征跟踪算法^[31]、循环结构的检测跟踪算法和 KCF 器跟踪算法^[32]。随着信息技术的快速发展，对视觉目标跟踪的要求越来越高，因此，在实用性、目标外观适用性和在线学习能力等方面急需提高。

1.3 主要研究内容及章节安排

本文主要基于云台摄像机对特定目标进行检测跟踪，在对传统常用于云台摄像机的跟踪算法进行实验对比后，选择了 TLD 算法应用于本文的云台摄像机。为了提高跟踪性能，更好的结合云台控制系统进行跟踪，对 TLD 算法进行了优化改进，从而达到实时跟踪的效果。

本文的结构和内容如下：

第一章：绪论。本章阐述本文的研究背景及意义，介绍国内外研究现状，安排主要内容和结构。

第二章：传统的运动目标跟踪算法研究。本章简要介绍三种常用于云台摄像机运动目标跟踪算法，进行了实验对比分析，阐述了它们的优缺点。

第三章：基于在线学习 TLD 跟踪算法的研究。本章首先介绍了 TLD 算法的工作原理和 workflow，然后对该算法进行优化，使其更好的应用于云台摄像机进行跟踪。针对 TLD 算法的缺点，本文将 fDSST 跟踪算法与 TLD 算法进行融合，又改进了 TLD 算法检测模块中滑动窗口范围，提高了算法的跟踪性能。最后介绍了评价跟踪算法性能的指标，并通过多次实验证明了改进后该算法的有效性。

第四章：云台摄像机跟踪控制系统。本章介绍了系统硬件配置、软件开发环境和系统结构。在设计控制算法时，将其分成两个部分：转动预测部分、云台控制部分。在介绍了本文采用的中心点预测算法后，又详细介绍了云台控制部分的云台转动方向、转动速度和镜头变倍的控制方法，构建了完整的控制系统。

第五章：系统实验结果及分析。本章设计了智能监控系统界面，对特定目标的选取和云台控制系统进行了实验测试。

2 传统的运动目标跟踪算法研究

在计算机视觉领域中,运动目标跟踪具有非常重要的意义,其包含了模式识别、自动控制、人工智能和图像处理等专业性问题的。在给定视频图像序列初始帧目标大小与位置的情况下,预测后续帧中该目标的大小与位置,这就是跟踪的任务^[33]。随着人们生活水平日益提高,计算机性能和摄像机成像质量也有了质的飞跃,在多种因素的综合影响下,计算机视觉的应用也越来越广泛,在企业和研究领域的热度也在持续升温。近几年,视觉跟踪技术日趋成熟,但还存在着一些问题急需解决,例如:目标遮挡、运动目标形状变化、姿态变化、大小变化、光照干扰、实时性和鲁棒性等问题,对科研人员来说仍是一个巨大的挑战。

目前传统跟踪算法大体可以分为两大类,确定性跟踪法和概率性跟踪法。前者的典型算法是 Mean Shift 算法,后者是粒子滤波算法,也是近年来常用于云台摄像机运动目标跟踪算法。Mean Shift 算法复杂度低,实时性好,对目标变形也有较好的抵御性,但是其使用直方图模型建模,保留空间信息较少,导致跟踪准确度低,对遮挡问题不敏感,所以科研人员在此基础上又提出了 CamShift 算法,对遮挡问题有了较好的改善。粒子滤波跟踪算法能较好地克服复杂环境的噪声,但该算法也存在着粒子退化现象严重,特征单一,目标模板更新不及时等问题。故学者们提出了一系列改进算法,如文献[34]提出一种利用 Kalman 预测器改进的 CamShift 算法;文献[35]提出一种将 Mean Shift 算法和粒子滤波结合的跟踪算法;文献[36]提出结合样本特征和位置融合的粒子滤波跟踪算法。改进后的算法性能都有所提高,因此许多学者都把目光转移到了方案的改进上面。本章首先从传统跟踪算法的介绍开始,进而分析和研究行人跟踪问题。

2.1 Mean Shift 算法

Mean Shift 算法^[37-38]是基于密度的非参数聚类算法,其算法思想是假设不同簇类的数据集符合不同的概率密度分布,找到任一样本点密度增大的最快方向,样本密度高的区域对应于该分布的最大值,这些样本点最终会在局部密度最大处收敛,且收敛到相同局部最大值的点被认为是同一簇类的成员。该算法用于跟踪时,首先需要计算目标区和候选区内像素的特征值概率,通过计算得到目标模型和候选模型的描述信息,然后通过相似函数的引入,进而得到候选模型和目标模型帧的相似之处,将相似信息代入到相似函数中,最后选择使相似函数最大的候选模型并得到关于目标模型的 Mean Shift 向量,该向量就是从最初的位置移动到目标位置的向量。由于均值漂移算法的快速收敛性,通过不断迭代计算 Mean Shift 向量,算法最终将收敛到目标的真实位置,达到跟踪的目的。

如图 2.1 所示为 Mean Shift 跟踪算法的流程图。




图 2.1 Mean Shift 算法示意图

Fig. 2.1 Flow chart of Mean Shift

下面是 Mean Shift 算法目标跟踪的过程：

- (1) 选择一个矩形窗口，记录矩形框的坐标和大小。
- (2) 将 RGB 颜色空间转化成 HSV 颜色空间，HSV 归一化到 0~255。计算 HSV 第一个通道 H 的直方图。
- (3) 根据直方图求反向投影图，用颜色出现的概率替换图像中的像素值，再换算成灰度。因此，反向投影图是一幅灰度图像。
- (4) 利用 Mean Shift 算法计算出要跟踪的中心。矩形框的位置会不断调整，向着反向投影图中概率密度值最大的方向移动，最终移动到目标质心。
- (5) 输出实时跟踪后目标的新位置。

Mean Shift 算法用于视频目标跟踪时，搜索的特征就是目标颜色直方图，通过不断迭代，使得位置不断地收敛于正确位置，进而实现跟踪的目的。这一算法优点在于计算量小，在目标区域已知的情况下完全可以达到实时性，且采用核函数直方图模型，对边缘遮挡，目标旋转，变形和背景运动不敏感。不过，Mean Shift 算法也存在着如下缺点：缺乏必要的模板更新；跟踪过程中由于窗口宽度大小保持不变，当目标尺度有所变化时，

跟踪就会失败；当目标速度较快时，跟踪效果不好；直方图特征在目标颜色特征方面略显匮乏，缺少空间信息。

2.2 CamShift 算法

虽然 Mean Shift 算法有一些缺点，但由于其对复杂环境有一定的适应性且算法的实时性好，优点突出，因此 Mean Shift 算法依旧是研究的热点之一。随着研究的深入，出现了 Mean Shift 算法的改进：CamShift 跟踪算法^[39]。此算法改进了 Mean Shift 算法中搜索窗口一旦初始化后就固定不变的缺陷，它可以根据视频序列的初始帧图像来进行搜索窗口的初始化，搜索窗口会根据上帧得到的结果不断的自动调整，进而实现中心位置的确定。CamShift 跟踪算法的流程图如图 2.2 所示。




图 2.2 CamShift 跟踪算法流程图

Fig. 2.2 Flow chart of CamShift

下面介绍用 CamShift 算法实现跟踪的具体过程：

- (1) 初始化搜索窗；
- (2) 计算搜索窗的颜色概率分布（反向投影）；
- (3) 运行 Mean Shift 算法，获得搜索窗新的大小和位置；
- (4) 将 (3) 中求得的新窗口重复 (1) (2) 过程。

CamShift 算法在计算的过程中,没有引入核函数,因此在计算中没有进行加权处理,这就意味着目标区域中,每一个像素点的权重是相等,这也是造成算法的抗噪性比较弱的主要原因。CamShift 算法中也没有定义候选目标,而是直接通过目标模板进行跟踪。在建立目标直方图模型时,采用方法为 HSV 色彩空间的 H 分量,因此,色彩信息是其跟踪的唯一线索, CamShift 会自动将其包括在内,导致跟踪窗口扩大,有时甚至会将跟踪窗口扩大到整个视频大小,导致目标定位的不准确,连续跟踪下去会造成目标的丢失。

2.3 粒子滤波算法

粒子滤波算法^[40]是属于预测算法的一种,将跟踪描述成状态空间中的贝叶斯估计问题,先根据先验条件的概率密度函数在状态空间中生成一个粒子的集合,然后将这些粒子的权重进行粒子之间的加权均值来替代积分运算,要对粒子进行重采样,再根据这些相关的信息来完善之前的先验条件概率密度函数,最后获得目标状态。粒子滤波算法是一种有效的非线性滤波技术,几乎可以应用在任何状态空间来表示非线性随机系统中。基于粒子滤波的运动目标跟踪实验中使用的是直方图特征,计算量小、对方向和尺寸变化不敏感,对有部分遮挡时也可以保持鲁棒性,当粒子数量足够大时,估计的后验概率密度函数就和真实的后验概率很相近了。粒子跟踪算法的流程图如图 2.3 所示。




图 2.3 粒子滤波跟踪算法流程图

Fig. 2.3 Flow chart of particle filtering

下面介绍用粒子算法实现跟踪的具体过程:

(1) 初始化阶段: 生成初始粒子集合, 将粒子在空间内均匀分布。在视频的初始阶段, 跟踪目标的选取通过手动完成, 并将跟踪目标框的大小和位置坐标记录下来。对图像序列进行均值滤波出来后, 将颜色空间从 RGB 转化成 HSV。

(2) 预测阶段: 根据状态转移方程, 每一个粒子得到一个预测粒子。先根据 $x(t-1)$ 的概率分布生成大量的采样, 这些采样就称为粒子。那么这些采样在状态空间中的分布实际上就是 $x(t-1)$ 的概率分布。

(3) 状态观测阶段: 计算粒子与跟踪目标的相似度, 更新每一个粒子的权值。对每一个粒子附近的区域求颜色直方图特征值, 再用巴氏系数计算其与跟踪目标区域的相似度, 越是和跟踪目标相似, 越可能是跟踪目标。

(4) 决策阶段: 计算跟踪目标的期望位置。对预测粒子进行评价, 其权重越大, 越有可能是跟踪目标位置, 但是权重最大的粒子不会被直接确定为跟踪结果, 而是通过计算大部分粒子的综合结果, 降低局部地区的敏感程度, 使跟踪更准确。

(5) 重采样阶段: 根据粒子权重对粒子进行筛选, 筛选过程中, 既要保留权重大的粒子, 又要保留一部分权重小的粒子, 复制权重大的粒子填满空间, 然后回到第(2)步继续。

粒子滤波算法与 Mean Shift 算法相比, 计算量虽然有所增加, 但是具有良好的鲁棒性。虽然重采样的方法可以避免由于粒子退化带来的影响, 但是也会导致粒子的多样性丧失。

2.4 实验结果及分析

为了对比上述几种算法的效果, 本文选用同一视频进行测试, 采用 C++ 语言编程, 在 windows10 平台进行测试, 实验测试结果如图 2.4 所示:



Mean Shift 跟踪算法实验结果



图 2.4 三种算法的实验结果

Fig. 2.4 Experimental results of three algorithms

为了对比三种算法的跟踪效果，截取了实验结果的第 23 帧、第 152 帧和第 423 帧如图 2.4 所示。为了避免干扰，测试跟踪算法的优劣性，选出更适应于云台摄像机的跟踪算法，所以本文选用的测试视频背景简单，目标颜色与背景差异较大，更利于跟踪。

通过实验发现，针对本视频的跟踪效果如下：三种算法的准确度都很高，Mean Shift 算法的平均帧率可达到 165 帧左右，Camshift 算法的平均帧率可达到 140 帧左右，粒子滤波算法的平均帧率可达到 125 帧左右，三种算法均满足实时性的要求，但是 Mean Shift 算法跟踪框的大小不会随着目标的尺寸变化，不利于接下来应用于云台摄像机时镜头变焦的研究，Camshift 算法和粒子滤波算法都具有跟踪框可以变化的特性，但 Camshift 算法的运行速度更快，所以 Camshift 算法能更好的满足本文的要求。

为了更深一步的探究 Camshift 算法，本文又选取一个背景相对复杂的视频，跟踪目标与背景颜色差异较小。实验测试结果如图 2.5 所示：



图 2.5 Camshift 跟踪算法实验结果
Fig. 2.5 Experimental results of Camshift

从如图 2.5 所示的实验结果中可以清晰的看出对于跟踪目标与背景颜色差异较小的视频时,跟踪的精确度受到了不小的影响,虽然说跟踪框将跟踪目标圈在了范围内,但是由于圈住的背景也非常的多,因此,跟踪目标非常容易丢失。所以 Camshift 算法也不是本文较理想应用于云台摄像机的跟踪算法。

2.5 本章小结

本章简单介绍了 Mean Shift、Camshift 和粒子滤波这三种经典的运动目标跟踪算法,并对其进行了实验分析和对比,阐述了它们各自的优缺点。从实验结果可以看出,在同一视频跟踪同一目标简单背景的实验时,三种算法都能很好的满足跟踪要求,其中 Mean Shift 算法和 Camshift 算法在速度方面更占优势,Camshift 算法和粒子算法跟踪框的大小可以随着目标的尺寸变化,因此 Camshift 算法相对跟踪效果更好。为了更好的研究 Camshift 算法,本文又对其在背景和跟踪目标差异较小视频中进行了实验,实验结果表明 Camshift 算法的准确度明显降低。

实际行人跟踪应用监控场景中,背景的复杂程度是不确定的。有的监控场景单一固定,如建筑物或路面等,有的则是复杂多变,如行驶中的汽车、行人的路面或商场等。此外,本文研究的是基于云台摄像机的行人跟踪,摄像机的视角会随着目标转动,镜头会根据目标尺寸缩放,导致背景更加复杂多变。以上均为背景环境外在的外观变化,而在视觉跟踪中还有其物体本身内在的外观变化,如跟踪目标的姿态变化或形变等内在固有的外观变化。但是以上三种传统跟踪算法均不能适应外观变化,因为这类传统方法所用的特征如边缘、纹理和颜色等,是在第一帧时就确定好的,在随后的图像帧中也不能再改变。而解决外观变化在线学习的跟踪方法是最为行之有效的途径,该类方法可以自适应地增量更新外观模型,因此具有非常高的研究价值。

在线学习的跟踪方法众多,文献[41]中在 50 个标准数据集上对 29 种算法进行了测试,其中 TLD 算法相较于其他算法,更好的解决了跟踪目标丢失后,再次出现在监控视

野内，无法跟踪的问题，而且是一种能实现长时间跟踪效果较好的算法，非常有利于应用在本文的云台摄像机进行实际监控，所以本文选择了 TLD 在线跟踪算法作为接下来研究的跟踪算法并对其进行了优化。

3 基于在线学习 TLD 跟踪算法的研究及优化

3.1 TLD 跟踪算法概述

TLD 算法^[42-43](Tracking-Learning-Detection)是一种新的单目标长时间跟踪算法,由英国萨里大学的一个捷克籍博士生 Zdenek Kalal 在其攻读博士学位期间提出的。传统跟踪算法的跟踪结果非常容易受到跟踪目标形变或是被遮挡的影响,而 TLD 算法却可以完美的解决这一问题,它是将检测算法和跟踪算法相结合。同时,通过一种改进的在线学习机制不断更新跟踪模块的“显著特征点”和检测模块的目标模型及相关参数,从而使得跟踪效果更加稳定、鲁棒和可靠。

简单来说,TLD 算法主要由三部分组成:跟踪模块、检测模块、学习模块。




图 3.1 TLD 跟踪算法框架图

Fig. 3.1 TLD framework diagram

如图 3.1 所示为 TLD 算法的实现框图^[44-45]。首先对被跟踪对象在初始位置上进行相关目标标定,然后进入跟踪模块,利用中值光流法进行跟踪,并将跟踪结果反馈到学习模块中,再加上初始视频序列中跟踪目标存在特征在学习模块中,就可以被当做正样本,再选取一些负样本就可以训练检测模块的检测器,这样检测模块和跟踪模块在初始时就有了相应的判断标准。接下来视频图像序列逐帧的通过检测模块和跟踪模块,得出的跟踪结果反馈到综合模块输出目标位置和学习模块进行重新训练。

接下来详细讲述 TLD 算法中跟踪、检测和学习模块的实现原理。

3.2 TLD 跟踪算法的跟踪模块

TLD 跟踪算法的跟踪模块采用中值光流法(Median Flow)。跟踪模块的基础为金字塔 LK 光流法，并在算法中融入了向前向后误差算法，再加校正前后帧特征与误差算法相似程度的过程，可以很好的将不可靠的跟踪点去除，与此同时，跟踪失败自检测算法的辅助，使得跟踪结果的精确度更高。

3.2.1 金字塔 LK 光流法

光流算法是一种两帧差分的光流估计算法。光流表示的是视频图像序列中运动物体的瞬时速度，Horn 和 Schunck 在 1981 年提出著名的亮度恒定假设^[46]，用光流约束方程来对光流进行求解。为了防止该方法产生多个光流，需要在使用的过程中增加约束条件，进而实现解的唯一性，而求取的光流算法与增加的约束条件有着密切的关系，将局部平滑约束^[47]引入到 Lucas-Kanade 光流法方程中，就得了一个新的光流场（稀疏光流场），然后再通过图像的灰度梯度对光流进行计算。金字塔 LK 光流法的使用必须满足三种假设条件：亮度恒定不变、“小运动”和空间一致。

设在 t 时刻，像素点的坐标为 (x, y) ，时间经过了 dt ，位置坐标也会随之变化，坐标为 $(x + dx, y + dy)$ ，以亮度恒定约束方程为依据，公式(3.1)可以表示这一变化的过程。

$$I(x, y, t) = I(x + dx, y + dy, t + dt) \quad (3.1)$$

式中在 t 时刻，像素点的坐标为 (x, y) 时， $I(x, y, t)$ 为灰度值，对上式通过泰勒级数展开可得：

$$I(x, y, t) = I(x, y, t) + \frac{\partial I}{\partial x} \frac{dx}{dt} + \frac{\partial I}{\partial y} \frac{dy}{dt} + \frac{\partial I}{\partial t} + O(\partial^2) \quad (3.2)$$

其中 dx ， dy ， dt 的高阶项为 $O(\partial^2)$ ，若是满足上(3.2)式的条件下， $O(\partial^2)$ 可以被忽略，进而得出下面关系式：

$$I_x \mu_x + I_y \mu_y + I_t = 0 \quad (3.3)$$

式中 $\mu_x = dx/dt$ ， $\mu_y = dy/dt$ 是位置 (x, y) 处光流在水平和垂直的移动分量，光流 $\vec{v}$ 可表示为 (μ_x, μ_y) 。 I_x 、 I_y 、 I_t 分别表示位置 (x, y) 处灰度值的偏导数。

引入局部约束空间一致性假设, 来求解上述方程, 若 (x, y, t) 位置处像素点的光流为 (μ_x, μ_y) , 则该位置小领域内 $\Omega = \{(x_i, y_i, t_i) | i = 1, 2, \dots, n\}$ 全部像素点的光流均为 (μ_x, μ_y) 。则光流约束方程为式(3.4)所示。

$$I_x(i)\mu_x + I_y(i)\mu_y = -I_t(i), i = 1, 2, \dots, n \quad (3.4)$$

式中 n 代表光流点的数量, 采用矩阵的表示方式为(3.5):

$$\begin{bmatrix} \mu_x \\ \mu_y \end{bmatrix} = \begin{bmatrix} \sum_{i=1}^n I_{xi}^2 & \sum_{i=1}^n I_{xi} I_{yi} \\ \sum_{i=1}^n I_{xi} I_{yi} & \sum_{i=1}^n I_{yi}^2 \end{bmatrix} \begin{bmatrix} -\sum_{i=1}^n I_{xi} I_{ti} \\ -\sum_{i=1}^n I_{yi} I_{ti} \end{bmatrix} \quad (3.5)$$

式(3.5)是一个超定方程, 记作 $A\bar{v} = -b$, 可通过最小二乘法求解 (μ_x, μ_y) , 再根据公式 $A^T A\bar{v} = A^T(-b)$, 得到光流 $\bar{v}$ 的解, 其矩阵形式和展开式分别为式(3.6)和(3.7)。

$$\bar{v} = (A^T A)^{-1} A^T(-b) \quad (3.6)$$

$$\begin{bmatrix} \mu_x \\ \mu_y \end{bmatrix} = \begin{bmatrix} \sum_{i=1}^n I_{xi}^2 & \sum_{i=1}^n I_{xi} I_{yi} \\ \sum_{i=1}^n I_{xi} I_{yi} & \sum_{i=1}^n I_{yi}^2 \end{bmatrix} \begin{bmatrix} -\sum_{i=1}^n I_{xi} I_{ti} \\ -\sum_{i=1}^n I_{yi} I_{ti} \end{bmatrix} \quad (3.7)$$

在实际应用 LK 光流法时, 由于目标的运动很难保证相邻帧间位移很小, 导致跟踪的结果发生偏差, 金字塔 LK 光流法的引入就可以很好地解决这一问题。金字塔 LK 光流法的工作原理, 是从上到下, 将上一层的光流输入给下一层, 然后进行计算, 这个过程不断的重复, 直到最底层位置。并对跟踪目标根据这一层的光流进行标注, 这样就可以使 LK 光流法对大而不连贯的运动也具有可靠性。

3.2.2 前向后向误差检测

前向后向误差检测是我们假设跟踪算法应该具有正反向连续一致性, 因此, 不管是正序还是反序的跟踪轨迹在理论上都是一致的。因此, 前后向误差算法选用 I_{t+1} 帧到 I_t 帧的跟踪结果来检验 I_t 帧到 I_{t+1} 帧的跟踪结果。




图 3.2 前向后向误差示意图

Fig. 3.2 Schematic diagram of forward and backward errors

如上图 3.2 所示，在两帧图上都可以观测到点①的存在，那么点①的位置就能被准确的定位，跟踪轨迹也是保持基本一致的。而点②则是只出现在左图上，在右图上并没有发现，从前后跟踪轨迹上可知：跟踪器定位到的点不同，那么后向跟踪轨迹也就不可能与前向跟踪轨迹一致了。

误差距离与误差中值求取如式(3.8)和(3.9)所示：

$$FBerror = |\hat{X}_t - X_t| \quad (3.8)$$

$$MedFBerror = Med|\hat{X}_t - X_t| \quad (3.9)$$

若误差距离小于 $MedFBerror$ ，则该点的后向跟踪可信，该点轨迹保留；否则，将滤除。前向后向误差计算原理如图 3.3 所示。




图 3.3 前向后向误差计算原理

Fig. 3.3 Forward and backward error calculation principle

3.2.3 跟踪流程

跟踪模块的跟踪原理如图 3.4 所示。




Fig. 3.4 Tracking principle of the tracking module

跟踪模块的主要步骤如下：

(1) 在 t 时刻，均匀选取跟踪目标区域内的 $m \times n$ 个点，并通过金字塔 LK 光流法完成前向的跟踪，并在 $t+1$ 时刻记录下选取特征点的位置。

(2) 将第 $t+1$ 时刻的跟踪结果作为起点进行反向跟踪，然后利用公式(3.8)计算各特征点的前向后向误差，再利用公式(3.9)计算出误差的中值，将该中值作为阈值，滤除前向后向误差大于阈值的点。

(3) 根据剩下的特征点来评估出整个目标的具体位置，更新目标包围框。

(4) 若是在图像中不能找到目标框，则视为跟踪结果有误，不会将跟踪的结果输出，否则将目标框覆盖的区域作为跟踪模块的输出结果。

3.3 TLD 跟踪算法的检测模块

TLD 的检测模块是利用滑动窗口扫描每一帧整幅图像，对每一个可能的图像元进行判断，来确定目标是否存在。集成分类器、最近邻分类器和方差分类器共同组成了检测模块。滑动窗口输出的每一个图像元都需要经过这三层分类器，来确认跟踪目标存在与否。检测模块的整体流程图 3.5 所示。




Fig. 3.5 Detector module

3.3.1 方差分类器

方差分类器是检测模块的第一级分类器，也是过滤掉冗余背景图像窗口数量最多的部分。方差分类器是通过比较候选区域与目标区域的方差大小，去除掉小于原目标方差一半的区域。对于整幅图像除了前景目标就是背景图像，多余的背景图像增加了计算量，而前景目标与背景边界处的区分较为明显，在背景中像素的过渡值较小，所以可以通过方差阈值的设定，筛选出大于阈值的窗口，有效地减少后续分类器的任务量。方差分类器计算图像的灰度方差，如公式(3.10)：

$$D(x) = E(x^2) - E^2(x) \quad (3.10)$$

其中样本像素灰度值用 x 表示，像素灰度值均值用 $E(x)$ 表示，灰度值方差用 $D(x)$ 表示。在实际的操作中，采用积分图法可以有效的避免繁琐的计算。

3.3.2 集成分类器

集成分类器是检测模块的第二级分类器，对通过方差分类器的子图像来进行下一步的判断。集成分类器与随机森林相似，实际就是随机森林分类器，与随机森林的区别在于随机森林中的树分支较多，每一层节点的判断标准也需视情况而定，会产生若干个判断标准，而随机森林分类器结构单一，每层只有一种判断标准，如图 3.6 所示。




图 3.6 决策树示意图

Fig. 3.6 Schematic of decision tree

如上图 3.6 所示，将左边每层节点的判断条件统一，就演变成了右边的森林。因此，森林的结构也从树状转变成了线性。随机森林分类器分类的标准为样本的特征值。从图像中取任意的两点进行亮度的比较，分别用 A、B 表示，若 A 的亮度比 B 的亮度高，那么特征值取 1，反之，特征值取 0。一个新的特征值会随着一对新位置的选取而产生。森林中每个节点就是一对像素点的比较，并将结果编码成二进制。

每一个决策树都是一个独立的分类器，互不干扰。每一类样本都要经过藤后得到该类结果的先验概率，再结合公式(3.11)求出新输入样本图片的后验概率，再计算出后验概率的平均值，当平均值大于阈值时，则判定为含目标的图像区域，否则为非目标区域。

$$p(C_k|F) = \frac{p(F|C_k)}{\sum_k p(F|C_k)} \quad (3.11)$$

3.3.3 最近邻分类器

最近邻分类器是继方差分类器和随机森林分类器的第三级分类器，再经过前两级的分类器后仅剩一小部分的待分类图像块还需要继续分类。所以最近邻分类器的主要任务就是计算剩余的图像单元与在线模板库中的正负样本之间的相似度。相似度判定公式为(3.12)和(3.13)：

$$S^+(p, M) = \max_{p_i^+ \in M} S(p, p_i^+) \quad (3.12)$$

$$S^-(p, M) = \max_{p_i^- \in M} S(p, p_i^-) \quad (3.13)$$

式中， p 为候选样本， p_i^+ 为样本库 M 中的正样本， p_i^- 为样本库 M 中的负样本， $M = (p_1^+, p_2^+ \cdots p_m^+, p_1^-, p_2^- \cdots p_n^-)$ 为样本库。

相似度 S 计算通过求取样本间的归一化，表达形式为(3.14)和(3.15)：

$$S(p_1, p_2) = 0.5[NCC(p_1, p_2) + 1] \quad (3.14)$$

$$NCC(p_1, p_2) = \frac{1}{n-1} \sum_{x=1}^n \frac{(p_1(x) - \mu_1)(p_2(x) - \mu_2)}{\sigma_1 \sigma_2} \quad (3.15)$$

上式中， p_1 、 p_2 的均值用 μ_1 、 μ_2 表示， p_1 、 p_2 的标准差用 σ_1 、 σ_2 表示。

在计算候选样本时，保守相似度 S^Γ 的结果大于阈值，则候选样本被分类为正样本，否则被分类为负样本。

$$S^\Gamma = \frac{S^+(p, M)}{S^+(p, M) + S^-(p, M)} \quad (3.16)$$

3.4 TLD 跟踪算法的学习模块

P-N 学习目的为在线更新检测器，提高检测器的性能，是一种具有半监督性质的学习算法。它针对检测器对样本分类时产生的两种错误提供了两种“专家”进行纠正：P 专家检出漏检的正样本，并将其添加到正样本集中；N 专家改正误检的正样本，并将其添加到负样本集中。两种方法相互独立进行且可相互修正各自的错误。

3.4.1 P-N 学习流程

训练器、被监督的训练模块、分类器以及 P-N 专家构成了整个 P-N 学习结构。如图 3.7 所示。




图 3.7 P-N 学习框架图

Fig. 3.7 Framework diagram of P-N learning

P-N 学习的过程介绍如下：

- (1) 先使用已获得的标记样本训练分类器，是由方差分类器、集成分类器和最近邻分类器组成一个初始分类器。
- (2) 对未标记的样本利用初始化的分类器进行分类处理。
- (3) 通过判断 P-N 专家分类器标记样本正确与否，来确定是否需要重新标记该样本。
- (4) 将重新标记的样本加入训练集并重新训练分类器。
- (5) 重复 (1) 到 (4) 的步骤，进行循环。

3.4.2 P-N 学习的稳定性分析

P-N 学习的主要思想是将分类器中错误的结果做出纠正，利用纠正的结果来训练分类器，进而得到更新后的分类器。

通过一部分错误的正样本 $\alpha(K)$ 和负样本 $\beta(K)$ ，来表述分类器的性能。在第 K 次循环中，正确的正样本用 $n_c^+(K)$ 表示，错误的正样本用 $n_f^+(K)$ 表示，由P专家输出；正确的负样本用 $n_c^-(K)$ 表示，错误的负样本用 $n_f^-(K)$ 表示，由N专家输出。因此，在分类器中，下一次循环的正负样本的错误率可以由下式(3.17)和(3.18)表达：

$$\alpha(K+1) = \alpha(K) - n_c^-(K) + n_f^+(K) \quad (3.17)$$

$$\beta(K+1) = \beta(K) - n_c^+(K) + n_f^-(K) \quad (3.18)$$

P-N 学习的性能可以通过它们的准确率和召回率来描述如下：

$$P^+ = n_c^+ / (n_c^+ + n_f^+) \quad (3.19)$$

$$R^+ = n_c^+ / \beta \quad (3.20)$$

$$P^- = n_c^- / (n_c^- + n_f^-) \quad (3.21)$$

$$R^- = n_c^- / \alpha \quad (3.22)$$

综上所述，在第 K 次循环中，由P-N学习输出的正负样本的数量之间具有如下形式：

$$n_c^+(K) = R^+ \beta(K) \quad n_f^+(K) = \frac{(1-P^+)}{P^+} R^+ \beta(K) \quad (3.23)$$

$$n_c^-(K) = R^- \alpha(K) \quad n_f^-(K) = \frac{(1-P^-)}{P^-} R^- \alpha(K) \quad (3.24)$$

通过公式(3.17)、(3.18)、(3.23)和(3.24)，可得如下的方程：

$$\alpha(K+1) = (1-R^-) \alpha(K) + \frac{(1-P^+)}{P^+} R^+ \beta(K) \quad (3.25)$$

$$\beta(K+1) = (1-R^+) \beta(K) + \frac{(1-P^-)}{P^-} R^- \alpha(K) \quad (3.26)$$

通过定义一个状态矢量 $\bar{x}(K) = [\alpha(K) \beta(K)]^T$ 和一个 2×2 的矩阵 M ， M 定义如下：

$$M = \begin{bmatrix} 1-R^- & \frac{(1-P^+)}{P^+} R^+ \\ \frac{(1-P^-)}{P^-} R^- & 1-R^+ \end{bmatrix} \quad (3.27)$$

通过重写，进而得到：

$$\bar{x}(K+1) = M\bar{x}(K) \quad (3.28)$$

在离散动态系统中，公式(3.28)就是它的一个递归方程。通过递归方程的求解，可以清晰的了解到在 P-N 学习的迭代中，分类器的错误是怎样传递的。

3.5 TLD 算法优缺点分析

TLD 跟踪算法优点在于将检测模块、跟踪模块和学习模块结合到一起，当目标形变太大或被完全遮挡导致跟踪失败时，算法将在之后帧进行目标检测，一旦检测到目标，立刻恢复跟踪，这种方式使得 TLD 算法更适合进行长时间的目标跟踪。

TLD 跟踪算法的缺点在于跟踪模块应用金字塔 LK 光流跟踪法和检测模块采用滑动窗口的形式。滑动窗口的方式是要遍历整幅图像，然后将整幅图像分解成一个个的子窗口再对跟踪目标进行检测，但因大部分子窗口并不含跟踪目标，所以分类所有的子窗口计算量大，运行速度慢。而金字塔 LK 光流跟踪法需要满足三个假设，而这三个假设条件非常容易违反，进而导致跟踪的失败。

为了将 TLD 算法的优点发挥到最好，规避弥补掉其缺点，本文将对该算法进行优化改进。

3.6 特定目标选择方式

典型的 TLD 算法采用鼠标进行跟踪目标的选取，需要人工操作，不够智能化。在本文的应用中，增加了利用行人自动检测和越界判断的两种方式来选取需要跟踪的特定目标。

3.6.1 行人自动检测

基于 HOG 特征的支持向量机(SVM)算法的行人检测算法^[48]流程如图 3.8 所示。将检测到的第一个行人设定为特定目标。



图 3.8 行人检测方法

Fig. 3.8 Pedestrian detection method

首先，利用第一章介绍的常用检测方法帧差法检测运动目标区域。

然后，利用 HOG 特征提取。HOG 即梯度方向直方图^[49]，是一种描述算子，它以形状边缘特征为依据，可以实现物体的检测功能。其中图像目标的边缘信息通过梯度信息可以很好的显示出来，同时图像局部信息的特征化也可以通过局部梯形的大小来完成。HOG 描述子具有效率高、计算少的优点。并且在描述边缘方向分布和检测目标光强梯度时，由于自身的特性，使得光学和几何转化具有不变性。HOG 特征提取算法的流程图如图 3.9 所示：



图 3.9 HOG 特征提取基本流程

Fig. 3.9 HOG feature extraction basic process

最后，利用支持向量机(SVM)算法^[50]进行分类。该算法属于有监督学习算法的范畴，主要应用在模式领域，可以很好的解决数据分类的问题。在特征矢量空间中，为分隔数据找到一个最大的间隔平面。通过计算可以在这个最大间隔平面的两侧求得两个平行的超平面，在两个超平面距离最大的时候，分类模型的分类精确度达到了最大。如图 3.10 所示为基于支持向量机(SVM)的分类算法的基本流程。




图 3.10 基于支持向量机的分类算法流程图

Fig. 3.10 Flow chart of classification algorithm based on support vector machine

3.6.2 越界判断

通过在特定的区域对运动目标进行检测，并自动判断运动目标（人物）是否越过特定的区域即越界^[51]，将越界目标设定为特定目标。越界判断流程图如图 3.11 所示。




图 3.11 越界判断流程图

Fig. 3.11 Flow chart of cross boundary judgment

首先，读入视频，以视频中无运动目标的第一帧作为背景图，使用第一章介绍的背景差分法提取视频的前景图，进而得到粗略运动目标的前景图，阴影和运动目标也是前

景图的一部分，再设置阈值去除大部分的阴影，得到较准确的运动目标前景，画出运动目标轮廓，并将面积小的矩形删掉，取运动目标轮廓中底边中点作为运动目标位置，以备与设置好的边界区域位置进行比较。

其次，因摄像机拍摄的图像中的物体易发生畸变，所以要对监测矩形区域和运动目标位置利用透视变换进行转换。透视变换是将图像投影到一个新的平面。透视变换公式如式(3.29)所示

$$\begin{bmatrix} x' \\ y' \\ w' \end{bmatrix} = [u, v, w] \begin{bmatrix} a_{11} & a_{12} & a_{13} \\ a_{21} & a_{22} & a_{23} \\ a_{31} & a_{32} & a_{33} \end{bmatrix} \quad (3.29)$$

其中，原始图片坐标为 (u, v) ，变化后的图片坐标为 (x, y) ， $\begin{bmatrix} a_{11} & a_{12} & a_{13} \\ a_{21} & a_{22} & a_{23} \\ a_{31} & a_{32} & a_{33} \end{bmatrix}$ 为透视变换

矩阵，由此可以得出：

$$\begin{aligned} x &= \frac{x'}{w'} = \frac{a_{11}u + a_{21}v + a_{31}}{a_{13}u + a_{23}v + a_{33}} \\ y &= \frac{y'}{w'} = \frac{a_{12}u + a_{22}v + a_{32}}{a_{13}u + a_{23}v + a_{33}} \end{aligned} \quad (3.30)$$

最后，将透视变换后的运动目标位置坐标和待监测矩形区位置坐标进行比较，来判断运动目标是否在矩形范围内。

3.7 TLD 算法检测部分改进

TLD 算法的检测器是把视频中的每一帧都看作一幅独立的图像，并在每幅图像上进行完整扫描来定位出已经观察到的所有目标外观。在检测器检测的过程中，整图的扫描通过滑动窗口的方式完成，并将整幅图像划分为多个子窗口，最后检测出跟踪目标。由于子窗口中大部分并没有跟踪目标，产生了许多的无效计算，浪费时间，还易导致检测错误，降低算法的鲁棒性和实时性。为了满足本文云台摄像机实时检测跟踪的性能，所以提出在满足检测准确性的基础上，缩小检测范围。

帧与帧之间的运动范围是有限的，一个目标不能在短时间内用有限的速度运动较远的距离，所以可以通过缩小检测范围，减少遍历窗口的数目，降低计算量，提高跟踪速度。本文采用如图 3.12 所示，设以 a 为顶点的矩形框为 $a(x_0, y_0, w_0, h_0)$ 跟踪目标，则以

A 点为顶点的矩形框 $A(x_1, y_1, w_1, h_1)$ 为缩小范围后的检测区域, 已知矩形框 a 的信息则可通过公式(3.31)求取 A 。

$$\begin{cases} x_1 = x_0 - w_0 \\ y_1 = y_0 - h_0 \\ w_1 = 3w_0 \\ h_1 = 3h_0 \end{cases} \quad (3.31)$$

但在实际算法运算时, 若按照公式(3.31)计算时, 矩形框 A 很容易超出图像实际大小范围, 所以还要对 A 进行限定, 使其大小位置不得超过原图像大小。




图 3.12 缩小扫描区域示意图

Fig. 3.12 Illustration of reducing the scanning area

如图 3.13 所示, 目标跟踪框外大的红色框即为缩小后的检测区域范围, 之后滑动窗口将在该区域内进行遍历, 检测跟踪目标。



图 3.13 缩小后滑动窗口区域

Fig. 3.13 Sliding window area after zooming out

为了在减少计算量的同时也不降低算法的鲁棒性, 我们采用如图 3.14 所示动态调整检测范围^[52]的方法, 当上一帧跟踪失败或者在新的检测范围内没有检测到跟踪目标时, 检测范围会被再调整到整幅图像。




图 3.14 动态调整检测窗口的流程图

Fig. 3.14 Flow chart of dynamically adjusting detection window

下面是对不同尺寸的目标矩形框，扫描时间和子窗口数量的对比，如表 3.1 所示。

表 3.1 对更改扫描区域前后的情况对比

Tab. 3.1 Comparison of the situation before and after changing the scanning area

目标框信息 (像素)	占总面 积比(%)	更改前消耗 时间(毫秒)	更改后消耗 时间(毫秒)	更改前个 数(个)	更改后个 数(个)
40 x 27(189, 110)	1.34	26.54	2.75	67654	6234
53 x 32(118, 121)	1.77	30.03	4.03	71435	8864
62 x 96(163, 123)	7.65	30.54	13.43	70123	36583
75 x 106(174, 104)	8.95	28.78	17.68	71655	40756
115 x 78(119, 150)	10.56	31.85	19.85	72026	46534
88 x 121(144, 105)	12.88	30.36	20.12	58123	51235
152 x 158 (90, 52)	22.23	10.12	9.12	26125	25982
155 x 141(112, 81)	26.31	16.21	17.01	39852	38854
160 x134(125,111)	28.65	17.13	17.13	26789	26789

从表 3.1 可以看出，通过上述的方法缩小检测范围后，产生的样本数减少了很多，

消耗时间也有明显的减少。其中，对于较小的目标框，减少的样本数和消耗的时间会有更加明显的变化；对于目标框较大的，求取的矩形框 A 的大小与原图相差较小，与对全图进行扫描相差甚少，改进效果相对不够明显。总体上减少了样本数量，节省了消耗时间，从而减少系统运行时间。

3.8 TLD 算法跟踪部分改进

TLD 算法的跟踪模块采用了中值光流法，相当于运行了两次光流法，运算量大，运行速度慢，且精度不高，在检测模块和学习模块的辅助下才能完成长时间跟踪。而 fDSST 算法是一种短时间跟踪效果较好，计算效率较高的算法，但对于跟踪目标快速移动和快速变形时，跟踪的效果并不理想。为了克服两种算法存在的不足，将两种算法进行融合，使其更好的适应于本文的云台摄像机进行目标跟踪。

3.8.1 fDSST 算法

fDSST 算法是 DSST 算法的加速版，其中 DSST 算法是在 MOSSE 算法的基础上改进的。DSST 算法^[53]选择多维特征 $l \in \{1, 2, \dots, d\}$ 进行样本提取时，将样本的灰度和样本的 HOG 特征相结合作为输入样本 f 的多维特征，对于纹理特征的场景加入了 HOG 特征使该算法能更好的适应，则最小均方误差和可以表示为：

$$\varepsilon = \left\| g - \sum_{i=1}^d h^i * f^i \right\|^2 + \lambda \sum_{i=1}^d \|h^i\|^2 \quad (3.32)$$

其中，通过训练 f 得到的理想输出 g ，正则项系数用参数 λ 表示，当 $t=1$ 的时，可得：

$$H^l = \frac{\overline{G} F^l}{\sum_{k=1}^d F^k F^k + \lambda} = \frac{A_t^l}{B_t} \quad (3.33)$$

式中为了避免分母为零和滤波器过拟合的情况，引入了 λ 来消除 f 频谱中的零频分量的影响。其中， G 符合高斯分布，样本 F 正中间为峰值点。

一维高斯分布函数为：

$$G(r) = \frac{1}{\sqrt{2\pi}\sigma^2} \exp\left(-\frac{x^2}{2\sigma^2}\right) \quad (3.34)$$

二维高斯分布函数为：

$$G(x,y) = \frac{1}{\sqrt{2\pi}\sigma^2} \exp\left(-\frac{x^2+y^2}{2\sigma^2}\right) \quad (3.35)$$

由于 $d \times d$ 维线性方程的求解非常耗时, 为了获得鲁棒的近视结果, 对公式(3.33)中的 A_t^l 和 B_t 进行单独更新, 公式为:

$$A_t^l = (1 - \eta) A_{t-1}^l + \eta \overline{G} F_t^l, l = 1, 2, \dots, d \quad (3.36)$$

$$B_t = (1 - \eta) B_{t-1} + \eta \sum_{k=1}^d \overline{F_t^k} F_t^k \quad (3.37)$$

其中, η 表示学习率, 在新的一帧中目标位置的最大响应为:

$$y_t = F^{-1} \left\{ \frac{\sum_{l=1}^d \overline{A_{t-1}^l} Z_t^l}{B_{t-1} + \lambda} \right\} \quad (3.38)$$

该算法还有基于一维独立的相关滤波器的尺度搜索和目标估计方法。新的一帧图像中, 在二维的位置滤波器下先确定目标新位置, 然后以当前中心位置为中心点在一维的尺度相关滤波器下, 获取不同尺度的候选块, 最后寻找出最优的匹配尺度。根据公式(3.39)进行图像候选块大小的选取。

$$a^n P \times a^n R, n \in \{-(S-1)/2, \dots, [S-1/2]\} \quad (3.39)$$

其中, 目标框的宽度和高度用 P 和 R 表示, 尺度个数用 S 表示, 尺度因子用 a 表示。

DSST 算法除了增加 HOG 特征来跟踪目标位置, 最大的优势就是将位置滤波和尺度滤波相结合得到很好的跟踪效果, 如图 3.15 所示是位置滤波和尺度滤波的执行过程。




图 3.15 fDSST 位置滤波器和尺度滤波器目标位置估计过程

Fig. 3.15 Schematic diagram of fDSST position filter and scale filter target position estimation

fDSST 算法是 DSST 算法通过对滤波结果的插值、维数压缩进行的加速版，也继承了 DSST 算法的位置和尺度两种滤波来分别预测跟踪目标位置和尺度。在 fDSST 算法中，逐点推进是滤波器推导的方式。为了加快速度，通过快速傅里叶变换方式提高效率，然后将时间域上面的运算转移到复频域，最后使用 DFT 实现快速的运算。针对 HOG 特征，对维数进行压缩的处理，通过在滤波结果插值的方式确保信息的完整。PCA 降维的方式是维数压缩常常使用的方法，这种方式可以将尺度、位置滤波器中的各项维数降低。通过降维处理，位置滤波器 HOG 特征从 31 降至 18，尺度滤波器维数则是从 1000 降到 17，通过三角多项式插值的方式可以将准确的位置定位。这一方法的使用大大降低了计算量，由于 FFT 的计算代价和特征维数呈正相关的关系，目标检测的范围也可以加大，使得跟踪的效果更好。

3.8.2 fDSST 算法和 TLD 算法融合

如图 3.16 所示为 fDSST 和 TLD 算法融合结构图，TLD 算法的跟踪模块使用的是金字塔 LK 光流法，该方法是以图像作为输入，目标框作为输出，和 fDSST 算法的形式相同。所以，TLD 算法的跟踪模块可以由一个失败纠正方法和 fDSST 算法来替代^[54-55]。




图 3.16 fDSST 算法与 TLD 算法融合

Fig. 3.16 fDSST and TLD fusion

在跟踪模块中，如上所述，在输入和输出两个方面，TLD 算法和 fDSST 算法保持一致，因此金字塔 LK 光流法可以直接由 fDSST 算法替代，在替代的过程中，需要为其增设一个跟踪失败检测方法。信号之间的相似程度在信号处理领域中通过相关性来描述，这也是 fDSST 算法的中心思想。相关性的好坏与参数值的大小呈正比关系，也就是

参数值越大，代表相关性就越好，那么跟踪的效果也就越好。公式(3.40)为峰值旁瓣比的计算公式，其中最大的高斯核响应值用 $g_{\max}$ 表示，也就是峰值，以峰值点为中心，矩形框以外的所有像素点为 11×11 ，旁瓣的均值为 μ_{sl} ，标准差为 σ_{sl} 。通过文献[56]的相关资料可知：在目标跟踪过程若是一直保持稳定，那么 psr 的波动范围将保持在一个固定的区间 20~60，若是波动超出这一范围，就表示跟踪出现了偏差，当数值小于 7 时，则表示目标跟踪失败或是目标被遮挡。因此，用 psr 的波动范围来构建一个检测跟踪稳定性的方法，进而实现与 TLD 的跟踪模块被 fDSST 算法替代的完美结合。

$$psr = \frac{g_{\max} - \mu_{sl}}{\sigma_{sl}} \quad (3.40)$$

3.9 实验结果及分析

3.9.1 实验平台

(1) 硬件平台

本文选择系统为 window10，处理器为 i7 的计算机，内存为 12GB，显卡为 NVIDIA GTX-1060。

(2) 软件平台

本文采用的软件平台为 MATLABR2014a+VS2013+OPENCV2.4.9。

3.9.2 评价跟踪算法性能的指标

(1) 中心偏移距离

真实的目标框是人工标定，它与跟踪目标框之间的中心点的距离就是中心偏移的距离，计算公式如下：

$$error(i) = \sqrt{(x_i - x_c)^2 + (y_i - y_c)^2} \quad (3.41)$$

式(3.41)中， x_i 和 y_i 代表跟踪算法跟踪处理到第 i 帧目标中心的横纵坐标。而 x_c 和 y_c 代表第 i 帧人工标定的真实目标中心的横纵坐标。

(2) 跟踪重叠率

人为标定的目标框与实际跟踪的目标框的重叠度即为重叠率，而重叠率的计算公式如下：

$$overlap = \frac{w_i \cap w_c}{w_i + w_c - w_i \cap w_c} \quad (3.42)$$

式(3.42)中, 人为标定的真实跟踪框为 w_c , 真实的跟踪框为 w_i , 两个跟踪框之间存在交集用 $w_i \cap w_c$ 表示。

(3) 平均帧率

帧率就是每秒显示的帧数, 而平均帧率是将总帧数除以总时间。平均帧率是判断跟踪算法实时性的依据。

3.9.3 实验数据集

在计算机领域中, 数据集为计算机视觉算法提供了实验分析的材料与依据, 加快了计算机视觉算法的发展。如本文 3.5 节所述 TLD 算法的缺点, 主因是跟踪模块使用的金字塔 LK 光流跟踪法, 该跟踪算法的有效性基于以下三个假设:

- (1) 同一区域内的点, 运动的方向大体相同;
- (2) 相邻帧中像素的灰度值相对稳定;
- (3) 目标在相邻帧的位移不大。

在实际的应用, 上述三个条件非常不容易满足, 因此金字塔 LK 光流跟踪算法很难准确的跟踪到结果。金字塔 LK 光流跟踪失败往往与光照条件变化、目标快速运动和目标发生非刚性形变有关, 为了验证本文改进后的算法对以上的缺点是否有所改进, 和是否满足长时间跟踪, 本文从包含了一百个视频集的 Visual Tracking Benchmark 数据集中, 选取了三个视频序列: Woman、David 和 skating2 来测试, 如表 3.2 所示, 他们分别对应的视频序列特点为光照条件变化、目标快速移动和目标发生非刚性形变的情况, 而且帧数都超过三百帧。

表 3.2 数据集
Tab. 3.2 data set

	David	skating2	Woman
帧数	770	473	597
分辨率	320x240	640x352	352x288
摄像机移动	是	是	是
遮挡	是	是	是
光照	是	否	否
干扰	否	是	是
非刚性	是	是	是
尺度变化	是	否	是
旋转	否	是	否

3.9.4 实验结果分析

下面给出了 TLD 算法和本文改进后的 TLD 算法在 Woman、David 和 skating2 视频序列上实验测试跟踪效果，图中绿色框代表改进后的 TLD 算法，红色代表 TLD 算法，从图中可以看出改进后的 TLD 算法的跟踪效果有明显提升。



图 3.17 Woman 数据集跟踪效果图

Fig. 3.17 Tracking effect of the Woman dataset

如图 3.17 所示 Woman 视频序列上跟踪效果图，行人是选定的跟踪目标，由于人行走时，手臂的摆动和步伐的运动，都会出现非刚性形变。第 1 帧选取跟踪目标后，目标可以被正确跟踪，在第 376 帧，由于摆动的幅度比较大，导致非刚性形变较大，这时就会导致跟踪发生很大的偏移，跟踪尺寸也明显缩小。而改进后的算法跟踪更加准确，跟踪框的尺寸也在随目标不断变化。





图 3.18 David 数据集跟踪效果图

Fig. 3.18 Tracking effect of the David dataset

如图 3.18 所示为 David 视频序列上算法跟踪效果图，该视频中有明显的光照变化，违背了光流法的第二个假设，第 1 帧选取跟踪目标后，在第 572 帧目标明显丢失，尺度也明显不正确，在全局检测中，TLD 算法的检测模块开始工作，目标在第 632 帧又被检测到，进而使得跟踪的过程得以恢复。改进后的 TLD 算法的跟踪效果明显比原算法要好，跟踪框的大小也在不断变化，并且能准确的跟踪住目标。



图 3.19 skating2 数据集跟踪效果图

Fig. 3.19 Tracking effect of the skating2 dataset

图 3.19 所示 skating2 视频序列上算法跟踪效果图，该数据集目标移动速度非常快，导致光流出现了不稳定的情况，违反了第三条假设。跟踪目标的选定在第一帧完成，在目标移动、变形和被遮挡初期跟踪效果相对准确，在第 276 帧发生了偏移，在之后帧又找回目标。而改进后的算法跟踪效果相对较好。

如图 3.20 所示为改进后的 TLD 算法和 TLD 算法在 3 个数据集上跟踪精度图。通过图中发现：改进后的追踪效果得到了很好的提高，当阈值为 30 像素时，Woman、David 和 skating2 数据集的精度分别为 0.93、0.87 和 0.84。改进后的 TLD 算法跟踪精度得到明显提升。




图 3.20 跟踪算法在 3 个数据集上跟踪精度

Fig. 3.20 Tracking algorithm tracking accuracy on three datasets

如图 3.21 所示为改进后的 TLD 算法和 TLD 算法在 3 个数据集上跟踪重叠度分布图，图中横坐标表示目标的真实位置与横轴坐标处的跟踪目标框的重叠程度，纵坐标表示跟踪的成功率。当重叠度的阈值为 0.5 时，Woman、David 和 skating2 数据集的追踪成功率分别为 0.46、0.83 和 0.27。改进后的 TLD 算法跟踪成功率有明显提升。




图 3.21 跟踪算法在 3 个数据集上跟踪重叠度

Fig. 3.21 Tracking algorithm tracking overlap on three datasets

表 3.3 为跟踪算法在数据集上跟踪平均帧数，改进后的 TLD 算法跟踪实时性也得到了提高。

表 3.3 跟踪算法在 3 个数据集上跟踪平均帧率

Tab. 3.3 Tracking algorithm average frame rate tracked on three datasets

	Woman	David	skating2
TLD	15.42	11.52	13.18
本文算法	18.01	12.66	15.53

综合上述实验测试结果可以看出，改进后的 TLD 算法跟踪的鲁棒性和实时性都比原 TLD 算法有明显提升。

4 云台摄像机跟踪控制系统

4.1 系统设计

控制模块和跟踪模块共同组成了智能监控系统，目标所在的位置和大小由跟踪模块标出，再由控制模块控制云台转动和缩放。两个模块相互配合，确保跟踪目标始终位于监控画面中心。

4.1.1 系统硬件

智能监控系统中视频采集模块的主要任务就是读取视频，本文选用的是海康威视 DS-2DC4223IW-D 网络监控球机，实物如图 4.1 所示。具体参数如表 4.1 所示。



图 4.1 云台摄像机实物图

Fig. 4.1 Physical map of PTZ camera

表 4.1 海康 DS-2DC4223IW-D 网络监控球机参数表

Tab. 4.1 Parameter table of HIKVISION DS-2DC4223IW-D network dome camera

海康威视 DS-2DC4223IW-D 网络监控球机主要参数		
基础参数	图像传感器	1/2.8"Progressive Scan CMOS"
	电子快门	1/1-1/30,000s
	视频压缩	H.265/H.264/MJPEG
	图像分辨率	1920×1080
镜头	从光学变倍倍数	23 倍
	水平及垂直范围	水平 0° ~360° ； 垂直-15° ~90°
	光圈数	F1.6~F3.5
	变倍速度	大约 3.3 秒
接口	网络接口	内置 RJ45 网口，支持 10M/100M 网络数据
一般规范	工作温度和湿度	温度-30° ~65° ； 湿度小于 90%

该摄像头配备较快的快门捕捉速度，较高的图像分辨率，并且配有完备的 SDK 开发包，可以实现二次开发^[57]，全景监控在双马达设计后得以实现。视频数据在获取后，通过解码器解码，其颜色空间为 YUV 格式，而系统选取的图像处理的颜色空间为 RGB 格式，因此需要对视频图像的格式进行转换，转换公式如(4.1)所示：

$$\begin{pmatrix} R \\ G \\ B \end{pmatrix} = \begin{pmatrix} 1 & 0 & 1.402 \\ 1 & -0.34414 & -0.71414 \\ 1 & 1.772 & 0 \end{pmatrix} \begin{pmatrix} Y \\ U \\ V \end{pmatrix} \quad (4.1)$$

4.1.2 系统软件开发环境

本文智能监控系统的目标跟踪和云台控制由一台计算机实时处理，编程语言采用 C++ 语言，开发过程中使用的 OpenCV 版本为 2.4.9。图像采集和云台控制部分采用的是海康威视提供的 SDK 开发包，界面编写使用的是 Microsoft Visual Studio 2013 配套的是 MFC。

4.1.3 系统结构

如图 4.2 所示是系统的软件部分整体示意图。




图 4.2 软件系统框图

Fig. 4.2 System Block Diagram

首先由云台摄像机完成视频的采集工作，然后通过跟踪算法获取跟踪目标的大小和位置，最后调用云台控制系统，发送控制命令，驱动云台转动和缩放，使得跟踪目标始终处于监控画面中央^[58]。

图像采集：本文使用的海康威视 DS-2DC4223IW-D 网络监控球机进行视频采集。如上所介绍的海康威视摄像头配有完备的 SDK 开发包，H.264 的实时流为最初获取的格式。通过解码器获取 YUV 格式的图像数据，然后转换成 RGB 格式。

目标选取：目标的选取有三种方式，一种是利用鼠标圈选特定目标；一种是先利用帧差法检测运动目标区域，然后再采用基于 HOG 特征的支持向量机算法来完成行人检测，最后将检测到的第一个行人作为特定目标；还有一种是在特定区域内，将越界目标作为特定目标。

跟踪算法和云台控制：在系统中，目标的跟踪是通过改进后的 TLD 算法实现的，将目标的中心位置和大小进行记录，并把跟踪得到的信息传送给云台控制系统，进行变倍和转动。SDK 中的函数 NET_DVR_PTZControl 实现对云台操作的控制，云台控制在接收到相关的参数后，就会执行与之对应的指令，函数中没有速度参数，因此云台转动会默认为最大的速率。NET_DVR_PTZControlWithSpeed 函数中带有速度参数，可以对云台的转动速率进行调节。SDK 中的控制函数向云台发送的控制码是根据当前设置的解码器种类和解码器地址生成的，减少了使用者研究云台控制指令格式的麻烦。

4.2 云台摄像机控制算法

4.2.1 云台转动预测

在云台摄像机实际运行时，可能会因电机转动，速度转换，镜头变倍等原因带来延迟，为了达到实时性，在运动的过程中，提前将跟踪目标运动的位置预测出来，再按照直线模型预先转动到目标的预测位置，这样就可以实现系统的实时自动跟踪^[59]。如图 4.3 所示是运动目标的真实运动曲线，将每一帧连接形成了运动的真实轨迹，以目标的移动轨迹为标准，云台开始转动跟踪。虽然目标的运动为曲线，但是云台的转动一定是通过直线模型来实现目标的追踪。




图 4.3 云台的预测跟踪模型

Fig. 4.3 PTZ's predictive tracking model

如图 4.3 所示, 假设 $P_0(x_0, y_0)$ 为第 $i-2$ 帧目标的真实位置, 那么第 $i-1$ 帧的真实位置为 $P_1(x_1, y_1)$ 。假如跟踪目标的运动为匀速运动, 且运动轨迹为直线, 那么就可以通过 P_0 和 P_1 计算出第 i 帧的预测位置。下面具体介绍中心点预测法:

连接 P_0 和 P_1 , 并延长到 P'_2 , 使得直线 P_0P_1 和 $P_1P'_2$ 长度相等, 因此, P_1 就是延长后直线的中心点, 设 P'_2 坐标为 (x'_2, y'_2) , 那么

$$x'_2 = 2x_1 - x_0; \quad y'_2 = 2y_1 - y_0 \quad (4.2)$$

第 i 帧的预测位置就是位置 P'_2 。假设点 P_1 恰好在云台中心位置, 则坐标为 $(D1/2, D2/2)$ 。预测位置为 P'_2 点, 那么目标中心 x'_2 水平方向上的偏离距离为:

$$S_x = x_1 - x'_2 = \frac{D1}{2} - x'_2 \quad (4.3)$$

在垂直方向, y'_2 的偏离距离为:

$$S_y = y_1 - y'_2 = \frac{D2}{2} - y'_2 \quad (4.4)$$

补充说明:

(1) 首先在水平和垂直方向上分别设定两个阈值 S_{Tx} 和 S_{Ty} 。经实验数据分析, 设阈值为分辨率的十六分之一, 即 $S_{Tx} = D1/16$, $S_{Ty} = D2/16$ 。

水平方向: 若 $|x_1 - x_0| < S_{Tx}$, 则水平方向停止运动, $x'_2 = x_1$;

垂直方向: 若 $|y_1 - y_0| < S_{Ty}$, 则垂直方向停止运动, $y'_2 = y_1$;

(2) 当预测坐标出现极值时, 则判断规则如下:

水平方向: 若 $x'_2 < 0$, 则 $x'_2 = 0$; 若 $x'_2 > D1$, 则 $x'_2 = D1$;

垂直方向: 若 $y'_2 < 0$, 则 $y'_2 = 0$; 若 $y'_2 > D2$, 则 $y'_2 = D2$;

(3) 当预测位置与监控视场中心之间存在差值时, 此时判断条件为:

水平方向: 云台在 $|x'_2 - D1/2| < S_{Tx}$ 的条件下, 不发生转动;

云台在 $|x'_2 - D1/2| > S_{Tx}$ 的条件下, 会跟踪目标转动, 使目标的位置恰好处于画面的中心位置;

垂直方向：云台在 $|y'_2 - D1/2| < S_{Ty}$ 的条件下，不发生转动；

云台在 $|y'_2 - D2/2| > S_{Ty}$ ，的条件下，会跟踪目标转动，使目标的位置恰好处于画面的中心位置；

4.2.2 云台控制

如图 4.4 所示为云台控制系统的整体工作流程图，控制系统主要分为：方向控制、转速控制和镜头变倍控制。




图 4.4 云台控制系统模块结构图

Fig. 4.4 Structure of PTZ control system module

4.2.2.1 云台方向和速度的控制策略

在传统的跟踪控制中，要通过摄像机的标定操作才能实现摄像机运动来对跟踪目标进行跟踪，而在实际应用系统中，不管是三维建模还是摄像机标定都是很难实现的，还有被跟踪目标运动的随机性，也很难用精确的数学模型来描述。因此，本文采用模糊控制^[60]的思想来实现对云台控制，该策略既可以避免摄像机的标定，也可以使控制的精确性在跟踪算法上得以主要体现。

云台模糊控制策略的基本思想如下：利用目标跟踪算法获得跟踪目标的质心位置后，将模糊控制的距离设定为该位置与视场中心的距离，再将这个距离与预先设定的阈值进行比较，得出云台转动的方向模糊控制量；然后再求出转动的速度，之后就让云台做间歇性转动，即：每转动一次，停下来计算当前帧中跟踪目标质心与视场中心的距离，确定是否需要转动，重复该过程，最终使得跟踪目标始终保持在监控画面中心。

由于只能发送开始运动、停止运动的命令来启动和停止转动，需要在开始和停止命令之间设置一个延时参数 Δt ，为云台留出时间来做出相应的动作。根据上述的控制策略可对云台摄像机的云台运动方向和云台转动速度进行控制。

(1) 云台运动方向控制

图像平面像素的坐标可由如图 4.5 所示，点 O 是视场中心， (x_c, y_c) 是视场中心点的坐标， (x_i, y_i) 是跟踪目标质心当前帧的位置坐标，分别求取跟踪目标中心与视场中心的横纵坐标之差，即：

$$\begin{cases} \Delta x = x_i - x_c \\ \Delta y = y_i - y_c \end{cases} \quad (4.5)$$

根据中心点预测算法设定的阈值 S_{Tx} 和 S_{Ty} ，当 $|\Delta x| \geq S_{Tx}$ 或 $|\Delta y| \geq S_{Ty}$ 时，跟踪目标走出或即将走出摄像机视场中心区域，云台开始转动，使得摄像机的成像中心轴移向跟踪目标；当 $|\Delta x| \leq S_{Tx}$ 和 $|\Delta y| \leq S_{Ty}$ 时，跟踪目标处于摄像机中心视场范围内，云台不转动。以摄像机视场中心为基准，跟踪目标质心与之呈现对应的关系，为此，可将云台的转向方向分为以下 8 中情况，具体详见如图 4.5 所示。




图 4.5 图像平面的像素坐标示意图

Fig. 4.5 Schematic diagram of the pixel coordinates of the image plane

通过阈值和偏差比较，来确定云台的转动方向。具体的判断标准如下：

情况 0: $\Delta x > S_{Tx}$ 且 $|\Delta y| \leq S_{Ty}$ ，水平向右转动；

情况 1: $\Delta x > S_{Tx}$ 且 $\Delta y < -S_{Ty}$ ，向右上方转动；

情况 2: $|\Delta x| \leq S_{Tx}$ 且 $\Delta y < -S_{Ty}$ ，垂直向上转动；

情况 3: $\Delta x < -S_{Tx}$ 且 $\Delta y < -S_{Ty}$ ，向左上方转动；

情况 4: $\Delta x < -S_{Tx}$ 且 $|\Delta y| \leq S_{Ty}$ ，水平向左转动；

情况 5: $\Delta x < -S_{Tx}$ 且 $\Delta y > S_{Ty}$ ，向左下方转动；

情况 6: $|\Delta x| \leq S_{Tx}$ 且 $\Delta y > S_{Ty}$ ，垂直向下转动；

情况 7: $\Delta x > S_{Tx}$ 且 $\Delta y > S_{Ty}$ ，向右下方转动。

采取优先控制策略，当 x 和 y 方向上要同时转动时，比较视场中心和跟踪目标质心在 x 和 y 两个方向上的偏移量 Δx 和，偏移量绝对值较大的那个方向优先转动。

(2) 云台转动速度控制

云台摄像机的水平和垂直转动由内部步进电机驱动，不同解码器的速度设置可以设置云台的速度大小，范围一般控制在 0 到 7。控制摄像机转动时，理论上在当前帧判定摄像机云台需要转动时，下一帧图像中心区域立刻与目标中心重合，这显然行不通。目标偏离中心的位置距离不同时，云台采用某一恒定速度转动，无论速度偏小或偏大，都可能会出现摄像机振荡或者目标脱离视野区域的问题，特别是在目标移动速度与摄像机转动速度相差较大时，问题更是明显^[61]。

在水平和垂直方向，摄像机均有 [0,7] 共 8 级调速，依据这一设置，系统自适应的速度控制进行转动速度控制，偏差越大，云台速度也随之选择更大的级数，如图 4.6 所示的转速级别对应示意图，根据 $|\Delta x|$ 和 $|\Delta y|$ 的大小来确定转动速度的大小。




图 4.6 转速对应级别

Fig. 4.6 Speed corresponding level

4.2.2.2 云台镜头变倍控制

本文选用的云台摄像机变倍的速度可以像转动一样，通过某种方式计算出来，比如有些文献采用提取特征点来计算变倍率，还有些文献还涉及到摄像机的标定，都相对来说比较复杂，考虑到云台控制的实时性，本文采用摄像机的标准恒定速度进行变倍，变倍的方法^[59]是设定一个合适尺寸 A_{size} ，即目标在画面中显示的合适尺寸。 A_{size} 可以视情况选定合适的尺寸，暂定为整个画面的六十四分之一，即：

$$A_{size} = \frac{D1 * D2}{64} \quad (4.6)$$

设变量 $A_{current}$ 为目标在画面中的实际大小尺寸，它随跟踪目标的变化而时刻变化，所以可根据跟踪算法获得的目标框的长宽求取，即：

$$A_{current} = width * height \quad (4.7)$$

再设定一个尺寸的阈值 A ，若是 A 的数值小于目标合适尺寸和当前实际尺寸的差值绝对值时，系统就会启动自动变倍功能。 A 也可以视情况选定合适的尺寸，暂定为 A_{size} 的十六分之一，即：

$$A = \frac{A_{size}}{16} \quad (4.8)$$

当比较 $| \Delta x |$ 、 $| \Delta y |$ 的大小都没有超过阈值时，再根据下面的判定规则进行变倍。

(1) 如果 $|A_{current} - A_{size}| > A \&\&(A_{current} > A_{size})$ ，镜头需要拉远，使得目标在屏幕的尺寸变小，缩放为合适尺寸 A_{size} 。

(2) 如果 $|A_{current} - A_{size}| > A \&\&(A_{current} < A_{size})$ ，镜头需要拉近，使得目标在屏幕的尺寸变大，扩大为合适尺寸 A_{size} 。

(3) 如果 $|A_{current} - A_{size}| < A$ ，此时镜头不需要变倍。

因为都是以摄像机标准速度进行缩放控制的，所以无法达到一步到位的情况，也就是说不可能通过一帧就缩放到理想合适的尺寸。缩放之后还需要计算变倍率，来对跟踪目标进行重新定位，变倍率 f 的大小也就是标准缩放速度和延时参数的乘积，缩放后的跟踪目标尺寸变成原来的 f 倍。如果在缩放后的图像中，继续使用缩放前的跟踪框作为初始搜索框，而不按照变倍率对目标跟踪框进行相应的调整，跟踪框就难以完整的框住跟踪目标，易导致跟踪算法失败。所以为了保证跟踪算法在镜头变倍后的有效性，需要根据变倍率来调整跟踪框的尺寸，使得跟踪框仍然可以包含完整的目标。则跟踪框

$A_{current}$ 的尺寸应为:

$$A_{current} = f * A_{current} \quad (4.9)$$

$$\begin{cases} f = f/k, A_{current} - A_{size} > A \\ f = f*k, A_{current} - A_{size} < -A \\ f = f, |A_{current} - A_{size}| \leq A \end{cases} \quad (4.10)$$

其中 k 为变倍速率。

4.3 本章小结

本章对云台摄像机自动跟踪系统进行了设计。首先介绍了系统硬件配置、软件开发环境和系统结构。然后为了避免云台摄像机在实际运行时，因电机转动，速度转换，镜头变倍等原因带来的延迟，采用了中心点预测法对目标位置先进行预测。最后详细介绍了云台控制部分的云台转动方向、转动速度和镜头变倍的控制方法，构建了完整的控制系统。

5 系统实验结果及分析

5.1 系统整体界面设计



图 5.1 系统控制界面

Fig. 5.1 Control interface of the system

系统的界面设计采用 MFC 编写^[62], 如图 5.1 所示为界面示意图, 主要功能如下:

- (1) 通过 IP 地址和用户名、密码连接不同的网络摄像头;
- (2) 播放、暂停和录像按钮实现控制用户端显示监控画面、暂停显示和录像的功能;
- (3) 摄像机云台转动方向、转动速度和监控画面的变倍都可以通过云台控制按钮实现;
- (4) 设置了三种特定目标选择方式: 鼠标圈选、自动检测、越界判断。
- (5) 设置保存监控信息的路径。

5.2 特定目标选取实验测试

5.2.1 自动行人检测

为了验证 3.6.1 节介绍的行人自动检测的效果, 本文从 Visual Tracking Benchmark 数据集中选取了一些视频和自己事先录好的视频进行测试, 如图 5.2 所示为行人检测算法检测行人的部分测试结果图。



图 5.2 行人检测结果

Fig. 5.2 Pedestrian detection results

从实验结果图 5.2 所示可以看出，行人自动检测可以准确的检测到行人，如图 5.3 所示为自动选取特定目标跟踪效果图，是以检测到的第一个行人为特定目标进行跟踪的结果。



图 5.3 目标跟踪效果图

Fig. 5.3 Effect of target tracking

5.2.2 越界判断

针对 3.6.2 节介绍的越界判断方法，本文进行了实验验证。实验中，在地板上设置待监测矩形区域，将摄像头设置在固定状态下，使监控视角覆盖监测矩形区域，获取图像信息如图 5.4 所示，利用鼠标获取矩形的四个点，并通过透视变换得到如图 5.5 所示

标准的矩形。同样利用透视变换，对检测到的运动目标框中的底边中点也进行变换，获取新的位置，然后再判断规则的矩形中是否包含变换后的新位置。我们用绿色矩形框框住的运动目标表示没有发生越界行为，用红色矩形框框住的运动目标表示发生越界行为。两种情况的实验结果如图 5.6、图 5.7 所示。




图 5.4 未变换之前的监测矩形

Fig. 5.4 Monitoring rectangle before transformation



图 5.5 变换之后的监测矩形

Fig. 5.5 Transformed monitoring rectangle



图 5.6 界内

Fig. 5.6 Within bounds



图 5.7 界外

Fig. 5.7 Out of bounds

5.3 云台控制系统的实验结果及分析

将第三章中改进后的 TLD 算法和云台摄像机控制算法相结合，进而构建出完整的跟踪系统。云台摄像机在本实验中被安装在四楼窗外的位置，镜头对着楼下的道路。在

进行实验时，行人按照正常的速度行走，大约为 0.5 到 2 米每秒。运行过程中的平均帧率约为 16 帧左右。如图 5.8 所示记录了目标中心位置的离散图，如图 5.9 所示记录了云台跟踪的部分图像序列。





图 5.8 云台跟踪中的目标中心点的坐标位置散点图

Fig. 5.8 Scatter plot of coordinate position of target center point in gimbal tracking

如图 5.8 所示可以看出，目标位置坐标保持在监控画面中心附近，说明云台在跟随目标进行转动跟踪。






图 5.9 改进后 TLD 算法云台摄像机目标跟踪

Fig. 5.9 Improved TLD algorithm PTZ camera target tracking map

如图 5.9 所示实验结果中可以看到，在第一帧对目标行人进行圈选，然后系统开始对目标进行跟踪。如图第 1 帧到第 78 帧，行人坐标与视场中心点坐标之差未超过阈值，云台没有进行转动，准确跟踪目标。第 134 帧到第 167 帧，从背景环境的视角变化可以看出，云台开始转动，说明行人坐标与视场中心点坐标之差大于阈值，云台开始跟随目标转动。在第 201 帧中，行人经过路灯的位置；有部分位置被遮挡，但是跟踪目标并未丢失，在 243 帧时，也能准确跟踪，云台也在跟随目标转动。在第 310 帧位置，行人经过大树的位置，到 342 帧完全走出，行人经过一些树枝的遮挡，对目标跟踪效果并未有明显影响，云台也在准确的跟随目标转动，使目标始终处于监控画面中央的位置，达到很好的跟踪效果。

综合以上实验测试结果表明，改进后的 TLD 算法结合云台摄像机自动控制系统跟踪的鲁棒性和实时性都能满足要求，目标在运动过程中摄像机始终跟随目标，将目标位置保持在摄像机相对中心区域。

总结与展望

本文研究并设计了一套基于海康威视网络云台摄像机对特定目标检测与跟踪系统，其具有自动与半自动检测、实用性强、跟踪效果好和控制范围广的特性。本文对系统的控制算法和运动目标跟踪算法进行了详细的分析。本文的主要内容如下：

(1) 对 Mean shift 算法、粒子滤波算法和 Camshift 算法三种传统的运动目标跟踪算法进行了研究，并对其分别进行了实验，对比了它们的优缺点。

(2) TLD 算法是基于在线学习的跟踪算法，适用于长时间跟踪，具有自适应调节目标模型的功能，但也存在一定的不足，不能很好的适用于云台摄像机运动目标跟踪。因此，本文从检测模块缩小滑动窗口范围，跟踪模块与 fDSST 算法融合，对 TLD 算法进行了改进。

(3) 构建了完整的系统框架，详细介绍说明了云台控制系统各个环节的实现方式。将本文改进后的跟踪算法与云台控制算法相结合，搭建监控界面，通过实验验证了系统的有效性和实用性。

但由于时间、精力有限，本文的研究工作仍有很多待改进和完善之处：

(1) 在本文的设计中，跟踪目标的选择有三种方式，一种是手动鼠标圈选，一种是行人自动检测，还有一种是越界目标。但都无法满足真正的自动跟踪的需求，在后续的研究中可以加入一些行为识别，对特定行为的目标进行自动识别和跟踪，如吸烟的人，未戴安全帽的人等，提高系统的实用性。

(2) 在运行速度方面，改进后的 TLD 算法还有提高的可能。因此，后续可以对算法进行更好的优化，使其达到更加高的帧率，实现更加高效的行人跟踪。

(3) 本文云台控制系统中，为了避免因电机转动，速度转换，镜头变倍等原因带来的延迟，增加了目标运动预测算法，但还存在不够精确的问题，后续可以尝试更加精准的控制算法。

参考文献

- [1]赵玉吉. 基于视频序列的运动目标检测与跟踪算法研究[D].扬州大学,2017.
- [2]卞强. 智能视频监控中运动目标检测与跟踪算法研究[D].东北石油大学,2018.
- [3]王素琴,施文豪,李兆歆,毛天露.无人机航拍视频中的车辆检测方法[J]. 系统仿真学报, 2018, 30(07): 2776-2786.
- [4]李丽丽. 机器人视觉中的障碍物优化识别方法研究[J].计算机仿真,2016,33(06):306-309.
- [5]张义,季东杰,肖朋,钱文哲.智能视觉监控技术在国防工程中的应用与研究[J].网络安全技术与应用, 2017(03):160-161.
- [6]彭涛涛. 平安城市视频监控中目标检测与跟踪技术的研究[D].吉林大学,2015.
- [7]邵振峰,蔡家骏,王中元,马照亨.面向智能监控摄像头的监控视频大数据分析处理[J].电子与信息学报, 2017,39(05):1116-1122.
- [8]陈嵘. 智能监控系统中运动目标检测算法的研究与实现[D].湘潭大学,2018.
- [9]贾宁.智能视频监控技术研究综述[J].数字通信世界,2018(07):59-60.
- [10]张红军,段贺兵,曹志慷,石明明,王豫鑫.移动监控视频系统关键技术研究与应用[J].智能计算机与应用,2019,9(03):237-239+243.
- [11] Collins R, Lipton A, Kanade T, et al. A system for video surveillance and monitoring[A]. Citeseer, 1999: 25-29.
- [12] Kumar R., Sawhney H, Samarasekera S, et al. Aerial video surveillance and exploitation[J]. Proceedings of the,IEEE, 2001, 89(10):1518-1539.
- [13] Collins R T, Gross R, Shi J. Silhouette-based human identification from body shape and gait[C]. IEEE International Conference on Automatic Face and Gesture Recognition. IEEE Computer Society, 2002: 366.
- [14] Behan J. Keefe D. The Development of an Autonomous Robotic Aid to Assist the Disabled and Elderly [A]. Bioengineering in Ireland,Limerick,2004:146-152.
- [15] Patel D, Parmar R, Desai A, et al. Gesture recognition using FPGA and OV7670 camera[C]. International Conference on Inventive Systems&Control, 2017, 1-4.
- [16]李杨民,汤晖,徐青松,负远.面向生物医学应用的微操作机器人技术发展态势[J].机械工程学报, 2011,47(23):1-13.
- [17]罗忠祥,庄越挺,刘丰,潘云鹤.基于视频的人体动画[J].计算机研究与发展,2003(02):269-276.
- [18]<https://wenku.baidu.com/view/c5a248af3968011ca2009135.html>
- [19]http://www.tranbbs.com/Case/Eleccronic/Case_119480.shtml
- [20]何银飞. 基于改进的帧差法和背景差法实现运动目标检测[D].燕山大学,2016.
- [21]沈瑜,王新新.基于背景减法法和帧间差分法的视频运动目标检测方法[J].自动化与仪器仪表, 2017(04):122-124.
- [22]胡瑞卿,田杰荣.基于光流法的运动目标检测算法研究[J].电子世界,2019(05):58-61.
- [23]侯志强,韩崇昭.视觉跟踪技术综述[J].自动化学报,2006(04):603-617.

- [24] Kalman R.E. A new approach to linear filtering and prediction problems[J]. Journal of Basic Engineering, 1960(82):35-45.
- [25] 王法胜,鲁明羽,赵清杰,袁泽剑.粒子滤波算法[J].计算机学报,2014,37(08):1679-1694.
- [26] Ross D,Lim J,Lin R-S, et al. Incremental learning for robust visual tracking[J]. International Journal of Computer Vision, 2008,77(1/2/3):125-141.
- [27] Yang F,Lu H, Yang M. Rubust super-pixel tracking[J]. IEEE Transaction on image Processing, 2014, 23(4): 1639-1651.
- [28] Zhong W. Robust object tracking via sparsity-based collaborative model[J]. Proceedings of the 2012 IEEE Conference on Computer Vision and Pattern Recognition. 2012:1838-1845.
- [29] Babenko B, Yang M-H,Belongie S.Robust objecting tracking with online multiple instance learning[J]. IEEE Transaction ON Pattern Analysis and Machine learning, 2011, 33(8):1619-1632.
- [30] Zhang Kaihua,Zhang Lei,Yang Ming-Hsuan,et al. Fast tracking via spatio-temporal context learning [J]. IEEE Transaction on image Processing, 2015:413-416.
- [31] Zhang Kaihua,Zhang Lei,Yang Ming-Hsuan,Real-time object tracking via online discriminative feature selection[J].IEEE Transaction on image Processing, 2013,22(12):4664-4677.
- [32] Hénriques F,Caseiro Rui,Martins Pedro,et al. High-speed tracking with kernelized correlation filters [J]. IEEE Transaction on Pattern Analysis and Machine Intelligence, 2015,37(3):583-596.
- [33] 朱日东,杨小远,王敬凯.基于傅里叶域卷积表示的目标跟踪算法[J].北京航空航天大学学报, 2018, 44(01):151-159.
- [34] 龙涛. 基于 Kalman 预测器改进的 CamShift 目标跟踪[D].湘潭大学,2016.
- [35] 付晓薇,方康玲. 一种运动目标自适应检测与跟踪算法[J]. 武汉科技大学学报(自然科学版), 2007(02):189-191.
- [36] 赵康,王正勇,何小海,郑新波,田刚. 基于改进粒子滤波的视觉目标跟踪[J].四川大学学报(自然科学版), 2019, 56(05):875-882.
- [37] Comaniciu D,Ramesh V,Meer P Real-Time Tracking of Non-Rigid Objects using Mean Shift[C]. IEEE Conference on Computer Vision & Pattern Recognition, 2000,142-149.
- [38] Collins,Robert T. Mean-shift blob tracking through scale space[C]. IEEE Computer Society Conference on Computer Vision & Pattern Recognition, 2003,234.
- [39] Bradski G R. Computer Video Face Tracking for Use in a Perceptual User Interface[J]. Intel Technology Journal,1998,2:214-219.
- [40] Nicholas Metropolis,Ulam S. The Monte Carlo Method[J]. Publication of the American Statistical Association, 1949,44(247):335-341.
- [41] Yi W,Lim J,Yang M H. Online Object Tracking:A Benchmark[C]. Computer Vision and Pattern Recognition, 2013,2411-2418.
- [42] Kalal Z,Miko lajczyk K,Matas J. Tracking-Learning-Detection[J]. IEEE Trans Pattern Anal Mach Intell, 2012,34(7),1409-1422.
- [43] Kalal Z,Miko lajczyk K,Matas J. Face-TLD:Tracking-Learning-Detection applied to faces[C]. IEEE International Conference on Image Processing, 2010,3789-3792.
- [44] 姚沛.基于 TLD 多目标跟踪算法研究[D].西安电子科技大学,2014.
- [45] 张鹏.基于 TLD 的动态跟踪算法研究[D].西北师范大学,2017.

- [46] Horn B K P, Schuack B G. Determining optical flow[J]. Artificial Intelligence, 1981, 17(1-3):185-203
- [47] Lucas B D, Kanade T. An iterative image registration technique with an application to stereo vision[C]. International Joint Conference on Artificial Intelligence. Morgan Kaufmann Publishers Inc. 1981:674-679.
- [48] 武光利, 王绵沼. 基于 HOG 特征与 SVM 分类器的行人检测研究[J]. 中国有线电视, 2017(12): 1413-1415.
- [49] Dandan Wang, Tongei Lu, Yanduo Zhang. HOG pedestrian detection based on edge symmetry and trilinear interpolation[P]. International Symposium on Multispectral Image Processing and Pattern Recognition, 2018.
- [50] 王宏涛, 孙剑伟. 基于 BP 神经网络和 SVM 的分类方法研究[J]. 软件, 2015, 36(11): 96-99.
- [51] 田海蓉. 特定区域实时监测系统设计与实现[D]. 安徽工业大学, 2017.
- [52] 邓麟. TLD 框架下的运动目标跟踪算法研究[D]. 西安电子科技大学, 2017.
- [53] 张清洋. 基于 DSST 算法的目标跟踪系统设计与实现[D]. 华中科技大学, 2017.
- [54] 杜奇. 移动机器人的视觉目标跟踪方法研究与实现[D]. 哈尔滨工业大学, 2016.
- [55] 李轶锟. 基于视觉的四旋翼飞行器地面目标跟踪技术[D]. 南京航空航天大学, 2019.
- [56] Bolme D S, Beveridge J R, Draper B A, et al. Visual Object Tracking Using Adaptive Correlation Filters[C]//International Conference on Computer Vision and Pattern Recognition, IEEE, 2010: 2544—2550.
- [57] 陈俊良, 葛俊锋, 叶林, 桂康. 基于海康威视 SDK 的视频监控软件的开发[J]. 工业控制计算机, 2015, 28(07): 97-98+101.
- [58] 忻亦敏. 云台相机行人跟踪抓拍系统研究[D]. 华东师范大学, 2019.
- [59] 侯红娜, 徐凯凯. 商场云台摄像机跟踪控制策略及实现的研究[J]. 科技风, 2017(09):105.
- [60] 宗伟伟. 基于 PTZ 摄像机的运动目标跟踪算法研究与实现[D]. 东北大学, 2011.
- [61] 田昌胜. 基于改进的 TLD 算法 PTZ 摄像机行人跟踪研究[D]. 哈尔滨工程大学, 2017.
- [62] 张弦弦, 朱全松. 基于 MFC 软件界面设计的视觉优化[J]. 兵工自动化, 2016, 35(12):38-40+48.

致谢

回想三年前，带着对大连海事大学的憧憬，对研究生生活美好的畅想，来到了这里，开启了新的求学之旅。转眼间，这段美好的旅程也要接近尾声了，心里更多的是不舍和感激。谢谢给我悉心指导的老师，谢谢给我鼓励和帮助的小伙伴，谢谢给我生命养育我的父母，有你们真好。

我真的很幸运可以成为胡英老师的学生。每当我在课题上遇到困难，胡老师总是能以他专业的角度给我指导，并以鼓励的方式帮助我前进，让我对编程和做科研慢慢的产生了兴趣。在毕业设计过程中，胡老师更是给予了我很大的帮助，从选题到论文撰写，每一步的完成都少不了胡老师的悉心指导，因为有胡老师的帮助和支持，我才能克服一个又一个的困难和疑惑，直至论文撰写完成，真的很感谢胡老师一直以来的精心指导。同时，胡老师精益求精的工作作风，渊博的专业知识，乐观豁达的生活态度也深深地影响着我，让我受益匪浅。

谢谢实验室的每一个人，让我度过美好的研究生生活，让我拥有暖暖的回忆。谢谢在我研一时期给我温暖和细心帮助的种文艳师姐和马永军师兄；谢谢在我对课题一筹莫展时给我建议和指导的胡玥师兄和于宏伟师兄，还有拥有爽朗笑声带给我好心情的张炎师兄；谢谢在我困顿迷惑时给我鼓励和帮助的同学洪少壮和刘宝林；还要谢谢我的师弟金鑫和师妹付美涵给予我的无私帮助。因为你们的存在让我的研究生生活丰富多彩，让我拥有一个充满爱的大家庭！此外，还要谢谢我的室友王研婷和袁海燕，以及我的隔壁室友孟杨瑞，是你们在我失落的时候给我打气，在我需要安慰的时候给予我关怀。

还要特别感谢我亲爱的父母和朋友，因为有你们的支持和鼓励，我才可以坚定的选择了考研的道路，让我活出更美好的自己，更美好的未来。

