

单位代码：10293 密 级：公开

南京邮电大学

专业学位硕士学位论文



论文题目：基于多模态数据融合的机械手臂感知系统的研究

学 号 1321018129

姓 名 苏士伟

导 师 谢世朋

专业学位类别 电子信息硕士

类 型 非全日制

专业（领域） 电子信息

论文提交日期 二〇二四年五月

Research on the perception system of robotic arms based on multimodal data fusion

Thesis Submitted to Nanjing University of Posts and
Telecommunications for the Degree of
Master of Electronic Information



By

Shiwei Su

Supervisor: Prof. Shipeng Xie

May 2024

摘要

典型的机械臂操作场景通常比较复杂，可能相互遮挡，而且目标物的尺寸大小不一，这增加了目标检测的难度。目标检测算法可以识别目标物，但是识别出来的包围框和真实的包围框还有一定的差别，从而导致机械臂计算出的位姿有所偏差而操作失误。针对这种情况，本研究在 YOLOv5 目标检测的基础上进行了改进。为了捕获不同尺度的物体，增加了多尺度特征目标检测模块，提高模型在检测不同尺寸目标物的性能；另外，注意力机制可以提高模型对图像中不同区域的关注度，增加特征提取和识别能力，使模型能够在复杂场景中检测出被遮挡的物体。基于投票网络的 PVNet 网络可以对遮挡、截断和弱纹理场景具有良好的适应性，但其损失函数仅考虑方向损失，忽略了像素到关键点距离的影响，导致精度有所下降；而且在背景杂乱的情况下，会出现误投票的情况。针对上述投票网络的缺点，本研究提出了一种基于均方误差和注意力机制的投票网络(MSAM)。

为了能够获得更全面的环境感知能力，本研究搭建了机器人系统，使用了多传感器采集的多模态数据（RGB 图像数据、深度图像数据以及触觉传感器数据等）。首先，利用机器人的导航系统行走至需要操作的电厂屏柜正前方，通过柜面点云匹配，确认是否到达指定屏柜位置；然后，通过改进的 YOLOv5 对目标物进行识别；之后，利用本研究提出的基于 MSAM 的 PnP 位姿估计算法和视觉引导算法，引导机械臂末端工具操作目标物；最后，利用灵巧手的触觉传感器数据判断操作是否成功。为了评估基于 MSAM 的 PnP 位姿估计算法的性能，设计了对比实验，本研究的方法与 Occlusion Linemod 数据集上的基准方法进行比较，提高了大部分目标物的平均目标检测误差的得分，并且提高了整体目标检测误差的稳定性；此外，设计机械臂引导对位消融实验，引入基于 MSAM 的 PnP 位姿估计算法和改进的 YOLOv5 算法之后，视觉引导对位精度误差平均减小了 38.86%。

随着计算机、控制理论和机器视觉传感器等领域的蓬勃发展，机器人技术正迅猛前进。本研究搭建了机器人系统，并利用多模态数据融合技术对机械臂视觉引导提出了技术改进，在电厂屏柜的场景下机械臂能够准确无误操作目标物，为机器人系统研究及应用提供一定的参考意义和实用价值。

关键词：图像识别，位姿估计，视觉引导，手眼标定

Abstract

Typical scenarios of robotic arm operations are usually complex, with objects potentially occluding each other and varying in sizes, which increases the difficulty of object detection. Object detection algorithms can identify objects, but the bounding boxes they generate may differ from the true bounding boxes, leading to deviations in the calculated poses of the robotic arm and potential errors in operations. In this study, we improved upon the YOLOv5 object detection by adding a multi-scale feature object detection module to capture objects of different sizes, thereby enhancing the model's performance in detecting objects of varying sizes. Additionally, an attention mechanism was incorporated to increase the model's focus on different regions in the image, improving feature extraction and recognition capabilities, enabling the model to detect occluded objects in complex scenes. The PVNet network based on voting can adapt well to occlusion, truncation, and low-texture scenes, but its loss function only considers orientation loss, neglecting the impact of pixel-to-keypoint distances, resulting in decreased accuracy. Moreover, in cluttered backgrounds, misvoting may occur. To address these shortcomings of the voting network, this study proposes a Voting Network based on Mean Square Error and Attention Mechanism (MSAM).

In order to achieve comprehensive environmental perception capabilities, this study built a robotic system that utilized multi-sensor data collection, including multimodal data such as RGB image data, depth image data, and tactile sensor data. Firstly, the robot navigation system was used to walk to the front of the designated power plant cabinet, and through cabinet surface point cloud matching, the system confirmed whether the specified cabinet position was reached. Subsequently, the improved YOLOv5 algorithm was employed for target object recognition. Next, the Pose Estimation algorithm based on MSAM proposed in this study, along with the Visual Guidance algorithm, guided the robotic arm end effector in manipulating the target object. Finally, the tactile sensor data from the dexterous hand was used to assess the success of the operation. To evaluate the performance of the Pose Estimation algorithm based on MSAM, comparative experiments were designed, where the proposed method was compared with benchmark methods on the Occlusion Linemod dataset. The results showed an improvement in the average target detection error scores for most target objects, as well as an increase in the overall stability of target detection errors. Furthermore, a robotic arm guided positioning ablation experiment was conducted, and incorporating the Pose Estimation algorithm based on MSAM and the improved YOLOv5

algorithm resulted in an average reduction of 38.86% in visual guidance positioning accuracy error.

With the vigorous development in fields such as computer science, control theory, and machine vision sensors, robotics technology is advancing rapidly. In this study, a robotic system was built, and with the use of multi-modal data fusion technology, technical improvements were proposed for visual guidance of the robotic arm. In the scenario of the power plant cabinet, the robotic arm was able to operate the target object accurately and flawlessly. This research provides valuable insights and practical implications for the study and application of robotic systems.

Key words: image recognition, pose estimation, visual guidance, hand-eye calibration

目 录

第一章 绪论.....	1
1.1 课题背景与意义.....	1
1.2 课题研究现状.....	1
1.2.1 机械臂发展现状.....	2
1.2.2 机器视觉目标检测的发展现状.....	3
1.3 研究目的及研究内容.....	6
第二章 目标定位及视觉引导标定的设计	8
2.1 相机选型.....	8
2.2 机械臂视觉系统的标定.....	10
2.2.1 相机标定	10
2.2.2 相机标定实验.....	10
2.2.3 机械臂手眼标定	12
2.2.4 机械臂手眼标定实验.....	12
2.3 坐标系之间的转换关系.....	15
2.3.1 世界坐标系和相机坐标系.....	15
2.3.2 相机坐标系和图像坐标系.....	16
2.3.3 图像坐标系和像素坐标系.....	16
2.3.4 相机坐标系和机械臂基坐标系.....	17
2.4 本章小结.....	18
第三章 基于 YOLOv5 的视觉检测和位姿估计	20
3.1 YOLOv5 目标检测算法以及相关改进	20
3.1.1 目标检测算法介绍.....	20
3.1.2 基于 YOLOv5 目标检测算法的优化	21
3.2 点云配准的分类和介绍.....	26
3.2.1 粗略配准	27
3.2.2 精细配准	27
3.2.3 深度学习配准.....	28
3.3 基于多传感器融合的位姿估计算法的设计	28
3.3.1 多传感器融合的分类.....	28
3.3.2 基于 MSAM 投票算法的位姿估计	29
3.4 基于深度学习神经网络 YOLOv5 的图像识别实验	31
3.4.1 实验平台搭建.....	31
3.4.2 数据集准备	31
3.4.3 网络训练与测试效果.....	32

3.4.4 实验评价指标和实验分析.....	33
3.5 本章小结.....	35
第四章 机械臂操作平台的开发和实验验证	36
4.1 机械臂操作平台的搭建.....	36
4.2 机械臂正逆解分析.....	39
4.2.1 机械臂正解分析.....	39
4.2.2 机械臂逆解分析.....	41
4.3 视觉引导对位算法的设计	43
4.4 机械臂运动控制算法的设计	44
4.5 机械臂操作实验及误差分析	45
4.6 位姿估计与其他方法作比较	48
4.7 定量分析和消融实验.....	49
4.8 本章小结.....	50
第五章 总结与展望	51
5.1 总结.....	51
5.2 展望.....	51
参考文献.....	53

第一章 绪论

1.1 课题背景与意义

机器人是“制造业皇冠顶端的明珠”，其研发、制造、应用是衡量一个国家科技创新和高端制造业水平的重要标志^[1]。协作机器人作为一种新型的工业机器人，目前正处于快速发展阶段，随着技术的进步与需求的日益增长，协作机器人将被广泛用于生产，推进制造业的智能化进程，能够提高人们的生活水平^[2]。传统上的机器人工作方式为事先获取运动点，根据获取的运动点来设计机器人工作的运动路径，这种非智能的机器人操控技术在国外经过多年发展已经非常成熟^[3]。随着人工智能、机器人、传感器技术的不断发展，机器人已经由传统的在线示教工作模式向智能工作模式方向发展^[4]。

单目相机可以进行视觉检测、目标跟踪等功能。相比人工检测，视觉检测有望实现工厂产品识别检测的系统化、自动化，提高工作效率的同时，能够保证检测的实时性^[5]。但是单目相机只能获取到二维图像信息，无法直接获取场景中物体的深度信息。这使得在某些应用中需要进行深度感知或三维重建时，单目相机相对于双目相机表现较为有限。而且单目相机只有一个视角，相对于双目相机难以准确地进行物体定位和跟踪。在需要高精度的目标定位或者运动跟踪任务中，双目相机通常比单目相机更具优势。单目相机在进行视觉感知和目标检测等任务时，对场景中的纹理信息有较大的依赖。因此运用双目相机的深度和二维图像的组合传感系统能实现对物体更准确地识别和定位。

多传感器信息融合的基本原则就是采用多个类型的传感器对数据进行检测，使其在给定的融合规则中互相补充，从而获得相似的数据^[6]。融合视觉和雷达信息可以提供多模态的感知能力，视觉传感器可以提供高分辨率的图像信息，对于物体识别和姿态估计等任务较为有效，而雷达传感器可以提供距离、速度和方向等信息，对于目标跟踪和障碍物检测等任务更具优势。具有物体识别和操作功能的工业机器人越来越多的应用在工业设备和产品生产中，从而节省人工成本^[7]。因此，将多模态数据融合的技术应用到机器人的机械手臂上具有实用价值。

1.2 课题研究现状

多传感装置的数据互融的意思是集成两种或两种以上传感设备的系统，获取同一场景数

据信息,然后把各种传感设备的采集数据信息,按照一定算法规则处理后综合^[8]。其过程包括数据采集、数据预处理、特征提取、数据融合等过程。在多传感器信息融合中,要充分利用各种测量数据,并将其结合起来,得到更精确的数据,以改善多传感器的稳定性,克服单一类型传感器的局限性。因此同时采用多种不同类型的传感器集成的系统,能够弥补单一传感器系统信息量少、可靠性差等缺点,提高整个系统的检测和识别能力^[9]。

多传感器系统可以使用多种传感器来获取多模态数据,从而提供更全面的信息支持。和只使用单模态数据进行比较,多模态数据融合有以下几个优点:首先是可以增强所在系统的稳定性;其次是使用多模态数据可以提高系统的空间覆盖面以及空间分辨率;最后是可以获得更多的信息从而降低信息的缺失率^[10]。通过融合来自不同传感器的数据,可以获取更全面、准确的环境信息。不同传感器提供的数据互补性强,可以弥补各个传感器单独存在的局限性,从而提高感知能力。例如,将视觉传感器和雷达传感器的数据融合,可以同时获取目标的视觉特征和距离信息,提高目标检测和跟踪的准确性。当某个传感器受到干扰或损坏时,其他传感器可以弥补其缺失的数据,保持系统的正常运行。例如,当视觉传感器在光照条件不良的情况下无法正常工作,通过融合其他传感器的数据(如雷达、红外传感器),可以继续获取环境信息。除此之外,多传感器数据融合还可以提高位置和姿态估计的精度。通过融合来自多个传感器的数据,可以更准确地确定系统在三维空间中的位置、速度和方向。这对于导航、定位和姿态控制等应用非常重要。因此利用不同传感器采集的多模态数据融合技术,对提高机械臂自主化的发展具有重要的意义。

1.2.1 机械臂发展现状

协作机器人的起源和发展可以追溯到 20 世纪的工业机器人发展过程。最早的工业机器人主要是用于重复性、单一任务的自动化生产,它们通常是固定在一个位置,与人类工人分开工作。然而,随着对机器人的需求越来越多样化和复杂化,协作机器人的应用逐渐兴起。

协作机器人的目标是与人类工人在同一工作空间内合作完成任务,而不是简单地取代人类工人。这种机器人能够感知和理解人类工人的动作和意图,并相应地调整自己的行为,以实现有效的合作。

丹麦的 Universal Robots (UR) 公司于 2005 年成立,是最早推出协作机器人的厂家之一。他们的 UR 系列机器人于 2008 年问世,引领了协作机器人的发展潮流。采用轻巧、易于编程和安全的设计,适用于各种应用领域。美国的 Rethink Robotics 成立于 2008 年,于 2012 年推出了他们的第一款协作机器人 Baxter。Baxter 以其人性化的设计和灵活性而受到关注,它具

有可重定位的臂部和安全特性，可以与人类工人在同一工作空间内合作。ABB 是一家全球领先的工业机器人制造商，也在协作机器人领域有所发展。他们的协作机器人系列包括 YuMi 和 Single Arm YuMi。YuMi 于 2015 年发布，是一款双臂协作机器人，具有精确的操作能力和高度的安全性。KUKA 是另一家领先的工业机器人制造商，也在协作机器人领域有所贡献。他们的 LBR iiwa 系列机器人于 2013 年发布，被设计为与人类工人紧密合作。这些机器人具有高度的精确性和可编程性，适用于各种应用领域。

相较于国外发达国家，我国协作机器人的研究虽然起步稍晚，但近几年国内协作机器人产品不断推陈出新，在技术方面取得了很大突破，有着不弱于国际知名品牌的性能，推动了国内制造业和其他行业的快速发展，在市场方面，国产品牌占有国内协作机器人市场 70% 的份额，部分产品远销海外。智研咨询发布的《2024-2030 年中国协作机器人行业市场竞争态势及投资方向分析报告》显示，据统计，近年来我国协作机器人市场规模快速增长，截至 2022 年我国协作机器人市场规模约为 34.9 亿元，市场均价约为 12.25 万元/台。随着技术的进步及应用场景的不断成熟，协作机器人的应用将会越来越丰富，中国协作机器人市场需求仍将高速增长。

1.2.2 机器视觉目标检测的发展现状

目标检测是计算机视觉领域的一个重要任务，旨在识别图像或视频中的特定目标并确定其位置^[11]。随着深度学习和计算机硬件的发展，目标检测在准确性和效率方面取得了显著进展。目标检测在许多领域都有广泛的应用。其中包括自动驾驶汽车中的行人和车辆检测、安防监控系统的人脸识别和行为分析、智能交通系统中的交通标志和车辆识别、物体计数和跟踪、无人机和机器人的导航与感知、医学影像分析中的病变检测等。

传统目标检测算法通常需要手动设计和选择适合于目标识别的特征，只考虑局部区域的特征，缺乏全局和上下文信息的综合考虑。图像特征的表达方式在很大程度上受到随机性的影响，因此需要通过不断尝试和设计复杂的人工特征，才能最终获得既具有鲁棒性又计算效率高的特征^[12]。一些具有代表性的人工特征包括 HOG（Histogram of Oriented Gradients）特征描述子，具有形状信息和尺度不变性的特点；DPM（Deformable Part-based Model）模型，采用分而治之的方式；以及 AdaBoost 和随机森林分类器等^[13]。这些特征的构建需要不断的尝试和调整，以获得对目标进行准确检测的可靠性高的特征表示。

深度学习在目标检测领域的发展可以大致分为浅层神经网络检测器、二阶段深度神经网络检测器和单阶段深度神经网络检测器这三个阶段^[14]。目标检测的主干部分（backbone）主

要有：（1）VGGNet 是一个经典的卷积神经网络模型，具有多个卷积层和全连接层。虽然 VGGNet 在目标检测中的应用相对较少，但作为一个经典的模型，它对后续网络的设计产生了一定的影响；（2）ResNet 是由微软提出的一种深度残差网络结构。它通过引入残差连接（residual connections）来解决深层网络训练中的梯度消失和梯度爆炸问题。ResNet 在目标检测领域得到了广泛应用，并取得了很好的性能；（3）Inception 系列是由 Google 提出的一系列网络模型，以其多个并行的卷积分支和特征重组（feature concatenation）方式而闻名，Inception 系列的网络结构在目标检测中表现出色，其中较为著名的是 InceptionV3 和 InceptionResNetV2；（4）MobileNet 是一种轻量级的卷积神经网络，专为移动设备和嵌入式系统设计，它采用了深度可分离卷积（depthwise separable convolution）和逐点卷积（pointwise convolution）等结构，以降低模型的计算量和参数量，MobileNet 在目标检测任务中具有较高的速度和较好的准确性；（5）EfficientNet 是一系列具有不同规模的卷积神经网络模型，通过对网络的深度、宽度和分辨率进行统一缩放来提高模型的效率和准确性^[15]，EfficientNet 在目标检测领域取得了很好的性能，并成为当前流行的模型之一。这些主干网络的设计对于目标检测模型的性能和效率具有重要意义。

在 2014 年，R. Girshick 等人提出了一种经典的基于卷积神经网络的目标检测方法（Region-based Convolutional Neural Network, R-CNN），主要由三个步骤组成：候选区域生成、特征提取和目标分类与位置回归^[16]。R-CNN 使用选择性搜索（Selective Search）方法生成一系列可能包含目标的候选区域，还引入了边界框回归器，用于对候选区域的位置进行微调，以更准确地定位目标的边界框。

另外，He Kaiming 等人提出的 SPP-Net（Spatial Pyramid Pooling Network）是对 R-CNN 的改进之一。SPP-Net 的主要改进在于解决了 R-CNN 中固定输入尺寸的限制，并提高了整体的计算效率。在传统的 R-CNN 中，每个候选区域都需要被调整为固定的大小作为输入送入 CNN 进行特征提取。这样的做法存在两个问题：一是不同候选区域的大小不一样，需要进行调整，导致计算开销增大；二是固定的输入尺寸限制了候选区域的选择，可能会导致信息的丢失或者变形。SPP-Net 通过引入空间金字塔池化（spatial pyramid pooling）的操作，能够处理任意大小的候选区域，并且获得更好的检测性能。这种技术创新使得目标检测在处理不同尺寸和宽高比的图像时更加灵活和高效。

在 2015 年，R. Girshick 提出了一种被称为 Fast R-CNN 的端到端训练系统，以解决 R-CNN 需要多阶段训练的问题^[17]，Fast R-CNN 是对 R-CNN 的进一步改进，通过将候选区域的特征提取与目标分类合并为一个过程，提高了检测的速度。Fast R-CNN 引入了 RoI 池化层（Region of Interest pooling），可以在整个图像上共享特征提取的计算结果，从而避免了对每个候选区

域进行独立的卷积操作。这使得 Fast R-CNN 的速度相较于 R-CNN 提高了 146 倍。紧接着, R. Girshick 在次年提出了一种更为先进的目标检测方法, 即 Faster R-CNN。这一方法将区域建议引入神经网络, 实现了端到端的目标检测, 其中区域建议网络(RPN)引入了锚框(Anchor Box), 使用多个不同宽高比的边界框, 并通过回归来准确定位图像中的物体^[18]。RPN 可以有效地生成候选区域, 用于目标的分类和位置回归, 避免了选择性搜索的过程。另外, 其整体框架更加简化和高效, 进一步提高了检测的速度和准确性, 实现了每秒 5 帧的运行速度。

Dai 等人在研究中结合了 Faster R-CNN 和 FCN 各自的优势, 创造性地提出了 R-FCN (Region-based Fully Convolutional Networks)。R-FCN 中实现了几乎所有计算的共享, 认为全连接层的作用有限, 采用了位置敏感评分图和 RPN 相结合的方式, 取代了全连接层对目标进行定位^[19], R-FCN 进一步提升了检测准确率和运算速度, 超越了当时的 State-Of-The-Art (SOTA) 模型。

另一方面, Mask R-CNN 是在 Faster R-CNN 的基础上进行改进, 增加了对目标实例分割的支持。除了目标的分类和位置回归, Mask R-CNN 还可以生成每个目标实例的精确掩码, 实现像素级的分割。这使得 Mask R-CNN 在同时完成目标检测和实例分割任务时表现出色。

在 2015 年, J. Redmon 等人提出了 YOLO (You Only Look Once) 目标检测方法, 实现了推理速度质的飞跃^[20]。YOLOv1 是 YOLO 系列的第一个版本, 它引入了端到端的目标检测方法, 将目标检测任务转化为一个回归问题, 具有较快的检测速度。YOLOv1 的主要改进方法是在检测头中引入了先验框 (prior box), 通过预定义的先验框来预测目标的位置和类别信息。

YOLOv2 在 YOLOv1 的基础上进行了改进, 引入了一系列的技术以提高检测精度和定位准确性。包括引入了 Anchor Boxes 提高目标位置的预测精度, 使用了 Batch Normalization 等。并引入了 Darknet-19 作为特征提取网络, 使用多尺度训练和测试等。

YOLOv3 在 YOLOv2 的基础上进一步提升了检测精度和速度。它引入了 FPN (Feature Pyramid Network) 来提取多尺度特征, 引入了三个不同尺度的检测头, 使用不同大小的先验框来检测不同大小的目标。YOLOv3 采用了性能更强的 Darknet-53 作为主干网络。相比于 YOLOv2 中使用的 Darknet-19, Darknet-53 能够提取更多、更丰富的特征信息, 有助于提升检测的准确性和性能。

YOLOv4 在 YOLOv3 的基础上进行了一系列的改进, 包括使用更强大的骨干网络 (如 CSPDarknet53 和 CSPResNeXt), 采用了更多的技术 (如 SAM、PANet、CIOU 损失函数等) 来提高检测精度。并引入了 SAM (Spatial Attention Module) 和 PANet (Path Aggregation Network) 等技术, 使用 CIOU (Complete Intersection over Union) 损失函数来优化目标框的预测。

YOLOv5 于 2020 年发布, 在 YOLOv4 的基础上进一步改进了检测精度和速度, 并且减小了模型尺寸。使用 CSPDarknet53 作为骨干网络, 引入了特征金字塔网络来提取多尺度特征, 优化了网络结构和模型尺寸, 提升了检测精度和速度。

在 YOLO 的各个版本中, YOLOv4 和 YOLOv5 开始使用 PyTorch 框架, PyTorch 是一个基于动态图计算的深度学习框架, 相比于静态图计算框架, 如 TensorFlow, PyTorch 具有更直观、灵活的开发方式。它使用动态图计算模式, 允许开发者在运行时动态地定义、修改和调试网络结构, 简化了模型的设计和调试过程。而且 PyTorch 的 API 设计简洁、一致, 并且与 Python 语言自然地融合在一起, 这使得初学者可以更快速地上手。

百度飞桨 PaddlePaddle 团队在 2022 年 5 月发布的 PP-YOLOv5E 相对于上述的 YOLOv5 系列算法具有三大优势: 更丰富灵活的配置方案、更强的性能和更全面的硬件支持^[22]。PP-YOLOv5E 通过在 YOLOv5 的基础上进一步优化和改进, 提高了检测的准确性和性能。PP 代表 "Post-Processing", 指的是在目标检测结果后处理阶段进行的一系列操作, 例如使用更精细的锚框、应用非极大值抑制等。

2022 年 9 月, 美团 AI 团队研发 Chuyi Li 等人提出了 YOLOv6 版本, 主干网络设计了一个高效的重新参数化的骨干, 称为 EfficientRep。针对不同的场景, 设计了不同的模型, 兼顾精度与速度。在分类和回归任务上都使用自蒸馏策略, 动态调整教师模型和标签, 便于学生模型的训练。

2022 年 7 月, YOLOv4 团队提出了 YOLOv7, YOLOv7 和之前的版本相比更改了架构, 采用了一种叫做扩展高效层聚合网络(E-ELAN)的策略^[23], 通过控制最短最长的梯度路径, 允许深度模型更有效地学习和收敛。2023 年 1 月, YOLOv5 团队提出了 YOLOv8, YOLOv8 支持多种视觉任务, 如对象检测, 分割, 姿态估计, 跟踪和分类。

1.3 研究目的及研究内容

本研究利用多模态传感器数据, 包括相机的 RGB 图像信息、深度图像信息以及触觉传感器的信息等。通过综合利用这些多模态传感器数据, 能够获得更全面的环境感知能力, 从而改善机器人系统在各种任务中的表现。具体工作如下:

(1) 本研究搭建了相机标定和手眼标定系统, 并且进行了相应实验。通过相机标定, 获得了相机内参; 通过手眼标定, 计算出手眼标定矩阵。标定精度是机械手臂可以准确到达指定位置的前提。

(2) 本研究在 YOLOv5 目标检测的基础上进行了改进。为了捕获不同尺度的物体, 从

而提高模型在检测各种大小目标方面的性能，增加了多尺度特征目标检测模块；在观察图像时，通常人们会把更多的注意力放到自己感兴趣的地方，为了高效利用有限的注意力资源，本研究引入了注意力模块。注意力机制可以帮助网络“聚焦”于重要区域的机制。在目标遮挡的情况下，引入注意力机制可以帮助网络更加关注容易被遮挡的目标部分，可以自动学习到哪些区域对目标的检测和定位更为重要，从而提高在遮挡情况下的检测性能。

（3）基于特征点的方法在位姿估计中具有优势，无需数据集和复杂训练，硬件要求较低。但是对实时性和环境的适应性有限。基于投票网络的 PVNet 网络对这些问题有所改善，但其损失函数仅考虑方向损失，忽略了像素到关键点距离的影响，导致精度有所下降；而且在背景杂乱的情况下，可能会出现误投票的情况。针对上述投票网络的缺点，本研究提出了一种基于均方误差和注意力机制的投票网络(MSAM)。

（4）在 UR 机械臂和 Orbbec Gemini2 相机的硬件条件下，对基于改进 YOLOv5 的图像识别、基于 MSAM 模块的位姿估计进行实验。结合机器人实验平台对目标检测算法优化及目标物定位误差分析，提升了目标检测精度的同时验证机械臂操作系统的稳定性，为机器人系统研究及应用提供一定的参考意义和实用价值。

第二章 目标定位及视觉引导标定的设计

本研究基于 ROS 驱动 Orbbec Gemini2 深度相机，使用深度图像转成点云对电厂屏柜进行配准匹配；基于改进的 YOLOv5 对 RGB 图像进行目标识别，并使用本研究提出的基于 MSAM 投票网络的位姿估计方法进行位姿估计，使用 UR 机械臂进行轨迹规划，进而操作目标物。本研究的整体内容的流程图如图 2.1 所示。




图 2.1 整体流程图

2.1 相机选型

深度相机作为机械手臂的“眼睛”，因此相机的选型非常重要。深度相机的选型主要需要考虑以下几个方面：

- (1) 视野广度：视野广度指的是相机能够捕捉到的水平和垂直范围。
- (2) 分辨率：分辨率决定了相机能够捕捉到的细节程度，而图像质量则涉及噪声水平、动态范围和色彩准确性等因素。
- (3) 帧率和快门速度：帧率指相机每秒可以捕捉和传输的图像帧数，而快门速度则决定了相机对快速运动物体的拍摄能力。
- (4) 接口：相机的接口类型与设备的连接方式和数据传输速度有关。常见的接口包括 USB、Camera Link 等。

（5）外观和尺寸：机械臂上的相机需要适应机械臂结构，并且不会影响机械臂的正常运动。因此，选择外观紧凑、尺寸合适的相机也是比较重要的考虑因素。

（6）抗震性和稳定性：机械臂工作时会有震动，因此选择具有良好抗震性和稳定性的相机，以确保图像质量不受干扰，并保持稳定的工作性能。

因此，为了实现精确的视觉操作，综合以上相机选型方面的考虑，需要选择一款具有合适视野广度和分辨率的深度相机，以满足对目标物位置和姿态信息准确性和实时性的要求。综合考虑，本研究选择了 Orbbec Gemini2 深度相机，如图 2.2 所示。



图 2.2 gemini2 相机图

ROS（机器人操作系统，Robot Operating System）是一个开源的机器人操作系统。采用分布式架构，可以在多种操作系统上运行，提供了丰富的软件库和工具。本研究基于 ROS 对相机进行驱动，获取图像和深度信息的 Topic，进行采集图像。Gemini2 是奥比中光推出的一款双目结构光视觉传感器，具有 1280x800 的彩色摄像头分辨率和 1280x720 的深度摄像头分辨率，相机的检测范围为 0.2 米至 5 米。图 2.3 描述了 Gemini2 相机获取彩色图像和深度图像的流程。




图 2.3 获取彩色图像和深度图像的流程

2.2 机械臂视觉系统的标定

在现代制造和自动化领域，机械臂系统在执行各种任务中发挥着关键作用。随着机械臂应用的不断拓展，对其精确运动和视觉感知的要求也变得越来越高的。机械臂视觉系统的标定的准确度影响着机械臂在复杂环境中精准感知和操作。视觉系统标定是一种通过确定相机和机械臂之间的准确关系，将图像坐标映射到机械臂工作空间坐标的过程。

相机标定和手眼标定是计算机视觉和机器人领域中的关键技术，它们为视觉系统提供了三维世界和二维图像之间相互关联关系，从而使机器能够感知、理解环境。在标定过程中，考虑到机械臂和相机的固有误差、镜头畸变和变焦等因素，如何有效地校准视觉系统成为一个复杂而关键的问题。本章将回顾目前广泛使用的标定方法，并提出一种综合考虑多种误差来源的新型标定策略。通过这一策略，本研究旨在提高机械臂视觉系统在实际应用中的稳定性和可靠性，从而更好地满足不同行业对于高精度自动化的需求。

2.2.1 相机标定

相机标定是确定相机内部参数和外部参数的过程，以便正确地将物体在三维空间中的位置映射到二维图像上。这些参数包括：

(1) 内部参数包括焦距、主点坐标和畸变参数。焦距决定了图像中物体的尺寸和相对距离，主点坐标表示图像中心，而畸变参数用于校正镜头畸变。

$$M_{\text{camera}} = \begin{bmatrix} f_x & 0 & c_x \\ 0 & f_y & c_y \\ 0 & 0 & 1 \end{bmatrix} \quad (2.1)$$

式中，矩阵 M_{camera} 为一个 3*3 的内参系数， c_x ， c_y 由相机光心垂直投影到成像平面的坐标决定。 f_x ， f_y 由相机的焦距以及水平垂直方向上单个像元尺寸决定。

$$f_x = f/dx \quad (2.2)$$

式中， f 为相机焦距， dx 为相机每个像素的宽度。

(2) 外部参数：外部参数包括相机在世界坐标系中的位置和方向，通常由平移矢量和旋转矩阵描述。这些参数确定了相机观察物体的角度和位置。

2.2.2 相机标定实验

相机内参系数是相机成像的重要参数之一，它包括焦距、主点坐标和像素大小等信息，是进行相机几何校正和图像像素坐标到真实世界坐标的转换不可或缺的参数。获取相机内参

系数是相机视觉应用中的一个重要步骤,准确的相机内参系数可以保证后续的相机定位、三维重建和目标识别等任务的准确性。

为了获取相机内参系数,可以采用多种方法。首先,可以使用相机驱动和 ROS 来获取相机的内参系数。通过启动相机后,查看相机的话题消息 `camera_info`,就可以获取到相机的内参系数和畸变系数。其次,可以使用张正有标定法对相机进行标定。这种方法需要使用相机对标定板进行拍摄多张不同位姿的图片,通过求解世界实际坐标和像素坐标之间的对应关系,即可获取相机的内参系数。最后,可以利用 `opencv` 提供的 `calibrateCamera` 函数对相机进行标定,输入为标定板的 2D 点坐标和 3D 点坐标以及标定板网格的尺寸,输出为相机内参矩阵和畸变系数以及外参系数。

本研究采用 ROS 机器人操作系统中的 `camera_calibration` 工具和 `OpenCV` 视觉软件进行相机标定。首先,准备一张 6x9 的棋盘格标定板,使用支撑架固定好相机和标定板。本研究采用的是 Ubuntu18.04 系统,安装好对应 melodic 版本的 ROS 以及相机驱动(Orbbec SDK for ROS)。为了获取更准确的相机内参系数,本研究采集 70 张左右不同角度和距离的图像进行标定。相机标定实验如图 2.4 所示。

```
roslaunch camera_calibration cameracalibrator.py image:=/camer/color/image_raw --size 9x6 --square 0.02
```

上述指令为 ros 内参标定指令语言,/camer/color/image_raw 为相机 ROS 话题消息,size9x6 为标定板网格的格数,square 为每个网格的尺寸。




图 2.4 相机标定图

如图 2.4 所示, a 图为标定板的图片; b 图为内参标定时图片; c 图为相机拍摄的标定

图片，共 70 张图片；d 图为标定结果图片。

2.2.3 机械臂手眼标定

手眼标定，通常指的是在机器人系统中确定机械手臂末端相机（“眼”）相对于机械手臂末端（“手”）的位置和方向的过程。通常有“眼在手上”和“眼在手外”两种方案。

“眼在手外”指的是相机固定在机械臂末端以外的一个视野更好的位置的视觉系统，可以应用于自动化生产线上的零件装配、物料搬运等工作。“眼在手上”指的是相机通过连接件固定在机械臂末端的视觉系统，可以方便机械臂在处理不规则形状或者可变环境中更加灵活。本研究采用“眼在手上”的方案，需要确定机械臂末端相机与机械臂末端之间的关系。

$$M_{\text{target2base}} = M_{\text{gripper2base}} * M_{\text{cam2gripper}} * M_{\text{target2cam}} \quad (2.3)$$

式中， $M_{\text{target2base}}$ 为机械臂基坐标系下目标物的齐次矩阵； $M_{\text{gripper2base}}$ 为机械臂基坐标系下机械臂末端的齐次矩阵； $M_{\text{cam2gripper}}$ 为相机坐标系和机械臂末端坐标系之间的转换关系矩阵，即手眼标定矩阵； $M_{\text{target2cam}}$ 为相机坐标系下目标物的齐次矩阵。

通过矩阵运算，可以将齐次矩阵转换成旋转矩阵和平移矢量，然后在转换成需要的表示方法，旋转矩阵还有 3 种常用的表示方法，分别为：欧拉角、四元数和旋转矢量。旋转矩阵是描述物体在三维空间中旋转的数学概念，它是 3×3 的矩阵，用于表示旋转变换的方向和角度；欧拉角是一种常用的表示旋转的方法，它由三个轴角构成，分别表示绕固定的坐标轴进行旋转；四元数是一种扩展了复数概念的数学工具，在表示旋转时具有简洁和高效的特性，它可以用一个实部和三个虚部来表示旋转，常用于姿态控制和姿态表示；旋转矢量是一个三维向量，它的方向指示旋转轴，而其大小表示旋转角度。

2.2.4 机械臂手眼标定实验

在本节中，基于 ROS 平台和深度相机进行手眼标定实验。该实验通过拍摄图像和计算外参矩阵，将姿态旋转向量的表示形式转换成旋转矩阵的表示形式。然后，使用 OpenCV 中的 `calibrateHandEye` 函数，计算出手眼标定矩阵，并对标定结果进行精度测试和误差分析。

首先，通过拍摄的 14 组图像来计算每张图片相对于相机坐标系的外参矩阵，包括旋转向量和平移矢量，将姿态旋转向量的表示形式转换成旋转矩阵的表示形式；接着，获取每张图片对应的机械臂基坐标系下机械臂末端的位姿矩阵，这个位姿矩阵由平移矢量和欧拉角组成。

为了将位姿矩阵作为计算手眼标定矩阵的输入端，将欧拉角的表示形式转换成旋转矩阵的表示形式；然后，使用 OpenCV 中的 `calibrateHandEye` 函数。该函数的输入端是机械臂坐标系下机械臂末端的旋转矩阵和平移矢量，以及相机坐标系下标定板的旋转矩阵和平移矢量。通过运行该函数，可以得到手眼标定矩阵，该标定矩阵由旋转矩阵和平移矩阵组成，并将其转换成 4×4 的手眼标定齐次矩阵。

为了验证手眼标定的精度，本研究进行了手眼标定精度测试。由于标定板和机械臂基坐标系的相对位置保持不变，可以将每张图像所对应的机械臂基坐标系下机械臂末端的齐次矩阵、手眼标定齐次矩阵和相机坐标系下标定板的齐次矩阵进行相乘，并从结果中提取出平移矩阵进行误差分析。通过观测 14 组平移矩阵，可以得到 X、Y、Z 方向上的最大误差，并判断标定效果是否满足要求。

接下来，介绍基于 ROS 和深度相机进行手眼标定实验的步骤和方法。这些步骤包括准备标定板、拍摄图像、获取机械臂末端姿态信息、角点提取和亚像素精确化、相机内参标定以及标定结果评估。

首先，准备带有黑白格子网格的 9×6 标定板，并将其固定好。接着，保持机械臂基坐标系的位置不变，通过示教器移动机械臂末端，拍摄图像并获取机械臂末端的位置和姿态信息。




图 2.5 手眼标定实验图

如图 2.5 所示，机械臂末端依次移动到不同位置，拍摄多张图片，并记录对应的机械臂末端位姿信息，以获得 14 组不同位置和姿态的图片及机械臂末端位姿数据。

然后，利用 VScode 编程软件和 C++编程语言编写编程，设置好图片的数量、标定板上每个棋盘格的尺寸、标定板上每行和每列的角点数量等参数。运行程序，提取标定板上的 54 个角点并保存，然后对每个角点进行亚像素精确化，以确保对之前粗提取的角点进行精确化处理。接着，假设标定板放在世界坐标系中 $Z=0$ 的平面上，初始化标定板上每个角点的三维坐标，然后使用 opencv 的 `calibrateCamera` 函数对相机进行标定。输入端为每个角点的三维坐标和对应的二维坐标，输出端为相机的内参矩阵、畸变系数，以及每张图片的旋转向量和平移矢量。接下来，对标定结果进行评估，通过得到的相机内外参数，对每个角点的三维坐标进行重投影计算，从而获得新的投影点。再和之前的二维投影点进行误差估计，得到每幅图像的平均像素误差。

基于上述相机标定时已经得到了 14 组图像对应的外参矩阵，即每一张图片的旋转矩阵和平移矢量；然后对每张图像所对应的机械臂基坐标系下机械臂末端的位姿矩阵进行矩阵变换，此时的位姿矩阵由平移矢量和欧拉角组成，为了后续将位姿矩阵作为 opencv 计算手眼标定矩阵的输入端，需要将欧拉角的表示形式转换成旋转矩阵的表示形式。使用 opencv 的 `calibrateHandEye` 函数，输入端为机械臂坐标系下机械臂末端的旋转矩阵和平移矢量、相机坐标系下标定板的旋转矩阵和平移矢量；输出端为手眼标定矩阵，此时的标定矩阵是由旋转矩阵和平移矩阵组成，需要转换成 4×4 的手眼标定齐次矩阵。

手眼标定时，标定板和机械臂基坐标系的相对位置保持不变，以此来验证标定的精度。每张图像所对应的机械臂基坐标系下机械臂末端的齐次矩阵、手眼标定齐次矩阵、相机坐标系下标定板的齐次矩阵，三个矩阵进行相乘，再从结果中提取出平移矩阵。

表 2.1 手眼标定效果表

观测数据	X	Y	Z
1	0.8658	-0.0845	0.2377
2	0.8659	-0.0834	0.2379
3	0.8663	-0.0841	0.2375
4	0.8658	-0.0838	0.2388
5	0.8659	-0.0834	0.2384
6	0.8660	-0.0835	0.2378
7	0.8661	-0.0844	0.2375
8	0.8659	-0.0847	0.2372
9	0.8659	-0.0849	0.2375
10	0.8661	-0.0840	0.2378
11	0.8662	-0.0841	0.2379
12	0.8652	-0.0838	0.2384
13	0.8653	-0.0847	0.2374
14	0.8661	-0.0845	0.2376

如表 2.1 所示，为 14 组平移矩阵结果，可以计算出 X 方向最小为 0.8652m，最大为 0.8663m，

最大误差为 0.0011m；Y 方向最小为-0.0849m，最大为-0.0834m，最大误差为 0.0015m；Z 方向最小为 0.2372m，最大为 0.2388m，最大误差为 0.0016m。XYZ 所有方向最大误差为 1.6mm，满足要求。

2.3 坐标系之间的转换关系

世界坐标系是一个全局参考坐标系，用于描述物体在三维空间中的位置和姿态。通常以某个固定点为原点，用三个相互垂直的轴（如 X、Y、Z 轴）来定义。相机坐标系是相机本身的局部坐标系，与相机的硬件结构和安装位置有关。通常以相机的光学中心为原点，相机的光轴为 Z 轴，X 轴和 Y 轴与光轴垂直并构成一个平面。图像坐标系是相机成像后的二维图像上的坐标系，水平方向为 X 轴正方向，垂直方向为 Y 轴正方向。像素坐标系是图像坐标系的一种特殊形式，用于描述图像中的像素位置。通常以图像的左上角为原点，水平方向和垂直方向的单位长度为像素。

2.3.1 世界坐标系和相机坐标系

世界坐标系到相机坐标系的转换可以通过相机的外参（extrinsic parameters）来实现，包括相机的位置和姿态信息。这个转换可以使用旋转矩阵和平移向量来描述。其转换关系示意图如图 2.6 所示。




图 2.6 世界坐标系与相机坐标系之间关系

如图 2.6 所示， $P(X_w, Y_w, Z_w)$ 表示世界坐标系中的一个点， $C(X_c, Y_c, Z_c)$ 表示相机坐标系中的某个点，则这两个坐标点的转换关系可以表示为公式 (2.4)。

$$\begin{bmatrix} X_c \\ Y_c \\ Z_c \end{bmatrix} = R \begin{bmatrix} X_w \\ Y_w \\ Z_w \end{bmatrix} + T \rightarrow \begin{bmatrix} X_c \\ Y_c \\ Z_c \\ 1 \end{bmatrix} = \begin{bmatrix} R & T \\ 0^T & 1 \end{bmatrix} \begin{bmatrix} X_w \\ Y_w \\ Z_w \\ 1 \end{bmatrix} \quad (2.4)$$

式中， R 表示旋转矩阵， T 表示平移矢量。

2.3.2 相机坐标系和图像坐标系

相机坐标系和图像坐标系之间的转换关系可以通过相机的内参（intrinsic parameters）来实现，包括相机的内部参数，如焦距、主点位置等。这个转换可以使用相机投影模型，如针孔相机模型，将三维相机坐标投影到二维图像坐标。相机坐标系与图像坐标系之间的投影满足三角形相似原理。




图 2.7 相机坐标系与图像坐标系之间关系

如图 2.7 所示，根据三角形相似关系，可以知道 $\Delta O_c O C$ 相似于 $\Delta O_c A B$ ，并且 $\Delta O_c C p$ 相似于 $\Delta O_c B P$ ，可以得到公式：

$$\frac{O_c O}{O_c A} = \frac{O C}{A B} = \frac{p C}{P B} = \frac{O_c C}{O_c B} \quad (2.5)$$

进而得到相机坐标系和图像坐标系之间的转换关系为：

$$Z_c \begin{bmatrix} x \\ y \\ 1 \end{bmatrix} = \begin{bmatrix} f & 0 & 0 & 0 \\ 0 & f & 0 & 0 \\ 0 & 0 & 1 & 0 \end{bmatrix} \begin{bmatrix} X_c \\ Y_c \\ Z_c \\ 1 \end{bmatrix} \quad (2.6)$$

式中， f 表示相机焦距。

2.3.3 图像坐标系和像素坐标系

图像坐标系和像素坐标系之间的转换关系是一个线性关系，可以通过图像的尺寸和像素大小进行计算来实现。需要将图像的坐标值乘以一个比例因子，然后进行平移。两个坐标系之间的转换示意图如图 2.8 所示。




图 2.8 图像坐标系与像素坐标系之间关系

如图 2.8 所示, (x, y) 是图像坐标系上的点, 单位为 mm, 像素的单位为 pixel。 O_{uv} 表示像素坐标系的原点, O 表示图像坐标系的原点。两个坐标系之间的转换关系如公式 (2.7) 所示。

$$\begin{bmatrix} u \\ v \\ 1 \end{bmatrix} = \begin{bmatrix} 1 & 0 & u_0 \\ \frac{1}{dx} & \frac{1}{dy} & v_0 \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} x \\ y \\ 1 \end{bmatrix} \quad (2.7)$$

式中, dx 表示 x 轴上的物理长度, 即: $1\text{pixel} = d_x\text{mm}$ 。 dy 表示 y 轴上的物理长度, 即: $1\text{pixel} = d_y\text{mm}$ 。

将公式(2.4)、公式(2.6)和公式(2.7)进行整理可以得到三维坐标到二维坐标的转换关系:

$$\begin{aligned} Z_c \begin{bmatrix} u \\ v \\ 1 \end{bmatrix} &= \begin{bmatrix} 1 & 0 & u_0 \\ \frac{1}{dx} & \frac{1}{dy} & v_0 \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} f & 0 & 0 & 0 \\ 0 & f & 0 & 0 \\ 0 & 0 & 1 & 0 \end{bmatrix} \begin{bmatrix} R & T \\ 0^T & 1 \end{bmatrix} \begin{bmatrix} X_w \\ Y_w \\ Z_w \\ 1 \end{bmatrix} \\ &= \begin{bmatrix} f & 0 & u_0 & 0 \\ 0 & f & v_0 & 0 \\ 0 & 0 & 1 & 0 \end{bmatrix} \begin{bmatrix} R & T \\ 0^T & 1 \end{bmatrix} \begin{bmatrix} X_w \\ Y_w \\ Z_w \\ 1 \end{bmatrix} = M_1 M_2 \begin{bmatrix} X_w \\ Y_w \\ Z_w \\ 1 \end{bmatrix} \quad (2.8) \end{aligned}$$

式中, $f_x = \frac{f}{dx}$ 代表相机 X 轴的尺度因子, $f_y = \frac{f}{dy}$ 代表相机 Y 轴的尺度因子。 M_1 表示相机内参矩阵, M_2 表示相机外参矩阵。

2.3.4 相机坐标系和机械臂基坐标系

机械臂运行时的基准坐标系为机械臂基坐标系, 要想让机械臂运行到达指定位置, 需要将相机坐标系下目标物的位姿转移到机械臂基坐标系下。通过目标识别得到目标物的平移矢

量 (x, y, z) ，目标物的旋转矢量为 (R_x, R_y, R_z) ，并转换成旋转矩阵 $M_{rotation}$ ，如公式（2.9）所示，再将旋转矩阵和平移矢量拼接成 4×4 的位姿齐次矩阵 $M_{target2cam}$ ，如公式（2.10）所示。

$$M_{rotation} = \begin{bmatrix} R_{11} & R_{12} & R_{13} \\ R_{21} & R_{22} & R_{23} \\ R_{31} & R_{32} & R_{33} \end{bmatrix} \quad (2.9)$$

式中， $M_{rotation}$ 为旋转矩阵。

$$M_{target2cam} = \begin{bmatrix} R_{11} & R_{12} & R_{13} & x \\ R_{21} & R_{22} & R_{23} & y \\ R_{31} & R_{32} & R_{33} & z \\ 0 & 0 & 0 & 1 \end{bmatrix} \quad (2.10)$$

式中， x, y, z 为各自方向的平移量。

通过手眼标定得到手眼标定矩阵 $M_{cam2gripper}$ ；调用机械臂的接口可以得到机械臂基坐标系下机械臂末端的齐次矩阵 $M_{gripper2base}$ ，通过公式（2.3）计算出机械臂基坐标系下机械臂末端的齐次矩阵 $M_{target2base}$ 。

通过机械臂 TCP（工具中心点）工具标定方法，可以得到机械臂末端坐标系下工具末端的转换矩阵 $M_{tool2gripper}$ ；令基坐标系下目标物的齐次矩阵等于基坐标系下工具末端的齐次矩阵，即 $M_{target2base} = M_{tool2base}$ ；根据坐标系转换关系，机械臂末端坐标系下的工具末端齐次矩阵，转移到机械臂基坐标系下，表示为公式（2.12）：

$$M_{tool2base} = M_{gripperWithTool2base} * M_{tool2gripper} \quad (2.11)$$

式中， $M_{gripperWithTool2base}$ 为机械臂实际应该到达的位姿齐次矩阵， $M_{tool2gripper}$ 为机械臂末端坐标系下工具末端的转换矩阵， $M_{tool2base}$ 基坐标系下工具末端的齐次矩阵，同公式（2.13）。

公式（2.13）可以计算出机械臂基坐标系下机械臂末端需要到达位置的齐次矩阵。

$$M_{gripperWithTool2base} = M_{target2base} * (M_{tool2gripper})^{-1} \quad (2.12)$$

通过矩阵分解，将 4×4 的齐次矩阵分解出 3×3 的旋转矩阵和平移矢量 (x, y, z) ，旋转矩阵可以转换成旋转矢量 (R_x, R_y, R_z) 。

2.4 本章小结

本章主要介绍了相机标定和手眼标定的原理并详细讲述了具体的实现方法。然后介绍了涉及机械臂视觉引导对位相关的坐标系和各个坐标系之间的转换关系。相机标定是确定相机的内部参数和外部参数的过程，可以消除图像畸变，从而提高测量和定位的精度。通过准确

的相机标定，可以使得图像与现实世界之间的对应关系更加准确和可靠；本研究采用了“眼在手上”手眼标定系统，通过手眼标定可以得到机械臂末端和相机坐标系之间的转换关系，用于机械臂操作时的位姿解算。

本章节还建立了手眼标定和相机标定实验平台，进行了相应实验。相机标定和手眼标定的精度是机械手臂可以准确到达指定位置的前提。

第三章 基于 YOLOv5 的视觉检测和位姿估计

本章介绍了基于改进的 YOLOv5 的目标识别和基于 MSAM 的位姿估计方法求取目标物在相机坐标系下的位姿矩阵，本章的主要流程如图 3.1 所示。




图 3.1 位姿解算流程图

3.1 YOLOv5 目标检测算法以及相关改进

3.1.1 目标检测算法介绍

YOLOv5 是一种先进的目标检测算法，本研究基于 YOLOv5 算法中最小的网络模型 YOLOv5s 展开的。YOLOv5s 模型的特点是速度快但精度低，YOLOv5 还有三种网络模型在 YOLOv5s 的基础上进行了更深的网络层和更宽的网络通道的设计，以提升检测的精度，但相应地会减慢速度。

在数据增强方面，YOLOv5 引入了一种称为 Mosaic 的数据增强方法，使得 YOLOv5 能够生成具有更多多样性和丰富性的训练样本。YOLOv5 网络在主干网络的第一层引入了 Focus 结构，这有助于提取更多尺度的特征信息。此外，YOLOv5 还借鉴了跨阶段局部网络的思想，在主干网络和脖颈部分引入了两种不同的 CSP（Cross Stage Partial）结构，以加强特征的代表能力和信息流动性。在 YOLOv5 模型训练时使用了 CIoU（Complete IoU）损失函数。CIoU 损失函数在边框回归中考虑了目标框的位置、大小和形状等因素，能够更准确地衡量预测框

与真实框之间的差异，从而促进模型的学习和优化。下面介绍了常用的几种损失函数。

IoU（Intersection over Union）是一种常用的目标检测性能评估指标，根据计算预测框与真实框之间的重叠区域的尺寸大小来判断预测框的准确性。具体的计算过程如公式（3.1）所示。

$$\text{IoU} = \frac{|A \cap B|}{|A \cup B|} \quad (3.1)$$

式中，A 表示真实框，B 表示预测框。由公式可知，当真实框和预测框不重叠时，IoU 恒为 0。所以不好判断两个框的相对位置关系，也不好判断当两个框具有相同的 IoU 值时，它们实际是不是重叠在一起的。因此，提出了 GIoU 损失，考虑了两个框之间的位置、大小和形状等因素，通过计算两个框的最小闭包区域（即包围两个框的最小矩形框）的面积和它们的交集面积之间的差异，来度量它们的位置关系。具体的计算过程如公式（3.2）所示。

$$\text{GIoU} = \text{IoU} - \frac{|A_c - U|}{A_c} \quad (3.2)$$

式中， A_c 表示真实框和预测框的包围两个框的最小矩形框的面积，U 表示两个框并集的面积。除了 GIoU，在 IoU 损失的基础上进行了改进，提出了 DIoU（Distance-IoU）损失。具体计算过程如公式（3.3）所示。

$$\text{DIoU} = \text{IoU} - \frac{\beta^2(b, b^{gt})}{d^2} \quad (3.3)$$

式中，d 为最小矩形框的对角线距离，b 表示预测框的中心点， b^{gt} 表示真实框的中心点， β^2 为两个中心点的欧式距离。

在 DIoU（Distance-IoU）的基础上提出了一种名为 CIoU（Complete IoU）损失的方法，该损失函数考虑了边界框的长宽比。与 DIoU 损失相比，CIoU 损失进一步考虑了预测框和真实框之间的最小闭包区域的对角线距离以及它们中心点的欧式距离。这样可以加快模型的收敛速度，尤其是在两个框在水平或垂直方向上同时出现的情况下。CIoU 损失的计算过程可以使用公式(3.4)和公式(3.5)进行描述。

$$v = \frac{4}{\pi^2} \left(\arctan \frac{w^{gt}}{h^{gt}} - \arctan \frac{w}{h} \right)^2 \quad (3.4)$$

$$L_{\text{CIoU}} = 1 - \text{IoU} + \frac{\rho^2(b, b^{gt})}{c^2} + \alpha v \quad (3.5)$$

式中，v 用来表示长宽比的相似性， α 为权重系数。

3.1.2 基于 YOLOv5 目标检测算法的优化

本研究基于 YOLOv5 目标检测算法，通过采用多尺度特征检测来提高模型在不同尺寸目标上的检测能力。为了实现这一目标，YOLOv5 采用了三个不同的特征金字塔，能够有效地

捕获不同尺度的物体，从而提升模型在检测各种大小目标上的性能。此外，为了进一步提高多尺度检测的性能，研究结合了特征融合技术。特征融合是将来自不同层或不同特征金字塔的特征进行合并，以获得更加丰富和具有区分性的特征表示。在 YOLOv5 中，可以采用路径聚合网络（PAN）或特征金字塔网络（FPN）等方法来实现特征融合。

（1）多尺度特征目标检测（Multi-Scale Convolutional Neural Network）

卷积神经网络在目标检测可以提取特征。增加卷积层深度的优点是可以得到更丰富的语义信息。但是，深层卷积层会降低图像的分辨率，损失部分几何细节，尤其是对于小目标检测。为了解决这个问题，可以采用多尺度检测的方法。因为多尺度检测结合了不同深度卷积层提取的特征，综合利用低层和高层特征的优势，在不同尺度上进行目标检测。这样不仅可以保留高级语义信息，还可以不损失小物体的几何细节，从而提高模型对不同尺寸目标的检测性能。

一阶段目标检测器具有端到端的特性，因此具备实时性，但在检测准确性方面不如两阶段检测器。YOLOv5 就是一阶段目标检测器，只在顶层特征图进行检测。SSD 在网络中引入了多个不同层次的特征图，通过这些特征图来检测不同尺度的目标。并引入了一组先验框（prior boxes），这些先验框用于定义目标的位置和尺度范围。通过与先验框进行匹配，可以确定目标的位置和类别。这种先验框的引入可以提高目标检测的准确性。然而，SSD 也存在一些缺陷。由于 SSD 使用了多层卷积网络进行特征提取，其中较深层次的特征图分辨率较低，这导致 SSD 在检测小目标时的性能相对较弱。较低的分辨率可能使小目标的细节信息丢失，降低目标检测准确性。

多尺度特征检测可以使用特征金字塔网络（FPN）来实现，特征金字塔是一种通过构建多尺度的特征图来实现多尺度检测的方法。它通过在网络中引入多个分辨率不同的特征图，从而能够检测到不同尺度的目标。一种常见的实现方法是使用金字塔结构的卷积网络，在网络的上层和下层之间进行特征图的上采样和下采样操作，以得到多个尺度的特征图。通过这样的网络结构设计，语义信息和几何信息可以通过横向连接进行融合，融合了浅层到深层的特征图，从而充分利用各个层次的丰富全面的特征信息，有助于物体分类和定位任务。




图 3.2 FPN 结构示意图

如图 3.2 所示，展示了特征金字塔网络结构的示意图。

在 SSD 中引入特征金字塔网络（FPN）可以使得较低层级的特征图得到高层级语义信息的补充，从而改善对小目标的检测能力。具体来说，FPN 可以通过跳跃连接将高层级的特征图与低层级的特征图进行连接，并进行上采样操作，使得低层级的特征图具有更高的分辨率。这样一来，在进行目标检测时，SSD 可以同时利用多个尺度的特征图进行预测，从而提高对小目标的检测性能。

为了克服特征金字塔网络（FPN）存在的一些问题，PANet（Path Aggregation Network）是一种进一步改进多尺度特征处理的方法，它主要解决了 FPN 中的信息传递和特征融合的问题。在 FPN 中，特征金字塔结构通过跳跃连接将高层级的特征图与低层级的特征图进行连接，并进行上采样操作，以获取多尺度的特征图。然而，FPN 在进行特征融合时，仅仅是简单地将不同层级的特征图进行连接，可能导致信息传递不充分和特征融合不准确的问题。

PANet 通过引入自顶向下和自底向上的路径来解决这些问题。具体来说，PANet 在 FPN 的基础上增加了横向连接，将上层的特征图通过横向连接传递给下层，同时将下层的特征图通过上采样进行上级特征的补充。这样一来，PANet 能够更好地传递上层的语义信息到下层，并且能够更准确地进行特征融合，提高物体检测的性能。




图 3.3 FPN 与 PAN 网络结构示意图

如图 3.3 所示，展示了 FPN 与 PANet 结合起来的结构示意图。

YOLOv5 在特征提取网络后面引入了 FPN（Feature Pyramid Network）结构。FPN 能够获得多尺度的特征图，并且通过上采样和特征融合操作将不同尺度的特征图结合起来。这有助于提高对不同尺度目标的检测能力。YOLOv5 使用了一种称为“backbone”的主干网络来提取图像特征。在主干网络中，通常会使用卷积层和池化层来逐渐减小特征图的空间尺寸。使用了一组预定义的先验框（anchor boxes），用于检测目标的位置和大小。这些先验框在训练阶段通过聚类分析得到，以捕捉特定数据集中目标的尺度和宽高比分布。YOLOv5 的网络输出包含了对这些先验框的回归预测，用于预测目标的位置和尺寸。

YOLOv5 中，物体检测是在三个不同尺度的特征图上进行的，为了解决现有三个尺度特

征图可能丢失超小物体的轮廓和位置信息的问题，本研究在现有基础上进行了改进。增加了一个尺度（4 倍下采样）的特征图进行目标检测。通过这样的设计可以获得更细粒度、更全面的特征信息。在这四个尺度上，共获得 12 个先验框。

多尺度检测能够在不同尺度的特征图上进行目标检测，从而能够有效地检测不同尺度的目标。由于目标在图像中的大小和比例各不相同，使用多尺度检测可以提高对小目标和大目标的检测能力。YOLOv5 中，原作者采用了特征金字塔网络（FPN）和金字塔网络（PAN）结构来实现特征融合。本研究引入了跳跃连接，跳跃连接是指在网络中将低层级的特征图与高层级的特征图进行连接，以保留低层级的细节信息。融合后的多尺度特征可以用于检测不同尺度的目标。这样可以使得底层的细节信息直接传递到高层，从而提供更多的上下文信息。

（2）注意力目标检测（Attention-based Convolutional Neural Network）

在观察图像时，人们会快速注意到图像中的物体，并忽略掉一些背景信息，这种现象被称为“注意力机制”。注意力机制在图像处理中的应用可以提高模型对图像中不同区域的关注度，使模型能够更好地处理和利用与任务相关的信息。通过引入注意力机制，可以改善目标定位、分割、分类、生成和编辑等任务的性能和效果。

卷积注意力机制结合了卷积神经网络和注意力机制的思想。在卷积注意力模块中，卷积操作用于提取输入数据的特征表示，然后通过注意力机制对这些特征表示进行加权，以增强模型对不同特征的关注度。这种结合可以在图像处理和语音处理等任务中提高模型的性能。

CBAM（Convolutional Block Attention Module）属于卷积注意力机制（Convolutional Attention），它是一种用于图像处理任务的注意力模块，结合了卷积神经网络和注意力机制的思想，通过在卷积网络的不同层级引入通道注意力和空间注意力，增强模型对图像特征的关注能力^[33]。CBAM 可以帮助模型自适应地学习通道间的依赖关系和特征的重要性，可以提高目标检测的效果。




图 3.4 CBAM 模块结构图

如图 3.4 所示，展示了 CBAM 的结构图。CBAM 模块包含两个子模块，输入特征图经过通道注意力模块和空间注意力模块的加权调整，使输出的特征图网络能够更好地关注重要的特征。

通道注意力模块主要关注的是不同通道之间的特征相关性和重要性。它通过在卷积神经网络的不同层级引入通道注意力机制，利用最大值池化和平均值池化和全连接层来学习通道间的依赖关系。具体而言，通道注意力模块首先对输入特征图进行最大值池化和平均值池化操作，然后通过全连接层和激活函数进一步处理，生成通道注意力权重。这里的全连接层是多层感知机（Multilayer Perceptron, MLP）。最后，将通道注意力权重与输入特征图相乘，得到加权后的特征图，使得模型能够自适应地学习通道间的重要性，从而增强对不同特征的




图 3.5 通道注意力模块结构图

如图 3.5 所示，展示了通道注意力模块的结构图。输入特征图为： $F \in \mathbb{R}^{C \times H \times W}$ ，输出特征图为： $M_c \in \mathbb{R}^{C \times 1 \times 1}$ ， M_c 可以用公式（3.6）表示：

$$\begin{aligned} M_c(F) &= \sigma(\text{MPL}(\text{AvgPool}(F)) + \text{MPL}(\text{MaxPool}(F))) \\ &= \sigma(W_1(W_0(F_{\text{avg}}^c)) + W_1(W_0(F_{\text{max}}^c))) \end{aligned} \quad (3.6)$$

$$W_0 \in \mathbb{R}^{C/r \times C} \quad W_1 \in \mathbb{R}^{C \times C/r}$$

式中， σ 为 sigmoid 激活函数， F_{avg}^c 为平均值池化， F_{max}^c 为最大值池化， W_0 和 W_1 代表两个卷积操作。

空间注意力模块主要关注的是特征图中不同空间位置的重要性。它通过在卷积神经网络的不同层级引入空间注意力机制，利用通道注意力模块生成的加权特征图来学习空间位置的权重。具体而言，空间注意力模块首先对通道注意力加权后的特征图进行最大池化和平均池化操作，得到每个空间位置的最大值和平均值^[28]。然后，通过全连接卷积层和激活函数对最大值和平均值进行处理，生成空间注意力权重。最后，将空间注意力权重与加权特征图相乘，得到最终的特征图，使得模型能够自适应地学习空间位置的重要性，从而增强对不同空间位置的




图 3.6 空间注意力模块结构图

如图 3.6 所示，展示了空间注意力模块的结构图。输入为通道注意力模块的输出，输出 $M_s(F') \in \mathbb{R}^{H \times W}$ ，计算公式如（3.7）所示。

$$\begin{aligned} M_s(F') &= \sigma(f^{7 \times 7}([\text{AvgPool}(F'); \text{MaxPool}(F')])) \\ &= \sigma(f^{7 \times 7}(F_{\text{avg}}^S; F_{\text{max}}^S)) \end{aligned} \quad (3.7)$$

式中， σ 为 sigmoid 激活函数， $F_{\text{avg}}^S \in \mathbb{R}^{1 \times H \times W}$ ， $F_{\text{max}}^S \in \mathbb{R}^{1 \times H \times W}$ ， $f^{7 \times 7}$ 为卷积核大小为 7×7 的卷积操作。

$$F' = M_c(F) \otimes F \quad (3.8)$$

式中， F' 为通道注意力模块。

$$F'' = M_s(F') \otimes F' \quad (3.9)$$

式中， F'' 为 CBAM 模块整体的计算结果。

CBAM 模块引入了通道注意力和空间注意力机制，以突出目标检测器所关注的区域特征。这种注意力机制能够关注不同通道间的重要性和不同空间位置的重要性，从而提升模型在图像处理任务中的性能。通过将 CBAM 模块集成到 YOLOv5s 模型中，计算开销几乎可以忽略不计，可以有效地提升目标检测的检测性能。

3.2 点云配准的分类和介绍

点云配准是指将多个点云数据集对齐或匹配，使它们在同一个坐标系下表示同一场景或对象。配准的目标是找到一个变换（旋转、平移、缩放等），将点云数据集变换到最佳匹配的位置。点云配准包括成对配准和多点云配准^[29]两种方法，成对点云配准是其中一种常见的配准方式，它通过匹配两个点云数据集中的对应点来实现配准。成对点云配准又可以分为粗略配准和精细配准，粗略配准的结果被用作精细配准的初始值，从而实现更准确的位姿变换参数估计^{[30][32]}。多点云配准在成对配准的基础上，辅以全局优化策略如图优化，用于点云的融合任务。最近几年，基于深度学习的点云配准方法也受到了很高的关注。点云配准和深度学习配准是不同的配准策略，可以根据具体的应用场景和需求选择合适的方法或将它们结合

起来使用,以获得更好的点云配准结果。

3.2.1 粗略配准

粗略配准是指在点云配准过程中的初步对齐步骤。它通常用于将两个点云数据集的整体位置和方向进行大致的匹配,以提供一个初始的近似解。粗略配准的目标是降低后续精细配准的搜索空间,提高配准的效率和准确性。粗略配准以任意初始位姿为起始条件,分为基于特征的方法和不基于特征的方法^[34]。

基于特征的方法使用图像或点云中的特征点或特征描述子来进行匹配和配准。用于粗略配准的特征包括但不限于点特征^{[35][36][37]}、线特征^[38]、表面块特征^[39]和模型特征。

点特征分为关键点和点特征描述子^[40],该类方法通过关键点特征检测器得到关键点集合,然后利用关键点的描述子进行匹配,计算转换参数。在 3D 关键点中,SIFT^[41](尺度不变特征变换)是通过检测和描述关键点来进行匹配和配准;SURF(加速稳健特征)类似于 SIFT,更加快速和鲁棒;ORB(Oriented FAST and Rotated BRIEF)结合了 FAST 角点检测和 BRIEF 描述子进行匹配和配准。这些方法通过提取和匹配特征点或特征描述子来计算图像或点云之间的相对位姿,从而实现粗略配准。

不基于特征的方法 RANSAC(RANdom SAMple Consensus)算法从源点云和目标点云中随机选取三个对应点对,通过多次迭代更新内点,计算变换参数^[42]。基于 RANSAC 的粗略配准方法的主要思想是随机采样数据中的子集作为内点,然后根据这个子集来估计模型参数。通过计算其他数据点与该模型的拟合误差,将与模型拟合程度较好的数据点标记为内点,而偏离模型较远的数据点标记为离群点。重复这个过程多次,最终选择具有最多内点的模型作为最优模型。不基于特征的方法不依赖于显著的特征点,而是通过优化几何约束或统计模型来进行粗略配准。

3.2.2 精细配准

精细配准是在粗略配准的基础上进行的更精确的对齐步骤。它通过优化算法来进一步细化点云的相对位置和姿态,使得两个点云数据集达到更好的匹配。精细配准方法通常使用迭代最近点(Iterative Closest Point, ICP)算法或其变种,通过最小化点云之间的距离或误差来求解最佳的变换参数。精细配准需要更多的计算资源和时间,但可以获得更精确的配准结果。

3.2.3 深度学习配准

深度学习配准是近年来发展起来的一种新型配准方法，它利用深度学习模型来学习点云的特征表示和配准变换。深度学习配准方法可以直接从原始的点云数据中学习特征表示，并通过神经网络模型实现点云的匹配和变换。这种方法的优势在于它可以自动学习局部特征、全局特征和非线性变换，对于复杂的点云配准问题具有较好的适应性。深度学习配准方法包括 PointNet、PointNet++、DeepICP 等。

3.3 基于多传感器融合的位姿估计算法的设计

多传感器信息融合的基本原则就是采用多个类型的传感器对数据进行检测，使其在给定的融合规则中互相补充，从而获得相似的数据。本研究通过目标物的位姿估计来实现机械臂末端的精确定位，并将机械臂末端工具运行到目标物正前方的位置。首先，通过深度相机获取目标物的 RGB 图像和深度信息。然后，使用改进的 YOLOv5 算法以及多传感器融合的位姿估计方法。通过这些步骤，能够从图像和点云中提取出目标物的特征点，并得到目标物的位姿估计结果。接着，将目标物位姿估计的结果转换到机械臂末端的位姿估计，从而对机械臂进行运动控制。在机械臂控制系统中，将目标物位姿估计的结果作为目标位置来引导机械臂的运动，从而使机械臂末端能够准确地移动到目标物的正前方位置。

3.3.1 多传感器融合的分类

基于图像和点云融合的目标检测算法可以按照数据融合方法的不同分为三类：数据级融合、特征级融合、决策级融合和模型级融合方法。

在数据级融合中，图像和点云的原始数据直接进行融合，例如可以将二维图像与三维点云进行叠加，形成一个包含图像和点云信息的混合数据。这种融合方式可以在输入层级进行，以提供更丰富的输入信息给目标检测算法。在特征级融合中，图像和点云的特征被提取和融合，然后输入到目标检测算法中进行目标检测。这种方法通常将图像和点云的特征进行对齐和匹配，然后将它们融合成一个统一的特征表示。融合后的特征可以包括颜色、纹理、形状和点云的几何特征等。常见的特征级融合方法包括特征融合网络、多模态特征提取等。决策级融合是将图像和点云的检测结果进行融合，以得到最终的目标检测结果。这种方法将图像和点云的检测结果进行关联和匹配，然后采用一定的决策规则将它们融合。常见的决策级融合方法包括加权融合、投票融合、贝叶斯决策等。在模型级融合中，图像和点云分别使

用各自的目标检测模型进行检测，然后将它们的检测结果进行融合。这种方法可以使用不同的目标检测模型，如基于图像的目标检测模型（如 Faster R-CNN、YOLO）和基于点云的目标检测模型（如 F-PointNet、PV-RCNN）。融合可以在模型输出层级别或者在后处理阶段进行。

3.3.2 基于 MSAM 投票算法的位姿估计

基于特征点的方法在位姿估计方面具有一些优势，例如无需数据集和复杂训练，对硬件要求较低。然而，这些方法需要进行精细的设计和复杂的计算，并且在处理大量特征点时需要进行筛选，这对实时性有一定的影响。此外，它们在适应光照、旋转和尺度变化方面的能力有限。近年来，深度学习方法在 6D 位姿估计方面取得了显著进展，其中包括 YOLO6D、SSD6D 和 PoseCNN 等方法。这些方法具有出色的性能，但对环境要求较高，对遮挡和背景变化较为敏感。向量投票网络为位姿估计提供了一种新的视角，通过对物体像素进行投票来实现。这种方法展现出强大的性能，基于投票网络的 PVNet 网络在应对遮挡、截断和弱纹理场景方面具有良好的适应性，有效地解决了位姿估计问题。然而，该网络的损失函数只考虑了方向损失，忽略了像素到关键点距离的影响，因此在精度上有所下降。此外，在背景杂乱的情况下，可能会出现误投票的情况。

为了解决关键点投票网络存在的缺点，本章提出了一种新的投票网络，称为基于均方误差和注意力机制的投票网络(A voting network that mean square error and attention mechanism, MSAM)。传统的关键点投票网络通常包含两个预测内容：首先，预测像素的语义标签，以实现目标物体与背景的分割；其次，预测目标物体像素指向关键点的单位向量，通过对所有预测得到的单位向量进行投票，生成关键点假设，并计算关键点假设的置信度得分，得分最高的假设即为预测到的关键点。尽管这种方法在构建投票网络时通常能够取得良好的效果，但是仅考虑了向量方向。当像素与关键点的距离较远时，即使角度偏差较小，也会导致较大的距离偏差。因此，在考虑向量损失的基础上，MSAM 引入了距离的均方误差和注意力机制。通过引入距离损失，MSAM 能够实现更准确的预测效果。引入注意力机制，可以帮助网络更加关注重要的特征或区域，从而减少对不重要或噪声特征的关注。通过对输入数据进行加权，注意力机制可以提高网络对关键信息的感知能力，改善了投票网络误投票的情况。

MSAM 的输出有两个部分，对象的语义类别和像素单位向量。网络的损失函数也将从这两个方面分别考虑。本研究使用 softmax 交叉熵损失进行训练，记为 L_{seg} ，设像素 p 为目标物体的像素，损失可以表示为公式（3.10）。

$$L_{\text{seg}} = - \sum_{p \in M} \log(s(p)) \quad (3.10)$$

式中, M 代表目标物体掩码, $s(p)$ 表示像素 p 为指定目标的概率。

关键点投票网络的主要任务是预测向量场, MSAM 网络为每个关键点都预测一个向量场。对于每个像素点, 它会为 K 个关键点进行投票, 因此每个像素最终的输出维度为 $K*2$ 。乘以 2 是因为每个向量被分为 x 和 y 两个方向进行输出。预测向量场的损失可以从两个方面考虑。首先是方向损失 (角度损失), 即真实向量的方向与预测向量的方向之间的差异。

$$v_k(p) = \frac{k-p}{\|k-p\|_2} \quad (3.11)$$

式中, $v_k(p)$ 为指向关键点的方向向量, p 为一个像素点。

向量场的收敛使用 smooth L1 损失, 因为向量分为 x 、 y 两个方向, 所以需要分别从两个方向进行计算:

$$L_{pv} = \sum_{k=1}^K \sum_{p \in O} \ell_1(\Delta v_k(p)|_x) + \ell_1(\Delta v_k(p)|_y) \quad (3.12)$$

$$\Delta v_k(p) = \tilde{v}_k(p) - v_k(p) \quad (3.13)$$

式中, $\tilde{v}_k(p)$ 为预测的单位向量, $v_k(p)$ 为真实的单位向量, $\Delta v_k(p)|_x$ 和 $\Delta v_k(p)|_y$ 分别为 $\Delta v_k(p)$ 在 x 、 y 方向的分量。

在某种程度上, 投票网络可以通过最小化方向损失来正确预测像素的方向, 并进行投票^[48]。然而, 最小化方向损失存在一个问题, 即不同像素到关键点的距离不同。在相同的角度下, 距离关键点越远的像素会产生更大的偏差, 甚至产生误投票的情况。




图 3.7 距离损失示意图

如图 3.7 所示, 展示了距离关键点更远的点具有更大的距离偏差。基于最小化方向损失方法的基础上, 本研究引入了均方差距离损失提高预测精度, 同时引入注意力机制防止误投票的情况发生。如图所示, 图中展示了两个假设像素点 P_1 及 P_2 和一个真实关键点 k 。 P_1 到 k 为真实方向, P_1 延伸出的另一方向为预测方向, 两方向的夹角为 α , 距离偏差为 d_1 , P_2 同理; 根据图中所示, 在夹角相同的情况下, 距离关键点越远, 偏差越大。

$$d_1 > d_2 \quad (3.14)$$

式中, d_1 为 P_1 的距离偏差, d_2 为 P_2 的距离偏差。

方向损失虽能够较好地使模型收敛, 但是像素到关键点的距离对收敛结果的影响不可忽

略,因此,本研究在最小化方向损失的同时,使用均方距离损失,去掉差异化较大的距离,提高估计精度。

使用 MSAM 模块预测像素向量场,通过投票机制从向量场中得到预测的关键点。与直接回归关键点坐标相比,预测像素级向量方向可以使网络更加专注于物体的局部信息,并减少背景干扰对关键点的影响。在该方法中,选择两个目标像素,并将它们的方向向量交点 $h_{k,i}$ 作为一个关键点的假设。根据假设中指向该交点的像素数量,可以衡量假设的得分情况。所有的假设为, $\{h_{k,i} | i = 1,2,\dots,N\}$,若指向 $h_{k,i}$ 的像素数量衡量是否为真正关键点,通过 $w_{k,i}$ 来衡量假设 $h_{k,i}$ 的得分情况,计算公式为

$$w_{k,i} = \sum_{p \in O} \Pi\left(\frac{h_{k,i}-p}{\|h_{k,i}-p\|_2} v_k(p) \geq \theta\right) \quad (3.15)$$

式中, p 为物体像素,其预测像素向量方向为 $v_k(p)$, Π 为指示函数, θ 为每个像素的投票阈值(经验设定), O 表示预测的目标物体,通过注意力机制,将属于物体的像素对关键点进行投票,背景和距离超过一定阈值的像素将不参与投票。通过公式(3.15),可以得到每个关键点假设的得分情况,从而得到关键点假设的空间概率分布。最终,选择得分最高的假设作为最终的预测关键点。

准确的关键点预测对于位姿估计非常重要。在完成关键点预测后,可以进行 PnP 位姿解算,从而得到目标的 6D 位姿信息。

3.4 基于深度学习神经网络 YOLOv5 的图像识别实验

3.4.1 实验平台搭建

数据集采集使用的电脑系统为 Ubuntu18.04 系统,相机为 Orbbec Gemini 2,是一款搭载了奥比中光全新深度引擎芯片 MX6600 的双目结构光 3D 相机。

3.4.2 数据集准备

为了训练一个具有良好泛化能力的目标检测模型,在数据集的收集过程中,本研究在目标物不同的拍摄环境下,使用深度相机采集不同位姿的目标物照片,共计 10032 张图像,然后使用 LabelImg 工具对图像数据集进行了标注。




图 3.8 LabelImg 标注图

如图 3.8 所示，展示了运用 LabelImg 工具进行标注的截图。

3.4.3 网络训练与测试效果

本研究将数据集分为了训练集、验证集和测试集，以便有效地训练和评估模型。大部分数据集用于训练，小部分用于验证模型的性能，并有另外一小部分用于对模型结果进行测试。首先，对图像进行了预处理，包括调整为模型所需的大小，并进行归一化等处理。然后，运用数据增强技术，如随机裁剪、旋转、翻转等，以增加数据集的多样性，提高模型的鲁棒性和泛化能力。最后，将标注好的图片作为输入数据，经过一系列网络训练步骤，逐渐调整模型的权重和参数，最终训练出一个 pt 文件模型。

本研究使用 Pytorch 深度学习框架，在工作站上训练模型。工作站使用的是 GeForce RTX 3080，Windows 系统。训练模型使用 Adam 优化算法，训练 batch 大小为 16，训练批次为 200 个 epoch，初始学习率设置为 0.001，每经过 20 个 epoch，学习率会减半。当训练模型性能符合要求之后进行模型部署，将基于 pyTorch 框架训练出的 pt 模型转换为 onnx 中间模型，然后，再转换成适用于 Atlas 200 DK 的 om 模型。模型部署在深度学习平台 Atlas 200 DK 开发者套件中。

如图 3.9 所示，展示了识别的效果，通过图像识别，可以准确给出包围框和类别，以及置信度。



图 3.9 识别效果图

3.4.4 实验评价指标和实验分析

在目标检测算法中，精确率指标衡量了模型在所有预测为正类别的样本中，有多少是真正的正样本；召回率指标衡量了模型在所有真正的正类别样本中，有多少被成功预测为正类别；而均值平均精度（mAP）指标则是对所有类别的精确率进行平均值计算。对于分类模型的分析通常需要使用混淆矩阵，混淆矩阵可以直观地显示出每个类别的样本是否被混淆以及混淆程度。而上述指标都是基于混淆矩阵计算得到的。在目标检测算法中，对于每个类别都会有一个混淆矩阵，因此需要对每个类别分别计算精确率、召回率和 mAP 指标。

混淆矩阵是用来对分类模型的性能进行评估的重要工具。

表 3.1 混淆矩阵表

真实值\预测值	Positive	Negative
Positive	TP (True Positive)	FN (False Negative)
Negative	FP (False Positive)	TN (True Negative)

如表 3.1 所示，展示了混淆矩阵，从表中可以看出，TP (True Positive) 表示真正例（模型正确预测为正样本的数量），FN (False Negative) 表示假反例（模型错误预测为负样本的数量），FP (False Positive) 表示假正例（模型错误预测为正样本的数量），TN (True Negative) 表示真反例（模型正确预测为负样本的数量）。这些元素可以帮助我们对模型的性能进行更

细致的分析，比如通过计算精确率（Precision）和召回率（Recall），可以更好地衡量模型对正例和负例的分类能力。

（1）精准率（Precision）：又称为查准率，表示正确预测为正例占预测正例的比值，公式为：

$$P = \frac{TP}{TP+FP} \quad (3.16)$$

式中，P 为精准率，TP（True Positive）表示真正例，FP（False Positive）表示假正例。

（2）召回率（Recall）：即查全率，是指在所有正例中，模型能够正确预测出的正例的比例，公式为：

$$R = \frac{TP}{TP+FN} \quad (3.17)$$

式中，R 为召回率，TP（True Positive）表示真正例，FN（False Negative）表示假反例。

（3）均值平均精度（mAP）：为了解决精确率和召回率相互制约的限制，引入了 mAP（Mean Average Precision）指标。mAP 表示整个类别的平均精度再求均值，在目标检测任务中，常取 IoU（Intersection over Union）为 0.5。mAP_0.5 表示 IoU 取 0.5 的情况下的平均精度，而 mAP_0.5:0.95 表示 IoU 取 0.5 到 0.95 之间，间隔为 0.05 的情况下各个类别的均值平均精度。这个指标能够更全面地评估模型在目标检测任务中的性能。

$$mAP = \frac{1}{N} \sum_{i=1}^N AP_i \quad (3.18)$$

式中，mAP 为均值平均精度， AP_i 为 PR 曲线下面积，其实是在 0~1 之间所有召回率值的准确率的平均值。




图 3.10 PR_curve 和混淆矩阵图

如图 3.10 所示，a 图为 PR_curve 图，显示了在不同置信度阈值下的精确率（Precision）和召回率（Recall）之间的关系，可以看出在 IoU（Intersection over Union）阈值为 0.5 时的平均精度（mean Average Precision）为 0.995；b 图为混淆矩阵图，可以看出改进的 YOLOv5 目标检测算法训练了 33 个类别，没有发生识别混淆的情况。




图 3.11 训练结果图

如图 3.11 所示，本研究训练了 200 个轮次，准确率和召回率均无限接近于 1，训练效果符合预期。

3.5 本章小结

本章介绍了基于 YOLOv5 的视觉检测的设计，介绍了卷积神经网络以及 YOLOv5 目标检测算法，还搭建了实验平台，在 Atlas 200 DK 开发者套件上进行了模型部署，并对电厂屏柜柜面进行识别，识别效果良好。

本章节在 YOLOv5 目标检测的基础上进行了改进，为了捕获不同尺度的物体，从而提高模型在检测各种大小目标方面的性能，增加了多尺度特征目标检测模块；注意力机制在图像处理中的应用可以提高模型对图像中不同区域的关注度，使模型能够更好地处理和利用与任务相关的信息。本研究引入了注意力模块来改善注意力不集中的性能。

基于特征点的方法在位姿估计中具有优势，无需数据集和复杂训练，硬件要求较低。然而，需要精细的设计、复杂的计算，以及在大量特征点时需要进行筛选，影响了实时性。此外，该方法对光照、旋转和尺度变化的适应性有限。基于投票网络的 PVNet 网络可以对遮挡、截断和弱纹理场景具有良好的适应性，有效地解决了位姿估计问题，但其损失函数仅考虑方向损失，忽略了像素到关键点距离的影响，导致精度有所下降；而且在背景杂乱的情况下，可能会出现误投票的情况。针对上述投票网络的缺点，本研究提出了一种基于均方误差和注意力机制的投票网络(A voting network that mean square error and attention mechanism, MSAM)。

第四章 机械臂操作平台的开发和实验验证

4.1 机械臂操作平台的搭建

本研究采用 UR5 机械手臂进行开发，硬件包括机械臂本体以及示教器，该机械臂的负载为 5kg，满足实验要求。UR5 柔性机器人非常适合优化轻量级协作流程，例如拣选、放置和操作等。UR5 易于编程且能实现快速设置，在机器尺寸和功率间达到了理想平衡，是自动化轻型加工任务的理想选择。UR 机器人可模拟人类手臂的活动范围，可以使用示教器选择以末端坐标系或者是基坐标系为基准，改变机械臂的位姿；还可以进行拖动示教，只需将机器人移动到目标位置就可以设置路点。机械臂根据旋转向量和平移矢量进行旋转或者平移动作，到达指定位置。



图 4.1 “眼在手上”图

如图 4.1 所示，本研究采用“眼在手上”的方式，将相机固定在机械臂末端法兰上，同时也将工具固定在机械臂末端。相机与机械臂的连接件的精度和刚性可以满足实验要求，顺利的将相机，工具安装在机械臂末端。

运动学模型中的三维基础坐标系通常是指用于描述物体运动和姿态的参考坐标系。在三维空间中，通常使用笛卡尔坐标系作为基础坐标系。笛卡尔坐标系是以三个相互垂直的轴为基础的坐标系，通常表示为 XYZ 坐标系。其中，X 轴表示水平方向，Y 轴表示垂直方向，Z 轴表示深度方向。这种坐标系的原点通常被定义为物体的固定点或参考点。在运动学模型中，三维基础坐标系用于提供一个标准的参考框架，以便描述物体的运动和姿态，并进行相关的计算和分析。




图 4.2 刚体位姿在坐标系中的表达

如图 4.2 所示，O 代表物体本体坐标系的原点，而 X、Y、Z 则代表物体本体坐标系的三个坐标轴，P 代表目标物体的位置。通过确定目标物体在三维基础坐标系中的位置和姿态，能够实现对目标物体的精确操作。在运动学模型中，通常会使用一些数学方法来描述和计算物体的位姿，比如旋转矩阵、欧拉角、四元数等。这些方法能够帮助机器人系统精确地感知和理解目标物体的空间位置和姿态，从而实现准确的运动控制和操作任务。通过准确描述和计算目标物体的位姿，可以为机械臂的视觉操作任务提供重要的参考和支持，实现更加稳定和准确地操作。

通常情况下，机械臂的姿态变换会将旋转矩阵和平移向量组合在一起，称为齐次转换矩阵，可以同时描述平移和旋转变换。这样可以准确地描述和计算目标物体的位姿。

$$T_2^1 = \begin{bmatrix} R_2^1 & P_2^1 \\ 0 & 1 \end{bmatrix} \tag{4.1}$$

式中， R_2^1 表示 3×3 的旋转矩阵， P_2^1 表示 3×1 的平移矢量；




图 4.3 空间纯平移和纯旋转变换

如图 4.3(a)所示，纯平移变换是指物体在空间中只发生平移，而没有发生旋转的变换。在

位姿变换中, 纯平移变换可以通过齐次转换矩阵来表示。在齐次转换矩阵中, 纯平移变换对应的旋转矩阵部分是一个单位矩阵 (3*3 的矩阵, 主对角线上的元素为 1, 其余元素为 0), 表示没有发生旋转。平移向量部分则描述了物体在三维空间中的平移量。平移变换如公式(4.2)所示:

$$T_2^1 = \begin{bmatrix} 1 & 0 & 0 & d_x \\ 0 & 1 & 0 & d_y \\ 0 & 0 & 1 & d_z \\ 0 & 0 & 0 & 1 \end{bmatrix} \quad (4.2)$$

式中, T_2^1 为平移变换公式结果, d_x 为 x 方向的平移分量, d_y 为 y 方向的平移分量, d_z 为 z 方向的平移分量。

如图 4.3(b)所示, 位姿变换中的纯旋转变换是指物体在空间中只发生旋转, 而没有发生平移的变换。在位姿变换中, 纯旋转变换也可以通过齐次转换矩阵来表示。在齐次转换矩阵中, 纯旋转变换对应的平移向量部分是一个零向量, 表示没有发生平移。旋转矩阵部分描述了物体在三维空间中的旋转。 $A-X'Y'Z'$ 经过纯旋转变换得到新的坐标系 $B-X''Y''Z''$ 。B 在初始坐标系 A 中的表示可以通过公式(4.3)、公式 (4.4) 和公式 (4.5) 表示。

$$X'' = a_1X' + a_2Y' + a_3Z' \quad (4.3)$$

式中, a_1, a_2, a_3 分别表示参考系 B 中 X'' 在参考系 A 的投影。

$$Y'' = b_1X' + b_2Y' + b_3Z' \quad (4.4)$$

式中, b_1, b_2, b_3 分别表示参考系 B 中 Y'' 在参考系 A 的投影。

$$Z'' = c_1X' + c_2Y' + c_3Z' \quad (4.5)$$

式中, c_1, c_2, c_3 分别表示参考系 B 中 Z'' 在参考系 A 的投影。

对上面公式进行整理, 得到公式 (4.6) :

$$\begin{bmatrix} X'' & Y'' & Z'' \end{bmatrix} = \begin{bmatrix} X' & Y' & Z' \end{bmatrix} \begin{bmatrix} a_1 & a_2 & a_3 \\ b_1 & b_2 & b_3 \\ c_1 & c_2 & c_3 \end{bmatrix} \quad (4.6)$$

式中, $\begin{bmatrix} a_1 & a_2 & a_3 \\ b_1 & b_2 & b_3 \\ c_1 & c_2 & c_3 \end{bmatrix}$ 为旋转矩阵。

因此两个坐标系的齐次变换矩阵 T_2^1 为:

$$T_2^1 = \begin{bmatrix} a_1 & a_2 & a_3 & 0 \\ b_1 & b_2 & b_3 & 0 \\ c_1 & c_2 & c_3 & 0 \\ 0 & 0 & 0 & 1 \end{bmatrix} \quad (4.7)$$

式中, T_2^1 又称为纯旋转矩阵结果。

将纯平移矢量和纯旋转矩阵结合起来, 便是目标物的位姿的齐次变换矩阵。

4.2 机械臂正逆解分析

UR5 机械臂是一种常见的六轴机器臂，由一系列的关节连接而成，每个关节都有一个电机驱动，用于控制关节的运动。关节之间通过连杆连接，形成一个连续的运动链。其运动学分析涉及确定机械臂的末端执行器的位姿和机械臂关节变量之间的转换关系。UR5 机械臂的运动学可以通过 DH（Denavit-Hartenberg）参数化方法进行建模。DH 参数化方法是一种常用的机器人运动学描述方法，通过定义关节之间的连接和变换关系来描述机械臂的运动学。本章介绍了 UR5 机械臂正解和逆解的求解问题。



图 4.4 UR5 机械臂

图 4.4 展示了 UR5 机械臂的外观图。

4.2.1 机械臂正解分析

给定关节变量值（关节角度），通过正解可以计算出机械臂末端执行器的位置和姿态。这可以通过 DH 参数、转换矩阵的乘积以及旋转矩阵的组合等方法来实现。

表 4.1 UR5 机械臂的连杆参数

连杆 i	连杆扭角 $\alpha_i / (^\circ)$	连杆长度 $a_i / (\text{mm})$	连杆转角 $\theta_i / (^\circ)$	连杆距离 $d_i / (\text{mm})$	关节变量取值范围 $/ (^\circ)$
1	90	0	θ_1	89.2	± 360
2	0	-425	θ_2	0	
3	0	-392	θ_3	0	
4	90	0	θ_4	109.3	
5	-90	0	θ_5	94.75	
6	0	0	θ_6	82.5	

表 4.1 展示了 UR5 机械臂的连杆参数。

齐次变换矩阵如公式（4.8）所示：

$${}^{n-1}_nT = Rot(Z, \theta_n)Tran(0,0, d_n)Trans(a_n, 0,0)Rot(x, \alpha_n) \tag{4.8}$$

式中， $Rot(z, \theta_n)$ 表示绕 z 轴旋转 θ_n 角度， $Tran(0,0, d_n)$ 表示沿着 z 轴平移 d_n 个单位长度，

$Trans(a_n, 0, 0)$ 表示沿着 x 轴平移 a_n 个单位长度, $Rot(x, \alpha_n)$ 表示绕 x 轴旋转 α_n 角度。

$${}^{n-1}_nT = \begin{bmatrix} \cos\theta_n & -\sin\theta_n\cos\alpha_n & \sin\theta_n\sin\alpha_n & \alpha_n\cos\theta_n \\ \sin\theta_n & \cos\theta_n\cos\alpha_n & -\cos\theta_n\sin\alpha_n & \alpha_n\sin\theta_n \\ 0 & \sin\alpha_n & \cos\alpha_n & d_n \\ 0 & 0 & 0 & 1 \end{bmatrix} \quad (4.9)$$

公式 (4.9) 展示了两个相邻的坐标系之间的齐次变换矩阵。

下面进行推导齐次变换矩阵公式, 得到坐标系 i 到坐标系 i-1 的齐次变换矩阵 ${}^{i-1}_iT$ 。

$$\begin{aligned} {}^{i-1}_iT &= \begin{bmatrix} \cos\theta_i & -\sin\theta_i & 0 & 0 \\ \sin\theta_i & \cos\theta_i & 0 & 0 \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & d_i \\ 0 & 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} 1 & 0 & 0 & 0 \\ 0 & \cos\alpha_i & -\sin\alpha_i & 0 \\ 0 & \sin\alpha_i & \cos\alpha_i & 0 \\ 0 & 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} 1 & 0 & 0 & \alpha_i \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 1 \end{bmatrix} \\ &= \begin{bmatrix} \cos\theta_i & -\sin\theta_i\cos\alpha_i & \sin\theta_i\sin\alpha_i & \alpha_i\cos\theta_i \\ \sin\theta_i & \cos\theta_i\cos\alpha_i & -\cos\theta_i\sin\alpha_i & \alpha_i\sin\theta_i \\ 0 & \sin\alpha_i & \cos\alpha_i & d_i \\ 0 & 0 & 0 & 1 \end{bmatrix} \end{aligned} \quad (4.10)$$

将 DH 参数代入公式 (4.10), 0_1T 表示坐标系 0 和坐标系 1 之间的转换关系。

$${}^0_1T = \begin{bmatrix} \cos\theta_1 & 0 & \sin\theta_1 & 0 \\ \sin\theta_1 & 0 & -\cos\theta_1 & 0 \\ 0 & 1 & 0 & d_1 \\ 0 & 0 & 0 & 1 \end{bmatrix}, {}^1_2T = \begin{bmatrix} \cos\theta_2 & -\sin\theta_2 & 0 & \alpha_2\cos\theta_2 \\ \sin\theta_2 & \cos\theta_2 & 0 & \alpha_2\sin\theta_2 \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 1 \end{bmatrix} \quad (4.11)$$

$${}^2_3T = \begin{bmatrix} \cos\theta_3 & -\sin\theta_3 & 0 & \alpha_3\cos\theta_3 \\ \sin\theta_3 & \cos\theta_3 & 0 & \alpha_3\sin\theta_3 \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 1 \end{bmatrix}, {}^3_4T = \begin{bmatrix} \cos\theta_4 & 0 & \sin\theta_4 & 0 \\ \sin\theta_4 & 0 & -\cos\theta_4 & 0 \\ 0 & 1 & 0 & d_4 \\ 0 & 0 & 0 & 1 \end{bmatrix} \quad (4.12)$$

$${}^4_5T = \begin{bmatrix} \cos\theta_5 & 0 & -\sin\theta_5 & 0 \\ \sin\theta_5 & 0 & \cos\theta_5 & 0 \\ 0 & -1 & 0 & d_5 \\ 0 & 0 & 0 & 1 \end{bmatrix}, {}^5_6T = \begin{bmatrix} \cos\theta_6 & 0 & -\sin\theta_6 & 0 \\ \sin\theta_6 & 0 & \cos\theta_6 & 0 \\ 0 & 1 & 0 & d_6 \\ 0 & 0 & 0 & 1 \end{bmatrix} \quad (4.13)$$

式中, 0_1T 、 1_2T 、 2_3T 、 3_4T 、 4_5T 、 5_6T 为坐标系之间的变换矩阵。

可以将上述连杆变换矩阵按顺序相乘, 从而得到 UR5 机械臂的“手臂变换矩阵”, 即机械臂末端在机械臂基坐标系下的转换矩阵, 如公式 (4.14):

$${}^0_6T(\theta) = {}^0_1T(\theta_1){}^1_2T(\theta_2){}^2_3T(\theta_3){}^3_4T(\theta_4){}^4_5T(\theta_5){}^5_6T(\theta_6) \quad (4.14)$$

式中, ${}^0_6T(\theta)$ 是关于六个关节角度 $\theta_1, \theta_2, \theta_3, \theta_4, \theta_5, \theta_6$ 的函数。机械臂求正解就是已知六个关节角的角度 θ_i , 经过相关计算, 得到机械臂末端的位姿矩阵。

$${}^0_6T = {}^0_1T{}^1_6T = {}^0_1T{}^1_4T{}^4_6T = \begin{bmatrix} n_x & o_x & a_x & p_x \\ n_y & o_y & a_y & p_y \\ n_z & o_z & a_z & p_z \\ 0 & 0 & 0 & 1 \end{bmatrix} \quad (4.15)$$

公式 (4.15) 中:

$$n_x = -s_6 c_1 s_{234} + s_1 s_5 c_6 + c_1 c_5 c_6 c_{234} \quad (4.16)$$

$$o_x = -s_1 s_5 s_6 - c_1 c_{234} c_5 c_6 - c_1 c_6 c_{234} \quad (4.17)$$

$$a_x = s_1 c_5 - s_1 c_1 c_{234} \quad (4.18)$$

$$p_x = d_4 s_1 + d_5 c_1 c_{234} - d_6 s_5 c_1 c_{234} + a_2 c_1 c_2 + d_6 c_5 s_1 + a_3 c_1 c_{23} \quad (4.19)$$

$$n_y = s_1 c_{234} c_5 c_6 - s_5 c_1 c_6 - s_1 s_{234} s_6 \quad (4.20)$$

$$o_y = -s_1 s_6 c_{234} c_5 + s_5 s_6 c_1 - s_1 s_{234} c_6 \quad (4.21)$$

$$a_y = -s_1 s_5 c_{234} - c_1 c_5 \quad (4.22)$$

$$p_y = -d_4 c_1 + d_5 s_1 s_{234} - d_6 s_1 s_5 c_{234} - d_6 c_1 c_5 + a_2 s_1 c_2 + a_3 s_1 c_{23} \quad (4.23)$$

$$n_z = c_{234} c_5 c_6 + s_6 s_{234} \quad (4.24)$$

$$o_z = c_{234} c_6 - s_{234} s_6 c_5 \quad (4.25)$$

$$a_z = -s_{234} s_5 \quad (4.26)$$

$$p_z = -d_5 c_{234} + a_2 s_2 - d_6 s_{234} s_5 + a_3 s_{23} + d_6 \quad (4.27)$$

上述公式中： s_i 表示 $\sin\theta_i$ ， c_i 表示 $\cos\theta_i$ ， s_{23} 表示 $\sin(\theta_2 + \theta_3)$ ， c_{23} 表示 $\cos(\theta_2 + \theta_3)$ ， s_{234} 表示 $\sin(\theta_2 + \theta_3 + \theta_4)$ ， c_{234} 表示 $\cos(\theta_2 + \theta_3 + \theta_4)$ ，在 4.2.2 节也是使用相同的表达形式，以公式（4.28）举例。

$${}^aT = {}^aT_b {}^bT_0 {}^0T = {}^aT_b {}^bT_0 \begin{bmatrix} n_x & o_x & a_x & p_x \\ n_y & o_y & a_y & p_y \\ n_z & o_z & a_z & p_z \\ 0 & 0 & 0 & 1 \end{bmatrix} \quad (4.28)$$

式中，矩阵 0T 左乘矩阵 aT_b 和 bT_0 ，便可以得到坐标系 O_a 下的变换矩阵 aT 。

4.2.2 机械臂逆解分析

机械臂的逆解求解过程是给定机械臂末端的期望位姿矩阵，计算出对应的关节角度值。逆解通常使用数值方法或者解析方法来求解，如迭代方法或优化算法，以求解非线性方程组来实现。数值方法是通过迭代计算来逼近逆解的方法，其中最常用的方法是迭代逆运动学（Iterative Inverse Kinematics）。它的基本思想是通过不断迭代调整关节角度的初始猜测值，使得末端执行器的位置和姿态逐渐接近目标值。这种方法适用于大多数情况，但可能需要较多的计算时间和迭代次数，而且不一定能够找到所有的解。解析方法是通过数学推导和求解方程组来得到逆解的方法。对于一些特殊的机械臂结构和姿态要求，可能存在封闭解（Closed-Form Solution）。封闭解是指可以用解析表达式表示的精确逆解。然而，对于一般的六轴机械臂，获得封闭解并不容易，因为其复杂的几何结构和运动学方程。封闭解仅适用于特定的位置和姿态，且不一定存在。对于 UR5 机械臂来说，其肩关节、肘关节以及腕关节相互平行，满足了机械人机构学中的 Pieper 准则^[24]，因此具有封闭解^[25]的运动学逆解。可以

根据运动学正解的结果, 采用解析法^[26]中的分离变量法^[27]来求解运动学逆解。所以本章采用封闭解的求逆解方法。

首先, 由前一节可以得到机械臂变换矩阵 0T_6 。然后, 将机械臂变换矩阵 0T_6 左乘矩阵 ${}^1T^{-1}$, 右乘矩阵 ${}^5T^{-1}$ 。公式如 (4.29) 所示:

$${}^1T^{-1}{}^0T_6{}^5T^{-1} = \begin{bmatrix} c_1 & s_1 & 0 & 0 \\ 0 & 0 & 1 & -d_1 \\ s_1 & c_1 & 0 & 0 \\ 0 & 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} n_x & o_x & a_x & p_x \\ n_y & o_y & a_y & p_y \\ n_z & o_z & a_z & p_z \\ 0 & 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} c_6 & s_6 & 0 & 0 \\ -s_6 & c_6 & 0 & 0 \\ 0 & 0 & 1 & d_6 \\ 0 & 0 & 0 & 1 \end{bmatrix} \quad (4.29)$$

式中, 第 3 行第 4 列的元素相等, 整理公式可以得到:

$$s_1(p_x - d_6 a_x) - c_1(p_y - d_6 a_y) = d_4 \quad (4.30)$$

然后经过三角函数运算, 可得:

$$\theta_1 = \tan^{-1} \left(\frac{p_y - d_6 a_y}{p_x - d_6 a_x} \right) + \cos^{-1} \left(\frac{d_4}{r} \right) \quad (4.31)$$

式中, r 为:

$$r = \sqrt{(p_x - d_6 a_x)^2 + (p_y - d_6 a_y)^2} \quad (4.32)$$

将 0T_6 左乘 ${}^1T^{-1}$, 如公式 (4.33) 所示:

$${}^1T^{-1}{}^0T_6 = \begin{bmatrix} c_1 & s_1 & 0 & 0 \\ 0 & 0 & 1 & -d_1 \\ s_1 & -c_1 & 0 & 0 \\ 0 & 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} n_x & o_x & a_x & p_x \\ n_y & o_y & a_y & p_y \\ n_z & o_z & a_z & p_z \\ 0 & 0 & 0 & 1 \end{bmatrix} \quad (4.33)$$

式中, 第 3 行第 4 列的元素相等, 整理可得公式 (4.34):

$$s_1 p_x - c_1 p_y = d_6 c_5 + d_4 \quad (4.34)$$

化简可得:

$$\theta_5 = \pm \cos^{-1} \left(\frac{s_1 p_x - c_1 p_y - d_4}{d_6} \right) \quad (4.35)$$

公式 (4.33) 中第 3 行第 1 列与第 3 行第 2 列相等, 整理可得:

$$s_1 n_x - c_1 p_y = -s_6 s_5 \quad (4.36)$$

$$-s_1 o_x + c_1 o_y = c_6 s_5 \quad (4.37)$$

公式 (4.36) 和公式 (4.37) 进行联立, 整理可得:

$$\theta_6 = \pm \cos^{-1} \left(\frac{-s_1 o_x + c_1 o_y}{s_1 n_x - c_1 p_y} \right) \quad (4.38)$$

公式 (4.29) 第 1 行第 3 列和第 2 行第 3 列相等, 整理可得:

$$-(c_1 a_x + s_1 a_y) = s_5 s_{234} \quad (4.39)$$

$$a_z = -s_5 s_{234} \quad (4.40)$$

公式 (4.39) 和公式 (4.40) 进行联立, 可以得到:

$$\theta_{234} = \cos^{-1} \left(\frac{a_z}{(c_1 a_x + s_1 a_y)} \right) \quad (4.41)$$

公式 (4.33) 中的第 1 行第 4 列和第 2 行第 4 列相等, 整理可得:

$$-d_6(c_1 a_x + s_1 a_y) + c_1 p_x + s_1 p_y = a_2 c_2 + a_3 c_{23} + d_5 s_{234} \quad (4.42)$$

$$-d_6 a_z + p_z - d_1 = a_2 s_2 + a_3 s_{23} - d_5 s_{234} \quad (4.43)$$

公式 (4.42) 和公式 (4.43) 进行联立, 可以消除变量 $\theta_{23} (\theta_{23} = \theta_2 + \theta_3)$, 整理可得:

$$(m_1 - a_2 c_2)^2 + (m_2 - a_2 s_2)^2 = a_3^2 \quad (4.44)$$

公式 (4.44) 中, m_1 和 m_2 的表达式为:

$$m_1 = -d_6(c_1 a_x + s_1 a_y) + c_1 p_x + s_1 p_y - d_5 s_{234} \quad (4.45)$$

$$m_2 = -d_6 a_z + p_z + d_5 s_{234} - d_1 \quad (4.46)$$

整理之后可以得到:

$$\theta_2 = \cos^{-1} \left\{ \frac{m_1^2 + m_2^2 + a_2^2 - a_3^2}{\sqrt{(2 \times a_2 \times m_1)^2 + (2 \times a_2 \times m_2)^2}} \right\} + \tan^{-1} \left(\frac{m_2}{m_1} \right) \quad (4.47)$$

联立公式 (4.42) 和公式 (4.43), 可以得到:

$$\theta_{23} = \tan^{-1} \left\{ \frac{-d_6 a_z + p_z - d_1 - d_5 c_{234} + a_3 s_2}{-d_6(c_1 a_x + s_1 a_y) + c_1 p_y + s_1 p_x - d_5 s_{234} + a_3 s_2} \right\} \quad (4.48)$$

联立公式 (4.41) 和公式 (4.48), 可以得到:

$$\theta_4 = \theta_{234} - \theta_{23} \quad (4.49)$$

联立公式 (4.47) 和公式 (4.48), 可以得到:

$$\theta_3 = \theta_{23} - \theta_2 \quad (4.50)$$

经过以上计算, 便可以得到 UR5 机械臂的 6 个关节角度。

4.3 视觉引导对位算法的设计

随着工业自动化程度的不断提高, 机械臂在各个领域中得到了广泛的应用。然而, 机械臂在进行操作时往往需要精确地定位目标物体, 尤其是在复杂环境中, 传统的定位方法往往无法满足精确定位的要求。因此, 如何利用先进的技术实现机械臂的精确定位成为了当前研究的热点之一。本研究提出了一种基于 TCP 通信的机械臂视觉引导对位算法, 旨在解决机械臂在复杂环境中精确定位的问题。该算法利用机械臂上搭载的深度相机 Gemini2 获取目标物的图像, 并计算出目标物的位置信息, 并通过 TCP 通信将信息传输至控制端, 控制端根据接收到的数据实现机械臂的精确对位。实验结果表明, 该算法具有较高的定位精度和稳定性,

在实际应用中具有广阔的应用前景。视觉引导技术作为一种重要的定位手段，通过搭载视觉传感器，机械臂能够获取目标物体的位置信息，从而实现精确对位。具体的算法实现和技术细节如下：

（1）YOLOv5 图像识别出目标物

使用 ROS 对双目相机进行驱动，以获取图像数据，通过 YOLOv5 图像识别算法得到目标物的像素坐标信息、以及类别和置信度。

（2）相机坐标系下的位姿估计

利用本研究中提出的基于 MSAM 算法的 PnP 位姿求解算法，通过相机内参以及相机的深度信息和像素信息，可以计算出目标物的位姿信息。

（3）将相机坐标系下的位姿矩阵转移到机械臂基坐标系下

将这些位姿信息转换到机械臂基坐标系下，就可以得到视觉引导的位姿矩阵。

（4）计算出机械臂末端坐标系下工具末端的转换矩阵

在实验中，机械臂会携带工具，如灵巧手或夹爪等。因此，需要通过机械臂 TCP（工具中心点）工具标定方法获取机械臂末端坐标系下工具末端的转换矩阵。

（5）计算出机械臂基坐标系下工具末端的转换矩阵

将步骤三计算出的矩阵右乘步骤四计算出的矩阵的逆，便得到机械臂基坐标系下工具末端的转换矩阵。机械臂根据计算出的矩阵进行相应的转换，便可以运行机械臂达到相应的目标点位。

在上述的引导算法的基础上，本研究提出了一种新的二次引导算法。该方法较一次引导算法的精度提升了 60%。一次引导将相机引导至目标物正前方，再次进行识别，识别到目标物之后进行二次引导，二次引导减小了机械臂自身运动过程中产生的误差，也减小了由于机器人车身的晃动产生的误差。

4.4 机械臂运动控制算法的设计

机械臂接口提供了两种运动方式，一种是 moveL 运动，该方法适用于机械臂末端的直线运动；另一种是 moveJ 运动，该方法的输入端为机械臂六个轴的关节角度，机械臂根据此角度进行运动。

本研究的工作场景为电厂中屏柜上的目标物，工作任务分为几个大类，第一类为对按钮、旋钮和压板的操作，第二类为开门和关门的操作。

（1）对按钮、旋钮和压板的操作

机械臂根据视觉引导计算出的点位运行至目标物正前方，然后对目标物进行相应的操作即可。比如，按按钮需要在机械臂基坐标系下，向按钮方向进行 moveL 运动，灵巧手具有触觉反馈系统，一旦达到阈值，反馈给机械臂停止运动，便完成了按按钮的操作；

（2）开门和关门的操作

本研究提出了一种开门和关门的方法，即圆弧轨迹规划算法。

首先，通过图像识别和视觉引导计算出门把手或者是门边附近的一个特征点（螺栓），机械臂运行至目标点位；以门把手为例，机械手臂末端的工具抓住门把手，根据门宽、车身和电厂屏柜柜面的偏移角度计算出工具应该行走的路径，该路径为一个圆弧。机械臂末端上的工具根据计算出的圆弧轨迹进行运动，便可将门打开；关门便是将开门的轨迹反方向运动。




图 4.5 机械臂操作图（a 为按钮操作图，b 为旋钮操作图，c 为压板操作图，d 为开门操作图）

如图 4.5 所示，机械臂工具末端经过视觉引导算法到达目标物的指定位置，然后进行相应的目标物操作图片。

4.5 机械臂操作实验及误差分析

本节的实验旨在通过机械臂进行操作，针对电厂屏柜平面场景中的多个目标物进行识别、位姿估计和相应操作。实验步骤如下：首先，利用 Orbbec Gemini2 双目深度相机获取场景中的 RGB 图像信息，并运用目标识别技术确定目标物体。接着，对目标物体的位姿进行估计，获取其位姿信息。通过相机标定和手眼标定的坐标转换，将目标物体的位姿信息转换到机械

臂末端的坐标系下。最后，利用上位机软件通过 TCP 发送 json 格式的数据作为视觉引导程序的入口指令。

```
{
  "x": 0.17026999592781067,
  "y": -0.093489997088909149,
  "z": 0.49529001116752625,
  "roll": -1.2090599536895752,
  "pitch": 1.209089994430542,
  "yaw": -1.2090100049972534,
  "operateList": [{
    "sensorName": "重合闸压板",
    "sensorType": "122",
    "algType": "Platen",
    "sensorId": "327"
  }]
}
```

上述为一个 json 格式的数据，包括：机械臂初始位姿信息、需要操作的目标物信息。

经过目标识别和视觉引导算法之后，计算出目标物在机械臂基坐标系下的位姿信息：

[327]={0.472097,-0.374162,0.677485,-1.20906,1.20909,-1.20901}

上述 327 为 id 号，后面的 6 个数据分别为 x、y、z、Rx、Ry 和 Rz，即为位姿数据。机械臂通过位姿数据到达目标物的指定位置。

为了评估整个系统在机械臂操作任务中的准确性和成功率，进行了 27 组实验。这些实验主要测试了机械臂末端执行器是否能够精确到达目标点并成功执行既定任务。通过实验，调用机械臂接口，将机械臂上的工具末端运行至目标物正前方，并对压板进行操作，在所有的 27 次操作实验中，均操作完成，这意味着操作成功率为 100%。实验的数据通过 log 保存起来，以便后续分析。这些结果验证了本研究中目标识别与位姿估计算法的准确性和可行性。

表 4.2 压板目标物视觉引导实验结果

实验组数	X	Y	Z
1	0.472097	-0.374162	0.677485
2	0.471076	-0.365941	0.679631
3	0.471265	-0.355906	0.678305
4	0.471265	-0.355906	0.678305
5	0.472293	-0.349608	0.678564
6	0.473293	-0.349221	0.678743
7	0.471300	-0.348303	0.678408
8	0.472356	-0.339430	0.677016
9	0.472347	-0.339442	0.677860
10	0.472356	-0.339430	0.677016
11	0.473383	-0.333091	0.677274
12	0.474379	-0.333522	0.677438
13	0.473383	-0.333091	0.677274
14	0.472387	-0.332660	0.677109
15	0.472390	-0.331814	0.677120
16	0.471382	-0.332240	0.677786
17	0.472378	-0.332671	0.677952
18	0.472382	-0.331825	0.677964
19	0.472379	-0.334352	0.677086
20	0.472375	-0.335199	0.677074
21	0.473383	-0.333091	0.677274
22	0.472387	-0.332660	0.677109
23	0.474379	-0.333522	0.677438
24	0.474375	-0.334372	0.677427
25	0.473383	-0.333091	0.677274
26	0.474379	-0.333522	0.677438
27	0.473383	-0.333091	0.677274

如表 4.2 所示,展示了目标物压板的位置信息,经过分析, X 方向最小为 0.471076m, 最大为 0.474379m, 最大误差为 0.003303m; Y 方向最小为-0.374162m, 最大为-0.331814m, 最大误差为 0.042348m; Z 方向最小为 0.677016m, 最大为 0.679631m, 最大误差为 0.002615m。XYZ 所有方向最大误差为 Y 方向的 42.348mm。X 反向和 Z 方向的最大误差分别是 3.303mm 和 2.615mm, 满足要求。

Y 反向误差偏大误差分析: 首先, 考虑所有可能导致误差偏大的来源: 1、车身本体移动; 2、目标框大小不一, 导致中心点像素有偏差。

(1) 分析车身是否有移动

数据分析发现, 相机坐标系下目标物的像素和实际三维坐标均有所偏移, 相机坐标系下 X 反向像素值由 944 减小为 895, 正好对应机械臂基坐标系下 Y 反方向的误差; 相机坐标系下 X 反方向的实际三维坐标由 260.537mm 减小为 219.607mm, 实际减小了 40.93mm, 和 Y

方向的误差正好抵消掉,所有 Y 轴实际上的最大误差为: 1.418mm。

(2) 分析目标框中心像素点偏差

仔细对比中心点像素值,误差为 1 个像素,可以忽略不计。

经过分析,最主要的误差来源是因为车身本体移动,导致机械臂基坐标系移动产生的偏差。解决方法:为机器人车身本体安装制动功能,在机械臂操作的过程中,保证机器人车身本体没有移动。

4.6 位姿估计与其他方法作比较

本研究的方法分别与传统的基于模板的位姿估计方法、基于对应点的典型位姿估计方法 PVnet、基于 RGBD 图像的典型位姿估计方法 Densefusion 和 PoseCNN 方法分别进行位姿估计的比较。

基于对应点的方法主要是解决纹理丰富物体的位姿估计问题。该方法的核心步骤包括以下几个方面:首先将 3D 模型投影到 N 个角度,生成 N 个 RGB 模板图像,并记录 2D 像素点与 3D 模型点之间的对应关系。然后从单个真实 RGB 图像中提取特征点,使用 SURF、ORB、SIFT 等特征点提取算法,获取真实图像和模板图像之间的 2D 关键点对应关系。通过模板建立 2D-3D 关键点对应关系,最后使用 PnP 算法计算物体位姿。本实验比较了有代表性的 PVnet。

传统方法使用 RGBD 图像进行位姿估计,其中需要手动提取特征,并进行相应的分组和假设验证。这些方法通过从 RGB 图像中提取梯度特征以及从深度图像中提取表面法向量等特征来估计物体的姿态。本实验比较了有代表性的 Densefusion 和 PoseCNN。

为了评估基于 MSAM 的姿势估计算法的性能,基于 Linemod 数据集,设计了几组实验。使用 ADD(-S)评价指标进行评估。

$$ADD - S = \frac{1}{m} \sum_{x_1 \in M} \min_{x_2 \in \tilde{M}} ||(Rx_1 + t) - (\tilde{R}x_2 + \tilde{t})|| \quad (4.51)$$

式中, $\tilde{R}$ 和 $\tilde{t}$ 为实际的旋转和平移, R 和 t 为预测的旋转和平移。 $ADD - S$ 表示算法检测到的物体与实际物体之间的距离误差的平均值。

表 4.3 基于 Linemod 数据集的 ADD(-S) 指标

类别\方法	PoseCNN ^[43]	PVNet ^[44]	Densefusion ^[45]	PVN3D ^[46]	Ours(per)	Ours(iter)
ape	77.0	43.6	92.3	97.3	95.4	97.6
benchvise	97.5	99.9	93.2	99.7	97.6	99.8
camera	93.5	86.9	94.4	99.6	98.6	99.7
can	96.5	95.5	93.1	99.5	97.6	99.5
cat	82.1	79.3	96.5	99.8	98.5	99.7
driller	95.0	96.4	87.0	99.3	96.6	99.4
dulk	77.7	52.6	92.3	98.2	97.1	98.6
eggbox	97.1	99.2	99.8	99.8	99.8	99.7
glue	99.4	95.7	100.0	100.0	99.9	100.0
holepuncher	52.8	82.0	92.1	99.9	98.4	99.8
iron	98.3	98.9	97.0	99.7	98.7	99.7
lamp	97.5	99.3	95.3	99.8	97.5	99.7
phone	87.7	92.4	92.8	99.5	98.2	99.6
average	88.6	86.3	94.3	99.4	97.99	99.44

表 4.3 中，ADD(-S)指标在 Linemod 数据集中可以表示为检测算法的平均目标检测误差，表中的数值为平均 ADD(-S)得分，得分越高，平均目标检测误差越小。基于 Linemod 数据集，利用本研究提出的方法进行了相应实验，并且和基准方法进行了对比，可以看出，本研究提出的方法提高了大部分目标物的平均目标检测误差的得分，并且提高了整体目标物误差的稳定性。

4.7 定量分析和消融实验

为了定量评估本研究中提出的 MSAM 算法和改进的 YOLOv5 算法对引导机械臂到达指定位置的有效性，本节设计了消融实验。基准方法是 YOLOv5 算法，加传统的基于模板的位姿估计方法。然后逐步将本研究提出的 MSAM 算法和改进的 YOLOv5 算法加入到基准方法中。评价指标是机械臂末端在目标物 xyz 方向的平均偏移误差。

表 4.4 目标物 XYZ 平均误差实验结果

方法\目标物	压板	按钮	旋钮	螺栓孔
基准方法	2.8mm	2.9mm	3.6mm	3.3mm
加入 MSAM 算法	2.0mm	2.5mm	2.4mm	1.8mm
加入改进的 YOLOv5 算法	2.4mm	2.1mm	2.6mm	2.2mm
加入 MSAM 算法和改进 YOLOv5 算法	1.6mm	2.0mm	2.3mm	1.8mm

如表 4.4 所示，对以上四种情况分别进行了实验，记录了四种目标物的 XYZ 三个方向的平均误差。第一种和第二种方法进行比较发现：其他条件不变的情况下，加入 MSAM 算法的准确性要比没有加入 MSAM 算法的准确性平均提高了 0.975mm。第一种方法和第三种方法进

行比较发现：其他条件不变的情况下，加入改进的 YOLOv5 算法的准确性要比没有加入改进 YOLOv5 算法的准确性平均提高了 0.825mm。第一、二、三种方法分别和第四种方法进行了比较发现：其他条件不变的情况下，加入 MSAM 算和改进的 YOLOv5 算法的准确性要其他三种方法都要高。所以可以看出，本研究提出的 MSAM 算法和改进的 YOLOv5 算法可以提高机械臂视觉引导的准确性。

4.8 本章小结

本章搭建了机械臂操作平台，并介绍了机械臂正运动学和逆运动学的分析，然后介绍了视觉引导对应算法的详细设计。在前三章内容理论的基础上，本章节做了大量实验研究，对实验结果进行了误差分析和对比实验，误差满足既定要求。最后，对本研究改进的 YOLOv5 算法和基于 MSAM 模块的位姿估计进行了定量分析和消融实验，进一步验证了本研究中的方法的准确性。

第五章 总结与展望

5.1 总结

本研究描述了一种基于多模态数据融合的机械手臂感知系统的研究，分为四个章节进行描述。其中前三章描述了本研究所使用的理论和实现，第四章是对理论内容的应用，搭建了机械臂引导系统，进行了相应实验。

前三章首先介绍了相机标定、手眼标定的相关原理以及实验；然后描述了 YOLOv5 算法的相关理论以及改进实现方法。为了捕获不同尺度的物体，增加了多尺度特征目标检测模块，提高了模型在检测不同尺寸目标物的性能；注意力机制在图像处理中的应用也提高了模型对图像中不同区域的关注度，增加了特征提取和识别能力，使模型能够在复杂场景中检测出被遮挡的物体；为了获得更全面的环境感知能力，使用了多传感器采集的多模态数据。基于投票网络的 PVNet 网络对这些问题有所改善，但其损失函数仅考虑方向损失，忽略了像素到关键点距离的影响，导致精度有所下降；而且在背景杂乱的情况下，可能会出现误投票的情况。针对上述投票网络的缺点，在第三章中提出了一种基于均方误差和注意力机制的投票网络 (MSAM) 的位姿估计方法。

第四章中，在 UR 机械臂和 Orbbec Gemini2 相机的硬件条件下，对基于改进 YOLOv5 的图像识别、基于 MSAM 模块的位姿估计进行实验。为了评估基于 MSAM 的 PnP 位姿估计算法的性能，设计了对比实验，本研究的方法与 Occlusion Linemod 数据集上的基准方法进行比较，提高了大部分目标物的平均目标检测误差的得分；此外，设计了机械臂引导对位消融实验，引入基于 MSAM 的 PnP 位姿估计算法和改进的 YOLOv5 算法之后，视觉引导对位精度误差平均减小了 38.86%。结合机器人实验平台对目标检测算法优化及目标物定位误差分析，提升了目标检测精度的同时验证机械臂操作系统的稳定性，为机器人系统研究及应用提供一定的参考意义和实用价值。

5.2 展望

目前本研究中搭建了一套机械臂视觉引导系统，在机器人不制动的情况下，使用导航算法到达电厂屏柜柜面前进行目标物操作的精度还有待提升，提升方向有：（1）提升导航算法的精度；（2）提升机器人本身的制动性能。

本研究基于 YOLOv5 算法进行改进,并取得了一定的效果,后续可以使用最新的 YOLOv8 进行改进,应用到机械臂视觉引导系统。也可以使用二次引导算法或目标跟踪算法提升视觉引导的对位精度。

参考文献

- [1] 徐方. 我国机器人产业现状分析与发展研判[J]. 机器人研究与应用, 2015, DOI: 10.16418/j.issn.1000-3045.2015.06.011.
- [2] 刘华秋, 黄磊, 陈逸维. 协作机器人国内外发展现状与技术研究[J]. 现代制造技术与装备. 2023, 4:93-96.
- [3] Zhang Y, Tian G, Shao X. Safe and efficient robot manipulation: Task-oriented environment modeling and object pose estimation[J]. IEEE Transactions on Instrumentation and Measurement, 2021, 70: 1-12.
- [4] Collet A, Martinez M, Srinivasa S S. The MOPED framework: Object recognition and pose estimation for manipulation[J]. The international journal of robotics research, 2011, 30(10): 1284-1306.
- [5] Zhu D, Min Z, Zhou T, et al. An autonomous eye-in-hand robotic system for elevator button operation based on deep recognition network[J]. IEEE Transactions on Instrumentation and Measurement, 2020, 70: 1-13.
- [6] ZENG Yun, DING Ai-ping, HE Xin. Obstacle Avoidance Path Planning Method of Manipulator Based on Multi-Sensor Information Fusion. 2023(10): 1001-3997
- [7] Zuo Min, Zeng Guangping, Tu Xuyan. Research on navigation of subs tation patrol robot based on guideline visual recognition[C]. Wuhan: International Conference on Mechanic Automation and Control Engineering, 2010: 6123-6126.
- [8] 康健. 基于多传感器信息融合关键技术的研究[D]. 黑龙江省: 哈尔滨工程大学, 2013.
- [9] 王强, 沈涛, 郭超. 多传感器信息融合技术在机器人系统中的应用研究[J]. 科技风, 2019, 53(24): 8.
- [10] 章毓晋. 图像工程: 图像理解(第4版)[M]. 北京: 清华大学出版社, 2018: 305-326.
- [11] 王安鼎. 基于深度学习的无人机森林火灾图像检测算法研究[D]. 四川: 中国民用航空飞行学院, 2024.
- [12] 曹文武. 基于RGB-D视觉识别的机器人操作规划研究[D]. 哈尔滨: 哈尔滨工业大学, 2018.
- [13] Wang X, Han T X, Yan S. An HOG-LBP human detector with partial occlusion handling[C] // 2009 IEEE 12th international conference on computer vision. 2009: 32-39.
- [14] Liu L, Ouyang W, Wang X, et al. Deep learning for generic object detection: A survey[J]. International journal of computer vision, 2020, 128(2): 261-318.
- [15] Zou Z, Shi Z, Guo Y, et al. Object detection in 20 years: A survey[J]. arXiv preprint arXiv: 1905.05055, 2019.
- [16] 张臣, 胡佩佩, 朱新旺, 杨长祺. 基于高密度点云的激光焊接缺陷智能在线检测(特邀). 中国激光[J]. 2014(4). DOI: 10.3788/CJL231293
- [17] Girshick R. Fast r-cnn[C] // Proceedings of the IEEE international conference on computer vision. 2015: 1440-1448.
- [18] Ren S, He K, Girshick R, et al. Faster r-cnn: Towards real-time object detection with region proposal networks[J]. Advances in neural information processing systems, 2015, 28.
- [19] Dai J, Li Y, He K, et al. R-FCN: Object Detection via Region-based Fully Convolutional Networks[C] // Advances in Neural Information Processing Systems. 2016.
- [20] Redmon J, Divvala S, Girshick R, et al. You only look once: Unified, real-time object detection[C] // Proceedings of the IEEE conference on computer vision and pattern recognition. 2016: 779-788.
- [21] Tremblay J, To T, Sundaralingam B, et al. Deep object pose estimation for semantic robotic grasping of household objects[J]. arXiv preprint arXiv:1809.10790, 2018.
- [22] Xu S, Wang X, Lv W, et al. PP-YOLOv5E: An evolved version of YOLOv5[J]. arXiv preprint arXiv: 2203.16250, 2022.
- [23] WANG C Y, BOCHKOVSKIY A, LIAO H Y M. YOLOv7: trainable bag-of-freebies sets new state-of-the-art for real-time object detectors[J]. arXiv: 2207.02696, 2022.

- [24] 熊有伦. 机器人技术基础[M]. 武汉: 华中理工大学出版社, 1996.
- [25] 曲海波. 少自由度串联机器人构型综合与奇异分析[D]. 北京: 北京交通大学, 2008.
- [26] 王雪松, 许世范, 郝继飞. MOTOMAN机械手逆运动方程新的推导方法及求解[D]. 2001.
- [27] 张付祥, 史文军. 双臂液压钻车的逆运动学求解[J]. 机械设计与制造, 2015 (8): 147-149.
- [28] Wang Guoping, Hu Bo, Chen Zhongsheng, Hou Xinlin. Edge computing-based enhancement of mobileNetV-SSD for surface defect visual detection[J]. 船电技术, 2024, 44(3): 1003-4862.
- [29] Giovana A M, Daniel R d S. A framework for registration of multiple point clouds derived from a static terrestrial laser scanner system[J]. Applied Geomatics, 2020, 12(4): 409-425.
- [30] Xu Y, Richard B, Wei Y, Ludwig H, Uwe S. Pairwise coarse registration of point clouds in urban scenes using voxel-based 4-planes congruent sets[J]. ISPRS Journal of Photogrammetry and Remote Sensing, 2019, 151: 106-123.
- [31] Li P, Wang J, Zhao Y, Wang Y, Yao Y. Improved algorithm for point cloud registration based on fast point feature histograms[J]. Journal of Applied Remote Sensing, 2016, 10(4): 045024.
- [32] Lei H, Jiang G, Quan L. Fast Descriptors and Correspondence Propagation for Robust Global Point Cloud Registration[J]. IEEE transactions on image processing: a publication of the IEEE Signal Processing Society, 2017, 26(8): 3614-3623.
- [33] Chen L J, Yao H D, Fu J Y, et al. The classification and localization of crack using lightweight convolutional neural network with CBAM[J]. Eng Struct, 2023, 275, Part B: 115291.
- [34] Xu Z, Xu E, Zhang Z, Wu L. Multiscale Sparse Features Embedded 4-Points Congruent Sets for Global Registration of TLS Point Clouds[J]. IEEE Geoscience and Remote Sensing Letters, 2019, 16(2): 286-290.
- [35] Rosten E, Drummond T. Machine learning for high-speed corner detection[J]. In European conference on computer vision, Springer, 2006: 430-443.
- [36] Bay H, Tuytelaars T, Van Gool L. Surf: Speeded up robust features. In European conference on computer vision. Springer, 2006: 404-417.
- [37] Rublee E, Rabaud V, Konolige K, Bradski G. ORB: An efficient alternative to SIFT or SURF. In 2011 International Conference on Computer Vision. IEEE, 2011: 2564-2571.
- [38] Yang B, Zhang Y. Automated registration of dense terrestrial laser-scanning point clouds using curves[J]. ISPRS Journal of Photogrammetry and Remote Sensing, 2014, 95: 109-121.
- [39] Brenner C, Dold C. Automatic relative orientation of terrestrial laser scans using planar structures and angle constraints. In ISPRS Workshop on Laser Scanning, 2007: 84-89.
- [40] Mohamed L T, Tawfik G, Paul C, Laurent M, Laurent T. CICP: Cluster Iterative Closest Point for sparse-dense point cloud registration[J]. Robotics and Autonomous Systems, 2018, 108: 66-86.
- [41] Hansch R, Weber T, Hellwich O. Comparison of 3D interest point detectors and descriptors for point cloud fusion[J]. ISPRS Annals of Photogrammetry, Remote Sensing and Spatial Information Sciences, 2014, 2(3): 57.
- [42] Martin A, Robert C. Random Sample Consensus: A Paradigm for Model Fitting with Applications to Image Analysis and Automated Cartography[J]. Commun. ACM, 1981, 24(6): 381-395.
- [43] Y Xiang, T Schmidt, V Narayanan, and D Fox. Posecnn: A convolutional neural network for 6d object pose estimation in cluttered scenes. arXiv preprint arXiv: 1711. 00199, 2017. 1-10
- [44] S Peng, Y Liu, Q Huang, X Zhou, and H Bao. Pvnnet: Pixel-wise voting network for 6dof pose estimation. In Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2019: 4561-4570
- [45] C Wang, D Xu, Y Zhu, R Martín-Martín, C Lu, L Fei-Fei, and S Savarese. Densefusion: 6d object pose estimation by iterative dense fusion. In Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2019: 3343-3352
- [46] Yisheng He, Wei Sun, Haibin Huang, Jianran Liu, Haoqiang Fan, and Jian Sun. PVN3D: A Deep Point-wise3D Keypoints Voting Network for 6DoF Pose Estimation, 2020: 1-10
- [47] Li Y, Chen Y, Wang N, et al. Scale-aware Trident Networks for Object Detection[C]. Presented at the

IEEE/CVF International Conference on Computer Vision, 2019: 6054-6063.

[48] Zhang S, Wen L, Bian X, et al. Single-shot refinement neural network for object detection[C]. Proceedings of the IEEE conference on computer vision and pattern recognition, 2018: 4203-4212.