

中国科学技术大学

University of Science and Technology of China

硕士学位论文



论文题目 基于时序逻辑的动态不确定环境中

移动机器人运动规划研究

作者姓名 章可易

学科专业 控制科学与工程

导师姓名 阙震教授

完成时间 二〇二四年五月

中国科学技术大学

硕士学位论文



基于时序逻辑的动态不确定环境中 移动机器人运动规划研究

作者姓名： 章可易

学科专业： 控制科学与工程

导师姓名： 阚震教授

完成时间： 二〇二四年五月十日

University of Science and Technology of China
A dissertation for master's degree



Research on Motion Planning of Mobile Robots in Dynamic Uncertain Environments Based on Temporal Logic

Author: Zhang Keyi

Speciality: Control Science and Engineering

Supervisor: Prof. Kan Zhen

Finished time: May 10, 2024

摘 要

在当今科技不断进步的时代, 移动机器人的普及和应用已经成为科技领域的热点之一。随着自动驾驶汽车、无人机、智能导航系统等技术的不断发展, 人们对于移动机器人在日常生活中的角色和功能有了更深入的认识和期待。而在这一背景下, 运动规划作为移动机器人技术中的关键一环, 备受重视。

在现实世界中, 移动机器人往往需要在不确定和动态的环境中执行任务, 例如在城市交通中行驶、在工厂内部搬运货物、在野外环境中进行探索等。在这些情境下, 由于传感器的限制以及环境噪声等因素, 机器人通常无法获得完全的观测信息, 因此需要机器人有效地规划路径、做出决策, 并且在面对环境变化时做出即时调整, 以确保任务的顺利完成和安全性。

此外, 除了在面对环境不确定性时需要具备应变能力, 我们也期望移动机器人能够执行更为复杂的任务, 这些任务可能会涉及到各种时间和逻辑约束, 例如巡逻任务, 物流投递任务等。因此, 移动机器人在运动规划方面不仅需要考虑如何有效地规避障碍物、找到最佳路径, 还需要处理任务执行过程中的时间关系和逻辑顺序, 以确保任务的准确、高效完成。

因此, 研究运动规划具有重要的意义。通过深入探索运动规划算法、研究新的技术手段, 我们可以更好地应对移动机器人面临的挑战, 提高其在各种应用场景下的效率和性能。这不仅有助于推动移动机器人技术的发展, 也为社会带来更多便利和可能性, 例如提高交通安全、提升生产效率、拓展科学研究领域等。

针对上述问题和挑战, 本文以移动机器人为研究对象, 基于不等式线性时序逻辑 (inequality Linear Temporal Logic, iLTL) 和部分可观马尔可夫决策过程 (Partially Observable Markov Decision Process, POMDP) 对复杂任务和动态不确定环境进行建模, 并提出对应的求解方法, 以求解满足任务要求的最优策略。本文的主要研究内容和结果如下:

(1) 针对传统方法无法同时考虑时序信息和环境信息的问题, 本文提出了一种基于自动机和置信 MDP 的描述框架。考虑环境因素中的不确定性, 本文将环境建模为 POMDP。基于 POMDP 的状态分布, 根据 POMDP 的观测空间是否连续, 本文分别提出了基于贝叶斯估计和基于卡尔曼滤波两种置信 MDP 的构建方法, 从而将 POMDP 转化为置信 MDP。此外, 本文使用 iLTL 描述机器人需要完成的复杂任务, 提出了一种适合与置信 MDP 融合的新形式自动机。通过将自动机与置信 MDP 融合, 构建了同时包含运动信息与时序任务信息的乘积置信 MDP。

(2) 针对第一点中提出的乘积置信 MDP 框架, 本文基于强化学习方法提出了一种基于采样点的值迭代算法, 该算法根据乘积置信 MDP 的自动机部分设计

合适的回报结构和折扣因子。利用本文提出的算法，能够解得满足 iLTL 任务的策略，并且本文提出的算法在计算精度与计算开销之间取得了平衡。本文证明了在该回报设计下优化 iLTL 任务满足概率等价于优化强化学习算法当中的价值函数，并证明了该算法当中的价值函数能够保持封闭性。

(3) 搭建了软件仿真平台，设计了两种结构的部分可观马尔可夫决策过程并分别设计了移动机器人需要满足的复杂任务。通过构建乘积置信马尔可夫决策过程，并使用本文提出的基于采样点的值迭代算法进行求解，最终实现了仿真任务，验证了本文方法的有效性。

关键词：部分可观马尔可夫决策过程 强化学习 运动规划 时序逻辑 自动机

ABSTRACT

In the era of advancing technology, the proliferation and application of mobile robots have become one of the hot topics in the field of technology. With the continuous development of technologies such as autonomous driving vehicles, drones, and intelligent navigation systems, people have gained a deeper understanding and expectation of the roles and functions of mobile robots in daily life. Against this backdrop, motion planning, as a crucial component of mobile robot technology, is receiving significant attention.

In the real world, mobile robots often need to execute tasks in uncertain and dynamic environments, such as navigating through urban traffic, transporting goods within factories, or exploring outdoor environments. In these scenarios, due to limitations of sensors and environmental noise, robots usually cannot obtain complete observational information. Therefore, they need to effectively plan paths, make decisions, and make immediate adjustments in the face of environmental changes to ensure the smooth completion and safety of tasks.

Furthermore, apart from the adaptability required when facing environmental uncertainties, we also expect mobile robots to perform more complex tasks. These tasks may involve various time and logical constraints, such as patrol missions, logistics delivery tasks, and so on. Therefore, in motion planning, mobile robots not only need to consider how to effectively avoid obstacles and find the best paths but also need to handle temporal relationships and logical sequences during task execution to ensure accurate and efficient task completion.

Therefore, researching motion planning is of significant importance. By delving into motion planning algorithms and exploring new technological means, we can better address the challenges faced by mobile robots, improve their efficiency and performance in various application scenarios. This not only contributes to the advancement of mobile robot technology but also brings more convenience and possibilities to society, such as enhancing traffic safety, improving productivity, and expanding the scope of scientific research.

Given the aforementioned issues and challenges, this dissertation focuses on mobile robots, modeling complex tasks and dynamic uncertain environments based on Inequality Linear Temporal Logic (iLTL) and Partially Observable Markov Decision Process (POMDP), and proposes corresponding solution methods to find optimal strategies

that meet task requirements. The main research content and results of this dissertation are as follows:

1. Framework Proposal: Addressing the issue of traditional methods' inability to simultaneously consider temporal and environmental information, this dissertation proposes a framework based on automata and belief MDP. Considering uncertainty in environmental factors, this dissertation models the environment as a POMDP. Based on the state distribution of POMDP, two construction methods of belief MDP, based on Bayesian estimation and Kalman filtering respectively, are proposed. Furthermore, this article employs iLTL to describe the complex tasks that robots need to accomplish, proposing a novel form of automaton suitable for integration with belief MDPs. By integrating automata with belief MDP, a product belief MDP containing both motion and temporal task information is constructed.

2. Value Iteration Algorithm: Based on the product belief MDP framework proposed in the first point, this dissertation proposes a sampling-based value iteration algorithm using reinforcement learning methods. This algorithm designs appropriate reward structures and discount factors according to the automaton part of the product belief MDP. With this algorithm, strategies satisfying iLTL tasks can be derived, balancing computation precision and overhead. This dissertation proves that optimizing iLTL task satisfaction under this reward design is equivalent to optimizing the value function in reinforcement learning algorithms, and demonstrates the closure of the value function in this algorithm.

3. Software Simulation Platform: A software simulation platform is built, designing two structures of partially observable Markov decision processes and complex tasks that mobile robots need to satisfy. By constructing product belief Markov decision processes and using the proposed sampling-based value iteration algorithm for solving, the simulation tasks are ultimately achieved, validating the effectiveness of the proposed method.

Key Words: Partially Observable Markov Decision Process, Reinforcement Learning, Motion Planning, Temporal Logic, Automaton

目 录


第 1 章 简介.....	1
1.1 课题背景及研究意义.....	1
1.2 国内外研究现状.....	2
1.2.1 传统运动规划方法.....	2
1.2.2 基于时序逻辑的运动规划方法.....	5
1.2.3 部分可观马尔可夫决策过程中的规划方法	7
1.3 主要研究工作和结构安排	10
第 2 章 基础理论	12
2.1 马尔可夫决策过程.....	12
2.2 部分可观马尔可夫决策过程	12
2.3 线性时序逻辑.....	13
2.4 不等式线性时序逻辑.....	14
2.5 强化学习.....	15
2.6 本章小结.....	16
第 3 章 时序任务与部分可观马尔可夫决策过程的融合	17
3.1 嵌入式有限确定性广义布奇自动机	18
3.2 置信马尔可夫决策过程构造	20
3.2.1 基于贝叶斯估计的置信马尔可夫决策过程构造	20
3.2.2 基于卡尔曼滤波的置信马尔可夫决策过程构造	29
3.3 乘积置信马尔可夫决策过程	33
3.4 本章小结.....	36
第 4 章 乘积置信马尔可夫过程的求解方法	37
4.1 问题描述.....	37
4.2 回报结构设计.....	38
4.3 基于采样点的值迭代方法	44
4.4 本章小结.....	52
第 5 章 仿真实验	53
5.1 离散状态离散观测下的运动规划仿真验证	53
5.2 连续状态连续观测下的运动规划仿真验证	58
5.3 本章小结.....	60
第 6 章 总结与展望	62
6.1 结论.....	62
6.2 展望.....	62
参考文献.....	64

第1章 简介


1.1 课题背景及研究意义

移动机器人运动规划的研究旨在使机器人能够在复杂、未知的环境中实现自主导航，从而达到特定目标。这一领域对于多个应用领域具有重要意义。首先，通过有效的运动规划，机器人可以在生产线、仓储管理和服务领域等实现高效的自主操作，提高工作效率和服务质量。其次，在多机器人协作系统中，合理的运动规划是确保各个机器人协同工作、避免碰撞以及高效完成任务的关键。此外，考虑到环境中存在的不确定性，如传感器噪声和动态障碍物，运动规划算法需要具备适应性，以保证机器人能够在各种复杂情境下做出合理的决策。


在人机交互与安全性方面，运动规划研究能够使机器人更好地融入人类社会，避免与人发生碰撞，确保在共享空间中的安全性。图1.1a中为无人车与无人机进行物流运输的场景，能够代替快递员完成投递任务；图1.1b中为机械臂进行抓取任务，能够搬运重量远超人力的物体或者对物体进行精细化操作；图1.1c中展示了汽车的自动驾驶任务，能够为司机提供辅助；图1.1d中展示了火星车的探索任务，为人类的火星研究做出了很大贡献。整体而言，移动机器人运动规划的研究涉及计算机科学、人工智能和控制理论等多个学科领域，近年来受益于深度学习等新技术的引入，为解决复杂环境下的规划问题提供了更为全面和创新的方法。



(a) 物流运输



(b) 机械臂抓取



(c) 自动驾驶



(d) 火星探测

图 1.1 移动机器人应用场景

因此,研究动态不确定环境下移动机器人运动规划的意义在于提高机器人的导航能力、确保运动的安全性、提高实时性和响应性并解决不完全观测和感知问题。这些研究对于移动机器人技术的发展和实际应用具有重要的推动作用。随着机器人技术的不断发展和研究的深入,机器人运动规划算法的种类越来越丰富,能够用于处理各类问题,本章接下来将对这些方法和对应的优劣进行介绍,并提出本文的方法,以及针对的问题。

1.2 国内外研究现状

1.2.1 传统运动规划方法

传统机器人规划算法包括三大类:图搜索算法(例如A*)、基于采样的算法(如快速探索随机树法)以及基于反应的算法(如动态窗口法)。

图搜索算法是一类用于在图数据结构中搜索路径的算法,按照搜索优先级可以分为三个方向,分别为深度优先、广度优先和最佳优先。深度优先算法从起始节点开始,沿着一条路径尽可能深地探索,直到到达目标节点或不能再深入为止,然后回溯到最近的一个尚未完全探索的节点,继续搜索。广度优先搜索算法从起始节点开始,首先探索所有与起始节点直接相邻的节点,然后依次探索它们的邻居节点,直到找到目标节点为止。最佳优先搜索算法利用启发式函数在搜索树中为每个节点和边赋予一个值,在每次迭代中,算法将选择队列中具有最佳启发式值的节点进行扩展,并继续沿着这些节点所代表的路径向前搜索。图搜索算法包含许多种算法,最常见的是Dijkstra算法^[1]和A*算法^[2]。图1.2a中展示了道路网络被映射为由节点和边组成的图,图1.2b是图搜索算法的示意图。在对具体道路网络进行抽象后^[3],即可使用图搜索算法求解合适的路径。

Dijkstra算法是一种基于最佳优先搜索的算法,能够找到从指定起始节点到图中所有其他节点的最短路径,例如在道路网络中搜索最短路径。算法的基本思想是通过逐步扩展距离起始节点最短的节点来找到最短路径。Dijkstra算法维护两个集合:一个是已知最短路径的节点集合,另一个是未知最短路径的节点集合。在算法执行过程中,首先将起始节点加入已知最短路径的集合,并初始化起始节点到其它节点的距离估计。然后,重复以下步骤直到所有节点都被标记为已知最短路径的节点:(1)从未知最短路径的节点中选择一个距离起始节点最近的节点。(2)对于选定的节点,如果经过选定节点到达相邻节点的路径比当前已知最短路径更短的话,更新其相邻节点到起始节点的距离估计值。(3)将选定的节点标记为已知最短路径的节点。

A*算法的核心思想是综合考虑两个因素:路径成本和启发式评估函数。它在搜索过程中不断评估每个候选节点的成本,选择最有希望的节点进行扩展。这

个选择基于一个估计函数，称为启发式函数，它用来评估从当前节点到目标节点的预计最优成本。通过这种方式，A* 算法在搜索过程中向着目标节点前进，同时尽可能地避免搜索不必要的路径。具体来说，A* 算法维护了两个列表：开放列表和关闭列表。开放列表包含待评估的节点，关闭列表包含已评估过的节点。算法从起始节点开始，在每一步中选择开放列表中具有最小综合评估值的节点进行扩展，并更新其周围的邻居节点的评估值，直到找到目标节点或开放列表为空。A* 算法有许多变体，如动态 A* 和动态 D*[4]，Field D*[5]，Theta*[6]，Anytime Repairing A* (ARA*)，Anytime D*[7]，混合 A*[8]，AD*[9] 和状态格算法[10] 等。




图 1.2 图搜索算法示例

采样算法是一种常用的方法，用于在环境中生成候选路径或者采样点。采样算法通常是在地图或者环境中生成一组点，并利用这些点构建路径图或者进行路径搜索。常用于运动规划的采样算法主要包括快速探索随机树算法 (Rapidly-exploring Random Trees, RRT) 和概率路线图方法 (Probabilistic Roadmap, PRM)。RRT 算法通过随机搜索构建一棵树，通常以根节点为起始点，当到达目标点时完成整棵树的构建。这种方法能够快速而均匀地探索工作空间[11]，在寻找路径时，则采用从目标点向起始点反向搜索的方法。图1.3a给出了一个 RRT 算法示例。PRM 算法[12]通常用于静态场景。该算法具有两个阶段，即学习阶段和搜索阶段。在学习阶段，PRM 算法首先在可达空间中采样一个无碰撞的点，之后检测当前点和采样点的连线是否发生碰撞，且仅保留无碰撞的连线，通过反复进行以上步骤构建一个无碰撞的概率路线图。在搜索阶段，采用图搜索算法从概率路线图中搜索目标路径，如果能够搜索到从起点到终点的路径，则说明存在可行的运动规划方案。图1.3b给出了一个 PRM 算法示例。

不同于需要更长时间规划全局路径的图搜索算法，基于反应的算法旨在快速直观地做出反应或进行局部路径规划[13]。这里介绍了工程和制造领域广泛使用的三种基于反应的算法，它们分别是潜在场方法 (Potential Field Method, PFM)、速度障碍物方法 (Velocity Obstacle Method, VOM) 和动态窗口法 (Dynamic Window




图 1.3 采样算法示例

Approaches, DWA)。

潜在场方法^[14-15]是指利用向量表示行为，并使用向量求和将来自不同行为的向量组合起来产生新的行为^[13]。潜在场是一个可微的实值函数 U ，其值可以看作能量，其梯度可以看作力。如果人为定义潜在场函数 U ，则称为人工潜在场 (Artificial Potential Field, APF)。其梯度是一个指向最大增加 U 的局部方向的向量^[16]。因此，在潜在场或组合潜在场中的机器人将沿着潜在场的梯度移动，以最大化 U 。

PFM 的缺点包括：(1) 如果潜在场收敛到非全局最小值，则会出现局部最小值，从而陷入局部最优。(2) 当机器人以较高的速度在距离很近的障碍物之间导航时，会出现运动的振荡。(3) 无法通过狭窄的开口。这些缺点可以通过潜在场的变体（例如，广义潜在场方法 (Generalized Potential Fields Method, GPFM)^[17]、虚拟力场 (Virtual Force Field, VFF)^[18]、向量场直方图 (Vector Field Histogram, VFH)^[19] 和谐波潜在场 (Harmonic Potential Field, HPF)^[20] 等方法在实际工程和制造中得到部分解决。

速度障碍物方法^[21]依赖于机器人和障碍物的当前位置和速度来计算可达避让速度空间 (Reachable Avoidance Velocity space, RAV)，然后从 RAV 中选择适当的避让机动速度以避免静止和移动障碍物。为了计算 RAV：(1) 必须获得速度障碍物 VO。VO 是一个速度集或速度空间，从 VO 中选择速度将导致碰撞。(2) 通过将执行器约束映射到加速度约束获得一组可达速度 RV。(3) 通过计算 RV 和 VO 之间的差异来获得 RAV。

为了选择适当的避让速度，全局穷举搜索方法和启发式搜索方法在 RAV 中分别适用于离线和在线情况：(1) 可以通过在 RAV 上扩展树来获得搜索树。根据搜索树分支上的分配成本，可以从搜索树中选择适当的避让速度。成本与一些目标函数相关，例如：行驶距离，运动时间和能量等。搜索树在离线情况下扩

展, 因此可以获得具有最短时间或距离的近似最优轨迹^[21]。(2) 启发式搜索在搜索过程中耗费较少时间, 并且旨在选择能够实现特定目标的特定速度, 例如: 朝着目标的最高避让速度, 最大避让速度, 或确保所需轨迹结构的速度。然而, 在复杂场景, 如密集和动态情况中使用速度障碍物方法仍会存在与障碍物的碰撞。为此提出了一些优化的速度障碍物方法, 例如相互速度障碍物法 (Reciprocal Velocity Obstacle, RVO)^[22-24], 以更好地避免碰撞。

动态窗口法^[25]是一种常用于移动机器人路径规划的算法。该方法旨在让机器人能够安全、高效地在动态环境中规划自己的运动轨迹。动态窗口法的核心思想是将机器人的运动状态表示为一个动态窗口, 其中窗口的大小和速度范围会根据机器人当前的运动能力和环境条件而动态调整。动态窗口通常由机器人的最大线速度和最大角速度确定, 同时考虑到机器人当前的速度、加速度、以及环境中障碍物的位置和速度等因素。在每个时间步骤中, 动态窗口法会根据机器人当前的状态和环境信息, 计算出机器人在下一个时间步骤内可以采取的所有可能的运动命令。然后, 它会评估每个运动命令的安全性和效用, 并选择最优的运动命令作为机器人下一步的动作。

1.2.2 基于时序逻辑的运动规划方法

对于上述方法而言, 其主要适用范围为较为简单的到达指定地点的任务, 无法解决对机器人提出了逻辑要求和时序要求的任务, 例如序列任务, 要求按照顺序依次到达区域 A、B、C; 巡逻任务, 如依次到达区域 A、B、C 并无限循环; 以及同时包含这些的更复杂的组合任务, 如无限次访问区域 A、B、C, 不要经过区域 D, 当访问区域 E 时接下来访问区域 F 等等。仅仅依靠上述的传统运动规划方法不能解决这样具有复杂时序逻辑的规划问题, 但这类问题恰好是实际环境中我们希望机器人能够完成的具有复杂要求的问题。许多研究已经致力于考虑除了简单的到达目标任务之外的复杂任务, 并提出了形式化方法来研究能够解决复杂时序逻辑任务的算法。机器人领域的形式化方法研究包括:

- 形式化描述: 形式化描述是指使用精确的、严格的数学语言或形式化语言来描述系统、模型、算法、规范或属性。形式化描述通常采用符号、逻辑、数学符号等形式来精确地表达概念和关系, 避免了自然语言描述中可能存在的歧义和模糊性;
- 形式化求解: 形式化求解是指利用形式化描述对问题进行建模, 并通过严格的数学分析或计算方法找到满足描述的规划方案;
- 形式化验证: 在形式化验证中, 系统的行为通常通过形式化建模进行描述, 然后使用数学推理或计算机算法来检查系统是否满足所定义的属性或规范。

当机器人需要完成人类操作员给出的复杂任务时, 面临一大挑战为如何将自然语言转换为机器人命令。例如, 普通人无法以机器人能识别的形式输入命令, 但能够通过自然语言表达复杂任务。因此, 我们需要提出一种形式语言, 该语言应当能够规范地描述机器人行为。对于不同的应用场景, 该语言应当能够表达不同的信息, 例如, 表达必要性、信念、可能性、知识等。上下文无关语言 (Context Free Grammars, CFG)^[26-27]是最一般的形式语言之一, 也被用于机器人形式化描述领域。

一类比 CFG 更为严格但足够通用, 能够用于各种任务的语言是时序逻辑。时序逻辑是一种带有时序运算符的逻辑语言, 在机器人应用领域得到了广泛研究, 包括线性时序逻辑 (Linear Temporal Logic, LTL), 计算树逻辑 (Computation Tree Logic, CTL) 和信号时序逻辑 (Signal Temporal Logic, STL) 等。线性时序逻辑^[28-30]是一种在机器人领域得到广泛应用的形式化语言。LTL 的主要优势之一是它与自然语言具有结构上的相似性。此外, LTL 可以表达诸如顺序之类的属性。LTL 公式定义在布尔命题集、布尔运算符和时间运算符上, LTL 当中的时序运算符可以随着时间改变命题的值 (“True”, “False”)。在许多研究中, 研究人员使用 LTL 来表达可以在有限时间内执行的公式 (例如, co-safe LTL (sc-LTL)^[31])。这些基于时序逻辑的方法的主要优势在于它们可以用有限自动机来表示^[32-33], 并且可以通过自动机来验证它们是否被满足。

通常可以将 LTL 公式转换为带有 Büchi 或 Rabin 接受条件的无限字词的 ω 自动机^[34]。将时序逻辑引导的回报设计与强化学习相结合是目前的研究热点之一。在强化学习中, 一个主要挑战是如何选择适当的奖励函数。这被称为奖励工程^[35]。已经证明, 形式化语言可以用于在强化学习设置中塑造奖励函数。例如, 文献^[36]展示了如何将 LTL 公式转换为可作为奖励函数的实值函数, 该方法适用于指定目标并为强化学习问题引入领域知识。因此, 通过对 MDP 和自动机的乘积进行控制合成和模型检验^[37], 可以解决机器人运动规划问题。文献^[38]指出, 有限确定性布奇自动机 (Limit-Deterministic Büchi Automaton, LDBA)^[39]比确定性拉宾自动机 (Deterministic Rabin Automaton, DRA) 在大部分情况下更有优势。文献^[40]在无模型强化学习中分别使用了 LDBA 和 DRA, 并对其进行了轻微限制。该文献显示, LDBA 更适合在所有 ω 正则目标下对 MDP 进行定性和定量分析。文献^[41]指出, 将 LTL 规范转换为 LDBA 可能会生成比 DRA 更小的自动机状态空间。文献^[42]指出, 考虑到工作空间的不确定性, 使用 LDBA 的单一接受集生成回报会导致智能体在强化学习过程中很难获得回报, 可能会导致强化学习的收敛速度大大降低。该文献提出了一种有限确定性增广布奇自动机 (Limit-Deterministic Generalized Büchi Automaton, LDGBA) 的方法, 该方法使用一组序号记录已访问过的接受集, 防止智能体通过反复访问已访问过的接受集

积累回报。文献^[43-44]使用 LDGBA 设计奖励和折扣函数,并证明,在适当的回报函数和折扣函数下,优化基于强化学习方法的预期折扣回报等于寻找最优策略以最大化 LTL 规范满足概率。

文献^[45]引入了“奖励机器”的术语。简单来说,该方法将由确定性有限自动机 (Deterministic Finite Automaton, DFA) 表示的时间逻辑公式与环境的离散状态进行乘积,最后产生一个增强自动机,并在其中分配奖励。在类似的方式中,文献^[33]提出了一种称为 scTLTL 的 TLTL 片段,它可以由确定性有限自动机 DFA 表示,并且相应地在增强马尔可夫决策过程上定义奖励。文献^[45-46]提供了计算每一步奖励的方法,这对于使用常见的强化学习算法,如 Q-learning 等非常有用。

1.2.3 部分可观马尔可夫决策过程中的规划方法

动态不确定环境是指环境会随时间发生变化,并且机器人在其中获取信息时具有不确定性,无法准确预知自身所处状态的环境。机器人系统中普遍存在着由于传感器噪声、机器人控制的误差、快速变化的环境以及不准确的模型导致的不确定性。因此,在动态不确定环境中,机器人必须基于有限的传感器信息推理其行动的可能结果。部分可观马尔可夫决策过程^[47] (Partially Observable Markov Decision Process, POMDP) 是这种不确定性下进行机器人决策的一个通用框架。POMDP 在机器人方面具有许多应用,例如抓取^[48]、人机交互^[49]和自动驾驶^[50]等。图1.4a展示了一种 POMDP 应用场景的示意图,在该场景中,移动机器人将执行避障任务,并到达出口。




图 1.4 POMDP 示意图

在 POMDP 模型中,机器人是一个具有不完全状态信息的决策者。在每个时间步中,机器人执行一个动作,根据当前状态和动作产生一定的奖励,并根据该动作随机转换到一个新的系统状态,之后机器人通过含有噪声的观测获取有关新状态的信息。POMDP 的执行过程如图1.4b所示。求解 POMDP 是指基于机器人过去的行动信息和观测信息,求解机器人的行动策略。策略的性能通常由一个客观函数来衡量,该函数衡量了随时间的期望总回报。最优策略即为最大化这个客观函数的策略。为了计算最优策略,规划算法通过状态转移、观察和奖励模型

推导行动对未来状态、观察和奖励的可能长期影响。通常来说,这些规划方法的前提是获得机器人的运动模型。对于一些机器人任务,模型可以由领域专家指定,或者是在规划之前从数据中学习得到。因此,POMDP 规划方法大多是基于模型的,比如强化学习^[51]。主要的 POMDP 求解算法包括两类,一类为离线算法,一类为在线算法。

离线算法的目标是在开始执行策略之前为所有可能的信念状态计算一个策略。在执行时,只需从离线计算得到的策略库中查找一个动作。离线算法通常基于迭代应用贝尔曼最优性原理^[52-53],将求解时域为 h 的问题递归地分解为解决时域为 $h-1, h-2, \dots$ 的子问题。离线算法的核心思想是将价值函数通过一系列 α 向量表示,其中 α 向量代表了在不同状态下,不同动作能够带来的回报。

精确离线算法适用于状态数较少的小型问题。由于价值函数表示的复杂性取决于行动和观测的数量,在最坏情况下,所需的 α 向量数量随着时间 t 的增加而呈指数级别增长,因此,通过剪枝算法^[54-57]识别和移除一部分 α 向量是一种重要的减少计算开销的方法。然而,即使进行了剪枝, α 向量的数量增长仍然无法应对具有大规模行动和观测空间的问题。

基于点的值迭代算法是一类近似离线算法,通过在一个有限的信念状态集合 B 中维护每个信念状态的一个 α 向量来表示价值函数。由于表示价值函数所需的 α 向量总数被 $|B|$ 所限制,因此这类方法与精确算法相比大大节省了计算开销。基于点的算法可以通过不同的方法选择包含在 B 中的信念状态,例如,随机选择^[58],最小化误差界限^[59-60],或者更好地近似可达信念状态集合^[61]。这类方法通过一个迭代过程更新价值函数表示,这个过程只考虑 B 中的信念状态,迭代过程与精确算法类似。在迭代过程中,可能会向 B 中添加新的信念,并根据 B 的采样密集程度决定近似的精度。基于点的算法可以通过牺牲最优性来解决比精确离线算法更大规模的问题。然而,对于非常大的问题,即使基于点的算法也是计算上不可行的。

对于这样的问题,我们可以应用在线算法。早期的在线算法^[62]构建完整的搜索树,或使用启发式方法修剪搜索树,并通过显式计算信念状态来返回有限时间内的最优解。在 POMDP 的基于采样的在线算法中^[63-65],信念状态被表示为决策节点处的粒子集合,并通过对下一个状态、奖励和观测进行模拟来构建搜索树和估计行动-价值函数。这些算法在适当的假设下能够提供渐近最优性保证:随着迭代次数趋向无穷,解决方案将接近最优解。

基于采样的在线算法在构建搜索树的策略上有所不同。POMCP^[63]依赖于蒙特卡洛树搜索^[66]来迭代地构建搜索树,如图1.5所示。选择阶段在当前搜索树中进行遍历来选择行动,在到达叶节点后进入扩展阶段,向树中添加新节点。在模拟阶段,通过模拟以估计达到的叶节点的长期价值。在反向传播阶段,利用来自模

拟的信息更新从根节点到叶节点路径上节点的行动-价值估计。POMCPOW^[65]也使用蒙特卡洛树搜索方法，并应用了额外技术来处理连续的行动和观测空间。相比之下，确定化稀疏部分可观察树（Determinized Sparse Partially Observable Tree, DESPOT）^[64]将搜索限制为一个有限的随机采样场景集，随机场景决定了搜索树的哪些分支将被扩展。




图 1.5 蒙特卡洛树搜索示意图

在解决具有复杂任务约束的 POMDP 问题时，时序逻辑同样能够发挥作用。文献^[67]中研究了在具有无限视野的 POMDP 问题中定性模型检验的不可判定性。他们提出了一种有限内存方法，用于验证和合成具有 LTL 约束的 POMDP。该方法需要探索整个信念空间，因此适合于状态空间较小的问题。在一些研究中^[68-70]，LTL 公式被转换为 DRA，然后构建了 POMDP 和 DRA 的乘积。具体来说，文献^[68]利用有限状态控制器通过值迭代方法限制策略搜索。文献^[69]利用近似 POMDP 求解器在乘积 POMDP 的有限信念状态空间上搜索最优策略。有限状态控制器（FSC）也是一个解决具有时序任务约束的 POMDP 的方法。在文献^[70]中，通过训练 RNN 并从 RNN 表示的策略中提取相应的 FSC，然后构建马尔可夫链，并通过概率模型检验的方法在检验时序任务是否完成。若未完成，则可以通过检验信息再次训练 RNN 以优化策略。然而，文献^[71]的研究显示，即使存在可行解，这些方法也可能无法找到解决方案。

文献^[72]中使用了确定有限自动机（DFA）来描述 LTL 公式，并构造一个乘积 POMDP。文献^[73]中则使用 LDBA 表示 LTL 公式，将 POMDP 转换为相应的置信 MDP，然后构建了置信 MDP 和 LDBA 的乘积，并在该乘积置信 MDP 上求解最优策略。文献^[74]使用从 LTL 公式转换而来的 LDGBA 构建了一个乘积 POMDP，并分别使用深度强化学习方法和一种基于采样点的方法对该乘积 POMDP 进行了求解。

1.3 主要研究工作和结构安排

本文主要对移动机器人的运动规划进行研究,在动态不确定环境中,由于机器人通常无法获得完全的观测信息,故本文主要研究部分可观马尔可夫过程中的运动规划问题。在部分可观环境的基础上,通过时序逻辑对机器人的待执行复杂任务进行了建模,之后利用一种基于转移的有限确定性广义布奇自动机对时序逻辑的满足关系进行检验,并且将部分可观的环境信息转化为完全可观的置信状态以构建置信MDP,然后将二者结合构建乘积置信MDP,最后提出了一种基于强化学习的算法对乘积置信MDP进行求解。此外,本文通过仿真实验对上述方法进行了验证。

第一章首先介绍了移动机器人运动规划的课题背景和研究意义,之后从传统规划方法,时序逻辑方法,部分可观环境方法三个角度分析了当前国内外对移动机器人规划的研究现状,最后介绍了本文的研究内容和章节安排。

第二章为本文的预备知识,首先介绍了本文主要使用的建模方法,即部分可观马尔可夫过程,之后介绍了用于描述高层次复杂任务的不等式线性时序逻辑理论,并介绍了一种基于转移的有限确定性广义布奇自动机,用于检验时序逻辑的满足关系。最后对强化学习方法进行介绍,包括贝尔曼最优方程,回报函数和折扣因子。

第三章提出了一种新的部分可观马尔可夫过程和自动机的融合方法。首先对基于转移的有限确定性广义布奇自动机进行扩展,使其适合与马尔可夫过程叉乘。之后提出了基于贝叶斯估计或卡尔曼滤波,对于离散状态或连续状态下,具有离散观测或连续观测的部分可观马尔可夫过程,构建置信马尔可夫过程的方法。最后,基于之前对自动机的扩展和将部分可观马尔可夫过程转变为置信马尔可夫过程,构建了乘积置信马尔可夫过程,该过程同时包含了机器人的运动建模和时序任务信息。

第四章针对第三章所构建的乘积置信马尔可夫过程介绍了一种基于强化学习算法的求解方法。首先设计了一种合适的回报和折扣结构,并证明了在这种设计下,通过强化学习能够得到最优策略。之后介绍了一种基于采样点的算法,该算法能够克服部分可观马尔可夫过程求解的计算开销过大的问题,近似求得满足时序逻辑任务的最优策略。最后详细介绍了该算法的计算过程,并证明了这种算法能够保证值函数形式的封闭性。

第五章通过仿真验证了本文提出方法的可行性。第五章设计了两种结构的部分可观马尔可夫决策过程,一种为状态离散且观测离散的部分可观马尔可夫决策过程,另一种为状态连续且观测连续的部分可观马尔可夫决策过程,并在这两种环境中分别设计了移动机器人需要满足的复杂任务。之后使用第三章提出

的方法，构建了乘积置信马尔可夫决策过程，并使用第四章提出的算法进行求解，最终实现了仿真任务，由此证明了本文方法的有效性。

第六章为总结与展望，总结了本文的研究成果，并对该课题未来的研究方向进行了讨论。

图1.6展示了本文的结构安排。




图 1.6 本文章节安排

第2章 基础理论

2.1 马尔可夫决策过程

马尔可夫决策过程 (Markov Decision Process, MDP) 是一种数学框架, 用于描述序贯决策问题。在 MDP 中, 决策问题被建模为一个马尔可夫链, 其中包含一组状态、一组可能的决策和一组转移概率。由于 MDP 中的状态转移是以状态完全已知为基础的, 因此 MDP 可以用于建模具有确定信息的环境。

定义 2.1 马尔可夫决策过程由多元组 $M = (S, A, P, s_0, AP, L)$ 表示, 其中

- S 是有限状态集;
- A 是有限动作集;
- $P : S \times A \times S \rightarrow [0, 1]$ 是状态转移概率函数;
- $s_0 \in S$ 是初始状态;
- AP 是有限原子命题集;
- $L : S \rightarrow 2^{AP}$ 是定义在原子命题集上的标签函数, 用于为系统的状态分配原子命题。

若在状态 s 处智能体可采取的动作集为 $A' \subseteq A$, 则状态 s 处的状态转移概率函数应当满足 $\sum_{a \in A'} P(s, a, s') = 1$, 而对于不可采取的动作集 $A - A'$, 对应的状态转移函数概率均为 0。

2.2 部分可观马尔可夫决策过程

部分可观马尔可夫决策过程 (Partially Observable Markov Decision Process, POMDP) 是 MDP 的扩展。与 MDP 不同, POMDP 中的状态无法直接观测到, 只能通过观测到的部分信息进行推断和估计。因此, 对于机器人的传感器误差, 环境的噪声等等不确定的环境因素, POMDP 能够更好地进行描述。

定义 2.2 部分可观马尔可夫决策过程由多元组 $M = (S, A, T, Z, O)$ 表示, 其中:

- S 表示智能体的状态集, 为系统的状态空间。
- A 表示智能体的动作集, 是一个连续的动作空间或离散的有限个动作集合。
- $T : S \times A \times S$ 是智能体的状态转移概率函数, 满足 $\int_{s' \in S} T(s, a, s') ds' = 1, \forall s \in S, a \in A$ 。
- $Z = \{o_1, o_2, \dots, o_l\}$ 表示智能体的观测集, 是由可能得到的有限个观测组成的观测集合。
- $O : S \times Z \rightarrow [0, 1]$ 是观测函数, 表示智能体在状态 s 时获得观测 o 的概率,

并且满足 $\sum_{o \in O} \Omega(s, o) = 1$ 。

在定义了 POMDP 之后，我们可以对智能体的运动和观测历史进行描述，通常用一条路径序列来记录系统的状态和观测。

定义 2.3 给定 POMDP M ，从初始状态开始的路径定义为一个无限序列 $\sigma = s_0 s_1 s_2 \cdots \in S^\omega, \forall i \in \mathbb{N}, s_i \in S$ 。路径 σ 对应的观测路径为 $O(\sigma) = o_0 o_1 o_2 \cdots \in Z^\omega, \forall i \in \mathbb{N}, O(s_i, o_i) > 0$ 。

2.3 线性时序逻辑

在介绍不等式线性时序逻辑之前，先介绍传统的线性时序逻辑。线性时序逻辑 (Linear Temporal Logic, LTL) 是一种用于描述计算系统行为的一种逻辑语言，能够描述系统的时间性质和序列性质。LTL 可由布尔真值 ($True$)、原子命题 ($a \in AP$)、合取 ($\wedge$)、非 ($\neg$)、下一个 ($\bigcirc$) 和直到 ($\cup$) 递归构成，具体语法定义如下：

定义 2.4

$$\varphi ::= True | a | \varphi_1 \wedge \varphi_2 | \neg \varphi | \bigcirc \varphi | \varphi_1 \cup \varphi_2 \quad (2.1)$$

其中

- $True$ 是布尔真值。
- a 是原子命题集当中的命题。
- $\varphi, \varphi_1, \varphi_2$ 是 LTL 公式。
- $\wedge$ 和 $\neg$ 分别是且和非，均为标准布尔运算符。
- $\bigcirc$ 和 $\cup$ 分别是下一个和直到，均为时序运算符。

定义 2.5 由上述定义可以得到的常用布尔运算符和时序运算符定义如下：

- 或： $\varphi_1 \vee \varphi_2 := \neg(\neg\varphi_1 \wedge \neg\varphi_2)$ 。
- 如果...那么...： $\varphi_1 \rightarrow \varphi_2 := \neg\varphi_1 \vee \varphi_2$ 。
- 最终： $\Diamond\varphi := True \cup \varphi$ 。
- 总是： $\Box\varphi := \neg(\Diamond\neg\varphi)$ 。

在定义了上述的时序性质之后，LTL 可以用于检验系统模型是否满足给定的性质：

定义 2.6 给定一条无限路径 $\sigma = s_0 s_1 \cdots$ ，其中 $s_i \in S$ ，我们令 $s[i] = s_i s_{i+1} \cdots$ 。那么 σ 满足 LTL 公式 φ 的定义如下：

- $\sigma \models True$ 。
- $\sigma \models a$ ，当且仅当 $a \in L(s_0)$ 。
- $\sigma \models \varphi_1 \wedge \varphi_2$ ，当且仅当 $\sigma \models \varphi_1$ 且 $\sigma \models \varphi_2$ 。
- $\sigma \models \neg\varphi$ ，当且仅当 $\sigma \not\models \varphi$ 。

- $\sigma \models \bigcirc \varphi$, 当且仅当 $\sigma[1] \models \varphi$ 。
- $\sigma \models \varphi_1 \cup \varphi_2$, 当且仅当 $\exists j \geq 0, \sigma[j] \models \varphi_2$, 且 $\forall 0 \leq i < j, \sigma[i] \models \varphi_1$ 。
- $\sigma \models \Diamond \varphi$, 当且仅当 $\exists i \geq 0, \sigma[i] \models \varphi$ 。
- $\sigma \models \Box \varphi$, 当且仅当 $\forall i \geq 0, \sigma[i] \models \varphi$ 。

2.4 不等式线性时序逻辑

本文使用 iLTL^[75] 来描述高层次复杂任务。iLTL 是一种用于描述任务的时间属性的基于分布的时序逻辑。iLTL 通过在概率分布上进行定义和时序约束的验证, 对传统 LTL 进行了拓展。

定义 2.7 iLTL 公式在原子命题集 AP 上的定义如下:

$$\varphi ::= \text{True} \mid f \mid \varphi_1 \wedge \varphi_2 \mid \neg \varphi \mid \bigcirc \varphi \mid \varphi_1 \cup \varphi_2 \quad (2.2)$$

其中

- True 是布尔真值。
- f 是定义在状态分布上的函数。
- $\varphi, \varphi_1, \varphi_2$ 是 iLTL 公式。
- $\wedge$ 和 $\neg$ 分别是且和非, 均为标准布尔运算符。
- $\bigcirc$ 和 $\cup$ 分别是下一个和直到, 均为时序运算符。

iLTL 检验系统模型是否满足任务的方法可以通过与 LTL 类似的方式进行定义。

定义 2.8 令 $B = \{b \mid \int_{s \in S} b(s) ds = 1\}$ 表示状态集 S 中的所有状态分布, 给定一条无限路径 $\sigma = b_0 b_1 \dots$, 其中 $b_i \in B$, 我们令 $b[i] = b_i b_{i+1} \dots$ 。那么 σ 满足 iLTL 公式 φ 的定义如下:

- $\sigma \models \text{True}$ 。
- $\sigma \models f$, 当且仅当 $f(b_0) > 0$ 。
- $\sigma \models \varphi_1 \wedge \varphi_2$, 当且仅当 $\sigma \models \varphi_1$ 且 $\sigma \models \varphi_2$ 。
- $\sigma \models \neg \varphi$, 当且仅当 $\sigma \not\models \varphi$ 。
- $\sigma \models \bigcirc \varphi$, 当且仅当 $\sigma[1] \models \varphi$ 。
- $\sigma \models \varphi_1 \cup \varphi_2$, 当且仅当 $\exists j \geq 0, \sigma[j] \models \varphi_2$, 且 $\forall 0 \leq i < j, \sigma[i] \models \varphi_1$ 。
- $\sigma \models \Diamond \varphi$, 当且仅当 $\exists i \geq 0, \sigma[i] \models \varphi$ 。
- $\sigma \models \Box \varphi$, 当且仅当 $\forall i \geq 0, \sigma[i] \models \varphi$ 。

iLTL 任务的进展通常可以通过 iLTL 公式所对应的自动机进行检验, 本文使用基于转移的有限确定性增广布奇自动机 (transition-based Limit-Deterministic Generalized Büchi Automaton, tLDGBA) 来检验机器人的运动过程是否满足 iLTL

约束。在定义 tLDGBA 之前,先给出基于转移的广义布奇自动机 (transition-based Generalized Büchi Automaton, tGBA) 的定义。

定义 2.9 tGBA 由元组 $\mathcal{A} = (Q, q_0, \Sigma, \delta, F)$ 表示, 其中:

- Q 是有限状态集。
- $q_0 \in Q$ 是初始状态。
- $\Sigma = 2^{AP}$ 是输入字母表。
- $\delta : Q \times \Sigma \rightarrow 2^Q$ 是转移集合。
- $F = \{F_0, F_1, \dots, F_{k-1}\}, \forall j \in \{0, 1, \dots, k-1\}, F_j \subset \delta$ 是接受条件。

tGBA 的运行记为 $q = q_0 l_0 q_1 \dots \in Q(\Sigma Q)^\omega, (q_i, l_i, q_{i+1}) \in \delta, \forall i \in \mathbb{N}, l_i \in \Sigma$, 若有该: $\inf(q \cap F_j \neq \emptyset, \forall F_j \in F)$, 则称该运行满足 tGBA 的接受条件, 即运行 q 被 tGBA 接受, 其中, $\inf(q)$ 是运行 q 中出现频次为无限次的转移的集合。在给定 tGBA 的定义后, 我们可以对 tLDGBA 进行定义。

定义 2.10 tLDGBA 可以被定义为一个元组 $\mathcal{A} = (Q, q_0, \Sigma, \delta, F)$, 其中 Q, δ, F 均与 tGBA 定义当中一致, 而输入字母表扩充为 $\Sigma = 2^{AP} \cup \{\epsilon\}$, 且状态集 Q 可以分为两个集合: $Q = Q_I \cup Q_D, Q_I \cap Q_D = \emptyset$, 满足

- $F_j \subset Q_D \times \Sigma \times Q_D, \forall j \in \{1, \dots, k\}$ 。
- $\forall q \in Q_D, \{(q, l, q') \in \delta | l \in \Sigma, q' \in Q_D\}$ 只有一个满足的转移。
- $\forall q \in Q_D, \{(q, l, q') \in \delta | l \in \Sigma, q' \in Q_I\} = \emptyset$ 。
- $\forall (q, \epsilon, q') \in \delta, q \in Q_I \wedge q' \in Q_D$ 。

自动机的接受语言是指所有能够被自动机接受的字符串的集合。当自动机处理一个字符串时, 它会依据预设的转移规则和当前的状态, 逐个字符地读取输入, 并在每个字符后转移到下一个状态。

定义 2.11 tLDGBA A_ϕ 的接受语言定义为:

$$\mathcal{L}(A_\phi) = \{\omega \in \Sigma^\omega | \text{对于 } \omega, A_\phi \text{ 中存在一个接受运行}\}$$

其中, $\omega = l_0 l_1 \dots$ 为自动机的输入字词, Σ^ω 是输入字母表上所有无限字词的集合。

2.5 强化学习

Q-learning^[76] 是一种经典的强化学习算法, 用于学习最优策略的动作值函数。Q-learning 通过不断更新动作值函数来使智能体逐步学习到最优策略。在 Q-learning 中, 智能体通过与环境交互获取奖励, 并根据贝尔曼方程更新动作值函数, 以实现在未知环境中找到最佳策略的目标。

定义 2.12 给定状态空间 S 、回报函数 R 和折扣因子 γ , 策略 π 下的状态值

函数定义为:

$$V^\pi(s) := \mathbb{E}^\pi \left[\sum_{k=0}^{\infty} \gamma^k R_{t+k} | s_t = s \right], \forall s \in S, \quad (2.3)$$

动作值函数定义为:

$$Q^\pi(s, a) := \mathbb{E}^\pi \left[\sum_{k=0}^{\infty} \gamma^k R_{t+k} | s_t = s, a_t = a \right], \forall s \in S, \forall a \in A. \quad (2.4)$$

定义 2.13 最优值函数定义为:

$$V^*(s) := \max_{\pi} V^\pi(s), \forall s \in S, \quad (2.5)$$

最优动作值函数定义为:

$$Q^*(s, a) := \max_{\pi} Q^\pi(s, a) = \mathbb{E}[R_t + \gamma V^*(s_{t+1}) | s_t = s, a_t = a], \forall s \in S, \forall a \in A. \quad (2.6)$$

在强化学习中, 价值函数表示某个状态或状态-动作对的“好坏”程度, 即在当前策略下的长期累积奖励期望。价值函数包括状态值函数(V函数)和动作值函数(Q函数), 用于评估智能体在不同状态或采取不同动作时的价值。

定义 2.14 贝尔曼最优方程:

$$V^*(s) = \max_{a \in A} Q^*(s, a) = \max_{a \in A} \mathbb{E}[R_t + \gamma V^*(s_{t+1}) | s_t = s, a_t = a], \forall s \in S. \quad (2.7)$$

$$Q^*(s, a) = \mathbb{E}[R_t + \gamma \max_{a' \in A} Q^*(s_{t+1}, a') | s_t = s, a_t = a], \forall s \in S, a \in A. \quad (2.8)$$

贝尔曼最优方程是强化学习中的基本方程, 描述了状态值函数和动作值函数的迭代过程。在马尔可夫决策过程中, 贝尔曼方程表示当前状态值函数与下一个状态值函数之间的关系, 可以用来更新值函数。

2.6 本章小结

本章介绍了本文当中需要用到的预备知识, 主要包括部分可观马尔可夫决策过程、不等式线性时序逻辑和强化学习。为了介绍部分可观马尔可夫决策过程, 本章铺垫了马尔可夫决策过程的定义和相关性质。为了介绍不等式线性时序逻辑, 本章铺垫了线性时序逻辑的定义和有关性质。本章介绍了基于转移的有限确定性广义自动机, 并给出了该自动机检验 iLTL 公式满足关系的方法。此外, 本章对强化学习的基本方程, 即贝尔曼最优方程, 进行了介绍。

第3章 时序任务与部分可观马尔可夫决策过程的融合

对于含有时序任务的移动机器人运动规划问题,首要的任务是找到一种能够同时包含时序信息和机器人运动信息的描述框架,本章基于不等式线性时序逻辑与部分可观马尔可夫决策过程提出了一种满足上述要求的新框架。对该描述框架下的最优策略求解问题,将在第4章进行阐述。

本章首先对基于转移的有限确定性广义布奇自动机进行扩展,定义了一种嵌入式有限确定性广义布奇自动机,这种自动机能够与马尔可夫过程融合,并且在融合的过程当中不会损失时序任务信息。之后提出了基于贝叶斯估计和卡尔曼滤波的两种方法,这两种方法能够将离散状态或连续状态下,具有离散观测或连续观测的部分可观马尔可夫过程转换为置信马尔可夫过程。最后,基于之前对自动机的扩展和置信马尔可夫过程,构建了乘积置信马尔可夫过程,该过程同时包含了机器人的运动建模和时序任务信息。

线性时序逻辑可用于精确地描述系统的性质和行为要求,以形式化的方式对系统进行规约。通过 LTL 公式转化得到的自动机,可以清晰地定义系统应满足的约束条件和期望行为。但常见的自动机可能具有状态爆炸、转换成本过高、不适用于连续系统等问题。此外,当自动机与马尔可夫决策过程融合时,其时序任务信息有可能丢失,导致乘积马尔可夫决策过程无法求得满足时序任务的策略。

MDP 作为一种对不确定环境进行建模的优秀数学框架,能够描述智能体不同的动作和在状态之间转移的概率,表现出环境的不确定性。然而在 MDP 当中,智能体的状态必须精确已知,意味着在实际应用当中,机器人需要有极为精确的传感器以满足 MDP 对精确状态的需要。当环境噪声较多,或传感器精度不足,无法得到正确状态时,智能体将会做出错误的决策。POMDP 是对传统 MDP 的自然扩展,通过引入部分可观测性的概念,更贴合真实世界中状态无法完全观测的情况。POMDP 的核心思想是在决策智能体与环境交互的过程中,智能体无法直接获取完整的环境状态信息,而只能依赖于不完全、有噪声的观测数据来推断当前环境状态。这种不确定性的建模使得 POMDP 适用于处理实际问题中的复杂性和动态性,其中环境的状态变化和智能体的观测都受到随机性的影响。然而,在 POMDP 的求解当中,往往需要利用置信状态对智能体进行描述。置信状态是一个智能体根据环境状态,对自身状态进行估计的概率分布,而在连续空间当中,概率分布是一个定义域连续的函数,找到一个解析的表示方法具有相当大的挑战。

3.1 嵌入式有限确定性广义布奇自动机

基于有限确定性广义布奇自动机 LDGBA, 本节提出了一种拓展方法, 使得以该方法得到的嵌入式有限确定性广义布奇自动机 E-tLDGBA 能够与马尔可夫过程融合, 得到包含有时序信息的乘积过程。

对于一个 tLDGBA $\mathcal{A} = (Q, q_0, \Sigma, \delta, F)$, 我们可以设计一个边界记录集 T , 用于记录尚未访问的接受集。定义集合 $V = \{v | v \in \{0, 1, \dots, k-1\}\}$, 其中 v 代表了所有 k 个接受集的序号, 则对于 tLDGBA 的一条转移 $(q, l, q') \in \delta$, 可以定义一个函数 $f_{acc} : \delta \rightarrow 2^V$ 用于记录该转移所属的接受集, 即 $f_{acc}(q, l, q') = \{j \in V | (q, l, q') \in F_j\}$ 。之后令边界记录集 T 的初始状态为 F , 即 tLDGBA 的接受集, 且该边界记录集 T 按照如下规则进行更新,

$$f_A((v, q), l, (v', q'), T) = \begin{cases} T \setminus F_j, & \text{当 } v, j \in f_{acc}(q, l, q') \text{ 且 } F_j \in T, \\ F \setminus F_j, & \text{当 } v, j \in f_{acc}(q, l, q') \text{ 且 } T \neq \emptyset, \\ T, & \text{其他.} \end{cases} \quad (3.1)$$

当自动机的一个接受集 F_j 被访问时, 该接受集将从边界记录集 T 当中移除。而当边界记录集 T 为空集时, 则边界记录集 T 将会重置为 $F \setminus F_j$ 。由于 tLDGBA 的接受条件为无限次访问所有的接受集, 我们可以将遍历所有接受集的过程称为一个回合, 即当一个回合结束时, 边界记录集 T 将变为空集。若一条状态转移 (q, l, q') 同时属于多个接受集, 且这些接受集都在边界记录集 T 当中, 则该状态转移 (q, l, q') 对应的边界记录集 T 中的所有接受集都应当被移除。基于上述规则, 我们可以构造出嵌入式有限确定性广义布奇自动机。

定义 3.1 给定一个 tLDGBA $\mathcal{A} = (Q, \Sigma, \delta, q_0, F)$, 其对应的嵌入式有限确定性广义布奇自动机 (Embedded tLDGBA, E-tLDGBA) 可以由一个元组 $\bar{\mathcal{A}} = (\bar{Q}, \Sigma, \bar{\delta}, \bar{q}_0, \bar{F}, f_A, T)$ 表示, 其中

- $\bar{Q} = V \times Q$ 为增广自动机状态集;
- Σ 为输入字母表, 与 LDGBA 当中的输入字母表相同;
- $\bar{\delta} = \{((v, q), l, (v', q')) \in \bar{Q} \times \Sigma \times \bar{Q} | (q, l, q') \in \delta, v' = f_v(v, q, T)\}$ 为新的转移函数, 其中 $f_v(v, q, T)$ 为 E-tLDGBA 中表示当前待访问接受集 v 的转移函数:

$$f_v(v, q, T) = \begin{cases} i, & F_i = T[0]; \\ 0, & T = \emptyset. \end{cases}$$

$T[0]$ 表示在更新之后, 边界记录集当中排序为首位的接受集;

- $\bar{q}_0 = (0, q_0)$ 为自动机初始状态;
- $\bar{F} = \{\bar{F}_0, \bar{F}_1, \dots, \bar{F}_{k-1}\}, \bar{F}_j = \{((v, q), l, (v', q')) \in \bar{\delta} | (q, l, q') \in F_j, v \in f_{acc}(q, l, q'), v \leq j\}$ 为新的接受条件;

- f_A 为边界记录集更新函数, 对边界记录集 T 进行更新;
- T 为边界记录集, 初始为 F 。

在 E-tLDGBA 的定义当中, 分量 v 与 tLDGBA 当中的状态 q 进行组合形成了新的增广自动机状态, 其中 v 表示当前待访问的接受集。由于边界记录集在更新过程中会删除已访问接受集, 故 v 指向边界记录集当中的第一个集合, 指定了智能体当前待完成的子目标。当自动机进行状态转移时, 首先根据函数 f_{acc} 得到其所属的接受集, 然后按照边界记录集的更新规则对边界记录集 T 进行更新, 完成边界记录集的更新后即可得到下一步需要访问的接受集。

E-tLDGBA 在 tLDGBA 的基础上利用边界记录集 T 和更新规则 f_A 对待访问接受集进行了记录。当 tLDGBA 的所有接受集均被访问之后, 边界记录集 T 将会重置为初始状态。而对于相同的 iLTL 公式, tLDGBA 和该 tLDGBA 所对应的 E-tLDGBA 具有相同的接受语言。

定理 3.1 对于任意 iLTL 公式 ϕ , 我们可以构造一个 tLDGBA $\mathcal{A} = (Q, \Sigma, \delta, q_0, F)$ 和对应的 E-tLDGBA $\bar{\mathcal{A}} = (\bar{Q}, \Sigma, \bar{\delta}, \bar{q}_0, \bar{F}, f_A, T)$, 则这两个自动机具有相同的接受语言, 即

$$\mathcal{L}(\bar{\mathcal{A}}_\phi) = \mathcal{L}(\mathcal{A}_\phi) \quad (3.2)$$

证明 我们将通过证明 $\mathcal{L}(\bar{\mathcal{A}}_\phi) \subseteq \mathcal{L}(\mathcal{A}_\phi)$ 和 $\mathcal{L}(\bar{\mathcal{A}}_\phi) \supseteq \mathcal{L}(\mathcal{A}_\phi)$ 来得到 $\mathcal{L}(\bar{\mathcal{A}}_\phi) = \mathcal{L}(\mathcal{A}_\phi)$ 。

对于任意的接受语言 $\omega = \alpha_0 \alpha_1 \dots \in \mathcal{L}(\mathcal{A}_\phi)$, 存在一个对应的 tLDGBA 运行序列 $r = q_0 \alpha_0 q_1 \alpha_1 \dots$, 使得 $\inf(r) \cap F_i \neq \emptyset$ 。对于该运行序列 r , 我们可以通过 E-tLDGBA 的转移规则构造一个对应的运行序列 $\bar{r} = \bar{q}_0 \alpha_0 \bar{q}_1 \alpha_1 \dots$, 则该运行序列显然也是 E-tLDGBA 的一个有效运行序列。由于在全部的接受集被访问之后, 记录接受集将被重置, 自动机将会开始新的回合, 因此有 $\inf(\bar{r}) \cap \bar{F}_i \neq \emptyset$, 故 $\omega \in \mathcal{L}(\bar{\mathcal{A}}_\phi)$, 故 $\mathcal{L}(\bar{\mathcal{A}}_\phi) \subseteq \mathcal{L}(\mathcal{A}_\phi)$ 。

类似的, 对于任意接受语言 $\bar{\omega} = \bar{\alpha}_0 \bar{\alpha}_1 \dots \in \mathcal{L}(\bar{\mathcal{A}}_\phi)$, 存在一个对应的 E-tLDGBA 运行序列 $\bar{r} = \bar{q}_0 \alpha_0 \bar{q}_1 \alpha_1 \dots$, 使得 $\inf(\bar{r}) \cap \bar{F}_i \neq \emptyset$ 。对于该运行序列当中的所有 $\bar{q}$, 我们可以仅保留其中的 q , 得到一个运行序列 $r = q_0 \alpha_0 q_1 \alpha_1 \dots$, 显然该运行序列也是 tLDGBA 的一个有效运行序列, 并且由于当 $(\bar{q}, l, \bar{q}')$ 访问了接受集时, 对应的 (q, l, q') 也一定访问了接受集, 故 $\inf(r) \cap F_i \neq \emptyset$, 即 $\bar{\omega} \in \mathcal{L}(\mathcal{A}_\phi)$, 因此 $\mathcal{L}(\bar{\mathcal{A}}_\phi) \supseteq \mathcal{L}(\mathcal{A}_\phi)$ 。 ■

定理3.1说明 E-tLDGBA 在对 tLDGBA 进行拓展的同时, 仍然保持有相同的接受语言, 因此在检验时序任务的进展情况时, 具有和 tLDGBA 相同的效果, 同时, E-tLDGBA 指定了每个状态的待访问接受集, 更适合与机器人的运动信息进行结合, 其原因将在 3.3 小节进行阐述。

3.2 置信马尔可夫决策过程构造

3.2.1 基于贝叶斯估计的置信马尔可夫决策过程构造

在 POMDP 当中, 由于环境的不确定性和机器人的观测噪声等等因素, 通常无法确定性地表示机器人处于某个特定状态。因此, 往往通过历史观测信息对机器人实际所处状态进行估计。而置信状态 (belief state) 就是一类概率估计, 表示了智能体所处不同可能状态的概率。给定 POMDP $\mathcal{M} = (S, A, T, b_0, Z, O, AP, L)$, 置信状态是定义在 POMDP 状态集 S 上的概率分布:

$$b_t := Pr(s_t | b_0, a_0, o_1, \dots, b_{t-1}, a_{t-1}, o_t) \quad (3.3)$$

在置信状态 b 处, 当采取动作 $a \in A$ 且获得观测 $o \in Z$ 时, 置信状态可以根据贝叶斯公式更新:

$$\begin{aligned} b_a^o(s') &= Pr(s' | b, a, o) \\ &= \frac{Pr(o | b, a, s') Pr(s' | b, a)}{Pr(o | b, a)} \\ &= \frac{O(s', o) \sum_{s \in S} T(s, a, s') b(s)}{Pr(o | b, a)} \end{aligned} \quad (3.4)$$

其中 $Pr(o | b, a)$ 为归一化因子, 其值为:

$$Pr(o | b, a) = \sum_{s' \in S} O(s', o) \sum_{s \in S} T(s, a, s') b(s). \quad (3.5)$$

当状态空间连续时, 其中的对状态 s 遍历求和将变为对状态空间 S 求积分。通过使用置信状态, 智能体可以维护一个置信度分布, 表示对环境状态的信念。这个置信度分布会根据观察和动作的更新而更新, 最终使得智能体能够以完全可观察的方式对环境进行建模, 形成置信 MDP。

定义 3.2 给定 POMDP $\mathcal{M}$, $\mathcal{M}$ 生成的置信 MDP 可以用元组 $\mathcal{D} = (\mathcal{B}, A, T_D, b_0, Z, O, L_D)$ 表示, 其中:

- $\mathcal{B} = \{b(s) \in [0, 1]\}$ 是置信状态空间
- A 是有限动作集
- 置信状态转移函数 T_D 定义为

$$T_D(b, a, b') = \begin{cases} Pr(o | b, a) & b' = b_a^o, \\ 0 & \text{其他,} \end{cases}$$

- $b_0 \in \mathcal{B}$ 是初始分布;
- Z 是有限观测集;
- O 是观测函数;

• L_D 是定义在分布上的标签函数, 通过该函数可以获得自动机所需的标签。

在离散情况下, 具有 n 个状态的 POMDP 需要满足处于 n 个状态的概率总和为 1, 故生成的置信状态空间为 $n-1$ 维, 且由于置信状态是一种概率估计, 每一个维度均为 $[0, 1]$ 上的连续空间。因此当真实状态数趋于无穷时, 对应的置信状态空间维数也将趋于无穷。对于具有连续状态空间 S 的 POMDP, 则对应的置信状态空间为所有满足 $\int_{s \in S} b(s) ds = 1$ 的概率分布函数。在给定的初始置信状态下, 通常可以采用将连续空间离散化或规定特定的转移公式与观测公式以限制能够到达的置信空间范围。本节将介绍一种基于高斯混合分布限制置信空间可达范围的方法。选择的方法应该满足三个要求: 第一, 置信状态更新必须是封闭的, 即在 POMDP 的转移模型下, 置信状态能够始终用同一种形式表示; 第二, 价值函数也必须是封闭的; 第三, 价值函数与置信状态的积分必须是可计算的。故本文使用高斯混合分布以描述置信状态, 并使用高斯函数的线性组合来计算价值函数, 其中价值函数的封闭性和价值函数与置信状态积分的可计算性将在第 4 章详细证明。

例 3.1 本例展示一维连续 POMDP 转化为置信 MDP 的过程。考虑状态空间为 $(-\infty, +\infty)$, 动作集 $A = \{L, R\}$, 观测集为 $Z = \{o_+, o_-\}$ 的 POMDP 模型, 其观测函数定义为:

$$O(s, o_+) = \begin{cases} 0 & s < -1, \\ 0.5 & -1 \leq s < 1, \\ 1 & s \geq 1. \end{cases}$$

$$O(s, o_-) = \begin{cases} 1 & s < -1, \\ 0.5 & -1 \leq s < 1, \\ 0 & s \geq 1. \end{cases}$$

初始置信状态 $b_0(s)$ 定义为标准高斯分布 $\phi(s|0, 1)$, 转移概率函数定义为:

$$T(s, L, s') = \begin{cases} 1 & s' = s - 1, \\ 0 & s' \neq s - 1, \end{cases}$$

$$T(s, R, s') = \begin{cases} 1 & s' = s + 1, \\ 0 & s' \neq s + 1, \end{cases}$$

因此在执行动作 R 后, 获得观测 o_+ 的概率为

$$\begin{aligned}
 Pr(o_+|b_0, R) &= \int_{-\infty}^{+\infty} O(s', o_+) \int_{-\infty}^{+\infty} T(s, R, s') b_0(s) ds ds' \\
 &= \int_{-\infty}^{+\infty} O(s', o_+) \phi(s'|1, 1) ds' \\
 &= 0.5 \int_{-1}^1 \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{(s'-1)^2}{2}\right) ds' + \int_1^{\infty} \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{(s'-1)^2}{2}\right) ds' \\
 &= 0.7386
 \end{aligned}$$

给定初始置信状态 b_0 在采取动作 R 并得到观测 o_+ 之后, 其对应的置信状态为:

$$\begin{aligned}
 b_R^{o_+}(s') &= \frac{O(s', o_+) \int_{-\infty}^{+\infty} T(s, R, s') b_0(s) ds}{Pr(o_+|b_0, R)} \\
 &= \frac{O(s', o_+) \phi(s'|1, 1)}{0.7386} \\
 &= \begin{cases} 0 & s' < -1, \\ 0.6770 \phi(s'|1, 1) & -1 \leq s' < 1, \\ 1.3539 \phi(s'|1, 1) & s' \geq 1. \end{cases}
 \end{aligned}$$

对应的, 在执行动作 R 后, 获得观测 o_- 的概率为 $Pr(o_-|b_0, R) = 1 - 0.7386 = 0.2614$, 对应的置信状态为:

$$b_R^{o_-}(s') = \begin{cases} 3.8256 \phi(s'|1, 1) & s' < -1, \\ 1.9128 \phi(s'|1, 1) & -1 \leq s' < 1, \\ 0 & s' \geq 1. \end{cases}$$

图3.1a和图3.1b分别展示了从 b_0 处出发采取动作 R 后可能得到的置信状态 $b_R^{o_+}$ 和 $b_R^{o_-}$ 所对应的函数图像。




图 3.1 从 b_0 处出发采取动作 R 后可能得到的置信状态

根据对称性可知,当智能体采取动作 L 之后,获得观测 o_+ 和观测 o_- 的概率分别为 $Pr(o_+|b_0, L) = 0.2614$, $Pr(o_-|b_0, L) = 0.7386$, 对应的置信状态为

$$b_L^{o_+}(s') = \begin{cases} 0 & s' < -1, \\ 1.9128 \phi(s'|-1, 1) & -1 \leq s' < 1, \\ 3.8256 \phi(s'|-1, 1) & s' \geq 1. \end{cases}$$

$$b_L^{o_-}(s') = \begin{cases} 1.3539 \phi(s'|-1, 1) & s' < -1, \\ 0.6770 \phi(s'|-1, 1) & -1 \leq s' < 1, \\ 0 & s' \geq 1. \end{cases}$$

图3.2a和图3.2b分别展示了从 b_0 处出发采取动作 R 后可能得到的置信状态 $b_L^{o_+}$ 和 $b_L^{o_-}$ 所对应的函数图像。




图 3.2 从 b_0 处出发采取动作 L 后可能得到的置信状态

根据上述推导,可以得到置信状态转移函数:

$$T(b_0, R, b') = \begin{cases} 0.7386 & b' = b_R^{o_+}, \\ 0.2614 & b' = b_R^{o_-}, \\ 0 & \text{其他.} \end{cases}$$

$$T(b_0, L, b') = \begin{cases} 0.2614 & b' = b_L^{o_+}, \\ 0.7386 & b' = b_L^{o_-}, \\ 0 & \text{其他.} \end{cases}$$

以此类推,对每个置信状态,遍历智能体可以采取的动作和可能获得的观测,即可得到更新后的置信状态与转移概率,因此可以得到所有置信状态的转移关系,即该 POMDP 可以转化为完全可观的置信 MDP。图3.3展示了置信状态的更新过程,从 b_0 处通过动作 R 和 L 更新得到四个新的置信状态 $b_R^{o_+}$, $b_R^{o_-}$, $b_L^{o_+}$, $b_L^{o_-}$,




图 3.3 置信 MDP 更新过程

b_L^{o+} ，之后在这四个新的置信状态处可以循环进行上述操作，扩展置信状态转移关系。

然而在例3.1当中，置信状态只能用数值进行表示，无法用同一解析形式进行表示，因此本章接下来将展示一种方法，使置信状态能始终用同一种解析形式进行表示。

引理 3.2 对同一随机变量服从的两个高斯分布的乘积有如下结论：

$$\phi(x|a, A)\phi(x|b, B) = \delta\phi(x|c, C) \quad (3.6)$$

其中

$$\begin{aligned} \delta &= \phi(a|b, A+B) = \phi(b|a, A+B), \\ C &= (A^{-1} + B^{-1})^{-1}, \\ c &= C(A^{-1}a + B^{-1}b). \end{aligned}$$

证明 首先将式 (3.6) 的左式展开，有

$$\begin{aligned} \phi(x|a, A)\phi(x|b, B) &= \frac{1}{2\pi\sqrt{AB}} \exp\left[-\frac{(x-a)^2}{2A} - \frac{(x-b)^2}{2B}\right] \\ &= \frac{1}{2\pi\sqrt{AB}} \exp\left\{-\frac{1}{2}\left[\left(\frac{1}{A} + \frac{1}{B}\right)x^2 - \left(\frac{2a}{A} + \frac{2b}{B}\right)x + \frac{a^2}{A} + \frac{b^2}{B}\right]\right\} \\ &= \frac{1}{2\pi\sqrt{AB}} \exp\left\{-\frac{1}{2}\left(\frac{1}{A} + \frac{1}{B}\right)\left[x - \frac{A^{-1}a + B^{-1}b}{A^{-1} + B^{-1}}\right]^2 + \frac{2ab - a^2 - b^2}{2(A+B)}\right\} \\ &= \frac{1}{\sqrt{2\pi}\sqrt{A+B}} \exp\left[-\frac{(a-b)^2}{2(A+B)}\right] \frac{1}{\sqrt{2\pi(A^{-1} + B^{-1})^{-1}}} \exp\left[-\frac{(x - \frac{A^{-1}a + B^{-1}b}{A^{-1} + B^{-1}})^2}{2(A^{-1} + B^{-1})^{-1}}\right] \end{aligned}$$

可以看出，式 (3.6) 的左式等于一个常数系数与一个高斯分布的乘积。为了简化表示，令

$$\begin{aligned} \delta &= \phi(a|b, A+B) = \phi(b|a, A+B), \\ C &= (A^{-1} + B^{-1})^{-1}, \\ c &= C(A^{-1}a + B^{-1}b). \end{aligned}$$

即有

$$\phi(x|a, A)\phi(x|b, B) = \delta\phi(x|c, C)$$

■

引理3.2说明了两个服从高斯分布的同一随机变量在相乘之后仍然保持高斯分布的形式，而高斯混合分布由于是高斯分布的线性组合，故同样具有这个性质。因此在证明了引理3.2后，我们可以证明，在一定的条件下，置信状态的转移将不会改变置信状态的高斯混合分布形式。

定理 3.3 当初始置信状态 b_0 ，观测函数 O 为高斯混合分布，转移概率函数 T 为高斯分布时，所有的可达置信状态均可用高斯混合分布表示。

证明 设置信状态 $b(s) = \sum_j w_j \phi(s|s_j, \Sigma_j)$ ，实际状态转移概率函数 $T(s, a, s') = \phi(s'|s + \Delta(a), \Sigma^a)$ ，观测函数 $O(s, o) = \sum_i w_i^o \phi(s|s_i^o, \Sigma_i^o)$ 。

则执行动作 a ，且获得观测 o 后，生成的置信状态为

$$\begin{aligned} b_a^o(s') &\propto O(s', o) \int_{-\infty}^{+\infty} T(s, a, s') b(s) ds \\ &= O(s', o) \int_{-\infty}^{+\infty} \sum_j [w_j \phi(s|s' - \Delta(a), \Sigma^a) \phi(s|s_j, \Sigma_j)] ds \\ &= O(s', o) \sum_j w_j \left[\int_{-\infty}^{+\infty} \phi(s' - \Delta(a)|s_j, \Sigma_j + \Sigma^a) \phi(s|s'_j, \Sigma'_j) ds \right] \\ &= \sum_{i,j} w_i w_j \phi(s'|s_i^o, \Sigma_i^o) \phi(s'|s_j + \Delta(a), \Sigma_j + \Sigma^a) \\ &= \sum_{i,j} w_i w_j \delta_{i,j}^{a,o} \phi(s'|s_{i,j}^{a,o}, \Sigma_{i,j}^{a,o}) \end{aligned}$$

其中

$$\begin{aligned} \delta_{i,j}^{a,o} &= \phi(s_j + \Delta(a)|s_i^o, \Sigma_i^o + \Sigma_j + \Sigma^a), \\ \Sigma_{i,j}^{a,o} &= [(\Sigma_i^o)^{-1} + (\Sigma_j + \Sigma^a)^{-1}]^{-1}, \\ s_{i,j}^{a,o} &= \Sigma_{i,j}^{a,o} [(\Sigma_i^o)^{-1} s_i^o + (\Sigma_j + \Sigma^a)^{-1} (s_j + \Delta(a))]. \end{aligned}$$

由此可以得到

$$b^{a,o}(s') \propto \sum_k w_k \phi(s'|s_k, \Sigma_k),$$

其中，对所有 i, j 有 $w_k = w_i^o w_j \delta_{i,j}^{a,o}$ ， $s_k = s_{i,j}^{a,o}$ ， $\Sigma_k = \Sigma_{i,j}^{a,o}$ 。而 $b^{a,o}(s')$ 应当满足 $\int_{-\infty}^{+\infty} b^{a,o}(s') ds' = 1$ 的归一化条件，故经归一化后可得

$$b^{a,o}(s') = \frac{1}{\sum_k w_k} \sum_k w_k \phi(s'|s_k, \Sigma_k).$$

考虑到 $Pr(o|b, a)$ 为 $b^{a,o}(s')$ 的归一化因子，故 $Pr(o|b, a) = \sum_k w_k$ 。

■

定理 3.3 说明在初始置信状态 b_0 ，观测函数 O 为高斯混合分布，转移概率函数 T 为高斯分布时，所有的可达置信状态均可用解析形式进行表示，也就是均服从于高斯混合分布。而置信状态的这种良好表示性质将为后文中提出基于强化学习的求解算法提供帮助。下面我们举例说明使用高斯混合分布拟合观测函数的可行性。

例 3.2 本例展示初始置信状态 b_0 ，观测函数 O 为高斯混合分布，转移概率函数 T 为高斯分布时，由 POMDP 生成置信 MDP 的过程。考虑一个 POMDP 模型，状态空间为 $(-\infty, +\infty)$ ，动作集 $A = \{L, R\}$ ，观测集为 $Z = \{o_\emptyset, o_{tar}\}$ ，观测函数定义为：

$$O(s, o) = \begin{cases} \frac{1}{\phi(1|1, 0.25)} \phi(s|1, 0.25) & o = o_{tar}, \\ 1 - \frac{1}{\phi(1|1, 0.25)} \phi(s|1, 0.25) & o = o_\emptyset. \end{cases}$$

由于上例中未考虑到动作转移的不确定性，本例额外考虑动作的不确定性，两种动作对应的状态转移概率函数为：

$$T(s, L, s') = \phi(s'|s - 1, 0.01)$$

$$T(s, R, s') = \phi(s'|s + 1, 0.01)$$

给定初始置信状态 $b_0(s)$ 为标准正态分布 $\phi(s|0, 1)$ ，则在执行动作 R 后，获得观测 o_{tar} 时，根据定理 3.2，得到的置信状态和置信状态转移概率为

$$b^{R, o_{tar}} = \phi(s'|s_k, \Sigma_k),$$

$$Pr(o_{tar}|b_0, R) = \frac{\phi(1|1, 1.26)}{\phi(1|1, 0.25)} = 0.20,$$

其中，

$$\Sigma_k = \left(\frac{1}{0.25} + \frac{1}{1 + 0.01} \right)^{-1} = 0.20,$$

$$s_k = \Sigma_k \cdot \left(\frac{1}{0.25} + \frac{1}{1 + 0.01} \right) = 1.$$

而在执行动作 R 后，获取观测 $o_\emptyset$ 时，获得的置信状态为

$$\begin{aligned} b^{R, o_\emptyset} &\propto \left[1 - \frac{1}{\phi(1|1, 0.25)} \phi(s'|1, 0.25) \right] \int T(s, R, s') b(s) ds \\ &= \left[1 - \frac{1}{\phi(1|1, 0.25)} \phi(s'|1, 0.25) \right] \phi(s'|1, 1.01) \\ &= \phi(s'|1, 1.01) - \frac{\phi(1|1, 1.26)}{\phi(1|1, 0.25)} \phi(s'|1, 0.20) \end{aligned}$$

归一化之后可得，

$$b^{R, o_\emptyset} = 1.25(\phi(s'|1, 1.01) - 0.25\phi(s'|1, 0.20))$$

$$Pr(o_{\emptyset}|b_0, R) = 0.80$$

类似的,可以得到智能体执行动作 L 后,分别得到观测 $o_{tar}, o_{\emptyset}$ 的对应的置信状态和置信转移概率:

$$b^{L, o_{tar}}(s') = \phi(s'|0.60, 0.20)$$

$$b^{L, o_{\emptyset}}(s') = 1.06\phi(s'|-1, 1.01) - 0.06\phi(s'|0.60, 0.20)$$

$$Pr(o_{tar}|b_0, L) = 0.06$$

$$Pr(o_{\emptyset}|b_0, L) = 0.94$$

综上,可以得到置信状态转移函数:

$$T(b_0, R, b') = \begin{cases} 0.20 & b' = b^{R, o_{tar}}, \\ 0.80 & b' = b^{R, o_{\emptyset}}, \\ 0 & otherwise. \end{cases}$$

$$T(b_0, L, b') = \begin{cases} 0.06 & b' = b^{L, o_{tar}}, \\ 0.94 & b' = b^{L, o_{\emptyset}}, \\ 0 & otherwise. \end{cases}$$

若将状态空间的定义域从 $(-\infty, +\infty)$ 缩小至 $(-4, 4)$, 由于高斯混合分布 GMM 可以拟合任意分布, 现假设

$$O(s, o) = \begin{cases} \frac{1}{\phi(1|1, 0.25)}\phi(s|1, 0.25) & o = o_{tar}, \\ \sum_{i=-20}^{20} \frac{1}{4}\phi(s|\frac{i}{4}, 0.25) - \frac{1}{\phi(1|1, 0.25)}\phi(s|1, 0.25) & o = o_{\emptyset}. \end{cases}$$

两种观测函数的概率如图3.4所示, 从图中可以看出, 在区间 $(-4, 4)$ 以内, 拟合观测函数与原型观测函数一致。

则根据定理 3.3, 在执行动作 R 后, 获取观测 $o_{\emptyset}$ 时, 获得的置信状态为

$$\begin{aligned} b^{R, o_{\emptyset}} &\propto O(s', o_{\emptyset})\phi(s'|1, 1.01) \\ &= \sum_{i=-20}^{20} \frac{1}{4}\phi(\frac{i}{4}|1, 1.26)\phi(s'|s'_i, \Sigma'_i) - \frac{\phi(1|1, 1.26)}{\phi(1|1, 0.25)}\phi(s'|1, 0.20) \end{aligned}$$

其中

$$\begin{aligned} \Sigma'_i &= (\frac{1}{0.25} + \frac{1}{1+0.01})^{-1} = 0.20, \\ s'_i &= 0.20 \cdot (\frac{0.25i}{0.25} + \frac{1}{1+0.01}) = 0.20i + 0.20. \end{aligned}$$




图 3.4 原型观测函数与拟合观测函数

归一化后可得

$$b^{R,o_0} = 1.25 \left[\sum_{i=-20}^{20} \frac{1}{4} \phi\left(\frac{i}{4} \mid 1, 1.26\right) \phi(s' \mid 0.20i + 0.20, 0.20) - 0.20 \phi(s' \mid 1, 0.20) \right]$$

$$Pr(o_0 \mid b_0, R) = 0.80$$

类似的，可以得到其余的置信状态与置信状态转移概率

$$b^{R,o_{tar}} = \phi(s' \mid 1, 0.20)$$

$$b^{L,o_0} = 1.06 \left[\sum_{i=-20}^{20} \frac{1}{4} \phi\left(\frac{i}{4} \mid -1, 1.26\right) \phi(s' \mid 0.20i - 0.20, 0.20) - 0.056 \phi(s' \mid 0.60, 0.20) \right]$$

$$b^{L,o_{tar}} = \phi(s' \mid 0.60, 0.20)$$

$$Pr(o_{tar} \mid b_0, R) = 0.20$$

$$Pr(o_0 \mid b_0, L) = 0.94$$

$$Pr(o_{tar} \mid b_0, L) = 0.06$$

使用原型观测函数与拟合观测函数所得到的 $b^{L,o_{tar}}$ 如图3.5所示，从图中可以看出，可以通过采取拟合的方式来研究一定区域以内的置信状态生成与转移。




图 3.5 原型观测函数与拟合观测函数下的置信状态函数图像

3.2.2 基于卡尔曼滤波的置信马尔可夫决策过程构造

卡尔曼滤波^[77]是一种用于估计系统状态的数学方法，通过融合系统动态模型和观测数据来提供对系统状态的最优估计。它最初由 Rudolf E. Kálmán 开发，被广泛应用于控制系统、信号处理、导航和机器人等领域。

卡尔曼滤波的核心思想是通过递归地更新状态估计值，结合系统的动态模型和传感器测量值，以获得对系统状态的最优估计。它基于两个关键假设：1. 系统的动态模型可以用线性动态方程描述；2. 系统的观测模型是线性的且受高斯噪声影响。

卡尔曼滤波包括两个主要步骤：预测步骤和更新步骤。预测步骤指根据系统的动态模型，利用先前的状态估计值预测系统的下一个状态，并估计预测状态的不确定性（协方差矩阵）。更新步骤指将预测的状态与实际观测值进行比较，通过卡尔曼增益来调整预测状态，从而得到更准确的状态估计。更新步骤还会更新状态估计的不确定性。

卡尔曼滤波的优势在于它能够处理线性系统和高斯噪声，并且能够提供最优的状态估计，即最小化估计值与真实值之间的均方误差。它在实时系统中具有良好的性能，并且能够有效地处理传感器噪声和系统动态变化。为了利用卡尔曼滤波推导 POMDP，本节将给出 POMDP 另一形式的定义。

定义 3.3 给定一个部分可观的马尔可夫决策过程 $M = (X, U, Z, b_0, T, O)$ ，其中 X 为状态集， U 为动作集， Z 为观测集， b_0 为初始概率分布， $T(x, u, x') = Pr(x'|x, u)$ 为系统状态转移函数， $O(z, x) = Pr(z|x)$ 为系统观测函数。而系统的

状态转移方程以及观测方程满足如下规则：

$$x_k = Ax_{k-1} + Bu_{k-1} + w, \quad w \sim \mathcal{N}(0, Q) \quad (3.7)$$

$$z_k = Cx_k + v, \quad v \sim \mathcal{N}(0, R) \quad (3.8)$$

其中，

- $x_k \in X$ 为智能体第 k 步所处的状态；
- $u_k \in U$ 为智能体第 k 步选择的动作；
- w 为状态转移过程当中的不确定因素，且该噪声服从于正态分布；
- $z_k \in Z$ 为智能体第 k 步获得的观测；
- v 为观测当中的不确定因素，且该噪声服从于正态分布。

由于在系统的运行过程中无法直接得到第 k 步时系统的状态 x_k ，因此我们必须通过估计系统第 k 步的真实状态以决定智能体应当采取的下一步动作。我们用 $\hat{x}_k$ 来表示对系统真实状态 x_k 的最优估计，则真实状态 x_k 服从于均值为 $\hat{x}_k$ 的正态分布，而该正态分布恰好符合系统置信状态的形式，故通过该估计可以得到系统的置信状态。我们用 $\hat{x}_k^-$ 来表示对 x_k 的预测，则根据系统状态转移方程，式 (3.7) 可知

$$\hat{x}_k^- = A\hat{x}_{k-1} + Bu_{k-1} \quad (3.9)$$

在更新步骤当中，我们将预测的状态与实际观测值进行比较，通过卡尔曼增益来调整预测状态，即

$$\hat{x}_k = \hat{x}_k^- + K(z_k - C\hat{x}_k^-) \quad (3.10)$$

式 (3.10) 中卡尔曼增益 K 表示状态最优估计中预测误差与观测误差的比重。当 $K = 0$ 时，即预测误差为 0，系统的状态值完全取决于预测值 $\hat{x}_k^-$ ；而当 $K = C^{-1}$ 时，即观测误差为 0，系统的状态值完全取决于观测值 z_k 。

因此，我们用 $e_k^- = x_k - \hat{x}_k^-$ 表示预测误差， $e_k = x_k - \hat{x}_k$ 表示估计误差， $\Sigma_k^- = E[e_k^- \cdot e_k^{-T}]$ 表示真实状态值与预测状态值之间的协方差， $\Sigma_k = E[e_k \cdot e_k^T]$ 表示真实状态值与最优估计值之间的协方差，代入式 (3.10) 可得，

$$\begin{aligned} \hat{x}_k &= \hat{x}_k^- + K(C \cdot x_k + v_k - C \cdot \hat{x}_k^-) \\ &= \hat{x}_k^- + KC \cdot x_k + Kv_k - KC \cdot \hat{x}_k^- \end{aligned} \quad (3.11)$$

因此可知，

$$e_k = (I - KC) \cdot e_k^- - K \cdot v_k \quad (3.12)$$

因此, 估计误差的协方差为

$$\begin{aligned}\Sigma_k &= E[e_k \cdot e_k^T] = (I - KC) \cdot \Sigma_k^- \cdot (I - KC)^T + K \cdot R \cdot K^T \\ &= \Sigma_k^- - KC \Sigma_k^- - \Sigma_k^- C^T K^T + K(C \Sigma_k^- C^T + R)K^T\end{aligned}\quad (3.13)$$

卡尔曼增益的取值原则就是使最优状态估计的协方差最小, 使其越来越逼近于真实值。因此, 计算 Σ_k 对 K 求偏导可得,

$$\frac{\partial \Sigma_k}{\partial K} = -2(\Sigma_k^- C^T) + 2K(C \Sigma_k^- C^T + R) = 0 \quad (3.14)$$

由此可知, 最优估计下的卡尔曼增益矩阵为

$$K = \Sigma_k^- C^T (C \Sigma_k^- C^T + R)^{-1} \quad (3.15)$$

最优估计的协方差矩阵为

$$\Sigma_k = (I - KC) \cdot \Sigma_k^- \quad (3.16)$$

第 $k+1$ 步的预测误差为

$$e_{k+1}^- = (Ax_k + Bu_k + w_k) - (A\hat{x}_k + Bu_k) \quad (3.17)$$

$$= Ae_k + w_k \quad (3.18)$$

因此第 $k+1$ 步的预测误差的协方差矩阵为

$$\begin{aligned}\Sigma_{k+1}^- &= E[e_{k+1}^- \cdot e_{k+1}^{-T}] \\ &= E[(Ae_k)(Ae_k)^T] + E[w_k(w_k)^T] \\ &= A\Sigma_k A^T + Q\end{aligned}\quad (3.19)$$

综上所述, 根据卡尔曼滤波方程, 我们首先根据上一步的状态估计和观测对下一步状态进行预测, 并得到相应的方差,

$$\hat{x}_k^- = A\hat{x}_{k-1} + Bu_{k-1} \quad (3.20)$$

$$\Sigma_k^- = A\Sigma_{k-1} A^T + Q \quad (3.21)$$

在获得观测值之后, 我们可以对得到的预测作出修正, 并根据新得到的观测中蕴含的信息重新计算估计的方差,

$$K = \Sigma_k^- C^T (C \Sigma_k^- C^T + R)^{-1} \quad (3.22)$$

$$\hat{x}_k = \hat{x}_k^- + K(z_k - C\hat{x}_k^-) \quad (3.23)$$

$$\Sigma_k = \Sigma_k^- - KC \Sigma_k^- \quad (3.24)$$

其中 K 是卡尔曼增益。故在获得观测之后得到的置信状态为

$$x_k \sim b_k = \mathcal{N}(\hat{x}_k, \Sigma_k) \quad (3.25)$$

而获得观测 z 的概率为

$$Pr(z_k | b_{k-1}, u_{k-1}) = \int_{x_k \in X} O(z_k, x_k) \int_{x_{k-1} \in X} T(x_{k-1}, u, x_k) b_{k-1}(x_{k-1}) dx_{k-1} dx_k \quad (3.26)$$

则可以得到置信状态转移函数

$$T(b, u, b') = \begin{cases} Pr(z|b, u), & b' = b_u^z \\ 0, & \text{其他} \end{cases} \quad (3.27)$$

卡尔曼滤波假设系统的状态和观测在连续时间下是线性的，噪声服从高斯分布。它利用系统的动力学模型和观测模型，通过递推的方式，通过先验估计和观测数据的融合，得到对系统状态的最优估计。实际上，卡尔曼滤波是一种特殊的贝叶斯估计方法，适用于线性系统和高斯噪声的情况。在连续环境当中，由于基于贝叶斯估计的置信 MDP 方法计算复杂度过大，我们可以通过线性系统假设和高斯噪声假设对实际环境进行拟合，从而利用卡尔曼滤波方法降低计算复杂度，构造置信 MDP。下面通过一个例子来介绍基于卡尔曼滤波的置信 MDP 构造方法。

例 3.3 本例展示如何通过卡尔曼滤波构建置信 MDP，给定一个部分可观的马尔可夫决策过程 $M = (X, U, Z, b_0)$ 。 $X \subseteq \mathbb{R}$ 为状态空间， $Z \subseteq \mathbb{R}$ 为观测空间， $U = \{+1, -1\}$ 为动作集。对应的系统状态转移方程和观测方程如下：

$$x_{k+1} = x_k + u_k + \omega, \quad \omega \sim N(0, 0.01)$$

$$z_k = x_k + v, \quad v \sim N(0, 0.25)$$

则可以得到系统的状态转移函数和观测函数如下：

$$T(x_k, u, x_{k+1}) = \begin{cases} \mathcal{N}(x_k + 1, 0.01), & u = 1 \\ \mathcal{N}(x_k - 1, 0.01), & u = -1 \end{cases}$$

$$O(z_k, x_k) = \mathcal{N}(x_k, 0.25)$$

系统的初始置信状态为 $b_0 = \mathcal{N}(0, 1)$ ，在采取动作 $u = 1$ 后得到观测 z 的概率为

$$\begin{aligned} Pr(z|b_0, u_{right}) &= \int_{x' \in X} O(z, x') \int_{x \in X} T(x, u_{right}, x') b_0(x) dx dx' \\ &= \int_{x' \in X} \varphi(z|x', 0.25) \int_{x \in X} \varphi(x'|x+1, 0.01) \varphi(x|0, 1) dx dx' \\ &= \int_{x' \in X} \varphi(z|x', 0.25) \varphi(x'|1, 1.01) dx' \\ &= \varphi(z|1, 1.26) \end{aligned}$$

得到观测 z 后即可根据卡尔曼滤波方程得到新的置信状态 b'

$$\begin{aligned}\hat{x}_1^- &= 0 + 1 = 1 \\ \Sigma_k^- &= 0.01 \\ K &= 0.01 * (0.01 + 0.25)^{-1} = 0.04 \\ \hat{x}_1 &= 1 + 0.04 * (z - 1) \\ \Sigma_1 &= 0.01 - 0.04 * 0.01 \\ b'(x) &= \varphi(x|0.04z + 0.06, 0.01)\end{aligned}$$

类似的，在采取动作 $u = -1$ 后，得到观测 z 的概率为

$$\begin{aligned}Pr(z|b_0, u_{left}) &= \int_{x' \in X} O(z, x') \int_{x \in X} T(x, u_{right}, x') b_0(x) dx dx' \\ &= \int_{x' \in X} \varphi(z|x', 0.25) \int_{x \in X} \varphi(x'|x - 1, 0.01) \varphi(x|0, 1) dx dx' \\ &= \int_{x' \in X} \varphi(z|x', 0.25) \varphi(x'|-1, 1.01) dx' \\ &= \varphi(z|-1, 1.26)\end{aligned}$$

得到观测 z 后即可根据卡尔曼滤波方程得到新的置信状态 b'

$$\begin{aligned}\hat{x}_1^- &= 0 - 1 = -1 \\ \Sigma_k^- &= 0.01 \\ K &= 0.01 * (0.01 + 0.25)^{-1} = 0.04 \\ \hat{x}_1 &= -1 + 0.04 * [z - (-1)] \\ \Sigma_1 &= 0.01 - 0.04 * 0.01 \\ b'(x) &= \varphi(x|0.04z - 0.96, 0.01)\end{aligned}$$

在例3.3中，对于一个状态转移和观测噪声都服从于高斯分布的可以用线性系统表示的部分可观马尔可夫决策过程，其置信状态均可以用高斯分布进行描述，因此可以利用卡尔曼滤波方法得到置信状态的转移关系。并且在这种前提下，卡尔曼滤波方法能够大大减少计算开销，使具有连续状态空间和连续观测空间的 POMDP 可以在较短的时间内转化为置信 MDP。

3.3 乘积置信马尔可夫决策过程

在 3.1 节当中，我们对自动机进行了拓展，定义 E-tLDGBA 表示时序信息，检测 iLTL 任务；在 3.2 节中，我们将 POMDP 转化为置信 MDP，描述了机器人

的运动信息。因此本节将 E-tLDGBA 与置信 MDP 结合, 构造一个同时包含时序信息和机器人运动信息的描述框架, 即乘积置信 MDP。

定义 3.4 给定置信 MDP $D = (B, A, T_D, b_0, Z, O, L_D)$ 和 tLDGBA $A_\varphi = (Q, q_0, a \cup \{\epsilon\}, \delta, F)$, 乘积置信 MDP 定义为 $D = (B, A, T_D, b_0, Z, O, L_D)$, 其中:

- $D^X = B \times Q$ 是乘积置信状态集;
- $A^X = A \cup A^\epsilon, A^\epsilon := \{\epsilon\}$ 是动作集;
- $d_0^X = (b_0, q_0)$ 是初始置信状态;
- 乘积置信 MDP 的状态转移概率函数定义为:

$$T((b, q), a, (b', q')) = \begin{cases} T, & q = \delta, \\ 1, & b = b' \\ 0, & \text{otherwise;} \end{cases}$$

- $\delta_D^X = \{(d^X, a^X, (d^X)') \in D^X \times A^X \times D^X | T_D^X(d^X, a^X, (d^X)') > 0\}$ 是可行转移集;
- $F_D^X = \{F_0^X, \dots, F_{k-1}^X\}, F_j^X = \{((b, q), a^X, (b', q')) \in \delta_D^X | (q, L_D(b), q') \in F_j\}, \forall j \in \{0, 1, \dots, k-1\}$ 是接受条件。

本文使用 iLTL 而非传统 LTL 与置信 MDP 融合构建乘积置信 MDP, 是因为传统 LTL 需要精确的真实状态 s 以得到自动机所需的标签 L , 故在 POMDP 当中, 无法获得 LTL 需要的标签, 因此 POMDP 生成的置信 MDP 无法与传统 LTL 转化而成的 tLDGBA 融合, 构建出乘积置信 MDP。而 iLTL 的定义域是在分布空间上, 因此其转化成的 tLDGBA 利用概率分布来获取标签 L , 而 POMDP 生成的置信 MDP 的状态恰好是一种概率分布, 故可以与 iLTL 生成的 E-tLDGBA 融合, 构建同时包含系统信息和任务信息的乘积置信 MDP。由于乘积置信 MDP 同时包含了系统的运动建模和任务信息, 故满足 iLTL 约束的 POMDP 策略求解问题转化为了乘积置信 MDP 的策略求解问题。

例 3.4 本例展示乘积置信 MDP 的构建过程, 设 POMDP 对应的置信 MDP 如图 3.6b 所示, iLTL 约束为: $\varphi = \Diamond \Box E[I_a] > 0.95 \wedge \Diamond \Box E[I_b] > 0.95$, 其中 I_a 为示性函数:

$$I_a = \begin{cases} 1, & \text{当智能体处于区域 } a \text{ 时} \\ 0, & \text{其他情况} \end{cases}$$

I_b 与之类似。因此 $E[I_a]$ 与 $E[I_b]$ 分别是智能体处于区域 a 和区域 b 的概率, 即该任务要求智能体以大于 0.95 的概率往返于区域 a 和区域 b 之间。故依据该 iLTL 约束, 可以定义原子函数 $f_a = \int_{s \in S \wedge a \in L(s)} b(s) ds - 0.95$ 和 $f_b = \int_{s \in S \wedge b \in L(s)} b(s) ds - 0.95$ 。iLTL 公式 φ 因此可以表示为 $\varphi = \Diamond \Box f_a \vee \Diamond \Box f_b$, 其转化成的 E-tLDGBA 如图 3.6a 所示。




 图 3.6 iLTL 公式 $\varphi = \Diamond \Box f_a \vee \Diamond \Box f_b$ 对应的 E-tLDGBA 和置信 MDP 场景示例


图 3.7 乘积置信 MDP 示例

根据定义，由该 E-tLDGBA 和置信 MDP 构成的乘积置信 MDP 如图3.7所示，该乘积置信 MDP 具有八个乘积状态，和一个接受集。接受集在图中用带圈数字 1 表示，并且访问接受集的转移用红色箭头表示。虚线箭头表示该乘积置信 MDP 中的一个可行策略，即按照该策略能够最终完成 iLTL 任务。由于 E-tLDGBA 具有两个 ϵ 转移，故将其区分为 ϵ_1, ϵ_2 两个动作。在融合 tLDGBA 之后，乘积置信 MDP 的动作集拓展为 $A = \{u_0, u_1, u_2, \epsilon_1, \epsilon_2\}$ 。在本例中，E-tLDGBA 包含两条 ϵ 转移，这两条 ϵ 转移在乘积 MDP 中被进一步细分为动作 ϵ_1 和 ϵ_2 ，当某个 ϵ 动作被采用时，tLDGBA 状态被更新为该 ϵ 动作对应的自动机状态，即：采取动作 ϵ_1 ，自动机状态转移到 q_1 ；采取动作 ϵ_2 ，tLDGBA 转移到状态 q_2 。 ϵ 动作是一种自动机动作，实施该动作不会对智能体的实际状态产生影响，但会改变其自动机状态，影响智能体对任务进展的判断。在强化学习过程中，判断错误将导致乘积置信 MDP 的路径不再满足 iLTL 约束，从而无法得到回报。因此，为了最大化回报，智能体将在迭代过程中逐渐学习到正确的判断。初始状态 (q_0, b_0) 处的策略为 $\pi(q_0, b_0) = u_0, u_1$ ，采取动作 u_0 或 u_1 后将转移到状态 (q_0, b_0) 或 (q_0, b_1) ，而状

态 (q_0, b_1) 处的策略为 $\pi(q_0, b_0) = \epsilon_2$, 采取动作 ϵ_2 后可转移到状态 (q_2, b_1) , 该状态处的策略为 $\pi(q_2, b_1) = u_2$, 采取动作 u_2 得到的转移位于接受集 F_0 。当到达状态 (q_2, b_1) 后, 只需要不断采取动作 u_2 , 即可不断访问接受集 F_0 , 因此该路径满足 iLTL 任务。

从例 3.4 中我们可以看出, 在时序信息与运动信息的融合过程中, 自动机的形式需要满足一定要求才能够与置信 MDP 进行乘积, 构造乘积置信 MDP。不确定性布奇自动机的转移均为不确定性转移, 因此在构造乘积置信 MDP 时无法定义乘积置信 MDP 的状态转移函数, 因此无法使用; 本文拓展前的 iLDGBA 则因为没有指定每个状态下应该访问的接受集, 虽然能够构造乘积置信 MDP, 但在该乘积置信 MDP 中无法确认每个乘积置信状态下应该访问的接受集, 将会导致在后文的强化学习求解算法当中, 智能体无法访问所有的接受集, 从而导致任务失败。本章设计的 E-iLDGBA 通过指定当前待访问的接受集, 引导智能体访问所有接受集以完成时序任务, 因此能够在不丢失时序任务信息的前提下构建乘积 MDP。在本章所提出的框架下, 可以利用基于强化学习的算法对移动机器人最优策略进行求解。

3.4 本章小结

本章定义了一种基于不等式线性时序逻辑和部分可观马尔可夫决策过程的框架, 该框架能够在不损失时序信息的情况下同时描述机器人的时序任务和机器人的运动建模。该框架由自动机部分和 MDP 部分构成。该框架下的最优策略求解问题将在第 4 章中进行阐述。

本章提出了一种嵌入式有限确定性广义布奇自动机作为该框架的自动机部分。该自动机是有限确定性广义布奇自动机的一种扩展。并且该自动机能够与马尔可夫过程融合, 在融合的过程当中不会损失时序任务信息。对于不同建模方式的部分可观马尔可夫决策过程, 本章提出了基于贝叶斯估计和基于卡尔曼滤波两种构建置信 MDP 的方法, 并将此方法构建的置信 MDP 作为该框架的 MDP 部分。

第4章 乘积置信马尔可夫过程的求解方法

在第3章中,我们提出了一种同时包含了机器人的运动建模和时序任务信息的模型框架,本章将在该框架下求解能够满足时序任务的最优策略。本章首先对基于时序逻辑的部分可观马尔可夫过程的最优策略求解问题进行了定义,并给出一个假设使得该问题有解。之后本章将介绍一种回报函数和折扣函数的设计方法,并严谨地证明了该方法能够在第3章所定义的乘积置信MDP中引导移动机器人解得满足iLTL任务的最优策略。最后,本章提出了一种基于采样点的值迭代算法,并证明了该方法当中价值函数的封闭性。

对于在连续空间上定义的函数,例如置信状态、观察模型、转移模型和奖励模型等,可能具有任意形式,无法用解析形式表示。为了设计连续POMDP的可行算法,至关重要是使用具有简单参数化的函数类,并产生封闭的信念更新和贝尔曼方程。因此,对于连续的POMDP,本章提出了一种基于混合高斯分布(Gaussian Mixture Model, GMM)的方法,运用混合高斯分布对分布进行拟合,并证明了该方法的可行性。

POMDP的主要挑战在于它的状态空间是部分可观测的,并且在每个时间步中,智能体只能观察到部分环境信息。由于这种不完全观测性质,POMDP的状态空间可能非常庞大,因为它要考虑所有可能的环境状态和智能体可能的置信度分布。同时,由于POMDP的动作空间和观察空间也可能很大,这使得在这个空间内寻找最优策略变得非常困难。由于POMDP问题精确求解的复杂性,本章提出了一种基于采样点的近似求解方法。本章提出的基于采样点的值迭代算法,能够近似地求解满足iLTL任务的最优策略。该方法利用乘积置信MDP的值函数是分段线性凸函数的性质对最优值函数进行近似表示,并且通过扩充采样点集与更新价值函数交替进行,实现了计算速度与计算精度的平衡。

4.1 问题描述

本节规范化地提出本章待解决的问题。考虑一个POMDP $\mathcal{M}$ 和 iLTL 公式 ϕ 描述的任务,本章的目标是求解出能够以最大概率满足 iLTL 任务的最优策略 π^* 。

问题1 给定由POMDP $\mathcal{M}$ 和由 iLTL 公式 ϕ 转化得到的自动机 E-iLDGBA $\bar{A}$ 所融合得到的乘积置信 MDP $D^\times$, 提出一个强化学习算法求解最优策略 π^* 的近似解,理论上的最优策略满足:

$$Pr^{\pi^*}(b \models \phi) = Pr_{max}(b \models \phi) \quad (4.1)$$

其中, $Pr^{\pi^*}(b \models \phi) = Pr^{\pi^*}(\sigma \models \phi | \sigma[0] = b)$, $Pr_{max}(b \models \phi) = \max_{\pi} Pr^{\pi}(b \models \phi)$, $\forall b \in \mathcal{R}(b_0)$ 。

4.2 回报结构设计

为使问题1有解, 需要以下假设。

假设 4.1 在由 POMDP $\mathcal{M}$ 和由 iLTL 公式 ϕ 转化得到的自动机 E-tLDGBA $\bar{A}$ 所融合得到的乘积置信 MDP $D^{\times}$ 上至少存在一个满足 iLTL 公式的策略。

给定乘积置信 MDP $D^{\times}$, 考虑一个子乘积置信 MDP $\bar{D}^{\times}(\bar{D}^{\times}, \bar{A}^{\times})$, 其中, $\bar{D}^{\times} \subseteq D^{\times}$, $\bar{A}^{\times} \subseteq A^{\times}$ 。若 $\bar{D}^{\times}$ 是 $D^{\times}$ 的极大强连通分量, 且进入 $\bar{D}^{\times}$ 后无法转移出该子乘积置信 MDP, 则 $\bar{D}^{\times}$ 称为极大结束分量 (Maximum End Component, MEC)。MEC 可以分为三种: 接受极大结束分量 (Accepting Maximum End Component, AMEC), 拒绝极大强连通分量 (Rejecting Maximum End Component, RMEC) 和中立极大强连通分量 (Neutral Maximum End Component, NMEC)^[37]。若 $MEC \bar{D}^{\times}$ 满足 $(\bar{D}^{\times}, \bar{A}^{\times}, \bar{D}^{\times}) \cap \bar{F}_j^{\times} \neq \emptyset, \forall j \in \{0, 1, \dots, k-1\}$, 即该 MEC 与所有接受集的交集均非空, 则 $\bar{D}^{\times}$ 称为 AMEC。根据文献^[37], 存在一个策略使路径进入 AMEC 不再离开 AMEC, 该路径将无限次访问 AMEC 当中的所有转移。因此, 当路径进入 AMEC 后, 智能体能够完成时序任务。RMEC 表示该 MEC 与所有接受集的交集均为空集, NMEC 表示该 MEC 与部分接受集交集非空, 而与部分接受集交集为空。

记乘积置信 MDP $D^{\times}$ 上的一个无记忆策略 π 生成的马尔可夫链为 $MC_{D^{\times}}^{\pi} = (D_{\pi}^{\times}, T_{\pi}^{\times}, d_0^{\times})$, 马尔可夫链 $MC_{D^{\times}}^{\pi}$ 的状态可以划分为互不相交的一个瞬时类 T_{π} 和 n 个不可约常返闭集 $R_{D, \pi}^i, i \in \{1, \dots, n\}$, 即: $D_{\pi}^{\times} = T_{\pi} \cup R_{D, \pi}^1 \cup \dots \cup R_{D, \pi}^n$ 。记一个常返类 $R_{D, \pi}^j$ 中的转移的集合为 $\delta_{D, \pi}^j = \{(d^{\times}, a^{\times}, (d^{\times})') \in \delta_D^{\times} | d^{\times} \in R_{D, \pi}^j\}$ 。本节定义的乘积置信 MDP 有如下特性。

引理 4.1 对于乘积置信 MDP $D^{\times}$, 由策略 π 生成的马尔可夫链 $MC_{D^{\times}}^{\pi}$ 的任何一个常返类满足以下条件之一:

1. $\delta_{D, \pi}^j \cap \bar{F}_i^{\times} \neq \emptyset, \forall i \in \{0, 1, \dots, k-1\}$;
2. $\delta_{D, \pi}^j \cap \bar{F}_i^{\times} = \emptyset, \forall i \in \{0, 1, \dots, k-1\}$ 。

证明 假设存在策略 π , 其生成的马尔可夫链 $MC_{D^{\times}}^{\pi}$ 不满足上述两个条件, 即: $\delta_{D, \pi}^j \cap \bar{F}_i^{\times} \neq \emptyset, \forall i \in I$, 其中 I 为集合 $2^{\{0, 1, \dots, k-1\}} \setminus \{\{0, 1, \dots, k-1\}, \emptyset\}$ 的一个子集。对于常返类中的每个状态 $(d^{\times}, a^{\times}, (d^{\times})') \in \delta_{D, \pi}^j \cap \bar{F}_i^{\times}$, 有 $\sum_{k=0}^{\infty} p^k(d^{\times}, d^{\times}) = \infty$, 其中 $(d^{\times}, a^{\times}, (d^{\times})') \in \delta_{D, \pi}^j \cap \bar{F}_i^{\times}$, 并且 $p^k(d^{\times}, d^{\times})$ 表示了系统从状态 $d^{\times}$ 出发, 经过 k 步回到状态 $d^{\times}$ 的概率。故 $\sum_{k=0}^{\infty} p^k(d^{\times}, d^{\times}) = \infty$ 说明常返状态 $d^{\times}$ 能被无限次访问。由于常返类的转移集合仅有部分位于 tLDGBA 的所有接受集当中, 因

此 tLDGBA 的所有接受集无法被全部访问,即无法完成一个回合,故 E-tLDGBA 的边界记录集 T 无法重置。因此 E-tLDGBA 的状态 v 的部分将不会改变,使得乘积置信状态 $d^\times$ 无法再次被访问,而常返状态要求 $\sum_{k=0}^{\infty} p^k(d^\times, d^\times) = \infty$, 即该乘积置信状态 $d^\times$ 能够无限次被访问,故矛盾。 ■

由引理4.1可知,对任意策略,乘积置信 MDP 的全部接受集有两种可能,一种情况是全部接受集是该策略生成的马尔可夫链的瞬时类的子集,另一种可能为乘积置信 MDP 的全部接受集是该策略生成的马尔可夫链的某个能访问全部接受集的常返类的子集。

根据乘积置信 MDP 的状态转移是否位于该乘积置信 MDP 的接受集中,可以依照下列方法设计回报函数和折扣函数:

$$R_{D^\times} = \begin{cases} 1 - \gamma_{D^\times}, & (d^\times, a^\times, (d^\times)') \in F_{D^\times}^\times; \\ 0, & \text{其他.} \end{cases} \quad (4.2)$$

$$\Gamma_{D^\times} = \begin{cases} \gamma_{D^\times}, & (d^\times, a^\times, (d^\times)') \in F_{D^\times}^\times; \\ \gamma_b, & \text{其他.} \end{cases} \quad (4.3)$$

公式4.2和公式4.3当中, $\gamma_{D^\times} = \gamma_{D^\times}(\gamma_b)$ 是关于 γ_b 的函数,且该函数满足:

$$\lim_{\gamma_b \rightarrow 1^-} \frac{1 - \gamma_b}{1 - \gamma_{D^\times}(\gamma_b)} = 0. \quad (4.4)$$

给定乘积置信 MDP 的一条路径 $\sigma_{D^\times} = d_0^\times d_1^\times \dots$, 则该路径的累计折扣回报为:

$$G_t(\sigma_{D^\times}) = \sum_{i=0}^{\infty} R_{D^\times}(\sigma_{D^\times}[t+i]) \cdot \prod_{j=0}^{i-1} \Gamma_{D^\times}(\sigma_{D^\times}[t+j]) \quad (4.5)$$

并规定 $\prod_{j=0}^{-1} = 1$, 则期望累计折扣回报可以定义为:

$$V^\pi(d_t^\times) = \mathbb{E}^\pi[G_t(\sigma_{D^\times}) | \sigma_{D^\times}(t) = d_t^\times]. \quad (4.6)$$

回报黑客问题^[78-79]是指智能体在强化学习过程中只注重于获得最大化累计回报的策略,而无法得到期望的满足 iLTL 任务的策略。因此,本节利用乘积置信 MDP 的接受条件对回报函数和折扣函数进行了设计,使得最大化期望累计折扣回报的策略就是最大化满足 iLTL 任务概率的策略,从而解决了回报黑客问题。

引理 4.2 对乘积置信 MDP 当中的任意路径 $\sigma_{D^\times}$ 和该路径下的智能体获得的累计折扣回报 $G_t(\sigma_{D^\times})$, 有以下性质:

$$0 \leq \gamma_b G_{t+1}(\sigma_{D^\times}) \leq G_t(\sigma_{D^\times}) \leq 1 - \gamma_{D^\times} + \gamma_{D^\times} G_{t+1}(\sigma_{D^\times}) \leq 1. \quad (4.7)$$

证明 由于回报函数 $R_{D^x} \geq 0$, 因此累计回报 $G_t(\sigma_{D^x})$ 总是大于等于 0。而根据累计回报函数和折扣函数的定义, 若令 $\gamma_b = 1$, 我们可以得到一个更大或者相等的回报, 故可以得到累计回报的上界: $G_t(\sigma_{D^x}) \leq 1 - \gamma_{D^x}^n \leq 1$, 其中 n 为接受集的访问次数。而累计折扣 $G_t(\sigma_{D^x})$ 满足以下等式:

$$G_t(\sigma_{D^x}) = \begin{cases} 1 + \gamma_{D^x}(G_{t+1}(\sigma_{D^x}) - 1), & (\sigma_{D^x}[t], a^x, \sigma_{D^x}[t+1]) \in F_{D^x} \\ \gamma_b G_{t+1}(\sigma_{D^x}), & (\sigma_{D^x}[t], a^x, \sigma_{D^x}[t+1]) \notin F_{D^x} \end{cases} \quad (4.8)$$

根据 $G_t(\sigma_{D^x}) \leq 1$, 有 $1 + \gamma_{D^x}(G_{t+1}(\sigma_{D^x}) - 1) \geq \gamma_b G_{t+1}(\sigma_{D^x})$, 因此得证。 ■

引理 4.3 对乘积置信 MDP D^x , 由策略 π 引导产生的 AMEC 为 $AMEC_{D^x}^\pi = (D_{AMEC}^\pi, A_{AMEC}^\pi)$, 其中 D_{AMEC}^π 是 AMEC 的状态集, A_{AMEC}^π 是受限动作集。记 $\delta_{D^x}^\pi = \{(d^x, a^x, (d^x)') \in \delta_D^x | (d^x, a^x) \in AMEC_{D^x}^\pi; (d^x, a^x, (d^x)') \in \bar{F}_j^x, j \in \{0, 1, \dots, k-1\}\}$ 为满足该策略 π 并处于 D^x 接受集的转移的集合, 则对于该集合中的任一元素 $\forall (d^x, a^x, (d^x)') \in \delta_{D^x}^\pi$, 有 $\lim_{\gamma_b \rightarrow 1^-} V^\pi(d^x) = 1$ 。

证明 根据期望累计回报的定义, 状态 d^x 的期望累计折扣回报为:

$$V^\pi(d^x) = \mathbb{E}^\pi[G_t(\sigma_{D^x}) | \sigma_{D^x}(t) = d^x] = 1 - \gamma_{D^x} + \gamma_{D^x} \mathbb{E}^\pi[G_{t+1}(\sigma_{D^x}) | \sigma_{D^x}(t) = d^x]$$

由于 $d^x \in D_{AMEC}^\pi$, 故从 d^x 出发可以再次访问 d^x , 并且由于 $(d^x, a^x, (d^x)') \in \bar{F}_j^x$, 根据乘积置信 MDP 的性质, 我们可以得到在从 d^x 出发到再次访问 d^x 之间, 乘积置信 MDP 的所有接受集均已被访问, 故智能体在此过程中能够得到正回报。记 N_D^t 为时刻 t 从 d^x 出发后再次访问 d^x 的时间, 即 $N_D^t = \min\{t' | \sigma_{D^x}[t+t'] = d^x, t' > 0\}$ 。根据引理 4.2、回报函数和折扣函数的定义, 有:

$$\begin{aligned} V^\pi(d^x) &= 1 - \gamma_{D^x} + \gamma_{D^x} \mathbb{E}^\pi[G_{t+1}(\sigma_{D^x}) | \sigma_{D^x}[t] = d^x] \\ &\geq 1 - \gamma_{D^x} + \gamma_{D^x} \mathbb{E}^\pi[\gamma_b^{N_D^t-1} G_{t+N_D^t}(\sigma_{D^x}) | \sigma_{D^x}[t] = d^x] \\ &\geq 1 - \gamma_{D^x} + \gamma_{D^x} \mathbb{E}^\pi[\gamma_b^{N_D^t-1} | \sigma_{D^x}[t] = d^x] V^\pi(d^x) \\ &\geq 1 - \gamma_{D^x} + \gamma_{D^x} \gamma_b^{\mathbb{E}^\pi[N_D^t-1 | \sigma_{D^x}[t]=d^x]} V^\pi(d^x) \\ &\geq 1 - \gamma_{D^x} + \gamma_{D^x} \gamma_b^{n_D^t} V^\pi(d^x) \end{aligned} \quad (4.9)$$

其中, 第二个不等号根据马尔可夫性和 $\sigma_{D^x}[t+N_D^t] = d^x$ 成立, 第三个不等号为琴生不等式, 最终式中的常数 $n_D^t \geq 1$ 。将上式化简可得

$$V^\pi(d^x) \geq \frac{1 - \gamma_{D^x}}{1 - \gamma_{D^x} n_D^t} \geq \frac{1}{1 - n_D^t \frac{1-\gamma_b}{1-\gamma_{D^x}} - n_D^t (1-\gamma_b)} \quad (4.10)$$

由公式 (4.4) 和公式 (4.10) 以及 $V^\pi(d^x) \leq 1$ 可得 $\lim_{\gamma_b \rightarrow 1^-} V^\pi(d^x) = 1$ 。 ■

基于上述引理,可以得到在该回报设计下,当折扣因子满足一定条件时,期望累计折扣回报将趋向于该策略 π 下访问接受集的概率。

定理 4.4 给定乘积置信 MDP $D^\times = D \times \bar{A}_\phi$, 对任意乘积置信状态 $d^\times = (b, (v, q)) \in D^\times$, 基于策略 π 得到的期望回报 $V^\pi(d^\times)$ 满足 $\lim_{\gamma_b \rightarrow 1^-} V^\pi(d^\times) = Pr^\pi(\diamond \bar{F}_v^\times)$, 其中 $Pr^\pi(\diamond \bar{F}_v^\times)$ 表示一条路径从 $d^\times$ 出发, 最终能够访问接受集 $\bar{F}_v^\times$ 的概率。

证明 根据从 $d^\times$ 出发的路径是否访问接受集 $\bar{F}_v^\times$, 可以判断该路径的期望回报为:

$$\begin{aligned} V^\pi(d^\times) = & \mathbb{E}^\pi[G_t(\sigma_{D^\times}) | \sigma_{D^\times}[t] = d^\times, \sigma_{D^\times} \models \diamond \bar{F}_v^\times] \cdot Pr^\pi(\sigma_{D^\times} \models \diamond \bar{F}_v^\times) \\ & + \mathbb{E}^\pi[G_t(\sigma_{D^\times}) | \sigma_{D^\times}[t] = d^\times, \sigma_{D^\times} \not\models \diamond \bar{F}_v^\times] \cdot Pr^\pi(\sigma_{D^\times} \not\models \diamond \bar{F}_v^\times) \end{aligned} \quad (4.11)$$

其中 $Pr^\pi(\sigma_{D^\times} \models \diamond \bar{F}_v^\times) Pr^\pi(\sigma_{D^\times} \not\models \diamond \bar{F}_v^\times)$ 分别为访问接受集 $\bar{F}_v^\times$ 和不访问接受集 $\bar{F}_v^\times$ 的概率。

记智能体从 $\sigma_{D^\times}[t] = d^\times$ 出发后, 首次访问集合 $\delta_{D^\times}^\pi = \{(d^\times, a^\times, (d^\times)') \in \delta_D^\times | (d^\times, a^\times) \in AMEC_{D^\times}^\pi; (d^\times, a^\times, (d^\times)') \in \bar{F}_j^\times, j \in \{0, 1, \dots, k-1\}\}$ 所需的时间为 N , 即: $N = \min\{t' | (\sigma_{D^\times}[t+t'], a^\times, \sigma_{D^\times}[t+t'+1]) \in \delta_{D^\times}^\pi\}$, 则有:

$$\begin{aligned} & \mathbb{E}^\pi[G_t(\sigma_{D^\times}) | \sigma_{D^\times}[t] = d^\times, \sigma_{D^\times} \models \diamond \bar{F}_v^\times] \\ & \geq \mathbb{E}^\pi[G_t(\sigma_{D^\times}) | \sigma_{D^\times}[t] = d^\times, (\sigma_{D^\times}[t+t'], a^\times, \sigma_{D^\times}[t+t'+1]) \in \delta_{D^\times}^\pi] \\ & \geq \mathbb{E}^\pi[\gamma_b^N G_{t+N}(\sigma_{D^\times}) | \sigma_{D^\times}[t] = d^\times, (\sigma_{D^\times}[t+t'], a^\times, \sigma_{D^\times}[t+t'+1]) \in \delta_{D^\times}^\pi] \\ & \geq \mathbb{E}^\pi[\gamma_b^N | \sigma_{D^\times}[t] = d^\times, (\sigma_{D^\times}[t+t'], a^\times, \sigma_{D^\times}[t+t'+1]) \in \delta_{D^\times}^\pi] \\ & \quad \cdot V^\pi(\sigma_{D^\times}[t+N]) \\ & \geq \gamma_b^N \mathbb{E}^\pi[N | \sigma_{D^\times}[t] = d^\times, (\sigma_{D^\times}[t+t'], a^\times, \sigma_{D^\times}[t+t'+1]) \in \delta_{D^\times}^\pi] \cdot V^\pi(\sigma_{D^\times}[t+N]) \\ & \geq \gamma_b^n \cdot V^\pi(\sigma_{D^\times}[t+N]) \end{aligned} \quad (4.12)$$

由于 $\bar{F}_v^\times$ 中的转移可能出现在 $AMEC_{D^\times}^\pi$ 和 $RMEC_{D^\times}^\pi$ 中, 故第一个不等式成立; 第二个不等式根据引理4.2成立; 第三个不等式可以由马尔可夫性得到; 第四个不等式为琴生不等式; 第五个不等式中的 n 为常数。根据引理4.3和公式 (4.11), 可以得到 $V^\pi(d^\times)$ 的下界:

$$V^\pi(d^\times) \geq \gamma_b^n \cdot V^\pi(\sigma_{D^\times}[t+N]) \cdot Pr^\pi(\sigma_{D^\times} \models \diamond \bar{F}_v^\times) \quad (4.13)$$

类似的, 记 M 为智能体从 $\sigma_{D^\times}[t] = d^\times$ 出发后, 首次访问 $RMEC_{D^\times}^\pi$ 的时间,

则有:

$$\begin{aligned}
 & \mathbb{E}^\pi[G_t(\sigma_{D^\times}) | \sigma_{D^\times}[t] = d^\times, \sigma_{D^\times} \not\models \diamond \bar{F}_v^\times] \\
 & \leq \mathbb{E}^\pi[1 - \gamma_{D^\times}^M (1 - G_{t+M}(\sigma_{D^\times})) | \sigma_{D^\times}[t] = d^\times, \sigma_{D^\times} \not\models \diamond \bar{F}_v^\times] \\
 & \leq \mathbb{E}^\pi[1 - \gamma_{D^\times}^M | \sigma_{D^\times}[t] = d^\times, \sigma_{D^\times} \not\models \diamond \bar{F}_v^\times] \\
 & \leq 1 - \gamma_{D^\times}^{\mathbb{E}^\pi[M | \sigma_{D^\times}[t] = d^\times, \sigma_{D^\times} \not\models \diamond \bar{F}_v^\times]} \\
 & = 1 - \gamma_{D^\times}^m
 \end{aligned} \tag{4.14}$$

其中推导过程与之前类似, m 为一常数。故 $V^\pi(d^\times)$ 的上界为:

$$V^\pi(d^\times) \leq Pr^\pi(\sigma_{D^\times} \models \diamond \bar{F}_v^\times) + (1 - \gamma_{D^\times}^m) Pr^\pi(\sigma_{D^\times} \not\models \diamond \bar{F}_v^\times) \tag{4.15}$$

综上, 根据式 (4.13)、式 (4.15) 和引理4.3, 可以得到 $\lim_{\gamma_b \rightarrow 1^-} V^\pi(d^\times) = Pr^\pi(\diamond \bar{F}_v^\times)$ 。 ■

该定理表明, 当折扣函数中的 γ_b 从左侧逼近 1 时, 状态 $d^\times = (b, (v, q))$ 处的期望累计折扣回报将趋向于从该状态出发的路径访问当前需要访问的接受集 $\bar{F}_v^\times$ 的概率。根据引理4.1和定理4.4, 可以得到期望累计折扣回报与满足 iLTL 公式之间的联系。以下定理证明了在本章提出的回报设计当中, 优化期望累计折扣回报等同于优化满足时序任务的概率。

定理 4.5 给定乘积置信 MDP $D^\times = D \times \bar{A}_\phi$, 存在一个折扣因子 $\underline{\gamma}$, 使得对任意满足 $\gamma_b > \underline{\gamma}$ 和 $\gamma_{D^\times} > \underline{\gamma}$ 的强化学习算法, 该算法能够在 $D^\times$ 上得到无记忆策略 π^* , 并且该策略 π^* 能够生成满足乘积置信 MDP $D^\times$ 的接受条件的路径 $\sigma_{D^\times}^{\pi^*}$ 。若该算法还满足 $\gamma_b \rightarrow 1^-$, 则得到的最优策略 π^* 能够最大化满足 iLTL 公式 ϕ 的概率, 即: $Pr^{\pi^*}(d^\times \models \phi) = Pr_{max}(d^\times \models \phi)$ 。

证明 此处我们将利用反证法进行证明。假设存在一个通过强化学习得到的最优策略 π^* , 该策略不满足乘积置信 MDP 的接受条件, 并具有最大的期望累计折扣回报。根据前提假设, 乘积置信 MDP 上至少存在一个策略 π 满足乘积置信 MDP 的接受条件, 若该策略 π 获得的累计期望回报大于最优策略 π^* 的累计期望回报, 则与假设当中最优策略能够最大化期望累计折扣回报矛盾, 从而证明了本定理。

对任意策略 π' 生成的马尔可夫链 $MC_{D^\times}^{\pi'}$, 其状态集可划分为 $D_{\pi'}^\times = \mathcal{T}_{D, \pi'} \cup R_{D, \pi'}^1 \cup \dots \cup R_{D, \pi'}^n$ 。对策略 π^* , 根据引理4.1有: $\delta_{D, \pi'}^i \cap \bar{F}_i^\times = \emptyset, \forall i \in \{0, 1, \dots, k-1\}$ 。现在考虑一个乘积置信状态 $d_R^\times \in R_{D, \pi'}^k$, 根据常返类 $R_{D, \pi'}^k$ 的定义, 从 $d_R^\times$ 开始的转移只会发生在 $R_{D, \pi'}^k$ 中并且不会访问任何接受集, 故 $d_R^\times$ 在策略 π^* 下的期望回报为:

$$V^{\pi^*}(d_R^\times, d^\times) = \sum_{n=0}^{\infty} \gamma_b^n \cdot \sum_{d_R^\times \in R_{D, \pi'}^k} P_{\pi^*}^n(d_R^\times, d^\times) R_{D^\times}(d^\times) = 0 \tag{4.16}$$

其中, $P_{\pi^*}^n(d_R^{\times}, d^{\times})$ 是在策略 π^* 下, 从 $d_R^{\times}$ 触发经过 n 步到达 $d^{\times}$ 的概率。对任何一个满足 $D^{\times}$ 接受条件的策略 π' 生成的马尔科夫链 $MC_{D^{\times}}^{\pi'}$, 存在一个常返类 $R_{D, \pi}^I$, 满足该常返类与乘积置信 MDP 接受集的交集非空, 即 $R_{D, \pi}^I \cap \bar{F}_i^{\times} \neq \emptyset, \forall i \in \{0, 1, \dots, k-1\}$ 。记 $\underline{\gamma}$ 为折扣函数 $\Gamma_{D^{\times}}$ 的下界。

1. $d_R^{\times} \in R_{D, \pi}^I$

根据常返类 $R_{D, \pi}^I$ 的性质, 存在 $(d_R^{\times})', (d_R^{\times})'' \in R_{D, \pi}^I$ 使得 $((d_R^{\times})', a^{\times}, (d_R^{\times})'') \in \delta_{D, \pi}^I \cap \bar{F}_i^{\times}$ 并且从 $d_R^{\times}$ 到达 $(d_R^{\times})'$ 的概率非 0, 由此可得:

$$\begin{aligned} V^{\pi}(d_R^{\times}) &= \sum_{n=0}^{\infty} \sum_{d^{\times} \in R_{D, \pi}^I} P_{\pi}^n(d_R^{\times}, d^{\times}) R_{D^{\times}}(d^{\times}) \\ &\quad \cdot \prod_{(d^{\times})' \in \text{path}_{D^{\times}}^n(d_R^{\times}, d^{\times})} \Gamma_{D^{\times}}((d^{\times})') \\ &\geq \sum_{n=0}^{\infty} \underline{\gamma}^n P_{\pi}^n(d_R^{\times}, (d_R^{\times})') (1 - \gamma_{D^{\times}}) \\ &> 0 \end{aligned} \quad (4.17)$$

其中, $\text{path}_{D^{\times}}^n(d_R^{\times}, d^{\times})$ 表示从 $d_R^{\times}$ 经过 n 步到达 $d^{\times}$ 的路径, 当 $n=0$ 时, 规定 $\prod_{(d^{\times})' \in \text{path}_{D^{\times}}^n(d_R^{\times}, d^{\times})} \Gamma_{D^{\times}}((d^{\times})') = 1$, 因此有 $V^{\pi}(d_R^{\times}) > V^{\pi^*}(d_R^{\times})$ 。

2. $d_R^{\times} \in \mathcal{T}_{\pi}$

由于策略 π 满足乘积置信 MDP 的接受条件, 故存在常数 $\bar{k} \geq 1$, 使得从 $d_R^{\times}$ 出发的路径经过 $\bar{k}$ 步能够进入 $R_{D, \pi}^I$, 记到达的状态为 $(d_R^{\times})' \in R_{D, \pi}^I$ 。此外, 对于任意常返态 $d^{\times} \in R_{D, \pi}^I$, 总有 $\sum_{n=0}^{\infty} \gamma^n p^n(d^{\times}, d^{\times}) > \frac{\bar{p}}{1 - \gamma^{\bar{n}}}$, 其中存在 $\bar{n}$ 使得 $\gamma^n p^n(d^{\times}, d^{\times}) > 0$ 并且下界为 $\bar{p}$ 。忽略从 $d_R^{\times}$ 出发经过 $\bar{k}$ 步得到的路径的回报, 可以得到:

$$\begin{aligned} V^{\pi}(d_R^{\times}) &\geq \prod_{i=1}^{\bar{k}} \Gamma_{D^{\times}}(d_i^{\times}) \cdot P_{\pi}^{\bar{k}}(d_R^{\times}, (d_R^{\times})') \cdot \sum_{n=0}^{\infty} \sum_{d^{\times} \in R_{D, \pi}^I} \prod_{j=0}^{n-1} \Gamma_{D^{\times}}(d_j^{\times}) \cdot \\ &\quad P_{\pi}^n((d_R^{\times})', d^{\times}) R_{D^{\times}}(d^{\times}) \\ &> \underline{\gamma}^{\bar{k}} P_{\pi}^{\bar{k}}(d_R^{\times}, (d_R^{\times})') \cdot \sum_{n=0}^{\infty} \underline{\gamma}^n P_{\pi}^n((d_R^{\times})', d^{\times}) (1 - \gamma_{D^{\times}}) \\ &> \underline{\gamma}^{\bar{k}} P_{\pi}^{\bar{k}}(d_R^{\times}, (d_R^{\times})') \cdot \frac{\bar{p}}{1 - \gamma^{\bar{n}}} (1 - \gamma_{D^{\times}}) \end{aligned} \quad (4.18)$$

因此, 存在 $\underline{\gamma} < 1$, 使得当 $\gamma_b > \underline{\gamma}$ 和 $\gamma_{D^{\times}} > \underline{\gamma}$ 时, 有:

$$V^{\pi}(d_R^{\times}) > \underline{\gamma}^{\bar{k}} P_{\pi}^{\bar{k}}(d_R^{\times}, (d_R^{\times})') \cdot \frac{\bar{p}}{1 - \gamma^{\bar{n}}} (1 - \gamma_{D^{\times}}) \geq 0$$

在这两种情况下，均可以证明 $V^\pi(d_R^\times) > V^{\pi^*}(d_R^\times)$ ，与 π^* 是能够获得最大期望累计回报的最优策略矛盾。因此，存在一个满足 $D^\times$ 接受条件的最优策略 π^* ，而根据定理4.4，对策略 π^* 有 $\lim_{\gamma_b \rightarrow 1^-} V^\pi(d^\times) = Pr^\pi(\diamond \bar{F}_b^\times)$ ，说明了当 γ_b 趋向于 1 时，最大化期望回报即为最大化访问当前需要访问的接受集的概率，能够得到结论 $Pr^{\pi^*}(d^\times \models \phi) = Pr_{max}(d^\times \models \phi)$ 。 ■

定理4.5说明在本章提出的回报设计当中，优化期望累计折扣回报等同于优化满足时序任务的概率。因此通过强化学习算法得到的智能体策略即为能够以最大概率满足 iLTL 任务的最优策略。接下来，本章将提出一种具体的基于强化学习的乘积置信 MDP 求解算法。

4.3 基于采样点的值迭代方法

本小节使用强化学习中的值迭代算法在乘积置信 MDP 中求解满足 iLTL 任务的策略。基于上一节设计的折扣函数与回报函数，以及贝尔曼最优方程，乘积置信状态 $d^\times = (b, \bar{q}) = (b, (v, q))$ 处的最优值函数为：

$$V^*(b, \bar{q}) = \max_{a^\times \in A^\times} [R_{D^\times}(b, \bar{q}) + \Gamma_{D^\times}(b, \bar{q}) \sum_{b' \in B} \sum_{\bar{q}' \in \bar{Q}} T_{D^\times}((b, \bar{q}), a^\times, (b', \bar{q}')) V^*(b', \bar{q}')] \quad (4.19)$$

根据乘积置信 MDP 的定义，在乘积置信状态 $d^\times = (b, \bar{q})$ 处，若采取动作 $a^\times \in A$ ，则有 $\bar{q}' = \bar{\delta}(\bar{q}, L_D(b))$ ；若采取动作 $a^\times \in A^\epsilon$ ，则有 $\bar{q}' = \bar{\delta}(\bar{q}, \epsilon_{\bar{q}'})$ ，即乘积置信状态当中的自动机状态分量始终具有唯一确定的转移，故公式 (4.19) 可简化为：

$$V^*(b, \bar{q}) = \max_{a^\times \in A^\times} [R_{D^\times}(b, \bar{q}) + \Gamma_{D^\times}(b, \bar{q}) \sum_{b' \in B} T_{D^\times}((b, \bar{q}), a^\times, (b', \bar{q}')) V^*(b', \bar{q}')] \quad (4.20)$$

因此可以使用标准值迭代算法得到以任意精度接近最优值函数的近似最优值函数：其中 Δ 表示了该算法在对最优值函数进行近似时需要的精度。在该标

算法 4.1 标准值迭代算法

输入：乘积置信 MDP $D^\times$

输出：价值函数 V

1 初始化 $V_0(d^\times), \forall d^\times \in D^\times$;

2 初始化 $t = 0$;

3 repeat

4 $t \leftarrow t + 1$;

5 for all $d^\times \in D^\times$ do

6 $V_t(d^\times) = \max_{a^\times \in A^\times} [R_{D^\times}(d^\times) + \Gamma_{D^\times}(d^\times) \sum_{b' \in B} T_{D^\times}(d^\times, a^\times, (d^\times)') V_{t-1}((d^\times)')]$;

7 end

8 until $|V_t(d^\times) - V_{t-1}(d^\times)| < \Delta, \forall d^\times \in D^\times$;

准值迭代算法中，需要为置信状态空间当中的每一个点进行值函数维护，而由于置信状态空间为连续空间，其中的置信点有无穷多个，因此无法对所有点都进行

迭代, 导致了该算法无法实际应用于 POMDP 求解中。因此, 需要一种方式对置信空间中所有点的价值函数进行表示, 而置信 MDP 的一种性质可以解决值函数的表示形式问题。

由于在离散 POMDP 当中, 每个置信状态的值函数均为分段线性的凸函数, 因此可以表示为一组值函数向量, 即 $V^*(b) = \max_{\alpha \in A} (\alpha \cdot b)$, 图4.1是一维环境当中该方法的示意图。每一个向量都代表信念状态空间里的一个超平面, 对于每个状态而言, 选择最佳 α 向量同样也代表了在当前信念状态下的最优动作。然而, 尽管值函数的更新能够通过更新 α 向量来得到, 一方面, α 向量个数的增长是指数级的, 另一方面, α 向量的更新方法依旧是对置信状态空间当中的所有点进行更新。因此, 这种方法对于状态空间较大的 POMDP 问题是无法计算的。




图 4.1 α 向量示意图

基于采样点的方法是当前近似求解 POMDP 问题的一种高效并且实用的方法。该方法通过有限的置信状态采样集合对整个信念空间进行近似, 同时基于置信状态采样集合的值对整个策略空间的值函数进行近似。该方法不同于使用已知置信状态的价值通过插值对未知置信状态的价值函数进行计算, 而是通过已知置信状态对 α 函数进行更新, 再利用 α 函数对未知置信状态的值进行计算, 因此在整个信念空间当中具有更好的泛化性。图4.2给出了一个基于采样点的值迭代方法与精确值迭代方法的对比, 图 (a) 中显示了确切值函数, 剪枝后有 120 个约束。图 (b) 是基于采样点算法的结果, 最终只保留了 11 个线性函数。这两种方法在控制上基本没有差别。

类似的, 在连续 POMDP 当中, 基于采样点的方法仍然能够发挥作用。连续 POMDP 的值函数同样是凸的, 并且是 PWLC 的。因此, 在连续 POMDP 所生成的置信 MDP 上, 其 n 步最优价值函数 V_n 也能够使用一系列 α 函数进行表达, 即 $V_n(b) = \max_{\alpha_n^i \in A_n} \langle \alpha_n^i, b \rangle$, 其中 $\langle f, b \rangle$ 用于表示在由样本空间 S 和概率分布 b 定义的




图 4.2 基于采样点的值迭代方法与精确值迭代方法的对比

概率空间中函数 f 的期望值，对于连续状态的 POMDP，该算子定义为

$$\langle f, b \rangle = \int_{s \in S} f(s) b(s) ds \quad (4.21)$$

而对于离散状态的 POMDP，该算子定义为

$$\langle f, b \rangle = \sum_{s \in S} f(s) \cdot b(s) \quad (4.22)$$

连续 POMDP 当中的 α 函数与离散 POMDP 当中的 α 向量相对应，能够收敛到一个单一的不动点，即最优值函数 V^* 。

除了 POMDP 环境本身带来的挑战以外，还需要 iLTL 所描述的复杂任务。针对第 3 章构建的同时包含置信 MDP 和由 iLTL 公式生成的 E-tLDGBA 的乘积置信 MDP，本节提出了一种基于采样点的值迭代算法，能够解决移动机器人在 POMDP 环境中完成复杂时序任务的运动规划问题。

在乘积置信 MDP $D^\times = D \times \bar{A}_\phi$ 中，其状态 $d^\times = (b, \bar{q})$ 具有置信状态和自动机状态两个分量，因此乘积置信状态的 α 函数集合可以根据不同的自动机状态划分为 $A = \{A_{\bar{q}_0}, A_{\bar{q}_1}, \dots\}$ ，故乘积置信状态 $d^\times$ 的值函数可以表示为：

$$V(d^\times) = V((b, \bar{q})) = \max_{\alpha_{\bar{q}}^i \in A_{\bar{q}}} \langle \alpha_{\bar{q}}^i, b \rangle \quad (4.23)$$

使用 α 函数表示最优值函数后， n 步迭代的值函数可转化为用 α 函数表示的形式。在乘积置信状态 $d^\times = (b, \bar{q})$ 处，其动作集包含 POMDP 动作与自动机动作两个集合，即 $A^\times = A \cup A^e$ 。

当采取 POMDP 动作 $a^\times \in A$ 时，动作值函数可以写成如下形式：

$$Q((b, \bar{q}), a^\times) = R_{D^\times}(b, \bar{q}) + \Gamma_{D^\times}(b, \bar{q}) \int_{b' \in B} T_{D^\times}((b, \bar{q}), a^\times, (b', \bar{q}')) V^*(b', \bar{q}') db' \quad (4.24)$$

根据乘积置信 MDP 的状态转移公式, 可以得知, 仅当 $(b', \bar{q}') = (b^{a^x, o}, \bar{\delta}(\bar{q}, L_D(b)))$ 时, $T_{D^x}((b, \bar{q}), a^x, (b', \bar{q}'))$ 不为 0, 因此有:

$$Q((b, \bar{q}), a^x) = R_{D^x}(b, \bar{q}) + \Gamma_{D^x}(b, \bar{q}) \int_{o \in Z} Pr(o|b, a^x) V^*(b^{a^x, o}, \bar{q}') do \quad (4.25)$$

当观测集为离散集合时, 式 (4.25) 当中对 o 进行的积分将替换为对所有 o 的求和。式 (4.25) 当中 $(b^{a^x, o}, \bar{q}')$ 的最优值函数为:

$$\begin{aligned} V^*(b^{a^x, o}, \bar{q}') &= \max_{\alpha_{\bar{q}'}^i \in A_{\bar{q}'}} \langle \alpha_{\bar{q}'}^i, b^{a^x, o} \rangle \\ &= \frac{1}{Pr(o|b, a^x)} \max_{\alpha_{\bar{q}'}^i \in A_{\bar{q}'}} \int_{s'} \alpha_{\bar{q}'}^i(s') Pr(o|s') Pr(s'|b, a^x) ds' \end{aligned} \quad (4.26)$$

代入可得:

$$\begin{aligned} Q((b, \bar{q}), a^x) &= R_{D^x} + \Gamma_{D^x} \int_o \max_{\alpha_{\bar{q}'}^i \in A_{\bar{q}'}} \int_{s'} \alpha_{\bar{q}'}^i(s') Pr(o|s') Pr(s'|b, a^x) ds' do \\ &= R_{D^x} + \Gamma_{D^x} \int_o \max_{\alpha_{\bar{q}'}^i \in A_{\bar{q}'}} \int_{s'} \alpha_{\bar{q}'}^i(s') Pr(o|s') \left[\int_s Pr(s'|s, a^x) b(s) ds \right] ds' do \quad (4.27) \\ &= R_{D^x} + \Gamma_{D^x} \int_o \max_{\alpha_{\bar{q}'}^i \in A_{\bar{q}'}} \left\langle \int_{s'} \alpha_{\bar{q}'}^i(s') Pr(o|s') Pr(s'|s, a^x) ds', b \right\rangle do \end{aligned}$$

其中, $R_{D^x} = R_{D^x}(b, \bar{q})$, $\Gamma_{D^x} = \Gamma_{D^x}(b, \bar{q})$ 。

而当采取自动机动作 $a^x = \epsilon_{\bar{q}'} \in A^\epsilon$ 时, 由于其置信状态保持不变, 自动机状态从 $\bar{q}$ 转移到 $\bar{q}'$, 故新的乘积置信状态为 $(d^x)' = (b, \bar{q}')$ 。由于 ϵ 转移是自动机对于任务进度进行的猜测, 在当前乘积置信状态能够通过一步转移访问接受集时不会采用, 故具有 ϵ 转移的乘积置信状态处的任何转移均不可能访问接受集。因此, 其回报函数和折扣函数分别为 $R_{D^x}(b, \bar{q}) = 0$ 和 $\Gamma_{D^x}(b, \bar{q}) = \gamma_b$, 故有:

$$Q((b, \bar{q}), a^x) = \gamma_b \max_{\alpha_{\bar{q}'}^i \in A_{\bar{q}'}} \langle \alpha_{\bar{q}'}^i, b \rangle \quad (4.28)$$

综上, 可以得到乘积置信状态 $(b, \bar{q})$ 处的最优值函数:

$$V^*(b, \bar{q}) = \max_{a^x \in A^x} Q(b, \bar{q}, a^x) \quad (4.29)$$

本章提出的基于采样点的值迭代算法包含两个阶段, 第一个阶段为 α 函数更新, 第二个阶段为乘积置信点集扩充。首先对乘积置信采样点集当中的每个点通过模拟转移的方式对整个 α 函数集进行更新, 更新 α 函数集之后, 通过探索的方式得到新的乘积置信状态, 并选择部分加入乘积置信采样点集当中。在反复循环这两步之后, 最终得到的值函数将逐渐收敛于最优值函数, 从而得到满足乘积置信 MDP 接受条件的解。

给定乘积置信点集 $\{d_i^x\}$, 对 $\{d_i^x\}$ 中的每一个乘积置信点 $(b, \bar{q})$ 更新该点的 α 函数, 假设上一步 α 函数集为 $A = \{A_{\bar{q}_0}, A_{\bar{q}_1}, \dots\}$, 则具体的更新步骤如下:

1. 当采取 POMDP 动作 $a^x \in A$ 时, 令

$$\alpha_{a^x, o}^j(s) = \int_{s'} \alpha_{\bar{q}'}^j(s') Pr(o|s') Pr(s'|s, a^x) ds' \quad (4.30)$$

则式 (4.27) 可以表示为:

$$Q((b, \bar{q}), a^x) = R_{D^x}(b, \bar{q}) + \Gamma_{D^x}(b, \bar{q}) \int_o \max_{\alpha_{\bar{q}'}^j \in A_{\bar{q}}'} \langle \alpha_{a^x, o}^j, b \rangle do \quad (4.31)$$

记 $\alpha_{a^x, o, b} = \arg \max_{\alpha_{\bar{q}'}^j \in A_{\bar{q}}'} \langle \alpha_{a^x, o}^j, b \rangle$, 则可以得到新的 α 函数:

$$\alpha_{\bar{q}'}^{a^x}(s) = R_{D^x}(b, \bar{q}) + \Gamma_{D^x} \int_o \alpha_{a^x, o, b} do \quad (4.32)$$

2. 当采取自动机动作 $a^x = \epsilon_{\bar{q}'} \in A^\epsilon$ 时, 可以根据乘积置信 MDP 的定义得到采取该动作之后得到的乘积置信状态 $(b, \bar{q}')$, 令:

$$\alpha_{\bar{q}'}^{\epsilon_{\bar{q}'}} = \arg \max_{\alpha_{\bar{q}'}^j \in A_{\bar{q}}'} \langle \alpha_{\bar{q}'}^j, b \rangle \quad (4.33)$$

则根据式 (4.28) 可知, 新的 α 函数为:

$$\alpha_{\bar{q}'}^{a^x}(s) = \gamma_b \alpha_{\bar{q}'}^{\epsilon_{\bar{q}'}} \quad (4.34)$$

3. 由情况 1 和情况 2 可得, 系统的新 α 函数为:

$$\alpha_{\bar{q}} = \arg \max_{\alpha_{\bar{q}'}^{a^x}, a^x \in A^x} \langle \alpha_{\bar{q}'}^{a^x}, b \rangle \quad (4.35)$$

若得到的 $\alpha_{\bar{q}}$ 函数不包含于 $A_{\bar{q}}$ 函数集中, 则将该 α 函数插入到集合 $A_{\bar{q}}$ 函数集中, 完成 α 函数集的更新。

然而, 仅仅得到 α 函数的计算方法并不能保证 α 函数在值迭代过程中是可以计算的, 而在本文之前所使用的基于高斯混合分布的模型当中, α 函数在值迭代过程当中能够保持相同的形式。

定理 4.6 假设 POMDP 当中的观察函数, 转移函数和回报函数均为高斯函数的线性组合, 那么 α 函数也可以表示为高斯函数的线性组合。

证明 我们将通过归纳法对该命题进行证明, 对 $n > 0$, 记

$$\alpha_{n-1}^j(s') = \sum_k w_k^j \phi(s' | s_k^j, \Sigma_k^j) \quad (4.36)$$

那么当观察函数与转移函数均为混合高斯分布, 即状态转移概率函数 $T(s, a, s') = \phi(s'|s + \Delta(a), \Sigma^a)$, 观测函数 $\Omega(s, o) = \sum_l w_l^o \phi(s|s_l^o, \Sigma_l^o)$ 时, 我们有

$$\begin{aligned}\alpha_{a,o}^j(s) &= \int_{s'} \left[\sum_k w_k^j \phi(s'|s_k^j, \Sigma_k^j) \right] \cdot \left[\sum_l w_l^o \phi(s'|s_l^o, \Sigma_l^o) \right] \cdot \phi(s'|s + \Delta_a, \Sigma^a) ds' \\ &= \int_{s'} \sum_{k,l} w_k^j w_l^o \phi(s'|s_k^j, \Sigma_k^j) \phi(s'|s_l^o, \Sigma_l^o) \phi(s'|s + \Delta_a, \Sigma^a) ds' \\ &= \sum_{k,l} w_k^j w_l^o \int_{s'} \phi(s'|s_k^j, \Sigma_k^j) \phi(s'|s_l^o, \Sigma_l^o) \phi(s'|s + \Delta_a, \Sigma^a) ds' \\ &= \sum_{k,l} w_k^j w_l^o \phi(s_l^o|s_k^j, \Sigma_k^j + \Sigma_l^o) \phi_{k,l}^{j,o,a}(s),\end{aligned}$$

其中

$$\begin{aligned}\Sigma_{k,l}^{j,o} &= [(\Sigma_k^j)^{-1} + (\Sigma_l^o)^{-1}]^{-1}, \\ s_{k,l}^{j,o} &= \Sigma_{k,l}^{j,o} [(\Sigma_k^j)^{-1} s_k^j + (\Sigma_l^o)^{-1} s_l^o], \\ \phi_{k,l}^{j,o,a}(s) &= \phi(s|s_{k,l}^{j,o} - \delta_a, \Sigma_{k,l}^{j,o} + \Sigma_a).\end{aligned}$$

因此, 在第 n 步迭代中, 系统的值函数 $\{\alpha_{n+1}^j\}_j$ 为:

$$\alpha_n^j = r_a + \gamma \sum_o \operatorname{argmax}_{\{\alpha_{a,o}^j\}_j} \langle \alpha_{a,o}^j, b \rangle. \quad (4.37)$$

由于 r_a 和 $\alpha_{a,o}^j$ 均为高斯分布的线性组合, 故 $\{\alpha_{n+1}^j\}_j$ 同样为高斯分布的线性组合。因此, 在值迭代的过程中, α 函数能够始终保持高斯分布的线性组合的形式。■

在 α 函数的更新过程中, 对于采样点集当中的每个乘积置信状态, 按照本节算法只得到了一个 α 函数, 因此能够较为有效地降低 α 函数集的规模增长速度。由于每个乘积置信状态的 α 函数更新依赖于从上次的 α 函数集当中选择使该点动作值函数最大的 α 函数, 故 α 函数集的规模越小, 则更新速度越快。因此, 控制 α 函数集的规模增长速度是降低计算量的一种重要方法。

从上文提出的计算方法中可以看出, 在从上次 α 函数集当中选择使该点动作值函数最大的 α 函数的过程中, 我们能够得到对应于每个 α 函数的最优动作, 因此, 表达某个点的值函数的最优 α 函数也蕴含了最优动作信息, 即更新 α 函数集也同样是在更新最优控制策略。

在 α 函数的更新过程中, 我们将整个 α 函数集根据自动机状态 $\bar{q}$ 划分为了一系列包含自动机状态信息的 α 函数集 $A_{\bar{q}}$ 。当从乘积置信状态 $(b, \bar{q})$ 转移到 $(b', \bar{q}')$ 时, 对乘积置信状态 $(b, \bar{q})$ 进行 α 函数更新需要用到 $(b', \bar{q}')$ 处的 α 函数集 $A_{\bar{q}'}$ 。在一个乘积置信状态 $(b, \bar{q})$ 中, 分量 $\bar{q}$ 表示了系统的时序任务进度。对于处于不

同任务进度的状态,智能体应当采取不同的策略以访问不同的待接受集。若不对 α 函数集进行划分,那么当机器人处于相同位置,但具有不同任务进度时,无法得到符合当前任务进度的策略。因此,不同的 α 函数集 $A_{\bar{q}}$ 代表了在不同任务进度下,机器人分别应当采取的策略。

完成 α 函数集更新之后,通过扩充乘积置信采样点集 $\mathfrak{D}^x$,并再次进行 α 函数集的更新,可以得到对值函数更为精确的估计。假设初始乘积置信点集为 $\{(b_0, \bar{q}_0)\}$,本章提出的算法将通过模拟由采样乘积置信点集中的每个点在采取所有可行动作后可能到达的乘积置信状态,选择合适的乘积置信点加入候选采样点集。具体步骤为,首先根据系统的状态分布 $b(s)$ 选择一个状态 s ,再遍历其所有可行动作集,并得到对应的转移后状态 s' ,再根据观测函数采样对应的观测 o' ,由此即可通过贝叶斯估计或卡尔曼滤波方法得到新的置信状态 b' 。之后根据乘积置信MDP的定义即可得到新的乘积置信状态,最终得到候选采样点集 $\{d_{a_0^x}^x, d_{a_1^x}^x, \dots\}$ 。

由于候选采样点集中存在大量已经处于采样点集,或与采样点集距离过近的乘积置信状态,这些点对更新 α 函数而言无法起到优化作用,因此有必要对候选采样点集进行筛选并加入采样点集 $\mathfrak{D}^x$ 中。具体的筛选方法如下:

1. 删除满足 $d_{a_i^x}^x \in \mathfrak{D}^x$ 的候选点。若某个乘积置信状态已经处于采样点集中,说明该点信息已被考虑,故无需再次加入采样点集。
2. 定义函数 $distance(d_{a_i^x}^x)$ 为候选点访问当前待访问接受集的“距离”。该距离函数是一种启发式函数,我们希望距离函数越小,说明从候选点出发越容易访问乘积置信MDP接受集。因此,应当选择候选点集中距离值最小的候选点。函数 $distance(d_{a_i^x}^x)$ 的定义如下:
 - (1) 若转移 $(d^x, a^x, d_{a_i^x}^x)$ 位于乘积置信MDP的接受集,说明该状态已经完成了当前的iLTL任务,应当优先选择加入采样点集,故定义该点距离为: $distance(d_{a_i^x}^x) = -\infty$ 。
 - (2) 对于动作 $a^x \in A$,若 $(d^x, a^x, d_{a_i^x}^x)$ 不属于当前待访问的接受集,则考虑通过乘积置信状态 $d_{a_i^x}^x = (b_{a_i^x}^x, \bar{q}_{a_i^x}^x)$ 的自动机部分定义距离函数。如果自动机状态处存在可访问当前待访问的接受集的接受转移,则定义 $distance(d_{a_i^x}^x) = 0$,而对于自动机状态处不存在可访问当前待访问的接受集的接受转移,则可以使用递归的方式定义,定义为当前自动机状态可达状态当中最小的距离函数加1,这样的定义方式表明 $distance(d_{a_i^x}^x)$ 代表了从当前状态出发,到访问当前待访问接受集所需的最少状态转移次数,因此距离值越小,访问接受集需要的步数越少,也就是越容易访问接受集。
 - (3) 对于动作 $a^x \in A^\epsilon$,由于采取 ϵ 动作只会导致E-tLDGBA状态分量的转移,置信状态分量保持不变,故 $(d^x, a^x, d_{a_i^x}^x)$ 必然不属于当前待访问的接

受集。由于 ϵ 动作不会导致任务进度发生实际变化, 因此应该认为采取 ϵ 动作不会改变距离函数, 即 $distance(d_{a_i}^x) = distance(d^x)$ 。尽管在自动机层面上, 采取 ϵ 动作能够更加接近当前待访问接受集, 然而实际的置信状态并未发生改变, 若采用和非 ϵ 动作相同的距离函数定义方法, 则会导致采样点集中只保留选择 ϵ 动作的候选点, 从而导致失去了选择非 ϵ 动作的乘积置信状态的信息, 对整体乘积置信状态空间的泛化能力将会减弱。

(4) 若无论采取何种动作, 乘积置信状态的 E-tLDGBA 部分均转移到自身, 且该转移不属于任何接受集, 说明当智能体进入这种乘积置信状态时, 已经违反 iLTL 公式, 无法完成时序任务。因此, 将这类乘积置信状态称为“陷阱状态”, 陷阱状态由于无法完成任务, 故不应当加入采样点集中, 故定义陷阱状态的距离函数为 $distance(d_{a_i}^x) = \infty$ 。

通过遍历候选点集, 可以得到所有候选点的距离函数 $distance(d_{a_i}^x)$, 舍弃所有候选点当中距离函数较大的点, 仅保留距离函数值最小的点。

3. 经过之前的筛选, 候选点集中的候选乘积置信状态均具有相同的距离函数, 表示其时序任务信息已经得到充分考虑, 但还需考虑其置信状态以更充分探索置信空间。因此, 我们需要选择距离已采样点集在置信状态空间当中尽量“远”的候选点。首先, 对乘积置信点集 $\mathfrak{D}^x$ 中每个乘积置信状态的置信状态部分, 我们可以测量与当前候选点的置信状态之间的 L_1 范数, 将所有 L_1 范数当中的最小值作为当前候选点和已采样点集之间的距离。然后, 对于所有的候选点, 选择与已采样点集之间距离最大的候选点加入乘积置信点集 $\mathfrak{D}^x$ 中, 完成采样点集的扩充。这种方法是基于贪心算法的思想提出的, 尽量选择能尽快改善尚未探索部分的值函数估计的乘积置信点, 在探索乘积置信空间中能够发挥更大作用。

在以上乘积置信点集 $\mathfrak{D}^x$ 的扩充过程当中, 每个乘积置信状态只会产生一个新的采样点, 因此, 即使在经历三次筛选过后没有采样点被舍弃, 乘积置信点集 $\mathfrak{D}^x$ 的采样点数目只会增加为两倍。这种情况只在训练初期, 置信空间几乎没有被探索时发生。而当采样乘积置信点集 $\mathfrak{D}^x$ 的采样点数目达到一定规模时, 大部分采样点将会在筛选过程中被舍弃, 使采样乘积置信状态集当中的状态个数不会显著增长, 因此乘积置信点集 $\mathfrak{D}^x$ 的规模增长速度也能够得到有效控制。

在 α 函数的更新过程中, 对于采样点集中的每个乘积置信状态, 均需要进行更新, 得到一个 α 函数, 因此乘积置信点集 $\mathfrak{D}^x$ 的规模也是影响计算量的一个重要因素。基于以上提出的控制 α 函数集规模增长的方法和控制在采样乘积置信点集 $\mathfrak{D}^x$ 规模增长的方法, 完整的基于采样的值迭代算法在计算速度和计算精度上取得了平衡。

完整的基于采样的值迭代算法如算法4.2所示。

算法 4.2 基于采样的值迭代算法

输入: 乘积置信 MDP $\mathcal{D}^x$
输出: 近似最优价值函数 V_n

- 1 初始化采样点集 $\mathcal{D}^x$ 和 α 函数集 A ;
- 2 设置最大迭代回合数 max_eps ;
- 3 **repeat**
- 4 $\bar{\mathcal{D}}^x = \emptyset$;
- 5 **for all** $d^x \in \mathcal{D}^x$ **do**
- 6 模拟单步转移, 得到候选乘积置信点集 $\{d_{a_0^x}^x, d_{a_1^x}^x, \dots\}$;
- 7 根据扩充步骤, 选择候选乘积置信点集中与采样点集 $\mathcal{D}^x$ 距离最大的候选点 d_j^x ;
- 8 $\bar{\mathcal{D}}^x = \bar{\mathcal{D}}^x + d_j^x$
- 9 **end**
- 10 $\mathcal{D}^x \leftarrow \mathcal{D}^x \cup \bar{\mathcal{D}}^x = \emptyset$;
- 11 $episode = 0$;
- 12 **while** $episode < max_eps$ **do**
- 13 $A' \leftarrow A$;
- 14 $A = \{\emptyset, \emptyset, \dots\}$;
- 15 **for all** $d^x \in \mathcal{D}^x$ **do**
- 16 $\forall a^x \in A^x$, 计算对应的 $\alpha_{\bar{q}}$;
- 17 **if** $\alpha_{\bar{q}} \notin A_{\bar{q}}$ **then**
- 18 $A_{\bar{q}} \leftarrow A_{\bar{q}} + \alpha_{\bar{q}}$;
- 19 **end**
- 20 **end**
- 21 $episode++$
- 22 **end**
- 23 **until convergence**;

4.4 本章小结

针对本文第3章当中提出的框架, 本章提出了一种基于框架的自动机部分进行回报设计的方法, 并证明了该方法能够在第3章所定义的乘积置信 MDP 中引导移动机器人解得满足 iLTL 任务的最优策略。在这种回报结构的基础上, 本章提出了一种基于采样点的值迭代方法, 并证明了这种值迭代方法当中的价值函数的封闭性。

第5章 仿真实验

本章设计了不同的仿真实验环境，针对不同的环境使用了不同方法建立 POMDP 模型，并根据不同环境当中的时序任务定义对应的原子命题集，依据 iLTL 语法建立时序任务对应的 iLTL 公式约束。然后根据第 3 章中提出的方法，将 POMDP 转化为置信 MDP，利用 Rabinizer4^[80] 将 iLTL 公式转化为 tLDGBA，再根据 tLDGBA 构建对应的 E-tLDGBA，并与置信 MDP 融合，形成乘积置信 MDP。之后运用第 4 章提出的算法，对不同环境下的乘积置信 MDP 进行求解，验证了本文提出方法的可行性。本章所有仿真实验均在内存 16GB，CPU 型号为 12th Gen Intel(R) Core(TM) i9-12900H 2.50 GHz 的电脑上运行，操作系统为 Windows11。

5.1 离散状态离散观测下的运动规划仿真验证

在本实验中，我们使用了常用的网格世界作为仿真实验环境。如图 5.1a 所示，移动机器人在一个 5×4 的网格环境中运动，智能体每一步都位于一个网格当中，并获得观测信息。该环境具有离散的状态与离散的观测集合，其状态集为 $S = \{s_i\}, i \in \{0, \dots, 19\}$ ，观测集为 $Z = \{o_{s_i} | s_i \in S\}$ 。移动机器人具有四种动作，其动作集为 $A = \{Up, Down, Right, Left\}$ ，即向上方移动，向下方移动，向右侧移动，向左侧移动。原子命题集 $AP = \{tar, trap, None\}$ 表示了目标，陷阱以及其他情况。在该环境中，在状态 s_i 下获得观测 o_{s_j} 的概率为：

$$O(s_i, o_{s_j}) = \begin{cases} 0.9, & i = j \wedge L(s_i) = None, \\ 1, & i = j \wedge L(s_i) \neq None, \\ \frac{0.1}{N}, & otherwise, \end{cases}$$

其中， N 是一个标准化因子，使得 $\sum_{o \in Z} O(s, o) = 1, \forall s \in S$ 。标签函数定义如下：

$$L(s_i) = \begin{cases} tar1, & i = 4 \\ tar2, & i = 19 \\ trap, & i = 2, 3, 12, 15 \\ None, & \text{其他} \end{cases}$$

由于当系统的真实状态位于特定网格时，借助标签函数能够获得精确无误的观测信息。因此针对该任务的原子命题集定义为 $tar1, tar2, trap$ ，当系统确认其真

实状态位于状态 s_4 时, 满足命题 $tar1$, 其余命题则与此类似。本实验的任务设定为在保持避开 $trap$ 的前提下, 在 $tar1$ 和 $tar2$ 之间来回移动。

状态转移函数的定义如下:

$$T(s_j|s_i, R) = \begin{cases} p, & j = i + 1, (i + 1) \not\equiv 0 \bmod M \\ 1, & j = i, (i + 1) \equiv 0 \bmod M \\ \frac{1-p}{|N_{s_i}|}, & s_j \in \{s_i\} \cup N_{s_i} \setminus \{s_{i+1}\}, (i + 1) \not\equiv 0 \bmod M \end{cases}$$

$$T(s_j|s_i, L) = \begin{cases} p, & j = i - 1, (i - 1) \not\equiv 0 \bmod M \\ 1, & j = i, (i - 1) \equiv 0 \bmod M \\ \frac{1-p}{|N_{s_i}|}, & s_j \in \{s_i\} \cup N_{s_i} \setminus \{s_{i-1}\}, (i - 1) \not\equiv 0 \bmod M \end{cases}$$

$$T(s_j|s_i, D) = \begin{cases} p, & j = i + M, (i + M) \not\equiv 0 \bmod M \\ 1, & j = i, (i + M) \equiv 0 \bmod M \\ \frac{1-p}{|N_{s_i}|}, & s_j \in \{s_i\} \cup N_{s_i} \setminus \{s_{i+M}\}, (i + M) \not\equiv 0 \bmod M \end{cases}$$

$$T(s_j|s_i, U) = \begin{cases} p, & j = i - M, (i - M) \not\equiv 0 \bmod M \\ 1, & j = i, (i - M) \equiv 0 \bmod M \\ \frac{1-p}{|N_{s_i}|}, & s_j \in \{s_i\} \cup N_{s_i} \setminus \{s_{i-M}\}, (i - M) \not\equiv 0 \bmod M \end{cases}$$

其中, M 表示每一行的网格数量, 在本仿真实验当中 $M = 5$, N_{s_i} 表示状态 s_i 的相邻状态的集合, p 为智能体移动至正确的相邻网格的概率。而在本实验当中, $p = 0.8$ 。从状态转移函数当中, 我们可以知道, 当智能体位于最右侧一列并采取动作 $a = Right$ 时, 该智能体将会停留在原地不动。而其余动作的状态转移函数也与之类似。

本实验当中的 iLTL 约束为 $\phi = (\Box \Diamond tar1 \wedge \Box \Diamond tar2) \wedge \Box \neg trap$, 该约束要求移动机器人在两个目标之间来回移动以反复获得 tar 标签, 同时需要一直避免访问不安全的区域 $trap$ 。对应的 E-tLDGBA 结构如图 5.1b 所示。在本实验当中, 移动机器人在移动之后所到达的状态和得到的观测信息均是随机的, 本实验通过不同的折扣函数取值对回报函数与折扣函数的设计进行了验证。

图 5.2 展示了在两组不同的参数下, 本文提出的算法当中的值迭代部分。这两组参数均能够满足 $\lim_{\gamma_b \rightarrow 1} \frac{1-\gamma_b}{1-\gamma_{D^*}(\gamma_b)} = 0$, 并且最终都使初始置信状态 b_0 处的价值趋于收敛。当折扣因子和回报奖励取值为 $\gamma_{D^*} = 0.9, \gamma_b = 0.99$ 时, 从图中可




图 5.1 (a) 本仿真实验当中使用的网格世界环境，其中目标格和陷阱格分别用绿色和红色进行填充。(b) 对应 iLTL 公式 $\phi = (\Box \Diamond tar1 \wedge \Box \Diamond tar2) \wedge \Box \neg trap$ 的 E-tLDGBA 的结构示意图。




图 5.2 初始置信状态 b_0 在每个训练回合当中的价值曲线。其中蓝色线表示在 $\gamma_{D^*} = 0.95, \gamma_b = 0.999$ 条件下的训练过程，而橙色线代表在 $\gamma_{D^*} = 0.9, \gamma_b = 0.99$ 下的训练过程。

可以看出，训练曲线以更快的速度收敛，但最终收敛到的值函数小于另外一组参数所对应的曲线。当折扣因子和回报奖励取值为 $\gamma_{D^*} = 0.95, \gamma_b = 0.999$ 时，其训练曲线收敛速度较慢，但最终收敛得到的值函数较大。从两条训练曲线的比较中，我们能够看出，在满足 $\lim_{\gamma_b \rightarrow 1^-} \frac{1-\gamma_b}{1-\gamma_{D^*}(\gamma_b)} = 0$ 的前提下， γ_b 越接近 1，则最终得到的值函数越接近最优价值，但相应的，收敛速度将会减慢。

图 5.3 展示了另外三组不同参数的训练曲线，这三组参数的 γ_b 取值均为 0.9， γ_D 的取值不同。这三组参数不满足 $\lim_{\gamma_b \rightarrow 1^-} \frac{1-\gamma_b}{1-\gamma_{D^*}(\gamma_b)} = 0$ ，可以看出，由于有折扣因子的参与，这三种参数组合的取值最终仍然能够获得收敛的结果。但对比之





图 5.3 Caption

前的满足 $\lim_{\gamma_b \rightarrow 1} \frac{1-\gamma_b}{1-\gamma_D \times (\gamma_b)} = 0$ 的参数取值, 最终收敛到的价值要更小。以上五条训练曲线中均可以看出在前期收敛至一个结果, 而在之后价值又再次提升, 这是因为本文提出的 E-tLDGBA 具有多个接受集, 当智能体访问到第一个接受集时即可取得一定的回报。


(a) 自动机状态 $\bar{q} = (0, q_0)$ 时对应的策略

(b) 自动机状态 $\bar{q} = (1, q_0)$ 时对应的策略

图 5.4 在 $\gamma_D = 0.95, \gamma_b = 0.999$ 的条件下, 两种不同自动机状态下的对应策略。每个网格当中的数值和箭头代表了当智能体以概率 1 处于该网格中时, 其对应的价值和最优策略。

图 5.4 表示在 $\gamma_D = 0.95, \gamma_b = 0.999$ 的条件下, 本文提出算法所得到的训练结果。当智能体以概率 1 处于状态 $s_i \in S$ 时, 该置信状态的价值在图中给出, 并且图中也同样表示了智能体在该乘积置信状态下应当采取的行动策略。从图 5.4a 中我们可以看出, 当 E-tLDGBA 的状态为 $\bar{q} = (0, q_0)$ 时, 代表着移动机器人将会

向 $tar2$ 目标移动；而当 E-tLDGBA 的状态为 $\bar{q} = (1, q_0)$ 时，代表着移动机器人将会向 $tar1$ 目标移动，对应的策略为图5.4b。因此，靠近 $tar1$ 和 $tar2$ 目标的状态将具有更高的价值，而 $trap$ 状态因为无法完成 iLTL 任务，其价值均为 0。当 E-tLDGBA 的状态为 $\bar{q} = (0, q_0)$ 时，在 $tar2$ 处的策略为向上移动，这是因为当移动机器人到达 $tar2$ 时，其自动机状态将会转移至 $\bar{q} = (1, q_0)$ ，因此在 $tar2$ 处将采取同 $\bar{q} = (1, q_0)$ 中相同的移动策略。而 E-tLDGBA 的状态为 $\bar{q} = (1, q_0)$ 时 $tar1$ 处的策略同理。




图 5.5 仿真实验当中移动机器人的移动路径。

图5.5表示了移动机器人按照最优策略进行移动的路径。路径当中的圆圈箭头代表机器人尝试向墙壁移动以确认自身所处位置。移动机器人从初始状态 s_0 出发，首先尝试前往 $tar2$ 区域，之后前往 $tar1$ 区域，并在两个目标区域之间来回移动。在机器人到达状态 s_1 时，机器人尝试向上方移动，由于状态 s_1 的上方为墙壁，故在该状态采取向上方移动的策略并不会改变智能体所在的状态。通过这种方法，智能体能够提高状态分布的可靠程度。类似的，当智能体在 $tar2$ 状态和 $tar1$ 状态来回移动时，智能体会根据其推测的置信状态决定是否需要确认其所在的状态，如有需要，则选择向右移动，若在之前的转移当中向左侧滑动，则向右移动能够使移动机器人所在的实际状态重新回到正确的路径上；而若之前的转移当中没有发生滑动，那么向右移动并不会改变移动机器人实际所在的状态，因此也仍然处于正确的路径上。图中的深蓝色路径表示移动机器人根据自动机状态为 $\bar{q} = (0, q_0)$ 的策略进行移动；相应的，浅蓝色路径则表示移动机器人根据自动机状态为 $\bar{q} = (1, q_0)$ 的策略进行移动。

5.2 连续状态连续观测下的运动规划仿真验证

在本实验中，我们设计了一条走廊作为连续环境。在该环境当中，移动机器人的状态空间是连续的，且机器人能够对自身所在位置进行观测，故其观测空间同样也是连续的。如图5.6(a)所示，机器人在一个办公楼层当中移动，该楼层包含四个房间，用 'a', 'b', 'c', 'd' 来表示。移动机器人能够沿着走廊行动，其动作集为沿着走廊向前 0.5 个单位，或向后 0.5 个单位，或停在原地不动以获取观测信息。




图 5.6 (a) 本仿真实验当中使用的走廊环境，其中目标房间为房间 b 和房间 d。(b) 对应 iLTL 公式 $\phi = \Box \Diamond f \wedge \Box \Diamond g$ 的 E-tLDGBA 的结构示意图。

当机器人采取行动时，其状态转移方程如下：

$$s_{k+1} = s + u_a + w_a$$

其中，对应前进，后退，停止， u 分别取值为 0.5, -0.5, 0，而对应的 w_a 则分别服从于 $N(0, 0.25)$, $N(0, 0.25)$, $N(0, 0)$ 的正态分布，即当机器人移动时 $\Sigma^a = 0.25$ ，而当机器人停止不动时，其状态也不会发生变化。机器人的观测方程如下：

$$o_k = s_k + v, v \sim N(0, 1)$$

即机器人的观测空间为整条走廊，并且观测方差为 $\Sigma^o = 1$ 。在本实验当中，移动机器人的任务为在房间 b 和房间 d 之间来回移动。

我们将该系统的状态空间用一个连续的区间 $[-20, 20]$ 表示，其中房间 b 与房间 d 的门则分别位于 -7, 7 的位置。考虑到机器人不能完全精确地观测到其位置，我们用 p_b 和 p_d 来表示其位于房间 b 的门口和位于房间 d 的门口的概率，其中：

$$p_b = \int_{-7.25}^{-6.75} b(s) ds$$

$$p_d = \int_{6.75}^{7.25} b(s) ds$$

因此本实验当中的原子命题集可以定义为 $AP = \{f, g\}$ ，其中 $f = p_b - 0.95 > 0$ ， $g = p_d - 0.95 > 0$ 。故该实验的 iLTL 公式为 $\phi = \Box \Diamond f \wedge \Box \Diamond g$ ，该公式对应的 E-tLDGBA 也同样在图5.6(b) 中展示。




图 5.7 使用本文算法得到的移动机器人运动轨迹

图5.7展示了本仿真实验当中使用本文算法得到的移动机器人运动轨迹。图中的绿色实线代表移动机器人的真实位置，而绿色虚线则代表移动机器人根据观测信息对自身所处位置得到的估计，在绿色虚线两旁用绿色进行填充，表示了移动机器人对自身的估计标准差，移动机器人的实际位置在填充范围内的概率为 95%。本实验中，我们将机器人的初始位置设置在 0 处，初始置信状态则设置为均值为 0，方差为 10 的正态分布 $\phi(s|0, 10)$ 。从图中可以看出，机器人首先向房间 d 进行移动，在房间 d 处停止一段时间之后再向房间 b 移动，并反复循环。由于本实验当中，原子命题要求 $f = p_b - 0.95 > 0$ ， $g = p_d - 0.95 > 0$ ，即要求置信状态当中，处于房间 b 和房间 d 范围以内的概率大于 0.95，因此当机器人的传感器观测到机器人到达指定位置时，其置信状态仍有可能因为移动误差和测量误差导致无法满足任务要求，故在接近目标区域时，机器人将会停止数步，通过停止行动观测信息的方式来更新对自身位置的估计并减少方差，若发现自身不处于目标区域则会再次向目标区域行动，而若发现自身处于目标区域的概率满足任务要求，则会向下一个任务目标行动。

图5.8展示了使用传统 POMDP 求解方法所求得策略下移动机器人的轨迹。由于传统 POMDP 求解方法没有根据乘积置信 MDP 当中不同的自动机部分区分

不同的策略,即没有对 α 函数集进行划分,对于不同的任务进度无法给出正确的对应策略,因此在到达了第一个目标区域之后停止不动,无法前往第二个目标区域,最终导致了任务失败。




图 5.8 使用传统 POMDP 求解方法得到的移动机器人运动轨迹

图5.9展示了本实验当中机器人前 20 步的置信状态以及对应采取的行动策略,图中的 $\rightarrow$ 表示机器人沿着走廊前进,而 $\uparrow$ 表示机器人停止不动。从图中可以看出,一开始,由于目标区域处于机器人初始位置前方,故机器人采取前进的策略。随着机器人的行动和观测信息的更新,其方差呈现逐渐减少的趋势,而在数次行动之后,其方差相对稳定,但无法达到任务需求,因此当机器人到达任务区域时,机器人选择了停止不动,以提升自身位置信息的可靠程度,降低方差以满足任务需求。例如,当机器人经过第 33 步选择停止以收缩自身估计的标准差后得到的置信状态信息满足 $g = p_d - 0.95 > 0$ 之后,机器人将转变 E-tLDGBA 状态至 $(1, q_0)$,采取动作后退,向房间 b 移动。

5.3 本章小结

本章分别设计了网格仿真环境和走廊仿真环境两种仿真环境,前者具有离散的状态空间和离散的观测信息,后者具有连续的状态空间和连续的观测信息。之后,本章对这两种仿真环境利用第 3 章提出的方法构建乘积置信 MDP,并利用第 4 章提出的方法进行了最优策略求解,展示了仿真结果,并对结果进行了分析,验证了本文提出方法的有效性。




图 5.9 当机器人采取训练策略进行行动时，其置信状态的变化。图片下的箭头表示机器人的动作：→ 表示前进，← 表示后退，↑ 表示停止不动。横轴为机器人的状态，纵轴为对应置信值。

第6章 总结与展望

6.1 结论

本文主要以移动机器人为研究对象,基于 iLTL 和 POMDP 对复杂任务和动态不确定环境进行建模,并提出对应的求解方法,以求解满足任务要求的最优策略。由本文的内容得到以下总结:

(1) 对于 POMDP 和 tLDGBA 融合的问题,本文通过将 POMDP 转化为置信 MDP, tLDGBA 扩展为 E-tLDGBA,成功构建了乘积置信 MDP,该模型能够同时包含运动信息与时序任务信息。其中,当 POMDP 具有离散或连续的状态空间和离散的观测空间时,可以采用贝叶斯方法构建置信 MDP。而对于具有连续状态空间和连续观测空间的 POMDP,则可以使用卡尔曼滤波方法构建置信 MDP。本文根据 tLDGBA 扩展得到的 E-tLDGBA 与 tLDGBA 具有相同的接受语言,因此能够检验 iLTL 任务的满足关系。

(2) 对于乘积置信 MDP 的求解问题,本文提出了一种基于采样点的值迭代算法。本文提出了一种根据乘积置信 MDP 当中的自动机部分赋予智能体回报的方法,并证明了在该回报设计下优化 iLTL 任务满足概率等价于优化强化学习算法当中的价值函数。对于 POMDP 的无法精确求解问题,本文的方法能够通过采样点集,近似地求出乘积置信 MDP 的最优解,并且证明了该算法当中的价值函数能够保持封闭性和可计算性。

(3) 分别设计了具有离散空间状态、离散观测状态的部分可观马尔可夫决策过程和具有连续空间状态、连续观测状态的部分可观马尔可夫决策过程,并分别设计了移动机器人需要满足的复杂任务。对前者利用贝叶斯估计构建置信 MDP,对后者利用卡尔曼滤波得到置信 MDP,并使用本文提出的基于采样点的值迭代算法进行求解,最终实现了仿真任务,验证了本文方法的有效性。

6.2 展望

本文基于时序逻辑和强化学习提出了解决 POMDP 中机器人运动规划问题的框架,但仍有一些不足,以下是本文能够继续研究的几个优化方向:

其一,本文的采样算法较为简单,对于维数较高的空间仍旧有计算开销过大的问题,因此可以考虑优化采样算法加快强化学习的训练过程。

其二,本文的回报结构通过 E-tLDGBA 的多接受集增加了稠密性,在此基础上,可以尝试增加回报整形技术 (Reward Shaping) 进一步提升回报结构的稠密性,加快强化学习过程。

其三,对于乘积置信 MDP 的求解还可以考虑使用深度神经网络以拟合值函数,尝试使用 DQN 等深度强化学习方法对乘积置信 MDP 进行求解。

其四,在 POMDP 场景中,机器人训练过程中的安全性无法得到保证,可以通过控制障碍函数 (Control Barrier Functions, CBFs)、安全盾等方法改进强化学习方法,从而提高强化学习的训练效率。

其五,本文主要研究对象为单个移动机器人在场景当中的运动规划,为了适应更加复杂的任务和环境,未来可以研究多机器人的协同路径规划,通过多机器人协同工作完成单机器人较难完成的任务。

参考文献

- [1] DIJKSTRA E W. A note on two problems in connexion with graphs[M]//Edsger Wybe Dijkstra: His Life, Work, and Legacy. 2022: 287-290.
- [2] HART P E, NILSSON N J, RAPHAEL B. A formal basis for the heuristic determination of minimum cost paths[J]. IEEE transactions on Systems Science and Cybernetics, 1968, 4(2): 100-107.
- [3] MARIESCU-ISTODOR R, FRÄNTI P. Cellnet: Inferring road networks from gps trajectories [J]. ACM Transactions on Spatial Algorithms and Systems (TSAS), 2018, 4(3): 1-22.
- [4] STENTZ A. Optimal and efficient path planning for partially-known environments[C]// Proceedings of the 1994 IEEE international conference on robotics and automation. IEEE, 1994: 3310-3317.
- [5] FERGUSON D, STENTZ A. Using interpolation to improve path planning: The field d* algorithm[J]. Journal of Field Robotics, 2006, 23(2): 79-101.
- [6] DANIEL K, NASH A, KOENIG S, et al. Theta*: Any-angle path planning on grids[J]. Journal of Artificial Intelligence Research, 2010, 39: 533-579.
- [7] LIKHACHEV M, FERGUSON D, GORDON G, et al. Anytime search in dynamic graphs[J]. Artificial Intelligence, 2008, 172(14): 1613-1643.
- [8] MONTEMERLO M, BECKER J, BHAT S, et al. Junior: The stanford entry in the urban challenge[J]. Journal of field Robotics, 2008, 25(9): 569-597.
- [9] FERGUSON D, HOWARD T M, LIKHACHEV M. Motion planning in urban environments [J]. Journal of Field Robotics, 2008, 25(11-12): 939-960.
- [10] ZIEGLER J, STILLER C. Spatiotemporal state lattices for fast trajectory planning in dynamic on-road driving scenarios[C]//2009 IEEE/RSJ International Conference on Intelligent Robots and Systems. IEEE, 2009: 1879-1884.
- [11] LAVALLE S M, KUFFNER JR J J. Randomized kinodynamic planning[J]. The international journal of robotics research, 2001, 20(5): 378-400.
- [12] KAVRAKI L E, SVESTKA P, LATOMBE J C, et al. Probabilistic roadmaps for path planning in high-dimensional configuration spaces[J]. IEEE transactions on Robotics and Automation, 1996, 12(4): 566-580.
- [13] MURPHY R R. Introduction to ai robotics[M]. MIT press, 2019.
- [14] KHATIB O. Real-time obstacle avoidance for manipulators and mobile robots[J]. The international journal of robotics research, 1986, 5(1): 90-98.
- [15] 张殿富, 刘福. 基于人工势场法的路径规划方法研究及展望[J]. 计算机工程与科学, 2013,

- 35: 88-95.
- [16] ANTICH TOBARUELA J. New reactive and path-planning methods for mobile robot navigation[M]. Universitat de les Illes Balears, 2012.
- [17] KROGH B. A generalized potential field approach to obstacle avoidance control[C]//Proc. SME Conf. on Robotics Research: The Next Five Years and Beyond, Bethlehem, PA, 1984. 1984: 11-22.
- [18] BORENSTEIN J, KOREN Y. Real-time obstacle avoidance for fast mobile robots[J]. IEEE Transactions on systems, Man, and Cybernetics, 1989, 19(5): 1179-1187.
- [19] BORENSTEIN J, KOREN Y, et al. The vector field histogram-fast obstacle avoidance for mobile robots[J]. IEEE transactions on robotics and automation, 1991, 7(3): 278-288.
- [20] MASOUD A A. Decentralized self-organizing potential field-based control for individually motivated mobile agents in a cluttered environment: A vector-harmonic potential field approach[J]. IEEE Transactions on Systems, Man, and Cybernetics-Part A: Systems and Humans, 2007, 37(3): 372-390.
- [21] FIORINI P, SHILLER Z. Motion planning in dynamic environments using velocity obstacles [J]. The international journal of robotics research, 1998, 17(7): 760-772.
- [22] VAN DEN BERG J, LIN M, MANOCHA D. Reciprocal velocity obstacles for real-time multi-agent navigation[C]//2008 IEEE international conference on robotics and automation. Ieee, 2008: 1928-1935.
- [23] VAN DEN BERG J, GUY S J, LIN M, et al. Reciprocal n-body collision avoidance[C]//Robotics Research: The 14th International Symposium ISRR. Springer, 2011: 3-19.
- [24] GUY S J, CHHUGANI J, KIM C, et al. Clearpath: highly parallel collision avoidance for multi-agent simulation[C]//Proceedings of the 2009 ACM SIGGRAPH/Eurographics Symposium on Computer Animation. 2009: 177-187.
- [25] FOX D, BURGARD W, THRUN S. The dynamic window approach to collision avoidance[J]. IEEE Robotics & Automation Magazine, 1997, 4(1): 23-33.
- [26] SIPSER M. Introduction to the theory of computation[J]. ACM Sigact News, 1996, 27(1): 27-29.
- [27] DANTAM N, STILMAN M. The motion grammar: Analysis of a linguistic method for robot control[J]. IEEE Transactions on Robotics, 2013, 29(3): 704-718.
- [28] BRUNELLO A, MONTANARI A, REYNOLDS M. Synthesis of ltl formulas from natural language texts: State of the art and research directions[C]//26th International symposium on temporal representation and reasoning (TIME 2019). Schloss Dagstuhl-Leibniz-Zentrum fuer Informatik, 2019.
- [29] KRESS-GAZIT H, FAINEKOS G E, PAPPAS G J. From structured english to robot motion

- [C]//2007 IEEE/RSJ International Conference on Intelligent Robots and Systems. IEEE, 2007: 2717-2722.
- [30] 禹鑫淼, 陈浩, 郭永奎, 等. 基于线性时序逻辑理论的仓储机器人路径规划[J]. 高技术通讯, 2016, 26: 16-23.
- [31] BISOFFI A, DIMAROGONAS D V. A hybrid barrier certificate approach to satisfy linear temporal logic specifications[C]//2018 Annual American Control Conference (ACC). IEEE, 2018: 634-639.
- [32] KUPFERMAN O, VARDI M Y. Model checking of safety properties[J]. Formal methods in system design, 2001, 19: 291-314.
- [33] LI X, MA Y, BELTA C. Automata guided reinforcement learning with demonstrations[A]. 2018.
- [34] KŘETÍNSKÝ J, MEGGENDORFER T, SICKERT S. Owl: A library for ω -words, automata, and ltl[C]//LAHIRI S K, WANG C. Automated Technology for Verification and Analysis. Cham: Springer International Publishing, 2018: 543-550.
- [35] NG A Y, HARADA D, RUSSELL S. Policy invariance under reward transformations: Theory and application to reward shaping[C]//Icml: Vol. 99. 1999: 278-287.
- [36] LI X, VASILE C I, BELTA C. Reinforcement learning with temporal logic rewards[C]//2017 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS). IEEE, 2017: 3834-3839.
- [37] BAIER C, KATOEN J P. Principles of model checking[M]. MIT press, 2008.
- [38] KŘETÍNSKÝ J, MEGGENDORFER T, SICKERT S. Owl: a library for-words, automata, and ltl[C]//International Symposium on Automated Technology for Verification and Analysis. Springer, 2018: 543-550.
- [39] SICKERT S, ESPARZA J, JAAX S, et al. Limit-deterministic büchi automata for linear temporal logic[C]//International Conference on Computer Aided Verification. Springer, 2016: 312-332.
- [40] HAHN E M, PEREZ M, SCHEWE S, et al. Omega-regular objectives in model-free reinforcement learning[C]//International conference on tools and algorithms for the construction and analysis of systems. Springer, 2019: 395-412.
- [41] HASANBEIG M, KANTAROS Y, ABATE A, et al. Reinforcement learning for temporal logic control synthesis with probabilistic satisfaction guarantees[C]//2019 IEEE 58th Conference on Decision and Control (CDC). IEEE, 2019: 5338-5343.
- [42] OURA R, SAKAKIBARA A, USHIO T. Reinforcement learning of control policy for linear temporal logic specifications using limit-deterministic generalized büchi automata[J]. IEEE Control Systems Letters, 2020, 4(3): 761-766.

- [43] CAI M, XIAO S, LI B, et al. Reinforcement learning based temporal logic control with maximum probabilistic satisfaction[C]//2021 IEEE international conference on robotics and automation (ICRA). IEEE, 2021: 806-812.
- [44] CAI M, PENG H, LI Z, et al. Learning-based probabilistic ltl motion planning with environment and motion uncertainties[J/OL]. IEEE Transactions on Automatic Control, 2021, 66(5): 2386-2392. DOI: 10.1109/TAC.2020.3006967.
- [45] ICARTE R T, KLASSEN T, VALENZANO R, et al. Using reward machines for high-level task specification and decomposition in reinforcement learning[C]//International Conference on Machine Learning. PMLR, 2018: 2107-2116.
- [46] AKSARAY D, JONES A, KONG Z, et al. Q-learning for robust satisfaction of signal temporal logic specifications[C]//2016 IEEE 55th Conference on Decision and Control (CDC). IEEE, 2016: 6565-6570.
- [47] 桂林, 武小悦. 部分可观测马尔可夫决策过程算法综述[J]. 系统工程与电子技术, 2008: 1058-1064.
- [48] BOHG J, MORALES A, ASFOUR T, et al. Data-driven grasp synthesis—a survey[J]. IEEE Transactions on robotics, 2013, 30(2): 289-309.
- [49] LASOTA P A, FONG T, SHAH J A, et al. A survey of methods for safe human-robot interaction[J]. Foundations and Trends® in Robotics, 2017, 5(4): 261-349.
- [50] GRIGORESCU S, TRASNEA B, COCIAS T, et al. A survey of deep learning techniques for autonomous driving[J]. Journal of field robotics, 2020, 37(3): 362-386.
- [51] KOBER J, BAGNELL J A, PETERS J. Reinforcement learning in robotics: A survey[J]. The International Journal of Robotics Research, 2013, 32(11): 1238-1274.
- [52] ÅSTRÖM K J. Optimal control of markov processes with incomplete state information i[J]. Journal of mathematical analysis and applications, 1965, 10: 174-205.
- [53] BELLMAN R. Dynamic programming[J]. science, 1966, 153(3731): 34-37.
- [54] HAUSKRECHT M. Value-function approximations for partially observable markov decision processes[J]. Journal of artificial intelligence research, 2000, 13: 33-94.
- [55] LOVEJOY W S. A survey of algorithmic methods for partially observed markov decision processes[J]. Annals of Operations Research, 1991, 28(1): 47-65.
- [56] MONAHAN G E. State of the art—a survey of partially observable markov decision processes: theory, models, and algorithms[J]. Management science, 1982, 28(1): 1-16.
- [57] WHITE III C C. A survey of solution techniques for the partially observed markov decision process[J]. Annals of Operations Research, 1991, 32(1): 215-230.
- [58] SPAAN M T, VLASSIS N. Perseus: Randomized point-based value iteration for pomdps[J]. Journal of artificial intelligence research, 2005, 24: 195-220.

- [59] PINEAU J, GORDON G, THRUN S. Anytime point-based approximations for large pomdps [J]. *Journal of Artificial Intelligence Research*, 2006, 27: 335-380.
- [60] SMITH T, SIMMONS R. Heuristic search value iteration for pomdps[A]. 2012.
- [61] KURNIAWATI H, HSU D, LEE W S. Sarsop: Efficient point-based pomdp planning by approximating optimally reachable belief spaces[Z]. 2009.
- [62] ROSS S, PINEAU J, PAQUET S, et al. Online planning algorithms for pomdps[J]. *Journal of Artificial Intelligence Research*, 2008, 32: 663-704.
- [63] SILVER D, VENESS J. Monte-carlo planning in large pomdps[J]. *Advances in neural information processing systems*, 2010, 23.
- [64] SOMANI A, YE N, HSU D, et al. Despot: Online pomdp planning with regularization[J]. *Advances in neural information processing systems*, 2013, 26.
- [65] SUNBERG Z, KOCHENDERFER M. Online algorithms for pomdps with continuous state, action, and observation spaces[C]//*Proceedings of the International Conference on Automated Planning and Scheduling*: Vol. 28. 2018: 259-263.
- [66] BROWNE C B, POWLEY E, WHITEHOUSE D, et al. A survey of monte carlo tree search methods[J]. *IEEE Transactions on Computational Intelligence and AI in games*, 2012, 4(1): 1-43.
- [67] CHATTERJEE K, CHMELIK M, GUPTA R, et al. Qualitative analysis of pomdps with temporal logic specifications for robotics applications[C]//*2015 IEEE International Conference on Robotics and Automation (ICRA)*. IEEE, 2015: 325-330.
- [68] SHARAN R, BURDICK J. Finite state control of pomdps with ltl specifications[C]//*2014 American Control Conference*. IEEE, 2014: 501-508.
- [69] BOUTON M, TUMOVA J, KOCHENDERFER M J. Point-based methods for model checking in partially observable markov decision processes[C]//*Proceedings of the AAAI Conference on Artificial Intelligence*: Vol. 34. 2020: 10061-10068.
- [70] CARR S, JANSEN N, TOPCU U. Task-aware verifiable rnn-based policies for partially observable markov decision processes[J]. *Journal of Artificial Intelligence Research*, 2021, 72: 819-847.
- [71] RAMASUBRAMANIAN B, NIU L, CLARK A, et al. Secure control in partially observable environments to satisfy ltl specifications[J]. *IEEE Trans. Autom. Control*, 2020, 66(12): 5665-5679.
- [72] KALAGARLA K C, DHURVA K, SHEN D, et al. Optimal control of partially observable markov decision processes with finite linear temporal logic constraints[C]//*CUSSENS J, ZHANG K. Proceedings of Machine Learning Research*: Vol. 180 *Proceedings of the Thirty-Eighth Conference on Uncertainty in Artificial Intelligence*. PMLR, 2022: 949-958.

- [73] WANG Y, BOZKURT A K, PAJIC M. Reinforcement learning with temporal logic constraints for partially-observable markov decision processes[A]. 2021.
- [74] LI J, CAI M, WANG Z, et al. Model-based motion planning in pomdps with temporal logic specifications[J]. *Advanced Robotics*, 2023, 37(14): 871-886.
- [75] KWON Y, AGHA G. Linear inequality ltl (iltl): A model checker for discrete time markov chains[C]//International conference on formal engineering methods. Springer, 2004: 194-208.
- [76] WATKINS C J, DAYAN P. Q-learning[J]. *Machine learning*, 1992, 8: 279-292.
- [77] WELCH G, BISHOP G, et al. An introduction to the kalman filter[M]. Chapel Hill, NC, USA, 1995.
- [78] AMODEI D, OLAH C, STEINHARDT J, et al. Concrete problems in ai safety[A]. 2016.
- [79] LI X. A formal methods approach to interpretability, safety and composability for reinforcement learning[D]. Boston University, 2020.
- [80] KŘETÍNSKÝ J, MEGGENDORFER T, SICKERT S, et al. Rabinizer 4: from ltl to your favourite deterministic automaton[C]//International Conference on Computer Aided Verification. Springer, 2018: 567-577.