

分 类 号：TP391
单位代码：10719

学 号：2212102017
密 级：公开

延安大学
硕 士 学 位 论 文
(学 术 学 位)

论文题目（中文）	基于误差状态卡尔曼滤波的位姿估计 算法研究
论文题目（外文）	Research on Pose Estimation Algorithm Based on Error-State Kalman Filter
作 者 姓 名	贾博林
学 科 专 业	信息与通信工程
指 导 教 师	白宗文 教授
提 交 论 文 日 期	二〇二五年六月

基于误差状态卡尔曼滤波的位姿估计算法研究

信号与信息处理专业研究生 贾博林

指导老师 白宗文教授

摘 要：随着自动驾驶、机器人导航、无人机定位和智能定位技术的快速发展，精确的位姿估计已成为这些工业应用系统高效且可靠运行的重要需求。惯性测量单元（IMU）、全球定位系统（GPS）和激光雷达（LiDAR）是常用的定位与环境感知传感器。尽管每种传感器在特定场景下具有独特优势，但单一传感器往往难以应对复杂环境中的各种不确定性问题。IMU 在长时间运行中会受到误差积累的影响，GPS 信号会在遮挡和弱信号区域受限，激光雷达虽能提供高精度的环境信息，但其更新频率较低，且对动态环境的适应性差。为了解决这些问题，多传感器融合技术应运而生，通过综合多个传感器的互补优势，显著提升了系统的定位精度和鲁棒性。

本论文针对多传感器融合问题，提出了一种流形空间误差状态卡尔曼滤波（ESKF），并在此基础上设计了 IMU 与 GPS、IMU 与激光雷达的两种数据融合方法，旨在优化多传感器系统在复杂环境中的定位表现。所提方法通过在流形上建模状态变量，有效处理了姿态估计中的非线性问题，同时增强了滤波器的收敛性与鲁棒性。具体来说，通过流形空间优化，所提出的 ESKF 方法能够精确地保持惯性传感器在复杂环境下的估计精度，并解决了传统卡尔曼滤波在姿态估计中的局限性。

在实验验证部分，本文在多种复杂环境场景中测试了所提算法。结果表明，相比传统滤波方法，所提出的融合框架在精度、稳定性和实时性方面均表现出显著优势，能够有效应对多种不确定性和干扰。本文的研究为多传感器融合技术在复杂环境中的应用提供了新的思路，并为自动驾驶、机器人导航和无人机定位等领域提供了更可靠的技术支持。未来的研究可进一步优化融合算法，提升其在极端环境下的鲁棒性，并探讨在更大规模、多样化传感器网络中的应用潜力。

关键词：IMU；GPS；激光雷达；误差状态卡尔曼滤波；位姿估计

Research on Pose Estimation Algorithm Based on Error-State Kalman Filter

Bolin Jia (Signal and Information Processing)

Directed by Prof. Zongwen Bai

Abstract: With the rapid development of autonomous driving, robotic navigation, unmanned aerial vehicle (UAV) positioning, and intelligent localization technologies, precise pose estimation has become a critical requirement for the efficient and reliable operation of these industrial systems. Inertial Measurement Units (IMU), Global Positioning System (GPS), and Light Detection and Ranging (LiDAR) are commonly used positioning and environmental perception sensors. Although each sensor has unique advantages in specific scenarios, a single sensor often struggles to address the uncertainties in complex environments. IMUs are affected by error accumulation over time, GPS signals are limited in areas with signal obstruction or weak reception, and while LiDAR provides high-precision environmental data, it has a low update frequency and poor adaptability to dynamic environments. To address these challenges, multi-sensor fusion technology has emerged, significantly improving the positioning accuracy and robustness of systems by leveraging the complementary advantages of multiple sensors.

This paper addresses the multi-sensor fusion problem by proposing an error-state Kalman filter (ESKF) optimized using manifold space, and based on this, two data fusion methods are designed: IMU-GPS fusion and IMU-LiDAR fusion, aimed at optimizing the positioning performance of multi-sensor systems in complex environments. The proposed method models the state variables on a manifold, effectively addressing the nonlinearity in attitude estimation while enhancing the filter's convergence and robustness. Specifically, by optimizing in manifold space, the proposed ESKF method can precisely maintain the accuracy of inertial sensors in complex environments and

overcome the limitations of traditional Kalman filters in attitude estimation.

In the experimental validation section, the proposed algorithm was tested in various complex environmental scenarios. The results show that compared to traditional filtering methods, the proposed fusion framework demonstrates significant advantages in terms of accuracy, stability, and real-time performance, effectively handling various uncertainties and disturbances. This research provides new insights into the application of multi-sensor fusion technology in complex environments and offers more reliable technical support for fields such as autonomous driving, robotic navigation, and UAV positioning. Future research can further optimize the fusion algorithm to enhance its robustness in extreme environments and explore its potential applications in large-scale, diversified sensor networks.

Keywords: IMU; GPS; LiDAR ; Error-State Kalman Filter; Pose Estimation

目 录

第一章 绪论	1
1.1 课题背景及研究的目的和意义	1
1.2 国内外研究现状	3
1.2.1 位姿估计常见传感器	3
1.2.2 基于滤波理论的传感器融合方法	8
1.2.3 基于优化理论的传感器融合方法	12
1.3 本文研究内容	16
1.4 本文组织架构	17
第二章 相关理论基础	18
2.1 IMU 运动学	18
2.1.1 坐标系	18
2.1.2 旋转矩阵与旋转向量	18
2.1.3 旋转矩阵的微分	19
2.1.4 IMU 器件测量模型与运动学模型	20
2.1.5 流形空间上的 IMU 状态变量	21
2.2 贝叶斯滤波	23
2.2.1 贝叶斯定理	23
2.2.2 状态空间	23
2.2.3 递推步骤	24
2.2.4 后验估计	25
2.3 卡尔曼滤波	26
2.3.1 状态空间	26

2.3.2 递推步骤	26
2.3.3 卡尔曼滤波五大公式	28
2.4 误差状态卡尔曼滤波	29
2.4.1 状态空间	29
2.4.2 递推步骤	30
2.4.3 算法构成	31
第三章 基于流形空间误差状态卡尔曼滤波的 IMU 和 GPS 融合算法	32
3.1 问题引入	32
3.2 引入流形空间误差状态卡尔曼滤波的动机	33
3.3 误差状态卡尔曼滤波算法原理	34
3.4 IMU 状态运动学建模	35
3.4.1 连续时间运动学模型	36
3.4.2 离散时间运动学模型	38
3.5 IMU 和 GPS 融合算法	39
3.5.1 误差状态的运动过程	39
3.5.2 误差状态的更新过程	40
3.5.3 注入过程和重置过程	41
3.6 实验与分析	42
3.6.1 实验设置与数据来源	42
3.6.2 评价指标	42
3.6.3 实验结果	43
3.6.4 结果分析	47
3.7 本章小结	48
第四章 基于流形空间误差状态卡尔曼滤波的 IMU 和激光雷达融合算法	50
4.1 问题引入	50
4.2 引入误差状态卡尔曼滤波的动机与优势	52
4.3 IMU 和激光雷达融合算法	53

4.3.1 误差状态的更新过程	53
4.3.2 误差状态的注入过程和重置过程	54
4.4 实验与分析	54
4.4.1 实验设置和数据来源	54
4.4.2 评价指标	55
4.4.3 实验结果	56
4.4.4 实验结果分析	60
4.5 本章小结	61
第五章 总结与展望	63
5.1 工作总结	63
5.2 研究展望	63
参考文献	65
声 明	72
致 谢	73
在读期间的研究成果	74

第一章 绪论

1.1 课题背景及研究的目的和意义

位姿估计 (Pose Estimation) 是自动驾驶^[1] (Autonomous Driving)、机器人导航^[2] (Robot Navigation)、增强现实^[3] (Augmented Reality, AR) 和虚拟现实^[4] (Virtual Reality, VR) 等领域中的关键技术之一。位姿估计的基本任务是通过传感器数据获取物体或机器人的位置和朝向 (姿态), 即在三维空间中确定物体的位置和朝向。对于自动驾驶和智能机器人等系统而言, 准确的位姿估计是实现自主导航、避障、路径规划等功能的基础。

随着现代工业技术的快速发展, 惯性测量单元 (IMU)、全球定位系统 (GPS) 以及激光雷达 (LiDAR) 等传感器在测量精度、稳定性以及数据更新频率等方面均取得了显著进步, 广泛应用于自动驾驶、机器人导航与智能设备等领域。这些感知能力的提升显著增强了系统在动态与复杂环境中的位姿估计与环境感知能力。然而, 伴随着传感器数据精度和频率的不断提高, 系统在有限时间内需处理的数据量急剧增加, 对计算平台的处理能力、存储能力以及算法的执行效率提出了更为严苛的要求。特别是在实时性要求较高的应用场景中, 如何实现高效的数据处理与系统响应成为亟需解决的问题。

尽管单一传感器在特定条件下具有优势, 但其自身的固有限制显著制约了系统整体性能。具体而言, IMU 具有高频率和短时动态响应优势, 但其误差随时间累积, 易产生漂移; GPS 可提供全球定位信息, 但在室内环境或遮挡严重的环境中易失效; LiDAR 具备高分辨率的环境建图能力, 但对天气条件以及物体表面特性敏感, 且其数据处理计算开销较大。因此, 依赖单一传感器难以在多变环境中实现稳定、鲁棒且高精度的状态估计。

针对上述问题, 多传感器融合技术^[5-6]应运而生, 成为提升位姿估计精度的重要途径。通过综合利用各类传感器的互补特性, 例如融合 IMU 的高动态性能、GPS 的绝对位置信息与 LiDAR 的环境建图能力, 系统能够在多种工况下提升状态估计的精度、鲁棒性与可靠性。尤其在复杂的非结构化环境中, 传感器融合能够有效缓解单一传感器失效带来的影响, 为后续的路径规划与控制决策提供稳定的输入基

础。

然而，传感器融合在提升定位性能的同时，也显著增加了计算复杂度，尤其在传感器数量增多与更新频率提升的背景下，对数据融合算法的实时性与计算效率提出了更高要求。在资源受限的计算平台上，如无人机、小型机器人及便携式智能设备，传统高精度算法常因计算负载过重而难以满足实时运行需求。因此，如何在有限算力条件下，设计兼顾精度与效率的多传感器融合算法，成为当前智能系统位姿估计研究的关键问题。例如，在无人机巡航过程中，系统需实时感知环境并迅速调整飞行策略以实现避障与路径跟踪；而在复杂场景中的小型机器人任务执行中，同样对实时定位与路径规划能力提出了极高要求。在此背景下，发展面向算力资源受限相对平台的高效融合算法，对于提升系统整体性能与实际部署能力具有重要意义。

因此，本论文旨在提出一种基于流形空间的误差状态卡尔曼滤波（Error State Kalman Filter, ESKF）算法，该算法充分发挥卡尔曼滤波在实时性和计算效率方面的优势，针对惯性导航系统中姿态估计的特殊性进行优化。传统的姿态表示方法多采用欧拉角或四元数，但欧拉角在运算上存在奇异点问题，而四元数虽避免了奇异，但在滤波过程中四元数（4 个自由度）来描述旋转并非最小参数表达，这会增加算法复杂度。为解决这一问题，本文引入流形空间的概念，对状态变量在流形空间上进行参数化建模，将旋转矩阵映射到切空间（局部欧氏空间）进行计算和更新，从而提升了姿态估计的数值稳定性与计算效率。同时利用误差状态的特性，在卡尔曼滤波框架下仅对误差状态进行估计和更新，从而有效避免了姿态估计中的奇异性和非线性约束问题。该方法不仅提升了滤波过程的数值稳定性和准确性，还降低了算法的计算负担，该方法在保持高估计精度的同时显著降低了计算资源消耗，尤其适用于算力受限的平台，如小型机器人、无人机与嵌入式设备。此外，本文将所提出的流形空间优化 ESKF 算法分别应用于两种典型的多传感器融合任务：IMU-GPS 融合与 IMU-LiDAR 融合。前者结合了 IMU 的短时动态响应与 GPS 的全球定位能力，实现了在户外环境下的稳定位姿估计；后者则融合了 IMU 与 LiDAR 的高频率与高精度特性，使系统在结构化与非结构化环境中均具备较强的环境感知与鲁棒定位能力。

具体来说, 本研究具有以下几方面的意义: 其一、本论文基于误差状态卡尔曼滤波 (ESKF) 框架, 结合流形空间优化方法, 提出了一种兼顾精度与计算效率的位姿估计算法。通过在局部切空间中对姿态状态进行线性化处理, 避免了传统欧拉角奇异性问题和四元数冗余参数的问题, 同时降低了计算复杂度, 具有良好的实时性; 其二、本论文分别设计并实现了基于该 ESKF 框架的 IMU-GPS 和 IMU-LiDAR 融合方案, 充分挖掘了各类传感器的互补优势。IMU-GPS 融合提高了系统的全局稳定性; IMU-LiDAR 融合增强了对局部环境的高精度位姿估计能力; 其三、本论文进一步拓展了状态估计领域中对非欧空间变量建模与运算的研究路径, 增强了滤波理论在实际工程中的适用性, 对高精度导航系统的设计与实现具有一定的理论价值与参考意义。

1.2 国内外研究现状

位姿估计技术作为智能系统的核心技术之一, 在无人驾驶、机器人导航、无人机飞行等多个领域取得了显著进展。国内外的研究主要集中在提升位姿估计的精度、实时性, 以及多传感器融合技术的应用上。研究方法大体可分为两类: 一种是基于滤波理论的传感器融合方法, 另一种是基于优化理论的传感器融合方法。本节将综述这些研究方法及其代表性成果。

1.2.1 位姿估计常见传感器

IMU^[7-8], 如图 1.1 所示, 即惯性测量单元, 用于测量物体在三维空间中加速度、角速度的设备。IMU 主要通过一组传感器 (包括加速度计、陀螺仪和磁力计) 来工作, 它能为导航系统提供实时、连续的姿态和位置变化数据, 因此广泛应用于无人驾驶、航空航天、机器人、移动设备等领域。




图 1.1 IMU 传感器

Figure 1.1 IMU Sensor

IMU 的优点包括：（1）高频响应：IMU 能够以非常高的频率提供数据，通常为几百到几千赫兹，适用于实时系统。（2）无需外部参考信号：IMU 不依赖于外部信号，如 GPS，因此在没有 GPS 信号的环境中也能提供定位信息。（3）精确度：IMU 能够提供非常精确的短期位姿估计，尤其是在动态环境中。然而，IMU 也存在一些缺点：（1）误差积累：IMU 随着时间的推移会受到传感器噪声和偏差的影响，导致测量误差积累，尤其是加速度计和陀螺仪的误差会逐渐增加，造成位置漂移。

（2）依赖于初始化：IMU 系统的精度很大程度上依赖于初始状态的设置。如果初始化误差较大，可能会导致较大的测量误差。

由于 IMU 通过两次积分加速度信息来得到位移，通过一次积分角速度来得到姿态，在噪声的影响下，尤其是长期使用时，IMU 容易积累较大的偏置，进而导致较大的误差。

GPS^[9]（Global Positioning System，全球定位系统），如图 1.2 所示，是由美国政府主导建设的全球卫星导航系统，旨在提供全球范围内的高精度位置、速度和时间信息。GPS 系统通过卫星、地面站和用户接收机的协同工作，为全球用户提供实时的三维定位服务。作为一种高效且普及的定位技术，GPS 已经在多个领域得到了广泛应用，包括汽车、航空、船舶以及个人导航设备等，为用户提供实时位置更新并支持精确的路径规划和导航。



图 1.2 GPS 定位系统

Figure 1.2 GPS Positioning System

作为一种高效、普及的定位技术，已经在众多领域得到了广泛应用，诸如导航系统：GPS 广泛应用于汽车、航空、船舶和个人导航设备中，帮助用户实时获取当前位置并提供准确的路径规划和导航服务。

GPS 的优点在于：（1）全球覆盖：GPS 系统能够在全球任何地方提供定位服务，不受地域限制。（2）实时性：GPS 能够提供实时的位置、速度和时间信息。然而，GPS 也存在一些局限性：（1）信号遮挡问题：GPS 信号容易受到建筑物、森林、地下环境等障碍物的遮挡，导致信号丢失或精度降低。尤其在城市高楼林立的环境中，信号质量往往受到严重影响。（2）依赖外部信号：GPS 依赖于卫星信号，因此在没有信号的环境中（如地下、隧道、深山或海洋等）无法提供定位服务，这使得它在一些特殊环境中无法工作。（3）大气层中的电离层和对流层对 GPS 信号可能产生干扰，导致信号的传播速度和方向发生变化，从而影响定位精度，特别是在极端气象条件下，如大气湍流或强风暴中。（4）精度受限：普通的民用 GPS 定位精度通常在 5 米左右，对于需要厘米级精度的应用，需要借助差分 GPS 或 RTK 技术。

视觉里程计^[10]（Visual Odometry, VO），如图 1.3 所示，是一种通过摄像头或其他视觉传感器来估计相机或物体位姿（位置和姿态）变化的技术。与传统依赖 IMU、GPS 等硬件的定位方法不同，视觉里程计完全依赖图像数据进行空间位置的估算，因此具有较强的灵活性。视觉里程计在机器人导航、自动驾驶^[11-12]等领域中得到了广泛的应用，尤其是在无需依赖外部信号的情况下，能够实现相对精准的定位和路径估计。




图 1.3 对极几何

Figure 1.3 Epipolar Geometry

视觉里程计的优点在于：（1）成本较低：视觉传感器（如摄像头）的成本较低，适合大规模应用；（2）灵活性强：视觉里程计不依赖外部信号，如 GPS，因此在 GPS 信号无法覆盖的环境（如地下、室内等）中，也能有效工作。然而，视觉

里程计也面临若干挑战：（1）光照变化：视觉定位对光照的变化较为敏感，强光或低光环境下可能会导致图像质量差，从而影响特征点提取和匹配的精度，进而影响定位结果的准确性。（2）动态场景：当场景中存在运动物体（如行人、车辆等）时，可能会导致错误的特征点匹配，影响位姿估计的准确性。（3）特征提取与匹配的鲁棒性：在特征较少或存在重复纹理的场景中，特征点的提取和匹配变得困难，导致定位精度下降。这在一些复杂环境中尤为突出，如低纹理或无纹理的区域。（4）计算复杂度：尽管相机成本较低，但特征提取、匹配及优化过程的计算量较大，尤其是在实时应用中，可能导致计算延迟。因此，需要高效的算法来保证实时性和精度。

随着计算机视觉、机器学习、深度学习等技术的进步，纯视觉定位技术也在不断发展。当前，深度学习技术被应用于特征点提取、匹配和图像处理，极大提升了视觉定位系统在复杂环境中的表现。当前，深度学习技术被广泛应用于特征点提取、匹配和图像处理，从而大幅提升了视觉定位系统在复杂动态环境中的表现。深度学习通过自动学习复杂的特征表示，能够显著提升在低光照、动态场景以及特征稀缺区域的鲁棒性。此外，卷积神经网络（CNN）和循环神经网络（RNN）等深度学习模型，已经在提升视觉里程计的准确性、稳定性和实时性方面发挥了重要作用。

激光雷达^[13]（Light Detection and Ranging, LiDAR），如图 1.4 所示，是一种基于激光测距原理的遥感技术。它通过发射激光束并测量激光反射回来的时间来确定目标物体的距离，从而生成精确的三维点云数据，如图 1.5 所示。



图 1.4 激光雷达

Figure 1.4 LiDAR




图 1.5 三维点云图

Figure 1.5 3D Point Cloud Diagram

LiDAR 广泛应用于 SLAM^[14]、地形测量、无人驾驶^[15]、机器人导航^[16]等多个领域。激光雷达的优点包括：（1）高精度：激光雷达具有极高的空间分辨率和精度，能够在短距离内提供厘米级的定位精度，适用于高精度需求的应用场景。（2）三维数据：激光雷达能够生成详细的三维点云数据，为空间信息的建模、目标识别和环境感知提供丰富的数据支持。（3）实时性强：激光雷达能够在高速运动的情况下实时生成三维数据，适用于动态环境中的实时感知与建图任务。（4）应用场景广泛：与依赖视觉传感器的系统相比，激光雷达不受光照条件的影响，能够在黑暗或光照变化剧烈的环境中稳定工作。尽管如此，激光雷达也存在一些缺点：（1）成本较高：相比于普通的视觉传感器或 IMU，激光雷达的价格较为昂贵，尤其是多线激光雷达。（2）数据处理复杂：激光雷达生成的点云数据量庞大，处理和分析这些数据需要强大的计算能力和高效的算法，尤其在实时处理时可能成为瓶颈。（3）易受反射影响：某些光滑或透明的表面（如水面、玻璃等）可能导致激光反射信号较弱，从而影响测量的准确性，特别是在这些特殊材料表面的应用中。（4）受天气影响：激光雷达在恶劣天气条件下（如雪天、雾霾或大雨等）会受到较大影响，导致测量精度下降或无法有效获取数据。

由于 LiDAR、IMU、GPS、摄像头等传感器各自存在一定的局限性和缺陷，特别是在复杂环境中，它们的性能往往无法满足高精度定位与导航的需求。为了弥补这些单一传感器的不足，近年来多传感器融合技术逐渐成为自动驾驶、机器人导航、无人机定位等领域的主流解决方案。

多传感器融合的核心理念是通过结合多个传感器的数据，充分利用各自的优

点，并减少单一传感器的缺陷。通过融合不同类型的传感器，系统能够获取更全面和精确的环境信息。这种融合不仅能够弥补单一传感器的局限，还能够显著提升系统的鲁棒性和准确性，特别是在复杂动态环境和恶劣气候条件下。例如，在雪天或大雾天气中，激光雷达的性能会受到严重影响，而视觉传感器也会面临图像模糊和能见度差的问题，可能导致误识别。此时，融合其他传感器（如 IMU）的数据，能够增强系统的环境感知能力，提升定位精度和鲁棒性。

1.2.2 基于滤波理论的传感器融合方法

基于滤波理论的传感器融合方法是现代自动化系统、智能机器人、无人驾驶以及其他高精度定位系统中的核心技术之一。随着技术的不断进步，滤波理论已成为传感器融合的基础，通过递推计算和数据融合，不仅能优化多个传感器的信息，还能弥补单一传感器的局限性，从而显著提升系统的整体性能和鲁棒性。在动态环境中，基于滤波的传感器融合方法尤为重要，能够有效处理不确定性、噪声和数据不一致性，特别是在实时系统中，发挥着至关重要的作用。

滤波理论的核心在于通过对动态系统状态的估计和更新，解决传感器数据融合问题。滤波算法的目标是利用传感器数据的时序特性，实时估计系统状态，并消除或减少测量误差和噪声。通过递推更新，滤波算法能够提供准确、平滑的估计结果，确保系统在不断变化的环境中稳定运行。

基于滤波理论的传感器融合方法具有以下优势：（1）动态估计与实时更新：滤波算法能够根据实时的传感器数据动态估计系统状态，并进行持续更新。这种递推更新机制使得系统能快速响应环境变化，尤其适用于需要即时反应的自动化任务。（2）噪声抑制与误差修正：在多传感器融合过程中，数据通常包含噪声和不确定性。滤波算法通过优化和加权处理，能够有效去除噪声并修正系统误差，从而提升估计精度。（3）多传感器协同：不同传感器在不同环境条件下具有各自的优势和局限性。滤波算法能够加权融合传感器数据，充分发挥各传感器的优点，弥补个别传感器的不足，进而提高系统的感知能力和鲁棒性。（4）计算复杂度较低：基于滤波理论的融合方法在计算复杂度方面具有显著优势，尤其适合实时应用和计算资源受限的系统。

常见的基于滤波理论的算法包括经典的卡尔曼滤波（Kalman Filter, KF）、扩展

卡尔曼滤波（Extended Kalman Filter, EKF）、无迹卡尔曼滤波（Unscented Kalman Filter, UKF）、粒子滤波（Particle Filter, PF）等，这些算法广泛应用于多传感器融合和动态系统中的状态估计。

1. 卡尔曼滤波（Kalman Filter）

卡尔曼滤波（Kalman Filter）是一种广泛应用于动态系统中的线性滤波算法，最早由 Kalman 于 1960 年提出^[17]。该算法通过递推计算系统状态，结合预测和测量更新，能够在噪声较大的环境下提供最优的状态估计。卡尔曼滤波假设系统模型是线性的，且噪声符合高斯分布，利用最小化均方误差来估计系统状态。凭借其高效的计算能力和出色的性能，卡尔曼滤波被广泛应用于精密导航、飞行控制和自动驾驶等领域。在导航领域，卡尔曼滤波能够有效地将来自不同传感器的数据融合，为系统提供精准的定位和姿态估计。这对自动驾驶和无人驾驶汽车的应用至关重要。在自动驾驶系统中，卡尔曼滤波与其他感知技术（如视觉传感器、激光雷达）结合，显著提高了系统的定位精度和鲁棒性。Thrun 等人^[18]在其研究中展示了卡尔曼滤波在多传感器融合中的关键作用，尤其是在 SLAM（同步定位与建图）问题中的应用。

2. 扩展卡尔曼滤波（Extended Kalman Filter）

由于实际应用中的许多系统是非线性的，经典的卡尔曼滤波（KF）方法无法直接应用。为了处理非线性系统，扩展卡尔曼滤波（EKF）应运而生，作为一种有效的优化方法。EKF 由 Julier 和 Uhlmann 于 1997 年提出，它通过对非线性系统进行一阶泰勒展开近似，克服了经典卡尔曼滤波在非线性和非线性系统中的局限性^[19]。通过线性化过程，EKF 能够近似处理复杂的非线性系统，尤其适用于无人驾驶、机器人导航等领域中的多传感器融合任务。

在无人驾驶汽车中，EKF 被广泛应用于传感器融合任务，尤其是在 IMU（惯性测量单元）、GPS（全球定位系统）和 LiDAR（激光雷达）等不同传感器的数据融合中，能够实时估计车辆的精确位置和姿态。Damagatla 等人提出了一种通过机器学习优化 EKF 的方法，以增强 IMU 与 GNSS 数据融合的精度和鲁棒性，该方法显著提高复杂环境中的定位稳定性^[20]。此外，Xu 等人提出了一种计算高效且稳健的 LiDAR-IMU 融合框架，用于实时估计位置和姿态。通过将 EKF 与 LiDAR 数据结合，提升了框架在动态环境下的表现，减少了误差^[21]。

3. 无迹卡尔曼滤波 (Unscented Kalman Filter)

与扩展卡尔曼滤波 (EKF) 相比, 无迹卡尔曼滤波 (UKF) 采用无迹变换 (Unscented Transformation) 来处理非线性问题, 避免了对系统模型进行线性化的需求。Wan 等人提出了 UKF, 成功克服了传统 EKF 在处理高度非线性系统时的局限性, 特别是在面对复杂噪声和系统状态变化较大的情况下, UKF 能够提供比 EKF 更精确的非线性估计^[22]。UKF 通过采样和传播状态分布, 能够更有效地捕捉系统的非线性特性, 因此特别适用于高动态系统中的传感器融合任务, 尤其在自动驾驶、航空航天和无人驾驶汽车的定位与导航中得到了广泛应用。

例如, Cahyadi 等人提出了一种利用 UKF 进行 GPS 和 IMU 传感器数据融合的算法, 显著提高了在水域环境中的导航精度^[23]。该算法通过有效地融合 GPS 和 IMU 数据, 在恶劣环境中提供了更为准确的位姿估计, 尤其在 GPS 信号较弱或丢失的情况下。

4. 误差状态卡尔曼滤波 (Error State Kalman Filter)

误差状态卡尔曼滤波 (ESKF) 是一种用于处理高精度定位和导航问题的滤波算法, 尤其适用于非线性系统, 广泛应用于多传感器数据融合的场景^[24]。ESKF 作为卡尔曼滤波的扩展, 通过估计系统的误差状态来优化系统的状态估计, 特别适用于惯性导航系统 (INS)。惯性测量单元 (IMU) 在长期运行中会产生误差积累 (如传感器噪声、漂移等), 而 ESKF 通过对这些误差的补偿, 显著提高了定位精度。

ESKF 的核心思想是通过估计系统状态的误差来改进原始的状态估计。具体而言, ESKF 通过对误差状态 (即实际状态与预测状态之间的差异) 进行滤波, 从而最小化系统状态的估计误差。在这一过程中, ESKF 不直接估计系统的真实状态, 而是通过对误差状态的估计来优化状态更新。这种方法使得 ESKF 在处理非线性系统时表现出色, 尤其在惯性导航和机器人定位中, 能够有效补偿系统中的误差。

与传统卡尔曼滤波方法不同, ESKF 在处理多传感器数据融合时, 不仅依赖于传感器的直接测量, 而是结合了预测模型和误差状态估计, 从而提高了多传感器系统的鲁棒性和精度。这使得 ESKF 在现代无人驾驶、机器人导航和航空航天等领域得到了广泛应用。Liu 等人提出自适应卡尔曼滤波与多传感器融合策略, 在复杂城

市环境中提升定位鲁棒性^[25]。

5. 粒子滤波 (Particle Filter, PF)

粒子滤波 (Particle Filter, PF) 是一种基于蒙特卡罗采样的非线性滤波算法, 由 Gordon 等人在 1993 年首次提出, 其核心思想是通过大量带权重的随机样本 (粒子) 逼近系统状态的后验概率分布^[26]。与卡尔曼滤波系列方法依赖线性化假设不同, 粒子滤波无需对非线性模型进行泰勒展开, 能够直接处理多模态和非高斯噪声问题, 特别适用于高动态、强非线性的场景, 如无人机避障和复杂环境目标跟踪。Doucet 等人于 2000 年提出的序贯蒙特卡罗方法 (Sequential Monte Carlo, SMC) 进一步优化了粒子滤波的序贯重要性采样 (SIS) 流程, 加入了重采样策略以抑制粒子退化问题, 从而显著提升了算法的鲁棒性^[27]。在机器人导航与 SLAM 领域, FastSLAM 算法^[28]通过 Rao-Blackwellised 粒子滤波 (RBPF) 将 SLAM 问题分解为路径估计 (使用粒子滤波) 与地图构建 (使用卡尔曼滤波), 实现大规模环境下的实时建图。视觉 SLAM 系统如 ORB-SLAM^[29] 则结合粒子滤波优化关键帧选择和闭环检测, 进一步提升了系统在复杂环境中的稳定性和准确性。

这些滤波算法为多传感器系统的高效融合和精确定位提供了强大的支持, 推动了自动驾驶、机器人、无人机等智能系统的快速发展。然而, 在位姿估计方面存在一些显著的缺陷与短板。

(1) 线性假设限制: 许多经典的滤波方法, 尤其是卡尔曼滤波 (KF) 和扩展卡尔曼滤波 (EKF), 假设系统模型是线性的, 或通过一阶泰勒展开将非线性模型线性化。然而, 现实中的许多系统, 尤其在处理复杂传感器数据 (如视觉传感器和激光雷达数据) 时, 往往是高度非线性的。例如, 位姿估计中, 旋转矩阵和四元数是当前常用的两种描述方式, 但它们本质上都是非线性的, 这使得滤波方法在捕捉系统的非线性特性时可能无法有效处理。(2) 噪声假设的依赖性: 卡尔曼滤波等经典滤波方法通常假设噪声符合高斯分布, 并且是独立同分布的。然而, 实际中, 噪声往往并非高斯分布, 且可能存在非高斯特性, 或者由于外部环境的影响, 噪声不再是独立同分布的。这使得经典滤波方法在应对实际噪声时的表现受限。(3) 状态估计精度依赖于初始化条件: 滤波方法的性能通常依赖于初始状态的准确估计。在传感器数据不足或系统存在大量不确定性的情况下, 初始估计可能会产生较

大的误差，进而影响后续的状态更新，导致整个滤波过程的精度下降。（4）高维系统计算复杂度高：尽管滤波方法在计算复杂度上通常优于优化方法，但在处理高维系统，特别是在多传感器数据融合的情况下，滤波方法的计算量仍然可能非常庞大，尤其是当系统涉及多个传感器时，计算复杂度可能成为瓶颈。

1.2.3 基于优化理论的传感器融合方法

优化理论通过全局优化方式整合多个传感器的数据，特别是在处理复杂的非线性系统时展现出强大的优势。优化算法通过构建目标函数或代价函数，描述系统的状态估计与实际测量数据之间的差异，并通过优化过程最小化该目标函数，从而得到最佳的传感器融合结果。与递推估计不同，优化方法通常从全局角度处理传感器数据，能够同时考虑所有观测数据的约束条件，进而获得更精确的系统状态估计。

优化方法与基于滤波的方法的最大区别在于，优化方法进行的是全局优化。滤波算法依赖当前观测值与前一时刻的状态来估计当前系统状态，而优化方法通过综合多时刻的观测数据，全局搜索最优解。全局优化的优势在于，它能处理多传感器的复杂信息，避免局部最优解的问题，特别适用于大规模、高度非线性系统。

在优化理论中，目标函数（或代价函数）的构建至关重要。目标函数的设计依据传感器数据的特性及系统需求，能够衡量预测系统状态与实际观测之间的误差。优化方法的主要优势包括：（1）全局优化能力：优化方法通过全局优化，能够同时考虑所有传感器数据的约束条件，而非仅依赖当前时刻的观测结果。这样，优化方法能够有效避免局部最优解，特别是在多传感器协同工作时，能够充分考虑所有数据，提供更精确的估计。（2）处理复杂非线性系统：优化方法擅长处理非线性系统，尤其是多传感器融合中常见的视觉传感器、激光雷达和 IMU 等传感器，这些传感器涉及复杂的非线性关系。通过构造非线性的目标函数，优化方法能有效优化这些复杂系统，从而提升状态估计精度。（3）高精度估计：优化方法通常能提供更高精度的估计，特别是在大规模、多传感器系统中，通过综合考虑所有数据点的约束关系，能够进行更为高效的状态估计。（4）并行计算与扩展性：优化方法通常可以进行并行计算，尤其在处理大量传感器数据时，使得优化方法能够在计算资源丰富的环境中高效运行。

常见的优化方法包括最小二乘法、非线性最优化、图优化及基于深度学习的优

化方法。与滤波方法不同，优化方法侧重于全局优化，目标是从一组给定的传感器数据中获得系统状态的最佳估计。这个过程通常需要大量计算，并且通常需要多次迭代才能逼近最优解。

1. 最小二乘法 (Least Squares, LS)

最小二乘法^[30]是一种经典的优化方法，通过最小化观测值与预测值之间的差异来估计系统状态。在传感器融合中，最小二乘法可以将多个传感器的测量数据结合起来，从而得到全局最优的状态估计。该方法广泛应用于线性系统的状态估计，尤其是在传感器融合的初步阶段，能够提供简便而有效的解决方案。最小二乘法的优点是实现简单，计算效率高，但它的缺点在于对噪声和异常值较为敏感，特别是在处理非线性系统时，可能无法得到理想的结果。

2. 非线性优化 (Nonlinear Optimization)

对于复杂的非线性系统，通常采用非线性最优化方法进行状态估计。非线性最优化算法^[31]通过构造合适的目标函数（例如最小化误差的平方和），优化系统状态，并利用梯度信息或其他搜索策略逐步逼近全局最优解。非线性优化方法特别适用于传感器融合中的高非线性问题，如视觉 SLAM 和激光雷达融合等应用。在这些场景中，传感器数据往往呈现高度非线性的关系，因此需要更复杂的优化方法来确保融合精度和系统性能。

3. 图优化 (Graph Optimization)

图优化方法近年来在传感器融合中得到了广泛应用，特别是在 SLAM（同步定位与建图）和路径规划中。图优化将状态估计问题表示为图中的节点和边，其中节点代表系统的状态，边表示状态之间的约束。目标是通过最小化图中所有边的代价函数，获得一个全局最优解。

在图优化中，因子图模型被广泛应用，它将多个传感器的数据和约束转化为图中的因子，并通过优化算法（如 Levenberg-Marquardt 算法）进行求解。图优化方法能够有效处理大规模、非线性的优化问题，尤其在多个传感器协同工作时，显著提升定位精度。

G2O^[32] (General Graph Optimization) 是一个开源的图优化框架，广泛用于 SLAM 和其他图优化任务中。G2O 框架旨在提供一个高效、灵活的图优化解决方案，能够

处理大规模的非线性优化问题。它可以优化多种类型的图结构，如位姿图（Pose Graph）和因子图（Factor Graph）等。Wen 等人针对城市峡谷环境中 GNSS 信号受建筑物遮挡和反射导致的定位失效问题，提出了一种基于因子图优化（Factor Graph Optimization, FGO）的鲁棒性定位框架^[33]；而 Shan 等人提出的 LIO-SAM 是一种基于因子图优化的紧耦合多传感器融合框架，通过融合激光雷达（LiDAR）、惯性测量单元（IMU）和可选 GPS 数据，实现高精度实时定位与建图^[34]。

4. 深度学习与优化方法结合

随着人工智能技术的发展，深度学习与传统优化方法的结合在传感器融合中得到了广泛应用。深度学习能够从大量的传感器数据中自动学习特征和模式，并将这些学到的信息应用于数据的优化与融合。例如 Tang 等人所撰写的基于深度学习的多模态传感器融合比较综述^[35]。

在深度学习方法中，神经网络被用于近似复杂的非线性关系，尤其在处理来自视觉传感器、激光雷达等高维数据时，深度学习通过卷积神经网络（CNN）和递归神经网络（RNN）等架构，能够学习数据的时序特征和空间特征。通过将深度学习模型与优化方法结合，能够实现更高精度的传感器融合，特别是在处理复杂动态环境和大规模数据集时，深度学习能显著提升系统性能。

例如，深度强化学习（DRL）在路径规划和决策过程中结合优化算法，提供了自适应的解决方案，自动优化系统的行为与决策过程。Chu 等人提出了一种基于深度强化学习（DRL）的自主水下航行器（AUV）路径规划方法，重点解决海洋洋流扰动下的动态环境适应性问题^[36]。深度学习与图优化结合的方式（如深度图优化）已在自动驾驶系统中得到应用，实现了更高效、鲁棒的传感器数据融合。例如，Choi 等人提出了一种传感器融合系统，该系统结合红外热像仪与 LiDAR 传感器，能够在白天或黑夜等能见度较差的环境中可靠地检测和识别物体^[38]。

5. IMU 预积分

IMU 预积分是一种用于处理惯性测量单元（IMU）数据的技术，最早由 Lupton 等人于 2012 年提出^[41]，Forster 等人于 2015 年将其进一步拓展到李代数上，形成了一套完善的理论体系^[42]。该方法通过在短时间间隔内对 IMU 的加速度和角速度进行积分，从而推算物体的运动状态（如位置、速度和姿态）。在惯性导航中，IMU

会随着时间推移累积测量误差，例如加速度计的偏差和陀螺仪的漂移，导致长期积分精度下降。IMU 预积分技术通过优化算法缓解这一问题，尤其在实时定位和导航系统中，显著提高了系统的稳定性和精度。

具体来说，IMU 预积分方法将 IMU 测量值划分为多个时间段，对每个时间段内的加速度和角速度数据进行积分，从而获得当前位置和姿态的估计。与传统的积分方法相比，IMU 预积分能有效减少误差积累引起的精度下降，特别是在短时间、采样频率高的情况下。这一理论已被广泛的应用在基于光束平差法（Bundle Adjustment）优化框架的视觉惯性里程计（Visual Inertial Odometry）中。例如，由 Stumberg 等人[43]所提出的基于单目视觉与惯性传感器融合的高精度里程计框架 DM-VIO（Delayed Marginalization Visual-Inertial Odometry）。Mur-Artal 等人所提出的 VI-ORB-SLAM（Visual-Inertial ORB-SLAM）支持单目、双目和 RGB-D 相机与 IMU 的融合，其核心设计延续了 ORB-SLAM 的模块化架构，但通过 IMU 预积分方法显著提升了运动估计的鲁棒性和精度^[45]。Qin 等人提出的基于非线性优化的单目视觉-IMU 紧耦合算法 VINS-Mono 联合优化相机位姿、速度、IMU 偏差和 3D 地图点，采用预积分理论（IMU 预积分）降低计算复杂度，实现实时性^[46]。Yu 等人提出的 Vins-motion 是对 VINS-Mono 的重要改进工作，专注于通过融合运动学约束提升状态估计的鲁棒性和精度^[45]。此外，Liu 等人所提出的 ICE-BA 是 SLAM 和三维重建领域中对传统 Bundle Adjustment（BA）方法的重大改进^[47]。

这些优化方法已经经过长期的理论和实验验证，展现出了卓越的性能。但也存在一些挑战：（1）计算复杂度高：优化方法，尤其是在处理非线性系统时，通常需要进行大量计算。特别是在面对大规模数据和高维系统时，计算复杂度会迅速增加，导致性能瓶颈。（2）实时性差：优化方法通常需要在多个观测数据点之间进行全局优化，而滤波方法通过递推计算，可以在每个时刻快速更新状态估计。因此，优化方法在实时性方面往往无法与基于滤波的算法相媲美，特别是在高频数据流应用中，如自动驾驶中的实时定位。（3）局部最优解问题：尽管优化方法通过全局搜索进行状态估计，但在实际应用中，由于数据的不完整性、噪声和异常值的干扰，优化过程可能会陷入局部最优解，而非全局最优解，影响最终的估计精度。（4）依赖于良好的目标函数设计：优化方法的效果高度依赖于目标函数（或损失函数）

的设计。在多传感器融合问题中，目标函数需要精确表达系统状态与实际观测之间的差异。如果目标函数设计不合理或无法准确反映系统的真实约束，优化算法可能无法得到准确的结果。（5）大规模问题求解困难：随着传感器数量和数据量的增加，多传感器融合应用中的优化问题会变得更加复杂。优化方法需要处理大量参数和复杂约束，导致在大规模系统中的求解变得更加困难和耗时。

1.3 本文研究内容

通过对国内外在位姿估计领域相关研究的归纳与分析可以发现，当前多传感器融合技术尽管已取得显著进展，但在实际应用中仍面临诸多挑战，特别是在姿态表示的非线性建模、滤波器数值稳定性、算法实时性等方面仍存在亟待解决的问题。

针对上述问题，本文重点研究了三个方面的内容：

（1）基于流形空间的误差状态卡尔曼滤波算法设计：本论文将旋转状态建模在流形空间中，并在误差状态卡尔曼滤波框架下，利用切空间（李代数）对姿态误差进行线性化处理。该方法有效避免了传统欧拉角表示的奇异性问题，以及四元数冗余参数带来的数值不稳定与归一化约束，提升了滤波器的精度、稳定性与计算效率，具备良好的实时性和工程实用性。

（2）基于该算法的 IMU-GPS 融合系统设计与实现：面向低频率、广域导航应用，本文构建了基于所提 ESKF 算法的 IMU-GPS 融合系统。该算法通过误差状态建模，有效地克服了 IMU 漂移等问题，提升了系统在动态环境中的鲁棒性。利用 IMU 提供的高频动态信息和 GPS 的静态定位信息。实验表明，在非线性和非线性系统中，该方法能够实时、准确地估算位姿。

（3）基于该算法的 IMU-LiDAR 融合系统设计与实现：本文进一步将所提出的基于流形空间优化的误差状态卡尔曼滤波算法应用于 IMU 和高维激光雷达

（LiDAR）数据的融合，以实现在复杂和动态环境中的高精度位姿估计。激光雷达具有高空间分辨率和强环境感知能力，能够提供稠密且稳定的三维点云信息，特别适用于结构丰富或变化频繁的场景。通过融合激光雷达的观测信息与 IMU 提供的高频惯性数据，有效补偿了因惯性测量误差积累所导致的姿态与位置漂移问题。针对 LiDAR 数据维度高、处理计算量大的特点，本文在 ESKF 框架中引入了一种改进的卡尔曼增益计算策略，对观测更新步骤进行了优化，显著降低了矩阵计算复

杂度。

1.4 本文组织架构

本文基于误差状态卡尔曼滤波技术，提出了两种传感器融合方案，分别是 IMU 和 GPS 的数据融合以及 IMU 和激光雷达的数据融合。论文各章节内容安排如下：

第一章，绪论：本章简要介绍了本研究的背景与意义，并回顾了国内外相关领域的研究现状，提出了本文的研究目标和内容，最后概述了论文的结构安排。

第二章，相关理论基础：本章详细介绍了与本文研究相关的基础理论，包括流形上的 IMU 运动学的定义，以及贝叶斯滤波、卡尔曼滤波和误差状态卡尔曼滤波的理论推导。

第三章，基于流形空间误差状态卡尔曼滤波 IMU 和 GPS 融合算法：本章讨论了 IMU 与 GPS 数据融合所面临的技术难题，介绍了误差状态卡尔曼滤波（ESKF）的原理及数学推导过程，并通过实验验证了该算法的可行性。

第四章，基于流形空间误差状态卡尔曼滤波 IMU 和激光雷达融合算法：本章探讨了 IMU 与激光雷达数据融合中的技术难题，并引入了一种新的卡尔曼增益计算公式，并通过实验验证了该算法的可行性。

第五章，总结与展望：本章总结了论文的主要研究内容和创新点，并探讨了未来传感器融合任务的研究方向。

第二章 相关理论基础

本章主要介绍了 IMU 运动学和误差卡尔曼滤波的相关概念，理论。首先定义了流形空间中的 IMU 运动学，其次介绍了误差状态卡尔曼滤波算法。

2.1 IMU 运动学

2.1.1 坐标系

如果要定义一个物体位置和姿态，首先应该定义其所处坐标系。在这里，有两种非常重要的参考坐标系，世界坐标系和自身坐标。

(1) 世界坐标系 (World Coordinate System)

世界坐标系通常是一个固定的、全局的参考坐标系，用于描述物体在空间中的位置。它是所有物体和运动的统一参考，通常选择在地面或某一固定的地方设定。可以将其视为地球坐标系或实验场景中的固定坐标系。

(2) 自身坐标系 (Body Coordinate System)

自身坐标系是一个随着物体的运动而变化的参考坐标系，通常位于物体的质心处，或者以物体本身为参考点。它用来描述物体相对于自身的运动和姿态（如物体如何转动、如何加速）。在 IMU 中，自身坐标系通常由加速度计、陀螺仪等传感器测量并确定。

世界坐标系和自身坐标系的关系通过旋转矩阵来描述。假设在世界系下，点 p 的坐标为 p_w ，它在它在自身坐标系下的坐标为 p_b ，那么定义变换矩阵 R_{wb} 和平移向量 t_{wb} ，则有：

$$\mathbf{p}_w = \mathbf{R}_{wb}\mathbf{p}_b + \mathbf{t}_{wb} \quad (2-1)$$

2.1.2 旋转矩阵与旋转向量

在三维空间中，旋转是指物体绕轴进行的运动。旋转矩阵和旋转向量^{[48][52]}是描述和表示物体在三维空间中旋转的常见数学工具，它们可以用来描述物体的姿态（即物体的空间方向）。

(1) 旋转矩阵 (Rotation Matrix)

旋转矩阵是一个 3×3 的正交矩阵，同时也是一个三维的李群^{[49][52]} $SO(3)$ ，用于描述刚体的旋转操作，它满足以下性质：

$$\mathbf{R}^T \mathbf{R} = \mathbf{I} \quad (2-2)$$

(2) 旋转向量 (Rotation Vector)

旋转向量也称为角轴，是一种更简洁的表示旋转的方法，同时也是旋转矩阵群所对应的李代数 $\mathfrak{so}(3)$ 。它使用一个向量来表示旋转。旋转向量的大小表示旋转角度，方向表示旋转轴。它与旋转矩阵之间有直接的数学联系。

记一个旋转向量为 $\boldsymbol{\omega} \in \mathbb{R}^3$ ，可以分解为 $\boldsymbol{\omega} = \theta \mathbf{n}$ ，那么旋转向量和旋转矩阵的转换关系可以由罗德里格斯公式 (Rodrigues' formula) 或者李群上的指数映射来描述：

$$\mathbf{R} = \cos \theta \mathbf{I} + (1 - \cos \theta) \mathbf{n} \mathbf{n}^T + \sin \theta \mathbf{n}^\wedge = \exp(\boldsymbol{\omega}^\wedge) \quad (2-3)$$

这里 $\wedge$ 符号指的是将一个向量变换成反对称矩阵的形式^[52]：

$$\mathbf{a} = [a_1 \quad a_2 \quad a_3]^T \Rightarrow \mathbf{a}^\wedge = \begin{bmatrix} 0 & -a_3 & a_2 \\ a_3 & 0 & -a_1 \\ -a_2 & a_1 & 0 \end{bmatrix} \quad (2-4)$$

2.1.3 旋转矩阵的微分

物体的旋转和平移可分别由旋转矩阵 $\mathbf{R}$ 和位移 $\mathbf{t}$ 来描述，在连续的运动中，旋转矩阵和位移是关于时间 t 的函数 $\mathbf{R}(t)$ 和 $\mathbf{t}(t)$ 。显然，对于平移，微分是平凡的，但对于旋转矩阵，有：

$$\frac{d}{dt}(\mathbf{R}^T \mathbf{R}) = (\mathbf{R}')^T \mathbf{R} + \mathbf{R}^T (\mathbf{R}') = \mathbf{0} \quad (2-5)$$

可以得到：

$$\mathbf{R}^T (\mathbf{R}') = -[\mathbf{R}^T (\mathbf{R}')]^T \quad (2-6)$$

$\mathbf{R}^T (\mathbf{R}')$ 是一个反对称矩阵，设 $\boldsymbol{\omega}^\wedge \in \mathbb{R}^{3 \times 3} = \mathbf{R}^T (\mathbf{R}')$ ，可以得到 $\mathbf{R}$ 的微分方程：

$$\mathbf{R}' = \mathbf{R} \boldsymbol{\omega}^\wedge \quad (2-7)$$

给定初值 t_0 时刻的旋转矩阵为 $\mathbf{R}(t_0)$ ，则微分方程的解为：

$$\mathbf{R}(t) = \mathbf{R}(t_0) \exp[\boldsymbol{\omega}^\wedge (t - t_0)] \quad (2-8)$$

记 $\Delta t = t - t_0$ ，并且 $\exp(\boldsymbol{\omega}^\wedge) = \text{Exp}(\boldsymbol{\omega})$ ，该式可以写为：

$$\mathbf{R}(t) = \mathbf{R}(t_0) \text{Exp}(\boldsymbol{\omega} \Delta t) \quad (2-9)$$

另外，对旋转矩阵 $\mathbf{R}(t)$ 在时间 t_0 处一阶泰勒展开，可以得到一阶近似表达式：

$$\begin{aligned} \mathbf{R}(t_0 + \Delta t) &\approx \mathbf{R}(t_0) + \mathbf{R}'(t_0) \Delta t \\ &= \mathbf{R}(t_0) + \mathbf{R}(t_0) \boldsymbol{\omega}^\wedge \Delta t \\ &= \mathbf{R}(t_0) (\mathbf{I} + \boldsymbol{\omega}^\wedge \Delta t) \end{aligned} \quad (2-10)$$

则有：

$$\begin{aligned}\text{Exp}(\boldsymbol{\omega}\Delta t) &= \mathbf{I} + \boldsymbol{\omega}^{\wedge}\Delta t + \frac{1}{2}(\boldsymbol{\omega}^{\wedge}\Delta t)^2 + \cdots \\ &\approx \mathbf{I} + \boldsymbol{\omega}^{\wedge}\Delta t\end{aligned}\quad (2-11)$$

2.1.4 IMU 器件测量模型与运动学模型

IMU 在测量角速度与加速度的过程中，是被固定在被测物体上的，故其测量所得结果均处于自身坐标系下。

(1) 陀螺仪测量模型

$$\boldsymbol{\omega}_m(t) = \boldsymbol{\omega}(t) + \mathbf{b}_g(t) + \mathbf{n}_g(t) \quad (2-12)$$

其中，下标 m 表示测量，下标 g 表示陀螺仪； $\mathbf{b}_g(t)$ 是陀螺仪随时间变化的偏置，服从随机游走模型， $\mathbf{n}_g(t)$ 是陀螺仪的测量噪声，服从零均值高斯白噪声。该模型忽略地球自转对陀螺仪的影响。

(2) 加速度计测量模型

$$\mathbf{a}_m = \mathbf{R}^T(\mathbf{a} - \mathbf{g}) + \mathbf{b}_a(t) + \mathbf{n}_a(t) \quad (2-13)$$

其中，下标 a 表示加速度， $\mathbf{g}$ 表示重力加速度， $\mathbf{b}_a(t)$ 是加速度计随时间变化的偏置， $\mathbf{n}_a(t)$ 是加速度计的测量噪声，服从零均值高斯白噪声。

对于 IMU 的运动学方程，均在世界系中考虑，具体微分方程形式如下：

$$\mathbf{R}'(t) = \mathbf{R}(t)\boldsymbol{\omega}(t)^{\wedge} \quad (2-14)$$

$$\mathbf{p}'(t) = \mathbf{v}(t) \quad (2-15)$$

$$\mathbf{v}'(t) = \mathbf{a}(t) \quad (2-16)$$

其中， $\mathbf{R}(t)$ 表示姿态， $\mathbf{p}(t)$ 表示位置， $\mathbf{v}(t)$ 表示速度， $\mathbf{a}(t)$ 表示加速度。

使用欧拉积分，可得到运动学方程的离散形式：

$$\mathbf{R}(t + \Delta t) = \mathbf{R}(t)\text{Exp}(\boldsymbol{\omega}(t) \cdot \Delta t) \quad (2-17)$$

$$\mathbf{p}(t + \Delta t) = \mathbf{p}(t) + \mathbf{v}(t)\Delta t + \frac{1}{2}\mathbf{a}(t)\Delta t^2 \quad (2-18)$$

$$\mathbf{v}(t + \Delta t) = \mathbf{v}(t) + \mathbf{a}(t) \cdot \Delta t \quad (2-19)$$

欧拉积分其是一种数值方法，可以将微分方程近似为递推的形式。对于微分方程：

$$\mathbf{y}'(t) = \mathbf{f}(t, \mathbf{y}(t)) \quad (2-20)$$

设两个时刻 t 和 $t + \Delta t$ ，则欧拉积分定义为：

$$y'(t) = \frac{y(t + \Delta t) - y(t)}{\Delta t} = f(t, y(t)) \quad (2-21)$$

$$y(t + \Delta t) = y(t) + f(t, y(t))\Delta t \quad (2-22)$$

将测量模型 (2-12) 和 (2-13) 代入离散运动学方程，可得 IMU 运动学方程：

$$\begin{aligned} \mathbf{R}(t + \Delta t) &= \mathbf{R}(t)\text{Exp}(\boldsymbol{\omega}(t) \cdot \Delta t) \\ &= \mathbf{R}(t)\text{Exp}((\boldsymbol{\omega}_m - \mathbf{b}_g(t) - \mathbf{n}_{gd}(t)) \cdot \Delta t) \end{aligned} \quad (2-23)$$

$$\begin{aligned} \mathbf{p}(t + \Delta t) &= \mathbf{p}(t) + \mathbf{v}(t)\Delta t + \frac{1}{2}a(t)\Delta t^2 \\ &= \mathbf{p}(t) + \mathbf{v}(t)\Delta t + \frac{1}{2}[\mathbf{R}(t) \cdot (a_m - \mathbf{b}_a(t) - \mathbf{n}_{ad}(t)) + \mathbf{g}]\Delta t^2 \\ &= \mathbf{p}(t) + \mathbf{v}(t)\Delta t + \frac{1}{2}\mathbf{g}\Delta t^2 + \frac{1}{2}\mathbf{R}(t) \cdot (a_m - \mathbf{b}_a(t) - \mathbf{n}_{ad}(t))\Delta t^2 \end{aligned} \quad (2-24)$$

$$\begin{aligned} \mathbf{v}(t + \Delta t) &= \mathbf{v}(t) + a(t)\Delta t \\ &= \mathbf{v}(t) + \mathbf{R}(t) \cdot (a_m(t) - \mathbf{b}_a(t) - \mathbf{n}_{ad}(t))\Delta t + \mathbf{g}\Delta t \end{aligned} \quad (2-25)$$

式 (2-23)、(2-24) 和 (2-25) 中噪声项与偏置项均采用离散噪声形式。

可以进一步假设 $\Delta t = 1$ ，每个离散时刻由 $k = 0, 1, 2, \dots$ 表示，IMU 离散运动学方程可以简化为：

$$\mathbf{R}_{k+1} = \mathbf{R}_k \cdot \text{Exp}((\boldsymbol{\omega}_{(m)k} - \mathbf{b}_{(g)k} - \mathbf{n}_{(gd)k})) \quad (2-26)$$

$$\mathbf{p}_{k+1} = \mathbf{p}_k + \mathbf{v}_k + \frac{1}{2}\mathbf{g} + \frac{1}{2}\mathbf{R}_k(a_{(m)k} - \mathbf{b}_{ak} - \mathbf{n}_{(ad)k}) \quad (2-27)$$

$$\mathbf{v}_{k+1} = \mathbf{v}_k + \mathbf{R}_k(a_{(m)k} - \mathbf{b}_{ak} - \mathbf{n}_{(ad)k}) + \mathbf{g} \quad (2-28)$$

2.1.5 流形空间上的 IMU 状态变量

设 M 是 n 维流形^[50] (e.g. $M \in SO(3)$)，流形局部同胚于 $\square^n$ ，可以定义 M 的局部领域到其切空间 $\square^n$ 的双向映射，由两个算子 ($\cdot$ 和 $'$) 表示：

$$(\cdot : M \times \square^n \rightarrow M \quad (2-29)$$

$$' : M \times M \rightarrow \square^n \quad (2-30)$$

当 $M \in SO(3)$ ，有以下运算：

$$\mathbf{R}(\mathbf{r}) = \mathbf{R}\text{Exp}(\mathbf{r}) \quad (2-31)$$

$$\mathbf{R}_1' \mathbf{R}_2 = \text{Log}(\mathbf{R}_2^T \mathbf{R}_1) \quad (2-32)$$

其中, $\text{Exp}(\mathbf{r}) = \mathbf{I} + \frac{\mathbf{r}}{\|\mathbf{r}\|} \sin(\|\mathbf{r}\|) + \frac{\mathbf{r}^2}{\|\mathbf{r}\|^2} (1 - \cos(\|\mathbf{r}\|))$ 是指数映射, $\text{Log}()$ 是与指数映射相对应的逆映射[52]。

当 $\mathbf{M} \in \mathbb{R}^n$, 有以下运算:

$$\mathbf{a}(\mathbf{b}) = \mathbf{a} + \mathbf{b} \quad (2-33)$$

$$\mathbf{a}'(\mathbf{b}) = \mathbf{a} - \mathbf{b} \quad (2-34)$$

对于一个复合流形 $\mathbf{M} \in SO(3) \times \mathbb{R}^n$, 有:

$$\begin{bmatrix} \mathbf{R} \\ \mathbf{a} \end{bmatrix}(\begin{bmatrix} \mathbf{r} \\ \mathbf{b} \end{bmatrix}) = \begin{bmatrix} \mathbf{R}(\mathbf{r}) \\ \mathbf{a} + \mathbf{b} \end{bmatrix} \quad (2-35)$$

$$\begin{bmatrix} \mathbf{R}_1 \\ \mathbf{a} \end{bmatrix}, \begin{bmatrix} \mathbf{R}_2 \\ \mathbf{b} \end{bmatrix} = \begin{bmatrix} \mathbf{R}_1' \mathbf{R}_2 \\ \mathbf{a} - \mathbf{b} \end{bmatrix} \quad (2-36)$$

(运算如图 2.1 所示。




图 2.1 流形上的(运算

Figure 2.1 (Operations on Manifolds)

IMU 状态变量可以表示为^[51]:

$$\mathbf{M} = SO(3) \times \mathbb{R}^{15}, \dim(\mathbf{M}) = 18 \quad (2-37)$$

$$\mathbf{x}(t) = \begin{bmatrix} {}^G \mathbf{R}_I^T & {}^G \mathbf{p}_I^T & {}^G \mathbf{v}_I^T & \mathbf{b}_\omega^T & \mathbf{b}_a^T & {}^G \mathbf{g}^T \end{bmatrix}^T$$

其中, ${}^G \mathbf{R}_I^T$ 表示世界系下的姿态, ${}^G \mathbf{p}_I^T$ 表示世界系下的位置, ${}^G \mathbf{v}_I^T$ 表示世界系下的速度, $\mathbf{b}_\omega^T$ 表示本体系下的陀螺仪的偏置, $\mathbf{b}_a^T$ 表示本体系下的加速度计的偏置, ${}^G \mathbf{g}^T$ 表示世界系下的重力加速度。

2.2 贝叶斯滤波

贝叶斯滤波是一种基于概率论的滤波方法，广泛应用于动态系统的状态估计问题，尤其在自适应估计、目标跟踪、导航与定位等领域具有重要应用。贝叶斯滤波的核心思想是通过对系统状态的概率分布进行推断和更新，从而实现对系统状态的估计。

贝叶斯滤波的基本思想是，给定当前和过去的观测数据，利用贝叶斯原理来计算当前时刻系统状态的后验概率分布。贝叶斯滤波是递推式的，每一步根据当前的观测和前一时刻的状态进行更新。而卡尔曼滤波是基于贝叶斯滤波的。

2.2.1 贝叶斯定理

贝叶斯滤波的核心是贝叶斯定理。贝叶斯定理描述了条件概率之间的关系

$$P(A|B) = \frac{P(B|A) \cdot P(A)}{P(B)} \quad (2-38)$$

其中 $P(A)$ 是试验前的假定概率，被称为先验概率； $P(B|A)$ 为似然概率，是先前统计的事件中， A 事件发生情况下 B 事件发生的概率； $P(A|B)$ 称为后验概率，是事件 A 在已知事件 B 的情况下发生的概率。可以总结为先验概率经过信息观测而得到后验概率。

2.2.2 状态空间

状态空间模型是一种描述动态系统行为的数学模型，它使用一组一阶微分方程（连续时间系统）或差分方程（离散时间系统）来表示系统的内部状态的演化，同时用另一组方程来描述系统状态和输出之间的关系。这些方程可以表示为矩阵和向量的形式，以处理多变量系统。

在状态空间表述中，系统由下面的两个方程组定义：

(1) 状态方程

$$X_k = f(X_{k-1}) + V_k \quad (2-39)$$

(2) 观测方程

$$Y_k = h(X_k) + W_k \quad (2-40)$$

在状态方程中，假设过程噪声 V_k 是通过加法作用在 $f()$ 上（二者都处于欧氏空间当中，对加法运算封闭），并且假设 $V_k, V_{k-1}, \dots, V_0, X_0$ 相互独立。同样，在观测方

程中, 假设观测噪声 W_k 是通过加法作用在 $h()$ 上, 假设 $W_k, \dots, W_1, V_k, \dots, V_0, X_0$ 相互独立。词假设被称为马尔可夫假设。

2.2.3 递推步骤

贝叶斯滤波的推导过程可以分为两个主要步骤: 预测 (Prediction) 和更新 (Update)。这两个步骤在每个时间步都会执行一次, 递推更新系统状态的估计。

(1) 预测步骤

在预测步骤中, 根据前一时刻的状态估计和已知的动态模型, 预测当前时刻的状态。已知上一时刻的后验估计 X_{k-1}^+ 的分布函数为:

$$P(X_{k-1}^+ < x) = \int_{-\infty}^x f_{X_{k-1}^+}(x) dx \quad (2-41)$$

当前时刻噪声 W_k 和 V_k 的分布函数, 分别记为:

$$P(W_k < x) = \int_{-\infty}^x f_{W_k}(x) dx \quad (2-42)$$

$$P(V_k < x) = \int_{-\infty}^x f_{V_k}(x) dx \quad (2-43)$$

对于预测步, 有:

$$\begin{aligned} P(X_k < x) &= P(X_k < x, -\infty < X_{k-1} < +\infty) \\ &= \int_{-\infty}^x \left[\int_{-\infty}^{+\infty} f_{X_k|X_{k-1}}(x, y) dy \right] dx \end{aligned} \quad (2-44)$$

$$f_{X_k|X_{k-1}}(x, y) = f_{X_k|X_{k-1}}(x|y) \cdot f_{X_{k-1}}(y) = f_{W_k}(x - f(y)) f_{X_{k-1}}(y) \quad (2-45)$$

由(2-45)可得:

$$P(X_k < x) = \int_{-\infty}^x \left\{ \int_{-\infty}^{+\infty} f_{W_k}(x - f(y)) f_{X_{k-1}}(y) dy \right\} dx \quad (2-46)$$

而 X_k 的概率密度函数为:

$$f_{X_k^-} = \int_{-\infty}^{+\infty} f_{W_k}(x - f(y)) f_{X_{k-1}}(y) dy \quad (2-47)$$

(2) 更新步骤

在更新步骤中, 通过本时刻的观测数据 y_k 来修正状态的预测值:

$$\begin{aligned}
 P(X_k < x | Y_k = y_k) &= \int_{-\infty}^x \frac{f_{X_k Y_k}(x, y_k)}{f_{Y_k}(y_k)} dx \\
 &= \eta \int_{-\infty}^x f_{X_k Y_k}(x, y_k) dx
 \end{aligned} \tag{2-48}$$

$$\begin{aligned}
 f_{X_k Y_k}(x, y_k) &= f_{Y_k | X_k}(y_k | x) \cdot f_{X_k}(x) \\
 &= f_{V_k}[y - h(x)] f_{X_k^-}(x)
 \end{aligned} \tag{2-49}$$

$$P(X_k < x | Y_k = y_k) = \eta \int_{-\infty}^x f_{V_k}[y - h(x)] f_{X_k^-}(x) dx \tag{2-50}$$

$$f_{X_k | Y_k}(x | y) = \eta f_{V_k}[y - h(x)] f_{X_k^-}(x) \tag{2-51}$$

对(2-51)两边同时积分可得：

$$\eta = \left[\int_{-\infty}^{+\infty} f_{V_k}[y - h(x)] f_{X_k^-}(x) dx \right]^{-1} \tag{2-52}$$

2.2.4 后验估计

贝叶斯滤波的最终目标是通过后验分布来获取当前时刻的状态估计 $\hat{x}_k^+$ 。一般，有两种方法得到后验估计，如图 2.2 所示：

(1) 求期望

$$\hat{x}_k^+ = E(X_k^+) = \int_{-\infty}^{+\infty} x f_{X_k | Y_k}(x | y_k) dx \tag{2-53}$$

(2) 最大后验概率 (MAP)

$$\hat{x}_k^+ = \text{Max}(f_{X_k | Y_k}(x | y_k)) \tag{2-54}$$




图 2.2 期望与最大后验估计

Figure 2.2 Expectation and Maximum A Posteriori Estimation

2.3 卡尔曼滤波

在 2.2 中, 贝叶斯滤波的推导步骤已经展示了如何通过预测和更新两步递推来估计系统的状态。然而, 在实际应用中, 求解预测过程中的先验概率密度函数 $f_{X_k^-}$ 、更新过程中的常数 η 、最终的最优估计 $\hat{x}_k^+$ 均涉及无穷积分, 而在多数情况下, 无穷积分一般不存在解析解。特别是在高维度或非线性系统中, 这会导致计算异常困难。因此, 通常需要对贝叶斯滤波进行一些约束, 从而简化相应的计算, 使其适用于实际问题。

其中一个非常重要的简化假设是系统状态和观测模型是线性的, 且噪声服从高斯分布。在这种假设下, 贝叶斯滤波的推导可以进一步简化, 并转化为一个非常高效的递推算法——卡尔曼滤波。

2.3.1 状态空间

卡尔曼滤波假设系统状态的动态变化和观测模型都是线性的, 并且所有的噪声(过程噪声和观测噪声)都服从高斯分布。

(1) 状态方程

$$\begin{aligned} X_k &= f(X_{k-1}) + V_k \\ &= FX_{k-1} + Bu_k + V_k \end{aligned} \quad (2-55)$$

其中, $X_k \sim N(\mu_X, \sigma_X^2)$ 是系统的状态, F 是状态转移项, B 是控制比例项, u_k 是控制输入, $V_k \sim N(0, \sigma_V^2)$ 是过程噪声。

(2) 观测方程

$$\begin{aligned} Y_k &= h(X_k) + W_k \\ &= HX_k + W_k \end{aligned} \quad (2-56)$$

其中, Y_k 是观测数据, H 是观测矩阵, $W_k \sim N(0, \sigma_W^2)$ 是观测噪声。

2.3.2 递推步骤

(1) 预测步骤

设 $k-1$ 时刻状态变量 $X_{k-1} \sim (\mu_{k-1}^+, \sigma_{k-1}^{+2})$, 则 X_{k-1} 的后验概率密度函数为:

$$f_{X_{k-1}^+} = \frac{1}{\sqrt{2\pi\sigma_{k-1}^{+2}}} e^{-\frac{(x-\mu_{k-1}^+)^2}{2\sigma_{k-1}^{+2}}} \quad (2-57)$$

k 时刻状态变量 X_k 的先验概率密度函数为:

$$\begin{aligned} f_{X_k^-}(x) &= \int_{-\infty}^{+\infty} f_{V_k}[x - f(v)] f_{X_{k-1}^+}(v) dv \\ &= \int_{-\infty}^{+\infty} \frac{1}{\sqrt{2\pi}\sigma_{Q_k}} e^{-\frac{(x-Fv-Bu_k)^2}{2\sigma_{Q_k}^2}} \cdot \frac{1}{\sqrt{2\pi}\sigma_{k-1}^+} e^{-\frac{(v-\mu_{k-1}^+)^2}{2\sigma_{k-1}^{+2}}} dv \end{aligned} \quad (2-58)$$

对于(2-58)利用傅里叶变换可得:

$$f_{X_k^-}(x) = \frac{1}{\sqrt{2\pi(F^2\sigma_{k-1}^{+2} + \sigma_{Q_k}^2)}} e^{-\frac{(x-F\mu_{k-1}^+ - Bu_k)^2}{2(F^2\sigma_{k-1}^{+2} + \sigma_{Q_k}^2)}} \quad (2-59)$$

$f_{X_k^-}(x)$ 的均值和方差分别为:

$$\mu_k^- = F\mu_{k-1}^+ + Bu_k \quad (2-60)$$

$$\sigma_k^- = F^2\sigma_{k-1}^{+2} + \sigma_{Q_k}^2 \quad (2-61)$$

(2) 更新步骤

k 时刻状态变量 X_k 的后验概率密度函数为:

$$\begin{aligned} f_{X_k^+}(x) &= \eta \cdot f_{W_k}[y_k - h(x)] \cdot f_{X_k^-}(x) \\ &= \eta \frac{1}{\sqrt{2\pi}\sigma_{R_k}} e^{-\frac{(x-Hx)^2}{2\sigma_{R_k}^2}} \cdot \frac{1}{\sqrt{2\pi}\sigma_k^-} e^{-\frac{(x-\mu_k^-)^2}{2\sigma_k^{-2}}} \end{aligned} \quad (2-62)$$

其中, 常数 η 为:

$$\eta = \left[\int_{-\infty}^{+\infty} \frac{1}{\sqrt{2\pi}\sigma_{R_k}} e^{-\frac{(x-Hx)^2}{2\sigma_{R_k}^2}} \cdot \frac{1}{\sqrt{2\pi}\sigma_k^-} e^{-\frac{(x-\mu_k^-)^2}{2\sigma_k^{-2}}} dx \right]^{-1} \quad (2-63)$$

代入(2-62)可以得到:

$$f_{X_k^+}(x) = \frac{1}{\sqrt{2\pi(1-KH)\sigma_k^{-2}}} e^{-\frac{(x-(\mu_k^- + K(y_k - H\mu_k^-))^2}{2(1-KH)\sigma_k^{-2}}} \quad (2-64)$$

$f_{X_k^+}(x)$ 的期望和方差分别为:

$$\mu_k^+ = \mu_k^- + K(y_k - H\mu_k^-) \quad (2-65)$$

$$\sigma_k^{+2} = (1-KH)\sigma_k^{-2} \quad (2-66)$$

μ_k^+ 为 k 时刻状态变量 X_k 的最优后验估计 $\hat{x}_k^+$ 。这里, K 被称为卡尔曼增益:

$$K = \frac{H\sigma_k^{-2}}{H^2\sigma_k^{-2} + \sigma_{R_k}^2} \quad (2-67)$$

当 $\sigma_{R_k}^2 \square \sigma_k^{-2}$ 时, $K \rightarrow 0$, 有:

$$\mu_k^+ = \mu_k^- + K(y_k - H\mu_k^-) \rightarrow \mu_k^- \quad (2-68)$$

反之, 当 $\sigma_{R_k}^2 \square \sigma_k^{-2}$ 时, $K \rightarrow \frac{1}{H}$, 有:

$$\mu_k^+ = \mu_k^- + K(y_k - H\mu_k^-) \rightarrow \frac{y_k}{H} \quad (2-69)$$

卡尔曼滤波的核心思想, 当观测噪声非常大时, 后验估计的结果更偏向于预测的结果, 而当观测噪声非常小时, 后验估计的结果更偏向于观测的结果。本质上卡尔曼滤波是在预测和观测之间的取舍。

2.3.3 卡尔曼滤波五大公式

基于 2.3.2 中的内容, 可以得到卡尔曼滤波的五大公式:

(1) 预测步骤

$$\mu_k^- = F\mu_{k-1}^+ + Bu_k \quad (2-70)$$

$$\sigma_k^- = F^2\sigma_{k-1}^{+2} + \sigma_{Q_k}^2 \quad (2-71)$$

(2) 更新步骤

$$K = \frac{H\sigma_k^{-2}}{H^2\sigma_k^{-2} + \sigma_{R_k}^2} \quad (2-72)$$

$$\mu_k^+ = \mu_k^- + K(y_k - H\mu_k^-) \quad (2-73)$$

$$\sigma_k^{+2} = (1 - KH)\sigma_k^{-2} \quad (2-74)$$

进一步, 可以将这些单一随机变量的一维卡尔曼滤波公式推广到多个随机变量组成序列的多维卡尔曼滤波公式:

(1) 预测步骤

$$\mu_k^- = F\mu_{k-1}^+ + Bu_k \quad (2-75)$$

$$\Sigma_k^- = F\Sigma_{k-1}^+F^T + \Sigma_{Q_k} \quad (2-76)$$

(2) 更新步骤

$$K = \Sigma_k^-H^T(H\Sigma_k^-H^T + \Sigma_{R_k})^{-1} \quad (2-77)$$

$$\mu_k^+ = \mu_k^- + K(Y_k - H\mu_k^-) \quad (2-78)$$

$$\Sigma_k^+ = (I - KH)\Sigma_k^- \quad (2-79)$$

其中，状态变量 $\mathbf{X}$ 的维数为 $n \times 1$ ，状态转移矩阵 $\mathbf{F}$ 的维数为 $n \times n$ ，控制输入向量 $\mathbf{u}_k$ 的维数为 $t \times 1$ ，控制转移矩阵 $\mathbf{B}$ 的维数为 $n \times t$ ，观测量 $\mathbf{Y}$ 的维数为 $m \times 1$ ，观测矩阵 $\mathbf{H}$ 的维数为 $m \times n$ 。状态变量 $\mathbf{X}$ 的均值 $\boldsymbol{\mu}$ 的维数为 $n \times 1$ ，协方差矩阵 $\boldsymbol{\Sigma}$ 的维数为 $n \times n$ ，过程噪声的协方差矩阵 $\boldsymbol{\Sigma}_p$ 的维数为 $n \times n$ ，观测噪声的协方差矩阵 $\boldsymbol{\Sigma}_q$ 的维数为 $m \times m$ 。

由于正态分布的特殊性，后验估计取期望和最大后验估计相同，如图 2.3 所示。




图 2.3 正态分布的最大后验估计（期望）

Figure 2.3 Maximum A Posteriori Estimation (Expectation) of the Normal Distribution

2.4 误差状态卡尔曼滤波

误差状态卡尔曼滤波（Error-State Kalman Filter，简称 ESKF）是卡尔曼滤波的一种扩展，专门用于估计动态系统中的误差状态。与传统的卡尔曼滤波不同，ESKF 并不是直接估计系统的状态，而是通过对系统状态误差的估计来提高状态估计的精度。特别适用于那些误差随着时间累积的系统，如 IMU 和 GPS 的数据融合。

2.4.1 状态空间

在 ESKF 中，将真实状态拆分两个部分，其中不包含噪声的名义状态为大信号（large-signal），包含噪声的误差状态为小信号（small-signal），可以表示为：

$$\mathbf{X}_t = \mathbf{X} + \delta\mathbf{X} \quad (2-80)$$

$\mathbf{X}$ 名义状态是流形空间中的点， $\delta\mathbf{X} \in \mathcal{N}(\mathbf{0}, \boldsymbol{\Sigma})$ 是 $\mathbf{X}$ 的切空间中的随机变量。

(1) 状态方程

$$\begin{aligned} \delta\mathbf{X}_k &= f(\mathbf{X}_{k-1}, \delta\mathbf{X}_{k-1}, \mathbf{u}_{(m)k-1}, \mathbf{W}_k) \\ &= \mathbf{F}\delta\mathbf{X}_{k-1} + \mathbf{F}\mathbf{W}_k \end{aligned} \quad (2-81)$$

其中, $\delta \mathbf{X}_k$ 是 k 时刻的误差状态, $\mathbf{F}$ 是状态转移矩阵, $\mathbf{W}_k \sim \mathbf{N}(0, \Sigma_P^2)$ 是过程噪声。

(2) 观测方程

$$\begin{aligned}\mathbf{Y}_k &= h(\mathbf{X}_k) + \mathbf{V} \\ &= \mathbf{H}\mathbf{X}_k + \mathbf{V}\end{aligned}\quad (2-82)$$

其中, $\mathbf{Y}_k$ 是观测数据, $\mathbf{H}$ 是观测矩阵, $\mathbf{V}_k \sim \mathbf{N}(0, \Sigma_Q^2)$ 是观测噪声。

2.4.2 递推步骤

(1) 预测步骤

$$\hat{\mathbf{X}}_k^- = \mathbf{F}_X(\hat{\mathbf{X}}_{k-1}, \mathbf{u}_{(m)k-1}) \cdot \hat{\mathbf{X}}_{k-1} \quad (2-83)$$

$$\Sigma_k^- = \mathbf{F}_X \Sigma_{k-1} \mathbf{F}_X^T + \mathbf{F}_W \Sigma_P \mathbf{F}_W^T \quad (2-84)$$

(2) 更新步骤

$$\mathbf{K} = \Sigma_k^- \mathbf{H}^T (\mathbf{H} \Sigma_k^- \mathbf{H}^T + \Sigma_Q)^{-1} \quad (2-85)$$

$$\hat{\mathbf{X}}_k^+ = \mathbf{K}(\mathbf{Y} - h(\hat{\mathbf{X}}_k^-)) \quad (2-86)$$

$$\Sigma_k^+ = (\mathbf{I} - \mathbf{K}\mathbf{H})\Sigma_k^- \quad (2-87)$$

(3) 注入步骤

$$\hat{\mathbf{X}}_k^+ = \hat{\mathbf{X}}_k^- + \hat{\mathbf{X}}_k^+ \quad (2-88)$$

(4) 重置步骤

在开始迭代时, 误差状态 $\delta \mathbf{X}_0 \sim \mathbf{N}\{0, \Sigma_0\}$, 经过一轮更新得到误差状态的后验估计。此时误差状态的后验估计 $\hat{\delta \mathbf{X}}_1$ 会作为下一轮的输入, 由于 $\delta \mathbf{X}_1 \sim \mathbf{N}\{\hat{\delta \mathbf{X}}_1, \Sigma_1\}$, 均值不为 0, 这会导致一个存在偏置的迭代过程, 随着迭代的次数增加, 会累积出一个较大的偏置, 故引入重置操作, 同时误差的协方差需要根据该修正进行更新。

令重置函数为 $g()$, 有:

$$\delta \mathbf{X}_k \leftarrow g(\delta \mathbf{X}_k) = (\mathbf{X}_k - \hat{\mathbf{X}}_k)' (\mathbf{X}_k - \hat{\mathbf{X}}_k) \quad (2-89)$$

$$\Sigma_k^+ \leftarrow \mathbf{G} \Sigma_k^+ \mathbf{G}^T \quad (2-90)$$

2.4.3 算法构成

误差状态卡尔曼滤波（ESKF）算法总结如下：

算法：误差状态卡尔曼滤波

上一轮的最优后验估计 $\hat{\mathbf{X}}_{k-1}^+$ 和协方差矩阵 Σ_{k-1}^+

输入： 输入当前测量值 $\mathbf{u}_{(m)k}$

输入当前观测数据 $\mathbf{Y}_k$

- 1 通过(2-83)计算先验误差状态估计 $\delta\mathbf{X}_k^-$
- 2 通过(2-84)计算先验协方差矩阵 Σ_k^-
- 3 通过(2-85)计算卡尔曼增益 $\mathbf{K}$
- 4 通过(2-86)计算最优后验误差状态估计 $\delta\mathbf{X}_k^+$
- 5 通过(2-87)计算后验协方差矩阵 Σ_k^+
- 6 通过(2-88)计算最优后验状态估计 $\hat{\mathbf{X}}_k^+$
- 7 通过(2-89)重置误差状态 $\delta\mathbf{X}_k$ ，通过(2-90)更新后验协方差矩阵 Σ_k^+

输出： $\hat{\mathbf{X}}_k^+$ ， Σ_k^+

第三章 基于流形空间误差状态卡尔曼滤波的 IMU 和 GPS 融合算法

3.1 问题引入

随着智能交通、无人驾驶和机器人导航等领域的快速发展，系统对高精度、低延迟的定位与导航能力提出了更高要求。其中，IMU（惯性测量单元）和 GPS（全球定位系统）作为广泛应用的关键传感器，在位姿估计中扮演着重要角色。IMU 能够提供高频率的加速度与角速度数据，适用于动态过程中的短时精细估计；而 GPS 则具备提供全球范围绝对位置信息的能力，尤其在开阔区域下具有较高的定位精度。然而，单一传感器在复杂场景中往往难以满足精度与鲁棒性的双重需求。例如，在城市峡谷或室内等复杂环境中，GPS 信号易受遮挡或干扰，导致数据失效或精度大幅下降；而 IMU 虽具有良好的短期响应能力，但其输出易受到偏置漂移、传感器噪声等因素的影响，随着时间推移误差不断积累，最终导致姿态与位置估计的严重偏离。

为克服上述局限，IMU 与 GPS 的互补融合成为提升导航系统性能的重要手段。IMU 提供的高频动态信息能够弥补 GPS 更新率低的问题，而 GPS 提供的全局位置基准则可以有效修正 IMU 积累的误差。通过融合算法构建统一状态估计模型，能够实现对目标位置、速度和姿态的连续、稳定跟踪，增强系统在各种环境下的定位鲁棒性。

然而，IMU 和 GPS 数据的融合并非简单的将两者的数据进行叠加，仍面临一系列挑战，主要包括：

（1）数据异步性：IMU 和 GPS 的测量频率存在差异，IMU 通常提供每秒几十到几百次的高频数据更新，而 GPS 的更新频率较低，通常在每秒 1 次左右。这使得在融合过程中需要处理不同时间尺度下的数据，如何进行时间同步，确保 IMU 和 GPS 数据的准确对齐，成为数据融合中的一个重要问题。

（2）误差建模与补偿：IMU 的系统性误差（如陀螺偏置、加速度漂移）在长时间运行下容易累积，而 GPS 虽具备较强的全局精度，但在弱信号环境中存在定位波动。融合系统需建立合理的系统模型与误差动态，以实现 IMU 漂移的持续

抑制与 GPS 校正信息的高效利用。

(3) 观测空间差异: IMU 主要提供三维加速度和角速度信息, 而 GPS 提供的是全球坐标系下的位置数据。IMU 和 GPS 数据具有不同的测量模型和坐标系, 因此, 在融合过程中, 需要将它们的测量信息映射到同一个参考框架下, 这涉及到坐标变换的问题。

(4) 噪声特性差异: IMU 噪声高频且与系统动态密切相关, GPS 噪声则更具低频特性, 受环境因素如多路径效应影响较大。融合模型需针对不同噪声来源进行建模, 保证滤波估计的稳定性与精度。

针对以上挑战, 本文构建了基于流形空间优化的误差状态卡尔曼滤波 (ESKF) 算法框架, 将其应用于 IMU 与 GPS 的数据融合中。该方法通过在流形空间中对姿态状态进行本地线性化建模, 提高了非线性状态估计中的数值稳定性与滤波精度。同时, 在滤波过程中仅对误差状态进行更新, 避免了对全局状态变量的频繁迭代, 有效降低了计算负担, 提升了融合系统的实时性能。

本章将详细介绍该融合方法的系统建模过程, 包括状态转移模型、观测模型、误差状态定义与更新流程, 并结合实验数据验证所提出方法在复杂环境中的定位精度与运行效率。通过本研究, 旨在构建一套适用于动态环境、具备实时性和高鲁棒性的 IMU-GPS 融合位姿估计系统。

3.2 引入流形空间误差状态卡尔曼滤波的动机

惯性导航系统 (INS) 中的惯性测量单元 (IMU) 能够提供高频率的姿态与位移估计, 对动态目标的短期运动跟踪表现优异。然而, 由于加速度与角速度的积分过程不可避免地积累误差, IMU 长时间运行后会出现显著的漂移问题, 特别是在陀螺仪零偏与加速度噪声的长期作用下, 位姿估计误差将越来越大, 严重影响系统稳定性。因此, 必须引入外部观测源对其进行校正, 以实现长期稳定的状态估计。误差状态卡尔曼滤波 (ESKF) 因其良好的数值稳定性与非线性处理能力, 成为多传感器融合中的主流方法之一。该方法通过将状态变量分为名义状态与误差状态两部分, 在不直接干扰系统主状态演化的前提下, 实现对系统误差的局部线性估计与快速修正, 特别适用于处理 IMU 等高频输入与低频外部观测之间的协同估计问题。

相比于传统扩展卡尔曼滤波，ESKF 的优势主要体现在以下几个方面：

(1) 局部线性化与姿态简化表达：ESKF 将 IMU 的测量噪声（如陀螺仪零偏随机游走、加速度计白噪声）建模为误差状态的小量扰动，而非直接作用于名义状态。这种设计充分利用 IMU 单次测量噪声低的特点，同时通过误差状态的在线估计与补偿，抑制积分过程中的累积误差。

(2) 误差状态局限于原点附近：误差状态始终被限制在靠近零的小范围内，避免了由于大范围非线性变化而引发的参数奇异性和万向锁等问题，保证了线性化过程的有效性和滤波器的稳定性。

(3) 简化且高效的雅可比矩阵计算：由于误差状态较小，所有二阶及以上的非线性项均可忽略，使得雅可比矩阵的推导和计算大为简化，有时甚至可视为常数，极大提升了滤波器的计算效率。

(4) 误差状态的慢变特性：系统的名义状态负责追踪 IMU 的高频动态变化，而误差状态描述的仅是小幅度误差，动态变化缓慢。因此，滤波器可以以低于预测频率的速度进行校正更新，从而有效平衡计算负载和估计精度。

基于上述特点，本文进一步引入流形空间优化思想，在误差状态建模过程中采用流形空间构建姿态状态的局部参数化模型。与传统方法相比，该设计可避免旋转状态的冗余表达，提升状态空间表达的紧凑性与滤波稳定性，

因此，本文提出了一种利用流形空间优化 ESKF 的算法，可以直接使用旋转向量（3 个自由度）来描述姿态增量，摆脱扩展卡尔曼滤波方法对四元数（4 个自由度）和旋转矩阵（9 个自由度）的依赖。基于流形空间优化的误差状态卡尔曼滤波算法在保持实时性与效率的同时，显著提升了系统的稳定性与扩展性，是当前多传感器融合导航中极具潜力的解决方案。

3.3 误差状态卡尔曼滤波算法原理

在误差状态卡尔曼滤波的公式化表述中，我们讨论真实状态（true-state）、名义状态（nominal-state）和误差状态（error-state）。真实状态可以表示为名义状态和误差状态的组合（如线性求和、四元数乘积或矩阵乘积）。基本思想是将名义状态视为大信号（large-signal）（可采用非线性方式积分），而误差状态视为小信号（small-signal）（可采用线性方式积分，并适用于线性-高斯滤波）。在误差状态卡

尔曼滤波中，一方面，高频 IMU 数据 u_m 被积分至名义状态 x 当中，该状态不考虑噪声项 w 及其它可能的模型不完善性，所以名义状态会随时间的推移积累误差；另一方面，所有的误差都存在于误差状态 δx 当中，并由误差状态卡尔曼滤波（ESKF）进行估计，此时将所有噪声和扰动纳入考虑。误差状态由小信号组成，其运动学方程由时变线性动态系统定义，其中运动学矩阵、控制矩阵和测量矩阵均根据名义状态的值计算得出。在名义状态积分的同时，ESKF 预测误差状态的先验。此时，ESKF 仅进行预测。当 IMU 以外的测量信息 GPS 数据到达后，滤波器进行误差校正。该测量信息能够使误差变得可观测，校正过程提供了误差状态的后验估计。随后，误差状态的均值被注入名义状态中，并重置为零。误差状态的协方差矩阵也会进行相应的更新。系统按照这种方式不断循环进行。

3.4 IMU 状态运动学建模

惯性测量单元（Inertial Measurement Unit, IMU）作为惯性导航系统的核心传感器，提供高频的加速度和角速度测量数据，用于描述载体在三维空间中的运动状态。IMU 输出的加速度计和陀螺仪数据，分别对应载体在自身坐标系中的线性加速度和角速度信息。

IMU 状态运动学建模的核心目标是把这些传感器测量与载体的空间位置、速度和姿态紧密关联，建立连续且准确的动态模型，支撑后续的状态估计与融合处理。由于惯性导航系统需要通过对 IMU 输出信号的积分计算获得位姿信息，因此对 IMU 状态模型的精确描述尤为关键。

本节将基于惯性导航的基本原理，定义系统状态向量，包括位置、速度、姿态以及 IMU 传感器的偏置项，结合 IMU 测量的加速度和角速度，构建运动学状态方程。运动学方程描述了状态随时间的演化规律，既考虑了惯性导航系统的物理特性，也反映了传感器误差的动态变化。

在 2.1.5 节中，给出了流形空间中的 IMU 状态变量：

$$\begin{aligned} M &= SO(3) \times \mathbb{R}^{15}, \dim(M) = 18 \\ \mathbf{x}(t) &= \begin{bmatrix} {}^G \mathbf{R}_I^T & {}^G \mathbf{p}_I^T & {}^G \mathbf{v}_I^T & \mathbf{b}_\omega^T & \mathbf{b}_a^T & {}^G \mathbf{g}^T \end{bmatrix}^T \end{aligned} \quad (3-1)$$

为方便分析，做如下定义：

$${}^G\mathbf{R}_I^T \square \mathbf{R} \quad (3-2)$$

$${}^G\mathbf{p}_I^T \square \mathbf{p} \quad (3-3)$$

$${}^G\mathbf{v}_I^T \square \mathbf{v} \quad (3-4)$$

$$\mathbf{b}_\omega^T \square \mathbf{b}_\omega \quad (3-5)$$

$$\mathbf{b}_a^T \square \mathbf{b}_a \quad (3-6)$$

$${}^G\mathbf{g}^T \square \mathbf{g} \quad (3-7)$$

其中， $\mathbf{R}$ 表示世界系下的姿态， $\mathbf{p}$ 表示世界系下的位置， $\mathbf{v}$ 表示世界系下的速度， $\mathbf{b}_\omega$ 表示本体系下陀螺仪的偏置， $\mathbf{b}_a$ 表示本体系下的加速度计的偏置， $\mathbf{g}$ 表示世界系下的重力加速度。

流形空间误差状态卡尔曼滤波的所有相关变量的定义均在表 3.1 中给出：

表 3.1 误差状态卡尔曼滤波中的所有变量

Table 3.1 All Variables in the Error-State Kalman Filter

量	真实状态	名义状态	误差状态	运算关系	测量	噪声
状态	$\mathbf{X}_t$	$\mathbf{X}$	$\delta\mathbf{X}$	$\mathbf{X}_t = \mathbf{X} + \delta\mathbf{X}$		
旋转矩阵	$\mathbf{R}_t$	$\mathbf{R}$	$\delta\mathbf{r}$	$\mathbf{R}_t = \mathbf{R} + \delta\mathbf{r}$		
位置	$\mathbf{p}_t$	$\mathbf{p}$	$\delta\mathbf{p}$	$\mathbf{p}_t = \mathbf{p} + \delta\mathbf{p}$		
速度	$\mathbf{v}_t$	$\mathbf{v}$	$\delta\mathbf{v}$	$\mathbf{v}_t = \mathbf{v} + \delta\mathbf{v}$		
加速度计偏置	$\mathbf{b}_{at}$	$\mathbf{b}_a$	$\delta\mathbf{b}_a$	$\mathbf{b}_{at} = \mathbf{b}_a + \delta\mathbf{b}_a$		$\mathbf{n}_{ba}$
陀螺仪偏置	$\mathbf{b}_{\omega t}$	$\mathbf{b}_\omega$	$\delta\mathbf{b}_\omega$	$\mathbf{b}_{\omega t} = \mathbf{b}_\omega + \delta\mathbf{b}_\omega$		$\mathbf{n}_{b\omega}$
重力加速度	$\mathbf{g}_t$	$\mathbf{g}$	$\delta\mathbf{g}$	$\mathbf{g}_t = \mathbf{g} + \delta\mathbf{g}$		
加速度	a_t				a_m	$\mathbf{n}_a$
角速度	ω_t				ω_m	$\mathbf{n}_\omega$

3.4.1 连续时间运动学模型

(1) 真实状态运动学模型

在误差状态卡尔曼滤波框架中，真实状态（true-state）表示系统实际的物理状态，包括姿态、位置、速度、传感器零偏以及重力加速度等参数，其状态变量为：

$$\mathbf{X}_t \square \left[\mathbf{R}_t^T \quad \mathbf{p}_t^T \quad \mathbf{v}_t^T \quad \mathbf{b}_{at}^T \quad \mathbf{b}_{\omega t}^T \quad \mathbf{g}_t^T \right]^T \quad (3-8)$$

该状态由 IMU 的加速度计和陀螺仪测量驱动，并考虑噪声项。其运动学模型描述了这些状态随时间变化的动态过程，通常由以下微分方程定义：

$$\mathbf{R}'_t = \mathbf{R}_t (\omega_m - \mathbf{b}_{\omega t} - \mathbf{n}_\omega)^\wedge \quad (3-9)$$

$$\mathbf{p}'_t = \mathbf{v}_t \quad (3-10)$$

$$\mathbf{v}'_t = \mathbf{R}_t(a_m - \mathbf{b}_{at} - \mathbf{n}_a) + \mathbf{g}_t \quad (3-11)$$

$$\mathbf{b}'_{at} = \mathbf{n}_{ba} \quad (3-12)$$

$$\mathbf{b}'_{\omega t} = \mathbf{n}_{b\omega} \quad (3-13)$$

$$\mathbf{g}'_t = 0 \quad (3-14)$$

其中，下标 t 代表真实状态， a_m 表示本体系下的加速度计测量值； ω_m 表示本体系下的陀螺仪测量值； $\mathbf{R}_t$ 表示将本体系转换到世界系的旋转矩阵； $\mathbf{n}_{ba}$ 表示加速度计白噪声， $\mathbf{n}_{b\omega}$ 表示陀螺仪白噪声。

利用上述微分方程可以定义真实状态的系统方程 $\mathbf{X}'_t = f_t(\mathbf{X}_t, \mathbf{u}, \mathbf{w})$ ，该系统的状态变量为 $\mathbf{X}_t$ ，由IMU带噪声的测量值 $\mathbf{u}_m$ 驱动，并受到高斯白噪声 $\mathbf{w}$ 的干扰，所有变量由下列方程定义：

$$\mathbf{X}_t = \begin{bmatrix} \mathbf{R}_t \\ \mathbf{p}_t \\ \mathbf{v}_t \\ \mathbf{b}_{at} \\ \mathbf{b}_{\omega t} \\ \mathbf{g}_t \end{bmatrix} \quad \mathbf{u} = \begin{bmatrix} a_m - \mathbf{n}_a \\ \omega_m - \mathbf{n}_\omega \end{bmatrix} \quad \mathbf{w} = \begin{bmatrix} \mathbf{n}_{ba} \\ \mathbf{n}_{b\omega} \end{bmatrix} \quad (3-15)$$

(2) 名义状态运动学模型

名义状态（nominal-state）是系统状态的理想化表示，通过直接积分IMU的高频测量数据（加速度计和陀螺仪）得到，忽略噪声项与随机扰动，其状态变量与真实状态类似：

$$\mathbf{X} \square \begin{bmatrix} \mathbf{R}^T & \mathbf{p}^T & \mathbf{v}^T & \mathbf{b}_a^T & \mathbf{b}_\omega^T & \mathbf{g}^T \end{bmatrix}^T \quad (3-16)$$

其核心目标是实现高效的状态预测，同时为误差状态的线性化校正提供基础。通常由以下微分方程定义：

$$\mathbf{R}' = \mathbf{R}(\omega_m - \mathbf{b}_\omega)^\wedge \quad (3-17)$$

$$\mathbf{p}' = \mathbf{v} \quad (3-18)$$

$$\mathbf{v}' = \mathbf{R}(a_m - \mathbf{b}_a) + \mathbf{g} \quad (3-19)$$

$$\mathbf{b}'_a = 0 \quad (3-20)$$

$$\mathbf{b}'_\omega = 0 \quad (3-21)$$

$$\mathbf{g}' = \mathbf{0} \quad (3-22)$$

其中, a_m 表示本体系下的加速度计测量值; ω_m 表示本体系下的陀螺仪测量值; $\mathbf{R}$ 表示将本体系转换到世界系的旋转矩阵。

(3) 误差状态运动学模型

误差状态 (error-state) 描述了名义状态 (nominal-state) 与真实状态 (true-state) 之间的微小偏差, 它包含了真实状态中的全部噪声。其运动学模型基于小量假设, 通过线性化真实状态动态方程实现, 旨在高效估计并补偿积分漂移。其状态变量为:

$$\delta \mathbf{X} = [\delta \mathbf{r}^T \quad \delta \mathbf{p}^T \quad \delta \mathbf{v}^T \quad \delta \mathbf{b}_a^T \quad \delta \mathbf{b}_\omega^T \quad \delta \mathbf{g}^T]^T \quad (3-23)$$

这里, $\delta \mathbf{r}$ 表示姿态的误差状态 (李代数 $\mathfrak{so}(3)$ 表示的旋转向量)。

误差状态的动态方程由真实状态与名义状态的差异推导而来, 通过线性化得到:

$$\delta \mathbf{r}' = -(\omega_m - \mathbf{b}_\omega)^\wedge \delta \mathbf{r} - \delta \mathbf{b}_\omega - \mathbf{n}_\omega \quad (3-24)$$

$$\delta \mathbf{p}' = \delta \mathbf{v} \quad (3-25)$$

$$\delta \mathbf{v}' = -\mathbf{R}(a_m - \mathbf{b}_a)^\wedge \delta \mathbf{r} - \mathbf{R} \delta \mathbf{b}_a - \mathbf{n}_a + \delta \mathbf{g} \quad (3-26)$$

$$\delta \mathbf{b}_\omega' = \mathbf{n}_{b\omega} \quad (3-27)$$

$$\delta \mathbf{b}_a' = \mathbf{n}_{ba} \quad (3-28)$$

$$\delta \mathbf{g}' = \mathbf{0} \quad (3-29)$$

3.4.2 离散时间运动学模型

连续时间微分方程通过欧拉积分转换为时间间隔为 Δt 的离散时间差分方程。

离散化需要应用于以下子系统

1. 名义状态

2. 误差状态

(a) 确定性部分: 状态和控制。

(b) 随机性部分: 噪声和扰动。

(1) 离散时间名义状态运动学^[53]

$$\mathbf{R}(t + \Delta t) = \mathbf{R}(t) \text{Exp}(((\omega_m - \mathbf{b}_\omega)^\wedge) \Delta t) \quad (3-30)$$

$$\mathbf{p}(t + \Delta t) = \mathbf{p}(t) + \mathbf{v}(t) \Delta t + \frac{1}{2} \mathbf{R}(a_m - \mathbf{b}_a) \Delta t^2 + \frac{1}{2} \mathbf{g} \Delta t^2 \quad (3-31)$$

$$\mathbf{v}(t+\Delta t) = \mathbf{v}(t) + \mathbf{R}(a_m - \mathbf{b}_a)\Delta t + \mathbf{g}\Delta t \quad (3-32)$$

$$\mathbf{b}_a(t+\Delta t) = \mathbf{b}_a(t) \quad (3-33)$$

$$\mathbf{b}_\omega(t+\Delta t) = \mathbf{b}_\omega(t) \quad (3-34)$$

$$\mathbf{g}(t+\Delta t) = \mathbf{g}(t) \quad (3-35)$$

(2) 离散时间误差状态运动学^[53]

$$\delta r(t+\Delta t) = \text{Exp}(-(\omega_m - \mathbf{b}_\omega)\Delta t)\delta r - \delta \mathbf{b}_\omega\Delta t + r_i \quad (3-36)$$

$$\delta \mathbf{p}(t+\Delta t) = \delta \mathbf{p} + \delta \mathbf{v}\Delta t \quad (3-37)$$

$$\delta \mathbf{v}(t+\Delta t) = \delta \mathbf{v} + (-\mathbf{R}(a_m - \mathbf{b}_a)^\wedge \delta r - \mathbf{R}\delta \mathbf{b}_a + \delta \mathbf{g})\Delta t + \mathbf{v}_i \quad (3-38)$$

$$\delta \mathbf{b}_\omega(t+\Delta t) = \delta \mathbf{b}_\omega + \omega_i \quad (3-39)$$

$$\delta \mathbf{b}_a(t+\Delta t) = \delta \mathbf{b}_a + a_i \quad (3-40)$$

$$\delta \mathbf{g}(t+\Delta t) = \delta \mathbf{g} \quad (3-41)$$

其中, r_i , $\mathbf{v}_i$, ω_i , a_i 是作用于姿态, 速度和偏置的噪声, 其均服从高斯白噪声过程。它们的均值为零, 协方差矩阵由时间步长 Δt 内的积分获得:

$$\text{Var}(r_i) = \sigma_{n_\omega}^2 \Delta t^2 \mathbf{I} \quad [\text{rad}^2] \quad (3-42)$$

$$\text{Var}(\mathbf{v}_i) = \sigma_{n_a}^2 \Delta t^2 \mathbf{I} \quad [\text{m}^2/\text{s}^2] \quad (3-43)$$

$$\text{Var}(\omega_i) = \sigma_{b_\omega}^2 \Delta t \mathbf{I} \quad [\text{rad}^2/\text{s}^2] \quad (3-44)$$

$$\text{Var}(a_i) = \sigma_{b_a}^2 \Delta t \mathbf{I} \quad [\text{m}^2/\text{s}^4] \quad (3-45)$$

3.5 IMU 和 GPS 融合算法

3.5.1 误差状态的运动过程

为得到紧凑的表达形式, 定义名义状态 $\mathbf{X}$ 、误差状态 $\delta \mathbf{X}$ 、输入向量 $\mathbf{u}_{(m)}$ 以及扰动向量 $\mathbf{i}$:

$$\mathbf{X}_k = \begin{bmatrix} \mathbf{R}_k \\ \mathbf{p}_k \\ \mathbf{v}_k \\ \mathbf{b}_{(\omega)k} \\ \mathbf{b}_{(a)k} \\ \mathbf{g}_k \end{bmatrix} \quad \delta \mathbf{X}_k = \begin{bmatrix} \delta r_k \\ \delta \mathbf{p}_k \\ \delta \mathbf{v}_k \\ \delta \mathbf{b}_{(\omega)k} \\ \delta \mathbf{b}_{(a)k} \\ \delta \mathbf{g}_k \end{bmatrix} \quad \mathbf{u}_{(m)k} = \begin{bmatrix} \omega_{(m)k} \\ a_{(m)k} \end{bmatrix} \quad \mathbf{i} = \begin{bmatrix} \mathbf{v}_i \\ r_i \\ \omega_i \\ a_i \end{bmatrix} \quad (3-46)$$

其中, k 表示第 k 次迭代, 步长为 Δt 。

误差状态的运动过程为:

$$\delta \mathbf{X}_{k+1} \leftarrow f(\mathbf{X}_k, \delta \mathbf{X}_k, \mathbf{u}_{(m)k}, \mathbf{i}) = \mathbf{F}_x(\mathbf{X}_k, \mathbf{u}_{(m)k}) \cdot \delta \mathbf{X}_k + \mathbf{F}_i \cdot \mathbf{i} \quad (3-47)$$

误差状态的预测过程为:

$$\hat{\delta \mathbf{X}}_{k+1}^- \leftarrow \mathbf{F}_x(\hat{\mathbf{X}}_k, \mathbf{u}_{(m)k}) \cdot \hat{\delta \mathbf{X}}_k \quad (3-48)$$

$$\mathbf{P}_{k+1}^- \leftarrow \mathbf{F}_x \mathbf{P}_k \mathbf{F}_x^T + \mathbf{F}_i \mathbf{Q}_i \mathbf{F}_i^T \quad (3-49)$$

式(3-48)和(3-49)中, $\hat{\delta \mathbf{X}}_{k+1}^-$ 为误差状态的先验估计, $\mathbf{F}_x$ 和 $\mathbf{F}_i$ 分别是 $f()$ 关于误差状态和扰动的雅可比矩阵, $\mathbf{Q}_i$ 是扰动脉冲的协方差矩阵。

$$\mathbf{F}_x = \left. \frac{\partial f}{\partial \delta \mathbf{x}} \right|_{\mathbf{x}, \mathbf{u}_m} = \begin{bmatrix} \text{Exp}(-(\omega_m - \mathbf{b}_g)\Delta t) & 0 & 0 & -\mathbf{I}\Delta t & 0 & 0 \\ 0 & \mathbf{I} & \mathbf{I}\Delta t & 0 & 0 & 0 \\ -\mathbf{R}(a_m - \mathbf{b}_a)^{\wedge} \Delta t & 0 & \mathbf{I} & 0 & -\mathbf{R}\Delta t & 0 \\ 0 & 0 & 0 & \mathbf{I} & 0 & 0 \\ 0 & 0 & 0 & 0 & \mathbf{I} & 0 \\ 0 & 0 & 0 & 0 & 0 & \mathbf{I} \end{bmatrix} \quad (3-50)$$

$$\mathbf{F}_i = \left. \frac{\partial f}{\partial \mathbf{i}} \right|_{\mathbf{x}, \mathbf{u}_m} = \begin{bmatrix} \mathbf{I} & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & \mathbf{I} & 0 & 0 & 0 \\ 0 & 0 & 0 & \mathbf{I} & 0 & 0 \\ 0 & 0 & 0 & 0 & \mathbf{I} & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 \end{bmatrix} \quad (3-51)$$

$$\mathbf{Q}_i = \begin{bmatrix} \sigma_{n_\omega}^2 \Delta t^2 \mathbf{I} & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & \sigma_{n_a}^2 \Delta t^2 \mathbf{I} & 0 & 0 & 0 \\ 0 & 0 & 0 & \sigma_{b_\omega}^2 \Delta t \mathbf{I} & 0 & 0 \\ 0 & 0 & 0 & 0 & \sigma_{b_a}^2 \Delta t \mathbf{I} & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 \end{bmatrix} \quad (3-52)$$

3.5.2 误差状态的更新过程

当接收到 GPS 数据时, 对误差状态进行校正。观测方程为:

$$\mathbf{Y} = h(\mathbf{X}_t) + \mathbf{v} \quad (3-53)$$

其中 $\mathbf{v}$ 是高斯白噪声, 且 $\mathbf{v} \sim N\{0, \mathbf{V}\}$, 其协方差矩阵为 $\mathbf{V}$ 。

更新过程为:

$$\mathbf{K} = \mathbf{P}_{k+1}^- \mathbf{H}^T (\mathbf{H} \mathbf{P}_{k+1}^- \mathbf{H}^T + \mathbf{V})^{-1} \quad (3-54)$$

$$\hat{\delta \mathbf{X}}_{k+1} \leftarrow \mathbf{K}(\mathbf{Y} - h(\hat{\mathbf{X}}_{k+1}^-)) \quad (3-55)$$

$$\mathbf{P}_{k+1}^+ \leftarrow (\mathbf{I} - \mathbf{KH})\mathbf{P}_{k+1}^- \quad (3-56)$$

式(3-55)和(3-56)中, $\hat{\delta\mathbf{X}}_{k+1}$ 为误差状态的后验估计, $\mathbf{P}_{k+1}^+$ 为更新后的误差协方差矩阵, $\mathbf{H} \in \mathbb{R}^{m \times 18}$ 为观测方程对于误差状态的雅可比矩阵:

$$\mathbf{H} = \left. \frac{\partial h}{\partial \delta \mathbf{x}} \right|_{\mathbf{x}} = \left. \frac{\partial h}{\partial \mathbf{x}_t} \right|_{\mathbf{x}} \frac{\partial \mathbf{x}_t}{\partial \delta \mathbf{x}} \bigg|_{\mathbf{x}} = \mathbf{H}_x \mathbf{X}_{\delta \mathbf{x}_k} \quad (3-57)$$

这里, $\mathbf{H}_x = \left. \frac{\partial h}{\partial \mathbf{x}_t} \right|_{\mathbf{x}}$ 是 $h()$ 关于真实状态的雅可比矩阵, $\mathbf{X}_{\delta \mathbf{x}_k}$ 是真实状态关于误差状态的雅可比矩阵。

$$\mathbf{X}_{\delta \mathbf{x}} = \begin{bmatrix} \frac{\partial(\mathbf{R}(\delta r))}{\partial \delta r} & & & & \\ & \frac{\partial(\mathbf{p} + \delta \mathbf{p})}{\partial \delta \mathbf{p}} & \dots & & 0 \\ & & \frac{\partial(\mathbf{v} + \delta \mathbf{v})}{\partial \delta \mathbf{v}} & & \vdots \\ & \vdots & & \frac{\partial(\mathbf{b}_\omega + \delta \mathbf{b}_\omega)}{\partial \delta \mathbf{b}_\omega} & \\ 0 & \dots & & \frac{\partial(\mathbf{b}_a + \delta \mathbf{b}_a)}{\partial \delta \mathbf{b}_a} & \\ & & & & \frac{\partial(\mathbf{g} + \delta \mathbf{g})}{\partial \delta \mathbf{g}} \end{bmatrix} \quad (3-58)$$

式(3-58)中, 由于 δr 为 $\mathbf{R}$ 的右乘, 利用右乘 BCH 公式可得^[50]:

$$\frac{\partial \text{Log}(\mathbf{R}(\text{Exp}(\delta r)))}{\partial \delta r} = \mathbf{J}_r^{-1}(\mathbf{R}) \quad (3-59)$$

3.5.3 注入过程和重置过程

在误差状态得到更新后, 名义状态通过误差状态进行更新:

$$\hat{\mathbf{X}}_{k+1} \leftarrow \hat{\mathbf{X}}_{k+1}^- + \hat{\delta \mathbf{X}}_{k+1} \quad (3-60)$$

令重置函数为 $g()$, 有:

$$\delta \mathbf{X}_{k+1} \leftarrow g(\delta \mathbf{X}_{k+1}) = (\mathbf{X}_{k+1} (\delta \mathbf{X}_{k+1})')' (\mathbf{X}_{k+1} (\hat{\delta \mathbf{X}}_{k+1})) \quad (3-61)$$

$$\mathbf{P}_{k+1} \leftarrow \mathbf{G} \mathbf{P}_{k+1} \mathbf{G}^T \quad (3-62)$$

$$\mathbf{G} = \left. \frac{\partial g}{\partial \delta \mathbf{x}} \right|_{\delta \mathbf{x}} = \begin{bmatrix} \mathbf{I} - \frac{1}{2} \delta r_k^\wedge & 0 \\ 0 & \mathbf{I}_{15} \end{bmatrix} \quad (3-63)$$

3.6 实验与分析

在本节中，将详细介绍实验设计的各个方面，来证明基于误差状态卡尔曼滤波的 IMU 和 GPS 融合算法的可行性及有效性。

3.6.1 实验设置与数据来源

在本实验中，采用了 GNSS-INS-SIM^[54]（GNSS/INS 仿真系统）工具，作为验证 IMU 和 GPS 数据融合算法的数据来源。该工具由 Accinna 开源在 GitHub 上，该工具能够模拟不同的 GNSS 信号环境和 IMU 测量数据。

IMU 精度设置为“中等精度”，代表典型商用级 IMU 的性能。模拟的 IMU 具有典型的误差，如噪声、漂移和偏置，这些误差被建模为符合中等精度 IMU 的预期表现，这类 IMU 通常用于移动机器人、无人机和自动驾驶车辆等设备。

硬件平台

处理器：Intel Core i5-6500，4 核 4 线程，时钟频率为 3.2 GHz，TDP 65 W，发布于 2015 年第三季度。

内存：8GB DDR4 内存。

存储：致钛 PC005 500GB

主板：华硕 B150M

软件环境

操作系统：Ubuntu 20.04。

编程语言：C++。

框架与库：ROS（Robot Operating System）Noetic，用于传感器数据融合与通信；Eigen，提供高效的线性代数运算（矩阵/向量操作、四元数、李群/李代数变换）；YAML（YAML Ain't Markup Language）库，用于配置文件读写与参数管理，方便在系统中统一加载滤波器参数、传感器标定数据与算法配置项；Glog（Google Logging），用于系统日志记录与调试信息输出，支持高效的日志级别管理，便于系统调试与性能分析。

3.6.2 评价指标

为了全面评估所提出的基于流形空间误差状态卡尔曼滤波的 IMU 和 GPS 融合算法在位姿估计中的表现，本实验选取了绝对位置误差（Absolute Pose Error, APE）

作为主要精度评估指标。APE 能够直接反映估计轨迹与真实轨迹在空间位置上的偏离程度，是位姿估计算法性能评估中广泛采用的重要标准。在 APE 基础上，进一步从多个统计学维度对估计误差进行定量分析，包括最大误差（Max Error）、均值误差（Mean Error）、中位数误差（Median Error）、最小误差（Min Error）、均方根误差（Root Mean Square Error, RMSE）以及标准差（Standard Deviation, STD）。其中，最大误差反映算法在最极端情况下的偏离程度，均值误差与中位数误差描述整体精度水平，RMSE 综合体现了整体误差分布特征，而标准差则反映误差在整个序列中的稳定性与波动性。这些指标相互补充，从不同角度揭示算法在精度、稳定性和鲁棒性方面的性能差异。

通过上述多维度指标的综合评估，可全面分析并对比所提出的基于流形空间优化的误差状态卡尔曼滤波算法与其他对比算法在实验数据集中的表现优势与不足。实验结果不仅有助于验证本文所提出方法在不同运行场景下的有效性，也为后续在实际应用中选择适用的位姿估计方法提供了系统性的参考依据与理论支持。

3.6.3 实验结果

在本实验中，为了全面验证所提出的基于流形空间误差状态卡尔曼滤波（ESKF）算法的性能，设计了四组对比实验，分别为：IMU 直接积分法、扩展卡尔曼滤波（EKF）、四元数误差状态卡尔曼滤波（ESKF-Quaternion）以及本文所提出的流形空间误差状态卡尔曼滤波（ESKF-Manifold）。通过对比不同算法在相同传感器输入下的位姿估计结果，评估各算法在精度、稳定性与实时性方面的表现差异。

由于实验数据总长度为 5000 个采样点，若直接在单图中完整绘制全部数据，曲线将高度重叠，导致可视化效果不佳，且不利于细节观察。为提升图像可读性与局部动态变化的展示效果，本文在绘图过程中选取了数据序列中的中间连续 500 个样本点进行绘制与分析。所选取的时间段涵盖了系统在稳定工作状态下的典型运行轨迹，具有良好的代表性。

在下列图示中，蓝色曲线（fused）表示融合算法计算得到的位姿估计结果，融合了 IMU 与 GPS 传感器数据；红色曲线（gt）为系统的真实运动轨迹（Ground Truth）；绿色曲线表示原始 GPS 观测数据，未经任何滤波或平滑处理。

图 3.1 展示了 IMU 数据直接积分所得的 x 、 y 、 z 三个方向上的估计值，可以在未采用任何外部观测校正，估计结果出现明显的漂移现象。




图 3.1 IMU 直接积分结果

Figure 3.1 IMU Direct Integration Results

图 3.2 展示了 IMU 和 GPS 经 EKF 融合后的 x 、 y 、 z 三个方向上的估计值，可以看到，经过外部观测校正后，估计结果的准确性明显上升。




图 3.2 EKF 估计结果

Figure 3.2 EKF Estimation Results

图 3.3 展示了 IMU 和 GPS 经 ESKF-Quaternion 融合后的 x 、 y 、 z 三个方向上的估计值。




图 3.3 ESKF-Quaternion 估计结果

Figure 3.3 ESKF-Quaternion Estimation Results

图 3.4 展示了 IMU 和 GPS 经 ESKF-Manifold 融合后的 x、y、z 三个方向上的估计值。




图 3.4 ESKF-Manifold 估计结果

Figure 3.4 ESKF-Manifold Estimation Results

在完成各算法的位姿估计结果展示后，为了进一步对比不同方法在位姿估计精度上的表现，绘制了各算法的绝对位置误差曲线，图 3.5 展示了不同算法的 APE 曲线。




图 3.5 绝对位置误差

A. IMU 直接积分绝对位置误差 B. EKF 绝对位置误差

C. ESKF-Quaternion 绝对位置误差 D. ESKF-Manifold 绝对位置误差

Figure 3.5 Absolute Position Error

A. Absolute Pose Error of IMU Direct Integration

B. Absolute Pose Error of EKF

C. Absolute Pose Error of ESKF-Quaternion

D. Absolute Pose Error of ESKF-Manifold

四种方法的绝对位置误差的统计结果由表 3.2 给出，单位均为米（m）。为全面反映不同算法在位姿估计精度、稳定性及鲁棒性方面的性能表现，本文统计了最大误差（Max Error）、均值误差（Mean Error）、中位数误差（Median Error）、最小误差（Min Error）、均方根误差（RMSE, Root Mean Square Error）以及标准差（STD, Standard Deviation）等多项指标。

表 3.2 各算法绝对位置误差值

Table 3.2 Absolute Pose Error Values of Various Algorithms

算法	Max	Min	RMSE	Median	Mean	STD
IMU 直接积分	891.49	453.81	669.06	649.08	656.99	126.53
EKF	9.91	0.71	4.74	4.19	4.40	1.76
ESKF-Quaternion	9.21	0.62	4.15	3.84	3.67	1.53
ESKF-Manifold	7.89	0.27	3.35	3.03	3.11	1.25

为进一步评估各算法的实时性能, 本文对比了四种方法在位姿估计过程中每帧的平均计算耗时, 统计结果如表 3.3 所示, 单位均为毫秒 (ms)。所有实验均在相同硬件环境下进行。

表 3.3 各算法每帧的平均耗时

Table 3.3 Average Per-Frame Computation Time of Each Algorithm

算法	每帧平均耗时 (ms)
IMU 直接积分	0.23
EKF	3.24
ESKF-Quaternion	4.49
ESKF-Manifold	4.02

3.6.4 结果分析

为全面评估各算法在位姿估计任务中的精度与实时性表现, 本文对比分析了四种算法的绝对位置误差与平均单帧计算耗时, 相关统计结果分别如表 3.2 和表 3.3 所示。

在绝对位置误差方面, IMU 直接积分因缺乏外部校正机制, 导致误差快速累积, 其最大误差高达 891.49 m, RMSE 达到 669.06 m, 表现远逊于其他融合算法。EKF、ESKF-Quaternion 和 ESKF-Manifold 均显著改善了这一问题, 其中本文提出的 ESKF-Manifold 方法在所有统计指标上均表现最优, 最大误差为 7.89 m, RMSE 为 3.35 m, 均值和中位数误差也仅为 3.11 m 和 3.03 m。此外, 其标准差为 1.25,

在所有方法中波动最小,表明其在动态环境下具有更好的稳定性与鲁棒性。图 A-D 的误差曲线进一步佐证了上述统计结论,ESKF-Manifold 曲线整体更平稳,且误差均值带更窄,表现出更强的收敛性。

在实时性方面,IMU 直接积分由于无需状态更新,平均单帧计算耗时最短,仅为 0.23 ms,但其估计精度无法满足实际需求。相比之下,融合算法均在单帧耗时与估计精度之间取得了不同程度的权衡。其中 EKF 的平均计算时间为 3.24 ms,而 ESKF-Quaternion 和 ESKF-Manifold 分别为 4.49 ms 和 4.02 ms。尽管 ESKF-Manifold 稍高于 EKF,但在精度提升上的优势更为显著,且其运行时间仍控制在可接受范围内,适用于对实时性要求较高的实际场景。

综上所述,ESKF-Manifold 兼具高精度与良好的实时性能,相比传统方法在位姿估计任务中更具优势,验证了本文所提出方法在复杂动态环境下的有效性与实用性。

3.7 本章小结

本章详细探讨了基于流形空间误差状态卡尔曼滤波的 IMU 和 GPS 数据融合方法,重点解决了 IMU 误差累积问题。通过实验和仿真,验证了 IMU 和 GPS 融合在动态环境中的高精度、鲁棒性以及高效性。

首先,本章介绍了 IMU 和 GPS 各自的特点与局限性,IMU 能够提供高频率的动态信息,但由于传感器误差的积累,其精度会随时间逐渐下降。与此不同,GPS 在稳定环境下具有较高的定位精度,但其更新频率较低,并且在复杂或遮挡环境下可能丢失信号。因此,IMU 和 GPS 的融合成为提升定位精度和系统鲁棒性的重要手段。

接着,本文介绍了基于流形空间误差状态卡尔曼滤波的 IMU 和 GPS 数据融合方法。并且围绕所提出的 ESKF-Manifold 算法进行了多角度的性能评估。通过与 IMU 直接积分、传统 EKF 以及 ESKF-Quaternion 方法的对比实验,本文从位姿估计精度、误差统计指标和单帧计算耗时三个方面对四种算法的性能进行了全面分析。

实验结果表明,ESKF-Manifold 在保持较低误差的同时,也具备良好的稳定性与鲁棒性,尤其在最大误差、均方根误差和标准差等关键指标上表现最优。同时,

其计算效率也处于较高水平，满足对实时性的要求，适用于资源受限或响应速度要求较高的应用场景。

总的来说，本章的研究表明，IMU 和 GPS 的有效融合不仅提高了定位精度，还增强了系统的鲁棒性，为无人驾驶、机器人导航和智能定位等领域提供了一个可靠的解决方案。

第四章 基于流形空间误差状态卡尔曼滤波的 IMU 和激光雷达融合算法

4.1 问题引入

在上一章中，本文基于流形空间误差状态卡尔曼滤波（ESKF）算法，对 IMU 与 GPS 的融合方法进行了研究与验证。IMU 可以提供高频率的加速度与角速度信息，适合短时动态运动的连续估计；而 GPS 则能够提供绝对位置观测信息，修正 IMU 积分过程中的累积漂移误差。二者融合在开放环境下可以实现较为稳定的位姿估计效果。

然而，在实际应用场景中，尤其是在城市高楼林立、隧道、室内、森林等遮挡复杂的环境下，GPS 信号可能出现遮挡、弱化甚至完全丢失，导致定位结果精度下降甚至不可用。而 IMU 由于惯性积分误差的不断累积，也难以在长时间内单独维持高精度定位。IMU 虽然具备高频率与实时性优势，能够实时捕捉物体的动态变化，但受限于偏置漂移和随机噪声，其误差在长时间积分过程中呈指数式累积，严重影响位姿估计的长期稳定性。

为了弥补上述不足，需要引入能够提供丰富环境结构信息的额外传感器。其中，激光雷达（LiDAR）凭借其高精度、高分辨率的三维空间测距能力，能够实时捕获周围环境的几何特征，为运动估计提供丰富的空间约束信息。激光雷达通过发射激光并接收反射信号，能够精准测量与物体的距离，直接重建周围环境的三维点云模型，特别是在复杂和不规则环境中，在障碍物感知与地图构建任务中具有无可替代的优势。更重要的是，LiDAR 不依赖任何外部信号源，对外界光照、天气等干扰因素具有较强的适应性，因此在 GPS 信号失效或不稳定的场景下，成为提升系统定位精度与鲁棒性的关键传感器。

因此，将 IMU 与激光雷达的数据融合成为克服单一传感器局限性的有效方案。通过融合 IMU 提供的高频动态信息与激光雷达提供的空间几何约束，不仅能够充分利用二者的互补特性，提升整体位姿估计的精度与稳定性，同时也在复杂动态环境下具备更强的鲁棒性与适应能力，为后续的导航、路径规划与环境感知奠定坚实基础。

然而在 IMU 与激光雷达融合位姿估计中，主要面临以下核心问题：

（1）IMU 积分漂移问题

IMU 通过陀螺仪和加速度计的连续测量值推算载体的运动状态，这一过程本质上是基于牛顿运动定律的递推计算。然而，积分运算的固有特性使得传感器误差在时间维度上被逐级放大（角速度需一次积分，加速度需两次积分），导致位姿估计结果逐渐偏离真实轨迹，这一现象被称为“积分漂移”。

（2）传感器异构性

激光雷达提供世界系下的绝对位置观测（低频、高精度），而 IMU 输出本体系下的高频相对运动信息，二者数据速率和特性差异显著，需高效融合策略。

（3）姿态表示问题

传统扩展卡尔曼滤波（EKF）直接使用四元数或旋转矩阵来表示姿态，存在过参数化问题，可能导致协方差矩阵奇异，影响滤波稳定性。

（4）高维激光雷达数据运算问题

激光雷达（LiDAR）生成的点云数据因其高维度特性（且每个点包含三维坐标、反射强度等信息），在实时处理中面临显著的算力挑战。机械式激光雷达（如 Velodyne VLP-16）每帧生成约 30 万个点，固态雷达（如禾赛 PandarXT）可达百万级点云。这导致其运算复杂度非常高，尤其在低算力平台中，处理器可能无法处理如此规模的数据。

针对以上挑战，本文构建了基于流形空间优化的误差状态卡尔曼滤波（ESKF-manifold）算法框架，将其应用于 IMU 与激光雷达的数据融合中。该方法通过在流形空间中对姿态状态进行本地线性化建模，提高了非线性状态估计中的数值稳定性与滤波精度，从而实现高精度、高鲁棒性、高效的状态估计。这不仅可以提升定位精度，还能增强系统在复杂环境中的适应能力，尤其是在导航和环境感知任务中，提升系统的可靠性和安全性。

本章将详细介绍该融合方法的系统建模过程，包括状态转移模型、观测模型、误差状态定义与更新流程，并结合实验数据验证所提出方法在复杂环境中的精度与运行效率。通过本研究，旨在构建一套适用于动态环境、具备实时性和高鲁棒性的 IMU-LiDAR 融合位姿估计系统。

4.2 引入误差状态卡尔曼滤波的动机与优势

ESKF 通过分离名义状态与误差状态，针对上述问题提供了系统性解决方案。其核心动机与优势如下：

（1）解决 IMU 积分漂移

IMU 积分误差随时间呈非线性增长，传统扩展卡尔曼滤波直接对完整状态（如位置、姿态）进行滤波，难以在长时间内维持线性化假设。而误差状态卡尔曼滤波的名义状态可以通过 IMU 原始数据直接积分得到，作为“大信号”处理，允许非线性动态。而误差状态，仅描述标称状态与实际状态的微小偏差，始终维持在较小量级，满足线性化条件。并且具备以下优势：误差状态的动态方程可严格建模为线性系统，避免 EKF 因大误差导致的雅可比矩阵近似失效；激光雷达的低频观测直接修正误差状态，抑制长期漂移。

（2）多速率传感器融合

IMU（100 Hz）的工作频率与激光雷达（10 Hz）的工作频率速率差异大，传统 EKF 需在高频预测中频繁处理低频观测，计算冗余。而误差状态卡尔曼滤波可以仅更新名义状态（IMU 积分），无需频繁计算卡尔曼增益。仅在激光雷达数据到达时修正误差状态，显著降低计算负担。且有以下优势：通过误差状态的“注入-重置”机制（后文详述），实现传感器数据的异步高效融合。适合资源受限的嵌入式系统，如自动驾驶车辆或移动机器人。

（3）最小参数化设计

传统扩展卡尔曼滤波为了运算的封闭性，使用四元数（4 自由度）或旋转矩阵（9 自由度）表示姿态，冗余参数可能导致协方差矩阵奇异。而流形空间误差状态卡尔曼滤波利用误差状态是小量这一优势，可以直接利用流形空间的指、对数映射关系，使用三维小角度向量 $\delta \mathbf{r}$ 表示姿态误差，使得误差状态的协方差矩阵为 3×3 ，在维度上要小于四元数和旋转矩阵的协方差矩阵，避免协方差矩阵的奇异性风险。在高速旋转或剧烈运动中，流形空间 ESKF 的数值稳定性更好，并且简化协方差矩阵的更新过程，能够在一定程度上减少计算错误风险。

（4）计算效率提升：线性化与低维运算

传统扩展卡尔曼滤波需要频繁计算高维状态的雅可比矩阵，计算复杂度高。而

误差状态卡尔曼滤波的姿态误差仅需 3 维，比使用四元数的传统扩展卡尔曼滤波低一个维度，误差状态的传递矩阵 $\mathbf{F}$ 和观测矩阵 $\mathbf{H}$ 可以通过名义状态解析推导，无需数值近似，并且本文利用一种新的卡尔曼增益计算公式，能够显著降低其运算复杂度。

误差状态卡尔曼滤波通过误差状态线性化、多速率异步融合、最小参数化设计与低维运算优化，可以解决 IMU 与激光雷达融合中的漂移抑制、实时性、稳定性与计算效率问题，为自动驾驶、机器人定位等场景提供了高精度、高效率的鲁棒解决方案。

4.3 IMU 和激光雷达融合算法

在第 3 章中，已经对 IMU 状态运动学建模和误差状态运动过程进行了详细的描述，故在此不做重复赘述，现对激光雷达观测数据更新过程、注入过程和重置过程进行分析。

4.3.1 误差状态的更新过程

当接收到激光雷达数据时，对观测状态进行校正，观测方程为：

$$\mathbf{Y} = h(\mathbf{X}_t) + \mathbf{v} \quad (4-1)$$

其中， $h()$ 是激光雷达观测函数， $\mathbf{v}$ 是高斯白噪声，且 $\mathbf{v} \sim \mathcal{N}\{\mathbf{0}, \mathbf{V}\}$ ，协方差矩阵为 $\mathbf{V}$ 。

更新过程为：

$$\mathbf{K} = \mathbf{P}_{k+1}^- \mathbf{H}^T (\mathbf{H} \mathbf{P}_{k+1}^- \mathbf{H}^T + \mathbf{V})^{-1} \quad (4-2)$$

式 (4-2) 中， $\mathbf{K}$ 为卡尔曼增益， $\mathbf{P}_{k+1}^+$ 为更新后的误差协方差矩阵， $\mathbf{H} \in \mathbb{R}^{m \times 18}$ 为观测方程对于误差状态的雅可比矩阵：

$$\mathbf{H} \approx \left. \frac{\partial h}{\partial \delta \mathbf{x}} \right|_{\mathbf{x}} = \left. \frac{\partial h}{\partial \mathbf{x}_t} \right|_{\mathbf{x}} \left. \frac{\partial \mathbf{x}_t}{\partial \delta \mathbf{x}} \right|_{\mathbf{x}} = \mathbf{H}_x \mathbf{X}_{\delta \mathbf{x}_k} \quad (4-3)$$

经典卡尔曼增益计算公式的运算复杂度主要来自于矩阵逆运算 $(\mathbf{H} \mathbf{P}_{k+1}^- \mathbf{H}^T + \mathbf{V})^{-1}$ ，其复杂度为 $O(m^3)$ ，当观测维度 m 较低时（GPS 数据），经典卡尔曼增益公式是高效的，但当观测维度 m 较高时（激光雷达点云直接作为观测， m 可达数千维），其矩阵逆运算 $(\mathbf{H} \mathbf{P}_{k+1}^- \mathbf{H}^T + \mathbf{V})^{-1}$ 的运算复杂度将会非常巨大，实时性难以保证，尤其在低算力平台，可能无法处理如此规模的运算量。并且存储 $m \times m$ 矩

阵会占用大量内存开销。

故本文采用一种新的卡尔曼增益计算公式^{[21][55-57]}：

$$\mathbf{K} = \left(\mathbf{H}^T \mathbf{R}^{-1} \mathbf{H} + (\mathbf{P}_{k+1}^-)^{-1} \right)^{-1} \mathbf{H}^T \mathbf{V}^{-1} \quad (4-4)$$

该公式的优点在于，当观测数据来自激光雷达这类高维数据， $m \ll 18$ 时，此时 $\mathbf{H}^T \mathbf{R}^{-1} \mathbf{H} \in \mathbb{R}^{18 \times 18}$ ，需要逆运算的矩阵维度被固定在了 18×18 ，这将显著降低逆运算的运算复杂度。

$$\hat{\mathbf{x}}_{k+1} \leftarrow \mathbf{K}(\mathbf{Y} - h(\hat{\mathbf{x}}_{k+1}^-)) \quad (4-5)$$

$$\mathbf{P}_{k+1}^+ \leftarrow (\mathbf{I} - \mathbf{K}\mathbf{H})\mathbf{P}_{k+1}^- \quad (4-6)$$

4.3.2 误差状态的注入过程和重置过程

在误差状态得到更新后，名义状态通过误差状态进行更新：

$$\hat{\mathbf{x}}_{k+1} \leftarrow \hat{\mathbf{x}}_{k+1}^- + \delta \mathbf{x}_{k+1} \quad (4-7)$$

令重置函数为 $g()$ ，有：

$$\delta \mathbf{x}_{k+1} \leftarrow g(\delta \mathbf{x}_{k+1}) = (\mathbf{x}_{k+1} - \hat{\mathbf{x}}_{k+1})' \left(\mathbf{x}_{k+1} - \hat{\mathbf{x}}_{k+1} \right) \quad (4-8)$$

$$\mathbf{P}_{k+1} \leftarrow \mathbf{G} \mathbf{P}_{k+1} \mathbf{G}^T \quad (4-9)$$

$$\mathbf{G} = \frac{\partial g}{\partial \delta \mathbf{x}} \bigg|_{\delta \mathbf{x}} = \begin{bmatrix} \mathbf{I} - \frac{1}{2} \delta r_k^{\wedge} & 0 \\ 0 & \mathbf{I}_{15} \end{bmatrix} \quad (4-10)$$

4.4 实验与分析

在本节中，将详细介绍实验设计的各个方面，来证明基于误差状态卡尔曼滤波的 IMU 和激光雷达融合算法的可行性及有效性。

4.4.1 实验设置和数据来源

本实验中的数据来自 M2DGR^[58]，是由上海交通大学殷杰所提出的一个大规模多模态数据集，专门为自动驾驶、SLAM（同步定位与地图构建）、视觉惯性导航系统（VINS）、机器人学等领域的研究提供丰富的数据支持。该数据集由一台地面机器人采集，包含了多种传感器数据，旨在帮助研究人员评估和改进传感器融合算法、定位算法以及环境感知方法。

数据集传感器数据如下：

激光雷达: Velodyne VLP-32C, 水平视场 (FOV) 360° , 垂直视场 (FOV) -30° 至 $+10^\circ$, 采样频率 10Hz, 最大测距 200 米, 测距分辨率 3 厘米, 水平角分辨率 0.2° 。

IMU: Handsfree A9, 9 轴, 采样频率 150Hz。

RGB 相机: FLIR Pointgrey CM3-U3-13Y3C-CS, 鱼眼镜头, 分辨率 1280×1024 , 水平视场 (HFOV) 190° , 垂直视场 (V-FOV) 190° , 采样频率 15Hz。

1. 硬件平台

处理器: Intel Core i5-6500, 4 核 4 线程, 时钟频率为 3.2 GHz, TDP 65 W, 发布于 2015 年第三季度。

内存: 8GB DDR4 内存。

存储: 致钛 PC005

主板: 华硕 B150M

2. 软件环境

操作系统: Ubuntu 20.04。

编程语言: C++。

框架与库: ROS (Robot Operating System) Noetic, 用于传感器数据融合与通信; Eigen, 提供高效的线性代数运算 (矩阵/向量操作、四元数、李群/李代数变换); PCL (Point Cloud Library) 用于激光雷达点云的预处理 (去噪、滤波)、特征提取 (边缘/平面特征)、点云配准等; OpenCV, 用于图像处理; YAML (YAML Ain't Markup Language) 库, 用于配置文件读写与参数管理, 方便在系统中统一加载滤波器参数、传感器标定数据与算法配置项; Glog (Google Logging), 用于系统日志记录与调试信息输出, 支持高效的日志级别管理, 便于系统调试与性能分析。

4.4.2 评价指标

为了全面评估所提出的基于流形空间误差状态卡尔曼滤波的 IMU 和激光雷达融合算法在位姿估计中的表现, 本实验选取了相对位置误差 (Relative Pose Error) 作为主要精度评估指标。RPE 能够直接反映估计轨迹与真实轨迹在空间位置上的相对偏离程度, 是位姿估计算法性能评估中广泛采用的重要标准。在 RPE 基础上, 进一步从多个统计学维度对估计误差进行定量分析, 包括最大误差 (Max Error)、均值误差 (Mean Error)、中位数误差 (Median Error)、最小误差 (Min Error)、均

方根误差 (Root Mean Square Error, RMSE) 以及标准差 (Standard Deviation, STD)。其中, 最大误差反映算法在最极端情况下的偏离程度, 均值误差与中位数误差描述整体精度水平, RMSE 综合体现了整体误差分布特征, 而标准差则反映误差在整个序列中的稳定性与波动性。这些指标相互补充, 从不同角度揭示算法在精度、稳定性和鲁棒性方面的性能差异。

通过上述多维度指标的综合评估, 可全面分析并对比所提出的基于流形空间优化的误差状态卡尔曼滤波算法与其他对比算法在实验数据集中的表现优势与不足。实验结果不仅有助于验证本文所提出方法在不同运行场景下的有效性, 也为后续在实际应用中选择适用的位姿估计方法提供了系统性的参考依据与理论支持。

4.4.3 实验结果

在基于流形空间误差状态卡尔曼滤波 (ESKF) 的 IMU 和激光雷达融合算法中, 为了验证 IMU 与激光雷达融合算法的性能, 实验流程主要包括两个阶段: 地图构建阶段与位姿估计阶段。

首先, 在地图构建阶段, 利用激光雷达 (LiDAR) 在目标环境中采集的数据, 通过前端匹配与后端优化等点云处理算法, 生成了高精度的稠密三维点云地图。该地图作为后续定位过程中的静态环境参考, 为实时位姿估计算法提供空间几何约束信息。地图的准确性与完整性直接影响后续定位精度, 因此地图构建阶段在无 IMU 漂移影响的条件下单独进行, 以确保其稳定性。

在位姿估计阶段, 系统在已构建的静态点云地图基础上, 结合实时激光雷达扫描数据与 IMU 测量数据, 使用流形空间误差状态卡尔曼滤波融合算法, 实时估计系统当前的位姿状态。IMU 提供高频的运动先验信息, 有助于激光雷达匹配过程的快速收敛, 而激光雷达则通过与地图的匹配修正 IMU 积分累积误差, 从而实现高精度、低漂移的位姿估计结果。

本次实验所采用的数据集总大小为 27.3Gb, 录制时间 327 秒, 运行距离 248.40 米。

图 4.1 和 4.2 展示了生成的点云地图, 可以看到地图无明显分层、错位或断裂现象。




图 4.1 点云地图俯视图

Figure 4.1 Overhead View of the Point Cloud Map




图 4.2 点云地图正视图

Figure 4.2 Frontal View of the Point Cloud Map

得益于 LiDAR 的高精度扫描,点云地图保留了环境中的关键几何细节和语义特征:(1)结构化物体:如墙面直角、人行道路、拱门、花坛等几何参数清晰可见(图 4.1 和图 4.2 中建筑轮廓的锐利边界);(2)自然物体:植被分布(如树木点云的团簇形态)、地面起伏(如草坪与路面的高程差异)等非结构化特征被精确捕捉。结构化场景与非结构化环境的精确建模,以及动态干扰的有效抑制,表明该地图可直接支撑导航、避障等下游任务,为机器人长期自主运行提供了可靠的环境表征基础。

在本实验中,为了全面验证所提出的基于流形空间误差状态卡尔曼滤波(ESKF)

算法的性能，设计了四组对比实验，分别为：IMU 直接积分法、扩展卡尔曼滤波（EKF）、四元数误差状态卡尔曼滤波（ESKF-Quaternion）以及本文所提出的流形空间误差状态卡尔曼滤波（ESKF-Manifold）。通过对比不同算法在相同传感器输入下的位姿估计结果，评估各算法在精度、稳定性与实时性方面的表现差异。

图 4.3 和图 4.4 分别展示了 IMU 和 LiDAR 融合算法在点云地图中的运动过程可视化。图中的白色轨迹是经过融合后的运动轨迹，其平滑性与全局一致性可以验证了算法的位姿估计的精度——在复杂运动（如环形运动、快速移动）与特征缺失场景（如长直走廊、动态遮挡）下，轨迹均未出现显著跳变或累积漂移。




图 4.3 点云地图中的运动过程（A）

Figure 4.3 Motion Trajectory within the Point Cloud Map (A)



图 4.4 点云地图中的运动过程（B）

Figure 4.4 Motion Trajectory within the Point Cloud Map (B)

为了进一步对比不同方法在位姿估计精度上的表现，绘制了不同算法的相对位置误差曲线，图 3.5 展示了不同算法的 RPE 曲线。




图 3.5 相对位置误差

A. IMU 直接积分相对位置误差 B. EKF 相对位置误差

C. ESKF-Quaternion 相对位置误差 D. ESKF-Manifold 相对位置误差

Figure 3.5 Relative Position Error

A. Relative Pose Error of IMU Direct Integration

B. Relative Pose Error of EKF

C. Relative Pose Error of ESKF-Quaternion

D. Relative Pose Error of ESKF-Manifold

四种方法的相对位置误差的统计结果由表 4.1 给出，单位均为米（m）。为全面反映不同算法在位姿估计精度、稳定性及鲁棒性方面的性能表现，本文统计了最大误差（Max Error）、均值误差（Mean Error）、中位数误差（Median Error）、最小误差（Min Error）、均方根误差（RMSE, Root Mean Square Error）以及标准差（STD,

Standard Deviation) 等多项指标。

表 4.1 各算法相对位置误差值

Table 4.1 Relative Pose Error Values of Various Algorithms

算法	Max	Min	RMSE	Median	Mean	STD
IMU 直接积分	12.95	0.54	6.27	5.39	5.27	3.40
EKF	2.64	0.78	1.98	1.88	1.80	0.65
ESKF-Quaternion	2.17	0.58	1.77	1.78	1.74	0.37
ESKF-Manifold	2.12	0.52	1.74	1.76	1.70	0.36

为进一步评估各算法的实时性能, 本文对比了四种方法在位姿估计过程中每帧的平均计算耗时, 统计结果如表 3.2 所示, 单位均为毫秒 (ms)。所有实验均在相同硬件环境下进行。

算法	每帧平均耗时 (ms)
IMU 直接积分	0.25
EKF	44
ESKF-Quaternion	85
ESKF-Manifold	71

4.4.4 实验结果分析

为全面评估各算法在位姿估计任务中的精度与实时性表现, 本文对比分析了四种算法的相对位置误差与平均单帧计算耗时, 相关统计结果分别如表 4.1 和表 4.2 所示。

在相对位置误差方面, IMU 直接积分缺乏外部校正机制, 其误差指标明显高于其他三种融合算法; 在稳定了一段时间后, 位置误差快速累积, 且一直处于上升状态, 在长时间运行过程中误差快速累积, 最大误差达到了 12.95 m, 均方根误差 (RMSE) 为 6.27 m, 误差波动较大, 标准差为 3.40 m, 难以满足实际位姿估计需求。

相比之下, EKF、ESKF-Quaternion 和 ESKF-Manifold 在引入激光雷达观测信息后, 均显著改善了这一问题。EKF 算法通过融合 IMU 的高频动态信息与激光雷达提供的环境几何信息, 有效抑制了积分漂移, 最大误差降至 2.64 m, RMSE 为 1.98 m, 标准差也大幅降低至 0.65 m, 整体估计精度与稳定性有显著提升。

ESKF-Quaternion 算法在误差状态建模中引入了李群-李代数框架下的四元数表示, 进一步优化了姿态误差建模, 提升了整体融合效果, RMSE 降低至 1.77 m, 标准差为 0.37 m, 误差分布更加集中稳定。

本文所提出的 ESKF-Manifold 方法在建模过程中充分考虑了位姿空间的流形特性, 避免了四元数的冗余约束。在所有算法中, ESKF-Manifold 在各项误差指标中均表现最优, 最大误差为 2.12 m, RMSE 最低为 1.74 m, 标准差最小仅为 0.36 m, 充分验证了该方法在 IMU 与激光雷达紧耦合融合中的有效性与优势。需要指出的是, ESKF-Manifold 与 ESKF-Quaternion 在所有统计指标上表现出一定的相似性, 二者均在精度与稳定性方面明显优于传统 EKF 与 IMU 积分方法, 但 ESKF-Manifold 在误差收敛性及鲁棒性上仍展现出更优表现。

表 4.2 展示了各算法在测试数据中的平均每帧处理时间, 反映了其计算效率与实际运行时的实时性。IMU 直接积分法由于不涉及外部观测融合, 计算开销极低, 平均每帧耗时仅 0.25 ms, 但其精度无法满足实际定位需求。EKF 算法在实现过程平均每帧耗时为 44 ms。ESKF-Quaternion 与 ESKF-Manifold 平均每帧耗时分别为 85 ms 与 71 ms。尽管计算复杂度略有增加, 但在现代硬件条件下仍具备实时运行能力。

综合来看, ESKF-Manifold 算法在保持较高实时性的同时, 获得了最优的定位精度和误差稳定性。其在流形空间下的误差建模方式不仅保持了算法收敛性, 还提升了系统的整体鲁棒性, 特别适用于复杂环境中对高精度和高可靠性要求较高的定位任务。

4.5 本章小结

本章系统性地研究了基于流形空间误差状态卡尔曼滤波 (ESKF-Manifold) 的 IMU 与激光雷达数据融合算法, 重点针对惯性测量单元 (IMU) 在长时间运行中误差累积严重的问题, 提出了有效的融合与补偿方法。通过引入激光雷达作为高精度

外部观测源，为系统提供了丰富的环境几何信息与空间约束，有效抑制了 IMU 漂移误差的不断积累，提升了整体位姿估计的精度与稳定性。

在本章开始部分，首先分析了 IMU 与 GPS 融合方案在复杂环境下的应用瓶颈，指出在城市峡谷、隧道、森林等遮挡严重或信号弱化场景中，GPS 信号的不可用性严重影响了系统的连续定位能力。为克服这一问题，本文引入具备强大环境感知能力的激光雷达作为辅助观测传感器，结合其在三维空间中的高精度测距特性，实现了对复杂环境的稳定感知与约束。

随后，详细阐述了地图构建与实时位姿估计的整体流程，利用 IMU 与激光雷达的优势互补特性，设计了高精度、高鲁棒性的位姿估计系统。最后，通过在仿真与实验环境下的大量对比测试，验证了所提出算法在精度、稳定性与计算效率方面的优越性能，尤其在流形空间误差建模框架下，进一步提升了融合算法的整体表现，为后续在实际复杂环境中的应用提供了有力支撑与技术储备。

总的来说，本章的研究表明，IMU 和激光雷达的有效融合不仅提高了位姿估计精度，还增强了系统的鲁棒性，为复杂环境的位姿估计提供理论支撑。

第五章 总结与展望

5.1 工作总结

本论文主要研究了基于流形空间误差状态卡尔曼滤波(ESKF-Manifold)的 IMU 与 GPS 以及 IMU 与激光雷达数据融合方法,旨在提高多传感器系统在复杂环境下的定位精度、环境感知能力及系统鲁棒性。研究的核心工作包括以下几个方面:

(1) IMU 与 GPS 融合方法设计

通过深入分析 IMU 和 GPS 各自的优势与局限性,本文提出了一种基于流形空间 ESKF 的 IMU 与 GPS 数据融合算法。该算法有效解决了 IMU 误差积累和 GPS 信号丢失问题,能够显著提高定位精度。

(2) IMU 与激光雷达融合方法设计

结合 IMU 的高频动态数据和激光雷达提供的高精度环境信息,提出了基于流形空间 ESKF 的 IMU 与激光雷达数据融合算法。通过实验验证,融合方法在动态环境中有效提升了位姿估计的精度和稳定性,尤其在复杂场景和障碍物密集的环境下,展现出了优异的精度和鲁棒性。

(3) 实验验证与性能评估

本文通过 GNSS-INS-SIM 仿真工具和 M2DGR 数据集上的实验,验证了 IMU 与 GPS 以及 IMU 与激光雷达数据融合算法的有效性。实验结果表明,IMU 与 GPS 融合能够有效消除单一传感器的局限性,IMU 与激光雷达的融合则显著提高了位姿估计性能和系统实时性,增强了在复杂动态场景下的鲁棒性。

总体而言,本论文提出的基于 ESKF 的 IMU 与 GPS、IMU 与激光雷达数据融合方法在提高定位精度、增强系统鲁棒性和适应复杂环境方面取得了一定成果。这些研究为自动驾驶、机器人导航、环境感知等领域提供了一个有效的解决方案,并在实践中具有重要应用价值。

5.2 研究展望

尽管本研究取得了一定的成果,但在复杂环境中的定位精度和系统稳定性方面仍然存在一些挑战。未来的研究可以从以下几个方面进行拓展:

(1) 多传感器融合的进一步优化

当前的 IMU 与 GPS 及 IMU 与激光雷达数据融合主要集中在传感器误差的补偿和环境感知能力的提升上。未来可以探索更多类型的传感器（如视觉传感器、毫米波雷达、超声波传感器等）的融合，以进一步增强系统的环境感知能力和鲁棒性，尤其在复杂动态环境中，提升系统的适应性和精度。

（2）深度学习与数据融合的结合

随着深度学习技术的快速发展，未来可以探索将深度学习与传统数据融合方法相结合，利用深度神经网络对多传感器数据进行端到端学习。这将有助于提升系统在复杂环境中的感知和决策能力，尤其是在图像、点云等数据的自动特征提取和理解方面。

（3）更多硬件平台与算法的结合

本研究中使用多传感器系统是基于现有的硬件平台进行的实验，未来可以根据不同的应用场景和硬件平台进行算法优化和定制。特别是在低算力平台（如嵌入式系统、无人机等）上，进一步优化计算效率和功耗，以满足实时性和能效的需求。

（4）实际应用场景的验证与推广

虽然本研究中的算法和实验验证了其有效性，但仍需在实际应用场景中进行广泛验证。未来可以将这些算法应用于自动驾驶、工业机器人、无人机等实际系统中，通过不断改进和反馈，推动算法在实际环境中的应用与推广。

综上所述，未来的研究将进一步深化多传感器融合技术的应用与发展，探索更高效、智能和鲁棒的解决方案，推动智能定位与导航系统在各个领域的广泛应用。

参考文献

- [1] Yurtsever E., Lambert J., Carballo A., Takeda K. A survey of autonomous driving: common practices and emerging technologies[J]. *IEEE Access*, 2020, 8: 58443–58469.
- [2] Gul F., Rahiman W., Nazli Alhady S. S. A comprehensive study for robot navigation techniques[J]. *Cogent Engineering*, 2019, 6(1).
- [3] Carmigniani J., Furht B. Augmented reality: an overview[C]// Furht B., ed. *Handbook of Augmented Reality*. New York, NY: Springer, 2011.
- [4] Wohlgenannt I., Simons A., Stieglitz S. Virtual reality[J]. *Business & Information Systems Engineering*, 2020, 62: 455–461.
- [5] Mitchell H. B. Multi-Sensor Data Fusion: An Introduction[M]. Cham: Springer, 2010.
- [6] Lin X., Zai W., Lin Q., Zhang Q. A multi-sensor fusion SLAM algorithm for indoor aerial robots[J]. *Journal of Control and Decision*, 2024: 1–11.
- [7] Ahmad R. A. R., Ghazilla N. M., Khairi N. M., et al. Reviews on various inertial measurement unit (IMU) sensor applications[J]. *International Journal of Signal Processing Systems*, 2013, 1(2): 256–262.
- [8] Kim M. S., Yu S. B., Lee K. S. Development of a high-precision calibration method for inertial measurement unit[J]. *International Journal of Precision Engineering and Manufacturing*, 2014, 15: 567–575.
- [9] Xu G., Xu Y. GPS: Theory, Algorithms and Applications[M]. Cham: Springer, 2018.
- [10] Nister D., Naroditsky O., Bergen J. Visual odometry[C]. *Proceedings of the 2004 IEEE Computer Society Conference on Computer Vision and Pattern Recognition (CVPR)*, Washington, DC, USA, 2004.
- [11] Agostinho L. R., Ricardo N. M., Pereira M. I., Hiole A., Pinto A. M. A practical survey on visual odometry for autonomous driving in challenging scenarios and conditions[J]. *IEEE Access*, 2022, 10: 72182–72205.
- [12] Neyestani A., Picariello F., Basiri A., Daponte P., Vito L. D. Survey and research challenges in monocular visual odometry[C]. *Proceedings of the 2023 IEEE International Workshop on Metrology for Living Environment (MetroLivEnv)*, Milano, Italy, 2023: 107–112.
- [13] Yin H., Xu X., Lu S., et al. A survey on global LiDAR localization: challenges, advances and open problems[J]. *International Journal of Computer Vision*, 2024, 132: 3139–3171.

- [14] Huang L. Review on LiDAR-based SLAM techniques[C]. *Proceedings of the 2021 International Conference on Signal Processing and Machine Learning (CONF-SPML)*, Stanford, CA, USA, 2021: 163–168.
- [15] Roriz R., Cabral J., Gomes T. Automotive LiDAR technology: a survey[J]. *IEEE Transactions on Intelligent Transportation Systems*, 2022, 23(7): 6282–6297.
- [16] Cheng Y., Wang G. Y. Mobile robot navigation based on lidar[C]. *Proceedings of the 2018 Chinese Control and Decision Conference (CCDC)*, Shenyang, China, 2018: 1243–1246.
- [17] Kalman R. E. A new approach to linear filtering and prediction problems[J]. *ASME Journal of Basic Engineering*, 1960, 82(1): 35–45.
- [18] Thrun S., Burgard W., Fox D. Probabilistic Robotics[M]. Cambridge, MA, USA: MIT Press, 2005.
- [19] Julier S. J., Uhlmann J. K., Durrant-Whyte H. F. A new approach for filtering nonlinear systems[C]. *Proceedings of the 1995 American Control Conference (ACC)*, Seattle, WA, USA, 1995, vol. 3: 1628–1632.
- [20] Damagatla R. K. R., Atia M. Improving EKF-based IMU/GNSS fusion using machine learning for IMU denoising[J]. *IEEE Access*, 2024, 12: 114358–114369.
- [21] Xu W., Zhang F. Fast-LIO: a fast, robust LiDAR-inertial odometry package by tightly-coupled iterated Kalman filter[J]. *IEEE Robotics and Automation Letters*, 2021, 6(2): 3317–3324.
- [22] Wan E. A., Van Der Merwe R. The unscented Kalman filter for nonlinear estimation[C]. *Proceedings of the IEEE 2000 Adaptive Systems for Signal Processing, Communications, and Control Symposium*, Lake Louise, Canada, 2000: 153–158.
- [23] Cahyadi M. N., Asfihani T., Mardiyanto R., Erfianti R. Performance of GPS and IMU sensor fusion using unscented Kalman filter for precise i-Boat navigation in infinite wide waters[J]. *Geodesy and Geodynamics*, 2022.
- [24] Sola J. Quaternion kinematics for the error-state Kalman filter[R]. arXiv preprint arXiv:1711.02508, 2017.
- [25] Lyu Z., Li Z. Error-state Kalman filter for INS/GPS integration with application to UAV navigation[J]. *Journal of Navigation*, 2017, 70(4): 625–641.
- [26] Gordon N. J., Salmond D. J., Smith A. F. Novel approach to nonlinear and non-Gaussian

- Bayesian state estimation[J]. *IEE Proceedings - Radar, Sonar and Signal Processing*, 1993, 140(2).
- [27] Doucet A., Godsill S., Andrieu C. On sequential Monte Carlo sampling methods for Bayesian filtering[J]. *Statistics and Computing*, 2000, 10(3): 197–208.
- [28] Montemerlo M., Thrun S., Koller D., Wegbreit B. FastSLAM: a factored solution to the simultaneous localization and mapping problem[C]. *Proceedings of the AAAI National Conference on Artificial Intelligence*, 2002: 593–598.
- [29] Mur-Artal R., Montiel J. M. M., Tardós J. D. ORB-SLAM: a versatile and accurate monocular SLAM system[J]. *IEEE Transactions on Robotics*, 2015, 31(5): 1147–1163.
- [30] Björck Å. Least squares methods[M]// *Handbook of Numerical Analysis*, vol. 1. Amsterdam: Elsevier, 1990: 465–652.
- [31] Ruszczyński A. *Nonlinear Optimization*[M]. Princeton: Princeton University Press, 2011.
- [32] Kümmerle R., Grisetti G., Strasdat H., Konolige K., Burgard W. G2o: a general framework for graph optimization[C]. *Proceedings of the IEEE International Conference on Robotics and Automation (ICRA)*, Shanghai, China, 2011: 3607–3613.
- [33] Wen W., Hsu L.-T. Towards robust GNSS positioning and real-time kinematic using factor graph optimization[C]. *Proceedings of the IEEE International Conference on Robotics and Automation (ICRA)*, Xi'an, China, 2021: 5884–5890.
- [34] Shan T., Englot B., Meyers D., Wang W., Ratti C., Rus D. LIO-SAM: tightly-coupled LiDAR inertial odometry via smoothing and mapping[C]. *Proceedings of the IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*, 2020: 5135–5142.
- [35] Tang Q., Liang J., Zhu F. A comparative review on multi-modal sensors fusion based on deep learning[J]. *Signal Processing*, 2023, 213: 109165.
- [36] Chu Z., Wang F., Lei T., Luo C. Path planning based on deep reinforcement learning for autonomous underwater vehicles under ocean current disturbance[J]. *IEEE Transactions on Intelligent Vehicles*, 2023, 8(1): 108–120.
- [37] Chen P., Pei J., Lu W., Li M. A deep reinforcement learning based method for real-time path planning and dynamic obstacle avoidance[J]. *Neurocomputing*, 2022, 497: 64–75.
- [38] Choi J. D., Kim M. Y. A sensor fusion system with thermal infrared camera and LiDAR for autonomous vehicles and deep learning based object detection[J]. *ICT Express*, 2023, 9(2): 222–227.

- [39] Cai P., Wang H., Sun Y., Liu M. DQ-GAT: towards safe and efficient autonomous driving with deep Q-learning and graph attention networks[J]. *IEEE Transactions on Intelligent Transportation Systems*, 2022, 23(11): 21102–21112.
- [40] Sadid H., Antoniou C. Dynamic spatio-temporal graph neural network for surrounding-aware trajectory prediction of autonomous vehicles[J]. *IEEE Transactions on Intelligent Vehicles*, 2024.
- [41] Lupton T., Sukkarieh S. Visual-inertial-aided navigation for high-dynamic motion in built environments without initial conditions[J]. *IEEE Transactions on Robotics*, 2012, 28(1): 61–76.
- [42] Forster C., Carlone L., Dellaert F., Scaramuzza D. IMU preintegration on manifold for efficient visual-inertial maximum-a-posteriori estimation[C]. *Proceedings of Robotics: Science and Systems XI*, 2015.
- [43] Stumberg L. v., Cremers D. DM-VIO: delayed marginalization visual-inertial odometry[J]. *IEEE Robotics and Automation Letters*, 2022, 7(2): 1408–1415.
- [44] Mur-Artal R., Tardós J. D. Visual-inertial monocular SLAM with map reuse[J]. *IEEE Robotics and Automation Letters*, 2017, 2(2): 796–803.
- [45] Yu Z., Zhu L., Lu G. VINS-Motion: tightly-coupled fusion of VINS and motion constraint[C]. *Proceedings of the IEEE International Conference on Robotics and Automation (ICRA)*, Xi'an, China, 2021: 7672–7678.
- [46] Qin T., Li P., Shen S. VINS-Mono: a robust and versatile monocular visual-inertial state estimator[J]. *IEEE Transactions on Robotics*, 2018, 34(4): 1004–1020.
- [47] Liu H., Chen M., Zhang G., et al. ICE-BA: incremental, consistent and efficient bundle adjustment for visual-inertial SLAM[C]. *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2018: 1974–1982.
- [48] 戴建生. 旋量代数与李群, 李代数[J]. *机械设计与研究*, 2014, 30(4)
- [49] 王萼芳. 有限群论基础[M]. 清华大学出版社, 2002.
- [50] Bishop R. L., Crittenden R. J. *Geometry of Manifolds*[M]. New York: Academic Press, 2011.
- [51] Crassidis J. L., Junkins J. L. *Optimal Estimation of Dynamic Systems*[M]. Boca Raton: CRC Press, 2011.
- [52] 高翔, 张涛. 视觉 SLAM 十四讲: 从理论到实践 [M]. 第 2 版. 北京: 电子工业出版社,

- 2019.
- [53] 高翔. 自动驾驶与机器人中的 SLAM 技术 [M]. 北京: 电子工业出版社, 2023.
- [54] Aceinna. GNSS-INS-SIM: GNSS/INS Simulation Project. GitHub Repository. Available on line: <https://github.com/Aceinna/gnss-ins-sim>
- [55] Xu W., Cai Y., He D., Lin J., Zhang F. FAST-LIO2: fast direct LiDAR-inertial odometry [J]. *IEEE Transactions on Robotics*, 2022, 38(4): 2053–2073.
- [56] Zheng C., et al. Fast-LIVO: fast and tightly-coupled sparse-direct LiDAR–inertial–visual odometry[C]. *Proceedings of the IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*, 2022.
- [57] Zheng C., et al. Fast-LIVO2: fast, direct LiDAR–inertial–visual odometry[J]. *IEEE Transactions on Robotics*, 2025, 41.
- [58] Yin J., Li A., Li T., Yu W., Zou D. M2DGR: a multi-sensor and multi-scenario SLAM dataset for ground robots[J]. *IEEE Robotics and Automation Letters*, 2022, 7(2): 2266–2273.
- [59] 秦永元. 惯性导航 [M]. 北京: 科学出版社, 2014: 288-305
- [60] Bloesch M., et al. Robust visual inertial odometry using a direct EKF-based approach[C]. *Proceedings of the IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*, 2015: 298–304.
- [61] Nikolas T., et al. 3D relative pose estimation from distance-only measurements[C]. *Proceedings of the IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*, 2007.
- [62] Martinelli A. Vision and IMU data fusion: closed-form solutions for attitude, speed, absolute scale, and bias determination[J]. *IEEE Transactions on Robotics*, 2012, 28(1): 44–60.
- [63] Schneider T., et al. Maplab: an open framework for research in visual-inertial mapping and localization[J]. *IEEE Robotics and Automation Letters*, 2018, 3(3): 1418–1425.
- [64] Warner F. W. Foundations of Differentiable Manifolds and Lie Groups[M]. New York: Springer, 1983.
- [65] Jia B., Bai Z., Gao Y., Wang D., Zhou M., Gao P., Zhang P., Yang Z. Manifold-optimized error state Kalman filter for robust pose estimation in UAVs[J]. *Journal of Electronic Research and Application*, 2025, 8(3).
- [66] Vitali R. V., McGinnis R. S., Perkins N. C. Robust error-state Kalman filter for estimatin

-
- g IMU orientation[J]. *IEEE Sensors Journal*, 2021, 21(3): 3561–3569.
- [67] Iyer K., Dey A., Xu B., Sharma N., Hsu L.-T. Enhancing positioning in GNSS denied environments based on an extended Kalman filter using past GNSS measurements and IMU[J]. *IEEE Transactions on Vehicular Technology*, 2024, 73(6): 7908–7924.
- [68] Fan Z., Zhang L., Wang X., et al. LiDAR, IMU, and camera fusion for simultaneous localization and mapping: a systematic review[J]. *Artificial Intelligence Review*, 2025, 58: 174.
- [69] Shen Z., Wang J., Pang C., Lan Z., Fang Z. A LiDAR-IMU-GNSS fused mapping method for large-scale and high-speed scenarios[J]. *Measurement*, 2024, 225: 113961.
- [70] Zhao Y., Liang Y., Ma Z., Guo L., Zhang H. Localization and Mapping Algorithm Based on Lidar-IMU-Camera Fusion[J]. *Journal of Intelligent and Connected Vehicles*, 2024, 7(2): 97–107.