



廣東工業大學
GUANGDONG UNIVERSITY OF TECHNOLOGY

硕士学位论文

红外及可见偏振图像多模态 融合算法研究

作 者 姓 名 : 劳俞凯

导 师 姓 名 : 邸江磊

学科(专业)或领域名称 : 信息与通信工程

论 文 答 辩 年 月 : 2025 年 11 月 17 日



中图分类号:

学校代号: 11845

UDC:

密级:

学

号: 2112203032

广东工业大学硕士学位论文

(工学硕士)

红外及可见偏振图像多模态融合算法研究

劳俞凯

指导教师姓名、职称: 邱江磊 教授

校外指导教师姓名、职称: 无

学科(专业)或领域名称: 信息与通信工程

学生所属学院: 信息工程学院

答辩委员会主席: 吕晓旭 教授

论文答辩日期: 2025 年 11 月 17 日

A Dissertation Submitted to Guangdong University of Technology
in Partial Fulfillment of the Requirement
for the Degree of Master of Engineering Science

Research on Multimodal Fusion Algorithms for Infrared
and Visible Polarized Images

Candidate: LAO Yukai
Supervisor: Prof. DI Jianglei

Nov 17, 2025
School of Information Engineering
Guangdong University of Technology
Guangzhou, Guangdong, P. R. China, 510006

摘要

图像融合技术在计算机视觉领域的重要性日益凸显。利用图像融合技术整合不同波段图像的信息，能够为军事目标识别与检测、空域防护与监测等应用场景提供有力保障。红外图像具备感知目标热信息的能力，具有较好的穿透性和隐蔽性，但易受环境影响，对比度和分辨率较低；可见光波段的偏振图像不仅具有较高的光学分辨率，同时对场景光学特性敏感，但其成像质量受光照角度等条件影响明显。红外图像与可见偏振图像融合有助于实现目标背景信息的互补及目标精确识别。然而，现有图像融合算法面临模态间特征差异大、环境干扰敏感等问题，导致融合结果细节丢失或语义信息不匹配。针对上述问题，本文围绕红外图像及可见偏振图像融合的问题提出两种基于端到端卷积神经网络的图像融合算法，通过跨模态特征交互与自适应融合机制，实现复杂场景下多源图像信息的互补与增强。本文主要开展的研究工作有：

(1) 提出了一种用于红外和可见偏振图像融合的基于显著性引导的端到端多模态图像融合网络模型 **SGfusionNet**，旨在保留更加全面和生成信息更加丰富的融合图像。首先，引入了双分支特征提取模块，通过嵌入梯度滤波器，更好地捕捉强特征；其次，引入自适应特征融合模块，通过学习从多模态图像中逐步选择主导特征实现互补融合；最后，设计了一种显著性加权损失函数，通过在语义显著区域分配更高的权重，引导特征提取和融合更多地集中在显著区域，同时也在非显著区域保留了丰富信息。实验结果表明，所提出方法具有更自然的视觉效果，与最新融合方法 **CDDFuse** 相比在互信息、平均梯度、空间频率、视觉信息保真度和标准差等指标上分别提高了 31.74%、19.95%、30.14%、5.45% 和 3.09%。

(2) 提出了一种面向三波段红外图像的分层次端到端融合网络模型 **M3F Fusion**，旨在提升长波、中波与短波红外图像的整体融合质量。现有方法多侧重于局部特征提取，对不同波段中目标特征的差异化利用存在局限。**M3F Fusion** 通过两个跨模态交叉融合模块，提取长波、中波和短波红外的互补特征，从而生成细节更多信息更全的增强融合图像。同时，引用显著性加权损失函数优化融合质量。与最新融合方法 **PIAFusion** 相比，所提出算法在信噪比、相关系数和视觉信息保真度等指标上分别提高了 21.90%、23.25% 和 28.70%。

关键词：深度学习；图像融合；端到端融合网络；多模态图像

ABSTRACT

The Significance of Image Fusion Technology in the Field of Computer Vision is increasingly prominent. By integrating information from images of different wavebands, image fusion technology provides robust support for application scenarios such as military target recognition and detection, as well as airspace protection and monitoring. Common infrared images, capable of perceiving thermal information from targets, offer advantages like good penetration characteristics and concealment. However, they are significantly affected by environmental conditions and often exhibit low contrast and resolution. In contrast, visible polarization images not only possess higher resolution but are also sensitive to the optical properties of a scene. Nevertheless, their imaging quality is notably influenced by lighting conditions. Fusing infrared and visible polarization images facilitates the complementary integration of target and background information, thereby enabling more precise target identification. However, existing image fusion algorithms face challenges such as substantial feature discrepancies between different modalities and sensitivity to environmental interference, which can lead to loss of detail or semantic information mismatch in the fusion results. To address these issues, this thesis proposes two image fusion algorithms based on end-to-end convolutional neural networks for fusing infrared and visible polarization images. These algorithms aim to achieve complementary and enhanced multi-source image information in complex scenes through cross-modal feature interaction and an adaptive fusion mechanism. The primary research work conducted in this thesis includes the following:

(1) An end-to-end multimodal image fusion network model SGfusionNet based on saliency guidance is proposed for the fusion of infrared and visible polarized images, aiming to retain more comprehensive fused images and generate more information-rich fused images. Firstly, a dual-branch feature extraction module was introduced. By embedding gradient filters, strong features were better captured. Secondly, an adaptive feature fusion module is introduced to gradually select the dominant features from multimodal images through learning to achieve complementary fusion. Finally, a saliency weighted loss function was designed. By allocating higher weights in the semantic salient regions, it guides feature extraction and fusion to focus more on the salient regions, while also retaining rich information in the non-salient regions. The experimental results show that the proposed method has more natural visual effects, and compared with the latest fusion method CDDFuse, it improves the metrics of mutual information, average gradient, spatial frequency,

visual information fidelity, and standard deviation by 31.74%, 19.95%, 30.14%, 5.45%, and 3.09%, respectively.

(2) A hierarchical end-to-end Fusion method M3Fusion for three-band infrared images is proposed, aiming to improve the overall fusion quality of long-wave, medium-wave and short-wave infrared images. Most of the existing methods focus on local feature extraction, and there are limitations in the differentiated utilization of target features in different bands. M3Fusion extracts complementary features of long-wave, medium-wave and short-wave infrared through two cross-modal cross-fusion modules, thereby generating enhanced fusion images with more details and more complete information. Meanwhile, the significance weighted loss function is referenced to optimize the fusion quality. Compared with the latest fusion method PIAFusion, the proposed algorithm improves the signal-to-noise ratio, correlation coefficient, and visual information fidelity by 21.90%, 23.25%, and 28.70%, respectively.

Key words: deep learning; image fusion; end-to-end fusion network; multimodal images

目 录

第一章 绪论.....	1
1.1 研究背景及意义.....	1
1.2 国内外研究现状.....	2
1.2.1 传统图像融合方法.....	2
1.2.2 基于深度学习的图像融合方法.....	5
1.3 本文的主要研究内容.....	8
1.4 本文的组织结构.....	9
第二章 多模态图像融合的深度学习统一框架	11
2.1 多模态图像融合理论.....	11
2.2 图像融合指标.....	13
2.3 神经网络结构.....	16
2.3.1 卷积神经网络基本概念.....	16
2.3.2 残差网络	19
2.3.3 密集连接网络.....	20
2.3.4 注意力机制.....	21
2.4 监督学习与无监督学习.....	22
2.4.1 监督学习	22
2.4.2 无监督学习	22
2.5 本章小结.....	23
第三章 显著性引导的红外与可见偏振图像融合方法	24
3.1 引言.....	24
3.2 显著性引导的红外与可见光偏振图像融合方法	25
3.2.1 图像融合的一般架构.....	25
3.2.2 整体网络框架.....	27
3.2.3 主要组成模块.....	28
3.3 实验配置.....	31
3.3.1 数据集.....	31
3.3.2 网络训练细节.....	32
3.4 实验结果与分析.....	32
3.4.1 对比实验与定量分析.....	32
3.4.2 消融实验.....	34
3.4.3 视觉质量比较与分析.....	37
3.5 本章小结.....	39
第四章 基于分层处理的三波段红外图像融合方法	40

4.1 引言.....	40
4.2 基于分层处理的三波段红外图像融合方法	42
4.2.1 整体网络结构.....	42
4.2.2 主要组成模块.....	43
4.3 实验配置.....	45
4.3.1 数据集.....	45
4.3.2 网络训练细节.....	46
4.4 实验结果及分析.....	47
4.4.1 对比实验与定量分析.....	47
4.4.2 消融实验.....	48
4.4.3 视觉质量比较与分析.....	49
4.5 本章小结.....	50
第五章 结论与展望	51
5.1 结论.....	51
5.2 展望.....	52
参考文献.....	53

第一章 绪论

1.1 研究背景及意义

图像融合是将同一场景由相同或不同传感器拍摄的多张图像合成为一张高质量图像的过程，广泛应用于目标跟踪、检测、监视和伪装识别等领域^[1-5]。如图 1-1 所示，多模态图像融合通过整合不同传感器获取的互补图像信息（可见光图像、红外图像、偏振图像等），利用传统或深度学习手段提取图像的多维信息并实现特征级或者像素级融合，核心在于突破单一模态图像在光照变化、遮挡、分辨率等条件的局限性，提升目标跟踪等领域的检测识别效果。在多模态图像融合领域，红外图像与其他波段图像融合当前是最受关注的技术方向。由于成像原理不同，不同光学模态的图像数据所包含的信息往往具有互补性，能够在处理后实现更丰富的场景感知与特征表达。红外成像技术在低光、浓雾和雨天等挑战性条件下也能有效突出目标物体，弥补可见光成像的局限。然而，红外成像系统天然存在分辨率和信噪比低等不足。由于可见光以及偏振成像系统能够通过各种维度（如光强度、旋转方向、线性偏振光、椭圆偏振光、反射和空间特性）收集丰富的目标表面信息，从而有利于减少背景干扰，获取物体的形状、表面粗糙度和曲率等特征，使目标检测和识别更加容易。然而，可见光偏振成像技术对低光条件和拍摄角度敏感，可能导致目标信息的丢失。目前多数图像融合方法基于单一波段的红外图像进行处理，但单一红外图像通常仅能反映物体某一类热辐射特性，难以同时获取纹理、边缘和材料等多层次信息，从而限制了融合图像在目标细节表达方面的表现力^[6-11]。由于不同波段的红外图像各具优劣，例如短波红外波段具备较强的穿透雾霾与烟尘能力，纹理清晰，适用于弱光与夜视场景，但对热辐射不敏感，难以有效检测热目标；中波红外波段具有较高的热对比度和成像清晰度，适合中远距离目标识别，但易受到强背景干扰影响；长波红外波段则具有良好的被动成像能力，可实现全天候目标探测，尤其适用于人体、车辆等热源识别，不过图像分辨率较低，细节表达能力相对较弱。因此，无论是融合红外多波段图像，或将红外与其他不同模态的图像进行融合，对于增强复杂环境下的目标检测和识别的鲁棒性都具有重要研究意义。

近年来，传感器技术的持续进步和神经网络算法的迅速发展，使得基于深度学习的多模态图像融合方法逐渐成为学术界研究的热点。然而，现有的图像融合模型在实际应用中仍面临诸多挑战。首先，现有方法在结构设计方面普遍缺乏针对性。由于不

同模态图像的成像机制存在本质差异，导致其所包含的视觉信息侧重点不同。例如，可见光图像更注重呈现清晰的纹理细节，而红外图像则更强调热源显著性信息。针对这类异质特征，应采用差异化提取策略。现有方法仍采用固定的特征提取方式，容易导致融合图像出现细节缺失、伪影干扰等问题。其次，在融合策略方面，利用通道拼接、加权融合或注意力机制等传统方法，通常无法充分处理多尺度特征之间的差异性，使得融合结果在细节表现上不足，从而导致图像整体对比度偏低，影响视觉效果与后续任务性能。在此背景下，研究人员正积极探索新的特征提取机制、创新融合策略与深度网络结构，通过提升图像融合质量为视觉领域的实际应用提供可靠的技术支撑。




图 1-1 不同光学模态图像和融合对比。(a) 可见光图像、红外光图像、融合图像；(b) 可见光图像、线偏振度图像、融合图像

Figure 1-1 Comparison of images of different optical modalities. (a) Visible image, infrared image, and fused image; (b) Visible image, degree of linear polarization (DoLP) image, and fused image.

1.2 国内外研究现状

图像融合方法主要分为传统图像融合方法和基于深度学习的图像融合方法两类，本节将从这两个方面分别概述融合技术的国内外研究现状。

1.2.1 传统图像融合方法

传统图像融合方法主要通过稀疏表示法、变换域和空间域处理等手段^[11-15]，对源图像进行特征提取，以生成既保留关键细节又具备增强特性的融合图像。这些方法可以进一步划分为稀疏表示法、变换域分析法和空间域处理法等类别。每种方法均基于其独特的理论基础，并适用于特定的应用场景，共同构成了传统图像融合技术的重要体系。

(1) 稀疏表示理论为多源图像融合提供了有效的理论框架。首先，构建稀疏字典

以实现源图像的稀疏化表示^[11-12]。在融合处理阶段,针对各源图像对应的稀疏系数,通过选择能量占优的系数作为融合后系数,最终完成融合图像的重构。尽管该方法的计算复杂度较高,但其在保留图像细节特征与结构信息方面具有显著优势,从而能够保证融合结果的高质量。稀疏性原理的核心在于利用信号在特定变换域中的稀疏特性,即能量集中于少数非零系数,实现多源图像信息的有效提取与融合。具体来说,源图像首先通过构建适配性强的稀疏表示字典,使其在特定变换域内可表达为一组稀疏基的线性组合。基于稀疏表示理论,可进一步制定融合方案,例如采用最大系数选择原则或加权系数平均法,对来自多个图像的稀疏系数进行有针对性的整合。随后,借助稀疏重建技术,将融合后的稀疏表示重新映射回原始图像域,从而获得包含源图像关键信息的融合结果图像。该方法的优点包括:能够保持原始图像信息的完整性;克服了传统小波变换在信号结构表达上的局限性;能够突破多尺度分解中正交基对稀疏度的限制。尽管该方法的计算成本较高,但在医学影像分析等任务中的成功应用,仍体现了其显著的有效性。

(2) 多尺度变换域融合技术通过将源图像映射至多分辨率频率空间,实现对低频背景与高频细节信息的差异化处理。以小波分析方法为代表,该类技术通常首先对输入图像执行多层次的分解操作,进而提取在不同空间尺度和频率范围内的特征分量,以便开展后续的融合处理与信息分析;随后,依据能量分布、边缘显著性等各频域分量的特性设计加权平均、系数最大值选择或区域特征匹配等针对性融合策略;最终,通过逆变换操作将融合后的多尺度系数逐级重构至空间域,从高频细节到低频结构逐层恢复图像信息,生成兼具完整空间结构和丰富细节特征的融合图像。该类方法的本质在于通过变换操作将图像由原始的空间域映射至特定的变换域(如小波域、频域等),以便在该域中对不同频率成分进行分离与分析。随后,结合图像特征分布特点,应用具有适应性的融合策略,从而有效保留原始图像中包含的重要结构与信息内容。其优势包括:通过多尺度分解有效分离图像的不同特征尺度;允许针对各频率分量设计灵活融合策略;在重建阶段,图像的各个尺度信息可通过逐级还原方式进行融合优化,从而提升整体信息整合的质量与完整性。常见的典型变换域方法主要包括多分辨率金字塔分解^[13]、小波变换^[14]技术以及 Contourlet^[15]方向多尺度变换等,它们在不同应用场景中展现出良好的特征提取与融合能力。图像融合过程如图 1-2 所示。




图 1-2 基于变换域的图像融合方法

Figure 1-2 Image fusion method based on transform domain

(3) 空间域的图像融合技术^[17,18]主要侧重于在像素层级进行处理，通常通过代数计算、区域分析或多尺度分解等方式对图像数据进行操作，从而实现信息的有机整合。此类方法的基本机制在于直接作用于图像的像素值，通过精细的数值计算完成不同模态图像之间的信息融合与统一。目前较为典型的融合策略包括：加权平均融合，通过权重系数对相应像素进行线性叠加，操作简单且迅速，但容易导致边缘模糊；自适应权重融合，该方法基于梯度、显著性或区域分割动态分配权重，如在边缘区域降低权重以保留细节；金字塔融合方法通过拉普拉斯或高斯金字塔将图像分解为多尺度细节层，在各层按既定规则融合后重构，有效保留高频信息。此类方法直接作用于像素，计算过程直观，适用于多聚焦图像、医学图像、遥感影像等场景。其优点在于实现过程简单、可实时处理，但缺点是当依赖人工参数如固定权重时，容易丢失细节，且在复杂场景下需要结合梯度、分割等策略进行优化，或采用多尺度方法以提升融合质量；色空间变换融合技术则是通过将源图像从原始色彩空间如RGB映射至具有亮度和色度解耦特性的目标色空间如YCbCr、IHS^[19,20]等，实现光谱信息与空间细节的分层处理。具体流程包括：首先对多光谱图像进行色空间分解，分离出表征亮度信息的低频分量如Y或I分量与表征色彩信息的高频分量如CbCr或HS分量；接着，将高分辨率全色图像的的细节信息注入至亮度分量中，并采用加权平均、区域匹配等策略融合色度分量；最终通过逆变换重构至原始色彩空间，得到兼具光谱丰富性和空间清晰度的融合图像。

1.2.2 基于深度学习的图像融合方法

利用深度学习技术进行图像融合能够实现对多源图像的端到端特征提取与融合策略学习。这些图像源可能包括不同传感器（如红外与可见光相机）、不同成像技术（例如医学 CT 与 PET、遥感多光谱与全色图像）或不同视角（如多摄像头监控画面、无人机多方位航拍），通过深度学习模型能够有效地整合图像中的互补纹理和边缘等低层像素细节，物体轮廓和区域分布等中层结构特征，目标类别和场景语义等高层语义信息。最终生成的图像不仅保留了各输入图像的优势信息，如红外图像的热源定位能力和可见光图像的纹理细节，同时能够消除冗余数据，显著提升对比度、分辨率和色彩真实性等视觉效果。基于所采用的深度学习架构，这一图像融合方法主要可分为基于自编码器（Autoencoder, AE）、卷积神经网络（Convolutional Neural Network, CNN）、生成对抗网络（Generative Adversarial Network, GAN）、Transformer 的几大类方法。具体如下：

（1）自编码器类方法通常包括网络预训练以及特征提取与重构两个阶段。网络预训练的作用是使模型具备稳定的特征学习能力，特征提取与重构的目的是提取输入图像特征，并依据特定的融合准则对中间特征进行整合。该类方法的典型架构如图 1-3(a) 所示，具体而言，基于 AE 的图像融合模型主要由编码器、解码器及融合层构成，其中特征提取与重构过程相互独立。典型代表如 DenseFuse^[67]、IFCNN^[75]等方法，普遍采用自编码器结构完成关键特征的编码与解码，同时引入结构优化的融合模块，在视觉质量与融合效率方面表现优异，在多个评价指标上显著超越传统图像融合算法。Li 等^[67]首次将 AE 框架应用于图像融合领域，相较于传统图像融合方法，以浅层网络替代手工特征设计，显示明显优势。此外，为进一步增强特征提取能力，Li 等^[24]提出了一种基于巢状连接的架构。Wang 等^[25]在编码器中引入了非局部注意力机制，以捕获通道注意力和空间维度信息，生成更高质量的融合图像。Wang 等^[26]提出了一种改进的图像融合框架，基于双向 UNet，结合交叉卷积块以增强多尺度和全局特征的提取能力。此外，Li 等^[27]提出了一个名为 MAFusion 的多尺度注意力网络，该网络充分利用不同尺度的特征以减少融合图像中的伪影和不一致性。尽管基于 AE 的融合方法在融合指标上表现良好，但它们严重依赖于大型数据集和人工融合规则，需要投入大量的时间投入且泛化能力有限。

（2）在图像融合任务中，卷积神经网络（CNN）通常通过两种主要策略加以应用。

其一是设计具备特定功能的网络架构，并配合精心设置的损失函数，实现融合流程中的端到端学习，包括原始图像的特征提取、信息融合以及融合图像的重构等关键步骤。图 1-3(b)直观地展示了该类方法的基本工作机制。Zhang 等^[76]借鉴了 DenseNet 的理念，引入了一种名为 PMGL 的快速统一图像融合网络，该网络具备梯度和强度特征提取路径。为了进一步提升特征提取的能力，Wang 等^[30]还提出了一种多级双支注意力网络，用于有效提取特征，从而引导模型生成具备高视觉质量的融合图像。Wang 等^[34]提出基于特征筛选来强调显著性相关语义特征的显著性目标检测方法。同时，Liu 等^[35]提出了 SGFusion，该方法使用显著性检测解码模块生成显著性图，并将其纳入重建损失用于图像融合。Tang 等^[36]提出了 PSFusion，该方法逐步将综合显著性图集成到融合网络中，以确保融合结果具有丰富的语义信息。Zhou 等^[37]采用分级特征多标签学习网络进行 RGB-热红外城市场景语义分割，语义图被用作模型训练期间的监督。同时，Wu 等^[33]提出了一种边缘感知引导融合方法，以提供多模态语义感知的充分监督。Tang 等^[77]提出了 STDfusion，该方法使用手动标注的显著性目标掩码计算损失函数中的损失，从而指导图像融合。

(3) 鉴于生成对抗网络具备能够生成高质量图像并能模拟复杂数据分布，且无需依赖真实标签，因此 GAN 被自然地引入图像融合领域，其典型架构如图 1-3(c)所展示。Ma 等^[70]将 GAN 应用于低分辨率红外图像与高分辨率可见光图像的融合任务，通过协调生成器与判别器之间的对抗平衡，并联合优化对抗损失与内容损失，有效地保留了红外图像中的热辐射目标信息以及可见光图像中的精细纹理信息。Fu 等^[73]采用密集连接块进行特征提取，并在中间层融合可见光图像特征。除了对抗损失外，该方法还增强了融合图像的纹理细节，确保了其与人类视觉感知的一致性。然而，传统 GAN 方法中的判别器可能会导致生成图像偏向于某一模态的数据分布。在可见光与红外光图像融合的背景下，使用单一判别器处理单个光谱图像易造成另一源图像的有效信息丢失。为解决这一问题，Ma 等^[71]设计了双判别器，分别针对可见和红外图像的不同特性进行判别，以确保融合图像尽可能多地保留异源信息。尽管基于 GAN 的网络融合方法表现出色，但其生成的融合图像易引入噪声，导致融合图像的清晰度降低和纹理细节丢失。




图 1-3 不同的图像融合网络架构 (a) 基于 AE 的架构^[24,25]; (b) 端到端的 CNN 架构^[29,30]; (c) 基于 GAN 的架构^[70,71] (d) 基于 Transformer 的架构^[40,41]

Figure 1-3 Different architectures for image fusion (a) AE-based architecture^[24,25]; (b) CNN-based architecture^[29,30]; (c) GAN-based architecture^[70,71]; (d) Transformer-based architecture^[40,41]

(4) 基于 Transformer 的图像融合架构，通过自注意力机制获取源图像的全局特征，再通过融合规则（如人工加权融合）进行动态权重分配，最后通过解码器重构出融合图像，如图 1-3(d)所示。Li 等^[40]提出了一种基于 Transformer 的网络 TIPFNet，利用自注意力机制来捕捉全局上下文信息，用于红外和偏振图像融合。Ma 等^[41]提出了 SwinFusion，结合了长距离依赖建模和跨域融合机制，以捕获全局特征和上下文信息以促进不同模态间的融合。Tang 等^[42]提出了 YDTR，该方法引入动态 Transformer 模块来有效捕捉源图像中的局部特征和丰富的上下文信息。另一方面，Wang 等^[68]开始利用 Swin Transformer 进一步增强多模态图像的特征提取，从而提升融合图像的质量。Li 等^[28]提出了一种新颖的混合融合网络，该网络结合了交叉注意机制和 Transformer 的自注意力机制以增强互补特征。上述若干图像融合方法在相关应用场景中已展现出一定的有效性，取得了较为理想的实验结果。然而，结合当前研究现状与实际应用需求，仍可发现其在融合方法的设计与性能表现方面存在一定局限性和待改进之处。

尽管上述方法在图像融合任务中已取得显著成效，但综合来看，仍存在有待改进的问题：

(1) 在融合方法的设计方面，当前的研究尚存在若干不足之处。首先，现有方法在结构设计上缺乏针对性。例如，可见光图像与红外图像这类不同模态图像，各自侧重不同的信息类型，这是由于其光学波段和光学成像设备的差异。前者强调纹理细节，后者突出显著性信息。因此，针对不同层次和模态的特征，应采用差异化的提取策略。

然而，目前主流的图像融合方法在特征提取阶段普遍采用统一的提取策略，缺乏对不同模态之间本质差异的深入建模。这种处理方式容易导致融合图像在细节重构方面表现不佳，甚至可能出现仅保留单一模态信息或生成伪影等视觉干扰问题。此外，在融合策略的设计方面，现有方法多依赖通道拼接、特征相加或注意力机制等通用手段，但此类策略在处理多尺度特征结构和语义层级方面的适应性有限，难以有效协调不同层次信息之间的互补性，从而制约了整体融合质量的进一步提升。

(2) 在选择结构时，基于 Autoencoder 的融合技术虽然在融合指标上表现出色，但高度依赖数据集规模和人工设计的融合规则，不仅需要大量时间投入，而且其泛化能力也受到一定限制。GAN 网络虽然能提升融合效果，但是其固有的训练不稳定性和噪声引入问题会影响融合图像的质量。融合手工特征的基于 CNN 的融合方法在多模态图像融合任务中性能良好，并且无需依赖额外的信息源，但是由于需要人工设计特征提取或融合模块，导致存在主观设计偏差。而用端到端的 CNN 架构通过优化网络结构和损失函数，在保证性能的同时显著降低了模型复杂度，是更为可靠的解决方案。此外，基于 transformer 的方法虽能捕获长程依赖，但其数据需求量较大，在小数据集上存在过拟合风险。

综上，本文从无监督深度学习角度出发，在端到端的 CNN 基础上重点研究红外光图像和可见光偏振图像融合方法，以及三波段红外图像融合方法：(1) 针对红外图像与可见光偏振图像融合需求，本文构建出一种显著性语义引导的复杂背景下红外与可见光偏振图像渐进式融合网络。该网络通过显著性语义引导的损失函数对输入图像在整体训练过程中施加约束，并利用嵌入了滤波算子的自适应融合模块，实现多模态特征的高效提取与整合，最终生成高质量的融合图像；(2) 面向含有长波、中波和短波红外信息的军事目标图像融合，本文构建出基于分层次处理的多波段红外三模态图像融合方法，重点优化了跨模态交叉融合模块与跨尺度特征融合模块的设计逻辑，以提升不同长波、中波和短波红外特征在融合过程中的互补效果和优势信息保持能力。两种融合方案均基于无监督、端到端的深度神经网络架构，具备无需人工标注即可实现稳定训练的能力，同时，在多场景、多模态环境下表现出良好的泛化与适应性能，确保了模型在无标注条件下的稳定训练与广泛适应性。

1.3 本文的主要研究内容

本文针对复杂环境下的目标识别能力受限的问题，结合可见偏振和红外两种图像，

以及不同波段的三模态红外（远红外，中红外，近红外）图像，开展基于深度学习的多模态图像融合方法研究，提出了两种不同的图像融合算法，所完成的主要工作如下：

（1）提出了一种基于显著性语义引导的红外与可见偏振图像融合模型 SGFusionNet，旨在融合中波红外图像与可见偏振图像，实现复杂环境下目标的高效识别。SGFusionNet 采用端到端双分支渐进式融合网络结构，引入语义显著图作为引导损失，有效增强了网络对目标关键区域的关注能力，并提升了融合图像的语义表达与目标辨识性能。为验证所提方法的有效性，构建了一个包含复杂背景的多模态军事图像数据集，覆盖中波红外与可见偏振图像，为模型训练与评估提供了高质量的实验基础。

（2）提出了基于分层处理的三波段红外图像融合模型 M3Fusion，用于远红外，中红外，近红外三种图像的高效融合。在特征提取阶段，设计了简单且高效的特征提取模块，用于初步提取多层次的红外图像特征。为实现融合图像的高质量重建，解码器结构采用跨层连接机制，将编码器提取的不同尺度特征通过跳跃连接方式逐层恢复出融合图像，以保留更多的结构与纹理信息。该融合框架使用全卷积模块完成特征提取、融合与图像重建过程，摒弃冗余设计，具备模型轻量、部署灵活等优势，有效提高了图像融合效率与应用可拓展性。

1.4 本文的组织结构

本文共包含五个章节，章节安排如图 1-4 所示，具体结构安排如下：

第一章：绪论。主要阐明本研究的背景与意义，系统梳理当前多模态图像融合技术的发展历程与研究现状，深入分析现有方法在实际应用中存在的关键问题，并据此明确本研究所要解决的核心问题，提出研究目标与主要内容，最后给出全文的结构安排。

第二章：深度学习及图像融合基础。对本研究中所涉及的深度学习基础知识进行系统介绍，包括神经网络结构、密集连接机制、残差学习等关键模块。同时，阐释监督学习与无监督学习在深度融合任务中的应用原理，为后续章节中融合模型的设计提供理论支撑。

第三章：基于显著性引导的红外与可见光偏振图像融合方法。提出一种适用于复杂场景的红外与可见光偏振图像渐进融合网络，详细描述网络整体架构设计、各功能模块的实现细节，并设计融合过程中的显著性引导约束的损失函数以优化训练效果，通过丰富的定性和定量实验，验证所提出方法在提升融合图像质量方面的有效性与鲁

棒性。

第四章：基于分层处理的三波段红外图像融合方法。充分分析不同波段图像在目标显著性、背景纹理及成像特性上的差异，构建适配性强的网络架构与融合模块，以兼顾远红外与中红外中目标的强度信息以及近红外图像所提供的丰富背景细节，通过一系列定性定量对比实验，验证方法的融合性能。

第五章：结论与展望。总结全文的研究内容与创新点，回顾本研究在复杂环境下多模态图像融合方面所取得的成果，并基于当前研究的不足与发展趋势，对未来在该领域的进一步研究方向进行展望。




图 1-4 学位论文章节安排

Figure 1-4 The overview of thesis

第二章 多模态图像融合的深度学习统一框架

本章主要对多模态图像融合理论、融合指标和基于深度学习的多模态图像融合方法框架与关键技术进行系统梳理，重点分析卷积神经网络及其常见模块的结构特性与功能机制。同时，比较有监督学习与无监督学习的区别，为后续模型设计与算法实现奠定基础。

2.1 多模态图像融合理论

多模态图像融合旨在将来自不同传感器或模态的图像数据在信息层面进行有效整合，生成一幅在空间分辨率、语义完整性及目标可识别性等方面更具优势的图像。图像融合的目标是最大限度地保留源图像 I 中的有用信息，并在融合结果 F 中实现信息冗余最小化与信息互补最大化。信息熵（Entropy）作为信息论中的重要概念，常被用于量化图像的信息含量，其定义如下：

$$H(S) = -\sum_{i=1}^n p(\xi_i) \log p(\xi_i) \quad (2.1)$$

式中， S 表示图像的像素集合， $p(\xi_i)$ 是 S 取值为 ξ_i 的概率。在多模态图像融合中，理想的融合图像 F 应同时满足如下目标：

$$H(F) \geq \max(H(I_1), H(I_2)) \quad (2.2)$$

即理想的融合图像 F 应尽可能使其信息熵不低于所有源图像的信息熵，以实现有效的信息增益。

从信号处理角度看，多模态图像融合可被建模为一种信号分解与重构的问题。在此设想下，不同模态的图像（如红外、可见、偏振图像等）本质上可以看作是在不同物理传感机制下对同一场景的观测，其包含的特征信息在空间、频率及语义层面具有一定的互补性。因此，融合过程的核心目标就是在保持信息完整性的前提下，合理分离、提取并重建这些互补信号，以生成一幅结构更清晰、语义更丰富的图像。假设有两幅不同模态的图像分别为 I_1 和 I_2 ，则其融合可被表示为：

$$F=R(S_1(I_1),S_2(I_2)) \quad (2.3)$$

式中, $S_1(\cdot)$ 和 $S_2(\cdot)$ 分别表示从两个模态图像中提取特征的映射函数(例如卷积编码器), $R(\cdot)$ 表示特征融合与重构函数(如解码器或上采样模块)。

近年来, 神经网络(尤其是端到端架构)在图像融合任务中取得了显著成效。其理论依据来源于以下几点:

(1) 表示学习能力的提升: 神经网络具备强大的层级特征学习能力, 通过多层非线性变换, 能够自动从原始图像中提取由低到高的多尺度特征, 如边缘、纹理、结构乃至语义区域等^[1-4]。这使得网络在融合过程中不仅可以提取模态共享信息(如边缘轮廓等), 也能保留模态特有特征(如红外图像的热强度、可见光图像的色彩与纹理)。通过对深层语义的抽象表达, 模型能够实现异构模态之间的语义对齐与信息压缩重构, 为高质量图像融合奠定基础。

(2) 网络结构优化: 为了有效缓解深层网络中可能出现的梯度消失与训练瓶颈问题, DenseNet^[52]被引入, 通过恒等映射的方式简化特征学习路径, 显著提升了深层网络的可训练性与稳定性。同时, 注意力机制的引入进一步增强了网络对关键区域与重要特征的响应能力。通过空间与通道维度上的加权处理, 实现对显著性区域的精确感知, 使模型能够在融合过程中突出任务相关区域、抑制冗余或无效信息, 从而提升融合图像的辨识度与结构完整性。

(3) 多目标损失函数驱动优化策略: 图像融合不仅需保证信息完整性, 还应兼顾结构保持、细节锐度与视觉美感。为此, 深度融合网络通常设计多目标联合损失函数 L_{fusion} , 常采用多目标损失函数以约束信息保留、结构保持与视觉质量, 形式如下:

$$L_{fusion}=\beta_1L_{grad}+\beta_2L_{int}+\beta_3L_{SSIM} \quad (2.4)$$

式中, L_{grad} 为梯度损失(Gradient Loss), L_{int} 为强度损失(Intensity Loss), L_{SSIM} 为结构相似性损失(Structural Similarity Loss), β 为加权系数。

梯度损失 L_{grad} 的作用是使融合图像具有更多的纹理细节。为了引导融合图像在纹理细节上与源图像保持一致, 梯度损失 L_{grad} 项中引入了自适应判决模块, 其表达形式如下:

$$L_{grad} = \frac{1}{HW} \sum_i \sum_j S_{i,j} \times (\Delta_{fused_{i,j}} - \Delta_{I_{1,j}})^2 + S_{2,i,j} \times (\Delta_{fused_{i,j}} - \Delta_{I_{2,i,j}})^2 + S_{3,i,j} \times (\Delta_{fused_{i,j}} - \Delta_{I_{3,i,j}})^2 \quad (2.5)$$

式中, i 和 j 分别表示图像中第 i 行、第 j 列的像素位置, H 和 W 表示图像的高度与宽度, I_1 、 I_2 和 I_3 分别表示三个输入不同的图像, 如红外图像、可见光图像与偏振图像。 $\Delta(\cdot)$ 表示拉普拉斯算子, $S(\cdot)$ 是根据源图像的梯度水平由判决模块生成的判决图。

强度损失 L_{int} (Intensity Loss) 用于引导融合图像保留像素强度表示中的有用信息, 例如图像对比度。同时, 它还能使融合图像在视觉上更加自然。强度损失 L_{int} 的表达式如下:

$$L_{int} = \frac{1}{HW} \sum_i \sum_j (I_{fused_{i,j}} - I_{1,i,j})^2 + (I_{fused_{i,j}} - I_{2,i,j})^2 + (I_{fused_{i,j}} - I_{3,i,j})^2 \quad (2.6)$$

在图像融合中引入结构相似性损失 L_{SSIM} (Structural Similarity Index Loss), 可以增强融合图像 F 与源图像 I 在亮度、对比度和结构等方面的相关性, 从而使融合图像 F 在整体感知上更加接近源图像 I 。结构相似性损失 L_{ssim} 的表达式如下:

$$ssim_{I,F} = \sum_{x,f} \frac{2u_i u_f + C_1}{u_i^2 + u_f^2 + C_1} \cdot \frac{2\sigma_i \sigma_f + C_2}{\sigma_i^2 + \sigma_f^2 + C_2} \cdot \frac{\sigma_{if} + C_3}{\sigma_i \sigma_f + C_3} \quad (2.7)$$

$$L_{ssim} = \frac{1}{HW} \sum_i \sum_j (1 - ssim(I_{fused}, I_1)) + (1 - ssim(I_{fused}, I_2)) + (1 - ssim(I_{fused}, I_3)) \quad (2.8)$$

式中 i 和 f 分别表示源图像和融合图像在一个滑动窗口内的图像块, u_i 和 u_f 分别是源图像块和融合图像块的均值, 而 σ_i 和 σ_f 则为它们的标准差, σ_{if} 代表源图像与融合图像之间的协方差, 常数 C 的作用是维持计算公式的稳定性, 防止分母出现零值。

2.2 图像融合指标

为了便于后续定量评估的展开, 本节将介绍各种用于定量评估图像融合算法性能的指标。

平均梯度（Average Gradient, AG）是一种敏感度较高的图像质量评估指标，能够有效反映图像在细节对比度和纹理变化等方面的表现^[79]。数学定义如下：

$$AG = \frac{1}{(M-1)(N-1)} \times \sum_{i=2}^{M-1} \sum_{j=2}^{N-1} \sqrt{\frac{(H(i+1, j) - H(i-1, j))^2 + (H(i, j+1) - H(i, j-1))^2}{2}} \quad (2.9)$$

式中， $H(i, j)$ 代表图像在第*i*行、第*j*列的像素值，*M*和*N*分别代表图像的总行数 和总列数。

相关系数（Correlation Coefficient, CC）是一项用于客观评估融合图像与理想参考图像之间相关性的指标^[99]，计算公式如下：

$$CC = \frac{\sum_{i=1}^M \sum_{j=1}^N (I(i, j) - \alpha)(F(i, j) - \beta)}{\sqrt{\sum_{i=1}^M \sum_{j=1}^N (I(i, j) - \alpha)^2 \sum_{i=1}^M \sum_{j=1}^N (F(i, j) - \beta)^2}} \quad (2.10)$$

式中，*I*和 α 分别表示源图像和源图像的均值，*F*和 β 分别表示融合图像和融合图像的均值， $F(i, j)$ 代表融合图像在第*i*行、第*j*列的像素值。

空间频率（Spatial Frequency, SF）衡量图像在空间域内的整体活动程度，即灰度值变化的速度^[80]。数学定义如下：

$$SF = \sqrt{RF^2 + CF^2} \quad (2.11)$$

$$RF = \sqrt{\frac{1}{MN} \sum_{i=1}^M \sum_{j=2}^N |H(i, j) - H(i, j-1)|^2} \quad (2.12)$$

$$CF = \sqrt{\frac{1}{MN} \sum_{i=2}^M \sum_{j=1}^N |H(i, j) - H(i-1, j)|^2} \quad (2.13)$$

式中，RF表示行频率，CF表示列频率，*M*和*N*分别代表图像的总行数和总列数。

视觉保真度（Visual Information Fidelity, VIF）基于自然场 $SF = \sqrt{RF^2 + CF^2}$ 景统计与人类视觉系统建模，量化融合图像与源图像之间共享信息的程度。VIF值越高，表示融合结果越接近人类视觉感知^[81]。其定义为：

$$VIF = \frac{\sum_{i \in \text{subbands}} H(C_{s,i}, F_{s,i} | R_{s,i})}{\sum_{i \in \text{subbands}} H(C_{s,i}, I_{s,i} | R_{s,i})} \quad (2.14)$$

式中, 条件信息熵项 $H(C_{S,i}, F_{S,i} | R_{S,i})$ 和 $H(C_{S,i}, I_{S,i} | R_{S,i})$ 分别衡量了从融合图像 F 和源图像 I 的特定子带中能够获取的视觉信息量。 C_i 是来自源图像中第 i 个子带的随机场, 而 $C_{S,i}$ 随机场中的 S 个元素。当人类视觉系统模型分别以源图像 I 和融合图像 F 的第 i 个子带作为输入时, 其产生的输出信号元素相应地记为 $I_{S,i}$ 和 $F_{S,i}$ 。 $R_{S,i}$ 则是与第 i 个子带相关联的模型参数。

互信息 (Mutual Information, MI): MI 指标基于信息论度量从源图像转移到融合图像的信息量^[78], 其定义如下:

$$MI = MI_{A,F} + MI_{B,F} \quad (2.15)$$

$$MI_{X,F} = \sum_{x,f} P_{X,F}(x,f) \log \frac{P_{X,F}(x,f)}{P_X(x)P_F(f)} \quad (2.16)$$

式中, $MI_{A,F}$ 和 $MI_{B,F}$ 分别表示从源图像 A 和源图像 B 中转移到融合图像 F 的信息。 $P_X(x)$ 和 $P_F(x,f)$ 表示源图像与融合图像的联合直方图。

融合互信息 (Fusion Mutual Information, FMI): 是在 MI 的基础上发展而来, 专门用于度量融合图像同时保留了两幅源图像中的多少信息。FMI 值越高, 说明融合图像对原始图像特征的保留效果越好, 是衡量融合质量的重要参考指标^[104]。表达式如下:

$$FMI = MI_{A',F'} + MI_{B',F'} \quad (2.17)$$

式中, A' , B' , F' 表示源图像 A , B 和融合图像 F 的特征图。越高的 FMI 意味着更多的特征被转移到了融合图像中。

标准差 (Standard Deviation, SD): SD 能够反映融合图像的对比度以及分布^[79], 其具体定义如下:

$$SD = \sqrt{\sum_{i=1}^M \sum_{j=1}^N (F(i,j) - \alpha)^2} \quad (2.18)$$

式中, α 表示融合图像的均值。人类视觉系统通常更容易被高对比度区域吸引, 因此标准差较高的融合结果往往具有更优的图像对比度表现。

峰值信噪比 (Peak Signal-to-Noise Ratio, PSNR): PSNR 表示融合图像中峰值功率与噪声功率的比值^[98], 它能够从像素层面反映融合过程中的失真情况, 定义如下:

$$\text{PSNR}=10\log_{10}\frac{L^2}{\text{MSE}} \quad (2.19)$$

$$\text{MSE}=\frac{\text{MSE}_{A,F}+\text{MSE}_{B,F}}{2} \quad (2.20)$$

$$\text{MSE}_{I,F}=\frac{1}{MN}\sum_{i=0}^{M-1}\sum_{j=0}^{N-1}(I(i,j)-F(i,k))^2 \quad (2.21)$$

式中, L 表示融合图像的像素值的最大可能动态范围, MSE 表示均方误差, MSE 直接衡量了两幅图像像素级别的平均差异程度。 MSE 值越小, 说明融合图像 F 与源图 I 越相似。 PSNR 值越高, 说明噪声功率相对于信号功率越小, 即融合质量越好。

2.3 神经网络结构

在深度学习技术不断演进的过程中, CNN 与 GAN 等代表性网络架构相继提出, 并在各类视觉任务中发挥了重要作用。这些网络通过结构设计上的独特优势, 有效满足了不同场景下的任务需求。具体而言, CNN 依托其平移不变性、稀疏连接以及参数共享等特性, 在图像配准、目标识别等领域展现出卓越的性能^[44,45]; 而 GAN 则凭借生成器与判别器之间的对抗机制, 在图像生成、风格迁移等任务中取得了显著成果^[46,47]。考虑到 CNN 在特征提取与表征学习方面的稳定性与高效性, 本文以 CNN 为核心构建多模态图像融合框架, 根据不同源图像的模态特性, 本文设计了具有差异化特征处理能力的特征提取与自适应融合模块, 旨在提升多源信息的整合程度, 并增强融合结果。

2.3.1 卷积神经网络基本概念

在深度学习算法体系中, CNN 作为前馈神经网络的重要分支, 以卷积为核心的构建, 已成为计算机视觉任务中的主流模型。CNN 具备三项关键特性: 在卷积核参数复用机制中, 通过全局共享策略能够显著降低网络计算复杂度; 对于输入特征, 空间不变性原则使网络具备获得在不同空间位置的鲁棒感知能力; 局部连接的设计, 能够有效控制网络参数规模, 同时保留局部空间结构信息。由于 AlexNet、ResNet 和 GoogLeNet 等经典网络架构的不断演进, CNN 在图像分类、目标检测、图像配准与图像去噪等任务中取得了显著突破^[49-52]。图 2-1 展示了一个标准 CNN 架构图, 通常由五类功能模块组成: 卷积层、池化层、批量归一化层、全连接层以及激活函数。

典型的 CNN 结构如图 2-1 所示, 其框架清晰地呈现了卷积层在图像特征提取过程中的核心功能与重要地位, 直观地展示了卷积层在图像特征提取中的关键作用。卷积

层是 CNN 中最核心的组成，其基本原理建立在卷积核与输入数据之间的滑动卷积运算之上。具体而言，卷积核以权重矩阵的形式对输入图像进行局部操作，通过逐元素乘积与累加操作提取局部特征，最终生成对应的输出特征图。卷积层通过采用局部连接机制与参数共享策略，在有效提取图像中局部空间特征的同时，提高了模型对位移扰动的鲁棒性，从而具备较强的平移不变性。如图 2-2 所示，在传统卷积算子的基础上，空洞卷积（Dilated Convolution，DC）作为一种扩展感受野的新型操作单元，通过在卷积核内设定一定间隔的空洞配置，实现在不显著增加计算量的前提下扩展感受范围。这种设计使模型能够有助于对多尺度特征的提取与语义信息的整合。在训练过程中，CNN 通过反向传播算法优化卷积核参数，以最小化损失函数为目标，逐步学习输入数据中的复杂模式与高阶语义特征。




图 2-1 卷积神经网络结构

Figure 2-1 Convolutional neural network structure




图 2-2 空洞卷积示意图

Figure 2-2 Schematic diagram of the dilated convolution

池化层（Pooling Layer，PL）是卷积神经网络中至关重要的空间降维组件，主要通过对局部区域数据的聚合操作，有效压缩特征图的空间维度，同时保留关键信息，从而实现特征表示的简化与抽象。常用的池化策略主要包括平均池化（Average Pooling，AP）和最大池化（Max Pooling，MP）。其中，平均池化通过计算局部区域内像素的平均值来生成输出，具有一定的平滑效果，有助于抑制噪声干扰并保持图像的整体趋

势特征；而最大池化则选取局部区域中的最大值作为输出，有效突出显著特征区域，增强模型对局部变化的鲁棒性和空间不变性。池化操作不仅可以显著减少特征图的尺寸，从而降低后续网络层的计算复杂度，还能在一定程度上缓解过拟合问题，提升模型对平移、旋转等几何变换的适应能力。因此，池化层通常紧随卷积层之后使用，在提取高级抽象特征的同时，实现有效的信息压缩与泛化能力提升。

在深度神经网络中，批量归一化（Batch Normalization, BN）被广泛视为提升模型训练稳定性与效率的重要技术之一。该方法通过对每个训练批次中的特征输入进行标准化处理，使其在特征维度上具有一致的均值与方差，从而有效缓解梯度消失与梯度爆炸等常见问题，加快模型收敛速度，并提升其泛化性能。BN 操作通常在激活函数之前执行，其主要步骤包括：计算当前批次特征的均值与标准差，对特征进行标准化处理，随后引入可学习的缩放与偏移参数，以确保网络仍具备足够的表达能力。该归一化策略显著提升了模型对不同输入数据分布的适应能力，现已成为多种深度学习模型中的标准模块。

全连接层（Fully Connected Layer, FCL）是神经网络中实现高阶特征建模的重要组成部分，其结构特点在于当前层中的每一个神经元均与前一层的所有神经元建立连接。通过线性变换与非线性激活函数的组合操作，全连接层能够有效整合前层输出的特征信息，并完成特征空间向输出空间的映射。该层通常部署于神经网络的尾部阶段，承担将上层抽象得到的深层语义特征转换为具体预测结果的任务，广泛应用于分类、回归等决策类任务中，作为最终输出的重要环节。

激活函数是神经网络实现非线性建模能力的核心模块。通过引入非线性变换，激活函数使神经网络能够逼近更复杂的函数关系。常见激活函数包括 ReLU、Tanh 以及 Sigmoid、Leaky ReLU 等。Sigmoid 函数将输入压缩至(0,1)区间，适用于二分类任务；Tanh 函数将输出归一化至(-1,1)，在对称性上优于 Sigmoid；而 ReLU（Rectified Linear Unit）因其在正区间的恒等性与负区间的零响应，有效缓解了梯度消失问题，成为当前深度神经网络中最常用的激活函数。Leaky ReLU 则在 ReLU 基础上对负区间赋予非零斜率，以进一步提升模型训练的稳定性。激活函数的合理选择对于提升网络的表达能力与训练效果具有关键意义。

2.3.2 残差网络

随着卷积神经网络的持续发展，如何合理地控制网络深度已成为影响模型性能的重要课题。相关研究表明，适当加深网络结构有助于增强模型的特征表达能力与语义理解能力，从而在图像识别等视觉任务中获得更优的性能表现。然而，网络深度的增加也伴随着一系列结构性难题，如参数数量膨胀引发的过拟合风险、前向与反向传播过程中出现的梯度消失或爆炸问题，以及由于空间信息逐层压缩而导致的特征丢失与性能退化等现象。为有效缓解上述深层网络中普遍存在的训练瓶颈，He 等提出了残差网络（Residual Network, ResNet）架构，核心创新在于引入了跳跃连接机制，使得网络在保持高深度的同时仍可实现稳定高效的训练。该方法的基本思想并非直接拟合输入与输出之间的映射关系，而是通过构建残差学习路径，使网络学习输入与期望输出之间的残差函数。通过恒等映射与非线性变换的结合，该机制有效减轻了梯度消散问题，显著提升了深层网络的训练稳定性与性能表现^[89]。




图 2-3 残差结构^[44] (a) 基础残差块；(b) 瓶颈残差块

Figure 2-3 Residual structure^[44] (a) basicblock; (b) bottleneck

如图 2-3(a)和(b)所示, ResNet 的残差块分为两种类型: 浅层网络(如 ResNet-18/34)使用由 2 个 3×3 卷积层构成的基础残差块(basicblock), 深层网络(如 ResNet-50/101/152)使用由 3 个卷积层($1 \times 1 \rightarrow 3 \times 3 \rightarrow 1 \times 1$)构成的瓶颈残差块(bottleneck), 均通过跳跃连接缓解梯度消失问题。残差块中的跳跃连接机制将输入特征以恒等映射的形式直接传递至输出端, 并与主分支中的卷积特征进行逐元素相加。这一结构的设计理念在于

避免网络在训练过程中直接拟合复杂的高维映射关系，而是通过显式建模输入与输出之间的残差信息来降低学习难度。该机制不仅显著提高了深层网络的训练效率，还有效缓解了因网络层数加深所带来的性能退化问题，进而推动了深度神经网络在图像处理等任务中的广泛应用。

这一残差学习机制为深度神经网络的优化提供了新的理论路径，使得模型能够在更大深度下保持性能稳定与训练可行性，成为后续深层网络设计的重要基础。

2.3.3 密集连接网络

Huang 等于 2017 年提出密集连接网络（Dense Convolutional Network, DenseNet），构建出一种更高效的信息传递与特征复用机制^[52]。




图 2-4 密集连接网络结构^[53]

Figure 2-4 The network architecture of DenseNet^[53]

如图 2-4 所示，DenseNet 通过在每一层与其所有前置层之间建立直接连接，构建出高度密集的信息交互路径，实现了跨层次的特征传递与重用^[53]。这种连接机制不仅提升了特征复用率，强化了中间层语义信息的传递能力，还通过共享前置特征图而避免冗余计算，有效降低了参数数量与内存占用，提升了模型的表达效率与资源利用率。在网络后端，DenseNet 将所有前置层的输出在通道维度上进行级联融合，进一步扩展了网络深度与特征维度，为模型提供了更丰富的语义表征。此外，该密集连接策略使得每一层均可直接接收来自输入端的梯度信号，显著缓解了梯度消失问题，提升了深层网络的训练稳定性与收敛性能。

尽管 DenseNet 在特征传播与模型紧凑性方面表现出色，但其高度密集的连接结构也可能带来额外的内存负担。尤其在深层网络中，数据传输量的大幅增长可能导致资

源占用迅速上升。因此，在实际应用中需合理控制网络深度与连接密度，以平衡性能与资源消耗之间的关系。

2.3.4 注意力机制

注意力机制（Attention Mechanism）源于人类视觉系统中对特定区域的选择性感知能力，能够通过动态调整输入中不同区域的权重，引导模型将更多计算资源聚焦于关键目标区域，从而提升特征表达的有效性与判别性。该机制最初应用于自然语言处理领域，并因其优秀的信息选择与筛选能力迅速引起广泛关注，随后被成功引入图像识别、目标检测、语义分割等多个计算机视觉任务中。其核心优势在于赋予模型对特征区域的自适应关注能力，能够根据具体任务需求动态调整注意力的空间或通道分布，从而优先聚焦于与任务高度相关的显著特征区域，同时有效抑制冗余或无关信息的干扰。在此基础上，注意力机制不仅提升了模型对关键区域的感知能力，还在保证计算效率的前提下显著增强了整体预测性能。




图 2-5 SENet 网络结构^[61]

Figure 2-5 SENet network structure^[61]

从其作用维度进行分类，注意力机制通常可被划分为两种主要类型，即通道注意力与空间注意力两类^[56,57]。在卷积神经网络中，通道维度通常承载了不同类型的语义信息。通道注意力机制通过显式建模通道间的相关性，对各通道赋予不同的重要性权重，以突出任务相关特征，代表性方法如 SENet^[61]，其结构如图 2-5 所示。相较而言，空间注意力机制更侧重于挖掘特征图中不同空间位置的重要性信息。该机制通过构建像素级的权重矩阵，引导模型在空间维度上聚焦于具有显著意义的区域，从而强化关键区域的响应，提升空间特征的表达能力与区分度。在此基础上，Chen 等^[48]提出了卷积注意力模块（Convolutional Block Attention Module, CBAM），创新性地将通道注意力与空间注意力进行集成建模。该模块首先分别计算通道维度和空间维度上的注意力映射，然后通过逐元素相乘的方式对原始特征进行加权增强，从而获得更加具有判别能力的复合特征表示。CBAM 的引入显著提升了模型在复杂视觉任务中的表现，已成

为近年来注意力机制结构设计的重要代表之一。

2.4 监督学习与无监督学习

根据训练数据中是否包含完整的标签信息，当前主流的深度学习方法可大致划分为监督学习与无监督学习两种核心范式。监督学习依赖于人工标注的样本数据，在训练过程中通过构建输入与输出之间的显式映射关系，实现模型的精确拟合与预测能力的提升；而无监督学习则不依赖任何先验标签信息，主要通过挖掘数据内部潜在的结构特性与分布规律，完成对数据的表示学习与模式识别。

2.4.1 监督学习

监督学习是一种典型的深度学习训练范式，其核心思想是基于已知的输入与输出之间的对应关系，在标签数据的引导下对模型进行训练，从而学习输入特征与目标结果之间的映射函数。在该框架下，训练数据集包含明确的标注信息，这些标签作为监督信号，用于指导模型参数的优化过程。具体而言，模型首先接收输入样本，并输出预测结果；随后，通过定义合适的损失函数来衡量预测值与真实标签之间的误差；最后，借助优化算法（如梯度下降）对损失函数进行最小化，从而不断调整和更新网络的权重参数。经过多轮迭代训练后，模型能够逐步掌握数据的潜在分布规律，并具备一定的泛化能力，在面对未见样本时能够做出相对准确的预测。

监督学习在图像分类、目标检测、回归分析以及模式识别等任务中展现出优秀的性能，已成为计算机视觉和人工智能领域中最为主流的建模范式之一。然而，该方法的有效性在很大程度上依赖于高质量、海量的人工标注数据。由于标注过程通常耗时耗力、成本高昂，这在实际应用中成为限制其大规模推广的重要因素，尤其在数据获取受限或标注困难的场景下，监督学习方法的适用性与扩展性将受到明显制约。

2.4.2 无监督学习

无监督学习相较于监督学习，采用了截然不同的训练范式，其训练数据仅包含输入样本本身，完全不依赖人工标注信息。在这一架构下，神经网络通过自动挖掘输入数据中潜藏的结构特性、统计关系及分布模式，实现对数据的自适应建模与特征学习。无需外部标签的约束，模型能够基于数据内部规律自主构建有效的表示形式，从而完成多种任务。典型的无监督学习方法包括聚类分析、降维处理和自编码器结构等^[57]。其中，聚类算法通过度量样本间的相似性，将数据划分为若干内部一致性高、相互差异明显的子集；降维技术则旨在通过构建低维特征映射，将高维数据投射至更紧凑的

表示空间，从而便于后续的数据处理与可视化；自编码器通过“编码—解码”的网络结构，在重构输入数据的过程中学习其压缩表示，有效提取其潜在本质特征^[57-60]。总体而言，无监督学习在处理大规模未标注数据、开展探索性数据分析以及自动特征学习等方面展现出广泛的应用潜力与研究价值，成为推动深度学习算法摆脱对大量人工标签依赖的重要方向之一。

在图像融合领域，由于缺乏高质量的标准融合图像可作为训练标签，传统的监督学习方法难以直接应用。同时，现有的预训练模型通常针对单一模态优化，难以适应多模态图像间的特征差异。因此，图像融合任务多采用无监督学习策略，通过构建融合图像与源图像之间的复合损失函数（如像素损失、梯度损失、结构相似度等），对融合效果进行约束与优化，从而引导模型学习不同模态图像间的信息互补关系，实现高质量的融合结果。

2.5 本章小结

本章系统阐述了多模态图像融合在深度学习框架中的理论基础、各种用于定量评估图像融合算法性能的指标。以卷积神经网络、残差网络、密集连接网络以及注意力机制为代表的基于深度学习融合算法的基本原理与结构设计，深入分析了它们在深层特征提取与模型表达中的关键作用，为本课题融合方法的构建提供了坚实的理论支撑。同时，对监督学习与无监督学习两种典型训练范式进行了明晰界定，并结合图像融合任务的实际需求，明确指出本研究采用无监督学习框架开展模型训练，有效规避了对预训练模型的依赖，提升了方法的通用性与适应性。上述内容为后续图像融合方法的设计、实现与性能优化奠定了理论基础。

第三章 显著性引导的红外与可见偏振图像融合方法

3.1 引言

目前, 基于深度学习的多模态图像融合方法主要应用于红外图像与可见光图像的融合^[1-4]。然而, 这些融合方法忽视了偏振的重要性。偏振成像技术可通过多个维度从图像中获取丰富的表面信息^[92], 减少反射光的影响, 并增强不同材料的可识别性。在偏振图像融合方面, 已有多项研究成果^[93-96]。例如, Li 等^[40]为了生成具有更高目标对比度的图像, 提出了 TIPFNet 网络模型, 该模型有效的融合红外与红外偏振图像的优势。Liu 等^[96]通过模型整合了 RGB 和偏振图像特征, 通过动态提取并调整来自两种图像的注意力权重, 融合多模态特征, 显著提高分割性能。红外和红外偏振图像往往受到红外图像固有缺陷的限制, 即在场景中缺乏纹理。相对于红外光, 可见光图像具有丰富的纹理, 但其在雨雾场景下较为模糊, 对进一步识别造成阻碍。本章提出了一种新颖的基于显著性图引导的端到端融合网络模型 SGFusionNet, 用于实现军事目标的中波红外与可见光偏振图像融合。此外, 本章引入了特征编码模块和自适应融合模块, 以更好地捕捉多模态图像的互补信息和结构信息。综上所述, 本章的主要贡献有以下三个方面:

(1) 提出了一种显著性引导的双分支渐进式融合网络模型 SGFusionNet, 构建了包含复杂背景的中波红外与可见光偏振图像数据集, 为军事图像融合任务提供了基础支撑与实验验证平台。

(2) 设计了特征编码模块与自适应融合模块, 在融合过程中引入多尺度卷积与梯度算子, 有效增强对关键边缘与结构特征的提取能力。该模块不仅能够在推理过程中自适应地选择信息丰富的特征, 而且能实现对优势特征的高效筛选与提取。

(3) 构建了语义区域加权损失函数, 通过结合显著性图综合考虑像素差异与梯度信息, 引导网络更精准地进行特征重构与图像融合, 确保最终输出具备更高的视觉质量与语义一致性。

3.2 显著性引导的红外与可见光偏振图像融合方法

3.2.1 图像融合的一般架构

如图 3-1(a), (b)所示, 在端到端卷积神经网络 (CNN) 框架下构建的图像融合模型整体网络结构由双模态源图像输入、特征提取网络 (编码器)、融合模块、图像重建网络 (解码器)、融合图像和损失函数六个关键模块构成, 各模块之间紧密协作, 形成从原始图像输入到融合结果输出的完整流程, 实现流程如图 3-2 所示。其中编码器与解码器负责特征的表达与还原, 融合模块实现多模态信息的有效整合, 而损失函数则在训练过程中为模型提供优化目标与学习指导。




图 3-1 基于端到端 CNN 的图像融合网络结构 (a) 孪生神经网络; (b) 伪孪生神经网络

Figure 3-1 The architecture of the end-to-end CNN-based image fusion network (a) Siamese neural network; (b) pseudo-Siamese neural network




图 3-2 SGFusionNet 算法实现流程图

Figure 3-2 Flowchart of the proposed method in this chapter

在融合模型的构建过程中，编码器模块用于提取不同源图像的多层次特征，其结构设计通常采用孪生神经网络（Siamese Neural Network, SNN）或伪孪生神经网络（Pseudo-Siamese Network, PSN）两种形式，具体如图 3-1(a), (b)所示。针对输入图像相似度较高的场景，其局部存在清晰度与曝光度变化^[49]，可采取孪生神经网络，通过单一编码器对图像实现有效的特征提取。在这类任务中，图像间仅在局部区域存在清晰度或亮度的差异，整体语义结构一致性较强，使用统一编码器不仅能够有效提取共享特征，还可显著降低模型参数量，实现网络的轻量化。相比之下，伪孪生神经网络由两个相互独立的特征提取模块组成（可以结构相同或不同），更适用于差异较大的多模态图像融合任务，如强度图像与偏振图像融合、可见光与红外图像融合以及遥感多源图像融合^[1-4]等任务，在保持模态特异性特征的同时，提升融合表达的多样性与准确性。由于成像传感器类型不同，各模态图像在内容表现和统计特性方面存在显著差异。例如，红外图像主要用于捕捉温度信息，能突出热源目标，在夜间或恶劣气候条件下具有良好的穿透能力；而可见光图像则包含丰富的纹理结构和颜色信息，更适合呈现物体外观细节。两者具有高度互补性，融合后可提供更加完整的场景信息。伪孪生结构具备更强的适应性，能够分别提取各模态的独立特征并融合其优势，但由于包含双通道特征提取模块，网络结构相对更复杂，参数量和计算成本也相应增加。

针对上述问题，本章在 STDfusion 网络框架^[77]的基础上，提出了一种显著性图引导的多模态图像融合模型 SGFusionNet。

3.2.2 整体网络框架




图 3-3 SGFusionNet 网络结构

Figure 3-3 The SGFusionNet network structure

SGFusionNet 网络模型主要对架构与损失函数进行优化，结构如图 3-3 所示。该网络兼顾红外与可见光偏振两种模态的特征表达，在损失函数设计中增强对主导性信息的关注，无论该信息位于显著区域还是非显著区域，均能有效捕捉与引导。此外，为进一步挖掘多模态图像间的互补特性，在特征提取的早期阶段引入了自适应融合模块（Adaptive Fusion Module, AFM），以动态调整各模态信息的融合权重。为提升结构信息的保留能力，在特征编码模块与自适应融合模块中均嵌入了梯度滤波器，以增强对边缘与纹理特征的感知能力。如图 3-3 所示，所提出的模型由特征编码模块（Feature Encoding Module, FEM）、自适应融合模块（AFM）和特征解码模块（Feature Decoding Module, FDM）三个子模块组成。模型的输入为红外图像与可见光图像，输出为融合后的高质量图像。

如图 3-3 所示，给定一对已配准的可见光偏振图像 $I_{po} \in R^{H \times W \times 1}$ 和红外光图像 $I_{ir} \in R^{H \times W \times 1}$ ，SGFusionNet 首先应用一个 5×5 卷积和 LeakyReLU 激活函数以获得低层次特征嵌入 f_{ir} , $f_{po} \in R^{H \times W \times C}$, C 为 16, H 和 W 表示空间维度。然后，这些浅层特征 f_{ir} 和 f_{po} 通过一个三级对称编码模块，被转换为深层特征 $F_{out,ir}^i$, $F_{out,po}^i \in R^{H \times W \times 2C}$ 。FEM 是编码器的核心组件，用于实现高效的源图像特征提取，每个 FEM 由一组卷积层和 Prewitt 算子组成，用于提取边缘和纹理信息。此外，从 AFM 得到的特征 $F_{afm,ir}^i$ 和 $F_{afm,po}^i$ 用于

调制从 FEM 得到的特征 $F_{out,ir}^i$ 和 $F_{out,po}^i$ 。随后在解码器中,通过串联的 FDM 得到特征 F_{fdm}^n 。最后,使用一个 1×1 卷积层和一个 $\tanh$ 函数得到高质量的融合图像 $I_f \in R^{H \times W \times 1}$ 。

3.2.3 主要组成模块

(1) 特征编码模块 (the feature encoding module, FEM): Tang 等在 STDfusion^[77] 网络中引入了残差网络模块 (Residual block, ResBlock), 用于生成不同分辨率的特征图, 从而构建多层次的特征金字塔。尽管 ResBlock 结构简洁且计算效率高, 但其在处理多模态图像时可能存在边缘纹理细节保留不足的问题。为进一步提升融合图像的边缘感知能力, Wang 等^[29]和 Ma 等^[94]分别提出将 Sobel 梯度算子引入特征提取过程中, 用以增强对图像边缘结构的捕捉。如图 3-4 所示, 受上述方法启发, 本章设计了一种改进型特征编码模块 FEM。该模块由卷积层、边缘梯度算子、激活函数与残差连接四部分组成, 能够从源图像中提取更加丰富的特征。特别地, 梯度算子可用于提取图像在水平方向与垂直方向上的边缘与纹理信息, 增强模型对细节的感知能力。




图 3-4 特征编码模块结构

Figure 3-4 The feature encoding module module structure

形式上, FEM 的计算过程可表示为:

$$X_1 = \Re[f_{1 \times 1}(F_{in, \phi}^i)] \quad (3.1)$$

$$X_2 = \Re[f_{3 \times 3}(X_1)] \quad (3.2)$$

$$F_{out, \phi}^i = \Re[f_{1 \times 1}(X_2)] \quad (3.3)$$

$$F_{in, \phi}^i = F_{out, \phi}^{i-1} + F_{afm, \phi}^{i-1}, \quad i=2,3 \quad (3.4)$$

$$F_{in, \phi}^i = f_{\phi}, \quad i=1 \quad (3.5)$$

式中, $f_{1 \times 1}$ 和 $f_{3 \times 3}$ 分别表示卷积核大小为 1×1 和 3×3 的卷积层。 $\Re$ 表示激活函数

LeakyReLU。 f_{AFM} 表示第 i 个融合模块 AFM。 $\varphi \in \{po, ir\}$ ，“ po ”和“ ir ”分别表示来自可见光偏振图像路径或红外图像路径的特征。

(2) 自适应融合模块 (the adaptive fusion module, AFM)：之前的基于 CNN 的融合方法通常采用晚期融合策略，同时使用简单直观的融合技术，如直接串联、逐元素相加或最大化^[1-3]。对于这些方法，多模态图像的早期互补信息可能未被充分利用。为解决这一问题，Tang 等^[88]在 PIAfusion 中提出了一种早期融合策略，引入了跨模态差异感知融合模块来补偿多模态图像之间的差异信息。不同于 PIAfusion，本章首先整合来自两种模态的信息，然后通过全局调节将其分割成各自补偿的权重图。除了全局平均池化和深度卷积外，Prewitt 算子也被插入到 AFM 模块中进行特征调节。如图 3-5 所示。




图 3-5 自适应融合模块 AFM 结构

Figure 3-5 The adaptive fusion module structure

形式上，AFM 可以表示如下：

$$F^i_{pools} = f_{3 \times 3}^{dw} \left[f_{1 \times 1} \left(F^i_{in, \varphi} \right) \right] \quad (3.6)$$

$$F^i_{pools} = f_{3 \times 3}^{dw} \left[f_{gap} \left(F^i_{add} \right) \right] \quad (3.7)$$

$$F^i_{add} = f_{Prewitt} \left[F^i_{out, ir} + F^i_{out, po} \right] \quad (3.8)$$

式中， f_{gap} 表示全局平均池化操作， $f_{3 \times 3}^{dw}$ 表示 3×3 的深度通道卷积。

$$W^i = \sigma(F^i_{pools}) \quad (3.9)$$

$$\hat{F}^i_{afm, ir} = W^i \odot F^i_{out, ir} \quad (3.10)$$

$$\hat{F}^i_{afm, po} = (1 - W^i) \odot F^i_{out, po} \quad (3.11)$$

式中 $\sigma(\cdot)$ 表示 Sigmoid 函数。 W^i 表示红外图像的权重图，其元素取值范围在 0 和 1 之

间。 $\odot$ 表示逐元素乘法。

(3) 特征解码模块 (the Feature decoding module, FDM) 模块: FDM 的整体结构与 FEM 相同, 只是去掉了 Prewitt 算子, 目的是快速重建出高质量的融合图像。结构如图 3-6 所示。




图 3-6 特征解码模块 FDM 结构

Figure 3-6 the feature decoding module structure

形式上, FDM 可以表示如下:

$$F_{fdm}^n = f_{FDM}^n(F_{fdm}^{n-1}), \quad n = 2, 3, 4 \quad (3.12)$$

$$F_{fdm}^n = \sum (F_{out,\varphi}^i + \hat{F}_{afm,\varphi}^i), \quad n=1, i=3 \quad (3.13)$$

式中, F_{fdm}^n 表示重构模块 FDM 的函数。当 n 大于 1 时, 第 n 个 FDM 的输出依次输入到下一个 FDM。第一个 FDM 的输入等于最后一个 FEM 和 AFM 输出的和。

总的来说, FEM 和 AFM 的组合可以根据多模态图像的整体特征选择性地捕捉不同尺度下的主导特征信息。此外, FDM 可以快速高效地重建融合图像, 从而总体上提高融合质量。

(4) 多模态融合领域的最近研究 (如 STDfusion^[77]) 表明, 语义引导的损失函数能显著提升融合性能。这类方法通常基于静态先验假设: 红外图像独占显著性目标信息 (如热目标), 而可见光图像仅提供背景纹理, 并通过人工标注的显著性掩码固化该假设。然而, 实际场景中的目标显著性具有模态动态性, 即可见光偏振图像在高对比度条件下可能比红外图像包含更显著的前景信息, 而红外图像的背景区域 (如热纹理) 也可能比可见光图像更具结构性特征。这种静态假设与动态现实间的矛盾, 限制了现有方法在复杂场景下的适应性。

为解决上述问题, 本章提出基于最大信息选择的显著性损失函数。通过 $\max$ 函数跨模态比较像素/梯度特征 (如 $\max(po, ir)$ 和 $\max(\Delta po, \Delta ir)$), 自动选择更显著的

前景或背景信息。迫使融合图像同时捕获两模态中的主导特征。类似于 STDfusion，同时考虑像素级和梯度级特征损失，以保留融合图像和源图像之间的像素级和梯度级约束。因此，总体损失函数包括四个部分的损失，即显著性目标的像素级损失 L_p^s 、背景的像素级损失 L_p^b 、显著性目标的梯度损失 L_g^s 和背景内容的梯度损失 L_g^b 。显著性图引导的损失函数可以写为如下：

$$\mathcal{L}_{total} = \alpha \mathcal{L}_p^s + \beta \mathcal{L}_g^s + \lambda \mathcal{L}_p^b + \mu \mathcal{L}_g^b \quad (3.14)$$

$$\mathcal{L}_p^s = \frac{1}{HW} \left\| I_m \odot (I_f - \max(I_{po}, I_{ir})) \right\|_2^2 \quad (3.15)$$

$$\mathcal{L}_g^s = \frac{1}{HW} \left\| I_m \odot (\Delta I_f - \max(\Delta I_{po}, \Delta I_{ir})) \right\|_2^2 \quad (3.16)$$

$$\mathcal{L}_p^b = \frac{1}{HW} \left\| (1 - I_m) \odot (I_f - \max(I_{po}, I_{ir})) \right\|_2^2 \quad (3.17)$$

$$\mathcal{L}_g^b = \frac{1}{HW} \left\| (1 - I_m) \odot (\Delta I_f - \max(\Delta I_{po}, \Delta I_{ir})) \right\|_2^2 \quad (3.18)$$

式中， Δ 表示 Prewitt 操作算子，这是用于提取梯度特征。 H 和 W 分别表示图像的高度和宽度， I_m 、 I_f 、 I_{po} 和 I_{ir} 分别代表显著性图、融合图像、可见光偏振图像和红外图像。 $\max$ 表示从多模态图像中选择最大信息， α 、 β 分别表示显著区域的像素损失和梯度损失的权重系数，而 λ 、 μ 分别表示非显著区域的像素损失和梯度损失的权重系数。在后续的消融实验中，本章将分析损失函数对融合结果的不同影响。

3.3 实验配置

本节首先描述所用到的数据集和网络训练细节，然后分析所提出的 SGfusionNet 的定性和定量性能，并最终讨论消融研究。

3.3.1 数据集

本文收集了多模态图像并创建了一个名为 (Saliency-guided Infrared-Visible Polarization Dataset, SIVPD) 的数据集。该数据集包含 50 组 256×256 像素的多模态图像对，每组图像均通过中波红外相机与可见光偏振相机同步采集。为增强数据多样性，在采集过程中设置了不同背景（涵盖天空、街道、绿地等典型环境）和不同拍摄视角（包含不同俯仰角与偏航角组合）。为了验证模型的泛化性，本文使用公共数据集 TNO 进行了实验验证，该数据集覆盖了多种与军事应用密切相关的红外与可见光图

像融合场景，具备较高的代表性和实用价值。整体而言，TNO 数据集总共包含共收录了 74 组经过配准处理的红外图像与可见光图像对，分为 3 个序列，分别包含 19、23 和 32 对图像。该数据集的摄像系统包括 Athena、DHV、FEL 和 TRICLOBS。Athena 系统提供了一些军事目标和背景图像，例如：飞机、士兵等。DHV、FEL 系统提供了一些场景图像，例如：日出、湖泊等；TRICLOBS 提供了日常生活图像，例如房屋和汽车。

3.3.2 网络训练细节

使用了 30 对中波红外和可见光偏振图像进行训练，每张图像被裁剪成多个 128×128 的图像块，裁剪步长设置为 12。最终，共获得了 3,630 个图像块，并将其转换为灰度图像，范围在 $[-1,1]$ 之间。学习率设置为 $1e-3$ ，损失函数中的参数 α 、 β 、 λ 和 μ 分别设置为 1.2、1.2、1 和 1。使用 Adam 优化器作为优化器，批量大小和 epoch 分别设置为 4 和 30。所有实验在 Windows 10 操作系统上进行，使用 TensorFlow 1.0 框架、Intel Core i5-8300H CPU、8GB 内存和 NVIDIA GeForce GTX 1050。剩余的 20 对图像用于测试。

3.4 实验结果与分析

在本节中，本节将在创建的数据集 SIVPD 以及公共数据集 TNO 上开展实验，验证所提出方法的有效性，并分析模型中各个组成模块对整体性能的影响。

3.4.1 对比实验与定量分析

(1) 为验证方法的有效性，本章将 SIVPD 数据集划分为训练集与测试集，在 SIVPD 训练集上进行训练，并在其测试集及 TNO 数据集上进行了测试。在 SIVPD 数据集上，选择了 18 种代表性融合方法进行实验比较和分析，包括 5 种典型的传统方法，即 LP^[66]、DWT^[63]、NSCT^[64]、DTCWT^[65]、CVT^[66]，这些传统方法均采用像素平均融合策略；13 种基于深度学习的融合方法，其主要分为两大类：（1）基于自编码器（AE）的融合方法，即 DenseFuse^[67]、SwinFuse^[68]和 CDDFuse^[69]；（2）以基于深度学习为核心的端到端的图像融合方法，即 FusionGAN^[70]、DDcGAN^[71]、GANMcC^[72]、Prefuse-GAN^[73]、DDFM^[74]、IFCNN^[75]、PMGI^[76]、SDFusion^[61]和 STDfusion^[77]。在本章的实验中，基于自编码器的融合方法直接使用预训练的通用融合模型在测试数据集上进行测试。其他深度学习基线比较方法则使用原始论文中的默认参数设置进行了重新训练。

表 3-1 在数据集 SIVPD 上的 20 对图像上的定量结果。红色粗体表示最佳性能，蓝色粗体表示次佳性能，黑色加粗下划线表示第三佳性能

Table 3-1 Quantitative results on the 20 pairs of images on the dataset SIVPD. Red bold indicates the best performance, blue bold indicates the second best, and black with bold underlining indicates the third best

Model	Date/Publication	MI	AG	SF	VIF	SD
LP	1987'IJCV	2.3706	5.4567	0.0484	0.5757	8.8215
DWT	1995'ICIP	2.3794	<u>6.2820</u>	0.0647	0.4146	8.6663
NSCT	06'TIP	2.2723	5.4460	0.0474	0.4825	8.6182
DTCWT	07'Inf. Fusion	2.1743	5.1536	0.0454	0.4433	8.4756
CVT	07'Inf. Fusion	2.0169	5.2530	0.0454	0.3990	8.5738
DenseFuse	18'TIP	3.4159	3.5034	0.0331	0.5598	8.1106
FusionGAN	19'Inf. Fusion	3.3273	2.1537	0.0207	0.4653	6.9579
DDcGAN	20'TIP	2.7459	5.9902	0.0545	0.5249	9.7118
IFCNN	20'Inf. Fusion	2.5755	5.4970	0.0481	0.5401	8.2810
PMGI	20'AAAI	3.6087	4.7142	0.0395	0.6057	8.6483
GANMcC	20'TIM	3.2902	2.9674	0.0251	0.5303	8.1798
SDfusion	21'IJCV	3.3365	5.2045	0.0453	0.4987	7.9708
STDfusion	21'TIM	4.4685	5.5835	<u>0.0580</u>	0.6813	8.4117
Prefusion-GAN	21'Inf	2.6181	5.2082	0.0452	0.4498	7.7952
SwinFuse	22'TIM	3.4717	6.5514	0.0580	0.6591	9.4191
SwinFusion	22'JAS	<u>4.3946</u>	4.5500	0.0431	0.6017	8.5773
DDFM	23'ICCV	2.7740	4.3192	0.0378	0.5532	9.1661
CDDFuse	23'CVPR	3.7761	5.7312	0.0544	0.6148	8.7971
Ours	2023	5.0165	6.6275	0.0760	<u>0.6487</u>	<u>9.2718</u>

本节在 SIVPD 数据集进行了不同方法的定量分析。表 3-1 展示了使用五种指标对 20 对图像进行平均融合的结果。如表 3-1 所示，提出的 SGfusionNet 在 MI、AG 和 SF 指标上取得了最高的分数。具体而言，最佳的 MI 指标意味着 SGfusionNet 从源图像中转移了最多的信息。最佳的 AG 和 SF 指标表明，通过 SGfusionNet 获得的融合图像包含了最丰富的信息和纹理细节。至于 VIF 和 SD 指标，提出的 SGfusionNet 略微落后于 STDfusion 和 SwinFuse 以及 DDcGAN。尽管在这两个指标上有所滞后，但本章方法融合图像仍然保留了高度的视觉吸引力和丰富的对比信息。

表 3-2 在数据集 TNO 上的 25 对图像上的定量结果。红色粗体表示最佳性能，蓝色粗体表示次佳性能，黑色加粗下划线表示第三佳性能

Table 3-2 Quantitative results on the 25 pairs of images on the dataset TNO. Red bold indicates the best performance, blue bold indicates the second best, and black with bold underlining indicates the third best

Model	Date/Publication	MI	AG	SF	VIF	SD
LP	1987'IJCV	1.6155	4.3644	0.0437	0.8359	8.5338
DWT	1995'ICIP	1.8161	3.2682	0.0371	0.6518	8.2754
NSCT	06'TIP	1.6074	4.3084	0.0433	0.7210	8.4658
DTCWT	07'Inf. Fusion	1.5921	4.1984	0.0429	0.6702	8.4210
CVT	07'Inf. Fusion	1.5163	4.2838	0.0432	0.6297	8.4713
DenseFuse	18'TIP	4.4315	3.3537	0.0344	0.9527	9.6940
FusionGAN	19'Inf. Fusion	2.4351	1.4187	0.0136	0.5755	6.9375
DDcGAN	20'TIP	1.7188	5.4248	0.0497	0.7262	9.7489
IFCNN	20'Inf. Fusion	2.3290	4.5014	0.0453	0.7842	8.5771
PMGI	20'AAAI	2.1285	4.6258	0.0459	0.7885	8.9915
GANMcC	20'TIM	2.1482	2.0464	0.0182	0.7572	8.5757
SDfusion	21'IJCV	1.8147	4.1633	0.0420	0.4423	7.9796
STDfusion	21'TIM	3.3388	4.2265	0.0433	0.9854	8.9943
Prefusion-GAN	21'Inf	1.8895	4.5595	0.0457	0.3685	9.5623
SwinFuse	22'TIM	2.2831	4.8085	0.0514	0.8329	9.0842
SwinFusion	22'JAS	3.1779	4.1301	0.0407	0.8980	8.9619
DDFM	23'ICCV	1.5559	3.7037	0.0439	0.4106	9.2813
CDDFuse	23'CVPR	2.9658	4.7934	0.0491	0.9380	9.0983
Ours	2023	3.9070	5.7496	0.0639	0.9921	9.3796

(2) TNO 数据集：表 3-2 分别展示了使用五种指标对 25 对图像进行平均融合的结果。从表 3-2 可以看出，提出的 SGfusionNet 在 AG 和 SF 指标中均取得了最优结果，表明 SGfusionNet 保留了丰富的梯度和纹理信息。在 VIF 指标上，本章的方法取得了最优结果，表明 SGfusionNet 能够生成令人满意的融合结果。此外，提出的 SGfusionNet 仅在 SD 指标上以微弱优势仅次于 DDcGAN。DenseFuse 在 MI 指标上以显著优势均取得了最优结果，这意味着它可以从源图像向融合图像传输更多信息并生成令人满意的融合结果。DenseFuse 和 SwinFuse 是一种基于 AE 的方法，仅训练特征提取过程，对融合结果没有约束。当特征编码器提取的特征在推理过程中通过最大操作直接融合时，融合结果丰富地将信息从源图像传输到融合图像。

3.4.2 消融实验

本节主要分析并验证所提出方法 SGfusionNet 的各个组成模块的有效性以及损失

函数对融合结果的不同影响。如表 3-3 所示。

表 3-3 关键模块在 SIVPD 数据集上的 20 对图像上的有效性

Table 3-3 Effectiveness of key modules on the 20 pairs of images from the dataset SIVPD

	$f_{3 \times 3}$	f_{Prewitt}	f_{AFM}	SG loss	MI	AG	SF	VIF	SD
(Baseline)	-	-	-	-	4.4685	5.5835	0.0580	0.6813	8.4117
(1)	✓	-	-	-	4.3502	4.3639	0.0406	0.6921	8.0413
(2)	✓	-	-	✓	5.0780	5.3451	0.0511	0.7180	8.8522
(3)	✓	-	✓	-	5.1979	4.3225	0.0392	0.8709	8.2050
(4)	✓	-	✓	✓	6.8244	5.3370	0.0523	0.7435	8.5926
(5)	-	✓	-	-	2.8377	4.1777	0.0440	0.4511	6.8690
(6)	-	-	✓	-	3.9893	5.8997	0.0684	0.4990	11.1604
(7)	-	-	-	✓	6.8824	5.3573	0.0527	0.7452	8.5162
(8)	-	✓	✓	-	3.4357	5.3840	0.0536	0.5471	8.9273
(9)	-	✓	-	✓	6.7046	5.3492	0.0524	0.7462	8.5899
(10)	-	-	✓	✓	6.8998	5.3312	0.0524	0.7455	8.5710
(11)(Ours)	-	✓	✓	✓	5.0165	6.6275	0.0760	0.6487	9.2718

为了测试关键模块的独立影响，本文对各模块进行了消融实验，具体如下：

(1) 讨论关键模块的有效性：验证本章所提出 FEM、AFM 特征模块以及显著性引导损失（标记为 SG loss）的有效性。为了测试关键模块的单独影响，进行了消融实验。其中，为了测试标记为“ f_{Prewitt} ”的 Prewitt 算子的作用，FEM 中的 Prewitt 算子被 3×3 卷积层替换，并标记为“ $f_{3 \times 3}$ ”。此外，“SG loss”表示使用 STDfusion 的损失函数。表 3-3 展示了在提出的 SGfusionNet 中对各个关键组件进行消融研究的结果。表 3-3 中列出的基线是 STDfusion 的结果，并用作基准。

从表 3-3 的情况(1)和情况(5)的结果可以看出，仅使用 f_{Prewitt} 的 FEM 仅在 SF 指标上优于带有 $f_{3 \times 3}$ 的 FEM。对于情况(2)和情况(9)，以及情况(4)和情况(11)，可以观察到带有 f_{Prewitt} 的 FEM 在大多数指标上比带有 $f_{3 \times 3}$ 的 FEM 更有效。因此，可以发现虽然独立的 f_{Prewitt} 模块性能有限，但其提取的边缘细节对于融合方法很重要，与其他模块集成后，能显著提升融合图像的整体质量。除此之外，从情况(6)和基线可以看出，在引入 AFM 后，本方法在 AG、SF 和 SD 指标上均得到极大的提升。其他情况之间的比较，例如情况(1)和情况(3)，以及情况(5)和情况(8)，也揭示了引入 AFM 的事实，该模块调整多模态图像特征图之间的信息流，可以提高图像融合质量。此外，从基线和情况(7)之间的性能差异可发现，SG loss 可以在 MI 指标上最显著地提高性能。此外，其他对

比, 如情况(1)和情况(2)、情况(3)和情况(4)、情况(8)和情况(11), 进一步验证了所提出的 SG loss 的有效性, 这可以促进融合图像从两种模态图像中获取最相关的信息。




图 3-7 通过五个指标测量的图像融合质量与 α/λ 比值的关系。横轴表示 α/λ 的比值, 使用半对数坐标以便更好地观察

Figure 3-7 Image fusion quality measured by five metrics against the ratio of α/λ The x-axis denotes the ratio of α/λ and the semi-log coordinate is employed for better observation

(2) 损失函数的有效性: 本实验针对损失函数中权重系数 α 、 β 、 λ 和 μ 对图像融合性能的影响开展进一步的分析。在实验中, 显著区域的权重系数 (α, β) 与非显著区域 (λ, μ) 分别设为相同值。并在 $[0.05, 20]$ 范围内取 15 个值设置为 α/λ 的比值。图 3-7 展示了 α/λ 比值与基于五个指标的图像融合质量之间的关系。

可以观察到, 随着比值变大, 即显著区域被赋予更大的权重, MI 和 VIF 的值会下降。这一发现表明, 更多地关注显著目标会减少融合图像的信息丰富性和视觉效果。此外, AG、SF 和 VIF 的值会先增加后减少。这一现象表明, 在显著区域中适当的权重 (范围在 $[1.2, 1.8]$) 可以增强融合图像的空间频率、梯度信息丰富性和对比度以及纹理细节。为了在五个指标的性能之间取得平衡, 同时保持融合图像前景和背景的视觉质量, 损失函数中的 α/λ 比值设置为 1.2。

上述定量和定性结果都表明, 本章提出的网络模型 SGfusionNet 通过优化网络结构和引入显著性引导损失函数, 总体上实现了优越的融合性能。

3.4.3 视觉质量比较与分析




图 3-8 在创建的数据集 SIVPD 上不同融合算法的可视化比较结果

Figure 3-8 Visualization comparison results of different fusion algorithms on the created SIVPD dataset

选择两组中波红外与偏振图像，图 3-8 中展示了通过对比方法和所提出模型获得的两组对应图像融合结果。可以观察到，传统图像融合方法获得的融合图像在强度上往往趋于平均化。例如，在两组图像中，飞机的强度值均处于偏振图像和红外图像的中间值。这种现象可能归因于融合过程中低频信息的平均策略。对于基于自动编码器（AE）的方法（如 DenseFuse），仅对特征提取过程进行训练，从而对融合结果没有约束，导致当特征编码器提取的特征仅在推理过程中通过最大值操作直接融合时，其融合结果的对比度低、细节减少。在 SwinFuse 中也可观察到类似现象。对于基于生成对抗网络（GAN）的端到端方法，FusionGAN 由于仅采用单个判别器，从而使其仅关注红外图像的特征，导致可见特征丢失。DDcGAN 由于采用双判别器，可以同时保留红外和可见偏振图像的特征，因此获得了更好的视觉质量。另一方面，基于卷积神经网络（CNN）的端到端方法（如 STDfusion）在显著图的帮助下可以实现相对更好的视

觉效果。尽管借助 Transformer，Swinfusion 可以实现良好的视觉质量和目标完整性，但整体融合图像对比度较低。

相比之下，本章方法 SGfusionNet 采用显著引导损失，为显著区域分配相对较高的权重，可以在牺牲少量背景信息的情况下增强目标的视觉体验和图像对比度。例如，飞机的显著特征（如轮廓以及尾部和机翼的局部细节）被突出显示，虽会损失少量背景信息，但视觉主体明确，图像感知质量有效提升。




图 3-9 在公开的数据集 TNO 上不同融合算法的可视化比较结果

Figure 3-9 Visualization comparison results of different fusion algorithms on the created TNO dataset

在公开的数据集 TNO 同样选择了两对中波红外和可见光图像，并展示了比较方法和所提出的模型获得的两组图像融合结果，如图 3-9 所示。可以观察到，传统的图像融合方法 LP、DWT、NSCT、DTCWTT 和 CVT 削弱了显著目标。此外，DenseFuse 模糊了热目标的边缘，并且在背景区域存在严重的光谱污染。相比之下，只有本章的方和 DDcGAN、STDfusion、Prefusion-GAN 和 SwinFuse 成功地保持了显著目标的强度并保留了可见图像的纹理细节。总体上，本章提出的 SGfusionNet 有效地保留了可见图像的纹理细节，优于其他对比方案。

总之，定性和定量结果都表明 SGfusionNet 具有出色的泛化性能。这一成就表明，SGfusionNet 不仅保留了图像中的复杂梯度和纹理信息，而且始终产生视觉上吸引人且

高质量的融合结果。

3.5 本章小结

本章提出了一种显著性引导的端到端融合框架 SGfusionNet，用于多模态红外和可见偏振光图像与复杂背景的融合。具体而言，为了更好地提取边缘和纹理特征，并从多模态图像中逐步选择更多主导和互补特征，提出了一个特征编码模块和一个嵌入梯度滤波器的自适应特征融合模块。此外，为了引导融合以突出显著区域同时保持融合图像的良好视觉质量，提出了一种显著性引导损失，通过赋予显著区域相对于非显著区域较大的权重来实现。大量的实验表明，提出的 SGfusionNet 在融合图像的客观结果和视觉质量方面均取得了优越的表现。

第四章 基于分层处理的三波段红外图像融合方法

4.1 引言

红外成像技术在军事领域具有重要的应用价值，尤其在目标识别与跟踪任务中，凭借其卓越的远距离成像能力和对热源目标的高灵敏响应，已成为关键的观测手段。然而，多数融合方法仅使用单一波段红外图像进行融合，通常存在信息量有限、抗干扰能力弱等问题，而多波段红外图像的融合方法尚未得到充分研究。具体而言，不同波段的红外图像在成像特性上各具优势^[1-4]。如图 4-1 所示即为某目标模型的可见光、短波红外、中波红外和长波红外相机的拍摄效果图。如图 4-1 所示，左侧两列可见光图像和短波红外图像类似，分辨率和细节等几乎一致，仅仅由于目标和背景等反射率的差异，目标图像对比度稍有差异，但是在右侧两列的目标的红外辐射特性表现比较明显，目标的亮度明显提高。为了进一步提升红外成像在复杂环境下的表现，相比于第三章仅采用单波段红外图像的方法，本文引入多波段红外图像进行融合，旨在更复杂的应用场景中获取更加全面、准确的图像信息，从而有助于提升目标的识别与侦查能力。




图 4-1 创建的三模态图像红外与可见光数据集 M3IR

Figure 4-1 The created three-modal image infrared and visible light dataset M3IR

鉴于此，本章考虑整合短波、中波与长波红外图像的优势，设计有效的多波段融合方法，以弥补各单一波段成像的局限性。通过融合多个波段的红外图像，可改善整体图像质量，增强对目标的识别能力和环境适应性。相比于第三章仅使用单波段图像的策略，本章实现了更细致的信息融合，为红外图像提供了更丰富的细节表现和更高的分辨率。然而，相比于双模态融合（如红外与可见光融合），三波段红外图像的融

合面临诸多挑战,包括多源图像之间的配准误差、波段间显著性差异以及融合结果中信息冗余与细节缺失等问题。因此,本章提出一种基于分层处理的多波段红外三模态图像融合方法的新型融合架构,旨在充分挖掘不同波段红外图像中的互补信息,有效缓解多源图像对齐误差并提升融合图像的清晰度与目标可识别性。具体表现如下:(1)构建了一个包含复杂背景下红外三波段军事图像数据集,显著提升了模型在真实场景中的泛化能力。(2)提出了一种显著性引导的、基于分层处理的多波段红外三模态图像融合网络模型 **M3Fusion**,作为一种创新的端到端解决方案,用于整合长波、中波与短波红外图像的优势信息。为有效支持模型的训练与评估。(3)在网络结构方面,设计了以倒残差模块(**Inverted Residual, IR**)^[86]为核心的编码器,用于增强红外图像的特征提取能力,并获取多层次的语义信息。对应的解码器部分引入了跨层级跳跃特征重构策略,逐步恢复多尺度特征,实现高保真的图像重建。整个网络在融合阶段,模型引入了两个关键的融合模块:跨模态交叉融合模块与跨尺度特征融合模块,分别用于增强不同波段图像在边缘特征与目标属性方面的互补性。通过构建可学习的融合模块,实现了编码器与解码器之间信息的自适应传递,进一步提升了融合图像的结构完整性与语义一致性。

综合上述,本章的主要贡献可归纳如下:

(1)提出了一种显著性引导的、基于分层处理的多波段红外三模态图像融合模型 **M3Fusion**,为红外图像的多波段融合任务提供了一套创新性的端到端解决方案。与此同时,构建了一个涵盖长波、中波和短波红外图像,并包含复杂背景信息的多模态军事图像数据集,用于支撑模型的训练与性能评估,填补了相关领域在公开数据资源方面的空白。

(2)设计了以 **IR** 模块为核心的编码器结构,该模块专注于提升特征提取的效率,并实现多层次语义特征的高效捕获。在解码器部分,集成了跨层级跳跃连接的特征重构机制,从而实现多尺度信息的逐级恢复与高保真图像重建。整个网络架构完全由卷积模块构成,具有结构紧凑、计算效率高等优势,适用于对实时性与资源约束较高的实际应用场景。

(3)在融合模块设计方面,引入了跨模态交叉融合模块与跨尺度特征融合模块,显著提升了不同层级特征,尤其是边缘信息与目标属性之间的融合质量。该设计通过可学习的参数机制对编码器与解码器之间的连接方式进行自适应优化,进一步增强了融合图像的结构完整性与语义一致性。

4.2 基于分层处理的三波段红外图像融合方法

4.2.1 整体网络结构

本章所提出的网络模型 M3Fusion 同时兼顾长波红外、中波红外和短波红外三种模态的特征表达，并在损失函数中增强了对三模态图像中主导性特征的关注，无论这些信息是否位于显著区域，均能得到有效捕捉与保留。M3Fusion 网络模型由编码器子网络、融合子网络和解码器子网络三部分组成，整体结构如图 4-2 所示。




图 4-2 M3Fusion 网络结构

Figure 4-2 The M3Fusion network structure

在编码器部分，模型采用三个级联的 IR 模块作为核心单元，用于从输入图像中提取多尺度低层次语义特征。具体而言，给定一组配准的红外图像：长波红外图像 $I_{lir} \in R^{H \times W \times 1}$ 、中波红外图像 $I_{mir} \in R^{H \times W \times 1}$ 和短波红外图像 $I_{sir} \in R^{H \times W \times 1}$ ，分别经过三个 IR 模块后，得到对应的特征嵌入 $f_{lir}^i \in R^{H \times W \times C}$ 、 $f_{mir}^i \in R^{H \times W \times C}$ 和 $f_{sir}^i \in R^{H \times W \times C}$ ，其中通道维度 C 分别为 16、32 和 64， $H \times W$ 表示图像的空间分辨率。

IR 模块是编码器网络的核心组件，旨在高效提取源图像特征。该模块由两个连续的 1×1 卷积层和一个 3×3 深度可分离卷积层组成。其中， 3×3 深度卷积用于增强图像的局部感知能力并提取结构特征，随后通过 1×1 卷积实现通道压缩与融合，从而减少冗余特征并降低网络参数量。此外，从 CCFF 模块获得的融合特征 $F^i_{ccff,F}$ 与从 CMDAF 模块提取的融合特征 $F^i_{cmdaf,F}$ 进行拼接整合，形成多层次、多模态的联合表征。该融合特征随后输入至解码子网络，依次通过多个 Resblock 块进行特征重构与上采样操作。最后，使用一个 1×1 卷积层和 Tanh 激活函数生成最终融合图像 $I_f \in R^{H \times W \times 1}$ ，确保输出图像在保持热特征的同时具备良好的结构细节与视觉一致性，从而减少冗余特征并降

低网络参数量。

4.2.2 主要组成模块

本小节中主要介绍本章设计的融合子网络，主要由跨模态交叉融合模块和跨尺度特征融合模块两部分组成。

(1) 跨模态交叉融合模块(Cross-Modality Differential Awareness Fusion, CMDAF): 受到 PIAFusion^[88]设计融合模块的启发, 本章引入了一个 CMDAF 模块, 以增强浅层特征提取过程中差异信息的捕捉和补偿, 结构如图 4-3 所示。




图 4-3 The CMDAF 模块的网络结构

Figure 4-3 The CMDAF module network architecture

具体而言, CMDAF 模块整合了共同和互补特征, 从而实现了以下信息融合的表述:

$$F_{lir}^i = \frac{f_{lir}^i + f_{mir}^i + f_{sir}^i}{3} + \frac{f_{lir}^i - f_{mir}^i}{3} + \frac{f_{lir}^i - f_{sir}^i}{3} \quad (4.1)$$

$$F_{mir}^i = \frac{f_{lir}^i + f_{mir}^i + f_{sir}^i}{3} + \frac{f_{mir}^i - f_{lir}^i}{3} + \frac{f_{mir}^i - f_{sir}^i}{3} \quad (4.2)$$

$$F_{sir}^i = \frac{f_{lir}^i + f_{mir}^i + f_{sir}^i}{3} + \frac{f_{sir}^i - f_{lir}^i}{3} + \frac{f_{sir}^i - f_{mir}^i}{3} \quad (4.3)$$

式中, 共同部分捕捉了跨模态的共享特征, 而互补部分则突出了每个模态特有的独特特征。公式(4.1)、(4.2)和(4.3)阐明了差异分解的原则, 这一概念类似于差分放大电路。CMDAF 模块的核心思想是通过通道加权完全整合互补信息。因此, CMDAF 模块可以精确定义如下:

$$\begin{aligned} F_{cmdaf,lir}^i &= F_{lir}^i \oplus \delta \left(\text{GAP} \left(F_{mir}^i - F_{lir}^i \right) \right) \odot \left(F_{mir}^i - F_{lir}^i \right) \\ &\quad \oplus \delta \left(\text{GAP} \left(F_{sir}^i - F_{lir}^i \right) \right) \odot \left(F_{sir}^i - F_{lir}^i \right) \end{aligned} \quad (4.4)$$

$$F_{cmdaf,mir}^i = F_{mir}^i \oplus \left(GAP(F_{lir}^i - F_{mir}^i) \right) \odot (F_{lir}^i - F_{mir}^i) \oplus \left(GAP(F_{sir}^i - F_{mir}^i) \right) \odot (F_{sir}^i - F_{mir}^i) \quad (4.5)$$

$$F_{cmdaf,sir}^i = F_{sir}^i \oplus \left(GAP(F_{lir}^i - F_{sir}^i) \right) \odot (F_{lir}^i - F_{sir}^i) \oplus \left(GAP(F_{mir}^i - F_{sir}^i) \right) \odot (F_{mir}^i - F_{sir}^i) \quad (4.6)$$

$$F_{cmdaf,F}^i = F_{cmdaf,lir}^i + F_{cmdaf,mir}^i + F_{cmdaf,sir}^i \quad (4.7)$$

式中， $\oplus$ 表示逐元素求和， $\odot$ 表示通道内乘法， $\delta(\cdot)$ 表示 Sigmoid 函数。 $GAP(\cdot)$ 代表全局平均池化，该操作将互补特征压缩成一个向量，随后通过引入 Sigmoid 激活函数对该向量进行非线性压缩处理，将其映射至区间[0,1]，从而生成用于通道加权的归一化权重系数。随后，这些互补特征通过这些通道权重进行缩放，并作为补充模态信息加入融合特征中。因此，本章提出的特征解码器可以有效地利用 CMDAF 模块从不同模态中提取并预集成互补特征。

(2) 跨尺度特征融合模块 (CNN-based Cross-scale Feature Fusion, CCFF)：为了提深层特征的提取效果，在第三阶段之前引入了 CCFF 模块，结构，如图 4-4 所示。CCFF 模块能将三个相邻尺度的特征合并成一个增强的特征表示。




图 4-4 The CCFF 模块的网络结构

Figure 4-4 The CCFF module network architecture

融合块由两个 1×1 卷积和一个 3×3 卷积组成，用于调整通道维度。此外，还使用了 N 个 RepBlocks，每个 RepBlock 采用 RepConv，以实现有效的特征融合。来自三条路径的输出通过逐元素相加的方式结合。CCFF 模块生成的特征，通过以下公式计算：

$$F_{add}^i = f_{lir}^i + f_{mir}^i + f_{sir}^i \quad (4.8)$$

$$F_{c_{ff},F}^i = F_{add}^i + f_{1 \times 1} \text{concat} (f_{lir}^i, f_{mir}^i, f_{sir}^i) + f_{1 \times 1} f_{reblock} \text{concat} (f_{lir}^i, f_{mir}^i, f_{sir}^i) + f_{3 \times 3} \text{concat} (f_{lir}^i, f_{mir}^i, f_{sir}^i) \quad (4.9)$$

式中, $f_{1 \times 1}$ 和 $f_{3 \times 3}$ 表示具有 1×1 和 3×3 核大小的卷积层, $f_{reblock}$ 表示通过 RepBlocks 模块获得的特征。

与第三章所述损失原理相同, 本章通过基于最大信息选择的显著性损失函数, 旨在通过从三个源图像中提取最大信息量, 以识别并提取场景中前景与背景的主导特征。通过像素级和梯度级特征损失的加权组合, 确保了融合图像与源图像之间在像素级和梯度级上的约束得以保持。因此, 总体损失函数由四个部分组成, 包括显著性目标的像素级损失 L_p^s 、背景的像素级损失 L_p^b 、显著性目标的梯度损失 L_g^s 和背景内容的梯度损失 L_g^b 。显著性图引导的损失函数可以写为如下:

$$Loss = \lambda_1 L_p^s + \lambda_2 L_p^b + \lambda_3 L_g^s + \lambda_4 L_g^b \quad (4.10)$$

$$L_p^s = I_m \otimes \|I_f - \max(I_{lir}, I_{mir})\|_1 \quad (4.11)$$

$$L_p^b = (1 - I_m) \otimes \|I_f - I_{sir}\|_1 \quad (4.12)$$

$$L_g^s = I_m \otimes \|\Delta I_f - \max(\Delta I_{lir}, \Delta I_{mir})\|_1 \quad (4.13)$$

$$L_g^b = (1 - I_m) \otimes \|\Delta I_f - \Delta I_{sir}\|_1 \quad (4.14)$$

式中, Δ 表示 Prewitt 操作算子, 这是用于提取梯度特征。 H 和 W 分别表示图像的高度和宽度, I_m 、 I_f 、 I_{lir} 、 I_{mir} 和 I_{sir} 分别代表显著性图、融合图像、长波红外图像、中波红外图像和短波红外图像。 $\max$ 表示从多波段红外图像中选择最大信息, α 、 β 分别表示显著区域的像素损失和梯度损失的权重系数, 而 λ 、 μ 分别表示非显著区域的像素损失和梯度损失的权重系数。

4.3 实验配置

4.3.1 数据集

在第三章所创建的数据集基础上, 本章进一步采集了由长波红外 (Long Wave Infrared, LWIR)、中波红外 (Mid Wave Infrared, MWIR) 和短波红外 (Short Wave Infrared, SWIR) 传感器拍摄的多模态图像, 构建了 M3IR 数据集。如图 4-5 所示, 使用三种红外相机对飞机目标进行成像。




图 4-5 创建的三模态红外数据集 M3IR

Figure 4-5 The created three-model infrared dataset is named M3IR

M3IR 充分考虑了拍摄背景与角度的复杂性，共采集了 200 组多模态图像对，数据采集过程中充分考虑了背景的复杂性（如天空、绿地等元素）以及多种拍摄角度（包括不同的俯仰角与偏航角）。在图像融合前，对所采集的图像对进行了图像配准处理^[23]。由于 LWIR 可以提供目标的热辐射信息，MWIR 有助于提取清晰的结构细节，而 SWIR 则能够反映物体的材质属性与纹理特征。因此，在多波段红外图像的融合过程中，模型算法可从近红外图像中提取丰富的纹理信息，并从中远红外图像中提取显著的热特征，实现多源互补信息的有效整合。如图 4-5 所示，显著性信息主要源自远波红外和中波红外图像的前景部分，而非显著性信息则主要来自近红外图像的背景部分。然而，目标信息在近红外图像中的显著性可能高于远波红外和中波红外图像；相反，背景信息在中波红外图像中可能包含更丰富的纹理细节，而在近红外图像中则未必如此。

4.3.2 网络训练细节

本章利用了 140 组长波、中波和短波红外图像的数据集进行训练。每张图像被分割成多个 64×64 的块，总共得到 27,400 个块。这些块随后转换为灰度图像，像素值归一化到 $[-1, 1]$ 范围内。训练的学习率设置为 0.001，损失函数中的参数 λ_1 、 λ_2 、 λ_3 和 λ_4 分别配置为 7.5、5、7.5 和 1。采用 Adam 优化器，批量大小为 64，训练轮数为 30。所有实验均在 Linux 操作系统上使用 PyTorch 框架进行，配备 Intel Xeon Gold 5218 CPU、GeForce RTX 3090 GPU 和 32 GB 内存。剩余的 60 组图像用于测试。

4.4 实验结果及分析

4.4.1 对比实验与定量分析

为了验证本章所提出的长波、中波和短波红外图像融合模型的有效性,选择六种代表性融合方法与本章提出的模型 M3Fusion 进行了实验比较和分析。其中,这些方法包括两种典型方法 LP^[63]和 NSCT^[64],四种基于深度学习的端到端图像融合方法 PFNet^[100]、FusionGAN^[70]、STDfusion^[77]和 PIAFusion^[88]。基于深度学习的比较方法使用了原始论文中的默认参数设置重新训练。为了全面评估融合效果,采用了四个融合质量指标,包括空间频率(SF)^[80]、标准差(SD)^[79]、特征互信息(FMI)^[104]、峰值信噪比(PSNR)^[98]、相关系数(CC)^[99]和视觉信息保真度(VIF)^[81]。这些指标的值越大,表示融合性能越好。空间频率评估了融合图像的梯度分布,揭示其细节和纹理信息。标准差反映了融合图像的对比度及其分布情况。特征互信息衡量了源图像向融合图像传递的特征信息量。PSNR 反映了融合过程中像素级别的失真情况。CC 测量了融合图像与源图像之间的线性相关程度。VIF 则衡量了融合图像的视觉满意度。详细数据如表 4-1 所示。

表 4-1 所提出的图像融合算法在客观测试中的性能结果比较

Table 4-1 .Performance Results Comparison of Proposed Image Fusion Techniques on the Objective

Tests							
Model	Date/Publication	SF	SD	FMI	PSNR	CC	VIF
LP	1987'IJCV	6.025	33.738	31.723	10.858	0.307	0.606
NSCT	06'TIP	10.106	41.959	43.846	10.629	0.223	0.647
PFNet	20'Opt. Lett.	7.619	43.782	36.692	9.309	0.035	0.117
FusionGAN	19'Inf. Fusion	6.990	23.089	34.290	11.411	0.170	0.360
STDfusion	21'TIM	6.794	37.991	35.538	10.705	0.232	0.545
PIAFusion	22'Inf. Fusion	7.053	28.908	36.084	9.853	0.271	0.683
M3Fusion(Ours)	24	5.572	49.847	32.276	12.011	0.334	0.879

由表 4-1 可知,本章提出的 M3Fusion 在 SD、PSNR、CC 和 VIF 方面均优于其他方法,尤其是 VIF,与其他方法相比性能至少提升 28.7%,充分证明了本章提出的模型融合后的图像具有更高的对比度、丰富的梯度信息、边缘信息、纹理细节及其他信息,并符合人类视觉效果。领先的 SF 指标表明,NSCT 生成的融合图像在信息含量和纹理

细节上都非常丰富。FMI 指标则表明，NSCT 能够有效地从源图像中传递最大量的信息。

4.4.2 消融实验

本节主要分析并验证所提出模型 M3Fusion 的各个组成模块的有效性以及损失函数对融合结果的不同影响。如表 4-2 所示。

表 4-2 关键模块在 M3IR 数据集上的 60 对图像上的有效性

Table 4-2 Effectiveness of key modules on the 60 pairs of images from the dataset M3IR

	f_{CMDAF}	f_{CCFF}	SG loss	SF	SD	FMI	PSNR	CC	VIF
(1)	-	-	✓	5.515	51.283	32.228	12.151	0.354	0.923
(2)	-	✓	-	6.237	27.194	33.968	9.973	0.278	0.734
(3)	-	✓	✓	6.257	27.201	33.914	10.038	0.278	0.722
(4)	✓	-	-	6.159	26.495	33.613	9.812	0.280	0.714
(5)	✓	✓	-	6.256	27.201	33.914	10.038	0.278	0.722
(6)	✓	-	✓	5.512	50.070	32.080	11.951	0.331	0.897
(7)(Ours)	✓	✓	✓	5.572	49.847	32.276	12.011	0.334	0.879

为了测试关键模块的独立影响，本文对各模块进行了消融实验，具体如下：

验证本章所提出 CMDAF、CCFF 特征模块以及显著性引导损失（标记为 SG loss）的有效性。为了测试关键模块的单独影响，进行了消融实验。其中，“SG loss”表示使用 STDfusion 的损失函数。表 4-2 展示了在提出的 M3Fusion 中对各个关键组件进行消融研究的结果。从表 4-2 的数据中，当启用 f_{CMDAF} 时（如情况(4)、情况(5)、情况(6)、情况(7)(Ours)），与未启用时（情况(1)、情况(2)、情况(3)）相比，在融合指标上有不同程度影响。例如在 SF 指标上，启用后部分行数值有所提升，像情况(4)中 SF 为 6.159 和 FMI 为 33.613，相比情况(1)有增加，表明 f_{CMDAF} 比 SG loss 更能够保留融合图像的边缘信息和特征信息，在图像特征提取或融合过程中起到关键作用。当 f_{CMDAF} 与其他模块合理搭配时（情况(7)(Ours)），能进一步提升整体融合效果，是提升融合性能的重要组成部分。当启用 f_{CCFF} （情况(2)、情况(3)、情况(5)、情况(6)、情况(7)(Ours)）时，FMI 指标有明显变化，如情况(2)中 FMI 值为 33.968，相较于情况(1)有显著提升，说明它对融合图像特征信息保留能力影响较大，在调整图像间的特征信息、优化图像融合的一致性等方面发挥作用。 f_{CCFF} 与其他模块协同工作时（如情况(7)(Ours)），对整体融合质量的提升有积极贡献，是优化融合图像质量不可或缺的模块。此外，其他对比

如情况(1)和其他情况(2)、情况(3)、情况(4)、情况(5)、情况(6)和情况(7)，进一步验证了所提出的 SG loss 的有效性，这可以促进融合图像从三种模态图像中获取最相关的信息。

4.4.3 视觉质量比较与分析

选择了两组长波、中波和短波红外图像，并通过比较方法和所提出的模型获得了相应的两组图像融合结果，如图 4-6 所示。




图 4-6 M3IR 数据集上 60 组图像的定性结果。从左到右，分别是第一组和第二组的长波、中波和短波红外图像，不同算法的融合结果以及本章模型的结果

Figure 4-6 Qualitative results on the 40 sets of images on the M3IR dataset. From left to right of Group1 and Group2 are long-wave, mid-wave and short-wave infrared images, respectively, fusion results of different algorithms and ours

可以观察到，传统图像融合方法 LP 和 NSCT 得到的融合图像在强度上趋于平均。例如，飞机的强度值在这两组图像中处于长波红外和中波红外图像之间的中间值。

PFNet 采用了一种专有的损失最大化策略,以最小化源图像与融合图像之间的差异,有效管理纹理和强度。对于基于 GAN 的端到端方法, FusionGAN 表现不佳,因为它使用了一个单一的判别器来保留红外图像的特征。类似于 PIAFusion,本章也采用了交叉融合策略,以保留更多来自红外图像的目标信息。然而,本章模型相比 PIAFusion 保留了更多的纹理细节。

4.5 本章小结

本章针对红外图像融合中多波段信息分布不均与特征互补性差异显著的问题,提出了一种基于分层处理的三模态红外图像融合算法 M3Fusion。该模型在端到端网络框架下,引入了轻量化的 IR 编码模块用于提取多尺度特征,结合跨模态交叉融合模块(CMDAF)与跨尺度特征融合模块(CCFF),实现对显著区域和非显著区域主导信息的深度整合。同时,构建了红外三模态图像数据集 M3IR,并设计了基于显著性引导的多分支损失函数,以增强模型对前景与背景结构信息的辨识与保留能力。在实验部分,通过与多种传统及深度学习方法的定量和可视化对比,验证了 M3Fusion 在细节保持、热目标突出及全局结构表达等方面的优越性能。结果表明,该模型不仅在 SD, CC,VIF 融合质量指标上取得领先,还具备良好的视觉一致性与实际应用价值。

第五章 结论与展望

5.1 结论

近年来,随着深度学习的发展,多模态图像融合在图像处理领域取得了显著进展。然而,现有方法普遍未能充分利用可见光偏振图像中蕴含的丰富表面信息,尤其在复杂环境(如强光、雨雾等)下,融合图像在目标识别与视觉理解中的表现仍有较大提升空间。此外,传统的单波段红外图像受限于信息维度和抗干扰能力,难以满足复杂场景下的感知需求,而多波段红外图像在信息丰富性和场景适应性方面具有更大潜力。因此,本文围绕多波段红外图像及可见光偏振图像的多模态图像提出两种基于卷积网络的无监督融合方法,所完成的主要工作如下:

(1) 设计了一种显著性引导的多模态图像融合模型 **SGFusionNet**, 针对红外与可见光偏振图像模态差异大、背景复杂等挑战, 设计了嵌入梯度算子的特征编码模块(**FEM**)与具备特征选择能力的自适应融合模块(**AFM**), 并构建显著性加权损失函数, 从训练层面强化模型对关键区域的关注能力。实验结果表明, 该模型在多个评价指标上超越现有主流模型, 实现了纹理清晰、目标突出的融合效果。

(2) 提出了一种基于分层处理的三模态红外图像融合模型 **M3Fusion**, 面向长波、中波与短波红外图像融合任务, 构建轻量化编码结构与多尺度交叉融合机制, 分别引入 **CMDAF** 与 **CCFF** 模块以实现模态间差异信息的识别与深层特征的有效整合。此外, 构建了三模态红外数据集 **M3IR**, 并采用显著性图引导的复合损失函数, 进一步提升融合图像的细节完整性与语义一致性。对比实验与可视化分析表明, **M3Fusion** 在突出热目标、信息保留程度等方面均具有明显优势。

本文的创新性如下:

(1) 构建了一个包含复杂背景的多模态多波段红外图像及可见光偏振军事图像数据集, 覆盖中波红外与可见光偏振图像, 为模型训练与评估提供了高质量的数据支撑, 推动了该领域在军事目标识别方向的研究基础建设。

(2) 构建了显著性语义引导的多模态融合模型 **SGFusionNet**, 首次面向中波红外与可见光偏振图像融合任务, 设计了端到端的双分支渐进式融合网络, 并引入语义显著图作为引导损失, 有效增强模型对关键目标区域的关注能力, 提升了融合图像的语义表达与目标辨识性能。

(3) 设计了轻量化、高效的三模态红外图像融合模型 **M3Fusion**。该模型具备分

层处理能力，满足远红外、中红外和近红外图像的同时融合需求，并采用结构简洁的特征提取模块、交叉融合模块与跨层跳跃连接的解码机制，实现了融合图像的高质量重建。

5.2 展望

本文提出的基于多红外波段图像及可见偏振态的多模态图像融合算法提高了现有基于 STDFusion 的多模态图像融合模型在复杂环境下目标的信息，但仍然存在一些值得改进和优化的空间，主要概括如下：

（1）数据收集仅限于白天场景，这可能限制了研究结果在其他环境条件下的普遍适用性，例如夜间设置。其次，严重的相机抖动可能导致图像融合过程中源图像错位，最终输出中会出现伪影。此外，图像配准和融合算法的高计算复杂度给实时应用带来了重大挑战。未来的研究应重点关注两个主要领域：扩大数据集的多样性，包括来自不同时间段（如白天和夜晚）和地理特征（如城市、乡村、山区）的图像；优化算法设计，提高多模态图像处理的效率和鲁棒性，从而满足实时需求。

（2）算法应用。当前，当前大多数基于深度神经网络的图像融合方法，其研究与评估仍主要停留在仿真环境或实验性平台中进行，尚未充分拓展至真实场景中的实用化部署与验证。鉴于此，未来计划依据本文所述算法构建多模态图像融合系统，并将其部署于适配的硬件平台，实现在相关工作领域中的应用。

（3）多模态融合算法的核心在于实现有效的模态信息整合。当前，多模态信息融合主要包括三类策略：像素层融合、特征层融合与决策层融合，不同的融合层级对应不同的处理深度与融合效果。本文所采用的模型聚焦于特征层级的信息整合。基于此，后续研究可结合上述三种融合范式，探索更具针对性的融合策略，以进一步提升融合算法的整体性能与适应能力。

参考文献

- [1] Zhang H, Xu H, Tian X, et al. Image fusion meets deep learning: A survey and perspective[J]. Information Fusion, 2021, 76: 323-336.
- [2] Zhang X, Ye P, Leung H, et al. Object fusion tracking based on visible and infrared images: A comprehensive review[J]. Information Fusion, 2020, 63: 166-187.
- [3] Qiao T, Chen L, Pang Y, et al. Integrative binocular vision detection method based on infrared and visible light fusion for conveyor belts longitudinal tear[J]. Measurement, 2017, 110: 192-201.
- [4] Kumar P, Mittal A, Kumar P. Fusion of thermal infrared and visible spectrum video for robust surveillance[C]//Computer Vision, Graphics and Image Processing: 5th Indian Conference, ICVGIP 2006, Madurai, India, December 13-16, 2006. Proceedings. Berlin: Springer, 2006: 528-539.
- [5] Zhao Y, Zhang L, Zhang D, et al. Object separation by polarimetric and spectral imagery fusion[J]. Computer Vision and Image Understanding, 2009, 113(8): 855-866.
- [6] Li S, Jiang H, Zhu J, et al. Development status and key technologies of polarization imaging detection[J]. Chinese Optics, 2013, 6(6): 803-809.
- [7] Liu J, Duan J, Hao Y, et al. Semantic-guided polarization image fusion method based on a dual-discriminator GAN[J]. Optics Express, 2022, 30(24): 43601-43621.
- [8] Zhang J, Shao J, Chen J, et al. Polarization image fusion with self-learned fusion strategy[J]. Pattern Recognition, 2021, 118: 108045.
- [9] Zhang J, Zhang Y, Shi Z. Long-wave infrared polarization feature extraction and image fusion based on the orthogonality difference method[J]. Journal of Electronic Imaging, 2018, 27(2): 023021.
- [10] 徐东东. 基于无监督深度学习的红外与可见光图像融合方法研究[D]. 北京: 中国科学院大学(中国科学院长春光学精密机械与物理研究所), 2020.
- [11] Li X, Wang J, Ai N, et al. Remote sensing image fusion based on structured dictionary learning and joint sparse representation[C]//Proceedings of the 12th IEEE Conference on Industrial Electronics and Applications (ICIEA). IEEE, 2017: 1200-1205.
- [12] Venkataraman A, Alirezaie J, Babyn P, et al. Medical image fusion based on joint sparse method[C]//Proceedings of the 2nd Middle East Conference on Biomedical Engineering. IEEE, 2014: 103-106.
- [13] Burt P, Adelson E. The Laplacian Pyramid as a Compact Image Code[J]. IEEE

- Transactions on Communications, 1983, 31(4): 532-540.
- [14] Grossmann A, Morlet J. Decomposition of Hardy Functions into Square Integrable Wavelets of Constant Shape [J]. SIAM Journal on Mathematical Analysis, 1984, 15(4): 723-736.
- [15] Do M. N, Vetterli M. The contourlet transform: an efficient directional multiresolution image representation [J]. IEEE Transactions on Image Processing, 2005, 14(12): 2091-2106.
- [16] Xiang K, Yang K, Wang K. Polarization-driven semantic segmentation via efficient attention-bridged fusion [J]. Optics Express, 2021, 29(4): 4802-4820.
- [17] Desale R. P, Verma S. V. Study and analysis of PCA, DCT & DWT based image fusion techniques[C]//2013 International Conference on Signal Processing, Image Processing & Pattern Recognition. IEEE, 2013: 66-69.
- [18] Xue X, Guo L, Wang H, et al. A parallel fusion method of remote sensing image based on IHS transformation[C]//2011 4th International Congress on Image and Signal Processing. IEEE, 2011: 1600-1603.
- [19] Ma J, Ma Y, Li C. Infrared and visible image fusion methods and applications: A survey[J]. Information Fusion, 2019, 45: 153-178.
- [20] Tu T-M, Su S-C, Shyu H-C, et al. A new look at IHS-like image fusion methods[J]. Information Fusion, 2001, 2(3): 177-186.
- [21] Eman M, Mahmoud T. M, Ibrahim M. M, Abd El-Hafeez T. Innovative hybrid approach for masked face recognition using pretrained mask detection and segmentation, robust PCA, and KNN classifier[J]. Sensors, 2023, 23(15): 6727.
- [22] Ali A. A, El-Hafeez T, Mohany Y. A robust and efficient system to detect human faces based on facial features [J]. Asian Journal of Research in Computer Science, 2019, 2(4): 1-12.
- [23] Jiang W, Wu J, Chen C, et al. Registration of multi-modal images under a complex background combining multiscale features extraction and semantic segmentation[J]. Optics Express, 2022, 30(20): 35596-35607.
- [24] Li H, Wu X.-J, Durrani T. Nestfuse: An infrared and visible image fusion architecture based on nest connection and spatial/channel attention models[J]. IEEE Transactions on Instrumentation and Measurement, 2020, 69(12): 9645-9656.
- [25] Wang Z, Wu Y, Wang J, et al. Res2fusion: Infrared and visible image fusion based on dense res2net and double nonlocal attention models[J]. IEEE Transactions on

- Instrumentation and Measurement, 2022, 71: 1-12.
- [26] Wang X, Hua Z, Li J. Paccd: Pyramid attention cross-convolutional dual UNet for infrared and visible image fusion [J]. IEEE Transactions on Instrumentation and Measurement, 2022, 71: 1-16.
- [27] Li X, Chen H, Li Y, et al. Mafusion: Multiscale attention network for infrared and visible image fusion[J]. IEEE Transactions on Instrumentation and Measurement, 2022, 71: 1-16.
- [28] Li H, Wu X.-J. Crossfuse: A novel cross attention mechanism based infrared and visible image fusion approach[J]. Information Fusion, 2024, 103: 102147.
- [29] Wang Z, Shao W, Chen Y, et al. Infrared and visible image fusion via interactive compensatory attention adversarial learning [J]. IEEE Transactions on Multimedia, 2022.
- [30] Wang J, Jiang M, Kong J, et al. MDAN: Multilevel dual-branch attention network for infrared and visible image fusion [J]. Optics and Lasers in Engineering, 2024, 176: 108042.
- [31] Q. Xiao-Bo, Y. Jing-Wen, X. Hong-Zhi, et al. Image fusion algorithm based on spatial frequency-motivated pulse coupled neural networks in nonsubsampling contourlet transform domain [J]. Acta Automatica Sinica 34 (12) (2008) 1508-1514.
- [32] Liu Q, Qi X, Ding W, et al. Infrared and visible image fusion method based on saliency detection in sparse domain [J]. Infrared Physics & Technology 83 (2017) 94-102.
- [33] Gan W, Wu X, Wu W, et al. Infrared and visible image fusion with the use of multi-scale edge-preserving decomposition and guided image filter [J]. Infrared Physics & Technology 72 (2015) 37-51.
- [34] D. Wang, J. Liu, R. Liu, X. Fan, An interactively reinforced paradigm for joint infrared-visible image fusion and saliency object detection [J]. Information Fusion 98 (2023) 101828.
- [35] J. Liu, R. Dian, S. Li, H. Liu, Sgfusion: A saliency guided deep-learning framework for pixel-level image fusion [J]. Information Fusion 91 (2023) 205-214.
- [36] L. Tang, H. Zhang, H. Xu, J. Ma, Rethinking the necessity of image fusion in high-level vision tasks: A practical infrared and visible image fusion network based on progressive semantic injection and scene fidelity [J]. Information Fusion (2023) 101870.

- [37] W. Zhou, J. Liu, J. Lei, L. Yu, J.-N. Hwang, Gmnet: Graded-feature multilabel-learning network for rgb-thermal urban scene semantic segmentation [J]. IEEE Transactions on Image Processing 30 (2021) 7790-7802.
- [38] L. Tang, J. Yuan, J. Ma, Image fusion in the loop of high-level vision tasks: A semantic-aware real-time infrared and visible image fusion network [J]. Information Fusion 82 (2022) 28-42.
- [39] H. Zhou, W. Wu, Y. Zhang, et al. Semantic-supervised infrared and visible image fusion via a dual-discriminator generative adversarial network [J]. IEEE Transactions on Multimedia (2021).
- [40] K. Li, M. Qi, S. Zhuang, et al. TIPFNet: a transformer-based infrared polarization image fusion network [J]. Optics Letters 47 (16) (2022) 4255-4258.
- [41] J. Ma, L. Tang, F. Fan, et al. SwinFusion: Cross-domain long-range learning for general image fusion via swin transformer [J]. IEEE/CAA Journal of Automatica Sinica 9 (7) (2022) 1200-1217.
- [42] W. Tang, F. He, Y. Liu, Ydtr: Infrared and visible image fusion via y-shape dynamic transformer. IEEE Transactions on Multimedia (2022).
- [43] V. Vs, J. M. J. Valanarasu, P. Oza, V. M. Patel, Image fusion transformer, in: 2022 IEEE International Conference on Image Processing (ICIP). IEEE, 2022, pp. 3566-3570.
- [44] Liu F, Guan S, Yu K, et al. Infrared Target Detection Based on the Fusion of Mask R-CNN and Image Enhancement Network [C]. 2022 China Automation Congress (CAC), 2022: 2011-2016.
- [45] Perdios D, Vonlanthen M, Martinez F, et al. CNN-Based Ultrasound Image Reconstruction for Ultrafast Displacement Tracking [J]. IEEE Transactions on Medical Imaging, 2021, 40(3): 1078-1089.
- [46] Ebrahimzadeh D, Sharif S, Banad Y. Improving Image Classification using Triple-GAN: A Fusion of Generative Adversarial Networks and Transfer Learning [C]. 2023 IEEE Sixth International Conference on Artificial Intelligence and Knowledge Engineering (AIKE), 2023: 91-94.
- [47] Li S. Trans-CycleGAN: Image-to-Image Style Transfer with Transformer-based Unsupervised GAN [C]. 2022 3rd International Conference on Computer Vision, Image and Deep Learning & International Conference on Computer Engineering and Applications (CVIDL & ICCEA), 2022: 1-4.

- [48] Chen L, Li S, Bai Q, et al. Review of image classification algorithms based on convolutional neural networks [J]. Remote Sensing, 2021, 13(22): 4712.
- [49] 李云红, 刘宇栋, 苏雪平等. 红外与可见光图像配准技术研究综述 [J]. 红外技术, 2022, 44(07): 641-651.
- [50] Yu Y, Lee B G, Pike M, et al. Deep learning-based rgb-thermal image denoising: review and applications [J]. Multimedia Tools and Applications, 2024, 83(4): 11613-11641.
- [51] Shelhamer E, Long J, Darrell T. Fully convolutional networks for semantic segmentation [J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2017, 39(4): 640-651.
- [52] Huang G, Liu Z, Maaten L V D, et al. Densely Connected Convolutional Networks [C]. 2017 IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 2017: 2261-2269.
- [53] Szegedy C, Vanhoucke V, Ioffe S, et al. Rethinking the Inception Architecture for Computer Vision [C]. 2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 2016: 2818-2826.
- [54] Dosovitskiy A, Beyer L, Kolesnikov A, et al. An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale [J]. arXiv e-prints, 2020: arXiv:2010.11929.
- [55] Surlakar P, Araujo S, Sundaram K M. Comparative Analysis of K-Means and K-Nearest Neighbor Image Segmentation Techniques [C]. 2016 IEEE 6th International Conference on Advanced Computing (IACC), 2016: 96-100.
- [56] James R, Jolly A M, Anjali C, et al. Image Denoising Using Adaptive PCA and SVD [C]. 2015 Fifth International Conference on Advances in Computing and Communications (ICACC), 2015: 383-386.
- [57] Park S, Yu S, Kim M, et al. Dual Autoencoder Network for Retinex-Based Low-Light Image Enhancement [J]. IEEE Access, 2018, 6: 22084-22093.
- [58] Surlakar P, Araujo S, Sundaram K M. Comparative Analysis of K-Means and K-Nearest Neighbor Image Segmentation Techniques [C]. 2016 IEEE 6th International Conference on Advanced Computing (IACC), 2016: 96-100.
- [59] Nguyen K, Fookes C, Sridharan S. Improving deep convolutional neural networks with unsupervised feature learning[C]//2015 IEEE International Conference on Image Processing (ICIP). IEEE, 2015: 2270-2274.

- [60] Wang Z, Shao W, Chen Y, et al. Infrared and visible image fusion via interactive compensatory attention adversarial learning[J]. IEEE Transactions on Multimedia, 2022.
- [61] Zhang H, Ma J. SDFusion: A versatile squeeze-and-decomposition network for real-time image fusion[J]. International Journal of Computer Vision, 2021, 129: 2761-2785.
- [62] Burt P. J, Adelson E. H. The Laplacian pyramid as a compact image code[A]//Readings in Computer Vision. Elsevier, 1987: 671-679.
- [63] Chipman L. J, Orr T. M, Graham L. N. Wavelets and image fusion[C]//Proceedings of the International Conference on Image Processing. IEEE, 1995, 3: 248-251.
- [64] Da Cunha A. L, Zhou J, Do M. N. The nonsubsampling contourlet transform: Theory, design, and applications[J]. IEEE Transactions on Image Processing, 2006, 15(10): 3089-3101.
- [65] Lewis J J, Callaghan R. J, Nikolov S. G, et al. Pixel-and region-based image fusion with complex wavelets[J]. Information Fusion, 2007, 8(2): 119-130.
- [66] Nencini F, Garzelli A, Baronti S, et al. Remote sensing image fusion using the curvelet transform[J]. Information Fusion, 2007, 8(2): 143-156.
- [67] Li H, Wu X J. DenseFuse: A fusion approach to infrared and visible images[J]. IEEE Transactions on Image Processing, 2018, 28(5): 2614-2623.
- [68] Wang Z, Chen Y, Shao W, et al. SwinFuse: A residual Swin Transformer fusion network for infrared and visible images[J]. IEEE Transactions on Instrumentation and Measurement, 2022, 71: 1-12.
- [69] Zhao Z, Bai H, Zhang J, et al. CDDFuse: Correlation-driven dual-branch feature decomposition for multi-modality image fusion[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. IEEE, 2023: 5906-5916.
- [70] Ma J, Yu W, Liang P, et al. FusionGAN: A generative adversarial network for infrared and visible image fusion[J]. Information Fusion, 2019, 48: 11-26.
- [71] Ma J, Xu H, Jiang J, et al. DDcGAN: A dual-discriminator conditional generative adversarial network for multiresolution image fusion[J]. IEEE Transactions on Image Processing, 2020, 29: 4980-4995.
- [72] Ma J, Zhang H, Shao Z, Liang P, et al. GANMcC: A generative adversarial network with multi-classification constraints for infrared and visible image fusion[J]. IEEE Transactions on Instrumentation and Measurement, 2020, 70: 1-14.

- [73] Fu Y, Wu X.-J, Durrani T. Image fusion based on generative adversarial network consistent with perception[J]. Information Fusion, 2021, 72: 110-125.
- [74] Zhao Z, Bai H, Zhu Y, et al. DDFM: Denoising diffusion model for multi-modality image fusion[J/OL]. arXiv preprint arXiv:2303.06840, 2023.
- [75] Zhang Y, Liu Y, Sun P, et al. IFCNN: A general image fusion framework based on convolutional neural network[J]. Information Fusion, 2020, 54: 99-118.
- [76] Zhang H, Xu H, Xiao Y, et al. Rethinking the image fusion: A fast unified image fusion network based on proportional maintenance of gradient and intensity[C]//Proceedings of the AAAI Conference on Artificial Intelligence. 2020, 34: 12797-12804.
- [77] Ma J, Tang L, Xu M, et al. STDfusionNet: An infrared and visible image fusion network based on salient target detection[J]. IEEE Transactions on Instrumentation and Measurement, 2021, 70: 1-13.
- [78] Qu G, Zhang D, Yan P. Information measure for performance of image fusion[J]. Electronics Letters, 2002, 38(7): 1.
- [79] Rao Y.-J. In-fibre Bragg grating sensors[J]. Measurement Science and Technology, 1997, 8(4): 355.
- [80] Liu Z, Blasch E, Xue Z, et al. Objective assessment of multiresolution image fusion algorithms for context enhancement in night vision: A comparative study[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2011, 34(1): 94-109.
- [81] Han Y, Cai Y, Cao Y, et al. A new image fusion performance metric based on visual information fidelity[J]. Information Fusion, 2013, 14(2): 127-135.
- [82] Fan X. Automatic registration of multi-modal airborne imagery[M]. Rochester: Rochester Institute of Technology, 2011.
- [83] Livada B, Perić D. Imaging detector technology: A short insight in history and future possibilities[C]//7th International Scientific Conference OTEH. 2016.
- [84] Wen M, Wei L, Zhuang X, et al. High-sensitivity short-wave infrared technology for thermal imaging[J]. Infrared Physics & Technology, 2018, 95: 93-99.
- [85] Gaitanakis G. K, Vlastaras A, Vassos N, et al. InfraRed search & track systems as an anti-stealth approach[J]. Journal of Computations & Modelling, 2019, 9(1): 33-53.
- [86] Sandler M, Howard A, Zhu M, et al. MobileNetV2: Inverted residuals and linear bottlenecks[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2018: 4510-4520.

- [87] Zhao Y, Lv W, Xu S, et al. DETRs beat YOLOs on real-time object detection[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2024: 16965-16974.
- [88] Tang L, Yuan J, Zhang H, et al. PIAFusion: A progressive infrared and visible image fusion network based on illumination aware[J]. Information Fusion, 2022, 83: 79-92.
- [89] He K, Zhang X, Ren S, et al. Deep residual learning for image recognition[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2016: 770-778.
- [90] Ding X, Zhang X, Ma N, Han J, Ding G, Sun J. RepVGG: Making VGG-style convnets great again[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2021: 13733-13742.
- [91] 陈建明, 李定铨, 曾祥津, 等. 一种跨模态光学信息交互和模板动态更新的 RGBT 目标跟踪方法[J]. 光学学报, 2024, 44(07): 109-123.
- [92] Karim S, Tong G, Li J, et al. Current advances and future perspectives of image fusion: A comprehensive review[J]. Information Fusion, 2022.
- [93] Yang F, Wei H. Fusion of infrared polarization and intensity images using support value transform and fuzzy combination rules[J]. Infrared Physics & Technology, 2013, 60: 235-243.
- [94] Li X, Huang Q. Target detection for infrared polarization image in the background of desert[C]//2017 IEEE 9th International Conference on Communication Software and Networks (ICCSN). IEEE, 2017: 1147-1151.
- [95] Xiang K, Yang K, Wang K. Polarization-driven semantic segmentation via efficient attention-bridged fusion[J]. Optics Express, 2021, 29(4): 4802-4820.
- [96] Liu Z, Wang B, Wang L, et al. ShareCMP: Polarization-aware RGB-P semantic segmentation[J/OL]. arXiv preprint arXiv:2312.03430, 2023.
- [97] Vergara J. R, Estévez P. A. A review of feature selection methods based on mutual information[J]. Neural Computing and Applications, 2014, 24: 175-186.
- [98] Hore A, Ziou D. Image quality metrics: PSNR vs. SSIM[C]//2010 20th International Conference on Pattern Recognition. IEEE, 2010: 2366-2369.
- [99] Asuero A. G, Sayago A, González A. G. The correlation coefficient: An overview[J]. Critical Reviews in Analytical Chemistry, 2006, 36(1): 41-59.
- [100] Zhang J, Shao J, Chen J, et al. PFNet: An unsupervised deep network for polarization image fusion[J]. Optics Letters, 2020, 45(6): 1507-1510.

- [101] Morimatsu M, Monno Y, Tanaka M, et al. Monochrome and color polarization demosaicking using edge-aware residual interpolation[C]//2020 IEEE International Conference on Image Processing (ICIP). IEEE, 2020: 2571-2575.
- [102] Toet A. Natural colour mapping for multiband nightvision imagery[J]. Information Fusion, 2003, 4(3): 155-166.
- [103] Tan M, Nie R, Zhang G, et al. Deep learning-based infrared and visible image fusion: A survey[J]. Journal of Yunnan University (Natural Sciences Edition), 2023, 45(2): 326-343.
- [104] 唐霖峰, 张浩, 徐涵, 等. 基于深度学习的图像融合方法综述[J]. 中国图象图形学报, 2023, 28(01): 3-36.
- [105] Piella G. A general framework for multiresolution image fusion: From pixels to regions[J]. Information Fusion, 2003, 4(4): 259-280.

