

分类号: TP391
学校代码: 11065

密级: 公开
学号: 2020025802

青 岛 大 学

专业硕士学位论文

(统招全日制)

面向室内盲人轨迹信息挖掘与指令预测研究

作者姓名	史安朔
指导教师	李建波 教授
专业领域	计算机技术
培养单位	计算机科学技术学院
答辩日期	2023 年 6 月 1 日

摘要

随着时间推移,室内盲人导航辅助领域在全球范围内变得越来越重要。虽然对于公共场所的盲人导航方面有一些传统的导盲设施,但是室内导航工具和技术相对匮乏。本文研究的重点是为盲人在室内环境下安全行走提供帮助。目前已经存在一些室内盲人导航辅助设备,如语音交互导航系统、振动导航手环等,但是这些设备仍然存在许多问题。首先,技术上的限制导致了这些设备的准确度、精度等方面仍然不能完全满足盲人用户的需求。例如,语音交互导航系统往往存在语音识别难题,导致指令不准确或难以操作;振动手环也存在指示不精准、震动强度不够明显等问题。这些缺陷都表明室内盲人导航辅助技术的研究需要更加深入,本文的目的是实现实时监控,提前触发早期警报或者采取有效预防措施,合理的帮助盲人安全的按照正确轨道行走。

盲人指令预测是一项具有重大挑战性的研究。本文提出了一种实时预测盲人指令的方法,该方法的实时性可以很好地解决许多现实问题。这项工作的主要贡献如下:(1)本文提出了一种用于盲人轨迹预测的时空模型(BlindTPM)。空间卷积块捕捉道路和障碍物的空间相对特征。该模型结合了盲人独特的位置变化特征来实现轨迹预测任务。根据盲人的缓慢动作,该模型设计的时间卷积块可以捕获行人轨迹的长期历史信息。(2)本文以盲人的历史轨迹数据,标准盲道轨迹为数据输入,设计了模型 BlindIPN 来实现对于盲人下一时间步的行走指令预测。该方法融合了历史轨迹、标准盲道轨迹中的时序特征,并采用 BlindTPM 对于空间中障碍物分布的空间特征进行分析,可以有效实现对于未来一个时间步导航指令的精准预测,BlindIPN 模型中使用 ResNet-V 来简化网络训练,在大幅度加深网络的同时可以获得较高的精度。(3)本文在 BlindTPM 模型基础上添加了集成学习的模块,利用不同的拓扑结构、不同的超参数设置、不同的训练数据等不同的影响因素构建多个神经网络,然后将它们结合成一个鲁棒性更优的模型,提高指令预测的准确率。

关键词: 导航辅助; 室内轨迹; 避障算法; 指令预测; 集成学习

Abstract

With time passing, the field of assistive technology for blind people indoors is becoming increasingly important worldwide. While there are some traditional guideposts for blind people in public places, there is a relative lack of indoor navigation tools and technologies. The focus of this study is to provide assistance to blind people in walking safely indoors. Currently, there are some indoor assistive devices for blind people, such as voice-driven navigation systems and vibration navigation bands, but these devices still have many problems. First of all, technical limitations cause these devices to still not fully meet the needs of blind user community in terms of accuracy and precision. For example, voice-driven navigation systems often have difficulties with speech recognition, resulting in instructions that are not accurate or difficult to operate. Vibrating bands also have problems with indicating precision and vibration intensity being too weak. These defects indicate that research on indoor assistive technology for blind people needs to be deeper, and the aim of this study is to achieve real-time monitoring, trigger early alarms or take effective prevention measures to reasonably assist blind people in walking on the correct track.

Command prediction for blind people is challenging research. We propose a real-time prediction method for blind instructions. The real-time performance of this method can well solve many practical problems. The main contributions of this work are as follows. (1) We propose a spatiotemporal model (BlindTPM) for blind trajectory prediction. Spatial convolution blocks capture the spatial relative characteristics of roads and obstacles. The model combines the unique position change characteristics of blind people to realize the trajectory prediction task. According to the slow motion of the blind, the time convolution block designed by the model can capture the long-term historical information of the pedestrian track. (2) Based on the historical track data of the blind and the standard blind track as the data input, we designed the BlindIPN model to predict the walking instructions of the blind in the next time step. This method combines the temporal characteristics of the historical track, the standard blind track and the BlindTPM to consider the spatial characteristics of the obstacle distribution in space, which can effectively achieve the accurate prediction of the next time step navigation command. The BlindIPN model uses ResNet-V to simplify the network training, which can greatly deepen the network while obtaining high accuracy. (3) In this paper, the module of ensemble learning is added to BlindTPM to build multiple neural networks using different topologies, hyperparameter settings, training data, and other influencing factors, and then combine them into a model with better robustness to improve the accuracy of instruction prediction.

Keywords: navigation assistance; indoor trajectory; avoidance algorithm; command prediction; ensemble learning

目 录

第一章 绪论.....	1
1.1 研究背景及意义.....	1
1.2 国内外研究现状.....	1
1.2.1 室内盲人导航现状.....	1
1.2.2 盲人轨迹预测现状.....	2
1.2.3 盲人指令预测现状.....	3
1.3 主要研究内容.....	4
1.4 论文组织结构.....	4
第二章 相关理论基础	6
2.1 室内盲人行为相关概念定义	6
2.1.1 基础定义.....	6
2.1.2 时空数据定义.....	6
2.2 盲人预测经典模型.....	7
2.2.1 基于历史轨迹的神经网络预测模型.....	7
2.2.2 基于网格标签的神经网络预测模型.....	7
2.3 深度学习理论.....	7
2.3.1 卷积神经网络.....	7
2.3.2 循环神经网络.....	8
2.3.3 长短时记忆神经网络.....	9
2.3.4 时间卷积神经网络.....	11
2.3.5 注意力机制.....	13
2.4 本章小结.....	13
第三章 应用于盲人轨迹预测的深度学习模型	15
3.1 数据设计.....	15
3.1.1 横纵坐标法.....	15
3.1.2 网格图法.....	16
3.1.3 障碍物分布.....	18
3.2 模型设计.....	20
3.2.1 空间卷积块.....	20
3.2.2 障碍物网格空间分布.....	21
3.2.3 时间卷积块.....	22
3.2.4 估算块.....	23
3.3 实验对比.....	24
3.3.1 数据准备	24

3.3.2 实验设计	25
3.3.3 实验分析	26
3.3.4 障碍物分布网络	27
3.3.5 扩展分析	28
3.4 本章小结	29
第四章 盲人导航指令预测	30
4.1 问题概述	31
4.2 盲人导航指令预测方法	31
4.3 实验	33
4.3.1 数据描述	33
4.3.2 实验分析	33
4.4 本章小结	37
第五章 基于集成学习的盲人行走指令预测	38
5.1 盲人行走指令预测方法	38
5.1.1 基于横坐标和纵坐标轨迹的预测方法	38
5.1.2 网格地图预测法	38
5.1.3 指令	39
5.2 模型概述	41
5.2.1 空间卷积模块	42
5.2.2 时间卷积模块	43
5.2.3 集成学习模块	44
5.3 实验	45
5.3.1 数据准备	45
5.3.2 实验分析	46
5.4 本章小结	49
第六章 总结与展望	50
6.1 工作总结	50
6.2 未来展望	50
参考文献	52

第一章 绪论

1.1 研究背景及意义

根据世界卫生组织对盲人情况作的估计,预计到 2030 年时世界视力有缺陷的人将达到约 2500 万。盲人数量日益增长,这已经成为了严重的社会公共问题之一。盲人的生活质量越来越受到人们的关注^[1-3]。全球范围内,公共场所盲人导航仍采用传统的方法,需要大量人力进行引导,不适应现代社会的智能化生活。目前,常用的盲人导航技术有超声波导航和 GPS 导航^[4-7]。超声波导航仅能感知障碍物,不能提供正确行走的路线。GPS 导航在室外有较好的表现,但在室内精度不足。因此,对于室内导航工具和技术还很匮乏^[8-9]。

本研究旨在解决盲人在室内出行过程中的安全性问题。尽管有室内盲人轨迹预测与避障技术,但在盲人出行中,依然需要辅助设备发出运动指令以确保安全到达目的地。本研究提出一种时空模型和指令避障算法来预测盲人运动轨迹,并解决实时性较强的指令避障问题。通过在线学习盲人轨迹模式,推断他们的轨迹并预测盲人将要接受的指令,从而在监控系统中为盲人提供早期警报和有效预防措施,帮助盲人安全出行并按照正确轨道行走。

本研究的意义在于提高盲人在室内出行的安全性与实用性。在室内公共场所导航方面,传统的方法需要大量人力支持,且准确度不高,不能满足盲人的需求。现有的盲人导航技术有一定的局限性,如超声波导航和 GPS 导航等,都有着不同程度的缺陷。因此,有必要研究一种更为准确、智能、实用的盲人室内导航技术,以提升盲人在室内出行的安全性和自主性,帮助盲人更加安全、顺畅地在室内出行。该研究对于促进盲人增强自主能力,提高其生活质量和安全水平,具有重要的科学研究和现实意义。

1.2 国内外研究现状

1.2.1 室内盲人导航现状

随着城市化进程的加速,城市建设中的无障碍环境越来越受到人们的重视,而其中一个需要解决的难题就是室内盲人导航问题。目前,室内导航技术与系统已经得到了一定的发展,但仍存在许多问题待解决。

一方面,室内导航技术目前主要采用了各种传感器,如全球定位系统(GPS)、惯性导航(IMU)、激光雷达、摄像头和声纳等^[10-12],并结合了人工智能和机器学习

等技术,来感知和理解环境^[13-15]。这些技术有一定的优点,如精度较高、实时性强、能够渗透建筑物墙壁等,但同时也存在一些问题。例如,GPS 在室内灵敏度不够、高楼层起伏较大时易受到地形遮挡而误差较大;IMU 易受到长时间使用和环境干扰等问题而累积误差逐渐增大;激光雷达在精度和成本上存在矛盾,并不能完全适用于室内导航等等。

另一方面,室内盲人导航系统建设也存在一些问题。首先是建筑物室内地图不完善和维护成本高的问题。建筑物复杂的布局和内部结构,需要完整准确的地图来实现导航。因此,如何制作和维护室内地图是一个非常困难的问题。其次是系统设计和使用的不够人性化的问题。目前的用户界面和交互方式通常需要用户在操作中付出较大的努力和学习成本,这使得部分盲人用户难以直接使用。同时,由于室内环境的复杂性,导航系统需要考虑到各种复杂情况,如楼层间的高低差、门的打开角度以及紧急情况等。

想要解决室内盲人导航问题,技术方面需要进一步研究和发展。要探索更多有效的感知技术和机器学习算法,提高定位精度和实时性,减少误差。研究人性化的交互方式,实现更直观、自然的导航操作体验。其次,在地图数据方面,需要加强地理信息技术和大数据技术的应用,利用建筑物地图和用户轨迹数据等,采用自动化算法生成、更新和维护室内地图数据,降低制作成本。最后,在人工智能普及和政策支持方面,各界需要给予更多的关注和支持,推动科技发展服务社会的同时,为盲人群体营造更加友善的社会环境。

有人提出基于机器学习的实时引导和对象识别:利用室内定向和引导导航来增强盲人和严重视觉障碍(Blindness or Severe Visual Impairment, BSVI)人群的电子旅行辅助(Electronic Travel Authorization, ETA)^[16-17]。GPS 不能很好地工作,而且缺乏基础设施投资,或者室内导航安装成本太高。专门的可穿戴传感 ETA 设备、深度相机、智能手机、计算机视觉算法、触觉和音频接口以及计算智能算法都可以被用于室内盲人导航方面。将感兴趣点(如楼梯、门、卫生间、入口/出口)的语义数据与疏散方案相结合,可以使所提出的方法对 BSVI 用户更具吸引力。

1.2.2 盲人轨迹预测现状

近年来,随着人工智能的发展,深度学习技术出现在各类研究中,例如自然语言处理^[18-21]、计算机视觉^[22-24]、语音识别^[25-26]等。在海量数据的催化下,一些研究开始使用深度学习的算法进行盲人轨迹相关的研究。在数据驱动的预测任务中,Liu 等人^[27]介绍了 RNN 一项工作,提出了一种称为时空递归神经网络(Space-Time Recurrent Neural Network, ST-RNN)的全局预测模型,用于预测用户下一步的去向。

空间和时间被划分为离散的单元，以产生特定于时间和特定于距离的转换矩阵。对于一个时间单元中的每个特定时间值，以及对于每个特定空间值，计算对应的转换矩阵。与 ST-RNN 不同的是，本文主要是基于位置信息预测指令，所以本文重点关注了空间信息，在本文的模型中构建了局部与全局预测因子，分别对所有盲人的历史轨迹与室内场景规划轨迹的空间特征进行了提取。

Bartoli 等人^[28]通过提供目标行人到空间中静态物体的距离的长短期记忆模型（Long Short Term Memory, LSTM）以及网格地图形式的人与人之间的上下文，或者邻居的隐藏编码来考虑环境中上下文关系。Lee 等人^[29]通过从条件变分自动编码器中采样规划轨迹来预测行人的运动。他们根据未来的相互作用对轨迹进行评分，从而选择最合理的轨迹，并通过在占用栅格图中使用卷积神经网络对其进行编码来考虑环境。基于当前的这两个工作，本文把盲人的轨迹变分为栅格的形式，对栅格进行细分自动编码，再进行卷积操作，提高空间的特征强度以及加强环境中上下文关系。文中也对指令进行了编码，构建用数字表示指令状态的形式，这样更有利于模型的预测，提高预测的精度与速度。使呈序列化的预测指令精度更高。除了神经网络外，还提出了基于强化学习方法^[30]，高斯过程^[31]来预测行人环境。这种方法具有直观性、简单性和理论性，但是它的推广功能较弱。更关键的是，它只是模拟行人的短时反应速度，无法影响长期的位置信息。特别是在室内盲人指令预测领域研究的成果并不多见。

Lv 等人^[32]首次将时间卷积网络（Temporal Convolutional Network, TCN）应用于轨迹预测领域，其模型中一个卷积层可以计算出时间网络层需要的更深层的轨迹空间特征，并且拥有更高的精度与训练速度，增强非线性轨迹的权重，全局局部估计层取代了传统的线性方法。本文模型也沿用了 TCN 的优势，对捕捉到的网格特征、盲人历史轨迹特征以及规划轨迹的空间特征进行了融合。

1.2.3 盲人指令预测现状

在保持系统效率的同时获得自适应的路径指令，Cuayáhuatl 等人提出了一种两阶段的方法来学习分层寻路策略，采用分层强化学习^[33]，基于认知路标的机制，将多个连续指令组合成一个更紧凑的高阶指令^[34]，这样更便于引导盲人全程通过。Andrea 等人^[35]提出了一个自然语言生成模型，在提供室内路径指令的背景下，利用结构化且语法正确的路径指令。Cuayáhuatl^[36]提出了一种快速强化学习路径指令策略的方法。这种方法将问题分解为子问题，以便提前（即在用户-机器交互之前）学习低级行为，并在运行时学习高级行为，最后产生高级行为的指令。本文认为具有语法结构化的命令只应对正常人，所以本文没有采用自然语言处理的语法结构化模块，

而选择了对盲人友好的简单指令。

Zhong 等人^[37]提出了集成学习，它通过构建多个教学器，并将它们结合起来，从初始练习集中锻炼出某个基学习器，然后依据基学习器的特点，对样本布局加以调节，以便让先前做错的样品在未来获得更多的注意力，从而锻炼出更好的基学习器，反复训练，直至基学习器数量到达预期的值，或者整体实现结果满足预设要求^[38]，才能完成学习任务。

1.3 主要研究内容

盲人指令预测是一项具有重大挑战性的研究，本文旨在探讨室内盲人指令预测问题。首先针对盲人的室内的出行任务提出了一种轨迹预测的时空模型与指令避障算法，通过过去的轨迹序列来学习轨迹模式，其次在这个轨迹预测模型的基础上提出了一种针对盲人在室内场景的指令导航预测模型，最后在这个指令导航预测模型的基础上进行改进，加入了集成学习的模块，提出了新的模型，使得指令预测准确率更高，最后模型的性能得到了全面的检验。本文工作的主要研究内容如下：

- 本文提出了一种用于盲人轨迹预测的时空模型 (BlindTPM)。该模型使用空间卷积块来捕捉道路和障碍物的空间相对特征，并通过结合盲人独特的位置变化特征来实现轨迹预测任务。该模型特别设计了时间卷积块，以捕获行人轨迹的长期历史信息。
- 针对上述研究，本文提出了一种盲人轨迹命令预测模型(BlindIPM)。用于室内场景中的盲人接受指令预测与轨迹预测任务。BlindIPM 主要由两部分组成，它们分别是用于提取轨迹点空间特征信息的空间卷积层和用于对时序依赖性进行计算的 TCN。
- 本文引用了基于集合的方法以及集成学习的方法解决了数据集分布不均导致模型结果离散的问题，提出了 BlindPCN 模型，用于提高预测准确率。本文在数据集上进行了交叉验证，并用典型的时空模型、传统的循环神经网络和传统的机器学习方法作为基线进行验证。在优化所有基线的超参数之后，实验结果表明本文的方法和模型最优。

1.4 论文组织结构

论文总共分为六章，具体章节安排如下：

第一章为绪论部分。本文旨在深入探讨室内盲人导航技术的研究背景及其重要意义，并对国内外室内盲人导航、行人轨迹预测以及行人指令预测等方法进行了详细的分析，从而揭示出各种方法的优缺点，并阐述了本文的研究内容及其创新点，

最后，本文的结构和内容也将得到详细的阐述。

第二章为相关理论基础。首先对室内盲人行行为相关概念给出了定义，介绍了时空数据以及时空数据在室内盲人行行为研究中的应用，给出了本文中使用的两种数据集，并进行了详细的介绍。然后介绍了在室内盲人导航研究领域比较典型的模型，分析了每个模型的优缺点。最后详细介绍了近期比较受欢迎的深度学习方法中的经典模型如卷积神经网络、时间卷积神经网络、注意力机制等。

第三章主要介绍了基于时空卷积网络的运动轨迹预测模型。模型使用了空间卷积神经网络和时间卷积神经网络来分别研究交通轨迹数据的空间特性和时间特性，最后在真实数据集上与其他预测模型进行比较，验证了本文模型的有效性。

第四章主要介绍了面向室内场景的盲人轨迹与指令预测，并对模型的架构进行了详细的阐述，同时进行了大量的实验分析，证明了本文的时空模型在处理时间预测问题时具有较好的预测性能。

第五章主要介绍了面向室内场景的盲人导航指令预测，加入了集成学习的知识，通过数据实践证明有较好的准确率。

第六章对本文的研究进行了深入的总结，指出了目前研究中存在的问题，并提出了有效的改进建议。

第二章 相关理论基础

2.1 室内盲人行为相关概念定义

2.1.1 基础定义

在室内环境下，盲人不能依赖视觉感知环境信息，因此他们需要通过其他方式来导航和行动。以下是一些关于盲人在室内环境下的行为的关键点：

- 盲道：指专门为盲人设计的道路设施，包括转弯处的特殊处理与指引盲人前行的反光带等。
- 视力障碍：指眼睛无法看到或理解视觉信息的障碍，包括盲、弱视、视神经损伤等。
- 感知：盲人通过感知来感知室内的环境，例如通过触摸、听觉和嗅觉来感知室内的物体和空间。
- 语音识别技术：语音识别技术可以将语音转化为文本，使计算机可以听懂人的语音指令。这种技术可以帮助盲人更加高效地使用计算机和其他设备，同时也为盲人提供了一种更加安全的方式来与计算机进行交互。
- 语音合成技术：语音合成技术可以将计算机生成的文本转化为语音，以便盲人可以听到指令，与盲人进行交互。例如，计算机可以向盲人提供语音提示，告诉他们已经完成了某个任务。

室内盲人行为指的是盲人在室内环境中的行走方式和特征。这些特征在很大程度上受到室内环境的影响，例如建筑物的布局、家具布置、地面状况^[39]等。由于盲人没有视觉，他们需要依靠其他感官来导航，如听觉、嗅觉、触觉和身体平衡。智能导航系统是帮助盲人在室内环境中更加安全和顺畅地移动的重要手段。这些系统可以通过语音合成技术为盲人提供指令和提示，帮助他们顺利地移动和探索室内空间。通过了解盲人的行为特征，研究室内盲人行为并开发智能导航系统，以帮助盲人在室内环境中更加安全和顺畅地移动，帮助盲人更好地适应室内环境，提高他们的生活质量。

2.1.2 时空数据定义

时空数据是指室内盲人行为的空间和时间信息。它是通过记录盲人在室内环境中的移动轨迹、速度和方向来表示的。时空数据是室内盲人行为研究的重要数据来源，时空数据还可以用于评估室内环境的适宜性，是深入了解室内盲人行为的关键。

时空数据可以通过多种方法收集,例如通过 GPS、激光扫描仪、视觉追踪系统等设备来记录盲人的位置和移动情况^[40-42]。此外,也可以通过问卷调查和观察研究来获取盲人的行为信息。不同的数据收集方法具有不同的优缺点,因此需要选择合适的数据收集方法。通过时空数据的分析有助于了解室内盲人的行为特征。例如,本文可以通过时空数据分析来研究盲人在室内环境中的移动特征,如行走速度、路径特征^[43]等。这些信息对于更深入地了解室内盲人行为具有重要意义。

2.2 盲人预测经典模型

2.2.1 基于历史轨迹的神经网络预测模型

在机器学习应用领域,各种各样的指标有着多样的维度和单位^[44-45],想要更好地比较它们相互之间的差异,本文需要将它们进行标准化^[46],以便更好地反映实际情况。例如,想要更准确地表示盲人的位置,本文可以使用浮点数来表示,这样可以更好地反映实际情况。如公式 2-(1)所示。其中 μ 为平均值, σ 为标准差。这样能消除数据的影响。

$$x_{norm} = \frac{x - \mu}{\sigma} \quad 2-(1)$$

2.2.2 基于网格标签的神经网络预测模型

由于盲人行走速度缓慢,轨迹的横纵坐标随时间步长变化比较小,盲人的位置改变比较缓和^[47]。因此本文在基于历史轨迹的神经网络预测模型基础上加入了把轨迹点划分为网格标签的计算方法^[48-50]。此外,为了减小基于网格点规划方法的计算复杂度,可以采用自由配置空间 Cfree 的多分辨率网格表示。从概念上讲,如果以网格点为中心的直线单元的任何部分碰到了障碍物,则网格点被认为是一个障碍。为了改善障碍的表现,一个障碍单元可以被细分成更小的单元。原始单元的每一个维度都可以分成两部分,形成 2^n 个子单元。任何包含障碍的单元还可以继续分裂,直到合适的最大分辨率^[51]。这种表示方法的优势是只有靠近障碍物的空间改变为高分辨率,而那些远离障碍物的空间仍然由粗糙的分辨率表示。这可以使路径规划器用最小步长通过杂乱的空间,而使用大步长通过宽阔的空间。

2.3 深度学习理论

2.3.1 卷积神经网络

卷积神经网络（CNN）是深度学习领域中的一种常见模型。其可学习内容包含了权重和偏置量，主要应用于图像识别和分类等领域^[52]。CNN 模型可以通过局部感受野、设置池化层和权值共享来提取图像特征，具有广泛的应用前景。CNN 模型的主要由以下四个部分构成：

（1）卷积层是一种复杂的数学模型，由众多卷积单位构成，各个卷积单位都含有多种基本参数，采用反向传播方法，能够精确定位各个卷积单位，从而提取出图像中的复杂特征。

（2）激励层：用于对卷积层的输出结果进行非线性映射的一层。通常会使用 ReLU（修正线性单元）作为激活函数。ReLU 函数具有快速收敛、计算效率高等优点。ReLU 函数的定义公式 2-(2)，ReLU 函数的图像如图 2.1 所示。

$$f(x) = \max(0, x) \quad 2-(2)$$




图 2.1 ReLU 函数示意图

（3）池化层：主要用来将图像特征进行降维，减少参数量和简化网络的复杂程度。在训练过程中减少网络参数量能够减小运算量，在一定程度上抑制过拟合现象的发生。其中最大池化法和平均池化法，应用较为广泛。

（4）全连接层：将所有获得的局部特征进行结合，获得所提取的全局特征。

2.3.2 循环神经网络

传统的神经网络只考虑当前输入对结果的影响，而没有考虑其它时刻输入的影响。然而，循环神经网络记忆当前网络层前面的信息，并且运用到当前的输出信息的计算中^[53]。具体来说，RNN 在时间步长 $t-1$ 的输出会影响 RNN 在时间步长 t 的输出，考虑了时间维度的相关性。RNN 处理连续序列数据的场景，表现良好。如在文本生成、机器翻译、视频处理、语音识别等领域，表现出很好的应用前景^[54-55]。RNN 的结构图如图 2.2 所示，




图 2.2 RNN 模型结构图

相关数学公式描述为:

$$S_t = f(W * S_{t-1} + U * X_t + b) \quad 2-(3)$$

W 、 U 为权重向量, S_{t-1} 为输入样本在 $t-1$ 时刻的记忆, X_t 为 t 时刻的输入变量, b 为偏差, $f(x)$ 为激活函数。虽然 RNN 在处理时间序列数据方面表现出色, 但是随着训练时间的延长, 梯度消失和梯度爆炸的发生率也会大幅提升。因此, 后来出现了一系列的改进算法: 长短时记忆网络 (LSTM)^[56] 和门控循环单元 (GRU)^[57]。它们分别使用特殊的存储方式来存储记忆, 面对时间比较长、记忆量比较大的数据时, 在一定程度上能够解决梯度消失的问题和梯度爆炸的问题。

2.3.3 长短时记忆神经网络

LSTM 在 RNN 的基本上添加了一种新的存储器模块, 它由输入门、遗忘门和输出门三个部分构成, 以满足不同的存储需求。输入门控制保存在存储单元中的输入信息容量。遗忘门控制上一时刻到下一时刻的信息量。输出门控制信息输出信息的容量。“门”采用了 sigmoid 激活函数, 它与 tanh 激活函数有着相似的特性, 但是它不是在 -1 到 1 之间进行压缩, 而是在 0-1 之间进行压缩, 这样可以更好地更新或者忘记数值。这种“门”结构能够解决梯度消失、爆炸的问题, 能够用来处理长时期数据信息。LSTM 是目前使用最多的来处理时序数据的算法之一, 已经成功运用于涉及一系列序列数据的问题中, 如语音识别^[58]、图像处理^[59]、机器翻译^[60]等。LSTM 模型结构图如图 2.3 所示, 并对图中各个门进行了详细介绍。




图 2.3 LSTM 模型结构图

遗忘门是一个重要的决策因素，如公式 2-(4)所示，它决定了哪些信息可以从单元状态中被抛弃，哪些可以被保留，并且可以根据上一时刻的输出和当前时刻的输入，计算出相应的向量。输入门的 sigmoid 层决定着需要更新的信息，tanh 层包含着备选的更新信息内容，如公式 2-(5),2-(6),2-(7)所示，这两个层相结合构成输入门。决定有哪些信息能够被保存到存储单元，并且得出新的细胞状态。输出门决定着当前单元状态中有哪些信息能够输出到 h_t ，如公式 2-(8),2-(9)所示。

$$f_t = \sigma(W_f[h_{t-1}, x_t] + b_f) \quad 2-(4)$$

$$i_t = \sigma(W_i[h_{t-1}, x_t] + b_i) \quad 2-(5)$$

$$\tilde{C}_t = \tanh(W_C[h_{t-1}, x_t] + b_C) \quad 2-(6)$$

$$C_t = f_t * C_{t-1} + i_t * \tilde{C}_t \quad 2-(7)$$

$$o_t = \sigma(W_o[h_{t-1}, x_t] + b_o) \quad 2-(8)$$

$$h_t = o_t * \tanh(C_t) \quad 2-(9)$$

在后来的研究中，又提出了几种 LSTM 的变种模型，其中门控循环单元网络（GRU）较为经典。GRU 仅有两个门结构，一个更新门和一个重置门，模型结构如图 2.4 所示。它不使用单元状态，而是通过隐藏状态来传输信息。因此与 LSTM 相比，GRU 结构简单，更容易进行训练，并且很大程度上提高训练速率。




图 2.4 GRU 模型结构图

重置门决定着需要遗忘的上一时刻输出结果中的信息，如公式 2-(10)所示。更新门类似于 LSTM 的输入门和更新门，如公式 2-(11)所示，决定着上一时刻的输出结果以及当前的输入信息中有多少需要继续向下传递。通过使用重置门，过去相关的信息将被存储在新的记忆内容中，如公式 2-(12)所示。在最后一步中，通过更新门，如公式 2-(13)所示，可以确定当前单元的信息以及前一时刻输出信息中需要保存的内容，从而得出最终门控循环单元的输出结果，并将其传递给下一个单元，以实现更有效的控制。

$$r_t = \sigma(W_z \cdot [h_{t-1}, x_t]) \quad 2-(10)$$

$$z_t = \sigma(W_z \cdot [h_{t-1}, x_t]) \quad 2-(11)$$

$$\tilde{h}_t = \tanh(W \cdot [r_t * h_{t-1}, x_t]) \quad 2-(12)$$

$$h_t = (1 - z_t) * h_{t-1} + z_t * \tilde{h}_t \quad 2-(13)$$

2.3.4 时间卷积神经网络

传统的卷积网络受卷积核大小的限制，不能处理长时间的信息依赖关系。后来在 2018 年提出了一种特殊的卷积神经网络—时间卷积神经网络 (TCN)^[61]。TCN 有两个主要特点：一、过去和未来的信息存在因果关系。二、输入序列与输出序列之间等长度映射。在时间卷积神经网络模型中，一般使用因果卷积模型来处理序列问题。

因果卷积^[62]的定义：滤波器 $F = (f_1, f_2, \dots, f_K)$ ，序列 $X = (x_1, x_2, \dots, x_T)$ ，在 x_t 处的因果卷积为：

$$(F * X)_{(x_t)} = \sum_{k=1}^K f_k x_{t-K+k} \quad 2-(14)$$

因果卷积有两个显著的特征。首先，不考虑未来的信息，当通过给定的输入序

列 $\{x_1, x_2, \dots, x_t\}$ 来预测 $\{y_1, y_2, \dots, y_t\}$ 时，仅能通过观测完成的序列 $\{x_1, x_2, \dots, x_t\}$ 来预测 y_t ，而不能通过 $x_{t+1}, x_{t+2}, \dots$ ，此外，隐藏层的数量随着历史信息数量的增加而增加。

对于时间更长的历史数据，只通过因果卷积无法完成效果比较好的预测任务。针对此问题，Wei 等人^[63]提出了一种新的方法，即加入空洞卷积，以提高感受野，从而更好地预测长时间的数据。与标准卷积相比，空洞卷积还添加了一种超参数增长因子，从而更有效地提升预测精度。




图 2.5 空洞因果卷积示意图

空洞卷积的定义：滤波器 $F = (f_1, f_2, \dots, f_K)$ ，序列 $X = (x_1, x_2, \dots, x_T)$ ，在 x_t 处膨胀因子 d 的空洞卷积为：

$$(F_{*d}X)_{(x_t)} = \sum_{k=1}^K f_k x_t - (K - k)d \quad 2-(15)$$

空洞卷积的感受野大小为 $(K-1)D+1$ 。因此，本文可以通过提高 K 和 d 这两种方法来增加空洞卷积的感受野大小。在实际使用过程中，膨胀因子 d 随着网络层数的增加以 2 的指数倍增加(即网络的第 n 层 $d = O(2^n)$)。空洞卷积的优点是通过增加了感受野，确保某些滤波器可以命中访问有效历史数据中的每个输入信息，从而使每个卷积的输出包含了非常大范围的历史信息。空洞因果卷积的示意图如图 2.5 所示，该卷积的膨胀因子 $d=1, 2, 4$ ，滤波器的尺寸大小为 2，输出值 y_t 能够包含输入序列的所有值。




图 2.6 残差网络结构图

TCN 的感受野依赖于网络深度、滤波器的尺寸大小以及膨胀因子。由于随着网络层数的增加，TCN 可以提取更多的特征信息，因此更大、更深的 TCN 的稳定性十分重要。而对于深度非常深的卷积神经网络，通过激活函数（如 RELU）和批处理归一化，会削弱网络的训练效果。但是对于大型数据集而言，本文需要使用更深层次的网络架构来学习时空相关性。为了解决这一问题，提出了残差网络的思想，结构如图 2.6 所示。在设计通用 TCN 模型时，使用残差模块来代替卷积层。残差模块提供了两种输出方法，恒等映射输出和卷积分支输出^[64]。通过添加一个恒等映射，残差网络以元素方式连接网络的输入和输出。当网络足够深时，前面的数据信息可以通过恒等连接跳过一个或多个非线性层。这种方式的优点是网络的计算量小以及不产生额外的参数，可以提高网络的训练速度以及模型的训练效果。

2.3.5 注意力机制

人类的注意力机制在图像、语音和文本处理等领域得到了广泛应用^[65-67]，这些应用可以归因于注意力机制的基本原理。人们的大脑信号通过注意力机制处理，在对所获取的图片信息进行扫描时，着重关注重点区域，并且对这一区域中的重要细节信息进行投入较多的注意力，而忽略其他的无关信息。通过注意力机制的使用，提高了对所获取信息进行处理过程的效率，并且提升了信息处理的准确性。

注意力机制以编码器-解码器（Encoder-Decoder）模型框架为基础进行了改进，定义如下： $\{X\}$ 表示输入序列， $\{Y\}$ 表示输出序列。编码器是同时包括前向和后向隐含层状态的一种双向 RNN 网络结构。解码器是对所有输入序列的加权求和，其中包含着一个对齐模型，通过对输入序列与输出序列进行对齐匹配，得到相应的对齐分配向量。在训练过程中，解码器会与整体网络模型的其他部分联合训练。

2.4 本章小结

在本章中，本文定义了与室内盲人行为相关的各种概念，包括基本定义和时空

数据的定义。本文还介绍了两种基于历史轨迹和网格标签的神经网络预测模型。在这里，本文探讨了深度学习的理论基础，包括卷积神经网络（CNN）、递归神经网络（RNN）、长期记忆网络系统（LSTM）、时间卷积神经网络和注意力机理。

室内盲人行为的定义及其相关概念提供了对问题及其背景的清晰理解。神经网络预测模型介绍了预测室内盲人行人行为的两种常用方法，深度学习理论部分提供了最流行的深度学习算法及其应用的全面概述。

在下一章中，本文将介绍本文的研究方法，包括数据收集和预处理、模型实现和评估方法。这些将成为本文探索室内盲人行人行为预测的基础。

本章为本文的研究奠定了理论基础，并全面概述了与室内盲人行人行为预测相关的概念和理论。本文的目标是进一步探索这一领域，以更好地理解室内盲人行为，并改善视觉障碍者的导航设备。

第三章 应用于盲人轨迹预测的深度学习模型

在本章中，本文提出了基于盲人过去一段时间的行走轨迹进行未来一段时间盲人轨迹预测的深度学习模型(Blind Trajectory Prediction Model, BlindTPM)。该模型可以基于三种数据的驱动实现未来一段时间的轨迹预测，并且在第三种数据设计方法中，本文增加了障碍物的设计，以此来模拟实际应用场景，增加模型的实用性。

3.1 数据设计

本文设计了三种数据驱动的方法来完成盲目的轨迹预测任务，包括基于横、纵坐标的轨迹预测方法、基于网格图的轨迹预测方法和基于障碍物分布的网格图的轨迹预测方法。

3.1.1 横纵坐标法




图 3.1 基本轨迹位置。位置点随时间变化；X 和 Y 分别表示位置的横坐标和纵坐标

如图 3.1 所示，在本方法中，本文使用横、纵坐标来表示盲人的位置。其中， $X = \{x_1, x_2, x_3, \dots, x_t\}$, $Y = \{y_1, y_2, y_3, \dots, y_t\}$ 。因为这项工作是针对室内固定的盲动场景，所以X和Y是相对于固定原点的位置，而不是经纬度。 t 是盲区位置变化的时间步长。这种方法实现了最基本的轨迹预测任务，即用 t 个时间点的连续位置来预测未来的 $t + n$ 个时间点的位置，实现过程如下所示：

$$(X', Y') = \sigma'(BRT\{(\sigma(X, Y))\}) \quad 3-(1)$$

其中， $X' = \{x_{t+1}, x_{t+2}, x_{t+3}, \dots, x_{t+n}\}$, $Y' = \{y_{t+1}, y_{t+2}, y_{t+3}, \dots, y_{t+n}\}$ 。BRT是数据建模方法。 σ 和 σ' 分别代表数据标准化和去标准化过程。在机器学习方面，各种各

样的指标有着各种各样的维度和单位，为了更好地比较它们之间的差异，本文需要对数据进行标准化处理。为了更准确地反映盲区位置，本文采用 Z-score 作为数据标准化的方法，它可以将横坐标和纵坐标都转换为浮点数，并且可以有效地减少数据变化的范围，如公式 3-(2)所示。 μ 代表整体数据的平均值， δ 代表整体数据的标准差。Z-score 的计算过程简单，且消除了数据大小的影响。

$$Z = \frac{(X|Y) - \mu}{\delta} \quad 3-(2)$$

3.1.2 网格图法

在图 3.2 中，正常人和盲人的行走轨迹显示出了明显的差异。两者的时间步长间隔相同，均为两秒，但是正常人的运动轨迹呈现出明显的线性变化。由于盲人在运动时需要不断探索道路，他们的轨迹可能会发生较大的变化，这种情况可以通过图 3.2 来表示，即盲人的横坐标和纵坐标在一段时间内保持不变。然而，这种情况会导致实际轨迹的权重计算过程中出现大量的重复，从而降低模型的准确性。

为了更好地处理盲人轨迹的数据集，本文采用了局部采样^[68]方法，即在横坐标和纵坐标中取消多个局部不变点，如图 3.3 所示，经过数据清理后，轨迹表现出了显著的特征，如图 3.4(a)所示。当室内环境被映射到网格上时，盲人的位置可以通过网格的标签来清晰地表示出来。而且，当室内环境的复杂程度较高，网格数量也较多时，模型将原本用于回归预测盲人轨迹的任务转变为分类任务。




图 3.2 盲人和正常人的轨迹特征差异：(a)轨迹横坐标随时间的变化曲线和(b)轨迹纵坐标随时间变化曲线




图 3.3 样本轨迹设计。左侧是原始轨迹，右侧是样本轨迹




图 3.4 盲人轨迹和网格标签之间的转换：(a)原始轨迹在地图中的分布和(b)轨迹的网格标签分布

将轨迹点划分为网格标签的计算方法如公式 3-(3)所示。网格标签所代表的坐标维度在本文中被设为 2。公式 3-(3)所示，为横、纵坐标转化为网格标签计算过程，并且它将坐标数据的正负值考虑在内。

$$l_i^{(x)} = \begin{cases} \left\lceil \frac{\max(X) - x_i + 1}{\alpha} \right\rceil, & x_i > 0 \\ \left\lceil \frac{|\min(X)| + x_i + 1}{\alpha} \right\rceil, & x_i < 0 \end{cases} \quad 3-(3)$$

根据上述方法，本文可以得到横坐标 ($l_i^{(x)}$) 和纵坐标 ($l_i^{(y)}$) 的网格标签。本文期望根据历史轨迹在未来获得盲人的 n 个位置，因此公式 3-(4) 中的 $L^{(x)}$ 和 $L^{(y)}$ 是序列数据，并且， $L^{(x)} = \{l_{i+1}^{(x)}, l_{i+2}^{(x)}, \dots, l_{i+n}^{(x)}\}$ ， $L^{(y)} = \{l_{i+1}^{(y)}, l_{i+2}^{(y)}, \dots, l_{i+n}^{(y)}\}$ 。一般来说，定位点可以用二维的横坐标和纵坐标来表示。在评估模型的准确性时，本文会考虑这一点。只有当横坐标和纵坐标的网格标签的预测值与实际时间步长相符时，本文才能认为模型是正确的。

$$(L^{(x)}, L^{(y)}) = \text{LogSoftmax}(\text{BRT}(X, Y)) \quad 3-(4)$$

空间分布对盲人室内行走至关重要，图 3.5（a）展示了实际室内环境中各种障碍物的分布情况，其中，黑色区域代表障碍物，而图 3.5（b）则是经过数据清理处理后，标准化的障碍物分布图，以更好地帮助盲人理解室内环境的变化。由于（b）中存在一定的信息错误，本文必须尽可能多地收集障碍物，以确保不会出现遗漏的情况。最终，本文将障碍物空间分布矩阵如图 3.5（c）所示，其中包含障碍物的网格区域被设置为 0，其余网格区域被设置为 1。

图 3.5 表示障碍物空间分布的矩阵：（a）实际室内场景中障碍物的分布，（b）脱敏后障碍物的空间分布网格，以及（c）表示障碍物分布的矩阵

基于图 3.5 (c) 中提供的障碍物空隙分配网格和网格连接性规律, 本文提出了一个新的计算, 用于计算有障碍物的网格间的联通性邻接矩阵, 具体实现如计算 1 所示, 可以有效地提高网格联通性。图 3.6(b) 展示由算法 1 的输出对称邻接矩阵 A 。它的对称性表现在, 无论是正向还是反向的交互, 网格相互之间的连接性都是一致的。然而, 假如某个方格中出现障碍物, 那么它将不再与其他方格相连, 而且它的 9 个方向也将不相连, 连通值也将被设定为 0。




图 3.6 网络连通性邻接矩阵设计 (a)障碍物网格之间的连通性和(b)网络连通性的邻接矩阵

算法 1：网络连通性邻接矩阵的计算算法

算法:

输入: 障碍物空间分布的集合, L ; 网格边长, N ;

输出: 网络连通性的邻接矩阵, A .

```

1  初始化一个 0 矩阵  $A$ ; 维度是  $(N^2 \times N^2)$ .
2  for each  $i \in [0, N^2 - 1]$  do
3      for each  $j \in [0, N^2 - 1]$  do
4          //确定当前网格是否为障碍网格
5          if  $L_i = 0$  then  $A_{ij} = 0$ 
6          else
7              if  $i = j$  then  $A_{ij} = 1$ 
8              else if  $L_j = 1$  then
9                  //确定前面的连接
10                 if  $j = i - N$  then  $A_{ij}, A_{ji} = 1, 1$ 
11                 //确定左侧的连接
12                 else if  $j = i - 1$  &  $i \% N \neq 0$  then  $A_{ij}, A_{ji} = 1, 1$ 
13                 else if  $j = i + 1$  then
14                     if  $i < N - 1$  then  $A_{ij}, A_{ji} = 1, 1$ 
15                     end if
16                 //确定右侧的连接。
17                 if  $i \% N \neq 2$  &  $i > N - 1$  then  $A_{ij}, A_{ji} = 1, 1$ 
18                 end if
19                 //确定左前方的连接。
20                 end if  $j = i - N - 1$  &  $i \% N \neq 0$  then  $A_{ij}, A_{ji} = 1, 1$ 
21                 //确定右前方的连接。
22                 end if  $j = i - N - 1$  &  $i \% N \neq 2$  &  $i > N - 1$  then  $A_{ij}, A_{ji} = 1, 1$ 
23                 //确定背面的连接。
24                 end if  $j = i + N$  then  $A_{ij}, A_{ji} = 1, 1$ 
25                 //确定左后方的连接。
26                 end if  $j = i + N - 1$  &  $i \% N \neq 0$  then  $A_{ij}, A_{ji} = 1, 1$ 
27                 //确定右后方的连接。
28                 else if  $j = i + N + 1$  &  $i \% N \neq 2$  &  $i > N - 1$  then  $A_{ij}, A_{ji} = 1, 1$ 
29                 end if
30             end if
31         end if
32     end for
33 end for
34 final
35 return  $A$ 

```


3.2 模型设计

本文开发了一种新的深度空间-时间模型（BlindTPM），它可以用来训练、评估和预测盲人的运动信息，如图 3.7 所示，它由三个独立的模块组成，分别是空间卷积块、时间卷积块和估算块，它们可以有效地提升模型的准确度。空间卷积块可以用来描述轨道和障碍的空间分布，而时间卷积块则可以用来研究轨迹数据的时刻变化特征，而测量块则可以有效地减少轨迹预测结果的全局偏差和局部偏差。




图 3.7 模型架构设计

3.2.1 空间卷积块

盲人的行走过程十分复杂，他们的轨道可能会变得复杂多变，有时候直线可以很容易预测，但是由于转弯和障碍物的分布，盲人的轨道可能会变成一条曲线。因此，在轨迹预测的过程中，捕捉定位的空间关系变得尤为重要。因此，为了更准确地预测时间，本文需要对轨迹数据实行空间特征提取，并加强轨道局部曲线的重要性，而不能仅仅依赖标准化的位置数据。首先，将横、纵坐标的数据进行融合，计算出空间依赖特征，如下所示：

$$P_i = \sigma\{cat(\delta^{x_k} \times x_i + \mu^{x_k}, \delta^{y_k} \times y_i + \mu^{y_k})\} \quad 3-(5)$$

公式 3-(5)表示了位置数据的标准化过程，其中*i*节点的横、纵坐标由轨迹序列*k*的标准偏差 δ 和平均值 μ 计算得来。将横坐标和纵坐标融合到同一维度，可以更准确地反映实际情况，这种方法比单独处理横坐标或纵坐标矩阵更有效。盲人轨迹节点的空间依赖强度与轨迹特征的上下文信息之间的相关性非常重要。传统卷积网络通常使用下采样计算高维特征。然而，下采样方法使用固定感受野会导致边缘特征信息的丢失。尤其是对盲人而言，其行走过程非常缓慢，这导致在一定时间段内生成很多轨迹节点。这使得盲人轨迹的权重涉及更多的参数，并且这些参数信息极易丢失。如图 3.8 所示，本文使用构建多层空洞卷积，捕获盲人轨迹的复杂空间特征。在每一层中，使用正方形网格结构表示卷积核。卷积核中的黑色单元表示有效权重。三层空洞卷积网络的空洞因子分别为 2^2 、 2^1 和 2^0 。空洞卷积具有显著的优势，它可以以指数级增加感知范围，而不会丢失太多特征信息。其中，*d* 是每条轨道的首个和非首个结点之间的距离特征。




图 3.8 膨胀卷积过程

通过将 o^{conv} 与第 *k* 个轨迹的第 *i* 个节点和第一节点的距离进行结合，并利用 σ (ReLU 函数) 激活，本文能够有效地减小参数间的互相依赖性，从而有效地解决由于过度拟合而引起的梯度消失问题，具体实现如下：

$$O = \sigma\{cat(o^{conv}, \delta^{d_k} \times d_i + \mu^{d_k})\} \quad 3-(6)$$

3.2.2 障碍物网格空间分布

通过 GCN 技术，本文可以将障碍物网络的连通性邻接矩阵与特征数据融合，从而有效地提取出障碍物网格空间的特征。由于邻居节点和其他节点的变化，GCN 可以捕捉到这些变化的特征，从而更好地理解障碍物网格空间的结构和功能。拉普拉斯方法可以有效地将 GCN 特征的强度与节点之间的状态差成比例传递，从而更好地反映出节点之间的关系，并且可以更准确地预测节点。为了更好地反映节点的行为，本文对拉普拉斯方法进行了改进，如下所示：

$$La = O^{-1/2}AO^{-1/2} \quad 3-(7)$$

A 是一个具有自连接特性的连通矩阵，它能够利用空间卷积块的输出来表示结点的度分布（O），这样就能够解决自传输问题，并且能够利用将邻接矩阵的两侧乘以结点的度（the degree root of the node），最后取逆来完成邻接矩阵的归一化计算，从而达到更好的效果。根据原始谱图卷积，本文能够计算出每个结点的乘积和傅里叶映射的滤波，但是，由于特征矢量的高阶特性，拉普拉斯矩阵在大型图拓扑结构的属性划分步骤中效率较低。因此，为了提高效率，本文采用 K 阶切比雪夫多项式，如公式 3-(8) 所示，进行优化。 $T_i(\widetilde{La})$ 的计算过程如公式 3-(9) 所示，该公式展示了切比雪夫多项式的递归定义。K-局部卷积算法是一种有效的节点优化技术，它可以有效地抑制当前节点受到外部节点影响的可能性，从而大大减少了计算时间的复杂性。

$$g(\theta) \cdot o \approx \sum_{i=1}^k \theta_i \cdot T_i(\widetilde{La}) \cdot o \quad 3-(8)$$

$$T_i(\widetilde{La}) = \begin{cases} 2\widetilde{La} \cdot T_{i-2}(\widetilde{La}) - T_{i-2}(\widetilde{La}), \\ T_0(\widetilde{La}) = 1, \\ T_1(\widetilde{La}) = \widetilde{La}, \\ \widetilde{La} = \frac{2}{\lambda_{max}} \times La - I_n. \end{cases} \quad 3-(9)$$

3.2.3 时间卷积块

递归神经网络在时间序列数据预测领域发挥了巨大的作用。然而，传统的递归神经网络（RNN、LSTM、GRU 等）仅涉及单步计算方法。单步计算有两个缺点，计算过程的复杂性较高且长期预测的性能低。时间卷积网络（TCN）是基于卷积神经网络和并行化的思想设计的，它克服了传统递归神经网络的两个固有缺点。对于盲人轨迹预测，TCN 使用因果卷积来分析轨迹的所有历史位置点与预测的未来位置之间的关联性。空洞卷积可以让隐藏层能够获得更大的感受野，以捕捉盲人轨迹的高维时序特征。如图 3.9 所示，本文使用由 7 个隐藏层组成的时间卷积块来计算时间特征。每个隐藏层都有一个膨胀因子，每个因子都是 2 的指数式增长。TCN 的输出为时间预测序列 $\{h_0, h_1, \dots, h_k\}$ 。




图 3.9 时间卷积块设计

3.2.4 估算块

为了提高盲人轨迹预测的准确性，本文使用了局部-全局估计块。其目的是为盲人当前位置点添加下一个位置点的信息，以形成上下文多尺度计算过程。因此，盲人轨迹的每个位置点都将经历局部估计过程^[69]。与正常人的轨迹相比，单位时间内盲人轨迹的位置更密集。当执行多个局部估计时，其累积误差对最终预测结果有一定程度的影响。因此，本文使用全局估计来减少局部估计的累积误差，提高全局预测精度。

当盲人轨迹数据经过空间卷积块和时间卷积块处理后，会形成包含时间和空间特征的多维矩阵。在局部估计过程中，每个 h_k 都会从初始 128 维数据线性变换为 1 维数据。并在每次线性变换后执行激活函数。上述数据处理过程是为减少盲人轨迹中的噪声位置点。本文使用 Leaky ReLU 函数，如图 3.10 所示，该函数具有负饱和区域的优点，使数据更倾向于在负饱和区域饱和，而不是完全归零。




图 3.10 局部估算设计

本文使用三层残差网络来减少局部估计的累积误差。本文将第一个和非第一个节点的距离特征与权重进行了精确的匹配，以便更好地描述轨迹。每个位置点的特征融合过程将在三层残差网络中逐层跳接实现。实现过程如下所示：

$$h_i = \sigma(h_{i-1} + re(i)) \quad 3-(10)$$

第*i*个残差处理被称为 $re(i)$ ，而 h_{i-1} 则是先前残差单元的处理结果。残差单元的输入和输出可以通过全连接层进行组合，以便更好地估计盲人轨迹的特征，并计算出每个节点的权重。

3.3 实验对比

3.3.1 数据准备

本文的数据集是在有三条路线的多层购物中心中收集的。该数据集中包含时间戳集合，带注释的轨迹，以及相关的场景平面布置图。这三条路线包含了 9 名参与者的轨迹。从图 3.11 可以看出，盲人的路线范围并不包含三个场景中的所有路线。因此，本文只对每个场景的一部分进行实验建模。本文选择的区域包含 9 名参与者的整个轨迹范围。

如前所述，本文基于盲人的缓慢轨迹速度和他们每单位时间内不显著的位置变化对原始数据进行采样。样本轨迹表示轨迹的长期时间特性。图 3.12 表示了 9 名参与者的完整轨迹和样本轨迹之间的位置节点关系。在完整轨迹中，时间步长为 2~3 秒，而在样本轨迹中，时间步长为 100~1000 秒。



图 3.11 多层商场中盲人的轨迹分布




图 3.12 盲人原始轨迹和样本轨迹中包含的位置点数量

3.3.2 实验设计

为了确保实验结果的准确性，本文对常规的数学统计模型、卷积网络系统、递归网络系统、多元扩张卷积网络系统、TCN 以及复杂的空间模式做出了比较，以验证模型的有效性。同时，复杂空间建模的具体细节包括：

- **STF-RNN**: 模型通过搜索表层特征，将空间和时间混合特征输入到内部表示方法中，以实现轨迹的有效推导，从而更好地描述和预测复杂的轨迹。
- **Social-LSTM**: 模型设计了一个“社交（social）”池结构，它可以将 LSTM 末端序列的参数隐藏起来，从而使模型能够自动识别出时间重合轨迹之间的相互作用关系，从而提高模型的准确性和可靠性。
- **Social Attention**: 由于采用特定的 S-RNN 框架，模型可以测算出时空图信息的权重，其中，问题信息作为中心，时间序列数据作为边缘值，以此来实现对信息的有效分析。
- **DSCMP**: 此模型是一种用于识别和学习长时间轨迹的队列机制，它能够捕获运动场景中的上下文参数，并且能够有效地将空间和时限的一致性结合起来。

在数据集一致的情况下，本文使用 4 台 NVIDIA Tesla V100 进行实验训练，最终得出 200 次训练后的平均值。为了提高训练效率，本文选择了 Adam 算法，它能够在每次迭代中将学习速率调整到一个合理的范围，从而保证参数的稳定性。鉴于数据集的复杂性，本文采用了图 3.13 中提出的误差计算方法，其中， $\{d_1, d_2, \dots, d_n\}$ 分别代表实际点与预测点之间的距离，而 $\{p_1, p_2, \dots, p_n\}$ 则分别代表第 n 个预测点与第 $(n-1)$ 个实际点之间的距离。本文计算这两个序列的距离误差。




图 3.13 距离误差计算方法

均方根误差 (RMSE) 是一种衡量深度学习模型预测准确度的指标, 它可以用来反映预期值与现实值之间的差异。RMSE 的计算方法可以参考公式 3-(11), 而表 3.1 显示, BlindTPM 在中长期预测中表现出色。尽管马尔可夫模型在短期内可以有效地预测第一个点, 但是在长期的预测中, 它的准确度和可靠性却大打折扣。

$$RMSE = \sqrt{\frac{1}{m} \sum_{i=1}^m (y_i - \hat{y}_i)^2} \quad 3-(11)$$

表 3.1 RMSE 比较结果

Position	Markov	LSTM	D-Conv	STF-RNN	Social-LSTM	Social attention	DSCMP	BlindTPM
1	0.67	3.92	3.32	1.98	1.86	1.42	1.43	1.21
2	2.45	6.32	4.10	2.75	2.76	2.43	2.34	2.01
3	4.87	7.63	5.87	4.86	4.09	3.21	3.23	2.91
4	6.29	8.34	6.55	5.99	5.34	2.43	4.87	4.32
5	8.02	7.91	7.89	6.48	6.02	1.42	5.98	5.23

3.3.3 实验分析

数学统计模式只能用来预测行人情况和目标, 而马尔可夫模型虽然复杂性较低, 但其预测准确率却不高, 尤其是在第一点的预测上, 其误差会随着时间的推移而呈线性增加, 这一点与其他数据驱动模型相比, 差距更加明显。LSTM 是一种基于时间序列的递归网络, 它能够有效地捕捉位置点的特征, 而 D-Conv 则是一种多层扩展卷积模式, 它通过卷积核的平移来捕捉从底部到顶部的轨迹特征, 从而实现了更加精确的模型建立。BlindTPM 是一种新型的时空模型, 它通过调整卷积核的大小来捕捉动态范围变化的空间特征。与传统的递归网络不同, BlindTPM 能够同时考虑轨迹的空间和时间相关性, 从而更有效地提取空间特征。D-Conv 能够有效地提取空间特征, 并且能够动态地获取历史轨迹的空间分布权重, 从而在未来五个点的预测指标中显示出显著的优势。此外, 它还能够使用前一级的历史信息, 来分析下一级的参数隐含状况, 从而更好地实现时间相关性的计算。

尽管 RMSE 模型在提供准确的数据方面表现出色, 但仍需要解决图 3.14 中提出

的位置点密集和障碍物的挑战。图 3.14 (a) 展示了理想情况下的预测结果，它能够准确地捕捉到原始轨道的运动趋势。图 3.14 (b) 表明，模型能够准确预计直线轨迹，而且其预测值分散，不受阻力的影响。然而，由于线性轨道的空间样本单一，使得模型参数的权重较小，因而无法有效地预计过于密集的轨道。图 3.14 (c) 显示，由于模型未考虑室内环境中障碍物的空间分布，导致预期轨道与实际障碍物重叠，因而影响了盲轨迹估计的准确度。结果也证实，采用坐标的盲轨迹预测存有一定的缺陷。为了提高轨迹预测的准确度，本文应该采取更多的措施来分散轨迹点，并且将障碍物的空间分布作为一个重要的考虑因素，以便更好地模拟实际场景中的情况。




图 3.14 坐标系中 BlindTPM 预测结果

3.3.4 障碍物分布网络




图 3.15 障碍物分布网格中 BlindTPM 预测结果

图 3.15 表示将横、纵坐标转换为网格标签并且增加了障碍物的空间分布后，模型对盲人轨迹的预测结果。由图(a)可以看出，使用上述设计模型预测准确率有了明显提升，预测结果与实际轨迹一致。经过添加障碍物空间分布的改进，(b)和(c)表明，模型可以有效地避免障碍物的影响，从而使轨迹点不会重叠。此外，将数据以网格标签的形式输入模型后，模型的预测准确率也得到了显著提升，从而更好地满足实际应用的需求。通过使用模型，本文成功地预测了盲人的轨迹，并扩展了预测范围。表 3.2 显示了模型的预测误差。准确度是指模型在总样本中预测结果的准确率。虽然准确度指标可以判断模型总体预测的正确率，但当样本不平衡时，它不能很好的反映模型的预测效果。精度表示预测为正的所有样本中实际为正的样本的概率。精度指的是模型对正样本结果的预测精度，但精度指标指总体预测精度，包括正样本和负样本。因此本文使用召回率作为补充指标，召回率指实际为正的样本预测为正的的概率。召回率越高，预测实际为正的样本的概率越高。当三个指标均取自 5 个地点的预测平均值，且横坐标和纵坐标的网格标签均能够同时达到预期的准确性时，才可以认定模型的预测结果是准确的。BlindTPM 在三个指标方面表现优异，与表现最佳的模型(DSCMP)相比，其准确度(11%)、准确度(9%)和召回率(7%)都有很大提高。

3.3.5 扩展分析

通过将坐标系映射到网格标签，本文可以有效地解决表 3.2 中出现的预测误差问题。这种方法将轨迹预测任务从回归转变为分类，并且可以将未来位置的变化限制在一定范围内，从而大大降低了模型训练的复杂性，大大提高了预测的准确度。通过使用激活函数(ReLU)，本文可以在障碍物分布网格中将可通行区域的特征提升到 0，而将零值特征丢弃，从而在相同维度上对障碍物分布网格和轨迹分布网格进行加权。激活函数(ReLU)增强了可通行区域的特征，并丢弃了障碍区域的零值特征。为了验证本文提出的估计块的效果，本文进行了消融实验，如表 3.2 所示。BlindTPM 加入估计块后，模型预测精度有了明显提高。这是因为局部估计增加了盲人轨迹点之间的递归相关性。使用临时隐藏状态由时间序列数据通过局部估计生成。这些隐藏状态用来表示盲人短期未来位置点，并通过全局估计形成代表盲人完整轨迹的高级特征，进一步提高了模型预测的准确率。

表 3.2 预测误差的比较结果

Indicators	Markov	LSTM	D-Conv	STF-RNN	Social-LSTM	Social attention	DSCMP	BlindTPM (no estimation)	BlindTPM
Accuracy	0.60	0.72	0.77	0.82	0.82	0.80	0.83	0.84	0.94
Precision	0.59	0.73	0.80	0.83	0.79	0.81	0.84	0.83	0.93
Recall	0.61	0.71	0.79	0.81	0.80	0.80	0.85	0.84	0.92

3.4 本章小结

针对室内场景中盲人的辅助运动任务，本文提出了一个盲人避障算法和轨迹预测时空模型。在这项工作中，本文使用网格数据表示室内场景。盲人的轨迹相应地被转换为网格标签。这种转换方法将预测值控制在一定范围内，并克服了神经网络模型对浮点轨迹数据预测的困难。通过采用特定的规则，本文可以将场景中的障碍物转换为一个空间分布矩阵，从而有效地减少障碍物所在区域的重要性，同时增加可通行区域的重要性。实验验证了使用坐标轨迹和网格轨迹的预测差异，证明了本文设计模式的优越性。在未来的工作中，本文考虑将其他对盲人轨迹预测产生影响的因素添加到现有研究中。障碍物对盲人轨迹预测准确率的影响，展示了一个事实：人类是有思维的生物，他们的行为总是受到周围环境或其他人类的影响。

第四章 盲人导航指令预测

在第三章中,本文实现了根据盲人过去一段时间的轨迹,以及盲人运动场景的障碍位置去预测未来一段时间的盲人运动轨迹。但预测出的轨迹要想真正帮助盲人在有障碍物的室内行走,仍旧需要转换为对应指令来在关键位置对于盲人下达合适指令来指导盲人朝着合适方向行走。因此,在第四章中,本文以盲人的历史轨迹数据,标准盲道轨迹为数据输入,并基于第三章中的未来一段时间的盲人轨迹预测,设计了模型 BlindIPM 来实现对于盲人下一时间步的行走指令预测。

图 4.1 中,蓝色双实线代表了标准盲道轨迹,蓝色点表示标准盲道轨迹点采样,橙色虚线表示盲人历史轨迹,橙色点表示对于历史轨迹进行采样。黑色线表示对于未来一段时间的轨迹预测。

本章,本文提出了模型盲人指令预测模型(Blind Instructions Prediction Model, BlindIPM)来根据盲人的历史轨迹、标准盲道轨迹,以及 BlindTPM 根据障碍物位置预测得到的未来一段时间的盲人运行轨迹,来进行未来一个时间步导航指令的预测。该方法融合了历史轨迹、标准盲道轨迹中的时序特征和并采用 BlindTPM 对于空间中障碍物分布的空间特征进行考虑,可以实现对于未来一个时间步导航指令的精准预测。




图 4.1 BlindIPN 结构图

4.1 问题概述

随着导航技术的发展，盲人导航设备已经在实际中得到了广泛的应用，但是针对盲人的室内导航工具和技术仍然缺乏。为了解决盲人的室内导航任务，本文对盲人导航指令进行预测。本章使用三种数据，利用盲人的历史轨迹 $his_p = \{(x_{t-1}, y_{t-1}), (x_{t-2}, y_{t-2}), (x_{t-3}, y_{t-3}), \dots, (x_{t-h}, y_{t-h})\}$ ，标准盲道轨迹数据 $Trace_f = \{(x_{t+1}, y_{t+1}), (x_{t+2}, y_{t+2}), (x_{t+3}, y_{t+3}), \dots, (x_{t+f}, y_{t+f})\}$ ，以及 BlindTPM 根据障碍物位置预测得到的未来一段时间的盲人运行轨迹 $P = \{(x'_{t+1}, y'_{t+1}), (x'_{t+2}, y'_{t+2}), (x'_{t+3}, y'_{t+3}), \dots, (x'_{t+f}, y'_{t+f})\}$ ，来获得未来一个时间步导航的指令。其中， x 表示横坐标， y 表示纵坐标， t 表示盲区位置变化的时间步长。

4.2 盲人导航指令预测方法

本文提出了 BlindIPM 模型来对于盲人导航的指令进行预测，如图 4.1 所示，通过图 4.1 可以看出，模型分主要分为两个部分。首先，将历史轨迹数据和盲道轨迹数据作为第一模块，并将残差块作为模型的第一部分，构建一个堆叠的扩展因果卷积网络，以捕捉长期时间相关性，以便更好地分析和预测复杂的环境变化。残差块（残差块的变体：resnet-v，如 $\oplus$ ）由两层扩展的因果卷积组成，第一层卷积计算后进行批归一化和 ReLU，第二层卷积计算后进行另一批归一化。第一模块的结果作为模型第二部分的输入。模型第二部分首先通过 BlindTPM 模块，根据历史轨迹数据和障碍物矩阵预测，得到的未来一段时间的盲人运行轨迹 P 。然后应用全连接层和批归一化来投影预测轨迹 P ，之后用 ReLU 激活，再进行另一个全连接层和批量规范化。最后采用全连接层将第二部分残差变体模块的输出映射到本文的最终预测中。残差变体模块用于整合历史轨迹数据和预测轨迹 P 的随机过程的输出。

a) 模型第一部分

本文从 t 时刻的输入中获得 t 时刻的输出卷积，因果卷积方法允许本文跳过一定的步长，并在超出这个范围的区域中使用滤波器来进行处理。在单变量序列的情况下，给定一维输入序列 x ，具有核 w 的扩张卷积的位置 t 处的输出 s 可以表示为：

$$s(t) = (x *_d w)(t) = \sum_{k=0}^{K-1} w(k)x(t - d \cdot k) \quad 4-(1)$$

其中 d 是膨胀因子， K 是核的大小。堆叠多个扩展卷积不仅使得网络具有非常大的感受野，并且可以用较少的层数捕获长时间依赖性。

模型第一部分使用了具有相同的内核大小 K 和扩张因子 d 的两个扩张卷积，代替了经典的门控机制。扩张卷积之后是门控激活模块，残差块被视为它的成分。根据

图 4.1, 残差块由两层展开的因果卷积构成, 第一层卷积后, 将非线性单元 (ReLU) 批次归一化, 以便实现修正; 第二层卷积后, 将另一批归一化, 以实现更准确的结果。残差块已被证明有助于有效训练和稳定网络, 特别是当输入序列非常长时。此外, 实验证明, 由校正的非线性单元 ReLU 获得的非线性结果实现了更好的预测精度。各种自然语言处理 (NLP) 任务也支持上述结论。

b) 模型第二部分

该部分包括两个主要模块, 一个是残差神经网络的变体, 即 **resnet-v**。一个是将 **resnet-v** 的输出映射到概率预测的全连接层。如前所述, **resnet-v** 模块允许两个输入 (一个用于历史信息, 另一个用于预测轨迹 P), 并设计用于捕获这两个输入的信息。可以写成:

$$\delta_{t+f}^{(i)} = R(P_{t+f}^{(i)}) + h_t^{(i)} \quad 4-(2)$$

其中 $h_t^{(i)}$ 是模型第一部分的输出, $P_{t+f}^{(i)}$ 是通过 **BlindTPM** 获得的预测轨迹, $\delta_{t+f}^{(i)}$ 是 **resnet-v** 的潜在输出。 $R(\cdot)$ 是应用于 $P_{t+f}^{(i)}$ 的残差函数。因此, 非线性函数 $R(\cdot)$ 在动态回归模型中扮演传递函数的角色, 并解释由第一部分单独确定的盲人轨迹和预测之间的残差。

c) Loss 设计

本文在本文中考虑了两种概率预测框架。第一个是参数框架, 其中可以通过基于最大似然估计直接预测假设分布的参数来实现未来观测的概率预测。第二种是非参数预测, 它产生一组对应于分位数兴趣点的预测。实际上, 选择参数化方法还是非参数化方法取决于应用程序上下文。参数方法需要假设特定的概率分布, 而非参数方法是无分布的, 因此通常更稳健。但是, 决策情景可能依赖于某一时期的概率预测总和。在这种情况下, 非参数方法将不起作用, 因为输出不是随时间增加的, 而参数方法可以通过从估计分布中采样来灵活地获得此类信息。

在非参数框架中, 预测可以通过分位数回归获得。在分位数回归中, 将特定分位数水平 q 的观察和预测分别表示为 y 和 $\hat{y}^q$, 对模型进行训练以最小化分位数损失, 其定义为:

$$L_q(y, \hat{y}^q) = q(y - \hat{y}^q)^+ + (1 - q)(\hat{y}^q - y)^+ \quad 4-(3)$$

其中, $(y)^+ = \max(0, y)$, $q \in (0, 1)$ 。给定一组分位数水平 $Q = (q_1, \dots, q_m)$, 通过最小化定义为:

$$L_Q = \sum_{j=1}^m L_{q_j}(y, \hat{y}^q) \quad 4-(4)$$

对于参数方法, 给定预定分布 (例如高斯分布), 应用最大似然估计来估计相

应的参数。以高斯分布为例，对于每个目标值 y ，网络输出分布的参数，即平均值和标准差，分别用 μ 和 σ 表示。然后将负对数似然函数构造为损失函数：

$$\begin{aligned} L_G &= -\log \ell(\mu, \sigma|y) \\ &= -\log \left((2\pi\sigma^2)^{-\frac{1}{2}} \exp \left[-\frac{(y-\mu)^2}{2\sigma^2} \right] \right) \\ &= \frac{1}{2} \log(2\pi) + \log(\sigma) + \frac{(y-\mu)^2}{2\sigma^2} \end{aligned} \quad 4-(5)$$

4.3 实验

4.3.1 数据描述

本文的数据集是在有三条路线的多层购物中心中收集的。该数据集中包含时间戳集合，带注释的轨迹，以及相关的场景平面布置图。这三条路线包含了 9 名参与者的轨迹。从图 4.2 可以看出，盲人的路线范围并不包含包括三个场景中的所有路线。因此，本文只对每个场景的一部分进行实验建模。本文选择的区域包含 9 名参与者的整个轨迹范围。如前所述，本文基于盲人的缓慢轨迹速度和他们在单位时间内不显著的位置变化对原始数据进行采样。样本轨迹表示轨迹的长期时间特性。图 4.3 表示了 9 名参与者的完整轨迹和样本轨迹之间的位置节点关系。在完整轨迹中，时间步长为 2~3 秒，而在样本轨迹中，时间步长为 100~1000 秒。

4.3.2 实验分析

从表 4.1 可以看出相比于其他模型，BlindIPN 模型的准确率最高，同时它在图 4.2 中 ROC 曲线右下角面积最大，可以证明 BlindIPN 模型能更好地对盲人导航进行指令预测。结合表 4.1 和图 4.2 来看，CNN 的预测结果最差，TCN 模型相对于 LSTM 模型来说精确度更高，Social LSTM 模型和 UAV 模型在一定程度上都提升了模型的精确度，但是两个模型的精确度都低于 BlindIPN 模型。

表 4.1 盲人导航指令预测的实验结果

Model	Accuracy	Precision	Recall	F1-Score
CNN	0.54	0.54	0.61	0.572
LSTM	0.59	0.6	0.66	0.62
TCN	0.65	0.65	0.7	0.67
Social LSTM	0.77	0.7	0.76	0.72
UAV	0.79	0.77	0.81	0.78
BlindIPN	0.86	0.86	0.85	0.85




图 4.2 模型 ROC 曲线图

d) 实验分析

为了验证实验的正确性，分别对多个模型进行了评测。图 4.3 是 CNN 模型的混淆矩阵图，CNN 是卷积神经网络模型，卷积核的平移过程实现了从底部到顶部的轨迹的特征捕获。但是卷积神经网络不能像递归网络那样执行一步一步对时序数据进行推导。LSTM 是一种传统的递归网络，它无需其他辅助数据进行建模，但只能捕获位置点的简单时间递归特征。因此，如图 4.4 所示，它预测的正确指令数量高于 CNN 模型。




图 4.3 CNN 混淆矩阵




图 4.4 LSTM 混淆矩阵

TCN 是一种应用于时间序列数据的简单的一维卷积网络。TCN 使用深度神经网络和扩张卷积的组合结构。其中，卷积层不仅有助于改善模型延迟，并且由于每个预测只能依赖于其先前的预测，所以 CNN 存在因果关系，不会有来自未来的数据泄漏。图 4.5 为 TCN 的混淆矩阵图，其预测正确的数量比图 4.4 更多，TCN 的结构使得其在长期信息学习方面比 LSTM 模型更为优秀。




图 4.5 TCN 混淆矩阵

图 4.6 为 Social LSTM 模型的混淆矩阵图。Social LSTM 模型通过一种全新的架构将 LSTM 连接起来，从而解决了这一棘手问题。“社交”池化层可以让 LSTM 在空

间近端之间共享其隐藏状态，从而实现更加有效的数据管理。因此，它可以自动识别出时间重合的轨迹之间的典型交互作用，并且在盲人导航指令预测方面取得了令人满意的成果。




图 4.6 Social LSTM 混淆矩阵

如图 4.7、4.8 所示,UAV 模型的混淆矩阵正确预测的数据仅次于 BlindIPN 模型。UAV 模型引入了一个时空交互感知模块,它集成了图卷积网络和自注意力机制来模拟盲人的时空交互。自注意力机制使得模型可以并行处理,参数更少,速度更快,精度更高。其次,模型的轨迹分布感知模块,从观察到的和未来时间的测量轨迹中学习潜在的轨迹分布信息。这可以为后续指令预测提供知识丰富的轨迹分布信息,进一步提升预测精度。




图 4.7 UAV 混淆矩阵




图 4.8 BlindIPN 混淆矩阵

图 4.8 是 BlindIPN 模型的混淆矩阵图，相比于其他模型，BlindIPN 模型的预测精度更高。BlindIPN 模型通过考虑空间和时间相关性，可以有效地提取历史轨迹的特征，并利用 BlindTPM 模块，以及多层扩张卷积技术，实现动态地获取轨迹的空间分布权重，从而更好地描述历史轨迹。BlindTPM 模块可以利用前一层的历史数据，来深入分析下一层的参数隐藏状态，从而实现时间相关性的有效计算。BlindTPM 模块的应用对 BlindIPN 模型的精确度有着良好的积极作用。不仅如此，BlindIPN 模型中使用 resnet-v 来简化网络训练，在大幅度加深网络的同时可以获得较高的精度。

4.4 本章小结

本文提出了盲人指令预测模型 BlindIPM，根据盲人的历史轨迹、标准盲道轨迹，以及 BlindTPM 根据障碍物位置预测得到的未来一段时间的盲人运行轨迹，来进行未来一个时间步导航指令的预测。该方法融合了历史轨迹、标准盲道轨迹中的时序特征和并采用 BlindTPM 对于空间中障碍物分布的空间特征进行考虑，并且加入了自注意力机制，使得模型可以并行处理，参数更少，速度更快，精度更高，可以有效实现对于未来一个时间步导航指令的精准预测。

第五章 基于集成学习的盲人行走指令预测

本文在第四章提出了模型盲人指令预测模型(BlindIPM)来根据盲人的历史轨迹、标准盲道轨迹，以及根据障碍物位置预测得到的未来一段时间的盲人运行轨迹，来进行未来一个时间步导航指令的预测。在本章中，在 BlindIPM 模型基础上，本文提出了基于集成学习的盲人行走指令预测的模型，提高模型预测准确率。

5.1 盲人行走指令预测方法

5.1.1 基于横坐标和纵坐标轨迹的预测方法

如图 5.1 所示，将室内的某一移动场景固定，盲人起始点固定为 (x_1, y_1) ，在移动的过程中如果保持一个状态，则提供的命令为“No Action”，向前直走的命令为“Approaching”。如果要向左转或者右转则提供其他的指令。本文的任务是预测盲人在真实场景下对应的空间位置应该接受到什么指令。 $(x_1, y_1), (x_2, y_2), \dots$ 对应的命令就为 $O_1, O_2, \dots$ 如图 5.1 所示。在机器学习方面，各种各样的指标有着多样的维度和单位，想要更好地比较它们相互之间的差异，本文需要将它们进行标准化，以便更好地反映实际情况。




图 5.1 基于横坐标和纵坐标轨迹的示意图

5.1.2 网格地图预测法

鉴于盲人行走的速度较慢，其轨迹的横坐标和纵坐标变化较小，因此本文在 5.1.1 的基础上，引入了将轨迹点划分为网格标签的计算方法，以降低运算难度，并利用独立配置空间的多分辨率方格表达，以更好地反映盲人的行走轨迹。如果一个直线单元在遇到障碍时，它就被视为一个障碍。为了更好地理解这种情况，本文应该将它分解成更小的单元。每个单元都可能被分解成两个子单元，以便更好地理解障碍。

任何包含障碍的单元都可能被进一步分割，直到达到最佳的清晰度。这种表示方式的优势在于，仅仅接近障碍物的区域能够被提升到更高的清晰度，而离开障碍物的区域依然能够用较低的清晰度来显示。由于利用最小化步长，路径规划器能够有效地处理散乱的空间结构，而利用更大的步长能够更好地处理宽阔的空间结构。如图 5.2 所示，一块区域被网格标签化，以提高在同一块区域对指令预测的准确率，展现了数据设计的优越性。




图 5.2 网格划分图

如图 5.3 所示，在盲人行进过程中，只有当盲人所处空间位置对应的网格所应接受命令和同一时间步中预测的命令一致，才把这次预测视为成功的。




图 5.3 网格轨迹示意图

5.1.3 指令

为了创建一个预测完整状态序列的系统架构，本文首先考虑了九种动作与方向作为预测的指令。盲人可以在一个网格中朝九个方位走路，包括“向前”、“倒退”、“左转”、“右转”、“斜左旋转”、“斜右旋转”和“静止”。这九个方位分别对应于其邻近的八个网格。但是，由于室内环境中存在障碍物，以及原始轨迹的空间分布，为了让盲人能够更准确地预测，本文需要提供最简单、最有效的指令。本文删减了“左后”、“右后”、“倒退”这三种指令。如图 5.5 所示，整合为“Apporaching”，

“No_action”，“TurnLeft”，“TurnRight”，“TurnDiagonalLeft”，“TurnDiagonalRight”六种命令。其中“No_action”命令表示当前状态延续前一个命令。图 5.5 是 6 种指令对应盲人行走的状态。其中图 5.5(a)表示直行“Apporaching”指令，图 5.5(b)表示延续“No_action”指令，图 5.5(c)表示斜左旋转“TurnDiagonalLeft”指令，图 5.5(d)表示左转“TurnLeft”指令，图 5.5(e)表示右转“TurnRight”指令，图 5.5(f)表示斜右旋转“TurnDiagonalRight”指令。




图 5.5 (a) Apporaching. (b) No_action. (c) TurnDiagonalLeft. (d) TurnLeft
(e) TurnRight. (f) TurnDiagonalRight.

5.2 模型概述




图 5.6 模型架构

本文设计了一个能够训练、评估和预测盲人行走命令的模型（BlindPCN）。BlindPCN 由三个独立的模块组成，如图 5.6 所示，它们分别是空间卷积模块、时间卷积模块和集成学习模块。使用集成学习块可以有效地降低预测结果的整体偏差和局部偏差，这是因为集成学习可以将多个基学习器组合起来，形成一个更加全面的模型，从而更好地捕捉数据中的各种特征。空间卷积模块和时间卷积模块分别用于

模拟原始路线和盲人轨迹之间的空间关系和时间变化特征。这些模块的输出是特征向量，可以用于预测盲人轨迹。而集成学习块可以形成一个更加准确的预测模型。通过这种方式，集成学习块可以有效地降低预测结果的偏差，提高预测性能。集成学习块可以在不牺牲准确性的情况下，提高模型的泛化能力和鲁棒性，从而更好地应对复杂的机器学习问题。

5.2.1 空间卷积模块

如果盲道是一条直线，“直行”和“停止”只能提供有限的指令，但是由于路况的复杂性，转弯和障碍物的分布会影响命令的预测准确性。因此，在特征提取程序中，捕捉位置的空隙问题变得尤为重要，以便更好地预测盲道的行驶路线。为了更准确地预测时序，本文必须在进行时序预测之前，从盲人路径中抽取更多的特点，并加强部分曲线的权重。这样，本文就不必直接使用标准化的位置数据了。为了实现这一目标，本文必须将横坐标和纵坐标的信息进行整合，如图 5.7 为空间相关性特点的计算。模型中一个卷积层可以计算出时间网络层需要的更深层的轨迹空间特征，并且拥有更高的精度与训练速度，增强非线性轨迹的权重，全局局部估计层取代了传统的线性方法。本文模型也沿用了 TCN 的优势，对捕捉到的网格特征、盲人历史轨迹特征以及规划轨迹的空间特征进行了嵌入^[70-71]。




图 5.7 空间卷积模块中的特征学习

第 X_h 点的横坐标和纵坐标由第 X_h 轨迹序列的标准偏差和平均值计算，代表位置数据的标准化。与单独处理横坐标或纵坐标矩阵的结果相比，将横坐标和纵坐标融合到同一维度的结果更接近真实结果。再把网格标签信息空间卷积后的结果与坐标信息相融合，提高空间相关性。经过维度调整后，再与原始轨迹嵌入 cat 后得到全局时空特性。盲人轨迹节点的空间依赖强度与轨迹特征的上下文信息之间的相关性非常重要。传统卷积网络通常使用下采样来执行高维特征计算。然而，下采样方法的固定感受野会导致边缘特征信息的丢失。特别是对于盲人的轨迹，盲人的行走过程非常缓慢，在一定的时间内会产生大量的轨迹节点，而且在轨道转弯的时段内指令可能都不会改变。当盲人行走到室内某些位置的时候，指令都始终维持一种命令，

出现较大的模糊感。指令种类涉及更多的参数，而且轨迹参数信息很容易丢失。为了提高模型的准确性，本文采用了残差结构，如图 5.8 所示，这样可以有效地减少参数缺失，使得参数梯度值存在异号，从而避免 zigzag 现象的发生，从而更容易达到最优值。本文构建多层扩展卷积（TCN），以实现捕获盲人轨迹与接收指令的复杂空间依赖性的过程。扩展卷积网络的最大优势在于它能够以指数级速度增加感知范围，而不会损失任何特征信息。

本文结合了数据，即激活（ReLU 函数）后第 X_h 个节点和第 X_h 个轨迹，以减少参数的相互依赖性，并缓解因过度拟合而导致的梯度消失问题。




图 5.8 空间卷积结构

5.2.2 时间卷积模块

对于盲人指令预测，TCN 使用因果卷积使轨迹的所有历史位置点与未来一段时序预测的指令相关联。时间卷积网络（TCN）基于卷积神经网络和并行化的思想，克服了传统递归神经网络的两个固有缺点。使用扩张卷积可以使隐藏层获得更大的感受野，从而建立盲人轨迹与命令的高维定时特征，最后使用 softmax 层预测出最后的指令^[72]。针对本文设计的数据结构，本文构建了具有 5 个隐藏层的时间卷积块来计算时间特征。TCN 的作用主要体现在以下三个方面：

- 因果卷积，本文可以保留盲人的所有轨迹和网格历史信息，并对其进行长期的分析。
- 膨胀卷积，可以有效地扩大卷积过程的感受野，从而使空洞因子 Dilation 以指数级变化，从而有效地避免在深度计算时出现局部信息丢失的情况。
- 采用卷积神经网络（LSTM,GRU）作为基础，多层残差结构取代了传统的门控结构，大大提升了计算和训练的效率。

根据公式方法 5-(4)所示，因果卷积的公式方法由入口顺序 $\{x_1, x_2, \dots, x_t\}$ 、隐含层

输出顺序 $\{y_1, y_2, \dots, y_t\}$ 以及滤波器 $\{f_1, f_2, \dots, f_k\}$ 组成。 y_t 的结果只会由 $x_1, x_2, \dots, x_t$ 的数据得出，而不能由 x_t 之后的信息表示， K 表示距离序列点的长度。 K 越大，能够获得的历史信息也就越多。

$$y_t = \sum_{i=1}^K f_i \cdot x_{t-K+i} \quad 5-(4)$$

$$y_t = \sum_{i=0}^{K-1} f_i \cdot x_{t-i \cdot d} \quad 5-(5)$$

本文中，在不丢失分辨率的情况下为了增加感受野且降低计算量，进行下采样，采用了空洞卷积。根据公式 5-(5)，空洞卷积可以通过增大 d 或 K 来扩大感受野的范围，但是，由于网络层的增加，感受野的变化会导致卷积获得的数据与历史信息内部的关联性减弱，进而导致部分数据的损失。鉴于上述因素，本文将空洞因子 d 以指数级的增长率提升至 2。这样使得网络在深层次的训练中，密集的神元也能使模型的精度较好。

5.2.3 集成学习模块

在数据集中，当某一指令占比稍大时，导致数据分布不均，模型在分类问题上往往难以辨别。针对这种问题，本文引入了集成学习的方法^[73-75]，集成就相当于把特征转换，然后把所有比较弱的 $G(t)$ 进行组合，利用集体来获取比较好的模型 G ，有助于防止欠拟合。在扩大时间步长的基础上，本文引入了 Bagging 方法对数据集做处理，解决数据分布不均匀的问题。如公式 5-（6）所示，其中 $G_m(x)$ 的 out 为第 m 个模型预测 x 位置的指令。

$$G(x) = \operatorname{argmax} \left(\sum_{m=1}^k G_m(x) \right) \quad 5-(6)$$

由于盲人行走速率较慢，导致轨迹的横坐标和纵坐标随时间步长变化比较小，盲人的位置改变比较缓和。在这种情况下，盲人在行走一段时间内只能延续上一个指令，导致指令数据分布上“Approaching”指令占比较大，约 64%。这种数据在模型训练过程中带来很多困扰，导致准确率不够高。为了解决这个问题，本文采用了增大时间步长间隔的方法。虽然这种方法能改善命令重复的问题，但是效果并不好。根据图 5.9 所示，会出现不同程度的 underfitting 问题。本文加入了集成学习模块，通过调节数据集中有指令与无指令数据的数据量来形成 k 个不同的数据集，进而训练出 k 个模型，通过 k 个模型的预测结果取众数，得到最终预测结果。本文中的 k 为 6，结构如图 5.10 所示，这种方法的优点有：

- (1) 通过 Bagging 得到的强分类器的分类正确率比单个基分类器效果好很多，降

低欠拟合程度。

- (2) 每个数据集都是从原始数据中抽取出来的，因此，本文可以通过减少重复样本来提高抽样的准确性。
- (3) 当基分类器之间没有相关性时，它们能够更有效地降低泛化误差。
- (4) 可以有效排斥敏感点。




图 5.9 欠拟合问题




图 5.10 集成学习模块结构

5.3 实验

5.3.1 数据准备

本文对三种场景分别进行了实验建模。为了更加准确地描述本章所研究的问题，本文使用了新的数据集。这个数据集是在第三章和第四章改进的，在单位时间内对盲人不显著的位置变化进行建模的基础上更新。在这个数据集上，我们使用了多种不同的技术来进行实验，并且对结果进行了深入的分析和解释。

在实验过程中，我们使用了多种不同的技术来对数据集进行预处理和清洗。首

先，我们使用了一些常见的数据清洗技术，例如缺失值填充、异常值处理和数据转换等。接着，我们使用了一些常见的机器学习算法来进行实验。这些算法包括逻辑回归、决策树和神经网络等。最后我们使用了多种不同的数据集来进行实验，这些数据集主要包括文本数据。

5.3.2 实验分析

通过本文的模型对单个盲人轨道指令进行了预测，结果如下图 5.12 所示，这是一个关于指令预测的六分类的混淆矩阵。其中本章提出的模型预测的准确率 $ACC=81.4\%$ ，通过图 5.12 可以看出，在一段盲人轨迹指令数据中，标签为“4”指令概率最大，即“Approaching”的指令占比为 34.8%。

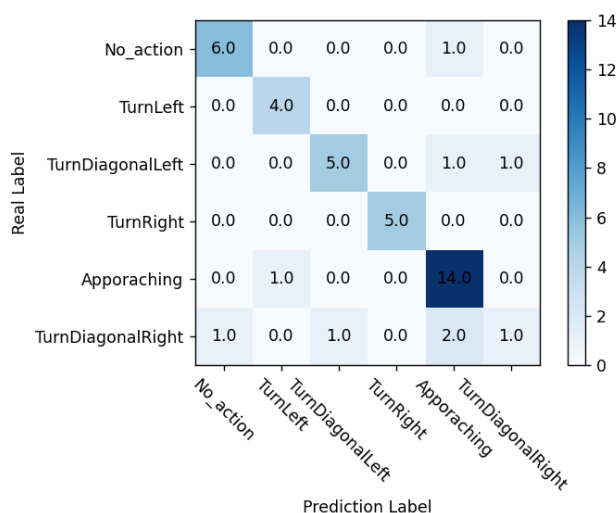


图 5.12 BlindPCN 混淆矩阵

在当前的自然语言处理领域中，循环神经网络 (RNN) 是一种被广泛使用的神经网络模型。其中，GRU、LSTM、Att-GRU 和 Att-LSTM 是 RNN 的变体，它们在实现序列到序列模型的转换方面表现出色。然而，这些模型也存在一些局限性。GRU 在实现序列到序列模型的转换方面表现出色。但是 GRU 的隐藏状态是固定不变的，因此它无法处理变长序列数据。用其他的模型分别对盲人数据进行指令预测。LSTM 在处理变长序列数据方面比 GRU 更加有效。但是 LSTM 的内存限制使其在处理大规模数据时表现不佳。Att-LSTM 和 Att-GRU 分别是在 LSTM、GRU 中引入注意力机制的变体，它们在实现序列到序列模型的转换方面表现出色。但是 Att-LSTM 和 Att-GRU 的注意力机制需要额外的注意力参数，这增加了模型的复杂度。把这几种模型的实验结果与本文的模型的实验结果进行对比。其中 LSTM、Att-LSTM、GRU、Att-GRU 模型的结果如下图 5.13 所示。实验结果表明，BlindPCN 模型采用注意力机制来捕捉序列中的重要关系，使得模型可以自适应地学习长时间序列数据。此外，

BlindPCN 模型还具有自注意力机制，这使模型可以处理变长序列数据，并且可以自适应地学习输入特征之间的复杂关系。BlindPCN 模型指令预测准确率更高。




图 5.13 (a) GRU 混淆矩阵 (b) Att-GRU 混淆矩阵 (c) LSTM 混淆矩阵 (d) Att-LSTM 混淆矩阵 (e) TCN 混淆矩阵

ROC 曲线是一种用于表达类别器预测结果的曲线，它的横坐标系为（False Positive Rate, FPR），其中 N 代表实际的负样本数量，而 FP 则代表在这 N 个负样

品中，被类别器预计为正样品的数量。通过对多种模型的数据分析，本文可以评估出模型的 ROC 指标，如图 5.14 所示。




图 5.14 多个模型的 ROC 曲线对比

为了确保结果具有科学性的前提下验证模型的性能，本文使用了传统递归网络（LSTM，GRU），带有注意力机制的 Atr+LSTM、Atr+GRU 模型，TCN，对复杂的时空模型进行了对比实验。

- (1) LSTM。传统的循环神经网络模型（RNN）无法有效地捕捉输入序列之间的长期相关性，而 LSTM 及其变种门控循环单元等模式则由于引入门控机理，大大减少了梯度消失造成的影响。
- (2) Atr+LSTM。在 LSTM 基础上加入了空间注意力 Spatial Attention，加大了模型对空间注意力分配概率数值（注意力权重）。
- (3) GRU。GRU 是 LSTM 网络的一种效果较好的变体，相较于 LSTM 参数较少，结构相对简单，训练速度更快。
- (4) Atr+GRU。在 GRU 基础上加入了注意力机制，但是需要额外的注意力参数，这增加了模型的复杂度。
- (5) TCN。TCN 是一种单向的结构，使用多层的卷积和池化操作来提取特征，这可能会导致一些冗余特征的出现

对模型在长期指令预测中的实验结果，如表所示。

表 5.1 对比实验结果

Indicators	GRU	Att-GRU	LSTM	Att-LSTM	TCN	BlindPCN
Accuracy	0.35	0.40	0.44	0.49	0.65	0.81
Precision	0.34	0.44	0.44	0.48	0.63	0.79
Recall	0.32	0.33	0.37	0.43	0.60	0.78

从表 5.1 中可以看出，使用了各类的循环神经网络的算法在加入了注意力机制后，在各个指标上都产生了性能上的提升，尤其是基于 GRU 的模型在加入了注意力

机制后，在预测指标上提升了百分之 10。另外，可以很明显看出本文所提算法 BlindPCN 在三个不同指标上的优势。

5.4 本章小结

针对室内场景内的盲人导航领域，在本文中，本文提出了一种用于室内盲人指令预测的网络。该网络由三部分组成：用于计算深层空间特征的空间层、用于计算轨迹在时间上的递推关系的时间层和减小全局误差的集成学习模块。为了解决传统卷积计算在空间层对特征空间依赖性不足的问题，本文构建了由扩展卷积组成的 SpatialConv。时间层采用 TCN，将其应用于时间轨迹预测领域。集成学习模块取代了传统的 Softmax 方法，利用训练出的多种模型对模型预测结果取众数的思想，减少了局部预测带来的误差。实验结果表明，该模型网络在长期预测中具有较高的精度。

然而，在进行长期预测时，在室内区域的预测过程中应考虑道路分布，障碍物分布情况。此外，还应考虑盲人行动实际变化，对盲人执行指令情况的因素。因为盲人在执行完单个不同指令后的速度、位置都可能与规划中的速度与位置不匹配。未来的研究将不仅着眼于解决上述问题，还将调查其他间接因素对盲人轨迹与指令的影响，包括盲人执行命令的反应时间、动作的规范性等。

第六章 总结与展望

6.1 工作总结

本文第一章介绍了论文的背景、研究现状和主要内容。第二章回顾了相关理论和技术基础,包括室内盲人行为的定义、盲人轨迹预测的经典模型以及深度学习理论,如卷积神经网络、递归神经网络和时间卷积神经网络。

第三章重点研究了深度学习模型在室内盲人轨迹预测中的应用。讨论了数据设计,数据表示方法、障碍物分布设计和模型设计,包括空间卷积块、时间卷积块、估计块以及局部和全局估计方法。还进行了实验,并对结果进行了分析,并与其他方法进行了比较。第四章讨论了深度学习模型在室内盲人导航指令预测中的应用。第五章进一步讨论了集成学习在室内盲人行走指令预测的优势。

本文提出了一种新的深度学习模型,用于预测室内盲人的轨迹和导航指令,并通过实验证明了该模型的可行性和有效性。本文的研究工作主要集中在以下几个方面:

(1) 本文提出了一种用于盲人轨迹预测的时空模型(**BlindTPM**)。空间卷积块捕捉道路和障碍物的空间相对特征。该模型结合了盲人独特的位置变化特征来实现轨迹预测任务。根据盲人的缓慢动作,该模型设计的时间卷积块可以捕获行人轨迹的长期历史信息。

(2) 本文以盲人的历史轨迹数据,标准盲道轨迹为数据输入,设计了模型 **BlindIPM** 来实现对于盲人下一时间步的行走指令预测。该方法融合了历史轨迹、标准盲道轨迹中的时序特征和并采用 **BlindTPM** 对于空间中障碍物分布的空间特征进行考虑,可以有效实现对于未来一个时间步导航指令的精准预测, **BlindIPN** 模型中使用 **resnet-v** 来简化网络训练,在大幅度加深网络的同时可以获得较高的精度。

(3) 本文在 **BlindIPM** 模型的基础上,添加了集成学习的模块。利用不同的拓扑结构、超参数设置和训练数据等因素,构建多个神经网络。这些神经网络被结合成一个更强大和鲁棒的模型,以提高指令预测的准确率。

6.2 未来展望

在室内盲人轨迹预测领域,已经进行了大量研究以提高预测模型的准确性和效率。尽管取得了进展,但仍有几个领域可以进一步改进。

首先,目前的大多数研究集中于室内轨迹预测,但缺乏对室外盲人行人运动预测的研究。这是一个重要的研究领域,应该在未来加以解决,因为这将大大有利于

经常在户外环境中盲人的出行活动。

第二，目前的室内轨迹预测模型主要基于从单个个体收集的历史数据。虽然这种方法已经产生了很好的结果，但探索可以在不同的个人和环境中推广的模型会很有趣。这可以通过将有关个人偏好、身体能力和其他上下文因素的信息纳入预测模型来实现。

第三，目前的模型没有更全面考虑周围环境对行人运动的影响。例如，环境的变化，例如添加新对象或重新排列现有对象，会极大地影响盲人的轨迹。未来的研究应探索将这些信息纳入预测模型的方法，以进一步提高其准确性。

第四，目前的模型没有考虑到可能影响盲人运动的社会和情感因素。例如，其他人的存在或行人的情绪状态会极大地影响他们的轨迹。未来的研究应旨在将这些因素纳入预测模型，以提供更完整和准确的行人运动表示。

第五，未来的工作可能包括探索更先进的深度学习模型，并整合更多信息，如音频和触觉反馈，以提高预测的准确性和可靠性。所提出的模型还可以扩展到其他应用，例如户外行人预测，以改善视力受损个人的可达性和移动性。

室内盲人轨迹预测领域近年来取得了重大进展，但仍有几个领域需要进一步研究。开发更先进、更准确的预测模型将极大地提高盲人的行动能力和独立性。

参考文献

- [1] Simões W C S S, Machado G S, Sales A M A, et al. A review of technologies and techniques for indoor navigation systems for the visually impaired[J]. *Sensors*, 2020, 20(14): 3935-3969.
- [2] Morizane Y, Morimoto N, Fujiwara A, et al. Incidence and causes of visual impairment in Japan: the first nation-wide complete enumeration survey of newly certified visually impaired individuals[J]. *Japanese Journal of Ophthalmology*, 2019, 63(1): 26-33.
- [3] Khan S, Nazir S, Khan H U. Analysis of Navigation Assistants for Blind and Visually Impaired People: A Systematic Review[J]. *IEEE Access*, 2021, 9(1): 1-21.0
- [4] Sammouda R, Alrjoub A. Mobile blind navigation system using RFID[J]. *Computer & Information Technology*, 2015, 1(1): 1-4.
- [5] Makino H, Ishii I, Nakashizuka M. Development of navigation system for the blind using GPS and mobile phone combination[C]//International Conference of the IEEE Engineering in Medicine & Biology Society, IEEE, 1996.
- [6] Guerreiro J, Sato D, Asakawa S, et al. CaBot: Designing and Evaluating an Autonomous Navigation Robot for Blind People[C]//ACM SIGACCESS Conference on Computers and Accessibility, ACM, 2019.
- [7] SerrO M, Rodrigues J, Rodrigues J I, et al. Indoor Localization and Navigation for Blind Persons using Visual Landmarks and a GIS[J]. *Procedia Computer Science*, 2012, 14(1):65-73.
- [8] Real S, Araujo A. Navigation systems for the blind and visually impaired: Past work, challenges, and open problems[J]. *Sensors*, 2019, 19(15): 3404-3418.
- [9] Sobnath D, Rehman I U, Nasralla M M. Smart cities to improve mobility and quality of life of the visually impaired[J]. *Technological Trends in Improved Mobility of the Visually Impaired*, 2020, 1(1): 3-28.
- [10] Caspers M G. Robotic Navigation And Mapping In GPS-Denied Environments With 3D Lidar And Inertial Navigation Utilizing A Sensor Fusion Algorithm[D]. Naval Postgraduate School, 2021.
- [11] Rajeev S, Wan Q, Yau K, et al. Augmented reality-based vision-aid indoor navigation system in GPS denied environment[C]//Mobile Multimedia/Image Processing, Security, and Applications 2019, SPIE, 2019.
- [12] Elloumi W, Latoui A, Canals R, et al. Indoor pedestrian localization with a smartphone: A comparison of inertial and vision-based methods[J]. *IEEE Sensors Journal*, 2016, 16(1): 5376-5388.
- [13] Gupta A, Anpalagan A, Guan L, et al. Deep learning for object detection and scene perception in self-driving cars: Survey, challenges, and open issues[J]. *Array*, 2021, 10(1): 100057.
- [14] Zhang J, Tao D. Empowering things with intelligence: a survey of the progress, challenges, and opportunities in artificial intelligence of things[J]. *IEEE Internet of Things Journal*, 2020, 8(10): 7789-7817.
- [15] Jayakumar J, Nagaraj B, Chacko S, et al. Conceptual implementation of artificial intelligent based E-mobility controller in smart city environment[J]. *Wireless Communications and Mobile Computing*, 2021, 2021(1): 1-8.
- [16] Plikynas D, Indriulionis A, Laukaitis A, et al. Indoor-guided navigation for people who are blind: Crowdsourcing for route mapping and assistance[J]. *Applied Sciences*, 2022, 12(1): 523-537.
- [17] 吴青明. 一种盲人智能导航避障出行辅助方法及系统, CN108743266A[P]. 2018.

- [18] 林子乔, 江源昌, 王荣康, 等. 导航视障用户的方法,用于视障用户的导航系统和引导机器人, CN114578805A[P]. 2022.
- [19] Chen J, Chen C, Xing Z, et al. Unblind your apps: Predicting natural-language labels for mobile gui components by deep learning[C]//Proceedings of the ACM/IEEE 42nd International Conference on Software Engineering, ACM, 2020.
- [20] Hapke H, Howard C, Lane H. Natural Language Processing in Action: Understanding, analyzing, and generating text with Python[M]. Simon and Schuster, 2019.
- [21] Bisk Y, Zellers R, Gao J, et al. Piqa: Reasoning about physical commonsense in natural language[C]//Proceedings of the AAAI conference on artificial intelligence, 2020.
- [22] Gurari D, Zhao Y, Zhang M, et al. Captioning images taken by people who are blind[C]//Computer Vision–ECCV 2020: 16th European Conference, Springer, 2020.
- [23] Real S, Araujo A. Navigation systems for the blind and visually impaired: Past work, challenges, and open problems[J]. Sensors, 2019, 19(15): 3404-3416.
- [24] Afif M, Ayachi R, Said Y, et al. An evaluation of retinanet on indoor object detection for blind and visually impaired persons assistance navigation[J]. Neural Processing Letters, 2020, 51(1): 2265-2279.
- [25] Weninger F, Watanabe S, Tachioka Y, et al. Deep recurrent de-noising auto-encoder and blind de-reverberation for reverberated speech recognition[C]//2014 IEEE International Conference on Acoustics, Speech and Signal Processing, IEEE, 2014.
- [26] Meliones A, Filios C, Llorente J. Reliable ultrasonic obstacle recognition for outdoor blind navigation[J]. Technologies, 2022, 10(3): 54-74.
- [27] Liu Q, Wu S, Wang L, et al. Predicting the next location: A recurrent model with spatial and temporal contexts[C]//Proceedings of the AAAI conference on artificial intelligence, AAAI, 2016.
- [28] Ziebart B D, Ratliff N, Gallagher G, et al. Planning-based prediction for pedestrians[C]//2009 IEEE/RSJ International Conference on Intelligent Robots and Systems, IEEE, 2009.
- [29] Lee N, Choi W, Vernaza P, et al. Desire: Distant future prediction in dynamic scenes with interacting agents[C]//Proceedings of the IEEE conference on computer vision and pattern recognition, IEEE, 2017.
- [30] Lu C L, Liu Z Y, Huang J T, et al. Assistive Navigation Using Deep Reinforcement Learning Guiding Robot With UWB/Voice Beacons and Semantic Feedbacks for Blind and Visually Impaired People[J]. Frontiers in Robotics and AI, 2021, 2021(1): 1-27.
- [31] Habibi G, Jaipuria N, How J P. Context-aware pedestrian motion prediction in urban intersections[J]. arXiv preprint arXiv:1806.09453, 2018.
- [32] Lv Z, Li J, Li H, et al. Blind travel prediction based on obstacle avoidance in indoor scene[J]. Wireless Communications and Mobile Computing, 2021, 2021(1): 1-14.
- [33] Cuayáhuil H, Dethlefs N, Frommberger L, et al. Generating adaptive route instructions using hierarchical reinforcement learning[C]//International Conference on Spatial Cognition, Springer, 2010.
- [34] Klippel A, Hansen S, Richter K F, et al. Urban granularities—a data structure for cognitively ergonomic route directions[J]. GeoInformatica, 2009, 13(1): 223-247.
- [35] Daniele A F, Bansal M, Walter M R. Natural language generation in the context of providing indoor route instructions[C]//Proceedings Robotics: Science and Systems Workshop on Model Learning

- p for Human-Robot Communication, IEEE, 2016.
- [36] Cuayáhuatl H, Dethlefs N, Frommberger L, et al. Generating adaptive route instructions using hierarchical reinforcement learning[C]//International Conference on Spatial Cognition, Springer, 2010.
 - [37] Zhong Y, Chen W, Wang Z, et al. HELAD: A novel network anomaly detection model based on heterogeneous ensemble learning[J]. Computer Networks, 2020, 169(1): 107049.
 - [38] Wang Q, Luo Z H, Huang J C, et al. A novel ensemble method for imbalanced data learning: bagging of extrapolation-SMOTE SVM[J]. Computational intelligence and neuroscience, 2017, 2017(1): 1-24.
 - [39] Engel C, Müller K, Constantinescu A, et al. Travelling more independently: a requirements analysis for accessible journeys to unknown buildings for people with visual impairments[C]//Proceedings of the 22nd International ACM SIGACCESS Conference on Computers and Accessibility, ACM, 2020.
 - [40] Hu M, Chen Y, Zhai G, et al. An overview of assistive devices for blind and visually impaired people[J]. International Journal of Robotics and Automation, 2019, 34(5): 580-598.
 - [41] Butilă E V, Boboc R G. Urban traffic monitoring and analysis using unmanned aerial vehicles (UAVs): A systematic literature review[J]. Remote Sensing, 2022, 14(3): 620-638.
 - [42] Arooj A, Farooq M S, Umer T, et al. Cognitive internet of vehicles and disaster management: a proposed architecture and future direction[J]. Transactions on Emerging Telecommunications Technologies, 2022, 33(8): 3625-3637.
 - [43] Wang S, Cao J, Yu P. Deep learning for spatio-temporal data mining: A survey[J]. IEEE transactions on knowledge and data engineering, 2020, 1(1): 2-26.
 - [44] Zhang X, Sun J, Qi X, et al. Simultaneous modeling of car-following and lane-changing behaviors using deep learning[J]. Transportation research part C: emerging technologies, 2019, 104(1): 287-304.
 - [45] Lv Z, Li Y, Feng H, et al. Deep learning for security in digital twins of cooperative intelligent transportation systems[J]. IEEE transactions on intelligent transportation systems, 2021, 23(9): 16666-16675.
 - [46] Shanker M, Hu M Y, Hung M S. Effect of data standardization on neural network training[J]. Omega, 1996, 24(4): 385-397.
 - [47] Ji Z, Hu W, Wang Z, et al. Seeing through events: Real-time moving object sonification for visually impaired people using event-based camera[J]. Sensors, 2021, 21(10): 3558-3582.
 - [48] Yuan Y, Zhang W, Yang X, et al. Traffic state classification and prediction based on trajectory data[J]. Journal of Intelligent Transportation Systems, 2021, 2021(1): 1-15.
 - [49] Capobianco S, Millefiori L M, Forti N, et al. Deep learning methods for vessel trajectory prediction based on recurrent neural networks[J]. IEEE Transactions on Aerospace and Electronic Systems, 2021, 57(6): 4329-4346.
 - [50] Wang R, Alazzam M B, Alassery F, et al. Innovative research of trajectory prediction algorithm based on deep learning in car network collision detection and early warning system[J]. Mobile information systems, 2021, 2021(1): 1-8.
 - [51] Mäenpää P, Aref M M, Mattila J. FORMI: a fast Holonomic path planning and obstacle representation method based on interval analysis[C]//2019 IEEE International Conference on

- Cybernetics and Intelligent Systems and IEEE Conference on Robotics, Automation and Mechatronics, IEEE, 2019.
- [52] Sharif Razavian A, Azizpour H, Sullivan J, et al. CNN features off-the-shelf: an astounding baseline for recognition[C]//Proceedings of the IEEE conference on computer vision and pattern recognition workshops, IEEE, 2014.
- [53] Cho K, Van Merriënboer B, Gulcehre C, et al. Learning phrase representations using RNN encoder-decoder for statistical machine translation[J]. arXiv preprint arXiv:1406.1078, 2014.
- [54] Abujar S, Masum A K M, Islam M S, et al. A Bengali text generation approach in context of abstractive text summarization using rnn[M]//Innovations in Computer Science and Engineering. Springer, 2020.
- [55] Li J, Zhao R, Hu H, et al. Improving RNN transducer modeling for end-to-end speech recognition[C]//2019 IEEE Automatic Speech Recognition and Understanding Workshop, IEEE, 2019.
- [56] Gers F A, Schmidhuber J, Cummins F. Learning to forget: Continual prediction with LSTM[J]. Neural computation, 2000, 12(10): 2451-2471.
- [57] Dey R, Salem F M. Gate-variants of gated recurrent unit (GRU) neural networks[C]//2017 IEEE 60th international midwest symposium on circuits and systems, IEEE, 2017.
- [58] Graves A, Jaitly N, Mohamed A. Hybrid speech recognition with deep bidirectional LSTM[C]//2013 IEEE workshop on automatic speech recognition and understanding, IEEE, 2013.
- [59] Chen M, Ding G, Zhao S, et al. Reference based LSTM for image captioning[C]//Proceedings of the AAAI conference on artificial intelligence, AAAI, 2017.
- [60] Cui Y, Wang S, Li J. LSTM neural reordering feature for statistical machine translation[J]. arXiv preprint arXiv:1512.00177, 2015.
- [61] Bai S, Kolter J Z, Koltun V. An empirical evaluation of generic convolutional and recurrent networks for sequence modeling[J]. arXiv preprint arXiv:1803.01271, 2018.
- [62] Brazil T J. Causal-convolution-a new method for the transient analysis of linear systems at microwave frequencies[J]. IEEE transactions on microwave theory and techniques, 1995, 43(2): 315-323.
- [63] Wei Y, Xiao H, Shi H, et al. Revisiting dilated convolution: A simple approach for weakly-and semi-supervised semantic segmentation[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, IEEE, 2018.
- [64] Liang G, Zheng L. A transfer learning method with deep residual network for pediatric pneumonia diagnosis[J]. Computer methods and programs in biomedicine, 2020, 187(1): 104964.
- [65] Li W, Zhu X, Gong Harmonious attention network for person re-identification[C]//Proceedings of the IEEE conference on computer vision and pattern recognition, IEEE, 2018.
- [66] Su B, yong Chen H, Chen P, et al. Deep Learning-based Solar-Cell Manufacturing Defect Detection with Complementary Attention Network[J]. IEEE Transactions on Industrial Informatics, 2020, 23(1): 1562-1579.
- [67] Xu K, Ba J, Kiros R, et al. Show, attend and tell: Neural image caption generation with visual attention[C]//International conference on machine learning, PMLR, 2015.
- [68] Sun W, Zhou X. Characterization of local sampling sequences for spline subspaces[J]. Advances in Computational Mathematics, 2009, 30(2): 153-175.

-
- [69] Lv Z, Li J, Dong C, et al. A deep spatial-temporal network for vehicle trajectory prediction[C]//Wireless Algorithms, Systems, and Applications: 15th International Conference, Springer, 2020.
- [70] Shi L, Wang L, Long C, et al. SGCN: Sparse graph convolution network for pedestrian trajectory prediction[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, IEEE, 2021.
- [71] Wang C, Cai S, Tan G. Graphtcn: Spatio-temporal interaction modeling for human trajectory prediction[C]//Proceedings of the IEEE/CVF Winter Conference on Applications of Computer Vision, IEEE, 2021.
- [72] Blukis V, Misra D, Knepper R A, et al. Mapping navigation instructions to continuous control actions with position-visitation prediction[C]//Conference on Robot Learning, PMLR, 2018.
- [73] Haiyun Z, Yizhe X. Sports performance prediction model based on integrated learning algorithm and cloud computing Hadoop platform[J]. microprocessors and microsystems, 2020, 79(1): 103322.
- [74] Cannizzaro D, Aliberti A, Bottaccioli L, et al. Solar radiation forecasting based on convolutional neural network and ensemble learning[J]. Expert Systems with Applications, 2021, 181(1): 115167.
- [75] Nti I K, Adekoya A F, Weyori B A. A comprehensive evaluation of ensemble learning for stock-market prediction[J]. Journal of Big Data, 2020, 7(1): 1-40.